ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHOA ĐIỆN - ĐIỆN TỬ

BÁO CÁO BÀI TẬP LỚN

XÁC SUẤT THỐNG KÊ

ĐỀ TÀI 11:

Phân tích và dự đoán tổng chi phí đặt hàng của một cửa hàng điện tử trực tuyến ở Úc

GVHD: TS. Phan Thị Hường

Nhóm 6 - Lớp: L09

Thành phố Hồ Chí Minh - 2024

Bảng phân chia công việc

Họ và tên	MSSV	Mô tả đóng góp	Chú thích
Vương Gia Khiêm	2311571	Latex, Thống kê suy diễn, Tiền xử lý số liệu	+0.5
Vũ Nhật Huy	2311267	Latex, Thống kê suy diễn, Tiền xử lý số liệu	+0.5
Nguyễn Minh Kha	2311394	Tổng quan dữ liệu	-2
Hà Tuấn Khanh	2311490	Kiến thức nền, Tài liệu tham khảo	+0.25
Đỗ Hoàng Thiên Ân	2310175	Thống kê mô tả	+0.5
Bùi Thị Quỳnh Anh	2310057	Thống kê mô tả	+0.25

Mục lục

Bảng phân chia công việc **2**

I Phần mở đầu **1**

1 Lý do chọn đề tài 1

2 Mục tiêu nghiên cứu 1

3 Nhiệm vụ nghiên cứu 1

4 Phạm vi nghiên cứu 1

II Tổng quan dữ liệu **2**

III Kiến thức nền **2**

1 Thống kê mô tả và thống kê suy diễn 2

1.1 Thống kê mô tả (Descriptive statistics) 2

1.2 Thống kê suy diễn (Inferential statistics) 2

2 Biểu đồ thống kê 3

3 Hồi quy tuyến tính bội 3

3.1 Hàm hồi quy tổng thể (PRF - Population Regression Function) 3

3.2 Hàm hồi quy mẫu (SRF - Sample Regression) Function 4

3.3 Phương pháp bình phương nhỏ nhất 4

3.4 Độ phù hợp của mô hình 4

3.5 Khoảng tin cậy và kiểm định các hệ số hồi quy 5

3.6 Kiểm định mức độ ý nghĩa chung của mô hình (Trường hợp đặc biệt của kiểm định WALD) 6

4 Phân tích phương sai một yếu tố 8

4.1 Lí thuyết về ANOVA (Phân tích phương sai) 8

4.2 Phân tích phương sai một yếu tố 8

IV Tiền xử lý số liệu **9**

1 Đọc dữ liệu 9

2 Làm sạch dữ liệu 10

V Thống kê mô tả **12**

1 Thống kê mô tả cho các biến định lượng 12

2 Thống kê số lượng cho các biến phân loại 12

3 Mô tả dữ liệu bằng đồ thị 14

3.1 Đồ thị Histogram 14

3.2 Đồ thị Boxplot 16

3.3 Đồ thị Scatter/Plot 19

VI Thống kê suy diễn **21**

1 Anova một nhân tố: So sánh tổng chi phí đặt hàng theo mùa 21
2 Hồi quy đa biến: Phân tích các yếu tố dự báo tổng chi phí đặt hàng phụ thuộc vào những biến nào 26

VII Thảo luận **29**

VIII Nguồn dữ liệu và nguồn code **30**

Tài liệu tham khảo **31**

I Phần mở đầu

1 Lý do chọn đề tài

Trong bối cảnh kinh tế hiện đại, các cửa hàng bán lẻ, đặc biệt là cửa hàng điện tử, đối mặt với sự cạnh tranh gay gắt và biến động không ngừng của thị trường. Để tồn tại và phát triển, các cửa hàng cần không chỉ hiểu rõ nhu cầu của khách hàng mà còn tối ưu hóa mọi khía cạnh trong hoạt động kinh doanh, từ quản lý hàng tồn kho, lên kế hoạch bán hàng, đến đánh giá hiệu quả của các chiến dịch tiếp thị.

Trên cơ sở đó, đề tài "Thống kê dữ liệu về doanh số bán lẻ của một cửa hàng điện tử" được nhóm tác giả lựa chọn nhằm nghiên cứu sâu hơn về cách mà dữ liệu doanh số có thể cung cấp thông tin quan trọng cho việc ra quyết định kinh doanh. Thông qua phân tích thống kê dữ liệu bán hàng, cửa hàng có thể nhận diện các xu hướng tiêu dùng và đánh giá hiệu quả các hoạt động khuyến mãi. Điều này giúp cung cấp cái nhìn toàn diện về sức khỏe tài chính của cửa hàng.

2 Mục tiêu nghiên cứu

Mục tiêu của bài tập lớn này là tìm hiểu sâu hơn về các nguyên tắc cơ bản và ứng dụng của lý thuyết thống kê dựa trên dữ liệu về doanh số bán lẻ của một cửa hàng điện tử. Bên cạnh đó, việc nghiên cứu đề tài còn giúp chúng ta cải thiện kỹ năng đọc dữ liệu, làm sạch dữ liệu và phân tích dữ liệu vào thực tiễn cũng như cải thiện kĩ năng tư duy logic.

3 Nhiệm vụ nghiên cứu

Đầu tiên, ta sẽ nhập dữ liệu vào môi trường R từ nguồn cung cấp, có thể từ file CSV và file Excel . Mục tiêu là ta làm quen với cấu trúc của dữ liệu và đảm bảo dữ liệu đã được tải đúng và đầy đủ.

Tiếp theo, những dữ liệu khuyết sẽ được xử lý (NA) hoặc các giá trị không hợp lệ, đảm bảo tính chính xác và sẵn sàng của dữ liệu cho phân tích.

Các biến dữ liệu sẽ được chuyển đổi (như log-transform, chuẩn hóa hoặc chuẩn hóa lại loại dữ liệu) để đảm bảo phù hợp với các phân tích thống kê tiếp theo.

Hơn nữa, Thống kê mô tả sẽ được thực hiện để hiểu rõ các đặc điểm cơ bản của dữ liệu. Chúng tôi sẽ sử dụng cả các thống kê mẫu (như trung bình, độ lệch chuẩn) và biểu đồ để trình bày các thông tin quan trọng từ dữ liệu.

Toàn bộ các bước thực hiện trong nghiên cứu sẽ được nhóm tác giả triển khai bằng ngôn ngữ R. Các đoạn mã sẽ được chú thích cẩn thận, giúp minh bạch hóa quá trình phân tích, cũng như đảm bảo khả năng tái lập kết quả cho những người đọc có nhu cầu tìm hiểu sâu hơn.

4 Phạm vi nghiên cứu

Phạm vi về mặt thời gian: Đề tài tập trung nghiên cứu về hoạt động bán hàng trong năm 2019. Khoảng thời gian một năm được lựa chọn nhằm cung cấp cái nhìn tổng quát và chi tiết về xu hướng doanh số, bao gồm các giai đoạn cao điểm như dịp lễ Tết và các chương trình khuyến mãi lớn trong năm.

II Tổng quan dữ liệu

Dữ liệu này chứa thông tin về một cửa hàng điện tử trực tuyến. Cửa hàng có ba kho hàng dùng để giao hàng. (CHỈNH LẠI CÂU MỞ ĐẦU NÀY)

Tên biến	Đơn vị	Loại biến	Mô tả
`order_id`	ORDxxxxxx	Biến phân loại	ID của mỗi đơn hàng
`customer_id`	IDzzzzzzzzzz	Biến phân loại	ID của mỗi khách hàng
`Date`	YYY-MM-DD	Biến phân loại	Thời gian đặt hàng
`shopping_cart`	-	Biến phân loại	Dữ liệu đại diện cho các mục đặt hàng
`nereast_warehouse`	-	Biến phân loại	Cửa hàng gần với khách hàng nhất
`order_price`	USD	Biến liên tục	Giá đơn hàng ban đầu
`order_total`	USD	Biến liên tục	Tổng chi phí đặt hàng đã bao gồm phí vận chuyển và các giảm giá
`season`	-	-	Mùa và đơn hàng được đặt
`delivery_charges`	USD	Biến liên tục	Chi phí vận chuyển
`customer_lat`	-	Biến liên tục	Vĩ độ vị trí của khách hàng
`customer_long`	-	Biến liên tục	Kinh độ vị trí của khách hàng
`is_expedited_delivery`	-	Biến phân loại	Khách hàng có hay không yêu cầu giao hàng nhanh
`distance_to_nearest_warehouse`	km	-	Khoảng cách đến kho hàng gần nhất
`coupon_discount`	percent	Biến liên tục	Phần trăm giảm giá được áp dụng vào `order_price`
`is_happy_customer`	-	Biến phân loại	Mức độ hài lòng của khách hàng
latest_customer_review	-	Biến phân loại	Đánh giá mới nhất của khách hàng

Mục tiêu phân tích:

- So sánh tổng chi phí đặt hàng ở các mùa.
- Thực hiện dự báo tổng chi phí đặt hàng phụ thuộc vào những biến nào.

III Kiến thức nền

1 Thống kê mô tả và thống kê suy diễn

1.1 Thống kê mô tả (Descriptive statistics)

Thống kê mô tả là quá trình mà ta:

- Thu thập dữ liệu: Xác định mục tiêu nghiên cứu và thu thập thông tin tương ứng.
- Tổng hợp và xử lý dữ liệu: tính các tham số mẫu như trung bình mẫu (sample mean), phương sai mẫu (sample variance), trung vị (median),...
- Phân tích phân phối: phân tích hình dáng phân phối, các điểm ngoại lai và đánh giá mức độ phân tán của dữ liệu.

1.2 Thống kê suy diễn (Inferential statistics)

Ta xử lý các thông tin có được từ thống kê mô tả, từ đó đưa ra các cơ sở cho những dự đoán (predictions), dự báo (forecasts) và các ước lượng (estimations).

- Ước lượng: tham số thống kê (trung bình, tỷ lệ, phương sai).
- Kiểm định giả thuyết: tham số thống kê (trung bình, tỷ lệ, phương sai), quy luật phân phối xác suất (chuẩn, poisson,...), tính độc lập,...

2 Biểu đồ thống kê

Biểu đồ thống kê là công cụ trực quan giúp ta hiển thị và mô tả các đặc trưng cơ bản của dữ liệu như trung bình cộng, độ lệch chuẩn, giá trị lớn nhất, giá trị nhỏ nhất:

- **Biểu đồ Histogram**: Phân tích sự phân bố tần số, thể hiện trực quan tính đối xứng của dữ liệu, phân tích về sự thay đổi theo thời gian.
- **Biểu đồ Boxplot**: Thể hiện 5 vị trí phân bố của dữ liệu gồm giá trị nhỏ nhất, tứ phân vị thứ nhất (Q1), trung vị (median), tứ phân vị thứ ba (Q3), và giá trị lớn nhất. Biểu đồ này giúp ta nhận diện sự phân tán và các điểm ngoại lai.
- **Biểu đồ Tán xạ**: Dùng để tìm hiểu mối quan hệ giữa hai biến dữ liệu, đặc biệt là trong việc xác định xu hướng và mức độ tương quan giữa chúng.
- **Ma trận tương quan**: Đo lường mối liên hệ giữa hai biến thông qua hệ số tương quan (r). Hệ số tương quan có giá trị từ -1 đến 1, giúp xác định mức độ mạnh yếu và hướng của mối quan hệ giữa các biến.

3 Hồi quy tuyến tính bội

Mô hình hồi quy tuyến tính bộ có dạng tổng quát như sau:

$$Y = \beta_1 + \beta_2 X_2 + \beta_3 X_3 + ... \beta_k X_k + u$$

Trong đó:

+ Y: Biến phụ thuộc.

+ X_i: Biến độc lập.

+ β_1: Hệ số tự do (hệ số chặn).

+ β_i: Hệ số hồi quy riêng.

Như vậy, "Hồi quy tuyến tính" là một phương pháp để ta có thể dự đoán giá trị của biến phụ thuộc (Y) dựa trên giá trị của biến độc lập (X).

Phân tích hồi quy thường được chúng ta sử dụng trong các hoạt động về khoa học - kỹ thuật, y học, kinh tế - xã hội, ... ta có nhu cầu xác định mối liên giữa hai hay nhiều biến ngẫu nhiên với nhau. **Ví dụ**: Mối liên hệ giữa chiều cao và cỡ giày của một người, từ đó một cửa hàng bán giầy dép có thể xác định chính xác cỡ giầy của một khách hàng khi biết chiều cao...

3.1 Hàm hồi quy tổng thể (PRF - Population Regression Function)

Với Y là biến phụ thuộc X_2, X_3,...,X_k là biến độc lập, Y là ngẫu nhiên và có một phân phối xác suất nào đó.

Suy ra: Tồn tại $E(Y|X_2, X_3,..., X_k)$ = giá trị xác định.

Do vậy, $F(X_2, X_3,...,X_k) = E(Y|X_2, X_3,..., X_k)$ là hàm hồi quy tổng thể của Y theo X_2, X_3,..., X_k.

Với một cá thể i tồn tại ($X_{2,i}$, $X_{3,i}$,...,$X_{k,i}$,Y_i).

Ta có: $Y_i \neq F\ (X_2, X_3,...,X_k) \Rightarrow u_i = Y_i$ - F.

Do vậy: $Y_i = E(Y|X_2, X_3,..., X_k) + u_i$.

Hồi quy tổng thể PRF:

- $Y = E(Y|X) = + U$
- $E(Y|X) = F(X)$

3.2 Hàm hồi quy mẫu (SRF - Sample Regression) Function

Trong thực tế, hiếm khi chúng ta có được dữ liệu về tổng thể, vì vậy không thể xác định được giá trị trung bình tổng thể của biến phụ thuộc đúng ở mức độ nào. Do vậy cần phải dựa vào dữ liệu mẫu để ước lượng. Trên một mẫu có n cá thể, gọi $\hat{Y} = \hat{F}(X_2, X_3, \ldots, X_k)$ là hồi quy mẫu. Với một cá thể mẫu, $Y_i \neq \hat{F}(X_2, X_3, \ldots, X_k)$ sinh ra $e_i = Y_i - \hat{F}(X_2, X_3, \ldots, X_k)$, với e_i là phần dư SRF. Ta có hàm hồi quy mẫu tổng quát có dạng như sau:

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_{2,i} + \hat{\beta}_3 x_{3,i} + \cdots + \hat{\beta}_k x_{k,i}$$

3.3 Phương pháp bình phương nhỏ nhất

Trong khi xây dựng mô hình hồi quy đa biến ta cần kiểm tra các giả thiết như sau:

1. Hàm hồi quy là tuyến tính theo các tham số.

   Điều này có nghĩa là quá trình thực hành hồi quy trên thực tế được miêu tả bởi mối quan hệ dưới dạng:
   $$y = \beta_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \cdots + \beta_k x_k + u$$
   hoặc mối quan hệ thực tế có thể được viết lại ví dụ như dưới dạng lấy loga cả hai vế.

2. Kỳ vọng của các yếu tố ngẫu nhiên u_i bằng 0.

   Trung bình tổng thể sai số là bằng 0. Điều này có nghĩa là có một số giá trị sai số mang dấu dương và một số sai số mang dấu âm. Do hàm xem như là đường trung bình nên có thể giả định rằng các sai số ngẫu nhiên trên sẽ bị loại trừ nhau, ở mức trung bình, trong tổng thể.

3. Các sai số độc lập với nhau.

4. Các sai số có phương sai bằng nhau.
   Tất cả giá trị u_i được phân phối giống nhau với cùng phương sai σ^2, sao cho:
   $$\mathrm{Var}(u_i) = E(u_i^2) = \sigma^2.$$

5. Các sai số có phân phối chuẩn.
   Điều này rất quan trọng khi phát sinh các bài thực hiện kiểm định giả thuyết trong những phạm vi mẫu là nhỏ. Nhưng nếu mẫu là lớn hơn, điều này trở nên không mấy quan trọng.

3.4 Độ phù hợp của mô hình

Để có thể biết được mô hình giải thích được như thế nào hay xác định độ biến động của các biến phụ thuộc, người ta sử dụng R^2 Ta có:

$$\sum (y_i - \bar{y})^2 = \sum [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 = \sum [e_i + (\hat{y}_i - \bar{y})]^2$$

$$= \sum e_i^2 + 2\sum e_i(\hat{y}_i - \bar{y}) + \sum (\hat{y}_i - \bar{y})^2$$

Đặt:

- TSS $= \sum (y_i - \bar{y})^2$: Tổng bình phương của tất cả các sai lệch giữa các giá trị quan sát Y_i và giá trị trung bình.

- ESS = $\sum(\hat{y}_i - \bar{y})^2$: Tổng bình phương của tất cả các sai lệch giữa các giá trị của biến phụ thuộc Y nhận được từ hàm hồi quy mẫu và các giá trị trung bình của chúng.

- RSS = $\sum e_i^2$: Tổng bình phương của tất cả các sai lệch giữa các giá trị quan sát Y và các giá trị nhận được từ hàm hồi quy.

Đặt: Do $\sum e_i(\hat{y}_i - \bar{y}) = 0$ ($\sum e_i\hat{y}_i = 0$; $\sum e_i\bar{y} = 0$) nên ta viết lại thành:

$$\text{TSS} = \text{ESS} + \text{RSS}$$

Khi đó R^2 được xác định bởi công thức:

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}} \quad (0 \leq R^2 \leq 1)$$

Từ biểu thức của R^2, chúng ta thấy R^2 đo tỷ lệ hay số phần trăm của toàn bệ sai lệch Y với giá trị trung bình được giải thích bằng mô hình. Do đó R^2 được sử dụng để đo sự phù hợp của hàm hồi quy.

- Nếu R^2 cao nghĩa là mô hình ước lượng giải thích được một mức độ cao biến động của biến phụ thuộc.

- Nếu R^2 bằng 0 nghĩa là mô hình không đưa ra được thông tin nào về sự thay đổi của biến phụ thuộc và dự đoán tốt nhất về giá trị của biển phụ thuộc là giá trị trung bình.

- Nếu $R^2 = 1$ nghĩa là 100% sự thay đổi của biến phụ thuộc được giải thích bởi các biến độc lập trong mô hình.

3.5 Khoảng tin cậy và kiểm định các hệ số hồi quy

a. Ước lượng khoảng tin cậy đối với các hệ số hồi quy

Mục đích của phân tích hồi quy không phải chỉ suy đoán về các hệ số hồi quy riêng β_1,β_2,...,β_k mà còn kiểm tra bản chất của sự phụ thuộc. Do đó cần phải biết phân bố xác suất của β_1,β_2,...,β_k. Các phân bố này phụ thuộc vào phân bố của các sai số u_i.
Từ các giả thiết của OLS, u_i có phân phối chuẩn $N(0;\sigma^2)$. Các hệ số ước lượng tuân theo phân phối chuẩn:

$$\hat{\beta}_j \sim N\left(\beta_j, \text{Se}(\hat{\beta}_j)\right)$$

$$\frac{\hat{\beta}_j - \beta_j}{\text{Se}(\hat{\beta}_j)} \sim T(n-k)$$

Ước lượng phương sai sai số dựa vào các phần dư bình phương tối thiểu. Trong đó k là số hệ số trong phương trình hồi quy đa biến:

$$\hat{\sigma}^2 = \frac{\sum e_i^2}{n-k}$$

+ Ước lượng 2 phía, ta tìm được $\frac{\alpha}{2}$ thỏa mãn:

$$P\left(-t_{\frac{\alpha}{2}}(n-k) \leq \frac{\hat{\beta}_j - \beta_j}{\text{Se}(\hat{\beta}_j)} \leq t_{\frac{\alpha}{2}}(n-k)\right) = 1 - \alpha$$

+ Khoảng tin cậy $1-\alpha$ của β_j là:

$$\left[\hat{\beta}_j - t_{\frac{\alpha}{2}}(n-k)\text{Se}(\hat{\beta}_j);\ \hat{\beta}_j + t_{\frac{\alpha}{2}}(n-k)\text{Se}(\hat{\beta}_j)\right]$$

b. Kiểm định giả thiết đối với β_j

Kiểm định ý nghĩa thống kê của các hệ số hồi quy có ý nghĩa hay không tức là kiểm định rằng các biến giải thích có thực sự ảnh hưởng đến biến phụ thuộc hay không. Nói cách khác là hệ số hồi quy có ý nghĩa hay không.

Có thể đưa ra giả thiết nào đó đối với β_j, chẳng hạn $\beta_j = \beta_j^*$. Nếu giả thiết đúng thì:

$$T = \frac{\hat{\beta}_j - \beta_j^*}{\text{Se}\left(\hat{\beta}_j\right)} \sim T(n-k)$$

Ta có bảng sau:

Bảng 1: Bảng tóm tắt giả thuyết và miền bác bỏ tương ứng

Loại giả thuyết	**Giả thuyết H_0**	**Giả thuyết đối H_1**	**Miền bác bỏ**
Hai phía	$\beta_1 = \beta_i^*$	$\beta_i \neq \beta_i^*$	$\lvert t\rvert > t_{\alpha/2;n-k}$
Phía phải	$\beta_1 \leq \beta_i^*$	$\beta_i > \beta_i^*$	$t > t_{\alpha;n-k}$
Phía trái	$\beta_1 \geq \beta_i^*$	$\beta_1 < \beta_i^*$	$t < -t_{\alpha;n-k}$

Ta có thể sử dụng giá trị P-value: P-value < mức ý nghĩa thì bác bỏ giả thuyết H_0.

Kiểm định β_j:

- Giả thuyết H_0: $\beta_j = 0 \Leftrightarrow x_j$ không tác động
- Giả thuyết H_1: $\beta_j \neq 0 \Leftrightarrow x_j$ có tác động
- $\beta_j < 0 \Leftrightarrow x_j$ có tác động ngược
- $\beta_j > 0 \Leftrightarrow x_j$ có tác động thuận

3.6 Kiểm định mức độ ý nghĩa chung của mô hình (Trường hợp đặc biệt của kiểm định WALD)

a. Khái quát về kiểm định WALD

Giả sử chúng ta có 2 mô hình dưới đây:

$$(U): Y = \beta_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + u$$

$$(R): Y = \beta_1 + \beta_2 X_2 + v$$

Mô hình U được gọi là mô hình không giới hạn (Unrestrict), và mô hình R được gọi là mô hình giới hạn (Restrict). Đó là do β_3 và β_4 buộc phải bằng 0 trong mô hình R. Ta có thể kiểm định giả thuyết liên kết $\beta_3 = \beta_4 = 0$, với ít nhất một trong những hệ số này không bằng 0. Kiểm định giả thuyết liên kết này được gọi là kiểm định Wald, thủ tục như sau.

Đặt các mô hình giới hạn và không giới hạn là:

$$(U): Y = \beta_1 + \beta_2 X_2 + \cdots + \beta_m X_m + \beta_{m+1} X_{m+1} + \cdots + \beta_k X_k + u$$

$$(R): Y = \beta_1 + \beta_2 X_2 + \cdots + \beta_m X_m + v$$

Mô hình (R) có được bằng cách bỏ bớt một số biến ở mô hình (U), đó là: $X_{m+1}, X_{m+2}, \ldots, X_k$.

Giả thuyết:

$$H_0 : \beta_{m+1} = \cdots = \beta_k = 0$$

$$H_1 : \text{“Không phải đồng thời các tham số bằng 0”}.$$

Lưu ý rằng (U) chứa k hệ số hồi quy chưa biết và (R) chứa m hệ số hồi quy chưa biết. Do đó, mô hình R có ít hơn $(k-m)$ thông số so với U. Câu hỏi chúng ta nêu ra là $(k-m)$ biến bị loại ra có ảnh hưởng liên kết có ý nghĩa đối với Y hay không.

Trị thống kê kiểm định đối với giả thiết này là:

$$F_c = \frac{[RSS_R - RSS_U]/(k-m)}{RSS_U/(n-k)} \sim F(\alpha, k-m, n-k)$$

Hoặc:

$$F_c = \frac{R_U^2 - R_R^2}{(k-m)} \Big/ \frac{1 - R_U^2}{(n-k)}$$

Với R^2 là độ đo thích hợp không hiệu chỉnh. Với giả thuyết không, F_c có phân phối F với $(k-m)$ bậc tự do đối với tử số và $(n-k)$ bậc tự do đối với mẫu số.

Bác bỏ giả thuyết H_0 khi:

$$F_c > F(\alpha, k-m, n-k)$$

Hoặc giá trị p-value của thống kê F_c nhỏ hơn mức ý nghĩa cho trước.

b. Kiểm định ý nghĩa của mô hình.

Trong mô hình hồi quy đa biến, giả thuyết “không” cho rằng mô hình không có ý nghĩa được hiểu là tất cả các hệ số hồi quy riêng đều bằng 0.

Ứng dụng kiểm định Wald (thường được gọi là kiểm định F) được tiến hành cụ thể như sau:

Bước 1: Giả thuyết $H_0 : \beta_2 = \beta_3 = \cdots = \beta_k = 0$.
Giả thuyết H_1: “Có ít nhất một trong những giá trị β khác không”.

Bước 2: Trước tiên hồi quy Y theo một số hạng không đổi và $X_2, X_3, \ldots, X_k$, sau đó tính tổng bình phương sai số RSS_U, RSS_R. Phân phối F là tỷ số của hai biến ngẫu nhiên phân phối khi bình phương độc lập. Điều này cho ta trị thống kê:

$$F_c = \frac{[RSS_R - RSS_U]/(k-m)}{RSS_U/(n-k)} \sim F(\alpha, k-m, n-k)$$

Vì $H_0 : \beta_2 = \beta_3 = \cdots = \beta_k = 0$, nhận thấy rằng trị thống kê kiểm định đối với giả thuyết này sẽ là:

$$F_c = \frac{ESS/(k-1)}{RSS/(n-k)} \sim F(\alpha, k-1, n-k)$$

Bước 3: Tra số liệu trong bảng F tương ứng với bậc tự do $(k-1)$ cho tử số và $(n-k)$ cho mẫu số, với mức ý nghĩa α cho trước.

Bước 4: Bác bỏ giả thuyết H_0 nếu $F_c > F(\alpha, k-1, n-k)$.
Đối với phương pháp giá trị p-value, giả thuyết H_0 bị bác bỏ nếu $P(F > F_c \mid H_0) < \alpha$, hoặc nói cách khác nếu giá trị p nhỏ hơn mức ý nghĩa.

4 Phân tích phương sai một yếu tố

4.1 Lí thuyết về ANOVA (Phân tích phương sai)

Mục tiêu của phân tích phương sai (Analysis of Variance - ANOVA) là so sánh trung bình của nhiều nhóm (tổng thể) dựa trên các trị trung bình của các mẫu quan sát từ các nhóm này và thông qua kiểm định giả thuyết của kết luận về sự bằng nhau của các trung bình tổng thể này.

Ta có các mô hình phân tích phương sai: phân tích phương sai một yếu tố và hai yếu tố. Cụm từ yếu tố ở đây ám chỉ số lượng yếu tố nguyên nhân ảnh hưởng đến yếu tố kết quả đang nghiên cứu.

4.2 Phân tích phương sai một yếu tố

Phân tích phương sai một yếu tố là phân tích ảnh hưởng của một yếu tố nguyên nhân (dạng biến định tính) đến một yếu tố kết quả (dạng biến định lượng) đang nghiên cứu.
Giả sử cần so sánh số trung bình của k tổng thể độc lập trên những mẫu ngẫu nhiên và độc lập n_1,n_2,...,n_k quan sát từ k tổng thể này. Cần ghi nhớ ba giả định sau đây để được tiến hành phân tích Anova:

- Các tổng thể này có phân phối chuẩn.
- Các phương sai của tổng thể bằng nhau.
- Các quan sát được lấy mẫu là độc lập

Nếu trung bình của các tổng thể được ký hiệu là $\mu_1 = \mu_2 = \cdots = \mu_k$ thì khi các giả định trên được đáp ứng, mô hình phân tích phương sai một yếu tố ảnh hưởng được mô tả dưới dạng kiểm định giả thuyết như sau:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$$

Và giả thuyết đối là:

$$H_1 : \text{Tồn tại ít nhất một cặp trung bình tổng thể khác nhau.}$$

Các bước thực hiện:
Bước 1: Tính trung bình mẫu của các nhóm $\bar{x}_1, \bar{x}_2, \ldots, \bar{x}_k$ theo công thức:

$$\bar{x}_i = \frac{\sum_{j=1}^{n_i} x_{ij}}{n_i}, \quad (i = 1, 2, \ldots, k)$$

Trung bình chung của k mẫu được tính theo công thức:

$$\bar{x} = \frac{\sum_{i=1}^{k} n_i \bar{x}_i}{\sum_{i=1}^{k} n_i}, \quad (i = 1, 2, \ldots, k)$$

Bước 2: Tính tổng các chênh lệch bình phương (tổng bình phương):

- **Tổng các độ lệch bình phương trong nội bộ nhóm (SSW):**

$$SSW = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2$$

- **Tổng các độ lệch bình phương giữa các nhóm (SSB):**

$$SSB = \sum_{i=1}^{k} n_i(\bar{x}_i - \bar{x})^2$$

- **Tổng các độ lệch bình phương của toàn bộ tổng thể (SST):**

$$SST = SSW + SSB = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(x_{ij} - \bar{x})^2$$

Bước 3: Tính các phương sai: **Bước 3:** Tính các phương sai:

$$MSW = \frac{SSW}{n-k} \quad \text{và} \quad MSB = \frac{SSB}{k-1}$$

Bước 4: Tính thống kê kiểm định:

$$F = \frac{MSB}{MSW}$$

Bước 5: Xác định miền bác bỏ của bài toán:

$$RR = (F_{\alpha;k-1;N-k}, +\infty)$$

Tìm giá trị $F_{\alpha;k-1;N-k}$: tra bảng Fisher mức ý nghĩa α ở cột $k-1$ và dòng $N-k$.

Bước 6: Đưa ra kết luận:

- Nếu $F > F_{\alpha;k-1;N-k} \iff F \in RR \implies$ Bác bỏ H_0, chấp nhận H_1.
- Nếu $F < F_{\alpha;k-1;N-k} \iff F \notin RR \implies$ Không bác bỏ H_0 (chưa bác bỏ được H_0, chấp nhận H_0).

Bảng 2: Bảng mô hình phân tích phương sai một nhân tố:

Nguồn biến thiên	**SS**	**df**	**MS**	**F**
Giữa các nhóm	SSB	$k-1$	MSB	$F = \frac{MSB}{MSW}$
Trong nội bộ nhóm	SSW	$n-k$	MSW	$F = \frac{MSB}{MSW}$
Toàn bộ	SST	$n-1$		$F = \frac{MSB}{MSW}$

IV Tiền xử lý số liệu

1 Đọc dữ liệu

Đầu tiên, ta tiến hành đọc tệp tin "dirty_data.csv" vào RStudio với dữ liệu được lấy từ Kaggle và kiểm tra một số thông tin về tệp tin với câu lệnh chính được sử dụng là **text.csv**(**Code**[**1**]→[**2**]).

```
Console   Terminal
R 4.4.2 · D:/BTL/
> dirty_data <- read.csv("D:/BTL/dirty_data.csv")
> str(dirty_data)
'data.frame':   500 obs. of  16 variables:
 $ order_id                   : chr  "ORD182494" "ORD395518" "ORD494479" "ORD019224" ...
 $ customer_id                : chr  "ID6197211592" "ID0282825849" "ID0579391891" "ID4544561904"
...
 $ date                       : chr  "2019-06-22" "2019-12-29" "2019-03-02" "2019-01-12" ...
 $ nearest_warehouse          : chr  "Thompson" "Thompson" "Nickolson" "Nickolson" ...
 $ shopping_cart              : chr  "[('Lucent 330S', 1), ('Thunder line', 2), ('iStream', 2), ('p
earTV', 1)]" "[('Thunder line', 1), ('Universe Note', 2)]" "[('Thunder line', 1), ('pearTV', 2)]" "
[('Universe Note', 1), ('Alcon 10', 2), ('Olivia x460', 1), ('iAssist Line', 1)]" ...
 $ order_price                : int  12200 9080 10670 24800 9145 7810 13700 7960 25390 13320 ...
 $ delivery_charges           : num  79.9 62.7 65.9 57.6 75.5 ...
 $ customer_lat               : num  -37.8 -37.8 -37.8 -37.8 37.8 ...
 $ customer_long              : num  145 145 145 145 145 ...
 $ coupon_discount            : int  10 0 10 15 25 10 5 5 10 15 ...
 $ order_total                : num  11060 9143 9669 21138 6934 ...
 $ season                     : chr  "Winter" "Summer" "Autumn" "Summer" ...
 $ is_expedited_delivery      : chr  "True" "False" "False" "False" ...
 $ distance_to_nearest_warehouse: num  1.28 1.162 1.095 0.857 0.587 ...
 $ latest_customer_review     : chr  "perfect phone and trusted seller. phone itself is amazing. i
got this phone as shown here on the description. i"| __truncated__ "it keeps dropping calls the wifi
don't work this is a waste of money this phone is worthless, it keeps dropping"| __truncated__ "five
stars this is a great cheap phone." "charger did not fit the charger didn't fit." ...
 $ is_happy_customer          : chr  "True" "False" "True" "False" ...
>
```

Hình 1: Kết quả khi kiểm tra một số thông tin về tệp tin

Nhận xét: Hình 1 Nhìn vào bảng ta thấy được dữ liệu được nạp vào tệp giống với các biến trong phần tổng quan về dữ liệu bao gồm 16 biến và 500 quan trắc.

2 Làm sạch dữ liệu

Ta tiến hành tạo tệp tin con bao gồm 11 biến bao gồm biên liên tục và biến phân loại cần phân tích để xem xét sự ảnh hưởng của biến order_total với 11 biến trên và xem 10 dòng đầu. Những biến đó bao gồm order_total, order_price, delivery_charges, coupon_discount, season, is_expedited_delivery, is_happy_customer, distance_to_nearest_warehouse, customer_lat và customer_long (**Code**[4]→[6]).

```
> head(new_data ,10)
   order_total order_price delivery_charges coupon_discount season is_expedited_delivery is_happy_customer
1     11059.89       12200            79.89              10 Winter                  True              True
2      9142.71        9080            62.71               0 Summer                 False             False
3      9668.87       10670            65.87              10 Autumn                 False              True
4     21137.61       24800            57.61              15 Summer                 False             False
5      6934.29        9145            75.54              25 Spring                 False              True
6      7100.22        7810            71.22              10 Spring                 False             False
7     13089.84       13700            74.84               5 Spring                 False              True
8     10789.79        7960            52.28               5 Autumn                 False             False
9     22958.58       25390           107.58              10 Spring                  True              True
10    11384.26       13320            62.26              15 winter                  True             False
   distance_to_nearest_warehouse nearest_warehouse customer_lat customer_long
1                         1.2800          Thompson    -37.81511      144.9328
2                         1.1621          Thompson    -37.80274      144.9511
3                         1.0949         Nickolson    -37.82130      144.9576
4                         0.8571         Nickolson    -37.81142      144.9731
5                         0.5867         Nickolson     37.82386      144.9699
6                         2.0752            Bakers     37.82025      145.0149
7                         0.6767          Thompson    -37.80774      144.9516
8                         1.3043          Thompson    -37.80634      144.9595
9                         1.6595            Bakers    -37.81081      145.0141
10                        0.6093          Thompson    -37.80868      144.9423
>
```

Hình 2: Kết quả khi kiểm tra một số thông tin về tệp tin

Sau đó, ta cần kiểm tra những dữ liệu bị khuyết với lệnh chính **head** để kết quả sau khi phân tích dữ liệu được chính xác hơn (**Code**[7]→[9]).

```
> apply(is.na(new_data), 2, which)
integer(0)
```

Hình 3: Kết quả khi kiểm tra dữ liệu khuyết

Nhận xét: Hình 3 Sau khi kiểm tra, ta thấy được tệp không có dữ liệu khuyết. Sau đó, ta tiến hành kiểm tra biến season (**Code[10]**).

```
> unique(new_data$season)
[1] "Winter" "Summer" "Autumn" "Spring" "winter" "spring" "autumn" "summer"
>
```

Hình 4: Kết quả khi kiểm tra biến season

Nhận xét: Hình 4 Kết quả kiểm tra cho thấy biến có lỗi định dạng, ta thực hiện thay các giá trị "spring" = "Spring", "summer" = "Summer", "autum" = "Autum", "winter" = "Winter" bằng hàm gán và kiểm tra kết quả (**Code[12]→[16]**).

```
> new_data$season[new_data$season == 'spring'] = 'Spring'
> new_data$season[new_data$season == 'summer'] = 'Summer'
> new_data$season[new_data$season == 'autumn'] = 'Autumn'
> new_data$season[new_data$season == 'winter'] = 'Winter'
> unique(new_data$season)
[1] "Winter" "Summer" "Autumn" "Spring"
>
```

Hình 5: Kết quả khi kiểm tra lại các giá trị của season.

Nhận xét: Hình 5 Như vậy, sau khi thay các giá trị của biến season ta thấy được biến season đã cho ra định dạng như ta mong muốn. Ta tiếp tục nhận thấy biến season và date đang có sự sai lệch với nhau. Ngoài ra, ta nhận thấy được định dạng của ngày-tháng-năm đang không được đồng nhất. Ta điều chỉnh định dạng của ngày-tháng-năm thành %Y-%m-%d và điều chỉnh season theo đúng với ngày bằng lệnh điều kiện (**ifelse**) và hàm gán. Ví dụ: tháng 6 là mùa hè (Summer) nhưng trong dữ liệu lại là mùa xuân (Spring) (**Code[18]→[21]**).

11059.89	12200	79.89	10	Summer
9142.71	9080	62.71	0	Winter
9668.87	10670	65.87	10	Spring
21137.61	24800	57.61	15	Winter
6934.29	9145	75.54	25	Autumn
7100.22	7810	71.22	10	Autumn
13089.84	13700	74.84	5	Autumn
10789.79	7960	52.28	5	Spring
22958.58	25390	107.58	10	Autumn
11384.26	13320	62.26	15	Spring
31973.25	31895	78.25	0	Summer
10464.79	13850	77.29	25	Winter
926057.25	19010	94.75	0	Winter
19785.64	19710	75.64	0	Winter
31979.78	31900	79.78	0	Spring
15196.35	20200	46.35	25	Spring
11188.19	14810	80.69	25	Summer
1304.52	1655	63.27	25	Summer
6268.89	6535	60.64	5	Winter

Hình 6: Kết quả khi kiểm tra và điều chỉnh lại season theo date.

Nhận xét: Hình 6: Như vậy, kết quả của giá trị season theo biến date cho ra đã đúng định dạng mà ta mong muốn. Tiếp tục, ta kiểm tra biến nearest_warehouse (**Code[23]**).

```
> unique(new_data$nearest_warehouse)
[1] "Thompson"  "Nickolson" "Bakers"    "nickolson" "thompson"
>
```

Hình 7: Kết quả khi kiểm tra biến nearest_warehouse.

Nhận xét: Hình 7 Ta thấy được biến nearest_warehouse đang có nhiều định dạng khác nhau dẫn đến sai lệch khi phân tích. Ta tiến hành điều chỉnh lại định dạng nickolson=Nickolson, thompson=Thompson bằng hàm gán. (**Code[24]→[26]**).

```
> new_data$nearest_warehouse[new_data$nearest_warehouse == 'thompson'] = 'Thompson'
> new_data$nearest_warehouse[new_data$nearest_warehouse == 'nickolson'] = 'Nickolson'
> unique(new_data$nearest_warehouse)
[1] "Thompson"  "Nickolson" "Bakers"
>
```

Hình 8: Kết quả sau khi điều chỉnh biến nearest_warehouse.

Nhận xét: Hình 8 Như vậy, biến nearest_warehouse đã cho ra 4 định dạng như ta mong muốn.

Như vậy, dữ liệu đã được làm sạch hoàn toàn, ta tiến hành phân tích.

V Thống kê mô tả

1 Thống kê mô tả cho các biến định lượng

Ta tiến hành tính thống kê mô tả cho các biến định lượng (**Code[33]**→**[36]**).

	order_total	delivery_charges	order_price	distance_to_nearest_warehouse
mean	39209.67	76.65820	25522.22	2.204224
median	11293.96	76.31000	12807.50	1.030100
sd	274194.02	14.48146	86333.73	8.812416
min	639.29	46.35000	585.00	0.107800
max	5688269.60	114.04000	947691.00	94.973400

Hình 9: Kết quả khi kiểm tính thống kê mô tả cho các biến định lượng

Nhận xét: Hình 9 Dựa vào các số liệu thống kê, ta có thể rút ra một số nhận xét như sau:

Ta thấy biến order_total có giá trị trung bình là 39,209.67, cao hơn nhiều so với giá trị trung vị là 11,293.96. Điều này chứng tỏ rằng phân phối của dữ liệu bị lệch phải, do một số đơn hàng có giá trị rất lớn kéo trung bình lên cao. Ngoài ra, giá trị lớn nhất của biến này là 5,688,269.6, trong khi giá trị nhỏ nhất chỉ là 639.29. Sự chênh lệch lớn giữa các đơn hàng thể hiện mức độ không đồng đều trong dữ liệu.

Ta thấy biến delivery_charges có giá trị trung bình là 76.658 và giá trị trung vị là 76.31, phản ánh phân phối dữ liệu khá đối xứng. Khoảng dao động của phí giao hàng cũng không lớn, với giá trị nhỏ nhất là 46.35 và giá trị lớn nhất là 114.04. Điều này cho thấy sự ổn định của phí giao hàng trong các đơn hàng.

Ta thấy biến order_price có giá trị trung bình là 25,522.22, cao hơn giá trị trung vị là 12,807.50. Sự chênh lệch này phản ánh sự xuất hiện của một số đơn hàng có giá trị rất cao, dẫn đến trung bình bị kéo lên. Giá trị lớn nhất là 947,691, trong khi giá trị nhỏ nhất là 585. Sự khác biệt lớn này cho thấy sự đa dạng đáng kể trong giá trị các đơn hàng.

Ta thấy biến distance_to_nearest_warehouse có giá trị trung bình là 2.20 km và giá trị trung vị là 1.03 km. Phần lớn khách hàng có khoảng cách gần với kho, nhưng giá trị lớn nhất lên tới 94.97 km lại chỉ ra rằng một số khách hàng ở rất xa. Đây có thể là các trường hợp ngoại lệ hoặc thuộc khu vực đặc biệt.

Tóm lại, ta thấy các biến order_total và order_price có phân phối không đồng đều do ảnh hưởng của các giá trị ngoại lai lớn, trong khi các biến delivery_charges và distance_to_nearest_warehouse lại có sự ổn định hơn. Ta cần kiểm tra thêm các giá trị ngoại lai và phân tích mối tương quan giữa các biến để đưa ra các kết luận chính xác và ý nghĩa hơn.

2 Thống kê số lượng cho các biến phân loại

Ta tiến hành lập bảng thống kê số lượng cho mỗi phân loại của biến (**Code[39]**).

```
> table(new_data$season)

Autumn Spring Summer Winter
   154    119    107    120
```

Hình 10: Kết quả khi lập bảng thống kê số lượng mỗi phân loại của biến season

Nhận xét: Kết quả hình 10 cho ta thấy rằng mùa thu (Autumn) là mùa xuất hiện nhiều nhất trong dữ liệu, trong khi mùa hè (Summer) lại là mùa ít xuất hiện nhất. Dựa trên điều này, ta có thể dự đoán rằng lượng đặt hàng vào mùa thu sẽ cao đáng kể so với các mùa còn lại. Điều này có thể chỉ ra rằng vào mùa thu, số lượng đơn hàng thường tăng lên, không phải do xu hướng mua sắm nhiều hơn mà có thể là do các chính sách ưu đãi đặc biệt được áp dụng trong mùa này. Như vậy, ta cần nghiên cứu thêm các yếu tố khác như chương trình khuyến mãi hoặc nhu cầu thị trường để hiểu rõ hơn về sự gia tăng đơn hàng trong mùa thu.

Ta tiếp tục lập bảng thống kê số lượng cho mỗi phân loại của biến is_expedited_delivery (**Code**[**40**]).

```
> table(new_data$is_expedited_delivery)

False  True
  251   249
```

Hình 11: Kết quả khi lập bảng thống kê số lượng mỗi phân loại của biến is_expedited_delivery table (new_data$is_expedited_delivery)

Nhận xét: Hình 11 Ta có thể đánh giá được lượng khách hàng chọn giao hàng nhanh ít lượng khách hàng không chọn nhưng không đáng kể. Qua đó cho thấy khách hàng không quan tâm tới thời gian giao hàng hoặc chọn giao chậm để tiết kiệm chi phí.

Ta tiếp tục lập bảng thống kê số lượng cho mỗi phân loại của biến nearest_warehouse (**Code**[**38**]).

```
> table(new_data$nearest_warehouse)

  Bakers Nickolson  Thompson
     119       184       197
```

Hình 12: Kết quả khi lập bảng thống kê số lượng mỗi phân loại của biến nearest_warehouse

Nhận xét: Hình 12 Bảng thống kê cho thấy, ta có thể nhận thấy rằng kho Thomson giữ 39.4% hàng hóa, kho Nicholson 36.8%, và kho Bakers 23.8%. Điều này chỉ ra rằng kho Thomson có vị trí địa lý thuận lợi, giúp ta nhận định rằng kho này có thể đáp ứng nhu cầu khách hàng tốt hơn các kho còn lại, từ đó hỗ trợ ta xây dựng chiến lược phát triển hiệu quả hơn.

Ta lập bảng thống kê số lượng cho mỗi phân loại của biến is_happy_customer (**Code**[**41**]).

```
> table(new_data$is_happy_customer)

False  True
  141   359
```

Hình 13: Kết quả khi lập bảng thống kê sự hài lòng của khách hàng is_happy_customer

Nhận xét: Hình 13 Trong tổng số 500 đơn đặt hàng, ta thấy có 359 đơn hài lòng với dịch vụ, chiếm 71.8%, xấp xỉ 3/4 số khách hàng. Điều này cho thấy phần lớn khách hàng cảm thấy

hài lòng với dịch vụ hiện tại. Tuy nhiên, ta cũng nhận thấy vẫn còn 28.2% khách hàng không hài lòng, một tỷ lệ không nhỏ. Sự không hài lòng này có thể phản ánh những vấn đề chưa được đáp ứng đầy đủ trong dịch vụ khách hàng, có thể là về thời gian giao hàng, chất lượng sản phẩm hay trải nghiệm mua sắm. Do đó, ta cần thực hiện các biện pháp để cải thiện chất lượng phục vụ, như nâng cao khả năng giao hàng nhanh chóng, cải thiện dịch vụ chăm sóc khách hàng, và đảm bảo chất lượng sản phẩm ổn định để tăng sự hài lòng và giảm tỷ lệ khách hàng không hài lòng.

3 Mô tả dữ liệu bằng đồ thị

3.1 Đồ thị Histogram

Ta tiến hành vẽ đồ thị Histogram thể hiện phân phối của order_total, delivery_charges, order_price, distance_to_nearest_warehouse và coupon_discount (**Code**[**43**]→[**48**]).

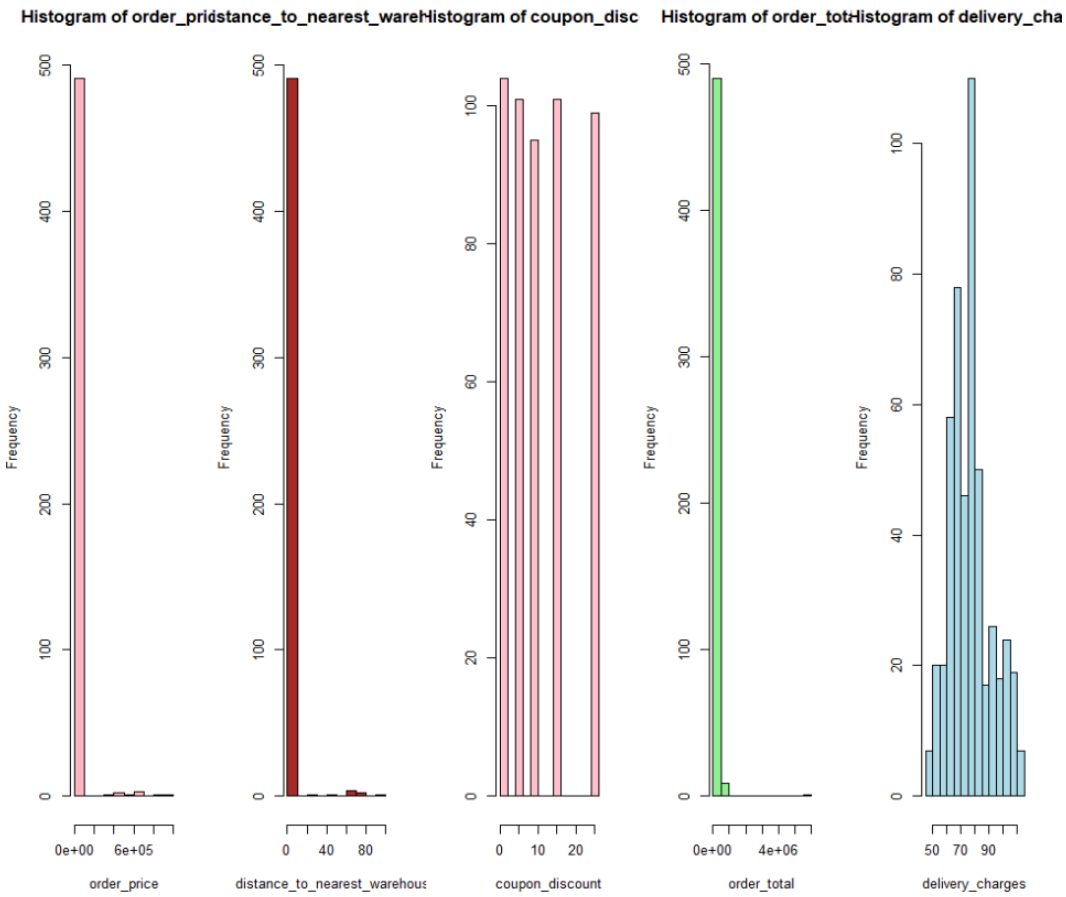

Hình 14: Kết quả khi vẽ đồ thị Histogram thể hiện phân phối của các biến.

Nhận xét: Hình 14 Từ các biểu đồ trên, ta thấy rằng ba trên năm biểu đồ có phân phối lệch phải, với một cột cao ở phía bên trái. Điều này chủ yếu do sự hiện diện của các điểm ngoại lai, khiến việc nhận dạng phân phối biến trở nên khó khăn. Để xử lý vấn đề này, ta sẽ sử dụng lý thuyết phân vị và chuyển các giá trị nằm ngoài khoảng giới hạn (tính theo công thức [Q1 - 1.5 * IQR] đến [Q3 + 1.5 * IQR]) thành NA và loại bỏ các điểm ngoại lai này (nếu giá trị ngoại lai không đáng kể) bằng cách sử dụng hàm **na.omit**.(**Code**[**50**]→[**70**]).

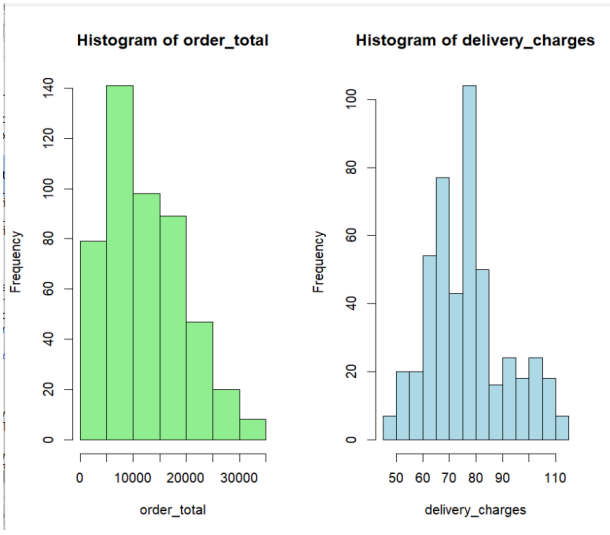

Hình 15: Kết quả khi vẽ đồ thị Histogram sau khi xử lí thể hiện phân phối của order_total và delivery_charges.

Nhận xét:
Hình 15 Ta thấy được:

- Ta thấy histogram của biến order_total cho thấy phân phối lệch trái, với phần lớn giá trị trong khoảng 0-15.000 và tần suất cao nhất ở khoảng 0-10.000. Từ 10.000 trở đi, tần suất giảm dần, cho thấy các đơn hàng giá trị cao ít phổ biến. Các đơn hàng trên 30.000 rất hiếm, gợi ý rằng ta thấy đa số khách hàng chỉ đặt các đơn hàng nhỏ.
- Ta thấy histogram của biến delivery_charges cho thấy phân phối gần như đối xứng, với phần lớn giá trị trong khoảng 70-90 và tần suất cao nhất ở khoảng 80. Phân phối có dạng chuông, cho thấy mức phí giao hàng thường dao động quanh giá trị trung bình. Phí giao hàng thấp dưới 60 hoặc cao trên 100 rất hiếm, phản ánh chi phí giao hàng ổn định trong một phạm vi nhất định, điều này cho thấy ta nhận thấy mức phí giao hàng khá đồng đều.

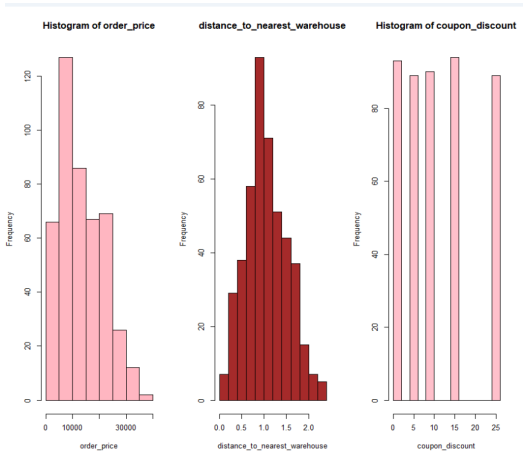

Hình 16: Kết quả khi vẽ đồ thị Histogram sau khi xử lí thể hiện phân phối của order_price, distance_to_nearest_warehouse và coupon_discount.

Nhận xét:
Hình 16 Ta thấy được:

- Ta thấy histogram của biến order_price cho thấy phân phối lệch phải, với phần lớn giá trị tập trung ở khoảng 0-10.000 và tần suất cao nhất đạt hơn 120. Sau mức 10.000, tần suất

giảm rõ rệt, cho thấy các đơn hàng giá trị cao ít phổ biến. Điều này cho thấy hầu hết đơn hàng có giá trị nhỏ, và các đơn hàng giá trị lớn rất hiếm.

- Ta thấy histogram của biến distance_to_nearest_warehouse có dạng hình chuông, vẫn còn xu hướng lệch phải, phản ánh phân phối chuẩn. Khoảng cách đến kho gần nhất tập trung chủ yếu từ 0.5-1.5 (đơn vị không rõ), với tần suất cao nhất tại khoảng 1.0. Điều này cho thấy phần lớn khách hàng ở khoảng cách trung bình so với kho, và khoảng cách cực gần hoặc cực xa rất ít xảy ra.
- Ta thấy histogram của biến coupon_discount cho thấy dữ liệu phân bố dạng rời rạc, với các giá trị cụ thể (5, 10, 15, 20, 25) và tần suất tương đối đồng đều ở từng mức. Điều này có thể do các mức giảm giá cố định được thiết lập sẵn, phản ánh chính sách ưu đãi theo từng nấc cụ thể của doanh nghiệp.

Nhận xét: Nhìn chung, ta thấy việc loại bỏ các điểm ngoại lai có thể giúp làm sạch dữ liệu và giảm ảnh hưởng của giá trị cực đoan. Tuy nhiên, dựa trên histogram hiện tại, dù các điểm ngoại lai đã được loại bỏ, ta vẫn thấy phân phối chưa đạt tính đối xứng gần như phân phối chuẩn và vẫn còn xu hướng lệch phải. Điều này cho thấy dữ liệu vẫn tồn tại sự thiên lệch và có thể cần thêm bước xử lý trước khi áp dụng các phương pháp thống kê yêu cầu giả định phân phối chuẩn.

3.2 Đồ thị Boxplot

Vẽ biểu đồ Boxplot thể hiện phân phối của order_total theo season (**Code**[**72**])

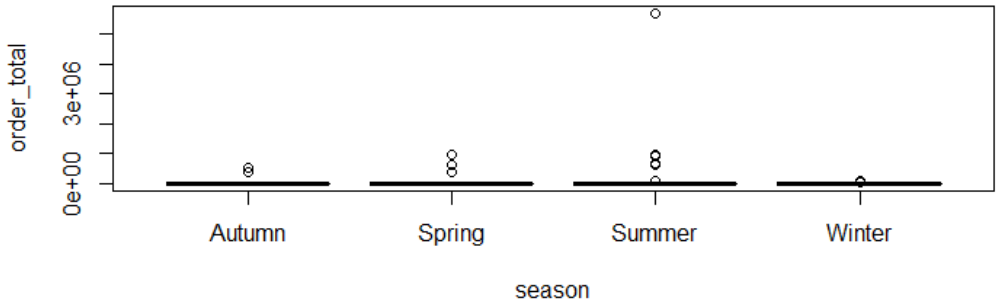

Hình 17: Kết quả khi vẽ Boxplot thể hiện phân phối của order_total theo season.

Nhận xét: Hình 17 Đồ thị cho thấy có nhiều điểm ngoại lai xa khiến ta không thể so sánh được phân phối của order_total theo season. Vì thế ta sẽ thực hiện đề xuất phương pháp phù hợp để xử lý các ngoại lai này.
Ta thực hiện tạo hàm tìm các ngoại lai và chuyển ngoại lai thành NA (**Code**[**74**]→[**81**])

```
> rm.out <- function(x, na.rm = TRUE,...){
+   qnt <- quantile(x,probs=c(.25,.75),na.rm = na.rm, ...)
+   H <- 1.5* IQR (x,na.rm =na.rm)
+   y <- x
+   y[x<(qnt[1]-H)] <- NA
+   y[x>(qnt[2]+H)] <-NA
+   y
+ }
>
```

Hình 18: (Tiến hành thực hiện xử lí).

Sau đó, ta thực hiện sử dụng hàm vừa tạo và thực hiện trên các bộ dữ liệu được phân theo season (**Code**[**82**]→[**96**]).

```
> rm.out <- function(x, na.rm = TRUE,...){
+   qnt <- quantile(x,probs=c(.25,.75),na.rm = na.rm, ...)
+   H <- 1.5* IQR (x,na.rm =na.rm)
+   y <- x
+   y[x<(qnt[1]-H)] <- NA
+   y[x>(qnt[2]+H)] <-NA
+   y
+ }
> #Dong bo season
> Spring_data =subset(new_data,new_data$season=="Spring")
> Spring_data$order_total =rm.out(Spring_data$order_total)
>
> Summer_data =subset(new_data,new_data$season=="Summer")
> Summer_data$order_total =rm.out(Summer_data$order_total)
>
> Autumn_data =subset(new_data,new_data$season=="Autumn")
> Autumn_data$order_total =rm.out(Autumn_data$order_total)
>
> Winter_data =subset(new_data,new_data$season=="Winter")
> Winter_data$order_total =rm.out(Winter_data$order_total)
>
```

Hình 19: Kết quả khi kiểm tra các dữ liệu NA (là các ngoại lai được tìm thấy).

Sau đó ta ghép các bộ dữ liệu sau khi tìm ngoại lại và thực hiện kiểm tra các dữ liệu NA (là các ngoại lai được tìm thấy) (**Code[95]→[98]**). Kết quả:

```
> new_data_2 <- rbind(Spring_data, Summer_data, Autumn_data, Winter_data)
> apply(is.na(new_data_2), 2, sum)
                 order_total                  order_price
                          17                            0
            delivery_charges               coupon_discount
                           0                            0
                      season         is_expedited_delivery
                           0                            0
           is_happy_customer distance_to_nearest_warehouse
                           0                            0
           nearest_warehouse
                           0
> apply(is.na(new_data_2), 2, mean)
                 order_total                  order_price
                       0.034                        0.000
            delivery_charges               coupon_discount
                       0.000                        0.000
                      season         is_expedited_delivery
                       0.000                        0.000
           is_happy_customer distance_to_nearest_warehouse
                       0.000                        0.000
           nearest_warehouse
                       0.000
```

Hình 20: Kết quả khi kiểm tra các dữ liệu NA (là các ngoại lai được tìm thấy).

Nhận xét: Hình 20 Ta tìm thấy 17 quan sát là ngoại lai (chiếm tỷ lệ 3.4% so với toàn bộ quan sát). Vì lượng dữ liệu ngoại lai nhỏ nên sai số sẽ không đáng kể. Vì vậy, ta sẽ chọn phương pháp xoá các các giá trị ngoại lai này và vẽ lại đồ thị (**Code[100]→[101]**).

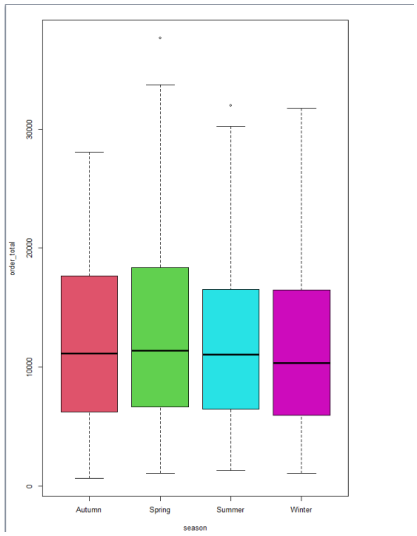

Hình 21: Kết quả khi vẽ lại Boxplot thể hiện phân phối của order_total theo season.

Nhận xét: Hình 21 Ta thấy boxplot tổng chi phí đặt hàng theo mùa cho thấy sự phân tán lớn giữa các mùa, với khoảng giữa (IQR) tương đối giống nhau. Mùa xuân có trung vị cao nhất,

phản ánh chi phí đặt hàng thường cao hơn, trong khi mùa hè và mùa đông có trung vị thấp hơn. Một số giá trị ngoại lệ xuất hiện ở mùa xuân và mùa hè, cho thấy các đơn hàng có chi phí rất cao. Mặc dù phạm vi tổng chi phí các mùa tương tự, mùa xuân có xu hướng chi tiêu cao hơn, gợi ý mùa xuân là thời điểm mua sắm sôi động. Ta có thể dự đoán mùa không ảnh hưởng quá nhiều đến tổng chi phí đặt hàng.
Ta tiến hành vẽ biểu đồ Boxplot thể hiện phân phối của order_total theo nearest_warehouse và tiến hành xử lí ngoại lai tương tự như biến season (**Code[102]→[124]**).

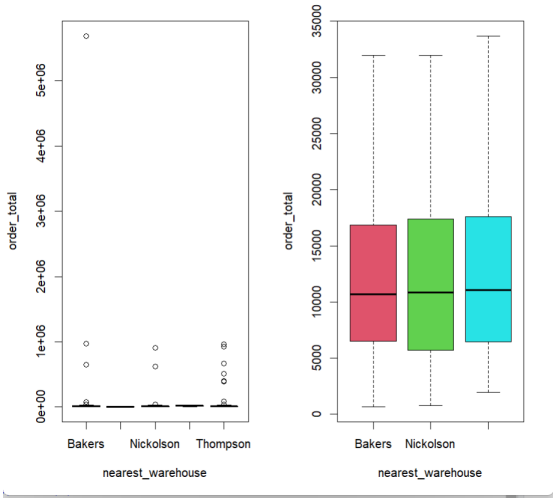

Hình 22: Kết quả khi vẽ boxplot thể hiện phân phối của order_total theo nearest_warehouse.

Nhận xét: Hình 22 Ta thấy từ boxplot biểu diễn mối quan hệ giữa biến nearest_warehouse (gồm các nhóm Bakers, Nickolson và Thompson) và biến order_total cho thấy phân bố tổng đơn hàng của các nhóm khá tương đồng, với khoảng giá trị dao động từ 0 đến 35.000. Trung vị của order_total ở ba nhóm gần nhau, không có sự chênh lệch rõ rệt về giá trị trung tâm. Phạm vi biến động của dữ liệu cũng tương đối giống nhau và không xuất hiện giá trị ngoại lệ đáng chú ý.

Trong các nhóm, nhóm Thompson có tổng đơn hàng trung vị cao nhất, trong khi nhóm Bakers có trung vị thấp nhất, tuy nhiên sự khác biệt này không quá lớn. Nhìn chung, ta có thể kết luận rằng biến nearest_warehouse không có ảnh hưởng đáng kể đến order_total, và sự hài lòng của khách hàng ở các kho hàng này không tác động mạnh đến tổng số lượng đơn hàng.

Vẽ biểu đồ Boxplot thể hiện phân phối của order_total theo is_happy_customer (**Code[130]**). Sau đó, ta thực hiện xử lí ngoại lai và vẽ lai đồ thị tương tự với hai biến trên (**Code[132]→[149]**).

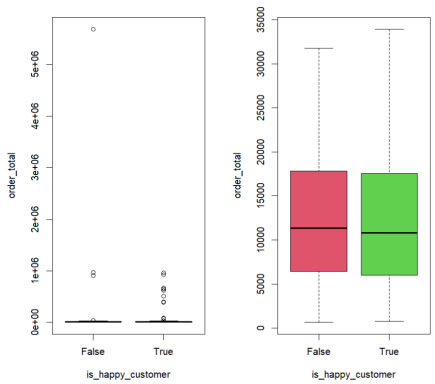

Hình 23: Kết quả khi vẽ boxplot thể hiện phân phối của order_total theo is_happy_customer.

Nhận xét: Hình 23 Ta thấy được đồ thị boxplot này biểu diễn mối quan hệ giữa biến is_happy_customer (gồm hai nhóm: False và True) và biến order_total. Dưới đây là nhận xét:

- Ta thấy rằng các nhóm False và True có phân bố giá trị order_total tương đối giống nhau, với khoảng giá trị từ 0 đến 35.000. Trung vị của nhóm True cao hơn nhóm False, cho thấy khách hàng hài lòng (True) có xu hướng chi tiêu cao hơn một chút, tuy nhiên sự khác biệt không lớn. Phạm vi giá trị và các chỉ số tứ phân vị cũng khá tương đồng giữa hai nhóm.

- Nhìn chung, ta có thể kết luận rằng biến is_happy_customer chỉ ảnh hưởng nhẹ đến order_total, với mức chi tiêu trung bình của nhóm khách hàng hài lòng (True) nhỉnh hơn nhóm không hài lòng (False).

Ta tiến hành vẽ biểu đồ Boxplot thể hiện phân phối của order_total theo is_expedited_delivery và ta thực hiện xử lí ngoại lai và vẽ lại đồ thị tương tự (**Code[152→[170]**).

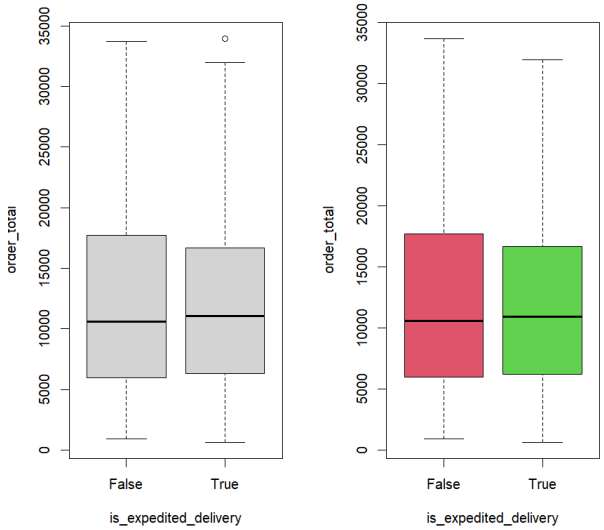

Hình 24: Kết quả khi vẽ boxplot thể hiện phân phối của order_total theo is_expedited_delivery.

Nhận xét: Hình 24 Dựa trên biểu đồ boxplot bên phải, ta thấy được biến is_expedited_delivery (việc giao hàng nhanh hay không) dường như không ảnh hưởng rõ ràng đến order_total (tổng giá trị đơn hàng). Cụ thể:

Ta nhận thấy rằng trung vị của hai nhóm (False và True) gần như bằng nhau, điều này cho thấy không có sự khác biệt lớn về giá trị trung bình giữa hai nhóm. Độ phân tán dữ liệu (thể hiện qua kích thước hộp và râu) của hai nhóm cũng tương đối giống nhau. Phân bố giá trị trong cả hai trường hợp là khá tương đồng, không có sự khác biệt rõ rệt.

3.3 Đồ thị Scatter/Plot

Ta thực hiện vẽ đồ thị Scatter/Plot theo biến order_total và order_price (**Code[175]**).

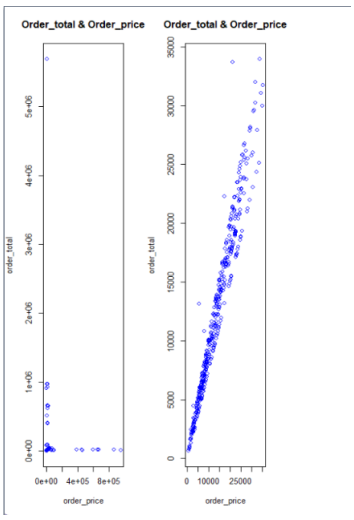

Hình 25: Kết quả khi vẽ Scatter/plot thể hiện phân phối của order_total và order_price.

Nhận xét: Hình 25 Sau khi loại bỏ các điểm ngoại lai, ta thấy được đồ thị trở nên rõ ràng hơn và cho thấy một xu hướng tuyến tính giữa order_price và order_total. Cụ thể:

- Ta nhận thấy một quan hệ tuyến tính rõ ràng giữa hai biến. Biểu đồ cho thấy sự tăng trưởng gần như tuyến tính: khi giá trị của order_price tăng lên, order_total cũng tăng theo, thể hiện qua việc các điểm dữ liệu xếp thành một đường chéo tăng dần.
- Ta cũng nhận thấy một mối quan hệ tương quan dương mạnh, với hầu như không có dữ liệu bị phân tán hoặc nằm ngoài xu hướng chính, chứng tỏ rằng hai biến có mối quan hệ tỷ lệ thuận.
- Kết quả này gợi ý rằng sự gia tăng của giá trị đơn hàng (order_price) sẽ dẫn đến sự gia tăng tương ứng của tổng đơn hàng (order_total), điều này có thể do tính chất cộng gộp của dữ liệu. Mối quan hệ này phù hợp với các hệ thống thương mại, nơi tổng số tiền phụ thuộc vào giá trị từng đơn hàng.

Ta vẽ đồ thị Scatter/plot cho order_total và distance_to_nearest_warehouse (**Code[177]**).

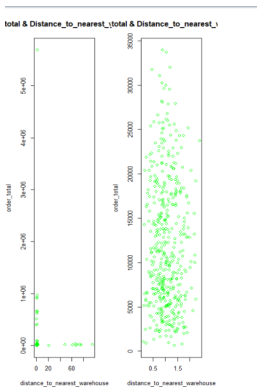

Hình 26: Kết quả khi vẽ Scatter/plot thể hiện phân phối của order_total và distance_to_nearest_warehouse.

Nhận xét: Hình 26 Như vậy, ta vẫn chưa thấy được giữa hai biến distance_to_nearest_warehouse và order_ total có quan hệ tuyến tính. Ta có thể dự đoán biến distance_to_nearest_warehouse không ảnh hưởng đến biến order_total.
Ta tiếp tục vẽ đồ thị Scatter/plot cho order_total và delivery_charges (**Code[176]**).

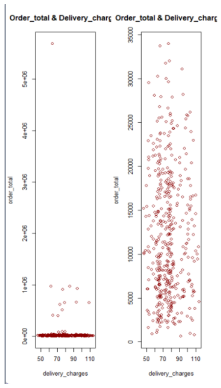

Hình 27: Kết quả khi vẽ Scatter/plot thể hiện phân phối của order_total và delivery_charges.

Nhận xét: Hình 27 Sau khi ta xóa điểm ngoại lai, ta vẫn chưa thấy được sự quan hệ tuyến tính rõ ràng giữa hai biến delivery_charges và order_total. Ta có thể dự đoán rằng biến delivery_charges không ảnh hưởng đến biến order_total.
Ta tiếp tục vẽ cho order_total và coupon_discount (**Code[178]**).

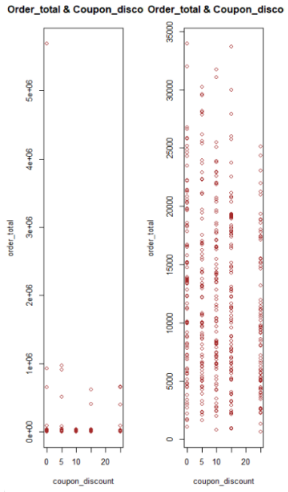

Hình 28: Kết quả khi vẽ Scatter/plot thể hiện phân phối của order_total và coupon_discount.

Nhận xét: Hình 28 Dựa trên biểu đồ scatter plot, ta thấy được mối quan hệ giữa coupon_discount (giảm giá phiếu giảm giá) và order_total (tổng đơn hàng) không rõ ràng. Giá trị coupon_discount chủ yếu tập trung ở mức thấp (dưới 10), trong khi order_total có sự phân tán rộng, dao động từ thấp đến hơn 30,000. Dữ liệu cho ta thấy hai biến không có xu hướng tuyến tính hoặc phi tuyến rõ rệt, cho thấy mức giảm giá không có ảnh hưởng trực tiếp hoặc có nhưng rất ít đến tổng chi phí đơn hàng.

VI Thống kê suy diễn

1 Anova một nhân tố: So sánh tổng chi phí đặt hàng theo mùa

Ta sẽ tách dữ liệu theo mùa (**Code[180→183]**). Các giả định cần kiểm tra:

+ Tổng chi phí đặt hàng ở các mùa tuân theo phân phối chuẩn.

+ Phương sai tổng chi phí đặt hàng ở các mùa bằng nhau.

Kiểm định giả định về phân phối chuẩn:

Đối với mùa xuân, ta thực hiện vẽ đồ thị(**Code[185→186]**):

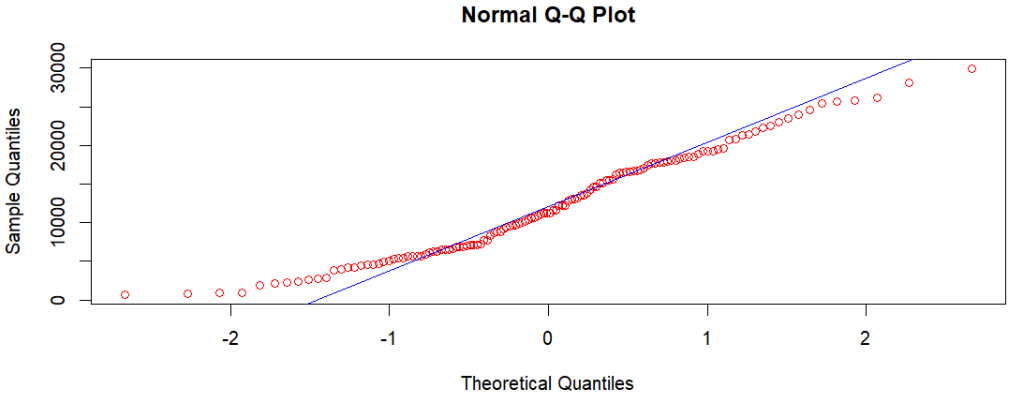

Hình 29: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa xuân

Nhận xét: Hình 29 cung cấp đồ thị QQ để so sánh phân phối của dữ liệu với phân phối chuẩn. Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa xuân không tuân theo phân phối chuẩn.

Ngoài ra, ta có thể dùng hàm Shapiro.test để kiểm tra:

Giả thuyết H_0: Chi phí đặt hàng ở mùa xuân tuân theo phân phối chuẩn.

Đối thuyết H_1: Chi phí đặt hàng ở mùa xuân không tuân theo phân phối chuẩn.

Code[187]

```
> shapiro.test(Spring_data_2$order_total)

        Shapiro-Wilk normality test

data:  Spring_data_2$order_total
W = 0.96776, p-value = 0.003468
```

Hình 30: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa xuân

Nhận xét: Hình 30 Kết quả của phương pháp Shapiro test được trình bày trong hình 30, dựa vào p-value = 0.0035 < mức ý nghĩa 5% ở kiểm định Shapiro.test nên ta bác bỏ H_0 và chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa xuân không tuân theo phân phối chuẩn.

Đối với mùa hạ, ta thực hiện vẽ đồ thị(**Code[189→190]**):

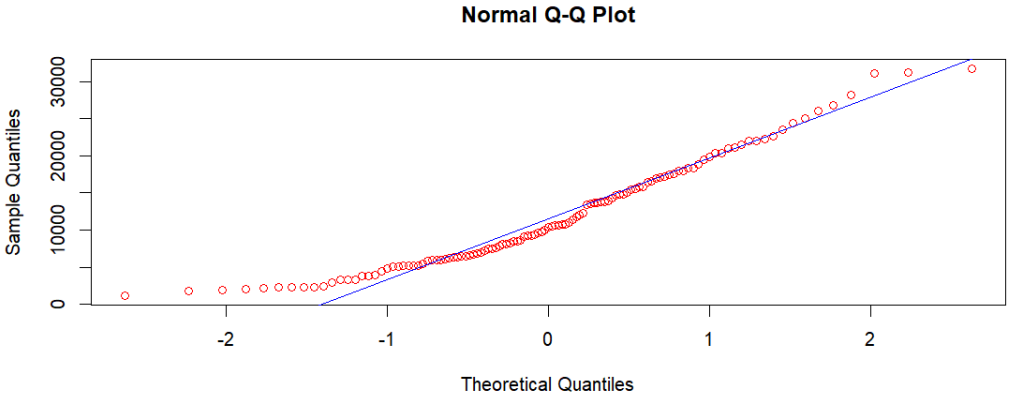

Hình 31: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa hạ

Nhận xét: Hình 31 cung cấp cho ta đồ thị QQ để so sánh phân phối của dữ liệu với phân phối chuẩn. Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa hạ không tuân theo phân phối chuẩn.

Ngoài ra, ta có thể dùng hàm Shapiro.test để kiểm tra:

Giả thuyết H_0: Chi phí đặt hàng ở mùa hạ tuân theo phân phối chuẩn.

Đối thuyết H_1: Chi phí đặt hàng ở mùa hạ không tuân theo phân phối chuẩn.

Code[191]

```
> shapiro.test(Summer_data_2$order_total)

        Shapiro-Wilk normality test

data:  Summer_data_2$order_total
W = 0.94214, p-value = 7.425e-05
```

Hình 32: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa hạ

Nhận xét: Hình 32 Kết quả của phương pháp Shapiro test được trình bày trong hình 32, dựa vào p-value $= 7.425e-05 <$ mức ý nghĩa 5% ở kiểm định Shapiro.test nên ta bác bỏ H_0 và chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa hạ không tuân theo phân phối chuẩn.

Đối với mùa thu, ta thực hiện vẽ đồ thị (**Code[193→194]**):

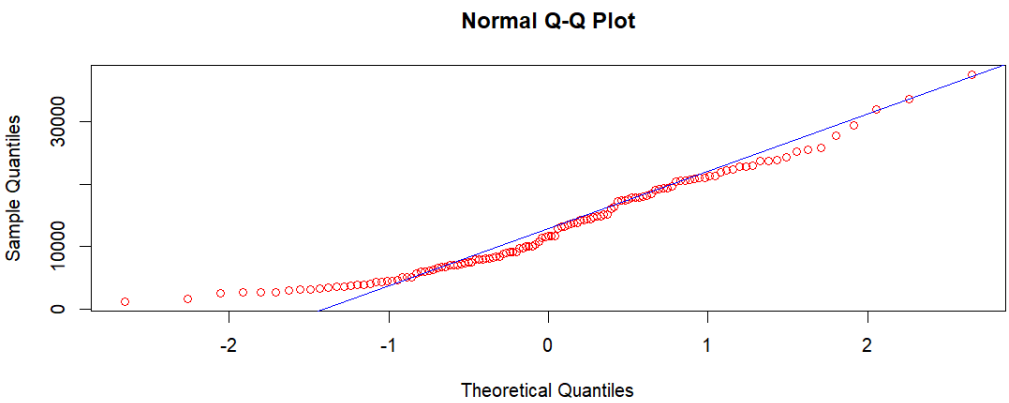

Hình 33: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa thu

Nhận xét: Hình 33 cung cấp cho ta đồ thị QQ để so sánh phân phối của dữ liệu với phân phối chuẩn. Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa thu không tuân theo phân phối chuẩn.

Ngoài ra, ta có thể dùng hàm Shapiro.test để kiểm tra:

Giả thuyết H_0: Chi phí đặt hàng ở mùa thu tuân theo phân phối chuẩn.

Đối thuyết H_1: Chi phí đặt hàng ở mùa thu không tuân theo phân phối chuẩn.

Code[195]

```
> shapiro.test(Autumn_data_2$order_total)

        Shapiro-Wilk normality test

data:  Autumn_data_2$order_total
W = 0.94867, p-value = 0.0001242
```

Hình 34: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa thu

Nhận xét: Kết quả của phương pháp Shapiro test được trình bày trong hình 34, dựa vào p-value = 0.0001242 < mức ý nghĩa 5% ở kiểm định Shapiro.test nên ta bác bỏ H_0 và chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa thu không tuân theo phân phối chuẩn.

Đối với mùa đông, ta thực hiện vẽ đồ thị (**Code[197→198]**):

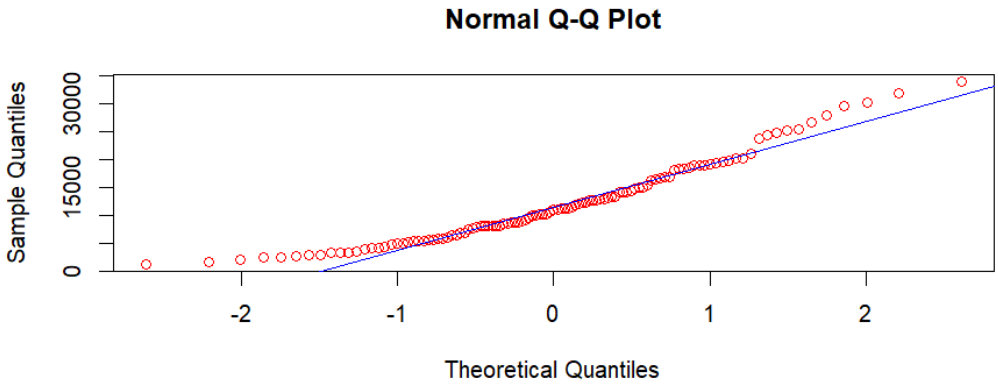

Hình 35: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa đông

Nhận xét: Hình 35 cung cấp cho ta đồ thị QQ để so sánh phân phối của dữ liệu với phân phối chuẩn. Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa hạ không tuân theo phân phối chuẩn.

Ngoài ra, ta có thể dùng hàm Shapiro.test để kiểm tra:

Giả thuyết H_0: Chi phí đặt hàng ở mùa hạ tuân theo phân phối chuẩn.

Đối thuyết H_1: Chi phí đặt hàng ở mùa hạ không tuân theo phân phối chuẩn.

Code[199]

```
> shapiro.test(Winter_data_2$order_total)

        Shapiro-Wilk normality test

data:  Winter_data_2$order_total
W = 0.93982, p-value = 8.11e-05
```

Hình 36: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa đông

Nhận xét: Kết quả của phương pháp Shapiro test được trình bày trong hình 36, dựa vào p-value $= 8.11e-05 <$ mức ý nghĩa 5% ở kiểm định Shapiro.test nên ta bác bỏ H_0 và chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa hạ không tuân theo phân phối chuẩn.

Kết luận: vậy có sự khác nhau về tổng chi phí đặt hàng ở cả bốn mùa.

Kiểm định giả định về tính đồng nhất của phương sai:

Giả thuyết H_0: Phương sai tổng chi phí đặt hàng ở các mùa bằng nhau.

Đối thuyết H_1: Có ít nhất hai mùa có phương sai tổng chi phí đặt hàng khác nhau.

Code[201→202]

```
Levene's Test for Homogeneity of Variance (center = median)
       Df F value Pr(>F)
group   3  0.8623 0.4605
      479
```

Hình 37: code R và kết quả khi kiểm tra giả định phương sai

Nhận xét: Kết quả của phương pháp Levene test được trình bày trong hình 37, dựa vào p-value $= 0.4605 >$ mức ý nghĩa 5% ở kiểm định leveneTest nên ta có thể kết luận phương sai tổng chi phí đặt hàng ở các mùa là bằng nhau.

Thực hiện Anova một nhân tố so sánh tổng chi phí đặt hàng trung bình ở các mùa:

Giả thuyết H_0: Tổng chi phí đặt hàng trung bình ở các mùa bằng nhau.

Đối thuyết H_1: Có ít nhất hai mùa có tổng chi phí đặt hàng khác nhau.

Code[204→205]

```
            Df    Sum Sq  Mean Sq F value Pr(>F)
season       3 8.749e+07 29163926   0.538  0.656
Residuals  479 2.595e+10 54170692
```

Hình 38: Kết quả khi thực hiện Anova một nhân tố

Nhận xét: Kết quả của phương pháp Anova một nhân tố được thể hiện trong hình 38 cho ta thấy:

SSB $= 8.749e+7$, bậc tự do $df = k-1 = 3(k=4)$ với k là số nhóm.

SSE $= 2.595e+10$, bậc tự do $df = N-k = 479(N=483, k=4)$ với N là tổng số quan sát trong các nhóm.

MSB $= \dfrac{SSB}{k-1} = 29163926$, MSE $= \dfrac{SSE}{kn-k} = 54170692$.

Giá trị kiểm định thống kê F $= \dfrac{MSB}{MSE} \approx 0.538$. Mức ý nghĩa quan sát Pr $= 0.656$ lớn hơn mức ý nghĩa 5% nên ta chưa bác bỏ H_0 được.

Vậy nên tổng chi phí đặt hàng trung bình ở các mùa bằng nhau.

2 Hồi quy đa biến: Phân tích các yếu tố dự báo tổng chi phí đặt hàng phụ thuộc vào những biến nào

Chúng ta thực hiện phân tích biến order_total có liên quan tới các biến khác trong bộ dữ liệu (**Code[207→214]**).

Từ kết quả phân tích, ta lặp được mô hình hồi quy bao gồm:

+ Biến phụ thuộc: order_total

+ Biến độc lập: coupon_discount, order_price, season.

Mô hình được biểu diễn như sau:

$$\text{order_total} = \beta_0 + \beta_1 \times \text{coupon_discount} + \beta_2 \times \text{order_price} + \beta_3 \times \text{seasonSpring} + \beta_4 \times \text{seasonSumer} + \beta_5 \times \text{seasonWinter} + \varepsilon.$$

Ta thực hiện ước lượng các hệ số $\beta_i,\ i = 0, \ldots, 5$ (**Code[216→217]**).

```
Call:
lm(formula = order_total ~ coupon_discount + order_price + season,
    data = new_data)

Residuals:
    Min      1Q  Median      3Q     Max
-2872.8  -400.7   -80.0   301.4 15129.0

Coefficients:
                  Estimate Std. Error t value Pr(>|t|)
(Intercept)      1.757e+03  1.548e+02  11.346   <2e-16 ***
coupon_discount -1.334e+02  6.228e+00 -21.422   <2e-16 ***
order_price      8.883e-01  6.671e-03 133.149   <2e-16 ***
seasonSpring    -8.485e+01  1.476e+02  -0.575    0.566
seasonSummer    -2.775e+02  1.500e+02  -1.850    0.065 .
seasonWinter    -1.095e+02  1.500e+02  -0.730    0.466
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1116 on 435 degrees of freedom
Multiple R-squared:  0.9767,    Adjusted R-squared:  0.9764
F-statistic:  3641 on 5 and 435 DF,  p-value: < 2.2e-16
```

Hình 39: Kết quả khi thực hiện xây dựng mô hình hồi quy bội

Nhận xét: Từ kết quả phân tích ta thu được:

$$\hat{\beta}_0 = 1.757e + 03; \hat{\beta}_1 = -1.334e + 02; \hat{\beta}_2 = 8.883e - 01;$$

$$\hat{\beta}_3 = -8.485e + 01; \hat{\beta}_4 = -2.775e + 02; \hat{\beta}_5 = -1.095e + 02$$

Như vậy, đường thẳng hồi quy ước lượng cho bởi phương trình sau:

$$\widehat{order_total} = 1.757e + 03 + (-1.334e + 02) \times \text{coupon_discount} + (8.883e - 01) \times \text{order_price} + (-8.485e + 01) \times \text{seasonSpring} + (-2.775e + 02) \times \text{seasonSumer} + (-1.095e + 02) \times \text{seasonWinter}.$$

Kiểm định các hệ số β_i:

+ Giả thuyết H_0: $\beta_i = 0$: hệ số β_i không có ý nghĩa thống kê.

+ Đối thuyết H_1: $\beta_i \neq 0$: hệ số β_i có ý nghĩa thống kê.

Ta nhận thấy rằng p-value ứng với các biến seasonSummer, seasonSpring, seasonWinter lớn hơn mức ý nghĩa 5% nên ta chưa bác bỏ được H_0. Vậy hệ số β_i ứng với các biến này bằng 0 (không có ý nghĩa thống kê). Tức là các biến này không ảnh hưởng order_total. Ta sẽ xem xét loại bỏ các biến này ra khỏi mô hình.

Ta xây dựng mô hình model_2 bỏ đi biến season từ model_1 (**Code[219→220]**).

```
Call:
lm(formula = order_total ~ coupon_discount + order_price, data = new_data)

Residuals:
    Min      1Q  Median      3Q     Max 
-2870.4  -395.4   -66.5   254.4 15242.2 

Coefficients:
                 Estimate Std. Error t value Pr(>|t|)    
(Intercept)     1.640e+03  1.243e+02   13.20   <2e-16 ***
coupon_discount -1.337e+02  6.221e+00  -21.49   <2e-16 ***
order_price     8.886e-01  6.669e-03  133.24   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1117 on 438 degrees of freedom
Multiple R-squared:  0.9765,	Adjusted R-squared:  0.9764 
F-statistic:  9090 on 2 and 438 DF,  p-value: < 2.2e-16
```

Hình 40: Kết quả khi thực hiện xây dựng mô hình 2

So sánh hai model_1 và model_2:

Giả thuyết H0: Mô hình model_2 hiệu quả hơn.

Đối thuyết H1: Mô hình model_1 hiệu quả hơn.

(Code[222]).

```
Analysis of Variance Table

Model 1: order_total ~ coupon_discount + order_price + season
Model 2: order_total ~ coupon_discount + order_price
  Res.Df       RSS Df Sum of Sq      F Pr(>F)
1    435 541679361                           
2    438 546110905 -3  -4431544 1.1863 0.3145
```

Hình 41: Kết quả khi so sánh hai mô hình 1 và mô hình 2

Nhận xét: Ta nhận thấy p-value = 0.3145 lớn hơn mức ý nghĩa 5%, nên ta chưa bác bỏ được H0, vậy nên mô hình model_2 hiệu quả hơn. Qua việc so sánh ta có thể nhận thấy mô hình model_2 là mô hình hiệu quả nhất.

Các giả định của mô hình hồi quy: $Y_i = \beta_0 + \beta_1 X_1 + \ldots + \beta_i X_i + \varepsilon_i,\ i = 1, \ldots n.$

+ Tính tuyến tính của dữ liệu: mối quan hệ giữa biến dự báo X và biến phụ thuộc Y được giả sử là tuyến tính.

+ Sai số có kỳ vọng bằng 0.

+ Phương sai của các sai số là hằng số.

+ Sai số có phân phối chuẩn. $\varepsilon \sim N(0, \sigma^2)$.

+ Các sai số $\varepsilon_1, \ldots, \varepsilon_n$ thì độc lập với nhau.

Ta thực hiện phân tích thặng dư để kiểm tra các giả định của mô hình (**Code[224→225]**).

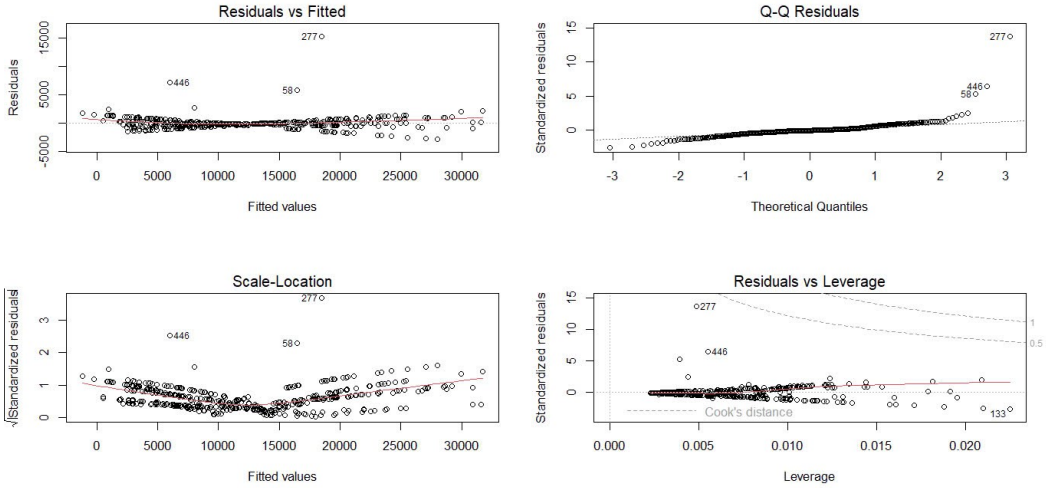

Hình 42: Code R và kết quả khi vẽ đồ thị phân tích thặng dư để kiểm tra các giả định của mô hình

Nhận xét:

Đồ thị 1: Vẽ các sai số hồi quy tương ứng với giá trị dự báo, dùng để kiểm tra giả định:

+ Y và các biến độc lập X có quan hệ tuyến tính.

+ Sai số có kỳ vọng bằng 0.

+ Phương sai các sai số là hằng số.

Dựa vào kết quả cho thấy:

+ Đường màu đỏ tương đối là đường thẳng nằm ngang nên giả định Y và các biến độc lập X có quan hệ tuyến tính thoả mãn.

+ Đường màu đỏ tương đối nằm sát đường y = 0 nên ta giả định Sai số có kỳ vọng bằng 0 thoả mãn.

+ Các giá trị sai số chưa phân tán ngẫu nhiên dọc theo đường màu đỏ, nên giả định Phương sai các sai số là hằng số chưa thoả mãn.

Đồ thị 2: Vẽ các sai số hồi quy được chuẩn hoá, dùng để kiểm tra giả định sai số có phân phối chuẩn.

Dựa vào kết quả cho thấy: các quan trắc tương đối nằm trên đường thẳng kỳ vọng phân phối chuẩn nên giả định Sai số có phân phối chuẩn thoả mãn

Đồ thị 3: Vẽ căn bậc 2 các sai số được chuẩn hoá, dùng để kiểm tra giả định Phương sai các sai số là hằng số.

Dựa vào kết quả cho thấy: Các giá trị sai số chưa phân tán ngẫu nhiên dọc theo đường màu đỏ, nên giả định phương sai các sai số là hằng số chưa thực sự thoả mãn.

Đồ thị 4: Vẽ ra những điểm có gây ảnh hưởng cao trong bộ dữ liệu cụ thể là các điểm 446,227. Tuy nhiên, không điểm nào vượt khỏi đường Cook's distance. Vì vậy, ta không cần loại bỏ các điểm khỏi dữ liệu.

Mô hình hồi quy tuyến tính về sự ảnh hưởng các nhân tố lên biến tổng chi phí đặt hàng (order_total) = 1.640e+03 + 8.886e-01 x order_price + -1.337e+02 x coupon_discount

Hệ số xác định hiệu chỉnh (Adjusted R-squared): R^2 hiệu chỉnh = 0.9764 nghĩa là 97.64% sự biến thiên trong tổng chi phí đặt hàng (order_total) được giải thích bởi các biến độc lập.

VII Thảo luận

Từ việc xây dựng mô hình Anova và hồi quy đa biến, ta rút được 2 kết luận:

- Giữa các mùa (season) trong năm không có sự khác biệt với tổng chi phí đặt hàng (order_total).
- Tổng chi phí đặt hàng (order_total) bị ảnh hưởng bởi 2 yếu tố chính là chi phi của đơn hàng (order_price) và mã giảm giá (coupon_discount).

Ngoài ra, ta có thể rút ra được ưu điểm và nhược điểm từ việc xây dựng hai mô hình:

Hồi quy đa biến:

- **Ưu điểm**: Hồi quy đa biến đơn giản, dễ hiểu, có thể kiểm tra ảnh hưởng của nhiều yếu tố và dự đoán tốt nếu mối quan hệ giữa các biến là tuyến tính.
- **Nhược điểm**: Giả định tuyến tính, dễ bị ảnh hưởng bởi đa cộng tuyến, dữ liệu ngoại lai, và không thể xử lý mối quan hệ phức tạp hoặc phi tuyến.

Anova:

- **Ưu điểm**: Anova là một công cụ mạnh mẽ để so sánh sự khác biệt giữa nhiều nhóm, đồng thời kiểm tra sự tương tác giữa các yếu tố. Nó giúp giảm số lượng phép kiểm tra và mang lại kết quả chính xác nếu các giả định được đáp ứng.
- **Nhược điểm**: Anova yêu cầu dữ liệu có phân phối chuẩn và phương sai đồng nhất. Ngoài ra, Anova chỉ cho biết có sự khác biệt hay không giữa các nhóm, mà không xác định nhóm nào khác biệt so với nhóm nào, và cũng không đưa ra mức độ khác biệt.

VIII Nguồn dữ liệu và nguồn code

Link dữ liệu https://www.kaggle.com/datasets/muhammadshahrayar/transactional-retail-dataset-of-electronics-store?select=dirty_data.csv

Link code: GITHUB

Tài liệu tham khảo

1. Nguồn dữ liệu: https://www.kaggle.com/datasets/muhammadshahrayar/transactional-retail-dataset-of-electronics-store?select=dirty_data.csv

2. Hoàng Văn Hà, Bài giảng Xác suất Thống Kê.

3. Nguyễn Thị Mộng Ngọc, Bài giảng Xác suất Thống Kê.

4. Nguyễn Tiến Dũng (chủ biên), Nguyễn Đình Huy, *Xác suất - Thống kê & Phân tích số liệu*, 2019.

5. *Introductory Statistic with R*, J. Jambers - D. Hand - W. Hardle.

6. *Applied Statistics with R*, 2020.

7. Phan Thị Hường, Bài giảng Xác suất Thống Kê

8. Nguyễn Đình Huy, *GIÁO TRÌNH XÁC SUẤT VÀ THỐNG KÊ, NHÀ XUẤT BẢN ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH, 2023*