ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA ĐIỆN - ĐIỆN TỬ

BÁO CÁO BÀI TẬP LỚN

XÁC SUẤT - THỐNG KÊ

LỚP: L13 - NHÓM:11

GIẢNG VIÊN HƯỚNG DẪN: Nguyễn Thị Mộng Ngọc
THÀNH VIÊN NHÓM:

STT	Họ và tên	MSSV	Ghi chú
1	Nguyễn Đức Thành	2113134	
2	Phạm Xuân Tân	2114732	Nhóm trưởng
3	Hoàng Phi Long	2211875	
4	Nguyễn Bá Thao	2112274	
5	Nguyễn Hoàng Long	1914000	

Tp. Hồ Chí Minh, Tháng 01/05/2024

Phân công làm việc

STT	Họ và tên	MSSV	Ghi chú
1	Nguyễn Đức Thành	2113134	Nhận xét kết quả
2	Phạm Xuân Tân	2114732	Tổng hợp báo cáo, kiến thức nền, thống kê suy diễn
3	Hoàng Phi Long	2211875	Thống kê mô tả, thống kê suy diễn
4	Nguyễn Bá Thao	2112274	Thống kê suy diễn
5	Nguyễn Hoàng Long	1914000	Thống kê suy diễn

Mục lục

1 TỔNG QUAN DỮ LIỆU **6**

2 KIẾN THỨC NỀN **7**
2.1 Hồi quy tuyến tính bội . . . 7
2.1.1 Hàm hồi quy tổng thể (PRF - Population Regression Function) . . . 7
2.1.2 Hàm hồi quy mẫu (SRF - Sample Regression Function): . . . 7
2.1.3 Các giả thiết của phương pháp bình phương nhỏ nhất cho mô hình hồi quy tuyến tính bội . . . 7
2.1.4 Độ phù hợp của mô hình . . . 8
2.1.5 Khoảng tin cậy và kiểm định các hệ số hồi quy . . . 8
2.1.6 Kiểm định mức độ ý nghĩa chung của mô hình (trường hợp đặc biệt của kiểm định WALD) . . . 10
2.2 Phân tích phương sai một yếu tố . . . 11
2.2.1 Lý thuyết về ANOVA (Phân tích phương sai) . . . 11
2.2.2 Phân tích phương sai một yếu tố . . . 11

3 TIỀN XỬ LÝ SỐ LIỆU **16**
3.1 Đọc dữ liệu . . . 16
3.2 Làm sạch dữ liệu . . . 16

4 THỐNG KÊ MÔ TẢ **17**
4.1 Thống kê mô tả cho các biến định lượng . . . 17
4.2 Thống kê số lượng cho các biến phân loại . . . 18
4.3 Mô tả dữ liệu bằng đồ thị . . . 18
4.3.1 Đồ thị Histogram . . . 18
4.3.2 Đồ thị Boxplot . . . 19
4.3.3 Đồ thị Scatter / Plot . . . 21
4.3.4 Đồ thị ma trận tương quan . . . 22

5 THỐNG KÊ SUY DIỄN **24**
5.1 Anova một nhân tố: So sánh tổng chi phí đặt hàng theo mùa . . . 24
5.2 Hồi quy đa biến: Phân tích các yếu tố dự báo chi phí vận chuyển . . . 28

6 THẢO LUẬN VÀ MỞ RỘNG **34**

7 NGUỒN DỮ LIỆU VÀ NGUỒN CODE **37**

8 TÀI LIỆU THAM KHẢO **37**

Danh sách bảng

1 Bảng tóm tắt giả thuyết và miền bác bỏ tương ứng 9
2 Bảng số liệu tổng quát thực hiện phân tích phương sai. 12
3 Bảng kết quả tổng quát của ANOVA khi phân tích bằng Excel hay SPSS. 13

Danh sách hình vẽ

1 Kết quả khi kiểm tra một số thông tin về tệp tin 16
2 Kết quả khi xem 10 dòng đầu tiên của tệp tin new_data 16
3 Kết quả khi kiểm tra dữ liệu khuyết 17
4 Kết quả khi kiểm tra các giá trị của season. 17
5 Kết quả khi kiểm tra lại các giá trị của season. 17
6 Kết quả khi kiểm tính thống kê mô tả cho các biến định lượng. 18
7 Kết quả khi lập bảng thống kê số lượng mỗi phân loại của biến season. 18
8 Kết quả khi lập bảng thống kê số lượng mỗi phân loại của biến is_expedited_delivery. 18
9 Kết quả khi vẽ đồ thị Histogram thể hiện phân phối của order_total. 19
10 Kết quả khi vẽ Boxplot thể hiện phân phối của order_total theo season. 19
11 Kết quả khi kiểm tra các dữ liệu NA (là các ngoại lai được tìm thấy) 20
12 Kết quả khi vẽ lại Boxplot thể hiện phân phối của order_total theo season 20
13 Kết quả khi vẽ Boxplot thể hiện phân phối của delivery_charges theo season 21
14 Kết quả khi vẽ Boxplot thể hiện phân phối của delivery_charges theo is_expedited_delivery 21
15 Kết quả khi vẽ đồ thị phân tán giữa Delivery_charges theo các biến customer_lat, customer_long, distance_to_nearest_warehouse. 22
16 Kết quả khi vẽ đồ thị ma trận tương quan 23
17 Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa xuân 24
18 Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa xuân 24
19 Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa hè 25
20 Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa hè 25
21 Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa thu 26
22 Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa thu 26
23 Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa đông 27
24 Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa đông 27
25 code R và kết quả khi kiểm tra giả định phương sai 27
26 Kết quả khi thực hiện Anova một nhân tố 28

27 Kết quả khi thực hiện xây dựng mô hình hồi quy bội 29
28 Kết quả khi thực hiện xây dựng mô hình 2 30
29 Kết quả khi thực hiện xây dựng mô hình 3 30
30 code R và kết quả khi so sánh hai model_1 và model_2 30
31 code R và kết quả khi so sánh hai model_2 và model_3 31
32 code R và kết quả khi vẽ đồ thị phân tích thặng dư để kiểm tra các giả định của mô hình 32
33 Kết quả khi thực hiện dự báo 33
34 Kết quả khi vẽ đồ thị phân tán giữa delivery_charges và distance_to_nearest_warehouse 35
35 Kết quả khi vẽ đồ thị phân tán giữa delivery_charges và distance_to_nearest_warehouse 35
36 Kết quả khi xây dựng lại mô hình hồi quy 1 36
37 Kết quả khi xây dựng lại mô hình hồi quy 2 36

1 TỔNG QUAN DỮ LIỆU

Tập dữ liệu này chứa thông tin về một cửa hàng điện tử trực tuyến. Cửa hàng có ba kho để giao hàng cho khách hàng.

Các biến chính trong bộ dữ liệu:

Tên biến	Đơn vị	Ghi chú
order_total	USD	Tổng chi phí đặt hàng đã bao gồm phí vận chuyển và các giảm giá
season	-	Mùa mà đơn hàng được đặt
delivery_charges	USD	Chi phí vận chuyển
customer_lat	-	Vĩ độ vị trí của khách hàng
customer_long	-	Kinh độ vị trí của khách hàng
is_expedited_delivery	-	Khách hàng có hay không yêu cầu giao hàng nhanh
distance_to_nearest_warehouse	km	Khoảng cách đến kho hàng gần nhất

Mục tiêu phân tích:
+ So sánh tổng chi phí đặt hàng ở các mùa.
+ Thực hiện dự báo chi phí vận chuyển các đơn đặt hàng.

2 KIẾN THỨC NỀN

2.1 Hồi quy tuyến tính bội

Mô hình hồi quy tuyến tính bội có dạng tổng quát như sau:

$$\mathrm{Y} = \beta_1 + \beta_2\mathrm{X}_2 + \beta_3\mathrm{X}_3 + \ldots + \beta_\mathrm{k}\mathrm{X}_\mathrm{k} + \mathrm{u}$$

Trong đó:
+ Y: Biến phụ thuộc
+ $\mathrm{X_i}$: Biến độc lập
+ β_1: Hệ số tự do (hệ số chặn)
+ β_i: Hệ số hồi quy riêng.

Như vậy, "Hồi quy tuyến tính" là một phương pháp để dự đoán giá trị biến phụ thuộc (Y) dựa trên giá trị của biến độc lập (X).

2.1.1 Hàm hồi quy tổng thể (PRF - Population Regression Function)

Với Y là biến phụ thuộc X_2, X_3,...,$\mathrm{X_k}$ là biến độc lập, Y là ngẫu nhiên và có một phân phối xác suất nào đó.
Suy ra: Tồn tại $\mathrm{E}\left(\mathrm{Y} \mid \mathrm{X}_2, \mathrm{X}_3, \ldots, \mathrm{X_k}\right)$ = giá trị xác định.
Do vậy, $\mathrm{F}\left(\mathrm{X}_2, \mathrm{X}_3, \ldots, \mathrm{X_k}\right)$=$\mathrm{E}\left(\mathrm{Y} \mid \mathrm{X}_2, \mathrm{X}_3, \ldots, \mathrm{X_k}\right)$ là hàm hồi quy tổng thể của Y theo X_2, X_3,...,$\mathrm{X_k}$.
Với một cá thể i, tồn tại $\left(\mathrm{X}_{2,\mathrm{i}}, \mathrm{X}_{3,\mathrm{i}}, \ldots, \mathrm{X}_{\mathrm{k},\mathrm{i}}, \mathrm{Y}_\mathrm{i}\right)$
Ta có: $\mathrm{Y_i} \neq \mathrm{F}\left(\mathrm{X}_2, \mathrm{X}_3, \ldots, \mathrm{X_k}\right) \Rightarrow \mathrm{u_i} = \mathrm{Y_i} - \mathrm{F}$
Do vậy: $\mathrm{Y_i} = \mathrm{E}\left(\mathrm{Y} \mid \mathrm{X}_2, \mathrm{X}_3, \ldots, \mathrm{X_k}\right) + \mathrm{u_i}$
Hồi quy tổng thể PRF:
+ $\mathrm{Y} = \mathrm{E}(\mathrm{Y} \mid \mathrm{X}) + \mathrm{U}$
+ $\mathrm{E}(\mathrm{Y} \mid \mathrm{X}) = \mathrm{F}(\mathrm{X})$

2.1.2 Hàm hồi quy mẫu (SRF - Sample Regression Function):

Do không biết tổng thể, nên chúng ta không biết giá trị trung bình tổng thể của biến phụ thuộc là đúng ở mức độ nào. Do vậy chúng ta phải dựa vào dữ liệu mẫu để ước lượng. Trên một mẫu có n cá thể, gọi $\hat{Y} = \hat{F}\left(\mathrm{X}_2, \mathrm{X}_3, \ldots, \mathrm{X_k}\right)$ là hồi quy mẫu. Với một cá thể mẫu $\mathrm{Y_i} \neq \hat{F}\left(\mathrm{X}_{2,\mathrm{i}}, \mathrm{X}_{3,\mathrm{i}}, \ldots, \mathrm{X}_{\mathrm{k},\mathrm{i}}\right)$ sinh ra $\mathrm{e_i} - \mathrm{Y_i} - \hat{F}\left(\mathrm{X}_2, \mathrm{X}_3, \ldots, \mathrm{X_k}\right)$; e_i gọi là phần dư SRF. Ta có hàm hồi quy mẫu tổng quát được viết dưới dạng như sau:

$$\hat{y}_\mathrm{i} = \hat{\beta}_1 + \hat{\beta}_2 x_{2,\mathrm{i}} + \hat{\beta}_3 x_{3,\mathrm{i}} + \ldots + \hat{\beta}_\mathrm{k} x_{\mathrm{k},\mathrm{i}}$$

Phần dư sinh ra: $e_i = y_i - \hat{y}_i$ Ký hiệu: $\hat{\beta}_\mathrm{m}$ là ước lượng của β_m. Chúng ta trông đợi $\hat{\beta}_\mathrm{m}$ là ước lượng không chệch của β_m, hơn nữa phải là một ước lượng hiệu quả. Ước lượng SRF: chọn một phương pháp nào đó để ước lượng các tham số của F qua việc tìm các tham số của $\hat{F}$ và lấy giá trị quan sát của các tham số này làm giá trị xấp xỉ cho tham số của F.

2.1.3 Các giả thiết của phương pháp bình phương nhỏ nhất cho mô hình hồi quy tuyến tính bội

Trong khi xây dựng mô hình hồi quy đa biến cần kiểm tra các giả thiết như sau:

a. Hàm hồi quy là tuyến tính theo các tham số.
Điều này có nghĩa là quá trình thực hành hồi quy trên thực tế được miêu tả bởi mối quan hệ dưới dạng: $y = \beta_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \ldots + \beta_k x_k + u$
hoặc mối quan hệ thực tế có thể được viết lại ví dụ như dưới dạng lấy loga cả hai vế.

b. Kỳ vọng của các yếu tố ngẫu nhiên $\mathbf{u_i}$ bằng 0.

Trung bình tổng thể sai số là bằng 0. Điều này có nghĩa là có một số giá trị sai số mang dấu dương và một số sai số mang dấu âm. Do hàm xem như là đường trung bình nên có thể giả định rằng các sai số ngẫu nhiên trên sẽ bị loại trừ nhau, ở mức trung bình, trong tổng thể.

c. Các sai số độc lập với nhau.

d. Các sai số có phương sai bằng nhau.
Tất cả giá trị u được phân phối giống nhau với cùng phương sai σ^2, sao cho: $\mathrm{Var}(u_i) = E\left(u_i^2\right) = \sigma^2$.

e. Các sai số có phân phối chuẩn.
Điều này rất quan trọng khi phát sinh khoảng tin cậy và thực hiện kiểm định giả thuyết trong những phạm vi mẫu là nhỏ. Nhưng phạm vi mẫu lớn hơn, điều này trở nên không mấy quan trọng.

2.1.4 Độ phù hợp của mô hình

Để có thể biết mô hình giải thích được như thế nào hay bao nhiêu % biến động của biến phụ thuộc, người ta sử dụng R^2.

Ta có:
+ $\Sigma\left(y_i - \bar{y}\right)^2$: TSS – Total Sum of Squares
+ $\Sigma\left(\hat{y}_i - \bar{y}\right)^2$: ESS – Explained Sum of Squares
+ Σe_i^2 : RSS – Residual Sum of Squares

Ta có thể viết: $TSS = ESS + RSS$

Ý nghĩa của các thành phần:

+ TSS là tổng bình phương của tất cả các sai lệch giữa các giá trị quan sát Y_i và giá trị trung bình.
+ ESS là tổng bình phương của tất cả các sai lệch giữa các giá trị của biến phụ thuộc Y nhận được từ hàm hồi quy mẫu và giá trị trung bình của chúng. Phần này đo độ chính xác của hàm hồi quy.
+ RSS là tổng bình phương của tất cả các sai lệch giữa các giá trị quan sát Y và các giá trị nhận được từ hàm hồi quy.
+ TSS được chia thành 2 phần: một phần do ESS và một phần do RSS gây ra.

R^2 được xác định theo công thức:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

Tỷ số giữa tổng biến thiên được giải thích bởi mô hình cho tổng bình phương cần được giải thích được gọi là hệ số xác định, hay là trị thống kê "good of fit". Từ định nghĩa R^2 chúng ta thấy R^2 đo tỷ lệ hay số % của toàn bộ sai lệch Y với giá trị trung bình được giải thích bằng mô hình. Khi đó người ta sử dụng R^2 để đo sự phù hợp của hàm hồi quy:

+ $0 \leq R^2 \leq 1$.
+ R^2 cao nghĩa là mô hình ước lượng được giải thích được một mức độ cao biến động của biến phụ thuộc.
+ Nếu $R^2 = 1$, nghĩa là đường hồi quy giải thích 100% thay đổi của y.
+ Nếu $R^2 = 0$, nghĩa là mô hình không đưa ra thông tin nào về sự thay đổi của biến phụ thuộc y.

2.1.5 Khoảng tin cậy và kiểm định các hệ số hồi quy

a. Ước lượng khoảng tin cậy đối với các hệ số hồi quy:

Mục đích của phân tích hồi quy không phải chỉ suy đoán về $\beta_1, \beta_2, \ldots, \beta_k$ mà còn phải kiểm tra

bản chất sự phụ thuộc. Do vậy cần phải biết phân bố xác suất của $\beta_1, \beta_2, \ldots, \beta_{\mathrm{k}}$. Các phân bố này phụ thuộc vào phân bố của các $\mathbf{u}_i$.

Với các giả thiết OLS, $\mathbf{u}_i$ có phân phối $\mathrm{N}\left(0, \sigma^2\right)$. Các hệ số ước lượng tuân theo phân phối chuẩn:

$$\hat{\beta}_j \sim N\left(\hat{\beta}_j, Se\left(\hat{\beta}_j\right)\right)$$

$$\frac{\hat{\beta}_j - \beta_j}{\mathrm{Se}\left(\hat{\beta}_j\right)} \sim T(n-k)$$

Ước lượng phương sai sai số dựa vào các phần dư bình phương tối thiểu. Trong đó k là số hệ số có trong phương trình hồi quy đa biến:

$$\hat{\sigma}^2 = \frac{\sum e_i^2}{n-k}$$

+ Ước lượng 2 phía, ta tìm được $t_{\frac{\alpha}{2}}(n-k)$ thỏa mãn:

$$P\left(-t_{\frac{\alpha}{2}}(n-k)\right) \leq \frac{\hat{\beta}j - \beta j}{\mathrm{Se}(\hat{\beta}j)} \leq P\left(t_{\frac{\alpha}{2}}(n-k)\right) = 1-\alpha$$

+ Khoảng tin cậy $1-\alpha$ của βj là:

$$\left[\hat{\beta}j - t_{\frac{\alpha}{2}}(n-k)\,\mathrm{Se}(\hat{\beta}j); \hat{\beta}j + t_{\frac{\alpha}{2}}(n-k)\,\mathrm{Se}(\hat{\beta}j)\right]$$

b. Kiểm định giả thiết đối với β_{j}

Kiểm định ý nghĩa thống kê của các hệ số hồi quy có ý nghĩa hay không: kiểm định rằng biến giải thích có thực sự ảnh hưởng đến biến phụ thuộc hay không. Nói cách khác là hệ số hồi quy có ý nghĩa thống kê hay không.
Có thể đưa ra giả thiết nào đó đối với β_j, chẳng hạn $\beta_j = \beta_j*$. Nếu giả thiết này đúng thì:

$$T = \frac{\hat{\beta}_j - \beta_j}{\mathrm{Se}\left(\hat{\beta}_j\right)} \sim T(n-k)$$

Ta có bảng sau:

Bảng 1: Bảng tóm tắt giả thuyết và miền bác bỏ tương ứng

Loại giả thiết	**Giả thiết $\mathbf{H_0}$**	**Giả thiết đối $\mathbf{H_1}$**	**Miền bác bỏ**
Hai phía	$\beta_1 = \beta_i^*$	$\beta_i \neq \beta_i^*$	$\lvert t\rvert > t_{\alpha/2;n-k}$
Phía phải	$\beta_1 \leq \beta_i^*$	$\beta_i > \beta_i^*$	$t > t_{\alpha;n-k}$
Phía trái	$\beta_1 \geq \beta_i{}^*$	$\beta_1 < \beta_i^*$	$t < -t_{\alpha;n-k}$

Ta có thể sử dụng giá trị P-value: P-value < mức ý nghĩa thì bác bỏ giả thiết H_0

Kiểm định β_{j}:
Giả thuyết $\mathrm{H}_0 : \beta_{\mathrm{j}} = 0 \Leftrightarrow \mathrm{x_j}$ không tác động
Giả thuyết $\mathrm{H}_1 : \beta_{\mathrm{j}} \neq 0 \Leftrightarrow \mathrm{x_j}$ có tác động.
$\beta_{\mathrm{j}} < 0 \Leftrightarrow \mathrm{x_j}$ có tác động ngược
$\beta_{\mathrm{j}} > 0 \Leftrightarrow \mathrm{x_j}$ có tác động thuận

2.1.6 Kiểm định mức độ ý nghĩa chung của mô hình (trường hợp đặc biệt của kiểm định WALD)

a. Khái quát về kiểm định WALD.

Giả sử chúng ta có 2 mô hình dưới đây:
(U) : $Y = \beta_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + u$
(R) : $Y = \beta_1 + \beta_2 X_2 + v$

Mô hình U được gọi là mô hình không giới hạn (Unrestrict), và mô hình R được gọi là mô hình giới hạn (Restrict). Đó là do β_3 và β_4 buộc phải bằng 0 trong mô hình R. Ta có thể kiểm định giả thuyết liên kết $\beta_3 = \beta_4 = 0$ với giả thuyết đối là ít nhất một trong những hệ số này không bằng 0. Kiểm định giả thuyết liên kết này được gọi là kiểm định Wald, thủ tục như sau.

Đặt các mô hình giới hạn và không giới hạn là:
(U) : $Y = \beta_1 + \beta_2 X_2 + \ldots + \beta_m X_m + \beta_{m+1} X_{m+1} + \ldots + \beta_k X_k + u$
(R) : $Y = \beta_1 + \beta_2 X_2 + \ldots + \beta_m X_m + v$ Mô hình (R) có được bằng cách bỏ bớt một số biến ở mô hình (U), đó là:X_{m+1}, X_{m+1},... X_k

Giả thuyết $H_0 : \beta_{m+1} = \ldots = \beta_k = 0$
Giả thuyết H_1 : "Không phải đồng thời các tham số bằng 0".

Lưu ý rằng (U) chứa k hệ số hồi quy chưa biết và (R) chứa m hệ số hồi quy chưa biết. Do đó, mô hình R có ít hơn (k − m) thông số so với U. Câu hỏi chúng ta nêu ra là (k − m) biến bị loại ra có ảnh hưởng liên kết có ý nghĩa đối với Y hay không.
Trị thống kê kiểm định đối với giả thiết này là:

$$Fc = \frac{[RSS_R - RSS_U]/(k-m)}{RSS_U/(n-k)} \sim F(\alpha, k-m, n-k) = \frac{R_U^2 - R_R^2/(k-m)}{1 - R_U^2/(n-k)}$$

Với R^2 là số đo độ thích hợp không hiệu chỉnh. Với giả thuyết không, F_c có phân phối F với (k − m) bậc tự do đối với tử số và (n − k) bậc tự do đối với mẫu số.

Bác bỏ giả thuyết H_0 khi:

$$F_c > F(\alpha, k-m, n-k)$$

Hoặc giá trị p-value của thống kê F nhỏ hơn mức ý nghĩa cho trước.

b. Kiểm định ý nghĩa của mô hình.

Trong mô hình hồi quy đa biến, giả thuyết "không" cho rằng mô hình không có ý nghĩa được hiểu là tất cả các hệ số hồi quy riêng đều bằng 0.

Ứng dụng kiểm định Wald (thường được gọi là kiểm định F) được tiến hành cụ thể như sau:

Bước 1: Giả thuyết H_0: $\beta_2 = \beta_3 = \ldots = \beta_k = 0$.
Giả thuyết H_1: "có ít nhất một trong những giá trị β khác không".
Bước 2: Trước tiên hồi quy Y theo một số hạng không đổi và $X_2, X_3, \ldots, X_k$, sau đó tính tổng bình phương sai số RSS_U, RSS_R. Phân phối F là tỷ số của hai biến ngẫu nhiên phân phối khi bình phương độc lập. Điều này cho ta trị thống kê:

$$F_c = \frac{[RSS_R - RSS_U]/(k-m)}{RSS_U/(n-k)} \sim F(\alpha, k-m, n-k)$$

Vì $H_0 : \beta_2 = \beta_3 = \ldots = \beta_k = 0$, nhận thấy rằng trị thống kê kiểm định đối với giả thuyết này sẽ là:

$$F_c = \frac{ESS/(k-1)}{RSS/(n-k)} \sim F(\alpha, k-1, n-k)$$

Bước 3: Tra số liệu trong bảng F tương ứng với bậc tự do (k − 1) cho tử số và (n − k) cho mẫu số, và với mức ý nghĩa α cho trước.

Bước 4: Bác bỏ giả thuyết H_0 ở mức ý nghĩa α nếu $F_c > F(\alpha, k-1, n-k)$

Đối với phương pháp giá trị p-value, tính giá trị $p = P\left(F > F_c \mid H_0\right)$ và bác bỏ giả thuyết H_0 nếu p bé hơn mức ý nghĩa α.

2.2 Phân tích phương sai một yếu tố

2.2.1 Lý thuyết về ANOVA (Phân tích phương sai)

Mục tiêu của phân tích phương sai (Analysis of Variance - ANOVA) là so sánh trung bình của nhiều nhóm (tổng thể) dựa trên các trị trung bình của các mẫu quan sát từ các nhóm này và thông qua kiểm định giả thuyết của kết luận về sự bằng nhau của các trung bình tổng thể này.

Ta có các mô hình phân tích phương sai: phân tích phương sai một yếu tố và hai yếu tố. Cụm từ yếu tố ở đây ám chỉ số lượng yếu tố nguyên nhân ảnh hưởng đến yếu tố kết quả đang nghiên cứu.

2.2.2 Phân tích phương sai một yếu tố

Phân tích phương sai một yếu tố (One way ANOVA) là phân tích ảnh hưởng của một yếu tố nguyên nhân (dạng biến định tính) ảnh hưởng đến một yếu tố kết quả (dạng biến định lượng) đang nghiên cứu.

a. **Trường hợp k tổng thể có phân phối chuẩn và phương sai bằng nhau**

Giả sử rằng chúng ta muốn so sánh trung bình của k tổng thể (với ví dụ trên thì k = 3) dựa trên những mẫu ngẫu nhiên độc lập gồm $n_1, n_2, n_3, \ldots, n_k$ quan sát từ k tổng thể. Cần ghi nhớ ba giả định sau đây về các nhóm tổng thể được tiến hành phân tích ANOVA.

+ Các tổng thể này có phân phối bình thường.
+ Các phương sai tổng thể bằng nhau
+ Các quan sát được lấy mẫu là độc lập nhau.

Nếu trung bình của các tổng thể được ký hiệu là $\mu_1 = \mu_2 = ... = \mu_k$ thì khi các giả định trên được đáp ứng, mô hình phân tích phương sai một yếu tố ảnh hưởng được mô tả dưới dạng kiểm định giả thuyết như sau:

$$H_0\text{: } \mu_1 = \mu_2 = ... = \mu_k$$

Và giả thuyết đối là:

$$H_1\text{: Tồn tại ít nhất một cặp trung bình tổng thể khác nhau.}$$

Các bước thực hiện:

<u>Bước 1</u>: Tính các trung bình mẫu của các nhóm (xem như đại diện của các tổng thể) Trước hết ta xem cách tính các trung bình mẫu từ những quan sát của k mẫu ngẫu nhiên độc lập (ký hiệu $\bar{x}_1\bar{x}_2, ...\bar{x}_k$) và trung bình chung của k mẫu quan sát (ký hiệu $\bar{x}$) từ trường hợp tổng quát như sau:
Tính trung bình mẫu của từng nhóm $\bar{x}_1\bar{x}_2, ...\bar{x}_k$ theo công thức:

$$\bar{x}_1 = \frac{\sum_{j=1}^{n_i} x_{ij}}{n_i} \ (i = 1, 2, ...k)$$

Bảng 2: Bảng số liệu tổng quát thực hiện phân tích phương sai.

Tổng thể			
1	2	3	4
X_{11}	X_{21}	...	X_{k1}
X_{11} ... X_{1n1}	X_{22} ... X_{2n2}	... ...	X_{k1} ... X_{knk}

Và trung bình chung của k mẫu (trung bình chung của toàn bộ mẫu khảo sát):

$$\bar{x} = \frac{\sum_{i=1}^{k} n_i.\bar{x}_i}{\sum_{i=1}^{k} n_i}$$

<u>Bước 2</u>: Tính các tổng các chênh lệch bình phương (hay gọi tắt là tổng bình phương) Tính tổng các chênh lệch bình phương trong nội bộ nhóm SSW^1và tổng các chênh lệch bình phương giữa các nhóm SSG^2.

+ Tổng các chênh lệch bình phương trong nội bộ nhóm (SSW) được tính bằng cách cộng các chênh lệch bình phương giữa các giá trị quan sát với trung bình mẫu của từng nhóm, rồi sau đó lại tính tổng cộng kết quả tất cả các nhóm lại. SSW phản ánh phần biến thiên của yếu tố kết quả do ảnh hưởng của các yếu tố khác, chứ không phải do yếu tố nguyên nhân đang nghiên cứu (là yếu tố dùng để phân biệt các tổng thể / nhóm đang so sánh).

+ Tổng các chênh lệch bình phương của từng nhóm được tính theo công thức:
Nhóm 1: $SS_1 = \sum_{j=1}^{n_i} (x_{1j} - \bar{x}_1)^2$
Nhóm 2: $SS_2 = \sum_{j=1}^{n_i} (x_{2j} - \bar{x}_2)^2$

Tương tự như vậy ta tính cho đến nhóm thứ k được SS_k. Vậy tổng các chênh lệch bình phương trong nội bộ các nhóm được tính như sau:

$$SSW = SS_1 + SS_2 + ... + SS_k$$

+ Tổng các chênh lệch bình phương giữa các nhóm (SSG) được tính bằng cách cộng các chênh lệch được lấy bình phương giữa các trung bình mẫu của từng nhóm với trung bình chung của k nhóm (các chênh lệch này đều được nhân thêm với số quan sát tương ứng cả từng nhóm). SSG phản ánh phần biến thiên của yếu tố kết quả do ảnh hưởng của yếu tố nguyên nhân đang nghiên cứu.

$$SSG = \sum_{i=1}^{k} n_i(\bar{x}_i - \bar{x})^2$$

Tổng các chênh lệch bình phương toàn bộ SST được tính bằng cách cộng tổng các chênh lệch đã lấy bình phương giữa từng giá trị quan sát của toàn bộ mẫu nghiên cứu (x_{ij}) với trung bình toàn bộ (x). SST phản ánh biến thiên của yếu tố kết quả do ảnh hưởng của tất cả các nguyên nhân.

$$SST = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2$$

Có thể dễ dàng chứng minh là tổng các chênh lệch bình phương toàn bộ bằng tổng cộng tổng các chênh lệch bình phương trong nội bộ các nhóm và tổng các chênh lệch bình phương giữa các nhóm.

$$SST = SSW + SSG$$

Như vậy công thức trên cho thấy, SST là toàn bộ biến thiên của yếu tố kết quả đã được phân tích thành hai phần: phần biến thiên do yếu tố đang nghiên cứu tạo ra (SSG) và phần biến thiên còn lại do các yếu tố khác không nghiên cứu ở đây tạo ra (SSW). Nếu phần biến thiên do yếu tố nguyên nhân đang xét tạo ra càng "đáng kể" so với phần biến thiên do các yếu tố khác không cét tạo ra, thì chúng ta càng có cơ sở để bác bỏ H_0 và kết luận là yếu tố nguyên nhân đang nghiên cứu ảnh hưởng có ý nghĩa đến yếu tố kết quả.

Bước 3: Tính các phương sai (là trung bình của các chênh lệch bình phương). Các phương sai được tính bằng cách lấy các tổng chênh lệch bình phương chia cho bậc tự do tương ứng.

Tính phương sai trong nội bộ nhóm (MSW) bằng cách lấy tổng các chênh lệch bình phương trong nội bộ các nhóm (SSW) chia cho bậc tự do tương ứng là n - k (n là số quan sát, k là số nhóm so sánh). MSW là ước lượng phần biến thiên của yếu tố kết quả do các yếu tố khác gây ra.

$$MSW = \frac{SSW}{n-k}$$

Tính phương sai giữa các nhóm (MSG) bằng cách lấy tổng các chênh lệch bình phương giữa các nhóm chia cho bậc tự do tương ứng là k - 1. MSG là ước lượng phần biến thiên của yếu tố kết quả do yếu tố nguyên nhân đang nghiên cứu gây ra.

$$MSG = \frac{SSG}{k-1}$$

Bước 4: Kiểm định giả thuyết:
Giả thuyết về sự bằng nhau của k trung bình tổng thể được quyết đinh dựa trên tỉ số của hai phương sai: phương sai giữa các nhóm (MSG) và phương sai trong nội bộ nhóm (MSW). Tỉ số này gọi là tỉ số F vì nó tuân theo định luật Fisher – Snedecor với bậc tự do k - 1 ở tử số và n - k ở mẫu số.

$$F = \frac{MSG}{MSW}$$

Ta bác bỏ giả thuyết H_0 cho rằng trị trung bình của k tổng thể bằng nhau khi:

$$F > F_{k-1;n-k;\alpha}$$

$F > F_{k-1;n-k;\alpha}$ là giá trị giới hạn với bậc tự do k tra theo hàng đầu tiên và n – k tra theo cột đầu tiên, nhớ chọn bảng với mức ý nghĩa phù hợp.

Sau đây là dạng bảng kết quả tổng quát của ANOVA khi phân tích bằng chương tình Excel hay SPSS.

Bảng 3: Bảng kết quả tổng quát của ANOVA khi phân tích bằng Excel hay SPSS.

Nguồn biến thiên	Tổng bình phương	Bậc tự do	Phương sai	Tỉ số F
Giữa các nhóm	SSG	$k-1$	$MSG = \frac{SSG}{k-1}$	$F = \frac{MSG}{MSW}$
Trong nội bộ nhóm	SSW	$n-k$	$MSW = \frac{SSW}{n-k}$	
Toàn bộ	SST	$n-1$		

b. Kiểm tra các giả định của phân tích phương sai

Chúng ta có thể kiểm tra nhanh các giả định này bằng đồ thị. Histogram là phương pháp tốt nhất để kiểm tra giả định về phân phối chuẩn của dữ liệu nhưng nó đòi hỏi một số lượng quan sát khá lớn. Biểu đồ thân lá hay biểu đồ hộp và râu là một thay thế tốt trong tình huống số quan sát ít hơn. Nếu

công cụ đồ thị cho thấy tập dữ liệu mẫu khá phù hợp với phân phối bình thường thì ta có thể xem giả định phân phối bình thường đã thỏa mãn.

Một phương pháp kiểm định tham số chắc chắn hơn cho giả định phương sai bằng nhau là kiểm định Levene về phương sai của các tổng thể. Kiểm định này xuất phát từ giả thyết sau.

$H_0 : \sigma_1^2 = \sigma_2^2 = ... = \sigma_k^2$
H_1: có ít nhất một cặp phương sai khác nhau.

Để quyết định chấp nhận hay bác bỏ H_0 ta tính toán giá trị kiểm định F theo công thức:

$$F_{max} = \frac{S_{max}^2}{S_{min}^2}$$

Trong đó:
S_{max}^2 là phương sai lớn nhất trong các nhóm nghiên cứu và S_{min}^2 là phương sai nhỏ nhất trong các nhóm nghiên cứu.

Giá trị F tính được được đem so sánh với giá trị $F_{k;df;\alpha}$ tra được từ bảng phân phối Hartley F_{max}. Trong đó, k là số nhóm so sánh, bậc tự do df tính theo công thức $df = (\bar{n} - 1)$.

Trong tình huống, các nhóm có số quan sát khác nhau thì $\bar{n} = \frac{\sum_{i=1}^{k} n_i}{k}$ (chú ý là nếu kết quả tính $\bar{n}$ là một số thập phân thì ta lấy phần nguyên).

Quy tắc quyết định:
$F_{max} > F_{k;df;\alpha}$ thì bác bỏ giả thuyết H_0 cho rằng phương sai bằng nhau và ngược lại.

Nếu chúng ta không chắc chắn về các giả định hoặc nếu kết quả kiểm định cho thấy các giả định không được thỏa mãn thì một phương pháp kiểm định thay thế cho ANOVA là phương pháp kiểm định phi tham số Kruskal - Wallis sẽ được áp dụng.

c. Phân tích sâu ANOVA

Mục đích của phân tích phương sai là kiểm định giả thuyết H_0 rằng trung bình của tổng thể bằng nhau. Sau khi phân tích và kết luận, có hai trường hợp xảy ra là chấp thuận giả thuyết H_0 hoặc bác bỏ giả thuyết H_0. Nếu chấp nhận giả thuyết H_0 thì phân tích kết thúc. Nếu bác bỏ giả thuyết H_0, bạn kết luận trung bình của các tổng thể không bằng nhau. Vì vậy, vấn đề tiếp theo là phân tích sâu hơn để xác minh nhóm (tổng thể) nào khác nhóm nào, nhóm nào có trung bình lớn hơn hay nhỏ hơn.

Có nhiều phương pháp để tiếp tục phân tích sâu ANOVA khi bác bỏ giả thyết H_0. Trong phần này chỉ đề cập đến một phương pháp thông dụng đó là phương pháp Tukey, phương pháp này còn được gọi là kiểm định HSD (Honestly Significant Differences). Nội dung của phương pháp này là so sánh từng cặp các trung bình nhóm ở mức ý nghĩa nào đó cho tất cả các cặp kiểm định có thể để phát hiện ra những nhóm khác nhau. Nếu có k nhóm nghiên cứu và chúng ta so sánh tất cả các cặp nhóm thì số lượng cặp cần phải so sánh là tổ hợp chập 2 của k nhóm.

$$C_2^k = \frac{k!}{2!(k-2)!} = \frac{k(k-1)}{2}$$

Giá trị giới hạn Tukey được tính theo công thức:

$$T = q_{\alpha;k;n-k}\sqrt{\frac{MSW}{n_i}}$$

Trong đó:

+ $q_{\alpha;k;n-k}$ là giá trị tra bảng phân phối kiểm định Tukey ở mức ý nghĩa, với bậc tự do k và n – k, với n là tổng số quan sát mẫu ($n = \Sigma n_i$).
+ MSW là phương sai trong nội bộ nhóm.
+ n_i là số quan sát trong một nhóm (tổng thể), trong trường hợp mỗi nhóm có số quan sát ni khác nhau, sử dụng giá trị n_i nhỏ nhất.

Tiêu chuẩn quyết định là bác bỏ giả thuyết H_0 khi độ lệch tuyệt đối giữa các cặp trung bình mẫu lớn hơn hay bằng T giới hạn.

Bên cạnh việc kiểm định để phát hiện ra những nhóm khác biệt, chúng ta có thể tìm khoảng ước lượng cho chênh lệch giữa các nhóm có khác biệt có ý nghĩa thống kê. Ước lượng khoảng về chênh lệch giữa hai trung bình nhóm có khác biệt tính theo công thức:

$$\mu_1 - \mu_2 = (\bar{x}_1 - \bar{x}_2) \pm (t_{n-k;\frac{\alpha}{2}} \sqrt{\frac{2MSW}{n_i}})$$

Trong đó, t là giá trị được tra từ bảng phân phối Student t với (n - k) bậc tự do. Trong chương trình Excel không có các lệnh phân tích sâu ANOVA. Chúng ta có thể thực hiện phân tích này bằng chương trình SPSS. Ngoài ra kết quả của SPSS còn cung cấp cho các bạn một kiểm định chính thức về sự bằng nhau của các phương sai tổng thể là kiểm định Levene.

3 TIỀN XỬ LÝ SỐ LIỆU

3.1 Đọc dữ liệu

Đọc tệp tin "dirty_data.csv" vào R.

```
dirty_data <- read.csv("~/Desktop/dirty_data.csv")
```

Kiểm tra một số thông tin về tệp tin "dirty_data.csv"

```
str(dirty_data)
```

Hình 1: Kết quả khi kiểm tra một số thông tin về tệp tin

```
## 'data.frame':    500 obs. of  16 variables:
##  $ order_id                    : chr  "ORD182494" "ORD395518" "ORD494479" "ORD019224" ...
##  $ customer_id                 : chr  "ID6197211592" "ID0282825849" "ID0579391891" "ID4544561904" ...
##  $ date                        : chr  "2019-06-22" "2019-12-29" "2019-03-02" "2019-01-12" ...
##  $ nearest_warehouse           : chr  "Thompson" "Thompson" "Nickolson" "Nickolson" ...
##  $ shopping_cart               : chr  "[('Lucent 330S', 1), ('Thunder line', 2), ('iStream', 2), ('pearTV',
1)]" "[('Thunder line', 1), ('Universe Note', 2)]" "[('Thunder line', 1), ('pearTV', 2)]" "[('Universe Note', 1),
('Alcon 10', 2), ('Olivia x460', 1), ('iAssist Line', 1)]" ...
##  $ order_price                 : int  12200 9080 10670 24800 9145 7810 13700 7960 25390 13320 ...
##  $ delivery_charges            : num  79.9 62.7 65.9 57.6 75.5 ...
##  $ customer_lat                : num  -37.8 -37.8 -37.8 -37.8 37.8 ...
##  $ customer_long               : num  145 145 145 145 145 ...
##  $ coupon_discount             : int  10 0 10 15 25 10 5 5 10 15 ...
##  $ order_total                 : num  11060 9143 9669 21138 6934 ...
##  $ season                      : chr  "Winter" "Summer" "Autumn" "Summer" ...
##  $ is_expedited_delivery       : chr  "True" "False" "False" "False" ...
##  $ distance_to_nearest_warehouse: num  1.28 1.162 1.095 0.857 0.587 ...
##  $ latest_customer_review      : chr  "perfect phone and trusted seller. phone itself is amazing. i got this
phone as shown here on the description. i"| __truncated__ "it keeps dropping calls the wifi don't work this is a
waste of money this phone is worthless, it keeps dropping"| __truncated__ "five stars this is a great cheap phon
e." "charger did not fit the charger didn't fit." ...
##  $ is_happy_customer           : chr  "True" "False" "True" "False" ...
```

3.2 Làm sạch dữ liệu

Tạo tệp tin con bao gồm các biến chính cần phân tích và xem 10 dòng đầu tiên.

```
new_data <- dirty_data[,c("order_total", "season", "delivery_charges",
  "customer_lat","customer_long","is_expedited_delivery",
  "distance_to_nearest_warehouse")]
head(new_data,10)
```

Hình 2: Kết quả khi xem 10 dòng đầu tiên của tệp tin new_data

```
##    order_total season delivery_charges customer_lat customer_long
## 1     11059.89 Winter            79.89    -37.81511      144.9328
## 2      9142.71 Summer            62.71    -37.80274      144.9511
## 3      9668.87 Autumn            65.87    -37.82130      144.9576
## 4     21137.61 Summer            57.61    -37.81142      144.9731
## 5      6934.29 Spring            75.54     37.82386      144.9699
## 6      7100.22 Spring            71.22     37.82025      145.0149
## 7     13089.84 Spring            74.84    -37.80774      144.9516
## 8     10789.79 Autumn            52.28    -37.80634      144.9595
## 9     22958.58 Spring           107.58    -37.81081      145.0141
## 10    11384.26 winter            62.26    -37.80868      144.9423
##    is_expedited_delivery distance_to_nearest_warehouse
## 1                   True                        1.2800
## 2                  False                        1.1621
## 3                  False                        1.0949
## 4                  False                        0.8571
## 5                  False                        0.5867
## 6                  False                        2.0752
## 7                  False                        0.6767
## 8                  False                        1.3043
## 9                   True                        1.6595
## 10                  True                        0.6093
```

Kiểm tra dữ liệu khuyết.

```
apply(is.na(new_data),2,which)
```

Hình 3: Kết quả khi kiểm tra dữ liệu khuyết

```
## integer(0)
```

Nhận xét: Tệp tin không chứa dữ liệu khuyết.

Thực hiện kiểm tra các giá trị của season.

```
  unique(new_data$season)
```

Hình 4: Kết quả khi kiểm tra các giá trị của season.

```
## [1] "Winter" "Summer" "Autumn" "Spring" "winter" "spring" "autumn" "summer"
```

Nhận xét: Kết quả cho thấy có lỗi định dạng viết thường 4 mùa "spring", "summer", "autumn", "winter"

Ta thực hiện thay các giá trị "spring" = "Spring", "summer" = "Summer", "autumn" = "Autumn", "winter" = "Winter" và kiểm tra lại kết quả:

```
new_data$season[new_data$season == 'spring'] <- 'Spring'
new_data$season[new_data$season == 'summer'] <- 'Summer'
new_data$season[new_data$season == 'autumn'] <- 'Autumn'
new_data$season[new_data$season == 'winter'] <- 'Winter'
unique(new_data$season)
```

Hình 5: Kết quả khi kiểm tra lại các giá trị của season.

```
## [1] "Winter" "Summer" "Autumn" "Spring"
```

4 THỐNG KÊ MÔ TẢ

4.1 Thống kê mô tả cho các biến định lượng

Tính thống kê mô tả cho các biến định lượng.

```
des_function <- function(x) {c(mean(x),median(x),sd(x),min(x),max(x))}
des_table <-apply(new_data[,c("delivery_charges","customer_lat","customer_long",
      "order_total","distance_to_nearest_warehouse")],2,des_function)
rownames(des_table)=c("mean","median","sd","min","max")
des_table
```

Hình 6: Kết quả khi kiểm tính thống kê mô tả cho các biến định lượng.

```
##        order_total delivery_charges customer_lat customer_long
## mean      39209.67         76.65820    -35.83523  144.96949418
## median    11293.96         76.31000    -37.81217  144.96535685
## sd       274194.02         14.48146     12.04539    0.02272027
## min         639.29         46.35000    -37.82712  144.92496720
## max     5688269.60        114.04000     37.82634  145.01983750
##        distance_to_nearest_warehouse
## mean                        2.204224
## median                      1.030100
## sd                          8.812416
## min                         0.107800
## max                        94.973400
```

4.2 Thống kê số lượng cho các biến phân loại

Lập bảng thống kê số lượng cho mỗi phân loại của biến season.

```r
table(new_data$season)
```

Hình 7: Kết quả khi lập bảng thống kê số lượng mỗi phân loại của biến season.

```
##
## Autumn Spring Summer Winter
##    127    134    124    115
```

Lập bảng thống kê số lượng cho mỗi phân loại của biến is_expedited_delivery.

```r
table(new_data$is_expedited_delivery)
```

Hình 8: Kết quả khi lập bảng thống kê số lượng mỗi phân loại của biến is_expedited_delivery.

```
##
##   0   1
## 251 249
```

4.3 Mô tả dữ liệu bằng đồ thị

4.3.1 Đồ thị Histogram

Vẽ đồ thị Histogram thể hiện phân phối của order_total.

```r
hist(new_data$order_total,xlab="order_total",main="Histogram of order_total",
    col="lightblue")
```

Hình 9: Kết quả khi vẽ đồ thị Histogram thể hiện phân phối của order_total.

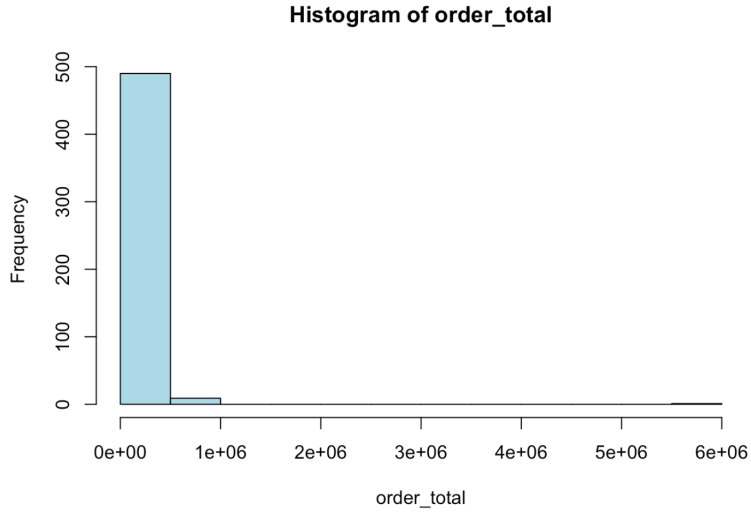

Nhận xét: Hầu hết các đơn hàng đều có tổng chi phí đặt hàng dưới 500000 USD.

4.3.2 Đồ thị Boxplot

Vẽ biểu đồ Boxplot thể hiện phân phối của order_total theo season.

```
boxplot(order_total~season,new_data)
```

Hình 10: Kết quả khi vẽ Boxplot thể hiện phân phối của order_total theo season.

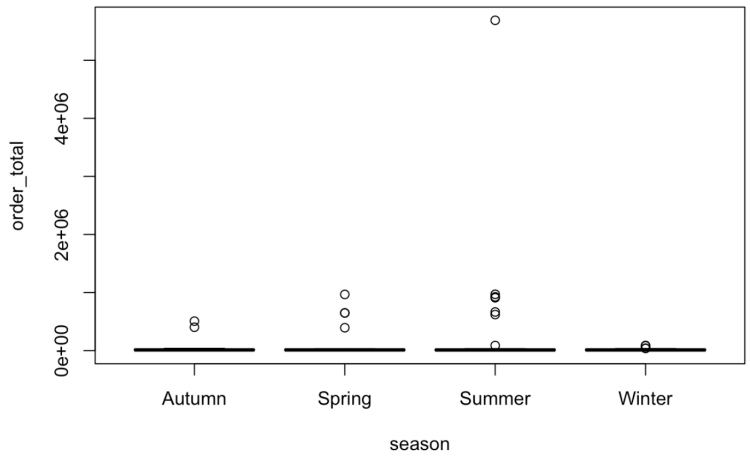

Nhận xét: Đồ thị cho thấy có nhiều điểm ngoại lai xa khiến ta không thể so sánh được phân phối của order_total theo season. Vì thế ta sẽ thực hiện đề xuất phương pháp phù hợp để xử lý các ngoại lai này.
Tạo hàm thực hiện tìm các ngoại lai và chuyển ngoại lai thành NA.

```
rm.out <- function(x, na.rm = TRUE, ...){
  qnt <- quantile(x, probs=c(.25, .75), na.rm = na.rm, ...)
  H <- 1.5 * IQR(x, na.rm = na.rm)
  y <- x
  y[x < (qnt[1] - H)] <- NA
  y[x > (qnt[2] + H)] <- NA
  y
}
```

Thực hiện sử dụng hàm vừa tạo và thực hiện trên các bộ dữ liệu được phân theo season.

```
Spring_data = subset(new_data,new_data$season =="Spring")
Spring_data$order_total = rm.out(Spring_data$order_total)

Summer_data = subset(new_data,new_data$season =="Summer")
Summer_data$order_total = rm.out(Summer_data$order_total)

Autumn_data = subset(new_data,new_data$season =="Autumn")
Autumn_data$order_total = rm.out(Autumn_data$order_total)

Winter_data = subset(new_data,new_data$season =="Winter")
Winter_data$order_total = rm.out(Winter_data$order_total)
```

Ghép các bộ dữ liệu sau khi tìm ngoại lại và thực hiện kiểm tra các dữ liệu NA (là các ngoại lai được tìm thấy).

```
new_data_2 <- rbind(Spring_data,Summer_data,Autumn_data,Winter_data)
apply(is.na(new_data_2),2,sum)
apply(is.na(new_data_2),2,mean)
```

Hình 11: Kết quả khi kiểm tra các dữ liệu NA (là các ngoại lai được tìm thấy)

```
##                  order_total                       season
##                           17                            0
##             delivery_charges                  customer_lat
##                            0                            0
##                 customer_long         is_expedited_delivery
##                            0                            0
## distance_to_nearest_warehouse
##                            0
```

```
##                  order_total                       season
##                        0.034                        0.000
##             delivery_charges                  customer_lat
##                        0.000                        0.000
##                 customer_long         is_expedited_delivery
##                        0.000                        0.000
## distance_to_nearest_warehouse
##                        0.000
```

Nhận xét: Ta tìm thấy 17 quan sát là ngoại lai (chiếm tỷ lệ 3.4% so với toàn bộ quan sát). Vì lượng dữ liệu ngoại lai nhỏ nên ta sẽ chọn phương pháp xoá các các giá trị ngoại lai này và vẽ lại đồ thị.

```
new_data_2<-na.omit(new_data_2)
boxplot(order_total~season,new_data_3,col=c(2,3,5,6))
```

Hình 12: Kết quả khi vẽ lại Boxplot thể hiện phân phối của order_total theo season

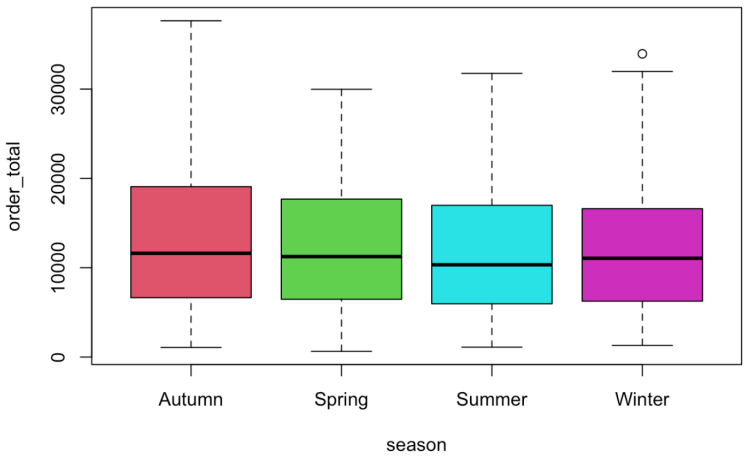

Nhận xét: ta dự đoán không có sự khác biệt nhiều về tổng chi phí đặt hàng ở các đơn hành theo các mùa.

Vẽ biểu đồ Boxplot thể hiện phân phối của delivery_charges theo season.

```
boxplot(Delivery_charges~seasson,new_data,col=c(2,3,5,6))
```

Hình 13: Kết quả khi vẽ Boxplot thể hiện phân phối của delivery_charges theo season

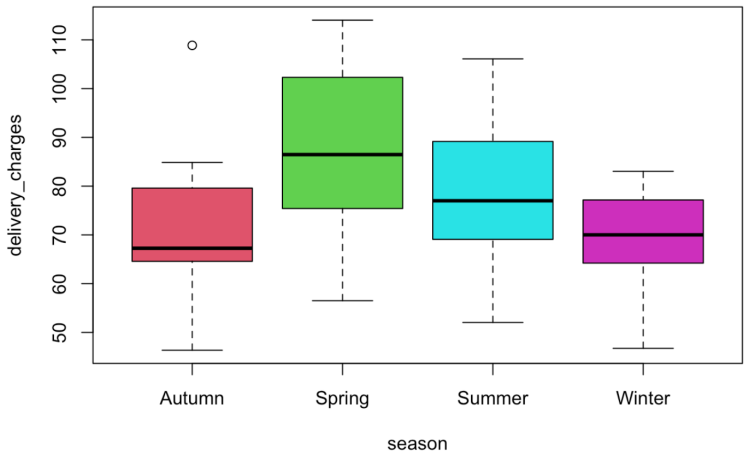

Nhận xét: ta thấy chi phí vận chuyển mùa xuân và mùa hè cao hơn so với mùa thu và mùa đông. Ta dựa đoán yếu tố mùa có ảnh hưởng đến chi phí vận chuyển.

Vẽ biểu đồ Boxplot thể hiện phân phối của delivery_charges theo is_expedited_delivery.

```
boxplot(Delivery_charges~is_expedited_delivery,new_data,col=c(2,3))
```

Hình 14: Kết quả khi vẽ Boxplot thể hiện phân phối của delivery_charges theo is_expedited_delivery

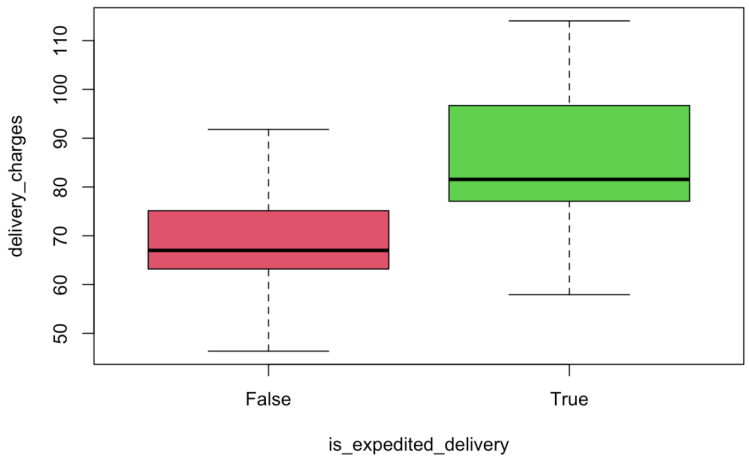

Nhận xét: ta thấy chi phí vận chuyển ở hình thức giao hàng nhanh cao hơn so với hình thức không có giao hàng nhanh. Ta dựa đoán yếu tố hình thức giao hàng có ảnh hưởng đến chi phí vận chuyển.

4.3.3 Đồ thị Scatter / Plot

Vẽ đồ thị phân tán thể hiện mối quan hệ tuyến tính giữa delivery_charges theo các biến customer_lat, customer_long, distance_to_nearest_warehouse.

```r
par(mfrow=c(1,3))
plot(delivery_charges~customer_lat,main="Customer_lat & Delivery_charges",
    col="darkred",data=new_data)
plot(delivery_charges~customer_long,main="Customer_long & Delivery_charges",
    col="darkred",data=new_data)
plot(delivery_charges~distance_to_nearest_warehouse,main="Distance to NW & Delivery_
    charges", col="darkred",data=new_data)
```

Hình 15: Kết quả khi vẽ đồ thị phân tán giữa Delivery_charges theo các biến customer_lat, customer_long, distance_to_nearest_warehouse.

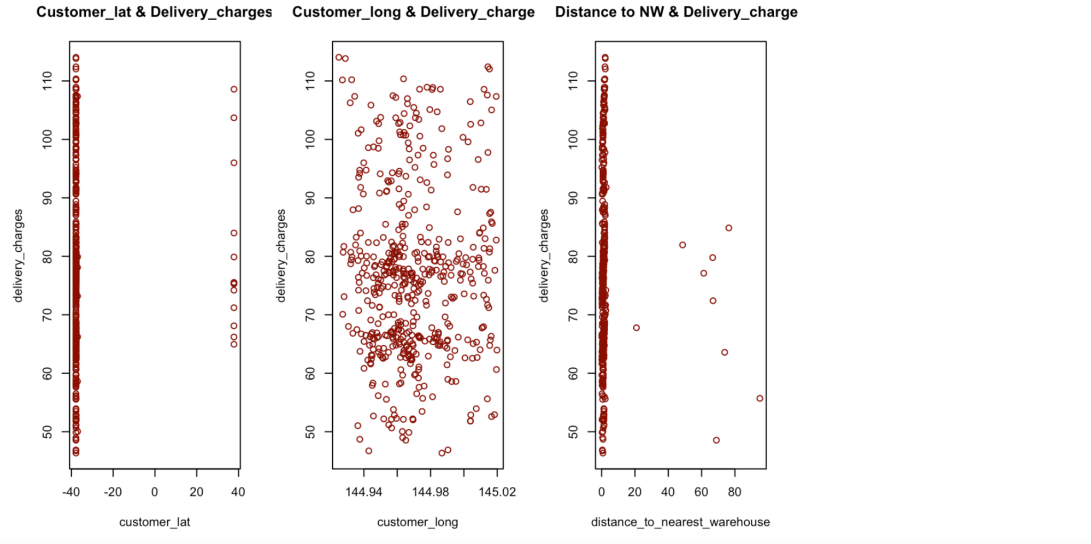

Nhận xét: ta nhận thấy các biến đều có quan hệ tuyến tính yếu (hoặc không có quan hệ tuyến tính) với Delivery_charges.

4.3.4 Đồ thị ma trận tương quan

Vẽ đồ thị ma trận tương quan kiểm tra hiện tượng đa cộng tuyến giữa các biến độc lập.

```r
cor_maxtrix <- cor(new_data[,c("delivery_charges","customer_lat","customer_long",
                "distance_to_nearest_warehouse")])
library(corrplot)
corrplot(cor_maxtrix,method="number")
```

Hình 16: Kết quả khi vẽ đồ thị ma trận tương quan

```
corrplot(cor_maxtrix,method="number")
```

Nhận xét: ta nhận thấy hệ số tương quan ứng với từng cặp biến độc lập đều gần bằng 0, cho thấy các biến độc lập không có quan hệ tuyến tính, do đó không xảy ra hiện tượng đa cộng tuyến.

5 THỐNG KÊ SUY DIỄN

5.1 Anova một nhân tố: So sánh tổng chi phí đặt hàng theo mùa

Ta sẽ tách dữ liệu theo từng mùa:

```
Spring_data_2<-subset(new_data_2,season =="Spring")
Summer_data_2<-subset(new_data_2,season =="Summer")
Autumn_data_2<-subset(new_data_2,season =="Autumn")
Winter_data_2<-subset(new_data_2,season =="Winter")
```

Các giả định cần kiểm tra :

+ Tổng chi phí đặt hàng ở các mùa tuân theo phân phối chuẩn.
+ Phương sai tổng chi phí đặt hàng ở các mùa bằng nhau.

Kiểm định giả định về phân phối chuẩn:

+ Đối với mùa xuân, ta thực hiện vẽ đồ thị:

```
qqnorm(Spring_data_2$order_total)
qqline(Spring_data_2$order_total)
```

Hình 17: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa xuân

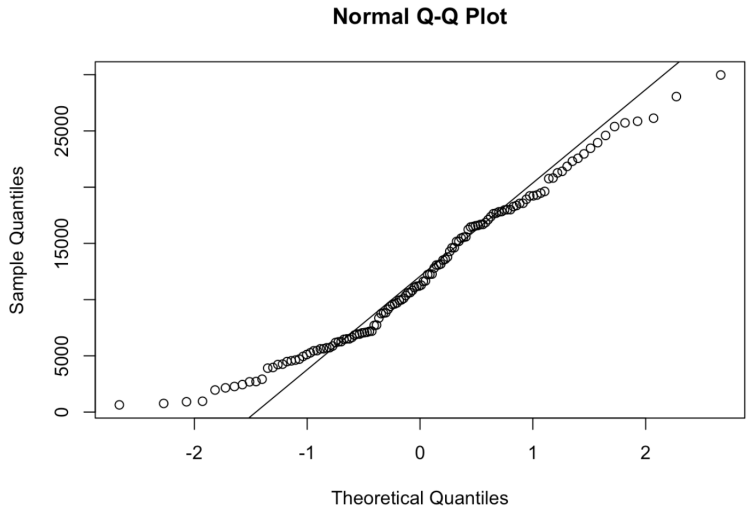

Nhận xét: Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa xuân không tuân theo phân phối chuẩn.

Mặc khác, ta có thể dùng hàm Shapiro.test kiểm tra:
Giả thuyết H_0: Chi phí đặt hàng ở mùa xuân tuân theo phân phối chuẩn.
Đối thuyết H_1: Chi phí đặt hàng ở mùa xuân không tuân theo phân phối chuẩn.

```
shapiro.test(Spring_data_2$order_total)
```

Hình 18: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa xuân

```
##
##  Shapiro-Wilk normality test
##
## data:  Spring_data_2$order_total
## W = 0.96776, p-value = 0.003468
```

Nhận xét: dựa vào p-giá trị = 0.0035 < mức ý nghĩa 5% ở kiểm định Shapiro.test, nên ta bác bỏ H_0, chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa xuân không tuân theo phân phối chuẩn.

+ Đối với mùa hè, ta thực hiện vẽ đồ thị:

```
qqnorm(Summer_data_2$order_total)
qqline(Summer_data_2$order_total)
```

Hình 19: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa hè

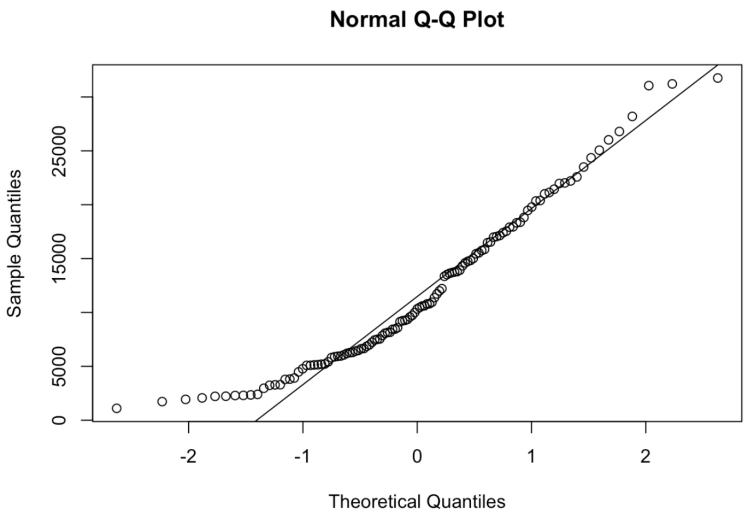

Nhận xét: Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa hè không tuân theo phân phối chuẩn.

Mặc khác, ta có thể dùng hàm Shapiro.test kiểm tra:
Giả thuyết H_0: Tổng chi phí đặt hàng ở mùa hè tuân theo phân phối chuẩn.
Đối thuyết H_1: Tổng chi phí đặt hàng ở mùa hè không tuân theo phân phối chuẩn.

```
shapiro.test(Summer_data_2$order_total)
```

Hình 20: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa hè

```
##
##  Shapiro-Wilk normality test
##
## data:  Summer_data_2$order_total
## W = 0.94214, p-value = 7.425e-05
```

Nhận xét: dựa vào p-giá trị = 7.425e-5 < mức ý nghĩa 5% ở kiểm định Shapiro.test, nên ta bác bỏ H_0, chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa hè không tuân theo phân phối chuẩn.

+ Đối với mùa thu, ta thực hiện vẽ đồ thị:

```
qqnorm(Autumn_data_2$order_total)
qqline(Autumn_data_2$order_total)
```

Hình 21: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa thu

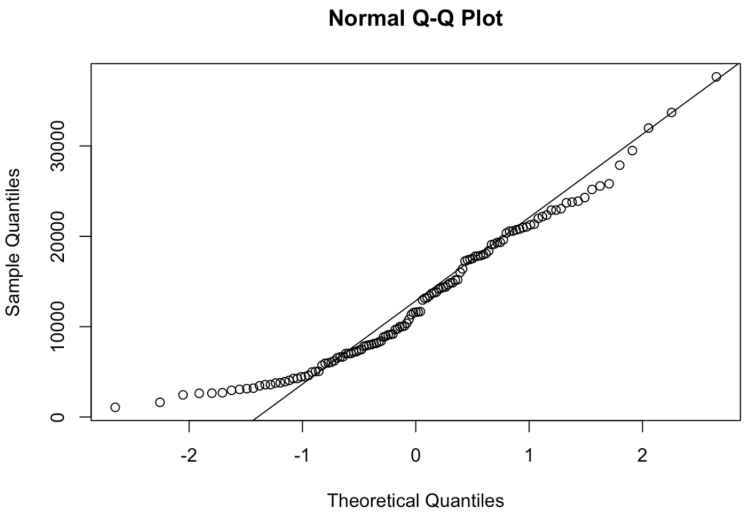

Nhận xét: Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa thu không tuân theo phân phối chuẩn.

Mặc khác, ta có thể dùng hàm Shapiro.test kiểm tra:
Giả thuyết H_0: Tổng chi phí đặt hàng ở mùa thu tuân theo phân phối chuẩn.
Đối thuyết H_1: Tổng chi phí đặt hàng ở mùa thu không tuân theo phân phối chuẩn.

```
shapiro.test(Autumn_data_2$order_total)
```

Hình 22: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa thu

```
##
##  Shapiro-Wilk normality test
##
## data:  Autumn_data_2$order_total
## W = 0.94867, p-value = 0.0001242
```

Nhận xét: dựa vào p-giá trị = 0.0001 < mức ý nghĩa 5% ở kiểm định Shapiro.test, nên ta bác bỏ H_0, chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa thu không tuân theo phân phối chuẩn.

+ Đối với mùa đông, ta thực hiện vẽ đồ thị:

```
qqnorm(Winter_data_2$order_total)
qqline(Winter_data_2$order_total)
```

Hình 23: Kết quả khi vẽ Normal QQ-plot cho order_total theo mùa đông

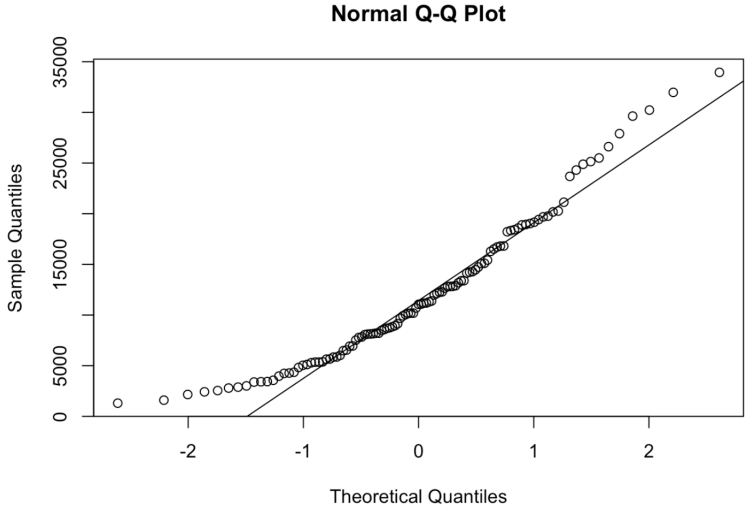

Nhận xét: Dựa vào đồ thị QQ-plot ta thấy các quan trắc nằm lệch ra khỏi đường thẳng kỳ vọng phân phối chuẩn nên có thể kết luận tổng chi phí đặt hàng ở mùa đông không tuân theo phân phối chuẩn.

Mặc khác, ta có thể dùng hàm Shapiro.test kiểm tra:
Giả thuyết H_0: Tổng chi phí đặt hàng ở mùa đông tuân theo phân phối chuẩn.
Đối thuyết H_1: Tổng chi phí đặt hàng ở mùa đông không tuân theo phân phối chuẩn.

```
shapiro.test(Winter_data_2$order_total)
```

Hình 24: Kết quả khi dùng kiểm định Shapiro.test cho order_total theo mùa đông

```
##
##  Shapiro-Wilk normality test
##
## data:  Winter_data_2$order_total
## W = 0.93982, p-value = 8.11e-05
```

Nhận xét: dựa vào p-giá trị = 8.11.e-5 < mức ý nghĩa 5% ở kiểm định Shapiro.test, nên ta bác bỏ H_0, chấp nhận H_1. Vậy tổng chi phí đặt hàng ở mùa đông không tuân theo phân phối chuẩn.

Kiểm định giả định về tính đồng nhất của phương sai:

Giả thuyết H_0: Phương sai tổng chi phí đặt hàng ở các mùa bằng nhau.
Đối thuyết H_1: Có ít nhất hai mùa có phương sai tổng chi phí đặt hàng khác nhau.

```
library(car)
leveneTest(order_total~as.factor(season),data=new_data_2)
```

Hình 25: code R và kết quả khi kiểm tra giả định phương sai

```
## Levene's Test for Homogeneity of Variance (center = median)
##        Df F value Pr(>F)
## group   3  0.8623 0.4605
##       479
```

Nhận xét: Dựa vào p-giá trị = 0.4605 > mức ý nghĩa 5% ở kiểm định **leveneTest**, ta có thể kết luận phương sai tổng chi phí đặt hàng ở các mùa bằng nhau.

Thực hiện Anova một nhân tố so sánh tổng chi phí đặt hàng trung bình ở các mùa:

Giả thuyết H_0: Tổng chi phí đặt hàng trung bình ở các mùa bằng nhau.
Đối thuyết H_1: Có ít nhất hai mùa có tổng chi phí đặt hàng khác nhau.

```
anova_model <- aov(order_total~season,data=new_data_2)
summary(anova_model)
```

Hình 26: Kết quả khi thực hiện Anova một nhân tố

```
##              Df    Sum Sq  Mean Sq F value Pr(>F)
## season        3 8.749e+07 29163926   0.538  0.656
## Residuals   479 2.595e+10 54170692
```

Nhận xét: Dựa trên kết quả ANOVA cho thấy:

$SSB = 8.749e + 7$, bậc tự do $df = k - 1 = 3(k = 4)$ với k là số nhóm;
$SSE = 2.595e + 10$, bậc tự do $df = N - k = 479$ $(N = 483, k = 4)$ với N là tổng số quan sát trong các nhóm.
$MSB = \dfrac{SSB}{k-1} = 29163926$
$MSE = \dfrac{SSE}{kn-k} = 54170692$
Giá trị thống kê kiểm định $F = \dfrac{MSB}{MSE} \approx 0.538$
Mức ý nghĩa quan sát: $Pr = 0.656$
Giá trị $Pr = 0.656$ lớn hơn mức ý nghĩa 5%, nên ta chưa bác bỏ được H_0.
Vậy nên tổng chi phí đặt hàng trung bình ở các mùa bằng nhau.

5.2 Hồi quy đa biến: Phân tích các yếu tố dự báo chi phí vận chuyển

Chia bộ dữ liệu thành 2 phần: train_data (80%) dùng để xây dựng mô hình hồi quy và test_data (20%) dùng để thực hiện dự báo.

```
train.rows <- sample(rownames(new_data), dim(new_data)[1]*0.8)
train_data <- new_data[train.rows, ]
test.rows <- setdiff(rownames(new_data), train.rows)
test_data <- new_data[test.rows, ]
```

Mô hình hồi quy bao gồm:
+ Biến phụ thuộc: delivery_charges.
+ Biến độc lập: customer_lat, customer_long, distance_to_nearest_warehouse, season, is_expedited_delivery.

Mô hình được biểu diễn như sau:

$$\begin{gathered} delivery_charges = \beta_0 + \beta_1 \times customer_lat, + \beta_2 \times customer_long \\ + \beta_3 \times distance_to_nearest_warehouse + \beta_4 \times seasonSpring \\ + \beta_5 \times seasonSummer + \beta_6 \times seasonWinter + \beta_7 \times is_expedited_deliveryTRUE + \varepsilon. \end{gathered}$$

Ta thực hiện ước lượng các hệ số β_i, $i = 0, ..., 7$.

```
model_1<-lm(delivery_charges~customer_lat+customer_long+distance_to_nearest_warehouse
    +season+is_expedited_delivery,data=train_data)
summary(model_1)
```

Hình 27: Kết quả khi thực hiện xây dựng mô hình hồi quy bội

```
##
## Call:
## lm(formula = delivery_charges ~ customer_lat + customer_long +
##     distance_to_nearest_warehouse + season + is_expedited_delivery,
##     data = train_data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -24.044  -5.551   1.683   5.876  20.694
##
## Coefficients:
##                                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)                    4.541e+03  2.834e+03   1.602    0.110
## customer_lat                   6.278e-02  3.825e-02   1.641    0.102
## customer_long                 -3.089e+01  1.955e+01  -1.580    0.115
## distance_to_nearest_warehouse  8.328e-03  5.353e-02   0.156    0.876
## seasonSpring                   1.845e+01  1.179e+00  15.654  < 2e-16 ***
## seasonSummer                   9.424e+00  1.199e+00   7.858 3.79e-14 ***
## seasonWinter                  -1.032e+00  1.281e+00  -0.805    0.421
## is_expedited_deliveryTrue      1.795e+01  8.621e-01  20.828  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.529 on 392 degrees of freedom
## Multiple R-squared:  0.669,  Adjusted R-squared:  0.663
## F-statistic: 113.2 on 7 and 392 DF,  p-value: < 2.2e-16
```

Nhận xét: Từ kết quả phân tích, ta thu được:

$$\widehat{\beta}_0 = 4.541e+03; \widehat{\beta}_1 = 6.278e-02; \widehat{\beta}_2 = -3.089e+01; \widehat{\beta}_3 = 8.328e-03; \widehat{\beta}_4 = 1.845e+01$$
$$\widehat{\beta}_5 = 9.424e+00; \widehat{\beta}_6 = -1.032e+00; \widehat{\beta}_7 = 1.795e+01$$

Như vậy, đường thẳng hồi quy ước lượng cho bởi phương trình sau:

$$\widehat{delivery_charges} = 4.541e+03 + 6.278e-02 \times customer_lat - 3.089e+01 \times customer_long$$
$$+8.328e-03 \times distance_to_nearest_warehouse + 1.845e+01 \times seasonSpring$$
$$+9.424e+00 \times seasonSumer - 1.032e+00 \times seasonWinter + 1.795e+01 \times is_expedited_deliveryTRUE$$

Kiểm định các hệ số β_i:
Giả thuyết H_0: $\beta_i = 0$: hệ số β_i không có ý nghĩa thống kê.
Đối thuyếtH_1: $\beta_i \neq 0$: hệ số β_i có ý nghĩa thống kê.

Ta nhận thấy rằng p-giá trị ứng với các biến customer_lat, customer_long, distance_to_nearest_warehouse, seasonWinter lớn hơn mức ý nghĩa 5% nên ta chưa bác bỏ được H_0. Vậy hệ số β_i ứng với các biến này bằng 0 (không có ý nghĩa thống kê). Tức là các biến này không ảnh hưởng delivery_charges. Ta sẽ xem xét loại bỏ các biến này ra khỏi mô hình.

Ta xây dựng mô hình model_2 bỏ đi biến customer_lat, customer_long ,distance_to_nearest_warehouse từ model_1.

```r
model_2<-lm(delivery_charges~season+is_expedited_delivery,data=train_data)
summary(model_2)
```

Hình 28: Kết quả khi thực hiện xây dựng mô hình 2

```
##
## Call:
## lm(formula = delivery_charges ~ season + is_expedited_delivery,
##     data = train_data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -25.168  -5.563   1.643   6.018  20.163
##
## Coefficients:
##                           Estimate Std. Error t value Pr(>|t|)
## (Intercept)                60.5272     0.9319  64.948  < 2e-16 ***
## seasonSpring               18.3090     1.1561  15.837  < 2e-16 ***
## seasonSummer                9.3705     1.1992   7.814 5.07e-14 ***
## seasonWinter               -1.1143     1.2756  -0.874    0.383
## is_expedited_deliveryTrue  17.9003     0.8631  20.740  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.551 on 395 degrees of freedom
## Multiple R-squared:  0.6646, Adjusted R-squared:  0.6612
## F-statistic: 195.7 on 4 and 395 DF,  p-value: < 2.2e-16
```

Ta xây dựng mô hình model_3 bỏ đi biến season từ mô hình model_2 .

```r
model_3<-lm(delivery_charges~is_expedited_delivery,data=train_data)
summary(model_3)
```

Hình 29: Kết quả khi thực hiện xây dựng mô hình 3

```
##
## Call:
## lm(formula = delivery_charges ~ is_expedited_delivery, data = train_data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -27.859  -7.574  -1.413   8.338  28.251
##
## Coefficients:
##                           Estimate Std. Error t value Pr(>|t|)
## (Intercept)                68.0230     0.8239   82.56   <2e-16 ***
## is_expedited_deliveryTrue  17.7662     1.1710   15.17   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.71 on 398 degrees of freedom
## Multiple R-squared:  0.3664, Adjusted R-squared:  0.3648
## F-statistic: 230.2 on 1 and 398 DF,  p-value: < 2.2e-16
```

So sánh hai model_1 và model_2:
Giả thuyết H_0: Mô hình model_2 hiệu quả hơn
Đối thuyết H_1: Mô hình model_1 hiệu quả hơn

```r
anova(model_1,model_2)
```

Hình 30: code R và kết quả khi so sánh hai model_1 và model_2

```
## Analysis of Variance Table
##
## Model 1: delivery_charges ~ customer_lat + customer_long + distance_to_nearest_warehouse +
##     season + is_expedited_delivery
## Model 2: delivery_charges ~ season + is_expedited_delivery
##   Res.Df   RSS Df Sum of Sq      F Pr(>F)
## 1    392 28513
## 2    395 28884 -3   -371.27 1.7014 0.1662
```

Nhận xét: Ta nhận thấy p-giá trị =0.1662 lớn hơn mức ý nghĩa 5%, nên ta chưa bác bỏ được H_0, vậy nên mô hình model_2 hiệu quả hơn.

So sánh hai model_2 và model_3:
Giả thuyết H_0: Mô hình model_3 hiệu quả hơn
Đối thuyết H_1: Mô hình model_2 hiệu quả hơn

```
anova(model_2,model_3)
```

Hình 31: code R và kết quả khi so sánh hai model_2 và model_3

```
## Analysis of Variance Table
##
## Model 1: delivery_charges ~ season + is_expedited_delivery
## Model 2: delivery_charges ~ is_expedited_delivery
##   Res.Df   RSS Df Sum of Sq      F    Pr(>F)
## 1    395 28884
## 2    398 54570 -3    -25686 117.09 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nhận xét: Ta nhận thấy p-giá trị <2.2e-16, rất bé so với mức ý nghĩa 5%, nên ta bác bỏ được H_0, vậy nên mô hình model_2 hiệu quả hơn.

Từ việc so sánh các mô hình, ta có thể nhận thấy mô hình model_2 là mô hình hiệu quả nhất.

Các giả định của mô hình hồi quy: $Y_i = \beta_0 + \beta_1.X_1 + ...\beta_i.X_i + \epsilon_i$, $i = 1, ...n$.
+ Tính tuyến tính của dữ liệu: mối quan hệ giữa biến dự báo X và biến phụ thuộc Y được giả sử là tuyến tính.
+ Sai số có kỳ vọng bằng 0.
+ Phương sai của các sai số là hằng số.
+ Sai số có phân phối chuẩn. $\varepsilon \sim N(0, \sigma^2)$
+ Các sai số $\varepsilon_1, ..., \varepsilon_n$ thì độc lập với nhau.

Ta thực hiện phân tích thặng dư để kiểm tra các giả định của mô hình.

```
par(mfrow=c(2,2))
plot(model_2)
```

Hình 32: code R và kết quả khi vẽ đồ thị phân tích thặng dư để kiểm tra các giả định của mô hình

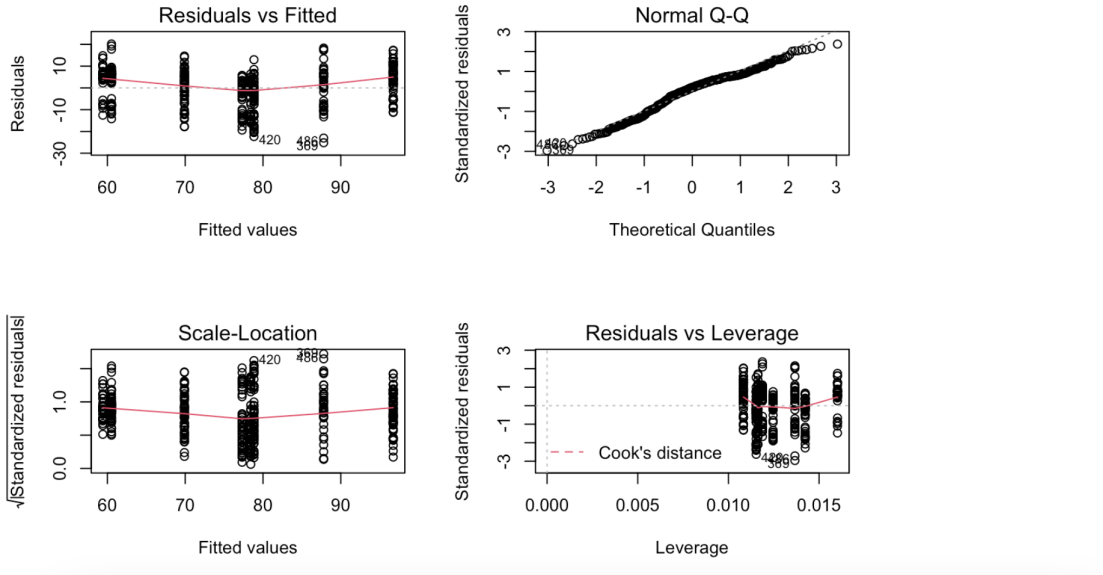

Nhận xét:
Đồ thị 1: Vẽ các sai số hồi quy tương ứng với giá trị dự báo, dùng để kiểm tra giả định:
+ Y và các biến độc lập X có quan hệ tuyến tính.
+ Sai số có kỳ vọng bằng 0.
+ Phương sai các sai số là hằng số.
Dựa vào kết quả cho thấy:
+ Đường màu đỏ tương đối là đường thẳng nằm ngang nên giả định Y và các biến độc lập X có quan hệ tuyến tính thoả mãn.
+ Đường màu đỏ tương đối nằm sát đường y = 0 nên ta giả định Sai số có kỳ vọng bằng 0 thoả mãn.
+ Các giá trị sai số chưa phân tán ngẫu nhiên dọc theo đường màu đỏ, nên giả định Phương sai các sai số là hằng số chưa thoả mãn.

Đồ thị 2: Vẽ các sai số hồi quy được chuẩn hoá, dùng để kiểm tra giả định sai số có phân phối chuẩn.
Dựa vào kết quả cho thấy: các quan trắc tương đối nằm trên đường thẳng kỳ vọng phân phối chuẩn nên giả định Sai số có phân phối chuẩn thoả mãn

Đồ thị 3: Vẽ căc bậc 2 các sai số được chuẩn hoá, dùng để kiểm tra giả định Phương sai các sai số là hằng số.
Dựa vào kết quả cho thấy: Các giá trị sai số chưa phân tán ngẫu nhiên dọc theo đường màu đỏ, nên giả định Phương sai các sai số là hằng số chưa thực sự thoả mãn.

Đồ thị 4: Vẽ ra những điểm có gây ảnh hưởng cao trong bộ dữ liệu, cụ thể là các điểm 420, 486, 369. Tuy nhiên không có điểm nào vượt ra khỏi đường Cook's distance. Vì vậy, ta không cần phải loại bỏ các điểm ra khỏi bộ dữ liệu.

Mô hình hồi quy tuyến tính về sự ảnh hưởng các nhân tố lên delivery_charges:

$$\widehat{delivery_charges} = 60.5257 + 18.3090 \times seasonSpring$$
$$+9.3705 \times seasonSumer - 1.1143 \times seasonWinter + 17.9003 \times is_expedited_deliveryTRUE$$

Hệ số xác định hiệu chỉnh (Adjusted R-squared): R^2 hiệu chỉnh = 0.6612 nghĩa là 66.12% sự biến thiên trong phí vận chuyển delivery_charges được giải thích bởi các biến độc lập.

Sử dụng mẫu kiểm tra test_data và dựa vào mô hình tốt nhất được chọn trên đưa số liệu dự báo cho chi phí vận chuyển delivery_charges ở tệp test_data.

```
test_data$predicted_value<-predict(model_2,test_data)
head(test_data,10)
```

Hình 33: Kết quả khi thực hiện dự báo

```
##    order_total season delivery_charges customer_lat customer_long
## 1     11059.89 Winter            79.89    -37.81511      144.9328
## 15    31979.78 Autumn            79.78    -37.80946      144.9724
## 17    11188.19 Winter            80.69    -37.80423      144.9717
## 19     6268.89 Summer            60.64    -37.80918      144.9729
## 28     5663.28 Winter            78.28    -37.82007      145.0117
## 37    10186.45 Winter            53.95    -37.80328      145.0074
## 38    12822.12 Winter            52.12    -37.80959      144.9637
## 44     8131.57 Autumn            66.07    -37.81214      144.9740
## 46     7446.01 Summer            66.01    -37.79906      144.9454
## 47    10598.30 Summer            98.30    -37.82179      144.9908
##    is_expedited_delivery distance_to_nearest_warehouse predicted_value
## 1                   True                        1.2800        77.31327
## 15                  True                       66.6483        78.42758
## 17                  True                        1.6104        77.31327
## 19                 False                        1.0880        69.89776
## 28                  True                        0.9992        77.31327
## 37                 False                        1.3080        59.41292
## 38                 False                        1.1272        59.41292
## 44                 False                        0.8182        60.52724
## 46                 False                        1.5218        69.89776
## 47                  True                        1.3710        87.79810
```

6 THẢO LUẬN VÀ MỞ RỘNG

Từ việc xây dựng mô hình anova và hồi quy đa biến ta rút ra được những nhận xét như sau:

+ Không có sự khác biệt về tổng chi phí đặt hàng ở các mùa trong năm.
+ Yếu tố có ảnh hưởng đến chi phí vận chuyển là việc khách hàng có chọn hình thức giao hàng nhanh hay không và yếu tố mùa trong năm.

Ở mô hình hồi quy, ta nhận thấy model_2 là mô hình tốt nhất để dự báo cho chi phí vận chuyển trong các mô hình mà ta xây dựng. model_2 với R^2 hiệu chỉnh = 0.6612 và hệ số này còn quá thấp (dưới 80%) chứng tỏ rằng chi phí vận chuyển còn có thể phụ thuộc vào những yếu tố khác (có thể kể đến như vị trí địa lý của khách hàng, mã giảm giá vận chuyển,...) chưa xem xét trong mô hình.

Nhìn lại đồ thị phân tán của chi phí vận chuyển và khoảng cách đến kho hàng gần nhất từ tệp train_data:

```
plot(delivery_charges~distance_to_nearest_warehouse,main="Distance to NW & Delivery_
    charges", col="darkred",data=train_data)
```

Hình 34: Kết quả khi vẽ đồ thị phân tán giữa delivery_charges và distance_to_nearest_warehouse

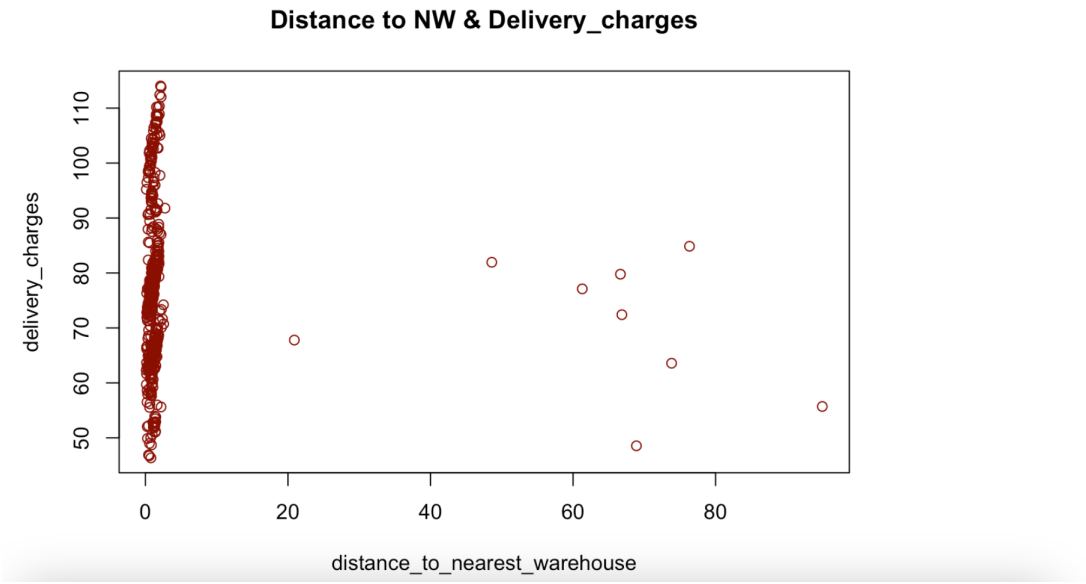

Nhận xét: Nếu ta có thể loại bỏ những điểm ngoại lai (quan trắc mà distance_to_nearest_warehouse có giá trị lớn hơn 20) thì ta có thấy dường như delivery_charges có quan hệ tuyến tính với distance_to_nearest_warehouse.

```
new_train_data<-subset(train_data,distance_to_nearest_warehouse < 20)
plot(delivery_charges~distance_to_nearest_warehouse,main="Distance to NW & Delivery_
    charges",
col="darkred",data=new_train_data)
```

Hình 35: Kết quả khi vẽ đồ thị phân tán giữa delivery_charges và distance_to_nearest_warehouse

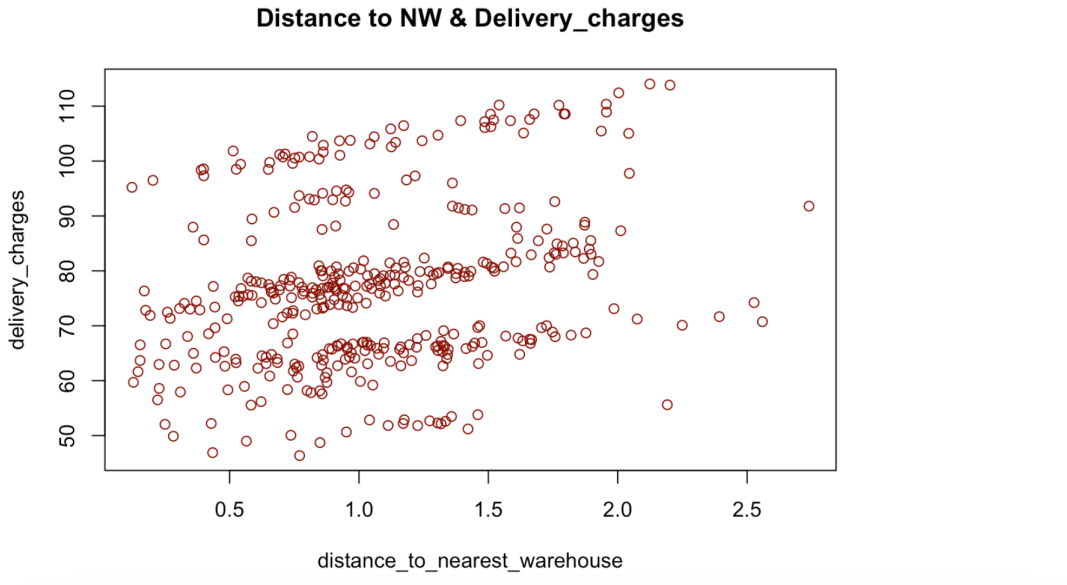

Thực hiện xây dựng lại mô hình hồi quy:

```
new_model<-lm(delivery_charges~customer_lat+customer_long+distance_to_nearest_
    warehouse + season+ is_expedited_delivery,data=new_train_data)
summary(new_model)
```

Hình 36: Kết quả khi xây dựng lại mô hình hồi quy 1

```
new_model<-lm(delivery_charges~customer_lat+customer_long+distance_to_nearest_warehouse + season+ is_expedited_de
livery,data=new_train_data)
summary(new_model)
```

```
##
## Call:
## lm(formula = delivery_charges ~ customer_lat + customer_long +
##     distance_to_nearest_warehouse + season + is_expedited_delivery,
##     data = new_train_data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -21.256  -5.941   2.057   5.916  19.956
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  6149.95021 2635.08009   2.334   0.0201 *
## customer_lat                    0.03006    0.03531   0.851   0.3952
## customer_long                 -42.05255   18.17773  -2.313   0.0212 *
## distance_to_nearest_warehouse   7.21265    0.83467   8.641   <2e-16 ***
## seasonSpring                   18.40650    1.08647  16.942   <2e-16 ***
## seasonSummer                   10.18707    1.12120   9.086   <2e-16 ***
## seasonWinter                   -0.58739    1.18039  -0.498   0.6190
## is_expedited_deliveryTrue      17.81943    0.79840  22.319   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.829 on 385 degrees of freedom
## Multiple R-squared:  0.7222, Adjusted R-squared:  0.7172
## F-statistic:   143 on 7 and 385 DF,  p-value: < 2.2e-16
```

```r
new_model_2<-lm(delivery_charges~customer_long+distance_to_nearest_warehouse + season
    + is_expedited_delivery,data=new_train_data)
summary(new_model_2)
```

Hình 37: Kết quả khi xây dựng lại mô hình hồi quy 2

```
##
## Call:
## lm(formula = delivery_charges ~ customer_long + distance_to_nearest_warehouse +
##     season + is_expedited_delivery, data = new_train_data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -21.274  -6.031   2.067   5.888  19.923
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  6118.8541  2633.8868   2.323   0.0207 *
## customer_long                 -41.8462    18.1696  -2.303   0.0218 *
## distance_to_nearest_warehouse   7.2879     0.8297   8.784   <2e-16 ***
## seasonSpring                   18.4795     1.0827  17.068   <2e-16 ***
## seasonSummer                   10.2142     1.1203   9.117   <2e-16 ***
## seasonWinter                   -0.5740     1.1799  -0.486   0.6269
## is_expedited_deliveryTrue      17.7830     0.7970  22.313   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.826 on 386 degrees of freedom
## Multiple R-squared:  0.7217, Adjusted R-squared:  0.7174
## F-statistic: 166.8 on 6 and 386 DF,  p-value: < 2.2e-16
```

Như vậy có thể thấy rằng việc ta loại đi những điểm ngoại lai ở trên và xây dựng lại, ta có thể thu được một mô hình tốt hơn để dự báo chi phí vận chuyển. Mô hình sau khi cải thiện cho thấy R^2 hiệu chỉnh ở mức 0.7174, cao hơn so với mô hình ban đầu.

Như vậy chi phí vận chuyển còn có thể ảnh hưởng bởi khoảng cách đến kho hàng gần nhất và kinh độ của vị trí khách hàng.

7 NGUỒN DỮ LIỆU VÀ NGUỒN CODE

Link dữ liệu:
https://www.kaggle.com/datasets/muhammadshahrayar/transactional-retail-dataset-of-electronics-store?select=dirty_data.csv

Link code:
https://drive.google.com/drive/folders/13XjKS7vBN-7W7vBqbjmvKlkIG0G_uXlQ?usp=drive_link

8 TÀI LIỆU THAM KHẢO

1. Hoàng Văn Hà, Bài giảng Xác suất Thống Kê.
1. Nguyễn Thị Mộng Ngọc, Bài giảng Xác suất Thống Kê.
2. Nguyễn Tiến Dũng (chủ biên), Nguyễn Đình Huy, Xác suất - Thống kê & Phân tích số liệu, 2019
3. Introductory Statistic with R, J Jambers - D.Hand - W.Hardle
4. Applied Statistics with R, 2020