ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÀI TẬP LỚN

XÁC SUẤT VÀ THỐNG KÊ (MT2013)

Computer Parts (CPUs and GPUs)

Nhóm MT07 - HK233

Giảng viên hướng dẫn: ThS. Nguyễn Kiều Dung

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 8 NĂM 2024

Danh sách thành viên

STT	Họ và tên	MSSV	Tên lớp	Tên khoa/ngành
1	**Nguyễn Thanh Toàn**	**2313492**	DL01	Kỹ thuật máy tính
2	Nguyễn Việt Hoàng	2311066	DL01	Kỹ thuật máy tính
3	Phạm Trương Anh Huy	2311241	DL01	Khoa học máy tính
4	Bùi Trung Quân	2312817	DL03	Khoa học máy tính
5	Trần Đức Hoàng	2311076	DL01	Khoa Điện
6	Trần Công Lộc	2311966	DL02	Khoa Điện
7	Ngô Trung Kiên	2311733	DL03	Khoa Điện

Bảng 1

Mục lục

1 Tổng quan dữ liệu (Data introduction) 3

2 Kiến thức nền 5

2.1 Thống kê mô tả và thống kê suy diễn 5

2.2 Biểu đồ thống kê 6

2.3 Các đặc trưng của tổng thể và mẫu 6

2.3.1 Tỷ lệ 6

2.3.2 Trung bình 6

2.3.3 Phương sai, độ lệch chuẩn 7

2.3.4 Các đặc trưng khác 7

2.4 Ước lượng 8

2.4.1 Ước lượng điểm 8

2.4.2 Khoảng tin cậy 9

2.4.3 Khoảng tin cậy - bài toán 2 mẫu 10

2.5 Kiểm định giả thuyết thống kê 11

2.5.1 Tiêu chuẩn kiểm định - Miền bác bỏ 11

2.5.2 Các sai lầm trong bài toán kiểm định 12

2.5.3 Các bước thực hiện kiểm định 12

2.5.4 Kiểm định 1 mẫu 12

2.5.5 Kiểm định 2 mẫu 13

2.6 Phân tích phương sai (ANOVA) 15

2.7 Phân tích hồi quy tuyến tính 18

3 Tiền xử lý số liệu: 19

3.1 Đọc dữ liệu vào R (Import data) 19

3.2 Làm sạch dữ liệu 20

3.2.1 Chọn ra tệp tin con bao gồm các biến sẽ được sử dụng và phân tích: 20

3.2.2 Xử lý đơn vị của các biến trong tệp: 20

3.2.3 Tạo thêm biến 21

3.3 Kiểm tra và xử lý các dữ liệu bị khuyết (NA) 21

4 Thống kê mô tả 23

4.1 Đồ thị histogram thể hiện phân phối của Memory_Bandwidth: 23

4.2 Mối liên hệ của Memory_Bandwidth đến Manufacturer 24

4.2.1 Tính thống kê mô tả thể hiện Memory_Bandwidth theo Manufacturer 24

4.2.2 Đồ thị Boxplot thể hiện phân phối của Memory_Bandwidth theo Manufacturer 25

4.3 Vẽ đồ thị Boxplot và đồ thị phân tán của Memory_Bandwidth theo năm . 26

4.4 Đồ thị tương quan giữa các biến 27

5 Thống kê suy diễn 28

5.1 Bài toán 1 mẫu 28

5.2 Bài toán 2 mẫu 32

5.3 Bài toán phân tích phương sai (Anova) 36

5.3.1 Kiểm tra điều kiện thứ hai cho dữ liệu của các hãng sản xuất 36

5.3.2 Kiểm tra điều kiện thứ ba cho dữ liệu của các hãng sản xuất 40

5.3.3 Thực hiện bài toán phân tích phương sai 41

5.4 Bài toán hồi quy tuyến tính đa biến 43

6 Nguồn dữ liệu và nguồn code 53

1 Tổng quan dữ liệu (Data introduction)

Tập dữ liệu này chứa thông số kỹ thuật chi tiết, ngày phát hành và giá phát hành của các bộ phận máy tính.

Tập dữ liệu chứa hai tệp CSV: gpus.csv dành cho Bộ xử lý đồ họa (GPU) và cpus.csv dành cho Bộ xử lý trung tâm (CPU). Mỗi bảng có danh sách các mục duy nhất, nhưng danh sách các tính năng bao gồm: tốc độ xung nhịp, nhiệt độ tối đa, độ phân giải màn hình, mức tiêu thụ điện năng, số lượng luồng, ngày phát hành, giá phát hành, kích thước khuôn, hỗ trợ ảo hóa và nhiều trường tương tự khác.

Trong Bài tập lớn thì sẽ tập trung vào Bộ xử lý đồ họa (GPU) trình bày phân tích hiệu suất hệ thống máy tính, tập trung vào mối quan hệ giữa các đặc tính của máy và các số liệu hiệu suất tương đối. Tập dữ liệu bao gồm các thuộc tính:

1. Architecture: Kiến trúc cơ bản của GPU, quyết định khả năng xử lý, hiệu suất và tính năng của nó.

2. Best_Resolution: Độ phân giải tối ưu mà GPU được thiết kế để xử lý trong khi vẫn duy trì hiệu suất cao và chất lượng hình ảnh tốt.

3. Boost_Clock: Tốc độ xung nhịp mà GPU có thể đạt được trong điều kiện tải công việc nặng và khi điều kiện làm mát đủ tốt.

4. Core_Speed: Tốc độ mà lõi của GPU hoạt động trong điều kiện bình thường, được đo bằng Megahertz (MHz) hoặc Gigahertz (GHz).

5. DVI_Connection: Số lượng cổng xuất hình Digital Visual Interface trên GPU, dùng để kết nối với màn hình. (integer)

6. Dedicated: GPU chuyên dụng nghĩa là nó là một phần cứng riêng biệt chỉ dùng để xử lý đồ họa, không phải là GPU tích hợp trong CPU.

7. Direct_X: Một tập hợp các API do Microsoft phát triển để xử lý các nhiệm vụ liên quan đến đa phương tiện, chủ yếu là trò chơi và video, trên nền tảng Windows.

8. DisplayPort_Connection: Số lượng cổng DisplayPort có trên GPU, dùng để kết nối với màn hình hỗ trợ. (integer)

9. HDMI_Connection: Số lượng cổng HDMI có trên GPU, cho phép truyền tải hình ảnh và âm thanh đến màn hình hoặc TV. (integer)

10. Integrated**:** GPU tích hợp nghĩa là nó được xây dựng như một phần của CPU và sẽ sử dụng một phần tài nguyên của máy tính như RAM.

11. L2_Cache: Là bộ nhớ đệm cấp 2 trong GPU, giúp tăng tốc độ xử lý bằng cách lưu trữ dữ liệu sử dụng thường xuyên.
12. **Manufacturer**: Công ty sản xuất GPU, ví dụ như NVIDIA, AMD, hoặc Intel.
13. Max_Power: Lượng điện năng tối đa mà GPU tiêu thụ khi hoạt động ở mức hiệu suất cao nhất.
14. Memory: Dung lượng bộ nhớ VRAM của GPU, quyết định khả năng lưu trữ dữ liệu đồ họa.
15. **Memory_Bandwidth**: Lượng dữ liệu tối đa có thể truyền qua bộ nhớ của GPU mỗi giây, đo bằng GB/s.
16. **Memory_Bus**: Độ rộng của bus bộ nhớ, ảnh hưởng đến băng thông và hiệu suất của bộ nhớ.
17. **Memory_Speed**: Tốc độ mà bộ nhớ của GPU có thể đọc và ghi dữ liệu, đo bằng MHz.
18. Memory_Type: Loại bộ nhớ VRAM sử dụng trong GPU, ví dụ như GDDR5, GDDR6.
19. Name: Tên mô hình của GPU.
20. Notebook_GPU: Chỉ ra liệu GPU có được thiết kế dành riêng cho máy tính xách tay không, thường có hiệu suất năng lượng tốt hơn.
21. Open_GL: Một chuẩn đồ họa máy tính để lập trình giao diện đồ họa.
22. PSU: Đề cập đến công suất tối thiểu của nguồn điện (Power Supply Unit) cần thiết để cấp điện cho GPU.
23. Pixel_Rate: Tốc độ mà GPU có thể xử lý pixel, thường được đo bằng pixel mỗi giây.
24. Power_Connector: Loại và số lượng các kết nối nguồn mà GPU cần để hoạt động.
25. Process: Kích thước của transistors trong GPU, đo bằng nanomet, ảnh hưởng đến hiệu suất và hiệu quả năng lượng.
26. ROPs: Các đơn vị đầu ra của bộ kết xuất trong GPU, quyết định số lượng pixel có thể xử lý mỗi chu kỳ.
27. **Release_Date**: Ngày mà GPU được giới thiệu ra thị trường.
28. Release_Price: Giá của GPU tại thời điểm ra mắt.
29. Resolution_WxH: Độ phân giải tối đa mà GPU có thể hỗ trợ, thường được biểu diễn dưới dạng chiều rộng x chiều cao.

30. SLI_Crossfire: Công nghệ cho phép kết nối nhiều GPU cùng một lúc để tăng hiệu suất đồ họa.
31. Shader: Các chương trình nhỏ được thực thi trên GPU để xử lý hiệu ứng đồ họa.
32. TMUs: Đơn vị trong GPU giúp ánh xạ texture lên bề mặt 3D.
33. **Texture_Rate**: Tốc độ mà GPU có thể xử lý các texture, thường được đo bằng texels mỗi giây.
34. VGA_Connection: Số lượng cổng Video Graphics Array trên GPU, dùng cho kết nối màn hình tương tự. (integer)

Trong nhiệm vụ này, nhóm hoàn toàn sử dụng **R** và **RStudio** làm công cụ và môi trường làm việc để phân tích dữ liệu. Trong bộ dữ liệu này, nhóm đã chọn ra và phân tích 6 biến gồm: **Manufacturer**, **Memory_Bandwidth**, **Memory_Bus**, **Memory_Speed**, **Texture_Rate** và **Release_Date**. Thoạt nhìn, có rất nhiều tham số liên quan đến từng mô hình dường như có tác động đến **Manufacter**, **Memory_Bandwidth**, **Memory_Bus**, **Memory_Speed**, **Texture_Rate** và **Release_Date**. Vì vậy các mô hình hồi quy sẽ là phương pháp của nhóm để tiếp cận tập dữ liệu trong bài tập lớn này.

2 Kiến thức nền

2.1 Thống kê mô tả và thống kê suy diễn

Thống kê mô tả (descriptive statistics): là quá trình thu thập, biểu diễn, tổng hợp và xử lý dữ liệu để biến đổi dữ liệu thành thông tin.

- Thu thập dữ liệu: khảo sát, đo đạc, ...
- Biểu diễn dữ liệu: dùng bảng và đồ thị.
- Tổng hợp và xử lý dữ liệu: tính các tham số mẫu như trung bình mẫu (sample mean), phương sai mẫu (sample variance), trung vị (median),...

Thống kê suy diễn (Inferential statistics): xử lý các thông tin có được từ thống kê mô tả, từ đó đưa ra các cơ sở cho những dự đoán (predictions), dự báo (forecasts) và các ước lượng (estimations).

- Ước lượng: tham số thống kê (trung bình, tỷ lệ, phương sai).
- Kiểm định giả thuyết: tham số thống kê (trung bình, tỷ lệ, phương sai), quy luật phân phối xác suất (chuẩn, poisson,...), tính độc lập,...

2.2 Biểu đồ thống kê

Biểu đồ thống kê là một công cụ trực quan được sử dụng để hiển thị dữ liệu thống kê. Các biểu đồ thống kê thường được sử dụng để mô tả các đặc trưng cơ bản của tập dữ liệu, chẳng hạn như trung bình cộng, độ lệch chuẩn, giá trị lớn nhất, giá trị nhỏ nhất.

- **Biểu đồ boxplot (box-and-whisker plot)**: là biểu đồ diễn tả 5 vị trí phân bố của dữ liệu, đó là giá trị nhỏ nhất (min), tứ phân vị thứ nhất (Q1), trung vị (median), tứ phân vị thứ ba (Q3), giá trị lớn nhất (max).
- **Biểu đồ pairs (paris plot)**: Là một biểu đồ thống kê được sử dụng để so sánh hai hoặc nhiều tập dữ liệu. Biểu đồ paris hiển thị các giá trị trung bình, độ lệch chuẩn và các giá trị nằm ngoài hai đường biên của từng tập dữ liệu.

2.3 Các đặc trưng của tổng thể và mẫu

2.3.1 Tỷ lệ

Với một tổng thể có N phần tử và M phần tử mang tính chất A nào đó. Tỷ lệ tổng thể (kí hiệu: p) được tính bởi công thức:

$$p = \frac{M}{N}$$

Với một mẫu có n phần tử và có m phần tử mang tính chất A nào đó. Tỷ lệ mẫu (kí hiệu: f hay $\hat{p}$) được tính bởi công thức:

$$f = \frac{m}{n}$$

2.3.2 Trung bình

Trung bình (mean): là đại lượng thường được sử dụng nhất để đo giá trị trung tâm của dữ liệu. Với một tổng thể có N phần tử, trung bình tổng thể (kí hiệu: μ hay $\bar{x}$) tính bởi công thức:

$$\mu = \frac{\sum_{i=1}^{N} x_i}{N} = \frac{x_1 + x_2 + \ldots + x_N}{N}$$

Với một mẫu có n phần tử, trung bình mẫu (kí hiệu: $\bar{x}$) tính bởi công thức:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + \ldots + x_n}{n}$$

Trong trường hợp X có bảng phân phối tần số như sau:

X	x_1	x_2	x_3	$\ldots$	x_k
Tần số	n_1	n_2	n_3	$\ldots$	n_k

Ta lại có trung bình mẫu tính bởi công thức:

$$\bar{x} = \frac{\sum_{i=1}^{k} x_i \cdot n_i}{n} = \frac{x_1 \cdot n_1 + x_2 \cdot n_2 + \cdots + x_k \cdot n_k}{n}$$

Lưu ý: Trung bình bị ảnh hưởng bởi các giá trị ngoại lai (outliers).

2.3.3 Phương sai, độ lệch chuẩn

Phương sai (Variance): là trung bình của bình phương độ lệch các giá trị so với trung bình. Phương sai phản ánh độ phân tán hay sự biến thiên của dữ liệu.

Độ lệch chuẩn (Standard deviation): Độ lệch chuẩn (Standard deviation) là căn bậc hai dương của phương sai. Độ lệch chuẩn dùng để đo sự biến thiên, biểu diễn sự biến thiên xung quanh trung bình và cũng có cùng đơn vị đo với dữ liệu gốc.

Với một tổng thể có N phần tử, phương sai tổng thể (kí hiệu: σ^2) tính bởi công thức:

$$\sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N} = \frac{\sum_{i=1}^{N} x_i^2 - N \cdot \mu^2}{N} = \frac{\sum_{i=1}^{N} x_i^2}{N} - \mu^2.$$

Khi đó: σ được gọi là độ lệch chuẩn của tổng thể. Với một mẫu có n phần tử, phương sai mẫu (kí hiệu: s^2) tính bởi công thức:

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1} = \frac{\sum_{i=1}^{n} x_i^2 - n \cdot \bar{x}^2}{n-1} = \frac{\sum_{i=1}^{n} x_i^2}{n-1} - \frac{n \cdot \bar{x}^2}{n-1}.$$

Khi đó: s được gọi là độ lệch mẫu.

Trong trường hợp X có bảng phân phối tần số như sau:

X	x_1	x_2	x_3	$\cdots$	x_k
Tần số	n_1	n_2	n_3	$\cdots$	n_k

Ta lại có phương sai mẫu tính bởi công thức:

$$s^2 = \frac{n}{n-1} \cdot \frac{s^2}{n} = \frac{1}{n-1} \sum_{i=1}^{k} (x_i - \bar{x})^2 \cdot n_i$$

$$= \frac{1}{n-1} \left[(x_1 - \bar{x})^2 \cdot n_1 + (x_2 - \bar{x})^2 \cdot n_2 + \cdots + (x_k - \bar{x})^2 \cdot n_k \right].$$

Khi đó: s được gọi là độ lệch mẫu.

2.3.4 Các đặc trưng khác

Yếu vị (Mode): là giá trị của phần tử có số lần xuất hiện lớn nhất trong mẫu. Yếu vị không bị ảnh hưởng bởi các điểm ngoại lai.

Hệ số biến thiên (Coefficient of variation): được sử dụng để so sánh sự biến thiên của hai hay nhiều tập dữ liệu, có thể đo ở các đơn vị khác nhau. Đơn vị tính bằng %.

$$CV(\text{tổng thể}) = \frac{\sigma}{\mu} \times 100\%$$

$$CV(\text{mẫu}) = \frac{s}{\bar{x}} \times 100\%$$

Sai số chuẩn (Standard Error): là giá trị đại diện cho độ lệch chuẩn của giá trị trung bình trong tập dữ liệu. Nó phục vụ như một thước đo biến động cho các biến ngẫu nhiên hay độ lượn độ phân tán. Độ phân tán càng nhỏ, dữ liệu càng chính xác.

$$SE(\text{tổng thể}) = \frac{\sigma}{\sqrt{N}}$$

$$SE(\text{mẫu}) = \frac{s}{\sqrt{n}}$$

Trung vị (Median) Giả sử X có N quan sát, sắp các quan sát này theo thứ tự tăng dần. Trung vị là giá trị nằm chính giữa dây số này và chia nó thành 2 phần bằng nhau. Cụ thể, nếu dữ liệu có dạng $x_1 < \cdots < x_{2k+1}$ thì trung vị là x_{k+1}; nếu mẫu có dạng $x_1 < \cdots < x_{2k}$ thì trung vị là trung bình cộng $\left(\frac{x_k + x_{k+1}}{2}\right)$. Trung vị không bị ảnh hưởng bởi các điểm ngoại lai (outliers).

Phân vị (Quartile)

- Điểm tứ phân vị dưới (Q1) là trung vị của nửa dữ liệu nhỏ, là giá trị chia dữ liệu thành 2 phần sao cho phía trái chiếm 25% của dữ liệu.
- Điểm tứ phân vị trên (Q3) là trung vị của nửa dữ liệu lớn, là giá trị chia dữ liệu thành 2 phần sao cho phía trái chiếm 75% của dữ liệu.
- Các điểm Q1, Q2 và Q3 được gọi là các điểm tứ phân vị.
- Hiệu $IQR = Q3 - Q1$ được gọi là khoảng tứ phân vị hay độ trải giữa.

Điểm outlier: gọi là điểm dị biệt, điểm ngoại lai. Đó là các phần tử của dữ liệu nằm ngoài khoảng $(Q1 - 1.5 \cdot IQR; Q3 + 1.5 \cdot IQR)$. Trong trường hợp phần tử nằm ngoài khoảng $(Q1 - 3.0 \cdot IQR; Q3 + 3.0 \cdot IQR)$ thì được gọi là ngoại lai xa.

2.4 Ước lượng

2.4.1 Ước lượng điểm

Một **ước lượng (estimator)** của một tham số (của tổng thể): là một biến ngẫu nhiên có giá trị phụ thuộc vào thông tin của mẫu, giá trị của nó là một xấp xỉ cho tham số chưa biết của tổng thể. Một giá trị cụ thể của biến ngẫu nhiên này gọi là một giá trị ước lượng điểm (estimate).

Xét đại lượng ngẫu nhiên X có phân phối $F(x;\theta)$ với tham số θ chưa biết.

Chọn một mẫu ngẫu nhiên cỡ n từ X: $X_1, X_2, \ldots, X_n$

Thống kê $\hat{\Theta} = h(X_1, X_2, \ldots, X_n)$ gọi là một ước lượng điểm cho θ.

Với một mẫu cụ thể $(x_1, x_2, \ldots, x_n)$, ta gọi $\hat{\theta} = h(x_1, x_2, \ldots, x_n)$ là một giá trị ước lượng điểm cụ thể cho θ.

2.4.2 Khoảng tin cậy

Cho tham số θ của tổng thể và $X_1, X_2, \ldots, X_n$ là các quan sát ngẫu nhiên. Ta gọi khoảng (c, d) là khoảng ước lượng (hay khoảng tin cậy) của tham số θ với độ tin cậy γ nếu: $P(\theta \in (c, d)) = \gamma$. Có thể nói, độ tin cậy γ cho khoảng ước lượng của tham số θ chính là xác suất để ta đúng khi ước lượng tham số θ bằng khoảng (c, d). Ngược lại, xác suất mà ta cho phép sai khi ước lượng θ được gọi là mức ý nghĩa. Kí hiệu là α. Ta có $\alpha + \gamma = 1$.

Bảng tóm tắt các bài toán tìm khoảng tin cậy (tỷ lệ và trung bình):

Dạng	Giả định	Loại	Ngưỡng sai số	Khoảng tin cậy
Tỷ lệ	$n > 30$	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \sqrt{\frac{f(1-f)}{n}}$	$f - \varepsilon < p < f + \varepsilon$
		Bên phải		$0 < p < f + z_\alpha \cdot \sqrt{\frac{f(1-f)}{n}}$
		Bên trái		$f - z_\alpha \cdot \sqrt{\frac{f(1-f)}{n}} < p < 1$
Trung bình	(1)	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$	$\bar{x} - \varepsilon < \mu < \bar{x} + \varepsilon$
		Bên phải		$-\infty < \mu < \bar{x} + z_\alpha \cdot \frac{\sigma}{\sqrt{n}}$
		Bên trái		$\bar{x} - z_\alpha \cdot \frac{\sigma}{\sqrt{n}} < \mu < \infty$
	(2)	Đối xứng	$\varepsilon = t_{\alpha/2;n-1} \cdot \frac{s}{\sqrt{n}}$	$\bar{x} - \varepsilon < \mu < \bar{x} + \varepsilon$
		Bên phải		$-\infty < \mu < \bar{x} + t_{\alpha;n-1} \cdot \frac{s}{\sqrt{n}}$
		Bên trái		$\bar{x} - t_{\alpha;n-1} \cdot \frac{s}{\sqrt{n}} < \mu < \infty$
	(3)	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$	$\bar{x} - \varepsilon < \mu < \bar{x} + \varepsilon$
		Bên phải		$-\infty < \mu < \bar{x} + z_\alpha \cdot \frac{\sigma}{\sqrt{n}}$
		Bên trái		$\bar{x} - z_\alpha \cdot \frac{\sigma}{\sqrt{n}} < \mu < \infty$

- Giả định (1): $X_i \sim N(\mu, \sigma^2)$, đã biết σ

- Giả định (2): $X_i \sim N(\mu, \sigma^2)$, chưa biết σ
- Giả định (3): Phân phối tùy ý, mẫu lớn ($n \geq 30$)

Lưu ý: Đối với bài toán ước lượng trung bình dạng (3), trường hợp chưa biết σ thì thay bằng s.

2.4.3 Khoảng tin cậy - bài toán 2 mẫu

Dạng	Loại	Ngưỡng sai số	Khoảng tin cậy
$p_1 - p_2$	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \sqrt{\frac{f_1(1-f_1)}{n_1} + \frac{f_2(1-f_2)}{n_2}}$	$(f_1 - f_2 - \varepsilon; f_1 - f_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = z_\alpha \cdot \sqrt{\frac{f_1(1-f_1)}{n_1} + \frac{f_2(1-f_2)}{n_2}}$	$(f_1 - f_2 - \varepsilon_1; +\infty)$
	Bên phải		$(-\infty; f_1 - f_2 + \varepsilon_1)$
$\mu_1 - \mu_2(1)$	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon; \bar{x}_1 - \bar{x}_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = z_\alpha \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon_1; +\infty)$
	Bên phải		$(-\infty; \bar{x}_1 - \bar{x}_2 + \varepsilon_1)$
$\mu_1 - \mu_2(2)$	Đối xứng	$\varepsilon = t_{(n_1+n_2-2),\alpha/2} \cdot \sqrt{\frac{S_p^2}{n_1} + \frac{S_p^2}{n_2}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon; \bar{x}_1 - \bar{x}_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = t_{(n_1+n_2-2),\alpha} \cdot \sqrt{\frac{S_p^2}{n_1} + \frac{S_p^2}{n_2}}$ với $S_p^2 = \frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-2}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon_1; +\infty)$
	Bên phải		$(-\infty; \bar{x}_1 - \bar{x}_2 + \varepsilon_1)$

Dạng	Loại	Ngưỡng sai số	Khoảng tin cậy
$\mu_1 - \mu_2(3)$	Đối xứng	$\varepsilon = t_{\alpha/2}^{(v)} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon; \bar{x}_1 - \bar{x}_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = t_\alpha^{(v)} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon_1; +\infty)$
	Bên phải	$\varepsilon_1 = t_\alpha^{(v)} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$ với $v = \dfrac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\dfrac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \dfrac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$	$(-\infty; \bar{x}_1 - \bar{x}_2 + \varepsilon_1)$

$\mu_1 - \mu_2$ (4)	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon; \bar{x}_1 - \bar{x}_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = z_\alpha \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon_1; +\infty)$
	Bên phải	$\varepsilon_1 = z_\alpha \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	$(-\infty; \bar{x}_1 - \bar{x}_2 + \varepsilon_1)$
Đối với dạng (4): TH chưa biết $\sigma_1, \sigma_2,$ ta thay bằng s_1, s_2 trong công thức sai số.			

$\mu_1 - \mu_2$ (5)	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \frac{\sigma_D}{\sqrt{n}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon; \bar{x}_1 - \bar{x}_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = z_\alpha \cdot \frac{\sigma_D}{\sqrt{n}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon_1; +\infty)$
	Bên phải	$\varepsilon_1 = z_\alpha \cdot \frac{\sigma_D}{\sqrt{n}}$	$(-\infty; \bar{x}_1 - \bar{x}_2 + \varepsilon_1)$
$\mu_1 - \mu_2$ (6)	Đối xứng	$\varepsilon = t_{\alpha/2}^{n-1} \cdot \frac{s_D}{\sqrt{n}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon; \bar{x}_1 - \bar{x}_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = t_\alpha^{n-1} \cdot \frac{s_D}{\sqrt{n}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon_1; +\infty)$
	Bên phải	$\varepsilon_1 = t_\alpha^{n-1} \cdot \frac{s_D}{\sqrt{n}}$	$(-\infty; \bar{x}_1 - \bar{x}_2 + \varepsilon_1)$
$\mu_1 - \mu_2$ (7)	Đối xứng	$\varepsilon = z_{\alpha/2} \cdot \frac{\sigma_D}{\sqrt{n}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon; \bar{x}_1 - \bar{x}_2 + \varepsilon)$
	Bên trái	$\varepsilon_1 = z_\alpha \cdot \frac{\sigma_D}{\sqrt{n}}$	$(\bar{x}_1 - \bar{x}_2 - \varepsilon_1; +\infty)$
	Bên phải	$\varepsilon_1 = z_\alpha \cdot \frac{\sigma_D}{\sqrt{n}}$	$(-\infty; \bar{x}_1 - \bar{x}_2 + \varepsilon_1)$
Đối với dạng (7): Trường hợp chưa biết $\sigma_D,$ ta thay bằng s_D trong công thức tính sai số.			

Quy ước các trường hợp ước lượng cho hiệu hai trung bình:

(1) 2 mẫu độc lập, X_1, X_2 có phân phối Chuẩn, đã biết σ_1^2, σ_2^2

(2) 2 mẫu độc lập, X_1, X_2 có phân phối Chuẩn, chưa biết σ_1^2, σ_2^2, với giả thiết $\sigma_1^2 = \sigma_2^2$

(3) 2 mẫu độc lập, X_1, X_2 có phân phối Chuẩn, chưa biết σ_1^2, σ_2^2, với giả thiết $\sigma_1^2 \neq \sigma_2^2$

(4) 2 mẫu độc lập, X_1, X_2 có phân phối tuỳ ý, $n_1 \geq 30$ và $n_2 \geq 30$

(5) 2 mẫu phụ thuộc tương ứng theo cặp, X_1, X_2 có phân phối Chuẩn, đã biết σ_D^2

(6) 2 mẫu phụ thuộc tương ứng theo cặp, X_1, X_2 có phân phối Chuẩn, chưa biết σ_D^2

(7) 2 mẫu phụ thuộc tương ứng theo cặp, X_1, X_2 có phân phối tuỳ ý, $n_1 \geq 30$ và $n_2 \geq 30$

2.5 Kiểm định giả thuyết thống kê

2.5.1 Tiêu chuẩn kiểm định - Miền bác bỏ

Xét một bài toán kiểm định giả thuyết H_0 và đối thuyết H_1. Giả sử rằng H_0, từ mẫu ngẫu nhiên $X = (X_1, X_2, \ldots, X_n)$. Ta chọn hàm $Z = h(X_1, X_2, \ldots, X_n; \theta_0)$ sao cho với số $\alpha > 0$ bất

tùy ý ta có thể tìm được tập hợp W_α thoả điều kiện:

$$P(Z \in W_\alpha) = \alpha$$

Đại lượng ngẫu nhiên $Z = h(X_1, X_2, \ldots, X_n; \theta_0)$ được gọi là tiêu chuẩn kiểm định giả thuyết H_0 (hay còn gọi là giá trị quan sát). Tập hợp W_α được gọi là miền bác bỏ giả thuyết H_0 (có thể hiểu là tập hợp những tiêu chuẩn kiểm định mà xảy ra thì khi đó giả thuyết H_0 bị bác bỏ), phần còn lại của W_α được gọi là miền chấp nhận. Giá trị α được gọi là mức ý nghĩa của bài toán kiểm định.

Một ký hiệu khác của miền bác bỏ giả thuyết H_0: RR (Reject Region)

2.5.2 Các sai lầm trong bài toán kiểm định

Trong bài toán kiểm định giả thuyết thống kê, ta có thể mắc phải các sai lầm sau:

- Sai lầm loại I: là sai lầm mắc phải khi ta bác bỏ giả thuyết H_0 trong khi thực tế giả thuyết H_0 đúng. Sai lầm loại I ký hiệu là α, chính là mức ý nghĩa của bài toán kiểm định.
- Sai lầm loại II: là sai lầm mắc phải khi ta chấp nhận giả thuyết H_0 trong khi thực tế giả thuyết H_0 sai. Sai lầm loại II ký hiệu là β.

	H_0 đúng	H_0 sai
Không bác bỏ H_0	Không có sai lầm $(1-\alpha)$	Sai lầm loại II β
Bác bỏ H_0	Sai lầm loại I α	Không có sai lầm $(1-\beta)$

2.5.3 Các bước thực hiện kiểm định

1. Phát biểu giả thuyết và đối thuyết của bài toán.
2. Tính giá trị thống kê kiểm định (tiêu chuẩn kiểm định) cho bài toán.
3. Xác định miền bác bỏ tốt nhất cho bài toán.
4. Đưa ra kết luận.

2.5.4 Kiểm định 1 mẫu

Kiểm định tỷ lệ 1 mẫu

Nếu ta so sánh tỷ lệ tổng thể p với giá trị cho trước gọi là p_0 thì bài toán này được gọi là kiểm định tỷ lệ 1 mẫu (Có nghĩa là dựa vào mẫu thu thập được, kiểm định để so sánh tỷ lệ tổng thể p với p_0 cho trước).

Điều kiện: $n > 30$	Tiêu chuẩn kiểm định	Miền bác bỏ
$H_0 : p = p_0$ $H_1 : p \neq p_0$	$z = \dfrac{p - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; \infty)$
$H_0 : p \geq p_0$ $H_1 : p < p_0$	$z = \dfrac{p - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$	$RR = (-\infty; -z_{\alpha})$
$H_0 : p \leq p_0$ $H_1 : p > p_0$	$z = \dfrac{p - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$	$RR = (z_{\alpha}; \infty)$

Với $np \geq 5$ và $n(1-p) \geq 5$ thì ta có phân phối (xấp xỉ) của tỷ lệ mẫu

$$\bar{P} \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$$

.

Kiểm định trung bình 1 mẫu

Nếu ta so sánh trung bình tổng thể μ với giá trị cho trước gọi là μ_0 thì bài toán này được gọi là kiểm định trung bình 1 mẫu (Có nghĩa là dựa vào mẫu thu thập được, kiểm định để so sánh trung bình tổng thể μ với μ_0 cho trước).

H_0	H_1	TCKĐ	Miền bác bỏ
(1) Trường hợp tổng thể có phân phối chuẩn, đã biết σ^2			
$\mu = \mu_0$	$\mu \neq \mu_0$	$z_{qs} = \dfrac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -z_{\alpha})$
	$\mu > \mu_0$		$RR = (z_{\alpha}; +\infty)$
(2) Trường hợp tổng thể có phân phối chuẩn, chưa biết σ^2			
$\mu = \mu_0$	$\mu \neq \mu_0$	$t_{qs} = \dfrac{\bar{x} - \mu_0}{s/\sqrt{n}}$	$RR = (-\infty; -t_{\alpha/2;n-1}) \cup (t_{\alpha/2;n-1}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -t_{\alpha;n-1})$
	$\mu > \mu_0$		$RR = (t_{\alpha;n-1}; +\infty)$
(3) Trường hợp tổng thể có phân phối tuỳ ý, $n \geq 30$			
$\mu = \mu_0$	$\mu \neq \mu_0$	$z_{qs} = \dfrac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -z_{\alpha})$
	$\mu > \mu_0$		$RR = (z_{\alpha}; +\infty)$

2.5.5 Kiểm định 2 mẫu

Kiểm định tỷ lệ 2 mẫu:

Giả thuyết	**Miền bác bỏ**
$H_0: p_1 = p_2$ $H_1: p_1 \neq p_2$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
$H_0: p_1 = p_2$ $H_1: p_1 > p_2$	$RR = (-\infty; -z_\alpha)$
$H_0: p_1 = p_2$ $H_1: p_1 < p_2$	$RR = (z_\alpha; +\infty)$

Tính thống kê kiểm định:

$$z_0 = \frac{f_1 - f_2}{\sqrt{\frac{\bar{f}(1-\bar{f})}{\bar{n}}}}$$

với

$$\bar{f} = \frac{m_1 + m_2}{n_1 + n_2}$$

$$\bar{n} = \frac{n_1 \cdot n_2}{n_1 + n_2}$$

Kiểm định trung bình 2 mẫu:

H_0	H_1	TCKĐ	Miền bác bỏ
(1) Kiểm định trung bình 2 mẫu - trường hợp đã biết σ_1^2, σ_2^2			
$\mu = \mu_0$	$\mu \neq \mu_0$	$z_0 = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -z_\alpha)$
	$\mu > \mu_0$		$RR = (z_\alpha; +\infty)$
(2) Kiểm định trung bình 2 mẫu, mẫu lớn $n_1 \geq 30$ và $n_2 \geq 30$			
$\mu = \mu_0$	$\mu \neq \mu_0$	$z_0 = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -z_\alpha)$
	$\mu > \mu_0$		$RR = (z_\alpha; +\infty)$

(3) Kiểm định trung bình 2 mẫu - trường hợp chưa biết σ_1^2, σ_2^2 hoặc $n_1 \leq 30$ và $n_2 \leq 30$

Trường hợp 1: $\sigma_1^2 = \sigma_2^2$:

Giả thuyết		**Miền bác bỏ (1)**
$H_0: \mu_1 = \mu_2$	$H_1: \mu_1 \neq \mu_2$	$RR = (-\infty; -t_{\alpha/2;df}) \cup (t_{\alpha/2;df}; +\infty)$
$H_0: \mu_1 = \mu_2$	$H_1: \mu_1 < \mu_2$	$RR = (-\infty; -t_{\alpha;df})$
$H_0: \mu_1 = \mu_2$	$H_1: \mu_1 > \mu_2$	$RR = (t_{\alpha;df}; +\infty)$

Với: $df = n_1 + n_2 - 2$

$$t_0 = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \quad \text{với } S^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

Với: $S^2 = \frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}$ và $df = n_1 + n_2 - 2$

Trường hợp 2: $\sigma_1^2 \neq \sigma_2^2$:

Giả thuyết		Miền bác bỏ (1)
$H_0 : \mu_1 = \mu_2$	$H_1 : \mu_1 \neq \mu_2$	$RR = (-\infty; -t_{\alpha/2;df}) \cup (t_{\alpha/2;df}; +\infty)$
$H_0 : \mu_1 = \mu_2$	$H_1 : \mu_1 < \mu_2$	$RR = (-\infty; -t_{\alpha;df})$
$H_0 : \mu_1 = \mu_2$	$H_1 : \mu_1 > \mu_2$	$RR = (t_{\alpha;df}; +\infty)$

$$df = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$ lấy df làm tròn số nguyên theo nguyên tắc quá bán

$$t_0 = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

(4) Kiểm định trung bình 2 mẫu không độc lập

$$\bar{d} = \frac{1}{n}\sum_{i=1}^{n} d_i$$

$$s_d^2 = \frac{1}{n-1}\sum_{i=1}^{n}(d_i - \bar{d})^2$$

Giả thuyết	Miền bác bỏ (1)
$H_0 : \mu_D = D_0$ $H_1 : \mu_D \neq D_0$	$RR = (-\infty; -t_{\alpha/2,n-1}) \cup (t_{\alpha/2,n-1}; +\infty)$
$H_0 : \mu_D = D_0$ $H_1 : \mu_D > D_0$	$RR = (-\infty; -t_{\alpha,n-1})$
$H_0 : \mu_D = D_0$ $H_1 : \mu_D < D_0$	$RR = (t_{\alpha,n-1}; +\infty)$

Thông thường: $D_0 = 0$

$$t_0 = \frac{\bar{d} - D_0}{\frac{s_d}{\sqrt{n}}}$$

$$\text{với} \quad d_i = x_i - y_i \quad ; \quad \bar{d} = \frac{1}{n}\sum_{i=1}^{n} d_i$$

$$s_d^2 = \frac{1}{n-1}\sum_{i=1}^{n}(d_i - \bar{d})^2$$

2.6 Phân tích phương sai (ANOVA)

Mục tiêu của phân tích phương sai là so sánh trung bình của nhiều nhóm (tổng thể) dựa

trên các số trung bình của các mẫu quan sát từ các nhóm này và thông qua kiểm định giả thuyết để kết luận về sự bằng nhau của các số trung bình này. Trong nghiên cứu, phân tích phương sai được dùng như là một công cụ để xem xét ảnh hưởng của một hay một số yếu tố nguyên nhân (định tính) đến một yếu tố kết quả (định lượng).

Ta có các mô hình phân tích phương sai như sau: phân tích phương sai một nhân tố, 2 nhân tố và 3 nhân tố. Cụm từ nhân tố cho ta số lượng nhân tố nguyên nhân ảnh hưởng đến kết quả ta nghiên cứu.

Phân tích phương sai một yếu tố là phân tích ảnh hưởng của một yếu tố nguyên nhân (dạng biến định tính) đến một yếu tố kết quả (dạng biến định lượng) đang nghiên cứu.

Giả sử cần so sánh số trung bình của k tổng thể độc lập trên những mẫu ngẫu nhiên và độc lập $n_1, n_2, \ldots, n_k$ quan sát từ k tổng thể này. Cần ghi nhớ ba giả định sau đây để được tiến hành phân tích Anova:

- Các tổng thể này có phân phối chuẩn.
- Các phương sai của tổng thể bằng nhau.
- Các quan sát được lấy mẫu là độc lập.

Nếu trung bình các tổng thể được ký hiệu là $\mu_1, \mu_2, \ldots, \mu_k$ thì ta có các giả thiết trong mô hình phân tích phương sai như sau:

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \cdots = \mu_k$$

(Giả thiết H_0 cho rằng trung bình của k tổng thể bằng nhau, tức nhân tố nguyên nhân không có tác động gì đến nhân tố kết quả ta đang nghiên cứu).

$$H_1 : \exists \mu_i \neq \mu_j \quad (i \neq j)$$

(Giả thiết H_1 cho rằng có ít nhất 2 giá trị trung bình ở các tổng thể khác nhau, tức nhân tố nguyên nhân có tác động đến nhân tố kết quả ta đang nghiên cứu). Các bước tiến hành phân tích phương sai một nhân tố:

Bước 1: Tính trung bình mẫu của các nhóm $\overline{x}_1, \overline{x}_2, \ldots, \overline{x}_k$ theo công thức:

$$\overline{x}_i = \frac{\sum_{j=1}^{n_i} x_{ij}}{n_i}, \quad (i = 1, 2, \ldots, k)$$

Trung bình chung của k mẫu được tính theo công thức:

$$\overline{x} = \frac{\sum_{i=1}^{k} n_i \overline{x}_i}{\sum_{i=1}^{k} n_i}, \quad (i = 1, 2, \ldots, k)$$

Bước 2: Tính tổng các chênh lệch bình phương (tổng bình phương):

- Tổng các độ lệch bình phương trong nội bộ nhóm (SSW):

$$\text{SSW} = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(x_{ij} - \overline{x}_i)^2$$

- Tổng các độ lệch bình phương giữa các nhóm (SSB):

$$\text{SSB} = \sum_{i=1}^{k} n_i(\overline{x}_i - \overline{x})^2$$

- Tổng các độ lệch bình phương của toàn bộ tổng thể(SST):

$$\text{SST} = SSW + SSB = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(x_{ij} - \overline{x})^2$$

Bước 3: Tính các phương sai:

$$\text{MSW} = \frac{\text{SSW}}{n-k}, \quad \text{MSB} = \frac{\text{SSB}}{k-1}$$

Bước 4: Tính thống kê kiểm định (tiêu chuẩn kiểm định, giá trị quan sát):

$$F = \frac{MSB}{MSW}$$

Bước 5: Xác định miền bác bỏ của bài toán:

$$RR = (F_{\alpha;k-1;N-k}; +\infty)$$

Tìm giá trị $F_{\alpha;k-1;N-k}$: tra bảng Fisher mức ý nghĩa α và cột $k-1$ và dòng $N-k$.
Bước 6: Đưa ra kết luận:

$$\text{Nếu } F > F_{\alpha;k-1;N-k} \iff F \in RR \Rightarrow \text{Bác bỏ } H_0, \text{chấp nhận } H_1$$

$$\text{Nếu} F < F_{\alpha;k-1;N-k} \iff F \notin RR \Rightarrow \text{không bác bỏ } H_0 \text{ (chưa bác bỏ được } H_0, \text{chấp nhận } H_0)$$

Bảng mô hình phân tích phương sai một nhân tố:

Nguồn của sự biến thiên	**SS**	**df**	**MS**	**F**
Giữa các nhóm	SSB	$k-1$	MSB	$F = \frac{\text{MSB}}{\text{MSW}}$
Trong từng nhóm	SSW	$N-k$	MSW	
Toàn bộ	SST	$N-1$		

2.7 Phân tích hồi quy tuyến tính

Hồi quy tuyến tính là một mô hình thống kê mô tả mối quan hệ tuyến tính giữa một biến phụ thuộc (Y) và một hoặc nhiều biến độc lập (X).

Trong mối liên hệ hàm số, với mỗi một giá trị X ta tìm được duy nhất một giá trị Y. Tuy nhiên trong thống kê, một giá trị X có thể cho tương ứng nhiều giá trị Y khác nhau, bởi vì ngoài biến chính là X, biến Y có thể còn chịu tác động bởi một số yếu tố khác.

Hồi quy tuyến tính đơn là một mô hình thống kê mô tả mối quan hệ tuyến tính giữa một biến phụ thuộc (Y) và một biến độc lập (X). Sau đó vẽ một đường thẳng hồi quy và từ phương trình đường thẳng này ta có thể dự đoán được biến y khi đã có X.

$$Y = \beta_0 + \beta_1 X + \mu$$

- X là biến độc lập, giải thích cho Y
- β_0 là hệ số chặn, là giá trị của biến phụ thuộc khi biến độc lập bằng 0
- β_1 là hệ số hồi quy, cho biết mỗi đơn vị thay đổi của biến độc lập sẽ làm cho biến phụ thuộc thay đổi trong bình bao nhiêu đơn vị
- μ là sai số

3 Tiền xử lý số liệu:

3.1 Đọc dữ liệu vào R (Import data)

Đọc dữ liệu "All_GPUs.csv" và lưu vào với biến có tên là gpu_data. Vì có quá nhiều biến nên chỉ chọn 3 dòng đầu tiên để hiện thị.

Code

```
gpu_data <- read.csv("F:/Study/233/archive/All_GPUs.csv")
head(gpu_data, 3)
```

Result

```
  Architecture   Best_Resolution Boost_Clock Core_Speed DVI_Connection Dedicated
1    Tesla G92b                                 738 MHz              2       Yes
2    R600 XT        1366 x 768                     \n-              2       Yes
3    R600 PRO       1366 x 768                     \n-              2       Yes
  Direct_X DisplayPort_Connection HDMI_Connection Integrated L2_Cache
1   DX 10.0                 NA             0         No      0KB
2   DX 10                   NA             0         No      0KB
3   DX 10                   NA             0         No      0KB
  Manufacturer Max_Power   Memory Memory_Bandwidth Memory_Bus Memory_Speed
1       Nvidia 141 Watts 1024 MB         64GB/sec   256 Bit      1000 MHz
2        AMD 215 Watts  512 MB        106GB/sec   512 Bit       828 MHz
3        AMD 200 Watts  512 MB       51.2GB/sec   256 Bit       800 MHz
  Memory_Type                Name Notebook_GPU Open_GL              PSU
1      GDDR3         GeForce GTS 150          No     3.3 450 Watt & 38 Amps
2      GDDR3 Radeon HD 2900 XT 512MB          No     3.1 550 Watt & 35 Amps
3      GDDR3      Radeon HD 2900 Pro          No     3.1 550 Watt & 35 Amps
   Pixel_Rate Power_Connector Process ROPs   Release_Date Release_Price
1 12 GPixel/s           None     55nm   16 \n01-Mar-2009
2 12 GPixel/s           None     80nm   16 \n14-May-2007
3 10 GPixel/s           None     80nm   16 \n07-Dec-2007
  Resolution_WxH SLI_Crossfire Shader TMUs Texture_Rate VGA_Connection
1      2560x1600           Yes      4   64  47 GTexel/s             0
2      2560x1600           Yes      4   16  12 GTexel/s             0
3      2560x1600           Yes      4   16  10 GTexel/s             0
```

Tiếp đến, ta kiểm tra số quan sát và số biến của tập tin thông qua số dòng và số cột:

Code

```
dim(gpu_data)
```

Result

```
[1] 3406   34
```

Ta thấy tệp tin có 3406 quan sát và 34 cột.

3.2 Làm sạch dữ liệu

3.2.1 Chọn ra tệp tin con bao gồm các biến sẽ được sử dụng và phân tích:

Ta sẽ xem xét chọn ra 6 biến phân loại để phân tích và tổng hợp nó vào selected_data.

Code

```
selected_data <- gpu_data[, c("Manufacturer", "Memory_Bandwidth", "Release_Date",
    "Memory_Bus", "Texture_Rate", "Memory_Speed")]
```

Result

```
'data.frame': 3406 obs. of  6 variables:
 $ Manufacturer    : chr  "Nvidia" "AMD" "AMD" "AMD" ...
 $ Memory_Bandwidth: chr  "64GB/sec" "106GB/sec" "51.2GB/sec" "36.8GB/sec" ...
 $ Release_Date    : chr  "\n01-Mar-2009 " "\n14-May-2007 " "\n07-Dec-2007 " "\n01-Jul-2007 " ...
 $ Memory_Bus      : chr  "256 Bit " "512 Bit " "256 Bit " "128 Bit " ...
 $ Texture_Rate    : chr  "47 GTexel/s" "12 GTexel/s" "10 GTexel/s" "7 GTexel/s" ...
 $ Memory_Speed    : chr  "1000 MHz" "828 MHz" "800 MHz" "1150 MHz" ...
```

3.2.2 Xử lý đơn vị của các biến trong tệp:

Ta sẽ loại bỏ các đơn vị của các biến Memory_Bandwitdth,Memory_Bus, Texture_Rate, Memory_Speed và xóa đi những dòng mà Release_Date bị thiếu thông tin.

Code

```
selected_data$Memory_Bandwidth <- as.numeric(sub("GB/sec", "",
    selected_data$Memory_Bandwidth))
selected_data$Memory_Bus <- as.numeric(sub("Bit", "", selected_data$Memory_Bus))
selected_data$Memory_Speed <- as.numeric(sub("MHz", "",
    selected_data$Memory_Speed))
selected_data$Texture_Rate <- as.numeric(sub("GTexel/s", "",
    selected_data$Texture_Rate))
selected_data <- selected_data[!grepl("Unknown␣Release␣Date",
    selected_data$Release_Date), ]
```

3.2.3 Tạo thêm biến

Biến Release_Date chứa đầy đủ ngày tháng năm khiến việc xử lý thông tin đôi khi gặp khó khăn, đề xuất việc tạo thêm 1 biến Year chỉ chứa năm ra mắt để tăng hiệu quả trong quá trình thống kê.

Code

```
test_mat <- strsplit(selected_data$Release_Date, split = '-')
date_matrix <- matrix(unlist(test_mat), ncol = 3, byrow = TRUE)
selected_data$Year <- date_matrix[, 3]
selected_data$Year <- as.numeric(selected_data$Year)
```

Result

XSTKassignment.rmd × selected_data ×

Filter

	Manufacturer	Memory_Bandwidth	Release_Date	Memory_Bus	Texture_Rate	Memory_Speed	Year
1	Nvidia	64.0	01-Mar-2009	256	47	1000	2009
2	AMD	106.0	14-May-2007	512	12	828	2007
3	AMD	51.2	07-Dec-2007	256	10	800	2007
4	AMD	36.8	01-Jul-2007	128	7	1150	2007
5	AMD	22.4	28-Jun-2007	128	6	700	2007
6	AMD	35.2	26-Jun-2007	128	6	1100	2007
7	AMD	134.4	13-Jul-2009	256	35	1050	2009
8	AMD	51.2	06-Nov-2007	256	7	800	2007
9	AMD	160.0	18-Jan-2014	256	62	1250	2014
10	AMD	2.9	02-Jan-2001	64	NA	366	2001
11	Nvidia	5.2	01-Nov-2002	128	2	325	2002
12	Nvidia	177.6	25-Jul-2011	384	36	925	2011
13	Nvidia	168.0	01-Nov-2012	320	NA	1050	2012
14	Nvidia	288.4	12-Nov-2013	384	169	1502	2013

3.3 Kiểm tra và xử lý các dữ liệu bị khuyết (NA)

Đầu tiên, ta sẽ kiểm tra tổng các khuyết thiếu của từng biến và thống kê tỉ lệ dữ liệu khuyết:

Code

```
total_missing <- colSums(is.na(selected_data))
print(total_missing)
```

Result

```
Manufacturer Memory_Bandwidth     Release_Date
           0              123                0
Memory_Bus     Texture_Rate     Memory_Speed            Year
          60              542              103               0
```

Từ kết quả, ta thấy biến Memory_Bandwidth bị thiếu 123 dữ liệu, Memory_Bus bị thiếu 60 dữ liệu, Texture_Rate là 542 và cuối cùng biến Memory_Speed có 103 dữ liệu bị khuyết.

Code

```
mean_missing <- colMeans(is.na(selected_data))
print(mean_missing)
```

Result

```
Manufacturer Memory_Bandwidth     Release_Date
  0.00000000        0.03643365       0.00000000
Memory_Bus     Texture_Rate     Memory_Speed            Year
  0.01777251       0.16054502       0.03050948     0.00000000
```

Từ kết quả, ta thấy biến Memory_Bandwidth bị thiếu 3.64% dữ liệu, Memory_Bus bị thiếu 1.78% dữ liệu, Texture_Rate là 16.05%, và cuối cùng biến Memory_Speed có 3.05% dữ liệu bị khuyết.

Để đảm bảo tính toàn vẹn và chính xác của phân tích, ta sẽ loại bỏ các dòng dữ liệu bị khuyết thiếu, vì khi một cột có tỷ lệ dữ liệu bị khuyết lớn, việc giữ lại các dòng dữ liệu khuyết có thể làm sai lệch kết quả, gây ảnh hưởng đến mô hình hoặc phân tích.

Code

```
selected_data <- na.omit(selected_data)
which(is.na(selected_data))
```

Result

```
integer(0)
```

4 Thống kê mô tả

4.1 Đồ thị histogram thể hiện phân phối của Memory_Bandwidth:

Code

```
hist(selected_data$Memory_Bandwidth,
     xlab = "Memory_Bandwidth",
     main = "Histogram of Memory_Bandwidth",
     labels = TRUE,
     ylim = c(0, 1800),
     col = "skyblue")
```

Result

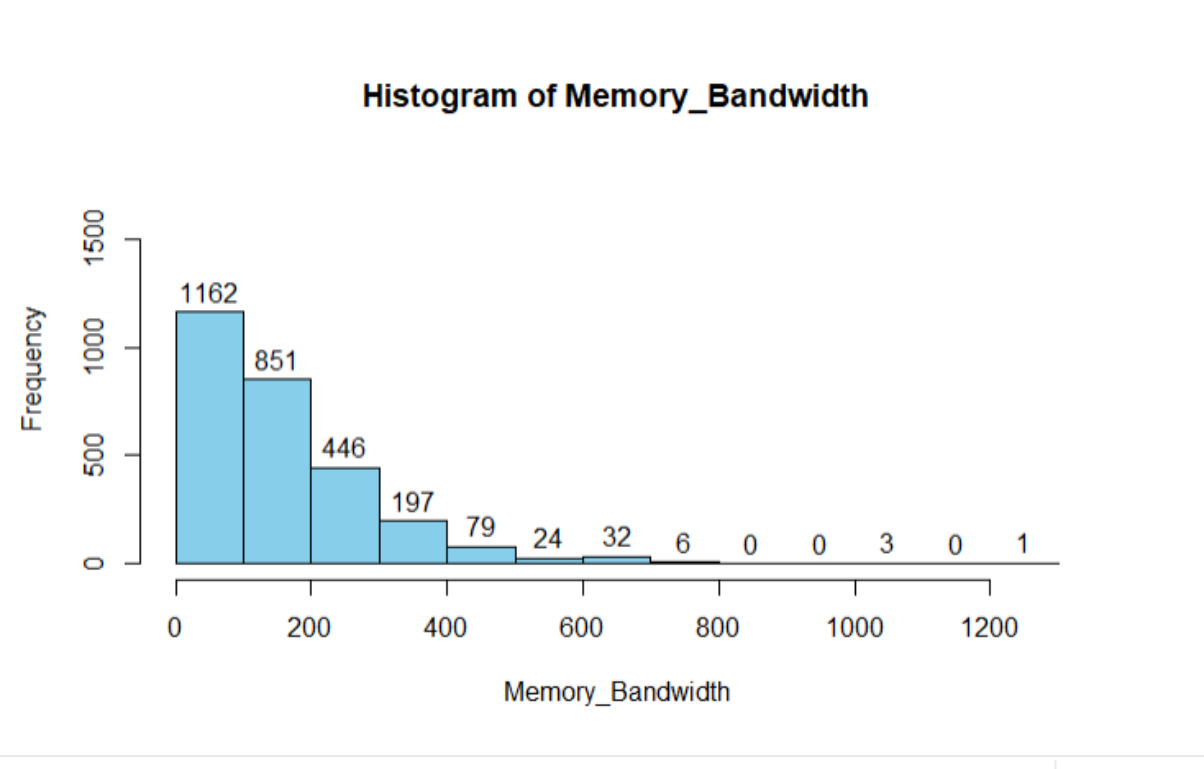

Đồ thị cho ta thấy được vùng giá trị của Memory_Bandwith từ 0 cho đến 100 có tần số xuất hiện cao nhất là 1162 lần. Đồ thị lệch phải cho thấy vùng phân bố giá trị của Memory_Bandwidth xuất hiện chủ yếu với các giá trị dưới 700. Đồ thị không có hình dạng phân phối chuẩn.

4.2 Mối liên hệ của Memory_Bandwidth đến Manufacturer

4.2.1 Tính thống kê mô tả thể hiện Memory_Bandwidth theo Manufacturer

Ta sẽ thống kê những giá trị đặc trưng những giá trị của Memory_Bandwidth theo từng Manufacturer khác nhau

Code

```
by(selected_data$Memory_Bandwidth, selected_data$Manufacturer, function(x)
    c(summary(x), sd = sd(x)))
```

Result

```
selected_data$Manufacturer: AMD
     Min.   1st Qu.    Median      Mean   3rd Qu.      Max.        sd
   3.2000   34.1000  112.0000  146.0449  192.0000 1280.0000  138.2814
------------------------------------------------------------------------------------------------------
selected_data$Manufacturer: ATI
     Min.   1st Qu.    Median      Mean   3rd Qu.      Max.        sd
 112.0000  211.2000  224.0000  221.7086  256.0000 1024.0000  116.4545
------------------------------------------------------------------------------------------------------
selected_data$Manufacturer: Intel
    Min.  1st Qu.   Median     Mean  3rd Qu.     Max.       sd
12.80000 25.60000 29.90000 28.68496 34.10000 34.10000  5.33856
------------------------------------------------------------------------------------------------------
selected_data$Manufacturer: Nvidia
    Min.  1st Qu.   Median     Mean  3rd Qu.     Max.       sd
  2.7000  80.0000 134.4000 168.8371 224.4000 769.0000 136.9688
```

Phân tích: Có sự khác biệt đáng kể về Memory_Bandwidth giữa các nhà sản xuất khác nhau.

4.2.2 Đồ thị Boxplot thể hiện phân phối của Memory_Bandwidth theo Manufacturer

Code

```
boxplot(
  Memory_Bandwidth ~ Manufacturer,
  data = selected_data,
  main = "Boxplot of Memory Bandwidth by Manufacturer",
  xlab = "Manufacturer",
  ylab = "Memory Bandwidth",
  col = c("LightSkyBlue", "SkyBlue", "SteelBlue")
)
```

Result

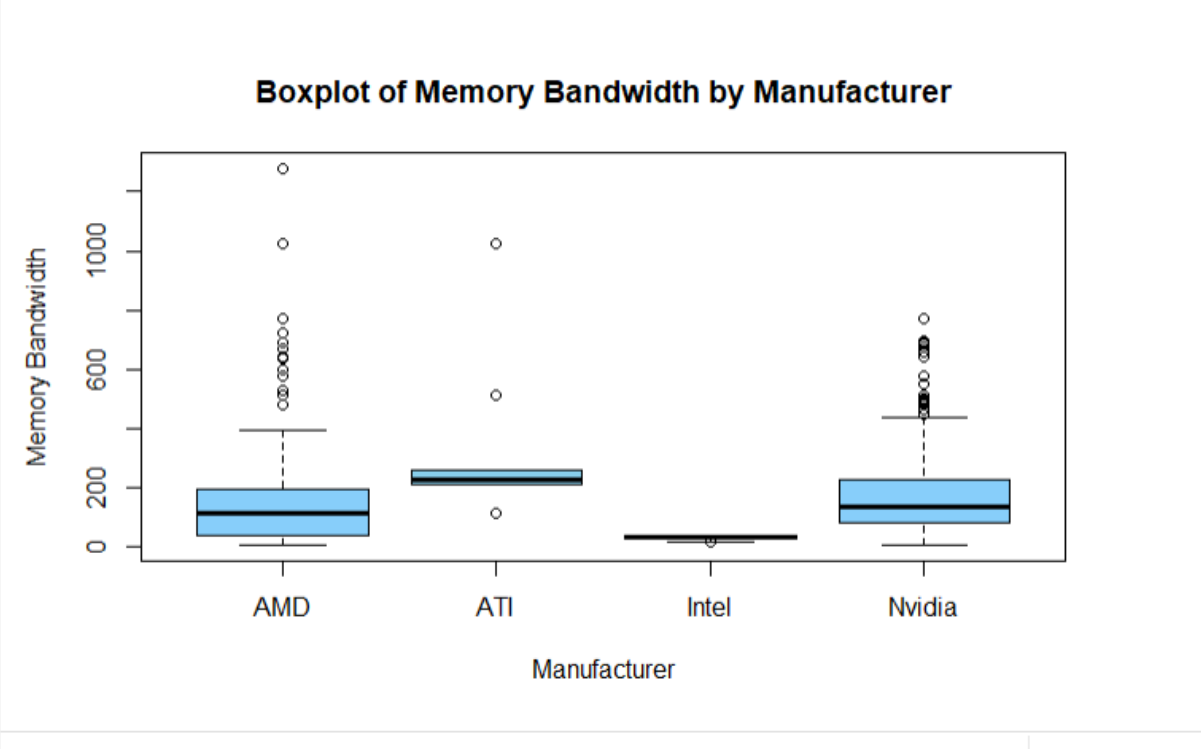

Dựa trên biểu đồ boxplot trong hình, ta có thể nhận xét về sự khác biệt trong phân phối Memory_Bandwidth giữa các nhà sản xuất (Manufacturer) như sau:

AMD: Có phân phối băng thông bộ nhớ khá thấp, với đa số giá trị nằm trong khoảng từ 0 đến khoảng 100 MB/s. Có nhiều giá trị ngoại lệ (outliers) nằm trên mức này, cho thấy có một số sản phẩm với băng thông bộ nhớ cao hơn, nhưng số lượng này là không đáng kể.

ATI: Phân phối của ATI có trung vị cao hơn AMD, nhưng vẫn thấp hơn nhiều so với các nhà sản xuất khác. Các giá trị của ATI ít ngoại lệ hơn và tập trung trong một phạm vi nhất định, cho thấy các sản phẩm của ATI có tính nhất quán hơn về băng thông bộ nhớ.

Intel: Intel có băng thông bộ nhớ trung bình thấp nhất trong số các nhà sản xuất, với rất ít biến động. Phần lớn giá trị tập trung gần mức 0. Điều này cho thấy sản phẩm của Intel trong dữ liệu này có băng thông bộ nhớ rất thấp, với rất ít ngoại lệ.

Nvidia: Nvidia có phân phối rộng nhất về băng thông bộ nhớ, với nhiều sản phẩm có băng thông rất cao. Phân phối này cho thấy Nvidia có sự đa dạng về sản phẩm, từ các sản phẩm có băng thông bộ nhớ thấp đến rất cao. Nvidia cũng có nhiều giá trị ngoại lệ, chứng tỏ sự hiện diện của các sản phẩm rất mạnh mẽ về băng thông bộ nhớ.

4.3 Vẽ đồ thị Boxplot và đồ thị phân tán của Memory_Bandwidth theo năm

Code

```
par(mfrow = c(1, 2))
boxplot (Memory_Bandwidth ~ Year, data = selected_data,xlab = "Year", ylab =
    "Memory␣Bandwidth",col = "LightSkyBlue" )
plot (selected_data$Year, selected_data$Memory_Bandwidth, xlab = "Year", ylab =
    "Memory␣Bandwidth",col = "DodgerBlue")
```

Result

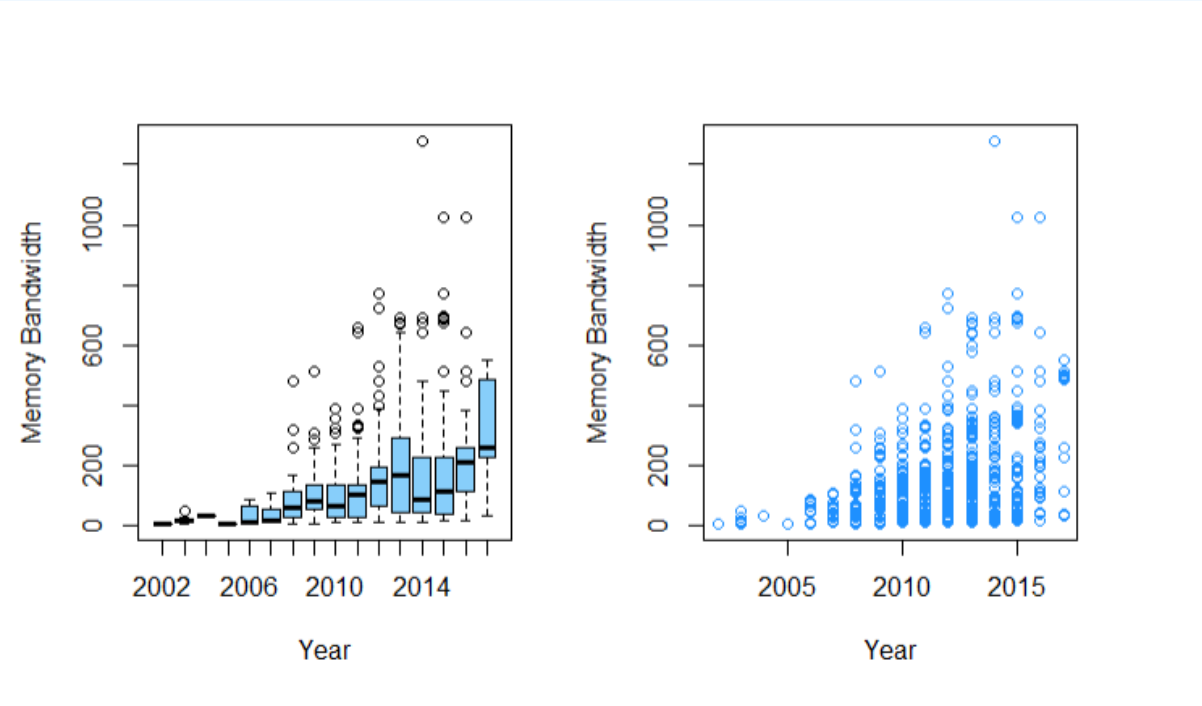

Khả năng truyền tải bộ nhớ qua các năm có xu hướng tăng tuy nhiên đồ thị cho thấy đây không có quan hệ tuyến tính giữa Memory_Bandwidth với Year.

4.4 Đồ thị tương quan giữa các biến

Code

```
selected_data_corr <- selected_data[, c("Memory_Bandwidth", "Year", "Texture_Rate",
    "Memory_Bus", "Memory_Speed")]
corr_matrix <- cor(selected_data_corr)
corrplot(corr_matrix, method = "circle")
```

Result

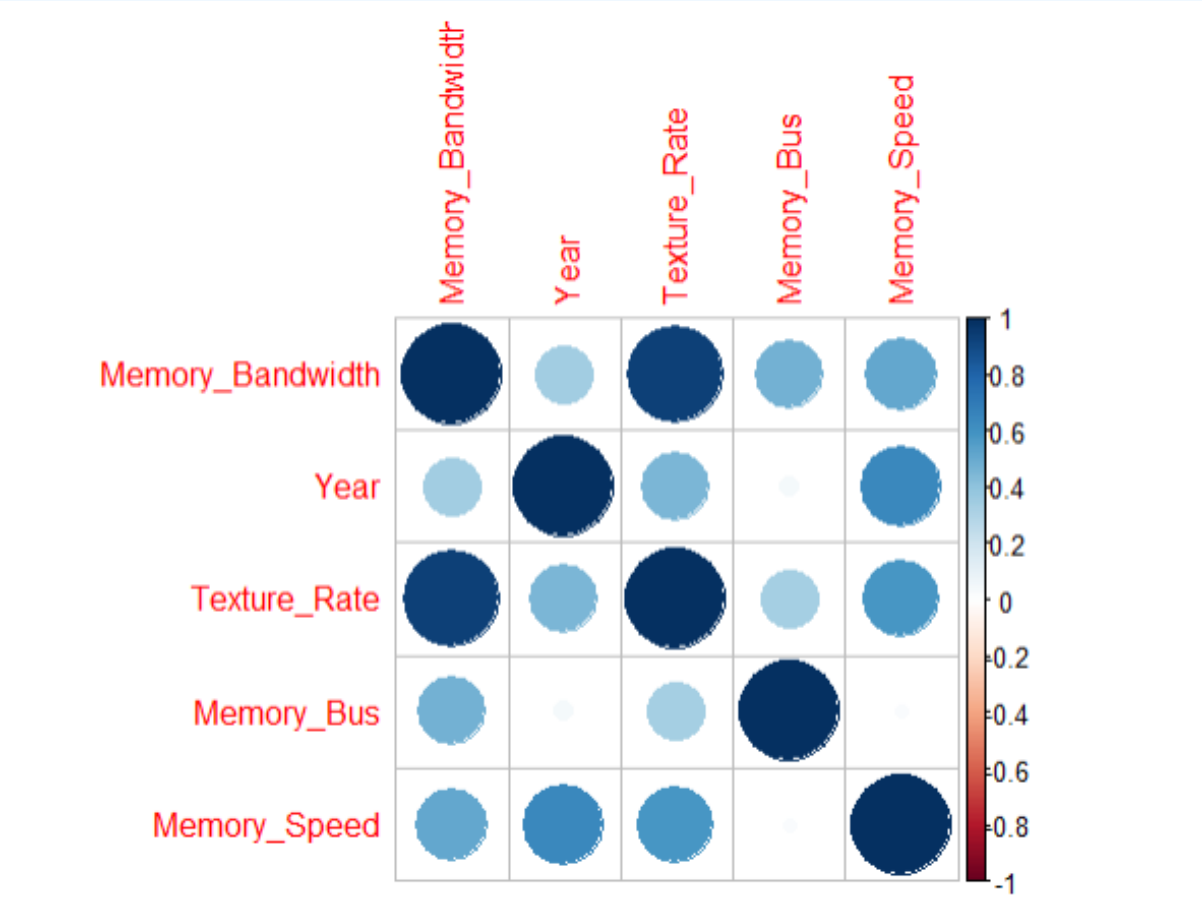

Từ hình ta nghi ngờ có hiện tượng đa cộng tuyến xảy ra. Ta sẽ xem xét loại bỏ 1 trong 2 biến trong này nếu không tìm được hệ số hồi quy khi xây dựng mô hình.

5 Thống kê suy diễn

5.1 Bài toán 1 mẫu

Ta đặt bài toán: Với độ tin cậy 95%, hãy ước lượng khả năng truyền tải dữ liệu của bộ nhớ GPU trung bình dựa theo bộ dữ liệu trên? Gọi X là khả năng truyền tải dữ liệu của bộ nhớ (Memory_Bandwidth).

Bước 1: Tính các thống kê mẫu $(n, \bar{x}, s)$

Code

```
n <- length(selected_data$Memory_Bandwidth)
xtb <- mean(selected_data$Memory_Bandwidth)
s <- sd(selected_data$Memory_Bandwidth)
data.frame(n, xtb, s)
```

Result

```
n xtb s
2801 154.6952 137.3717
```

Vậy theo đề bài ta ra được: $n = 2801$; $\bar{x} = 154.6952$; $s = 137.3717$. Bước 2: Kiểm định phân phối chuẩn Đặt giả thuyết:

- H_0: X tuân theo phân phối chuẩn.
- H_1: X không tuân theo phân phối chuẩn.

Có thể kiểm tra theo 2 cách:

Code

```
qqnorm(selected_data$Memory_Bandwidth)
qqline(selected_data$Memory_Bandwidth)
```

Result

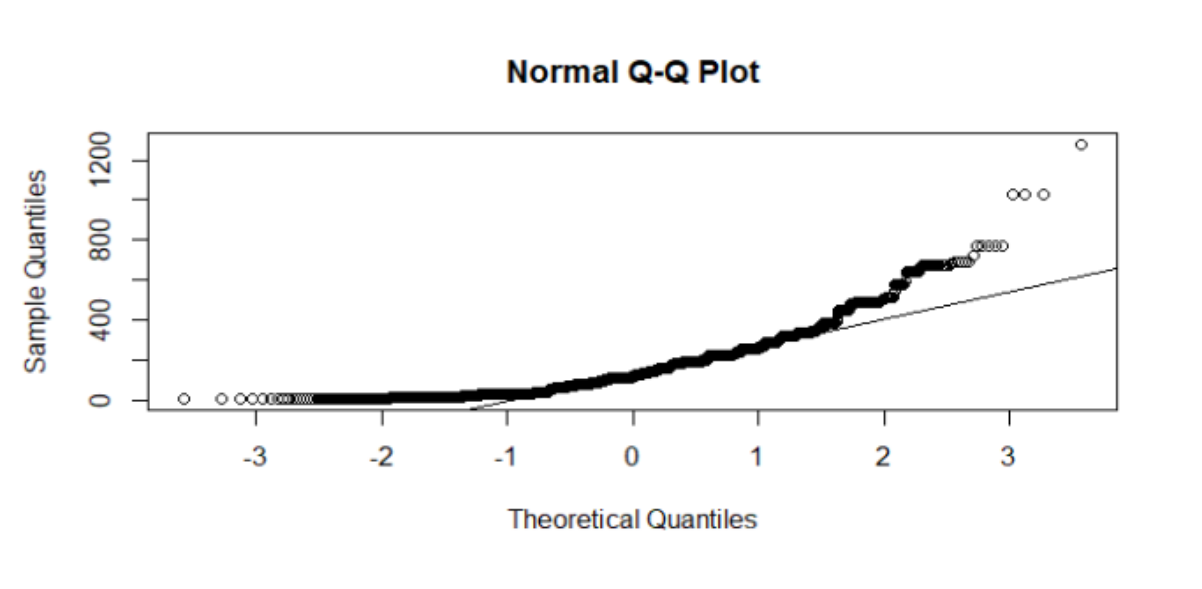

Code

```
shapiro.test(selected_data$Memory_Bandwidth)
```

Result

```
    Shapiro-Wilk normality test
data: selected_data$Memory_Bandwidth
W = 0.85418, p-value < 2.2e-16
```

Kết luận: Vì $p < 2,2e^{-16} < \alpha = 5\% \Rightarrow$ bác bỏ $H_0 \Rightarrow$

- X không có phân phối chuẩn.
- Đây là bài toán ước lượng trung bình, trong trường hợp tổng thể có phân phối bất kỳ và cỡ mẫu lớn.

Bước 3: Tính sai số

Code

```
E = qnorm(p= 1-0.05/2)*s/sqrt(n)
print(E)
```

Result

```
5.087317
```

Ta ra được độ chính xác: $\varepsilon = 5.0873$

Code

```
data.frame(CT=xtb-E, CP=xtb+E)
```

Result

```
CT CP
149.6079 159.7825
```

Với độ tin cậy 95%, khả năng truyền tải dữ liệu của bộ nhớ GPU trung bình dựa theo bộ dữ liệu trên: $(\bar{x} - \varepsilon; \bar{x} + \varepsilon) \Leftrightarrow (149.6079; 159.7825)$

Xét trường hợp giả sử X có phân phối chuẩn.

Code

```
E1 = qt(p=1-0.05/2, df = n-1)*s/sqrt(n)
print(E1)
```

Result

```
5.089517
```

Ta ra số liệu thống kê đã tính được ở trên: $n = 2801$; $\bar{x} = 154.6952$; $s = 137.3717$. Ta có độ chính xác: $\varepsilon = 5.0895$

Code

```
data.frame(CT1=xtb-E1, CP1=xtb+E1)
```

Result

```
CT1 CP1
149.6057 159.7847
```

Với độ tin cậy 95%, khả năng truyền tải dữ liệu của bộ nhớ GPU trung bình dựa theo bộ dữ liệu trên: $(\bar{x} - \varepsilon; \bar{x} + \varepsilon) \Leftrightarrow (149.6057; 159.7847)$

5.2 Bài toán 2 mẫu

Mục tiêu: Với mức ý nghĩa 1% có thể kết luận rằng khả năng truyền tải bộ nhớ GPU ở nhóm 2 có cao hơn so với nhóm 1 hay không? Vì bộ dữ liệu toàn các biến định lượng, do đó ta đặt biến mới, đặt tên là:

- **Nhóm 1:** Memory_Speed ≤ 1300
- **Nhóm 2:** Memory_Speed > 1300

Code

```
#Group 1
group_1_data <- subset(selected_data, Group == "Group_1")
n1 <- length(group_1_data$Memory_Bandwidth)
xtb1 <- mean(group_1_data$Memory_Bandwidth)
s1 <- sd(group_1_data$Memory_Bandwidth)
#Group 2
group_2_data <- subset(selected_data, Group == "Group_2")
n2 <- length(group_2_data$Memory_Bandwidth)
xtb2 <- mean(group_2_data$Memory_Bandwidth)
s2 <- sd(group_2_data$Memory_Bandwidth)
#Print result
data.frame(n1, xtb1, s1, n2, xtb2, s2)
```

Result

```
n1 xtb1 s1 n2 xtb2 s2
1547 93.18727 113.8026 1254 230.5746 125.5273
```

Gọi μ_1 và μ_2 lần lượt là khả năng truyền tải bộ nhớ trung bình ở nhóm 1 và nhóm 2. Giả thuyết được đặt ra như sau:

- $H_0 : \mu_1 = \mu_2$ (khả năng truyền tải bộ nhớ trung bình ở nhóm 1 và nhóm 2 là như nhau)
- $H_1 : \mu_1 < \mu_2$ (khả năng truyền tải bộ nhớ trung bình ở nhóm 1 thấp hơn nhóm 2)

Ta ra được các số liệu thống kê như sau:

$$n_1 = 1547, \quad \bar{x}_1 = 93.1873, \quad s_1 = 113.8026$$
$$n_2 = 1254, \quad \bar{x}_2 = 230.5746, \quad s_2 = 125.5273$$

Sau khi đã ra được các số liệu thống kê thì tiếp tục sẽ kiểm tra từng nhóm xem Nhóm 1 và Nhóm 2 có phân phối chuẩn hay không? Ta thực hiện bằng cách:

Code

```
shapiro.test(group_1_data$Memory_Bandwidth)
shapiro.test(group_2_data$Memory_Bandwidth)
```

Result

```
        Shapiro-Wilk normality test

data:  group_1_data$Memory_Bandwidth
W = 0.67048, p-value < 2.2e-16

        Shapiro-Wilk normality test

data:  group_2_data$Memory_Bandwidth
W = 0.85909, p-value < 2.2e-16
```

Nhận xét: Do cả 2 p-value của 2 nhóm đều bé hơn mức ý nghĩa 1%. Vậy Nhóm 1 và Nhóm 2 đều không tuân theo phân phối chuẩn.

$\Rightarrow$ Mẫu có phân phối bất kỳ, cỡ mẫu lớn

Tính thống kê kiểm định và tìm miền bác bỏ:

Code

```
z0 <- (xtb1 - xtb2) / sqrt(s1^2 / n1 + s2^2 / n2)
RR <- qnorm(p = 1 - 0.01 / 2)
c(z0 = z0, RR = RR)
```

Result

```
     z0 RR
-30.025323 2.575829
```

Miền bác bỏ:

$$RR = (-\infty; -2.5758)$$

Giá trị kiểm định:

$$z_0 = -30.0253$$

Vì $z_0 \in \mathbb{R}$, nên bác bỏ H_0 và chấp nhận H_1. Kết luận: Khả năng truyền tải bộ nhớ ở nhóm 2 cao hơn ở nhóm 1 với mức ý nghĩa 1%.

Xét trường hợp 2 nhóm có phân phối chuẩn

Ta tiếp tục so sánh phương sai của hai nhóm, thực hiện bài toán kiểm định phương sai hai mẫu.

Đặt giả thuyết:

- $H_0 : \sigma_1^2 = \sigma_2^2$
- $H_1 : \sigma_1^2 < \sigma_2^2$

Code

```
var.test(group_1_data$Memory_Bandwidth, group_2_data$Memory_Bandwidth,
    alternative = "less")
```

Result

```
    F test to compare two variances

data: group_1_data$Memory_Bandwidth and
        group_2_data$Memory_Bandwidth
F = 0.82192, num df = 1546, denom df = 1253, p-value = 0.0001266
alternative hypothesis: true ratio of variances is less than
95 percent confidence interval:
 0.0000000 0.8977167
sample estimates:
ratio of variances
          0.8219164
```

Do p-value bé hơn mức ý nghĩa 1% nên ta bác bỏ H_0 và chấp nhận giả thuyết H_1. Có nghĩa là $\sigma_1^2 < \sigma_2^2$ hay nói cách khác $\sigma_1^2 \neq \sigma_2^2$.

Gọi μ_1 và μ_2 lần lượt là khả năng truyền tải bộ nhớ trung bình ở nhóm 1 và nhóm 2.

Giả thuyết:

- $H_0 : \mu_1 = \mu_2$
- $H_1 : \mu_1 < \mu_2$

Ta đã có được các số liệu thống kê:

$$n_1 = 1547, \quad \bar{x}_1 = 93.1873, \quad s_1 = 113.8026$$
$$n_2 = 1254, \quad \bar{x}_2 = 230.5746, \quad s_2 = 125.5273$$

Tính thống kê kiểm định và tìm miền bác bỏ:

Code

```
t0 <- (xtb1 - xtb2) / sqrt(s1^2 / n1 + s2^2 / n2)
df <- ((s1^2 / n1) + (s2^2 / n1))^2 / ((s1^2 / n1) / (n1 - 1) + (s2^2 / n1) / (n2 - 1))
qt_value <- qt(1 - 0.01, df = df)
c(t0 = t0, qt_value = qt_value)
```

Result

```
      t0 qt_value
-30.025323 2.326495
```

Miền bác bỏ:

$$RR = (-\infty; -2.3265)$$

Giá trị kiểm định:

$$t_0 = -30.0253$$

Vì $t_0 \in \mathbb{R}$, nên bác bỏ H_0 và chấp nhận H_1.

Kết luận: Khả năng truyền tải bộ nhớ ở nhóm 2 cao hơn ở nhóm 1 với mức ý nghĩa 1%.

5.3 Bài toán phân tích phương sai (Anova)

Mục tiêu: So sánh khả năng truyền tải bộ nhớ GPU ở các hãng (Manufacturer) và đánh giá yếu tố hãng có ảnh hưởng đến khả năng truyền tải bộ nhớ hay không?

Điều kiện thứ nhất: giả thuyết các mẫu phải độc lập và các biến phụ thuộc phải là biến liên tuc, ở đây ta có thể thấy mẫu được lấy ra trong file là độc lập

Điều kiện thứ hai: Các tổng thể có phân phối chuẩn, để thực hiện kiểm tra ta có thể sử dụng hình vẽ đồ thi qqplot hoặc dùng kiểm định Shapiro-Wilk, việc chạy kiểm định này cần sử dụng thư viện nortest với giả thuyết:

- H_0 : Khả năng truyền tải bộ nhớ tuân theo phân phối chuẩn.
- H_1 : Khả năng truyền tải bộ nhớ không tuân theo phân phối chuẩn

Điều kiện thứ ba: Phương sai các tổng thể bằng nhau, dùng thư viện car và câu lệnh leneveText() để kiểm tra với giả thuyết:

- $H_0 : \sigma_i^2 = \sigma_j^2$ (Phương sai của khả năng truyền tải bộ nhớ ở các hãng là như nhau)
- $H_1 : \exists \sigma_i^2 \neq \sigma_j^2$ (Có ít nhất 2 hãng có phương sai của khả năng truyền tải bộ nhớ là khác nhau)

Giả ~~định~~ thuyết của bài toán:

- $H_0 : \mu_1 = \mu_2 = \mu_3 = \cdots = \mu_k$ (Không có sự khác biệt trong khả năng truyền tải bộ nhớ giữa các hãng khác nhau)
- $H_1 : \exists \mu_i \neq \mu_j \quad (i \neq j)$ (Yếu tố hãng có tác động đến khả năng truyền tải bộ nhớ)

5.3.1 Kiểm tra điều kiện thứ hai cho dữ liệu của các hãng sản xuất

Hãng AMD

Code

```
AMD_data <- subset(selected_data,selected_data$Manufacturer=="AMD")
qqnorm(AMD_data$Memory_Bandwidth)
qqline(AMD_data$Memory_Bandwidth)
```

Result

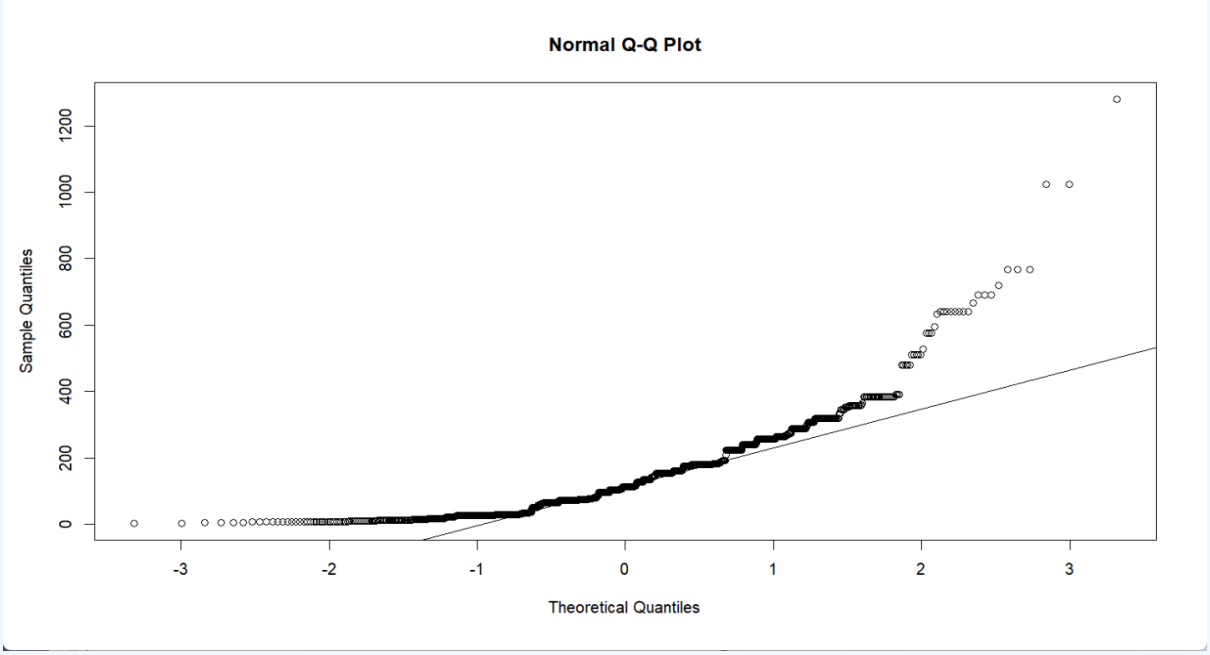

Code

```
shapiro.test(AMD_data$Memory_Bandwidth)
```

Result

```
    Shapiro-Wilk normality test

data: AMD_data$Memory_Bandwidth
W = 0.81461, p-value < 2.2e-16
```

Nhận xét: Vì *p-value* $< 2.2 \times 10^{-16}$ ($\ll 0.05$) nên ta đủ cơ sở để bác bỏ H_0, chấp nhận H_1, tức là khả năng truyền tải bộ nhớ của hãng AMD không tuân theo phân phối chuẩn.

Hãng ATI

Code

```
ATI_data <- subset(selected_data,selected_data$Manufacturer=="ATI")
qqnorm(ATI_data$Memory_Bandwidth)
qqline(ATI_data$Memory_Bandwidth)
```

Result

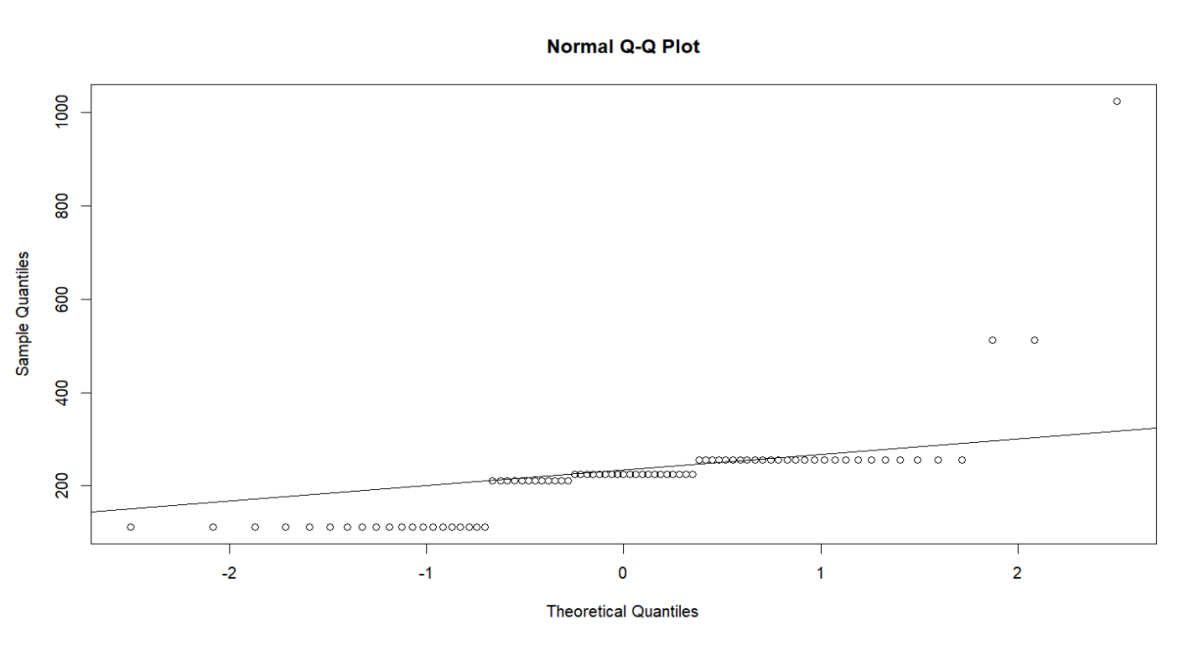

Code

```
shapiro.test(ATI_data$Memory_Bandwidth)
```

Result

```
        Shapiro-Wilk normality test

data: ATI_data$Memory_Bandwidth
W = 0.54984, p-value = 2.267e-14
```

Nhận xét: Vì $p\text{-}value = 2.267 \times 10^{-14}$ ($\ll 0.05$) nên ta đủ cơ sở để bác bỏ H_0, chấp nhận H_1, tức là khả năng truyền tải bộ nhớ của hãng ATI không tuân theo phân phối chuẩn.

Hãng Intel

Code

```
Intel_data <- subset(selected_data,selected_data$Manufacturer=="Intel")
qqnorm(Intel_data$Memory_Bandwidth)
qqline(Intel_data$Memory_Bandwidth)
```

Result

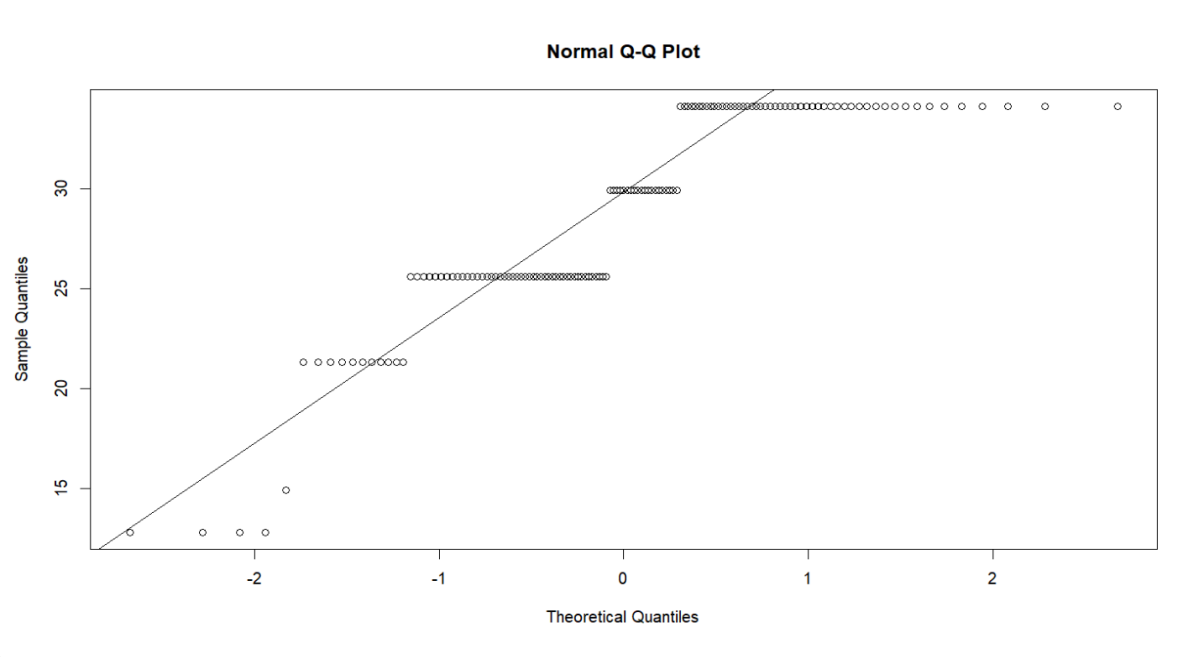

Code

```
shapiro.test(Intel_data$Memory_Bandwidth)
```

Result

```
    Shapiro-Wilk normality test

data: Intel_data$Memory_Bandwidth
W = 0.82927, p-value = 3.964e-11
```

Nhận xét: Vì *p-value* $= 3.964 \times 10^{-11}$ ($\ll 0.05$) nên ta đủ cơ sở để bác bỏ H_0, chấp nhận H_1, tức là khả năng truyền tải bộ nhớ của hãng Intel không tuân theo phân phối chuẩn.

Hãng Nvidia

Code

```
Nvidia_data <- subset(selected_data,selected_data$Manufacturer=="Nvidia")
qqnorm(Nvidia_data$Memory_Bandwidth)
qqline(Nvidia_data$Memory_Bandwidth)
```

Result

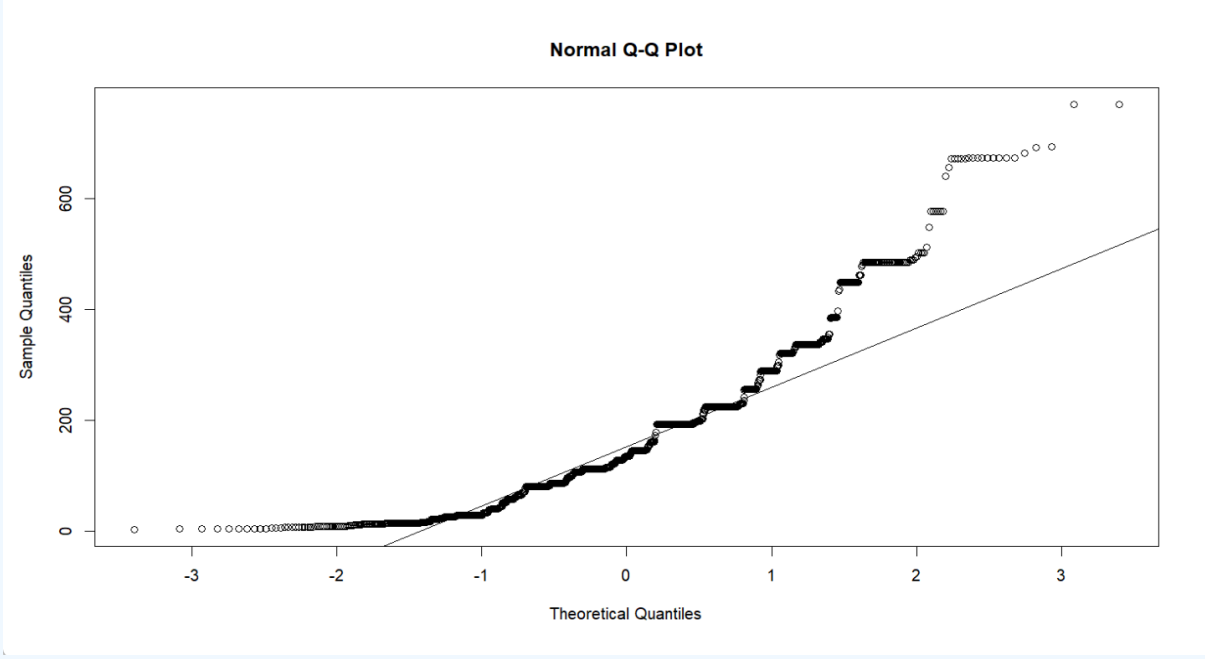

Code

```
shapiro.test(Nvidia_data$Memory_Bandwidth)
```

Result

```
    Shapiro-Wilk normality test

data: Nvidia_data$Memory_Bandwidth
W = 0.88592, p-value < 2.2e-16
```

Nhận xét: Vì *p-value* $< 2.2 \times 10^{-16}$ ($\ll 0.05$) nên ta đủ cơ sở để bác bỏ H_0, chấp nhận H_1, tức là khả năng truyền tải bộ nhớ của hãng Nvidia không tuân theo phân phối chuẩn.

5.3.2 Kiểm tra điều kiện thứ ba cho dữ liệu của các hãng sản xuất

Code

```
library(car)
leveneTest(Memory_Bandwidth~as.factor(Manufacturer), selected_data)
```

Result

```
    Levene's Test for Homogeneity of Variance (center = median)
    Df F value    Pr(>F)
group  3  44.548 < 2.2e-16 ***
    2797
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nhận xét: Vì $Pr < 2.2 \times 10^{-16}$ ($\ll 0.05$) nên ta đủ cơ sở để bác bỏ H_0, chấp nhận H_1, tức là Có ít nhất 2 hãng có phương sai của khả năng truyền tải bộ nhớ là khác nhau.

5.3.3 Thực hiện bài toán phân tích phương sai

Kết luận điều kiện của bài toán: Một số giả định không thỏa mãn để phân tích Anova. Tuy nhiên để tiếp tục thực hiện phân tích phương sai, ta giả sử rằng các giả định đều đúng để tìm hiểu xem là hãng nào có tốc độ truyền tải nhanh nhất.

Code

```
anova_model <- aov(Memory_Bandwidth~Manufacturer,selected_data)
summary(anova_model)
```

Result

```
    Df   Sum Sq Mean Sq F value Pr(>F)
Manufacturer    3  2854307  951436   53.24 <2e-16 ***
Residuals    2797 49984437   17871
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Nhận xét: $Pr < 53.24 \times 10^{-16}$ ($\ll 0.05$) nên khả năng truyền tải trung bình bộ nhớ ở các hãng là khác nhau. Để làm rõ hơn về sự khác nhau này, ta sử dụng thêm câu lệnh TukeyHSD và đồ thị plot().

Đặt giả định:

- $H_0 : \mu_i = \mu_j$ (Trung bình khả năng truyền tải bộ nhớ của 2 hãng bằng nhau)
- $H_1 : \mu_i \neq \mu_j$ (Trung bình khả năng truyền tải bộ nhớ của 2 hãng khác nhau)

Code

```
TuykeHSD(anova_model)
plot(TukeyHSD(anova_model))
```

Result

```
  Tukey multiple comparisons of means
  95% family-wise confidence level

Fit: aov(formula = Memory_Bandwidth ~ Manufacturer, data = selected_data)

$Manufacturer
                 diff        lwr        upr     p adj
ATI-AMD      75.66379   36.110711  115.21686 0.0000055
Intel-AMD  -117.35989 -148.894826  -85.82496 0.0000000
Nvidia-AMD   22.79226    9.138702   36.44583 0.0001081
Intel-ATI  -193.02368 -241.456558 -144.59080 0.0000000
Nvidia-ATI  -52.87152  -92.085187  -13.65786 0.0030118
Nvidia-Intel 140.15216 109.043997  171.26032 0.0000000
```

Result

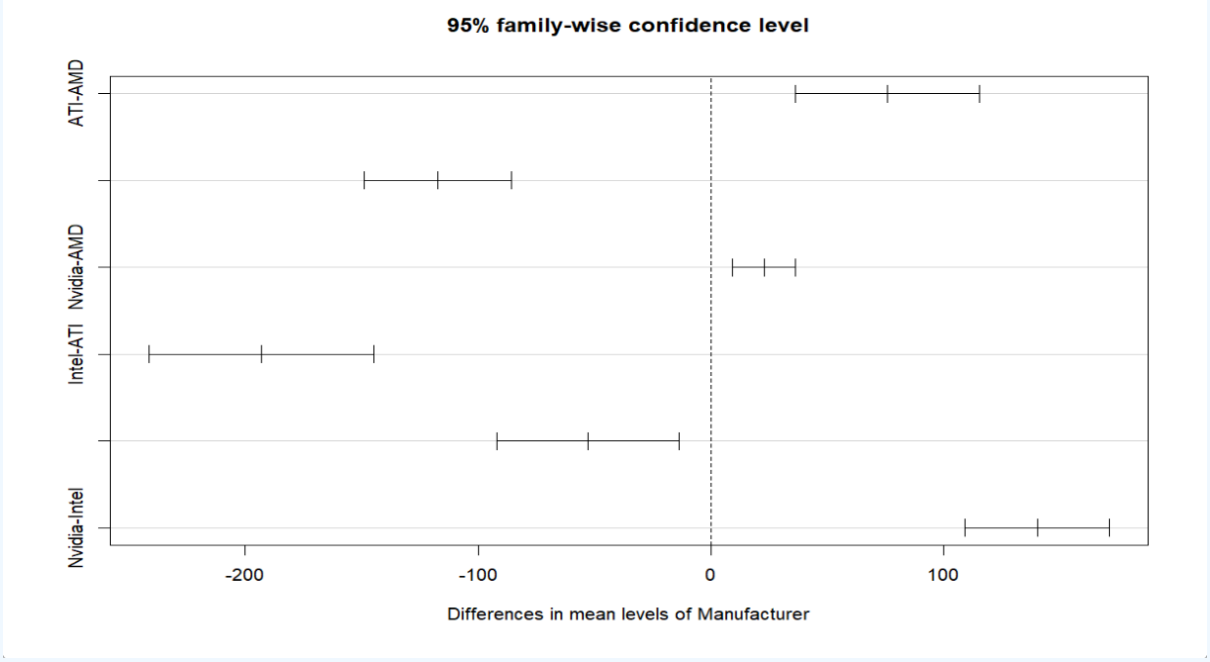

Nhận xét: Ta thấy tất cả các cặp nhóm ATI-AMD, Intel-AMD, Nvidia-AMD, Intel-ATI, Nvidia-ATI và Nvidia-Intel có giá trị p adj < 0.05 nên có sự khác nhau về khả năng truyền tải bộ nhớ có ý nghĩa thống kê. Mặt khác, giá trị diff của ATI-AMD lớn hơn 0; hoặc dựa vào đồ thị, ta có độ chệnh lệch về khả năng truyền tải bộ nhớ trung bình của hãng ATI so với hãng AMD nằm trong khoảng tin cậy $(36.1107, 115.2169)$, nên khả năng truyền tải bộ nhớ trung bình của ATI lớn hơn AMD ($\bar{x}_{ATI} > \bar{x}_{AMD}$). Còn đối với sự khác nhau về khả năng truyền tải bộ nhớ trung bình của cặp Intel-AMD, giá trị diff của Intel-AMD nhỏ 0; hoặc dựa vào đồ thị thì ta có độ chệnh lệch về khả năng truyền tải bộ nhớ trung bình của hãng Intel so với hãng AMD nằm trong khoảng tin cậy $(-148.8948, -85.8249)$, nên khả năng truyền tải bộ nhớ trung

bình của Intel nhỏ hơn AMD ($\bar{x}_{Intel} < \bar{x}_{AMD}$) Tương tự, với các cặp khác, ta có kết quả cuối cùng là $\bar{x}_{ATI} > \bar{x}_{Nvidia} > \bar{x}_{AMD} > \bar{x}_{Intel}$. Vậy khả năng truyền tải bộ nhớ trung bình của hãng ATI là nhanh nhất.

5.4 Bài toán hồi quy tuyến tính đa biến

Bài toán: Với mức ý nghĩa 5%, khả năng truyền tải bộ nhớ *Memory_Bandwidth* có liên quan đến các biến độc lập hay không ? Bên cạnh đó, bài toán còn dự đoán tác động của các biến đến *Memory_Bandwidth*.

- Biến phụ thuộc: *Memory_Bandwidth*
- Biến độc lập: *Manufacturer*, *Memory_Bus*, *Texture_Rate*, *Year*, *Memory_Speed*.

Ta chia bộ dữ liệu thành 2 phần gồm: *Train_data* (80%) dùng để chạy thực thi mô hình hồi quy và *Test_data* (20%) thực hiện dự báo.

Code

```
set.seed(1)
train_rows <- sample (rownames (new_data), dim(new_data) [1]*0.8)
train_data <- new_data[train_rows, ]
test_rows <- setdiff(rownames(new_data), train_rows)
test_data <- new_data[test_rows, ]
str(train_data)
str(test_data)
```

Result

```
> str(train_data)
'data.frame':   2240 obs. of 7 variables:
 $ Manufacturer    : chr  "AMD" "AMD" "Nvidia" "ATI" ...
 $ Memory_Bandwidth: num  9.6 179.2 12.6 512 96....
 $ Release_Date    : chr  "\n03-Apr-2014" "\n18-Jun-2015" "\n16-Sep-2011" "\n29-Jun-2016" ...
 $ Memory_Bus      : num  64 256 64 256 128 192 384 64 256 512...
 $ Texture_Rate    : num  5 62 5 365 60 22 216 6 21 358 ...
 $ Memory_speed    : num  600 1400 790 2000 1500 ...
 $ Year            : num  2014 2015 2011 2016 2013 ...
 - attr(*, "na.action")= 'omit' Named int [1:575] 10 13 15 17 18 21 22 27 70 71 ...
  ..- attr(*, "names")= chr [1:575] "10" "13" "15" "17" ...
> str(test_data)
'data.frame':   561 obs. of 7 variables:
 $ Manufacturer    : chr  "AMD" "Intel" "Intel" "Nvidia"...
 $ Memory_Bandwidth: num  35.2 34.1 29.9 3.2 2.7...
 $ Release_Date    : chr  "\n26-Jun-2007" "\n01-Sep-2015" "\n02-Jun-2015" "\n19-Feb-2002" ...
 $ Memory_Bus      : num  128 128 128 128 128 128 128 384 384 384 ...
 $ Texture_Rate    : num  688 1 1 9 9 452 220 196 ...
 $ Memory_Speed    : num  1100 1067 933 200 166 ...
 $ Year            : num  2007 2015 2015 2002 2002...
 - attr(*, "na.action")= 'omit' Named int [1:575] 10 13 15 17 18 21 22 27 70 71...
  ..- attr(*, "names")= chr [1:575] "10" "13" "15" "17" ...
```

Nhận xét: Sau khi chia bộ dữ liệu thành 2 phần ta thấy train_data có 2240 quan sát và test_data có 561 quan sát.

Xây dựng mô hình hồi quy tuyến tính dựa trên train_data

Code

```
regression <- lm(Memory_Bandwidth ~ Manufacturer + Memory_Bus + Texture_Rate +
    Year + Memory_Speed + Group, data = train_data)
summary(regression)
```

Result

```
Call:
lm(formula = Memory_Bandwidth ~ Manufacturer + Memory_Bus + Texture_Rate +
    Year + Memory_Speed + Group, data = train_data)

Residuals:
    Min      1Q  Median      3Q     Max
-319.46  -21.40   -3.86   18.33  270.42

Coefficients:
                        Estimate  Std. Error  t value   Pr(>|t|)
(Intercept)            1.443e+04  9.797e+02  14.725   < 2e-16 ***
ManufacturerATI       -3.700e+01  5.452e+00  -6.787   1.47e-11 ***
ManufacturerIntel     -3.313e-01  4.331e+00  -0.076   0.93903
ManufacturerNvidia -2.316e+01  1.831e+00 -12.646   < 2e-16 ***
Memory_Bus             8.461e-02  3.193e-03  26.497   < 2e-16 ***
Texture_Rate           1.374e+00  1.270e-02  108.179  < 2e-16 ***
Year                  -7.177e+00  4.880e-01  -14.709  < 2e-16 ***
Memory_Speed           4.036e-02  4.565e-03   8.841   < 2e-16 ***
GroupGroup_2          -8.898e+00  3.217e+00  -2.766   0.00572 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 39.89 on 2231 degrees of freedom
Multiple R-squared:  0.9196, Adjusted R-squared:  0.9193
F-statistic:  3188 on 8 and 2231 DF,  p-value: < 2.2e-16
```

Nhận xét:

- Với tứ phân vị thứ nhất, trung vị, tứ phân vị thứ ba lần lượt là -21.40, -3.86, 18.33.
- RSE $\approx$ 39.89, là giá trị biểu thị sai số trung bình.
- Trong phần Coefficients (hệ số), Estimate sẽ cho ta biết được phương trình ước lượng:

$$\hat{y} = 1.443{\cdot}10^4 - 3.700{\cdot}10X_1 - 3.313{\cdot}10^{-1}X_2 - 2.316{\cdot}10X_3 + 8.461{\cdot}10^{-2}X_4 + 1.374X_5 - 7.177X_6 + 4.036{\cdot}10^{-}$$

- Hệ số xác định R^2 hiệu chỉnh là 0.9193 chứng tỏ rằng mô hình rất tốt, quan hệ giữa Y và các biến X có quan hệ tuyến tính tốt. Hệ số này có ý nghĩa rằng: Trong 100% những nguyên nhân gây ra sự biến động của khả năng truyền tải bộ nhớ thì chỉ có 91.93% nguyên nhân được giải thích là do các biến độc lập đang xét trong mô hình gây ra. Còn 8.07% khác là do những biến dữ liệu khác chưa đưa vào mô hình, chưa xét tới hoặc là do thành phần sai số gây ra.

Kiểm định các hệ số hồi quy

- $H_0 : \beta_i = 0$ (~~hệ số không ảnh hưởng đến khả năng truyền tải bộ nhớ~~).
- $H_1 : \beta_i \neq 0$ (~~hệ số ảnh hưởng đến khả năng truyền tải bộ nhớ~~).

Dựa vào *p-value*, ta thấy ManufacturerIntel có *p-value* $> \alpha$ nên ta chưa thể nào bác bỏ $H_0 : \beta_2 = 0$, hay nói cách khác là ManufacturerIntel không ảnh hưởng đến khả năng truyền tải bộ nhớ ($\beta_2 = 0$).

Dựa vào *t-value* (thống kê kiểm định), ta có:

$$t\text{-value} = \frac{\hat{\beta}_i}{\text{SE}_{\hat{\beta}_i}} = \frac{\text{Estimate}}{\text{Std.Error}}$$

Ta có $t_{\frac{\alpha}{2};n-k-1} = t_{0.025;2794} \approx z_{0.025} = 1.96$.

Miền bác bỏ: $RR = (-\infty; -1.96) \cup (1.96; +\infty)$.

Ta thấy ManufacturerIntel có $t_2 \in RR$ nên ta chưa thể nào bác bỏ $H_0 : \beta_2 = 0$, hay nói cách khác là ManufacturerIntel không ảnh hưởng đến khả năng truyền tải bộ nhớ với mức ý nghĩa 5%.

Xây dựng mô hình loại bỏ biến Memory_Speed, Group và Memory_Bus.

Code

```
regression_2 <- lm(Memory_Bandwidth ~ Manufacturer +
                   Texture_Rate + Year, data = train_data)
summary(regression_2)
```

Tuy nhiên - ✓

Result

```
Call:
lm(formula = Memory_Bandwidth ~ Manufacturer + Texture_Rate +
    Year, data = train_data)

Residuals:
    Min      1Q  Median      3Q     Max
-373.38  -25.37   -4.39   21.44  625.18

Coefficients:
                        Estimate  Std. Error  t value   Pr(>|t|)
(Intercept)             1.208e+04  9.344e+02  12.931  < 2e-16 ***
ManufacturerATI        -2.240e+01  6.191e+00  -3.618   0.000304 ***
ManufacturerIntel      -8.610e+00  4.838e+00  -1.780   0.075287 .
ManufacturerNvidia     -2.542e+01  2.078e+00 -12.231  < 2e-16 ***
Texture_Rate            1.519e+00  1.254e-02  121.115  < 2e-16 ***
Year                   -5.987e+00  4.645e-01 -12.890  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 45.9 on 2234 degrees of freedom
Multiple R-squared:  0.8933, Adjusted R-squared:  0.8931
F-statistic:  3742 on 5 and 2234 DF,  p-value: < 2.2e-16
```

Nhận xét:

- Với tứ phân vị thứ nhất, trung vị, tứ phân vị thứ ba lần lượt là -25.80, -4.39, 21.44.
- RSE $\approx$ 45.9, là giá trị biểu thị sai số trung bình.
- Trong phần Coefficients (hệ số), Estimate sẽ cho ta biết được phương trình ước lượng:

$$\hat{y} = 1.208 \cdot 10^4 - 2.240 \cdot 10X_1 - 8.610X_2 - 2.542 \cdot 10X_3 - 1.519X_4 - 5.987X_5$$

Tiến hành so sánh hiệu quả hai mô hình regression và regression_2 với giả thuyết:

- H_0: mô hình regression_2 hiệu quả hơn.
- H_1: mô hình regression hiệu quả hơn.

Code

```
anova(regression_2, regression)
```

Result

```
Analysis of Variance Table

Model 1: Memory_Bandwidth ~ Manufacturer + Texture_Rate + Year
Model 2: Memory_Bandwidth ~ Manufacturer + Memory_Bus + Texture_Rate +
    Year + Memory_Speed + Group
  Res.Df     RSS Df Sum of Sq      F    Pr(>F)
1   2234 4706076
2   2231 3549232  3   1156844 242.39 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Nhận xét:

Dựa vào *p-value*, ta thấy *p-value* bé hơn α nên ta bác bỏ H_0, chấp nhận H_1, hay nói cách khác mô hình regression hiệu quả hơn. Giá trị R^2 hiệu chỉnh của regression (0.9193) lớn hơn regression_2 (0.8931), nên mô hình regression sẽ có hiệu quả cao hơn mô hình regression_2.

Ta có các giả định trong mô hình hồi quy như sau:

- Y và các biến độc lập X có quan hệ tuyến tính.
- Các sai số độc lập với nhau.
- Sai số có phân phối chuẩn với kỳ vọng bằng 0, phương sai không đổi.

Ta kiểm tra tiếp bằng đồ thị plot().

Code

```
plot(lm_model)
```

Result

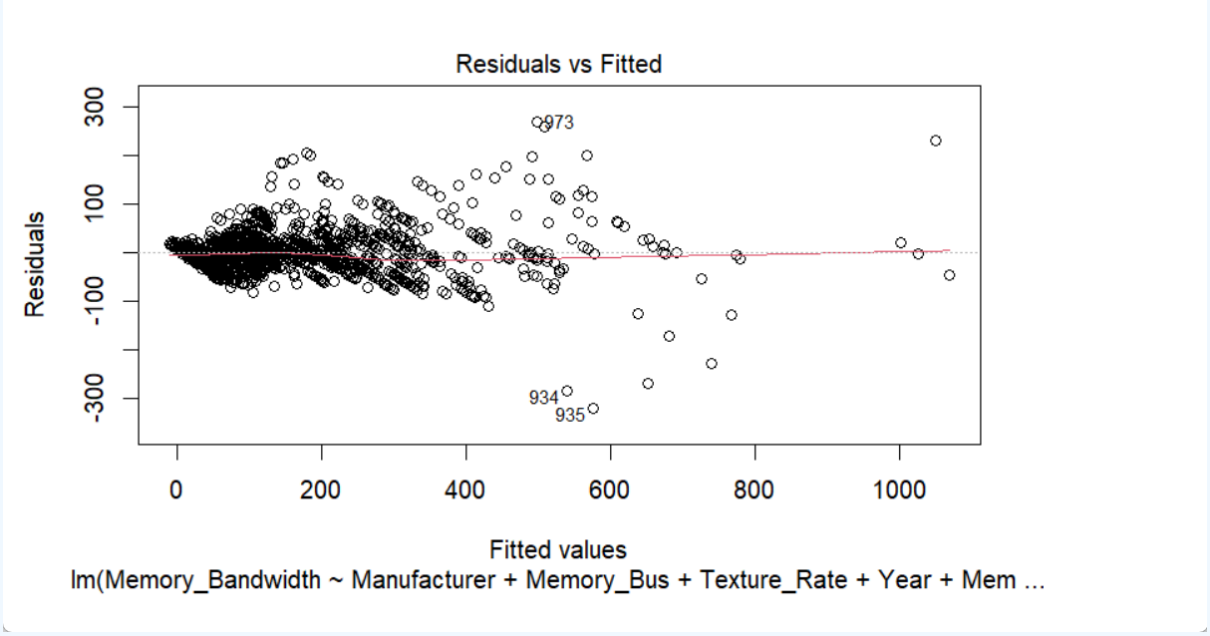

Nhận xét sự tuyến tính của dữ liệu qua đồ thị Residuals vs Fitted:

Dựa vào đồ thị Residuals vs Fitted, ta có thể đánh giá các giả định của mô hình hồi quy như sau:

- Y và các biến độc lập X có quan hệ tuyến tính: Đường màu đỏ chưa thực sự là đường thẳng nằm ngang, nên giả định Y và các biến độc lập X có quan hệ tuyến tính chưa thực sự thoả mãn.
- Sai số có kỳ vọng bằng 0: Đường màu đỏ nằm khá sát đường $y = 0$, nên ta tạm chấp nhận giả định sai số có kỳ vọng bằng 0 thoả mãn.
- Phương sai các sai số là hằng số: Các giá trị sai số chưa phân tán ngẫu nhiên dọc theo đường màu đỏ, nên giả định phương sai các sai số là hằng số chưa thực sự thoả mãn.

Result

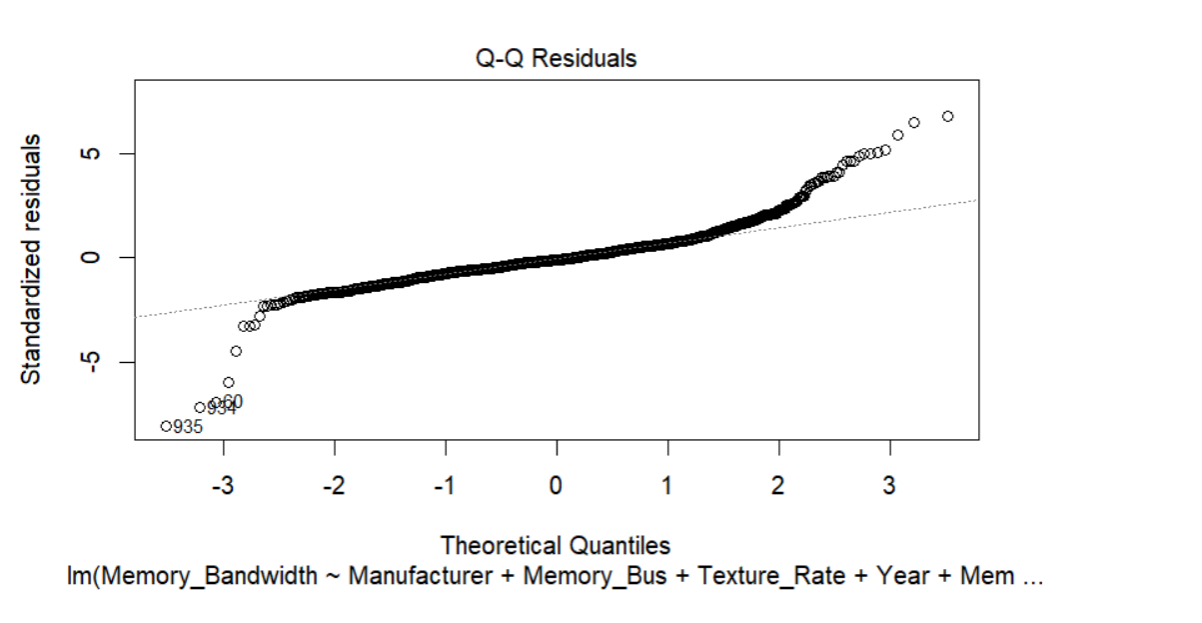

Nhận xét: Ta nhận thấy các giá trị thặng dư tập trung theo những đường thẳng, nhưng ở khoảng đầu và cuối có nhiều giá trị lệch ra khỏi đường thẳng. Điều đó cho thấy rằng giả định phân phối chuẩn của các sai số vẫn chưa được đáp ứng.

Result

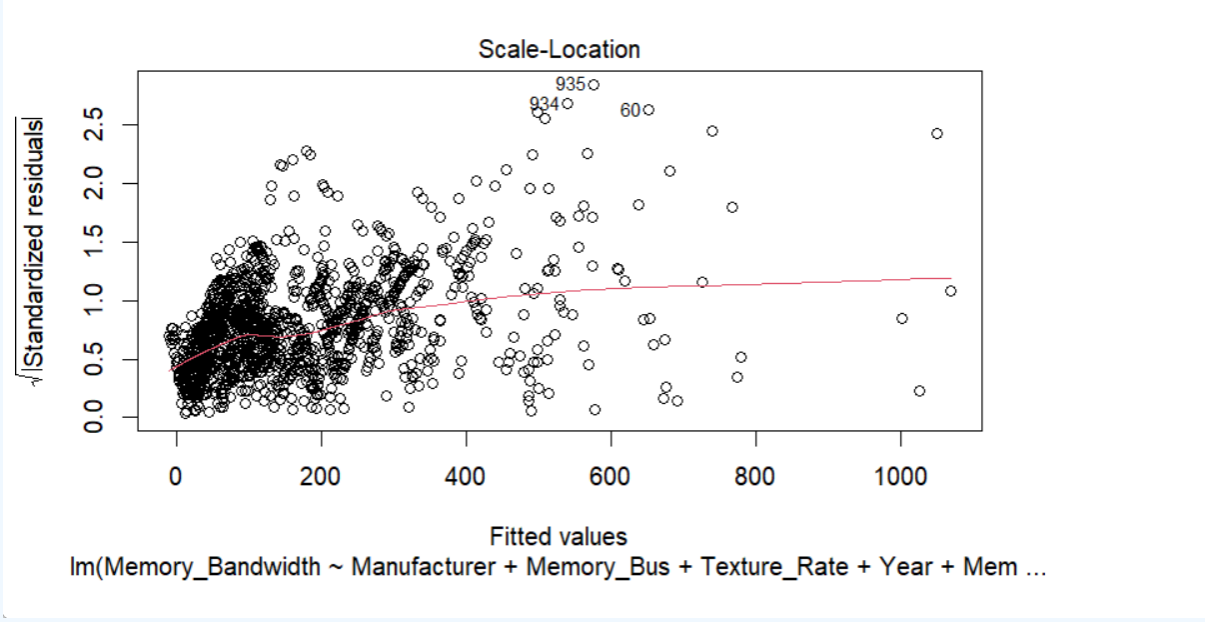

Nhận xét: Đồ thị Scale – Location về căn bậc hai của các giá trị thặng dư được chuẩn hóa với các giá trị dự báo, được dùng để kiểm tra phương sai của các sai số là hằng số hay không. Vì đường màu đỏ có độ dốc (cong) trên đường thẳng này nên giả định Phương sai các sai số là

hằng số chưa thực sự thoả mãn.

Result

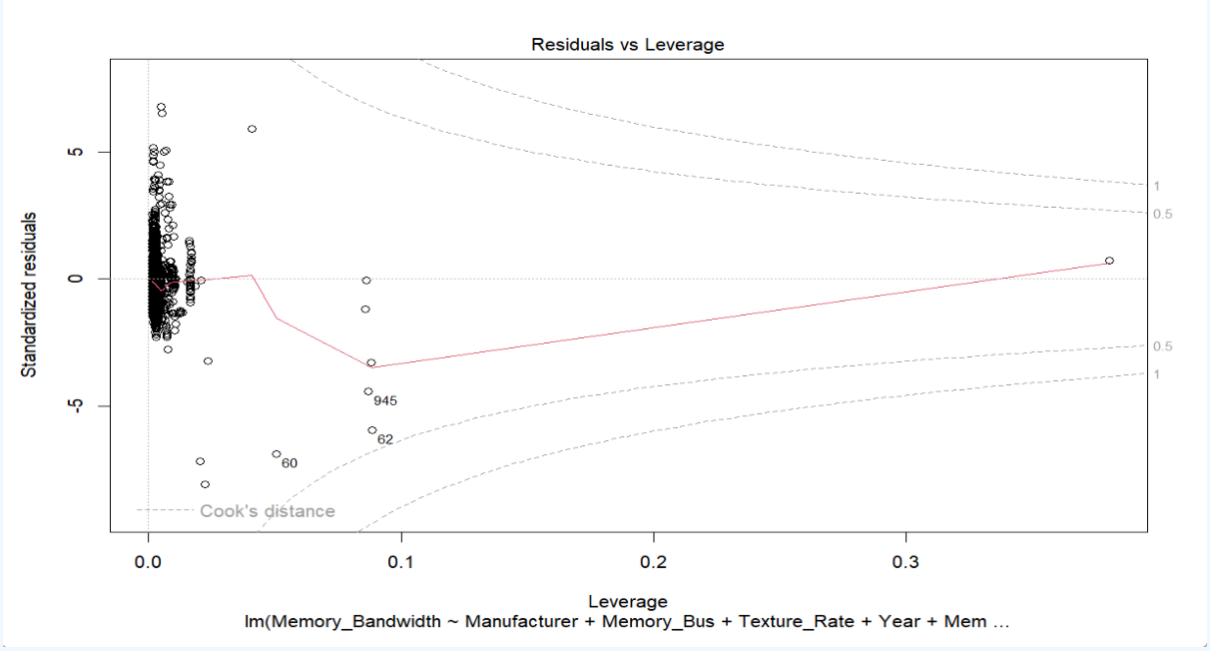

Nhận xét: Đồ thị *Residuals vs Leverage* cho phép xác định những điểm có ảnh hưởng cao, nếu chúng có hiện diện trong bộ dữ liệu. Những điểm có ảnh hưởng cao, cụ thể là 60, 62, 950 là những điểm có thể gây nhiều ảnh hưởng nhất khi phân tích dữ liệu. Tuy nhiên đồ thị không thấy đường Cook's distance và các điểm này không vượt qua khỏi đường Cook. Đồ thị thứ 4 chỉ ra không có điểm nào thực sự ảnh hưởng cao vì không vượt qua Cook's distance.

Thực hiện dự báo dựa trên *test_ data*: Ta có phương trình ước lượng:

$$\hat{y} = 1.208 \cdot 10^4 - 2.240 \cdot 10X_1 - 8.610X_2 - 2.542 \cdot 10X_3 - 1.519X_4 - 5.987X_5$$

Code

```
test_data$Predicted_Memory_Bandwidth <- predict(regression_2, test_data)
```

Result

Filter

	Manufacturer	Memory_Bandwidth	Release_Date	Memory_Bus	Texture_Rate	Memory_Speed	Year	Group	Predicted_Memory_Bandwidth
6	AMD	35.2	26-Jun-2007	128	6	1100	2007	Group_1	75.66698
28	Intel	34.1	01-Sep-2015	128	8	1067	2015	Group_1	22.19679
32	Intel	29.9	02-Jun-2015	128	8	933	2015	Group_1	22.19679
33	Nvidia	3.2	19-Feb-2002	128	1	200	2002	Group_1	72.58879
38	Nvidia	2.7	19-Feb-2002	128	1	166	2002	Group_1	72.58879
39	Intel	34.1	01-Sep-2015	128	9	1067	2015	Group_1	23.71556
41	Intel	29.9	02-Jun-2015	128	9	933	2015	Group_1	23.71556
51	Nvidia	672.0	28-May-2014	384	452	1750	2014	Group_2	685.70766
58	Nvidia	288.4	15-May-2013	384	220	1502	2013	Group_2	339.34019
65	Nvidia	288.4	19-Feb-2013	384	196	1502	2013	Group_2	302.88971
67	AMD	28.8	01-Mar-2013	128	46	900	2013	Group_1	100.49455
99	AMD	320.0	26-Mar-2014	512	164	1250	2014	Group_1	273.72223
117	AMD	264.0	01-Aug-2014	384	101	1375	2014	Group_2	178.03971
123	AMD	28.8	01-Feb-2012	128	16	900	2012	Group_1	60.91866

Code

```
new_value <- data.frame(Manufacturer = "AMD", Memory_Speed = 940,
Year = 2025, Memory_Bus = 512, Texture_Rate = 234)
predict(regression_2, new_value, interval = "confidence")
```

Result

```
       fit     lwr      upr
1 314.1769 303.745 324.6087
```

Nhận xét:

Khả năng truyền tải bộ nhớ trung bình với hãng AMD đến năm 2025 là 314.1769. Khoảng tin cậy 95% cho tốc độ truyền tải bộ nhớ trung bình dự báo: $(303, 324)$.

KẾT LUẬN

Những hạn chế của phương pháp thống kê mô tả

- Thiếu khả năng suy luận: Phương pháp thống kê mô tả không thể đưa ra kết luận về mối quan hệ nguyên nhân và kế giữa các biến số. Nó chỉ mô tả dữ liệu mà không giải thích được nguyên nhân của sự biến đổi.
- Khó khăn trong việc mô tả mối liên quan phức tạp: Nếu có mối liên quan phức tạp giữa các biến, thống kê mô tả có thể không đủ mạnh mẽ để mô tả mối liên quan này một cách rõ ràng.
- Khả năng ảnh hưởng của giá trị ngoại lai: Dữ liệu thống kê mô tả có thể bị ảnh hưởng bởi giá trị ngoại lai mà không có cơ hội xác định và xử lý chúng một cách cụ thể.

Những hạn chế của phương pháp thống kê suy diễn

- Phụ thuộc vào mẫu: Kết quả thống kê suy diễn phụ thuộc nhiều vào việc lựa chọn mẫu. Nếu mẫu không đại diện cho quần thể rộng hơn, thì kết quả có thể không có tính khái quát và không áp dụng được cho toàn bộ.
- Khó khăn trong việc hiểu và trình bày kết quả: Kết quả của phương pháp thống kê suy diễn thường phức tạp và khó hiểu, đặc biệt là đối với những người không chuyên bộ môn thống kê.
- Nhạy cảm với giá trị ngoại lai: Dữ liệu thống kê suy diễn có thể bị ảnh hưởng bởi giá trị ngoại lai, và kết quả có thể biến đổi nếu không có biện pháp đặc biệt để xử lý những giá trị này.

Nhìn chung, khi chúng ta kết hợp cả hai phương pháp trên lại với nhau thì sẽ cho ra cái nhìn tổng thể về kết quả toàn diện hơn, đặc biệt là trong việc nghiên cứu và tìm hiểu về bản chất của dữ liệu tìm được trong lĩnh vực nghiên cứu. Khi hiểu rõ được các yếu tố ảnh hưởng đến khả năng truyền tải bộ nhớ, chúng ta có thể cải thiện và nâng cao chất lượng trong quá trình sử dụng. Thông qua việc dự báo để tìm ra những cách hay tìm được những thông số kỹ thuật tốt nhất và hiệu quả nhất để có thể hoạt động mạnh mẽ.

6 Nguồn dữ liệu và nguồn code

- Nguồn dữ liệu được lấy từ: data.

TÀI LIỆU THAM KHẢO

Tài liệu

[1] V.T. Nguyễn, *Phân tích dữ liệu với R*, Nhà xuất bản Tổng hợp Thành phố HCM, 2014.

[2] T. Tran, *Lập trình R: tự học lập trình R từ cơ bản đến nâng cao*, Nhà xuất bản Đại học sư phạm HCM, 2019.

[3] Nguyễn Đình Huy, *BÀI TẬP XÁC SUẤT THỐNG KÊ*, NHÀ XUẤT BẢN ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH, 2023.

[4] Nguyễn Đình Huy, *GIÁO TRÌNH XÁC SUẤT VÀ THỐNG KÊ*, NHÀ XUẤT BẢN ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH, 2023.