TRƯỜNG ĐẠI HỌC BÁCH KHOA TP HỒ CHÍ MINH

BÀI TẬP LỚN MÔN XÁC SUẤT THỐNG KÊ

NHÓM : DD19

NGÀY NỘP : 10/12/2023

Giảng viên hướng dẫn: Nguyễn Kiều Dung

STT	Họ và tên	MSSV	Tên lớp	Tên khoa/ ngành
1	**Nguyễn Thanh Nguyên**	**2212324**	L06	Điện - Điện tử
2	Trần Nghĩa	2212241	L06	Điện - Điện tử
3	Ngô Văn Nguyên	2212301	L04	Điện - Điện tử
4	Nguyễn Đức Nghĩa	2212227	L06	Điện - Điện tử
5	Nguyễn Minh Dạ Thảo	2213163	L01	Điện - Điện tử

Thành phố Hồ Chí Minh – 2023

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BACHKHOACNCP.COM

BỘ MÔN KHOA HỌC ỨNG DỤNG

BÁO CÁO PHÂN CÔNG NHIỆM VỤ VÀ KẾT QUẢ THỰC HIỆN ĐỀ TÀI CỦA NHÓM: DD19

Môn **:XÁC XUẤT THỐNG KÊ**

STT	Họ và tên	MSSV	Kết quả	Chữ ký
1	**Nguyễn Thanh Nguyên**	**2212324**	Đã hoàn thành 100%	
2	Trần Nghĩa	2212241	Đã hoàn thành 100%	
3	Ngô Văn Nguyên	2212301	Đã hoàn thành 100%	
4	Nguyễn Đức Nghĩa	2212227	Đã hoàn thành 100%	
5	Nguyễn Minh Dạ Thảo	2213163	Đã hoàn thành 100%	

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

MỤC LỤC

PHẦN MỞ ĐẦU 1
I. NHIỆM VỤ CỦA ĐỀ TÀI 1
II. TỔNG QUAN DỮ LIỆU 2
III. KIẾN THỨC NỀN: 4
PHẦN NỘI DUNG 9
CHƯƠNG I: KIỂM ĐỊNH 1 MẪU 9
❖ Khái niệm 9
❖ Quy tắc kiểm định 10
CHƯƠNG 2: KIỂM ĐỊNH 2 MẪU 17
❖ Kiểm định tỉ lệ 2 mẫu: 17
❖ Kiểm định trung bình 2 mẫu 17
CHƯƠNG 3: ANOVA 21
❖ Định nghĩa phân tích phương sai: 21
❖ Bài toán phân tích phương sai (phân tích Anova) 21
❖ Giả định ANOVA: 23
CHƯƠNG 4: HỒI QUY 25
❖ Phân tích hồi quy: 25
❖ Giả định hồi quy 27
CHƯƠNG 5: XỬ LÝ VÀ TÍNH TOÁN SỐ LIỆU 28
❖ Xử lý dữ liệu 28
❖ Thống kê mô tả 33
❖ Các ví dụ bài toán 42
PHẦN KẾT LUẬN 70

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

VỀ XỬ LÝ SỐ LIỆU 70
CODE R 72
❖ Xử lý số liệu 72
❖ Thống kê mô tả 75
TÀI LIỆU THAM KHẢO 84

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

PHẦN MỞ ĐẦU

I. Nhiệm vụ của đề tài

Trong thế giới ngày càng phát triển của thương mại điện tử, việc hiểu rõ hành vi

và sự hài lòng của khách hàng trở nên cực kỳ quan trọng. Điều này đặc biệt đúng trong ngành điện tử, nơi mà sự cạnh tranh giữa các nhà bán lẻ là khốc liệt. Trong báo cáo này, chúng tôi sẽ khám phá một bộ dữ liệu giao dịch bán lẻ từ một cửa hàng điện tử, với mục tiêu là xác định liệu một khách hàng có hài lòng với đơn hàng cuối cùng của họ hay không.

1. Giới thiệu dữ liệu: Dữ liệu được thu thập từ cửa hàng điện tử và bao gồm thông tin về các giao dịch. Các nhân tố trong dữ liệu có thể bao gồm ID giao dịch, ngày giao dịch, sản

phẩm được mua, số lượng, giá, và thông tin khách hàng.

2. Rà soát và làm sạch dữ liệu: Chúng ta sẽ kiểm tra dữ liệu bị thiếu và giá trị không hợp lệ. Điều này có thể bao gồm việc kiểm tra các giá trị NA, kiểm tra sự nhất quán của dữ liệu (ví dụ: đảm bảo rằng tất cả các giá trị ngày đều ở định dạng đúng), và xử lý các

giá trị ngoại lệ.

3. Thống kê mô tả: Chúng ta sẽ sử dụng biểu đồ tần số, biểu đồ hộp, và biểu đồ phân tán để hiểu rõ hơn về dữ liệu. Chúng ta cũng sẽ tính toán các đặc trưng mẫu như trung bình, trung vị, và phương sai.

4. Xác định mục tiêu bài báo cáo và phương pháp thống kê: Mục tiêu của bài báo cáo có thể là hiểu rõ hơn về hành vi mua hàng của khách hàng, hoặc dự đoán doanh số trong tương lai. Phương pháp thống kê phụ thuộc vào mục tiêu này, nhưng có thể bao gồm phân tích hồi quy, phân tích thời gian, hoặc phân tích phân loại.

5. Nội dung phân tích thống kê: Chúng ta sẽ trình bày phương pháp thống kê được sử dụng, code R, kết quả từ R, và thảo luận trên kết quả nhận được. Kết luận sẽ tóm tắt những gì chúng ta đã học từ phân tích.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

II. Tổng quan dữ liệu

a. Ngữ quan dữ liệu:

Dữ liệu ngữ quan từ cửa hàng điện tử trực tuyến cung cấp một cái nhìn toàn diện về hoạt động kinh doanh trong năm 2019, tập trung vào ba kho hàng là các trung tâm quan trọng. Qua hệ thống này, hàng hóa được vận chuyển đến khách hàng, và bảng dữ liệu cung cấp thông tin chi tiết về mỗi kho. Ngoài ra, hai bảng dữ liệu khác chứa thông tin về "missing_data" và "dirty_data".

Từ những dữ liệu này, chúng ta có thể tiến hành phân tích sâu rộng về mô hình kinh doanh, đồng thời phát hiện cơ hội mới và xây dựng chiến lược phát triển dựa trên thông tin chi tiết về sản phẩm và khách hàng. Việc này không chỉ giúp chúng ta hiểu rõ hơn về xu hướng mua sắm và sở thích của khách hàng, mà còn tạo ra nền tảng để đưa ra các quyết định chiến lược mạnh mẽ nhằm phát triển cửa hàng trong tương lai.

Bằng cách này, chúng ta có thể tận dụng dữ liệu để xây dựng chiến lược kinh doanh thông minh, tập trung vào việc cải thiện trải nghiệm mua sắm của khách hàng và tối ưu hóa quy trình vận chuyển. Sự hiểu biết sâu rộng về các mặt hàng và quy trình kinh doanh sẽ giúp chúng ta đưa ra quyết định thông minh, đồng thời tận dụng những cơ hội chiến lược để định hình tương lai phát triển của cửa hàng điện tử trực tuyến.

b. Giá trị quan trắc:

Trong lĩnh vực thống kê mua bán hàng hóa, "giá trị quan trắc" (observed value) thường là giá trị thực tế được đo lường hoặc quan sát trong quá trình thử nghiệm, nghiên cứu hoặc ghi nhận dữ liệu. Nó thường được so sánh với giá trị kỳ vọng hoặc giá trị lý thuyết để phân tích sự chênh lệch giữa thực tế và dự đoán.

Trong môi trường mua bán hàng hóa, có hai loại giá trị quan trắc quan trọng:

+ Giá trị thị trường (Market Value): Đây là giá trị mà một sản phẩm hoặc hàng hóa có thể được bán trên thị trường tại một thời điểm cụ thể. Điều này có thể bao gồm giá bán lẻ cho người tiêu dùng hoặc giá bán buôn cho các đối tác kinh doanh. Giá trị thị trường thường phản ánh sự biến động của nhu cầu và cung cấp trên thị trường.

+ Giá trị sổ sách (Book Value): Là giá trị mà một sản phẩm hoặc hàng hóa được ghi nhận trong sổ sách tài chính của một doanh nghiệp. Thông thường, giá trị này dựa trên giá trị gốc và có thể điều chỉnh theo thời gian để phản ánh sự mất giá hoặc giảm giá trị của sản phẩm theo thời gian. Giá trị sổ sách là một chỉ số quan trọng trong việc đánh giá tình hình tài chính và giá trị tài sản của doanh nghiệp.

Trong bảng dữ liệu, có 7 giá trị quan trắc gồm order_id (mã đơn hàng), customer_id (mã khách hàng), order_price (giá đặt hàng), delivery_charges (phí

BACHKHOACNCP.COM

vận chuyển), coupon_discount (vé giảm giá), order_total (tổng đơn đặt hàng), distance_to_nearest_warehouse (khoảng cách đến nhà kho gần nhất). Các giá trị này sẽ giúp chúng ta phân tích và đánh giá các khía cạnh khác nhau của giao dịch và hoạt động kinh doanh.

c. <u>Cách thu thập:</u>

Chủ đề: Bộ dữ liệu "dirty_data.csv" là bộ dữ liệu chứa thông tin về một cửa hàng điện tử trực tuyến. Cửa hàng có ba kho để giao hàng cho khách hàng.

Dữ liệu gốc được cung cấp tại:
https://www.kaggle.com/datasets/muhammadshahrayar/transactional-retail-dataset-of-electronics-store?select=dirty_data.csv

Bộ dữ liệu gồm các biến chính sau:

• **order_id:** ID cho mỗi đơn hàng.

• **customer_id:** Id cho mỗi khách hàng.

• **date:** Ngày đặt hàng định dạng YYYY-MM-DD.

• **nearest_warehouse:** Tên kho gần khách hàng nhất.

• **shopping_cart:** Mặt hàng và số lượng được đặt.

• **order_price:** Đơn giá của mặt hàng (USD).

• **delivery_charges:** Phí vận chuyển đơn hàng.

• **customer_lat:** Vĩ độ vị trí của khách hàng.

• **customer_long:** Kinh độ vị trí của khách hàng.

• **coupon_discount:** Phiếu giảm giá (%).

• **order_total:** Tổng tiền đơn hàng.

• **season:** Mùa khách đặt hàng

• **is_expedited_delivery:** Khách hàng có yêu cầu giao hàng nhanh hay không.

• **distance_to_nearest_warehouse:** Khoảng cách giữa khách hàng và nhà kho gần nhất (km).

• **latest_customer_review:** Đánh giá của khách hàng về đơn hàng gần nhất.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

• **is_happy_customer:** Đánh giá mức độ hài lòng của khách hàng.

Trong bộ dữ liệu này, để khảo sát xem khách hàng có hài lòng với đơn hàng cuối cùng của họ không. Chúng em quan tâm đến biến **is_happy_customer** với đây là một biến định tính (gồm 2 giá trị True/False). Trong bài báo cáo, chúng em sử dụng kiểm định 1 mẫu, kiểm định 2 mẫu, anova 1 yếu tố và hồi quy tuyến tính đơn để hoàn thành yêu cầu đề bài.

III. Kiến thức nền:

1. Exploratory data analysis (EDA)

1.1 Khái niệm

Phân tích dữ liệu khám phá (EDA) là một thuật ngữ để chỉ một số loại phân tích và phát hiện ban đầu được thực hiện với các tập dữ liệu, thường là ở giai đoạn đầu của một quá trình phân tích.

Được phát triển bởi John Tukey vào những năm 1970, phân tích dữ liệu khám phá thường được mô tả như một triết lý và không có quy tắc khó và nhanh nào cho cách bạn tiếp cận nó. Điều đó nói rằng, nó cũng đã tạo ra cả một môi trường điện toán thống kê cả được sử dụng để giúp xác định EDA là gì và để giải quyết các nhiệm vụ cụ thể như:

- Phát hiện lỗi và thiếu dữ liệu.
- Vẽ sơ đồ cấu trúc cơ bản của dữ liệu.
- Xác định các biến quan trọng nhất.
- Liệt kê dị thường và ngoại lệ.
- Kiểm tra một giả thuyết / kiểm tra các giả định liên quan đến một mô hình cụ thể.
- Thiết lập một mô hình tuyệt vời (một mô hình có thể được sử dụng để giải thích dữ liệu với các biến dự đoán tối thiểu).
- Ước tính các tham số và tìm ra các khoảng tin cậy hoặc biên độ sai số liên quan.

Phân tích dữ liệu khám phá (EDA) là quá trình phân tích và trực quan hóa dữ liệu để hiểu rõ hơn về dữ liệu và thu thập thông tin chi tiết từ đó. Có nhiều bước liên quan khi thực hiện EDA nhưng sau đây là các bước phổ biến mà nhà phân tích dữ liệu có thể thực hiện khi thực hiện EDA:

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

- Nhập dữ liệu
- Làm sạch dữ liệu
- Xử lý dữ liệu
- Trực quan hóa dữ liệu

1.2. Các loại phân tích dữ liệu thăm dò EDA

Có bốn loại chính

- **Đơn biến phi đồ họa.** Đây là hình thức phân tích dữ liệu đơn giản nhất, trong đó dữ liệu được phân tích chỉ bao gồm một biến. Vì nó là một biến duy nhất nên nó không giải quyết được nguyên nhân hoặc mối quan hệ. Mục đích chính của phân tích đơn biến là mô tả dữ liệu và tìm ra các mẫu tồn tại trong đó.
- **Đồ họa đơn biến**. Các phương pháp phi đồ họa không cung cấp bức tranh đầy đủ về dữ liệu. Do đó cần phải sử dụng các phương pháp đồ họa. Các loại đồ họa đơn biến phổ biến bao gồm:

+Biểu đồ tần số (histogram): Đồ thị cơ bản nhất là biểu đồ tần số. Biểu đồ cột trong đó mỗi cột đại diện cho tần suất (số lượng) hoặc tỷ lệ (số lượng/tổng số lượng) của các trường hợp cho một phạm vi giá trị. Biểu đồ tần số là một trong những cách đơn giản nhất để tìm hiểu về dữ liệu như: trung bình, phân tán, đa chủng, ngoại lệ,

Code:

TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

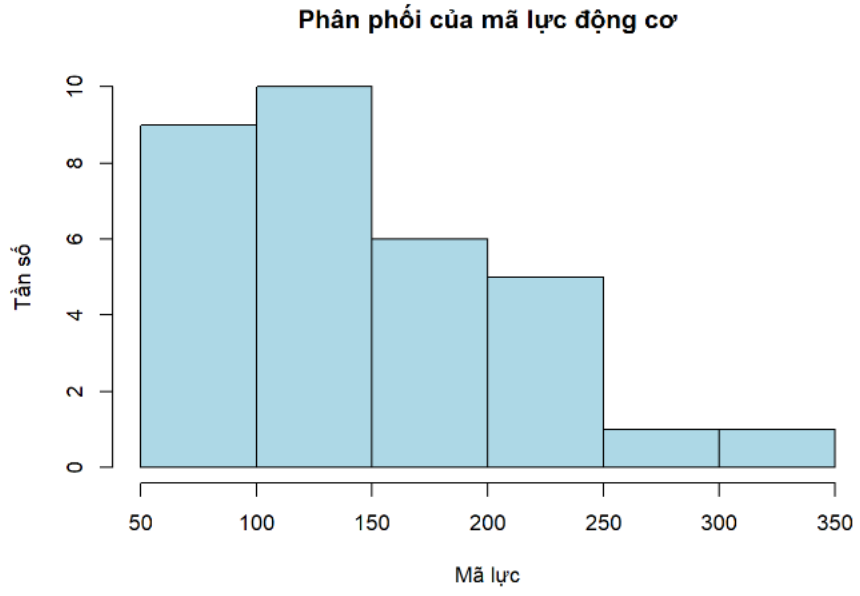

BACHKHOACNCP.COM

+Biểu đồ thân lá (Stem-and-leaf plots): Tương tự như biểu đồ tần số, nó lấy tất cả các giá trị dữ liệu và hình dạng của phân phối.

```
##
##   The decimal point is 2 digit(s) to the right of the |
##
##   0 | 5677799
##   1 | 0011111122
##   1 | 55888888
##   2 | 123
##   2 | 556
##   3 | 4
```

+Biểu đồ hộp (Box Plots): Biểu đồ phù hợp để trình bày các thông tin về trung bình, hiển thị các độ đo về vị trí và phân tán, cung cấp thông tin về đối xứng và ngoại lệ mặc dù chúng có thể dẫn đến sai lệch về đa chủng.

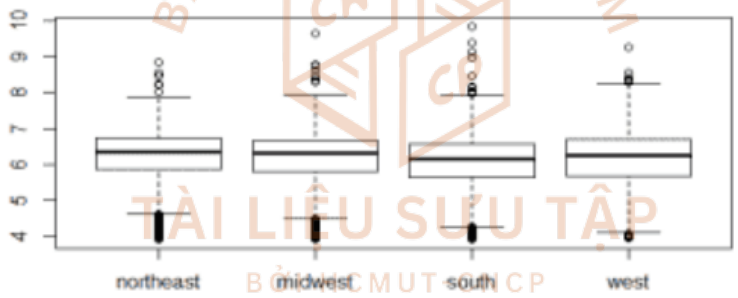

Biểu đồ Boxplots

- **Đa biến phi đồ họa:** Dữ liệu đa biến phát sinh từ nhiều hơn một biến. Các kỹ thuật EDA phi đồ họa đa biến thường cho thấy mối quan hệ giữa hai hoặc nhiều biến của dữ liệu thông qua bảng chéo hoặc thống kê.
- **Đồ họa đa biến:** Dữ liệu đa biến sử dụng đồ họa để hiển thị mối quan hệ giữa hai hoặc nhiều bộ dữ liệu. Đồ họa được sử dụng nhiều nhất là biểu đồ thanh hoặc biểu đồ thanh được nhóm lại với mỗi nhóm đại diện cho một cấp độ của một trong các biến và mỗi thanh trong một nhóm đại diện cho cấp độ của biến kia. Các loại đồ họa đa biến phổ biến khác bao gồm:

BACHKHOACNCP.COM

+ Biểu đồ phân tán, được sử dụng để vẽ các điểm dữ liệu trên trục ngang và trục dọc để cho biết mức độ ảnh hưởng của một biến đối với biến khác.

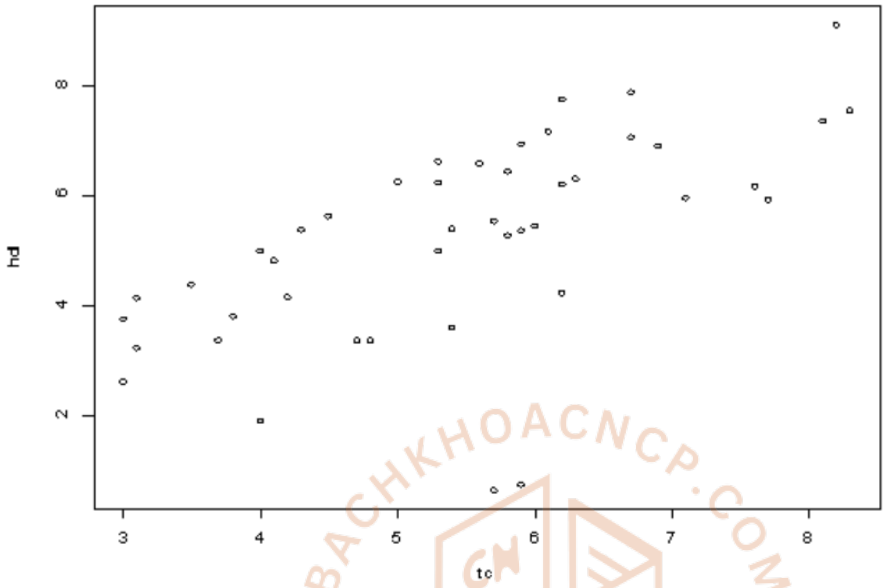

+ Biểu đồ chạy, là biểu đồ đường chứa dữ liệu được vẽ theo thời gian.

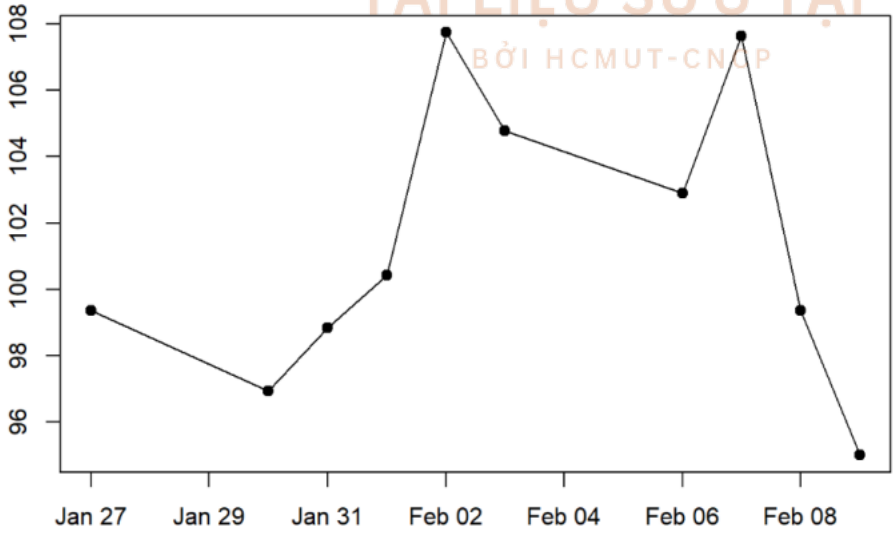

+ Biểu đồ bong bóng, là dạng trực quan hóa dữ liệu hiển thị nhiều vòng tròn (bong bóng) trong biểu đồ hai chiều. Ví dụ dưới đây là biểu đồ bong bóng được tạo trong microsoft

BACHKHOACNCP.COM

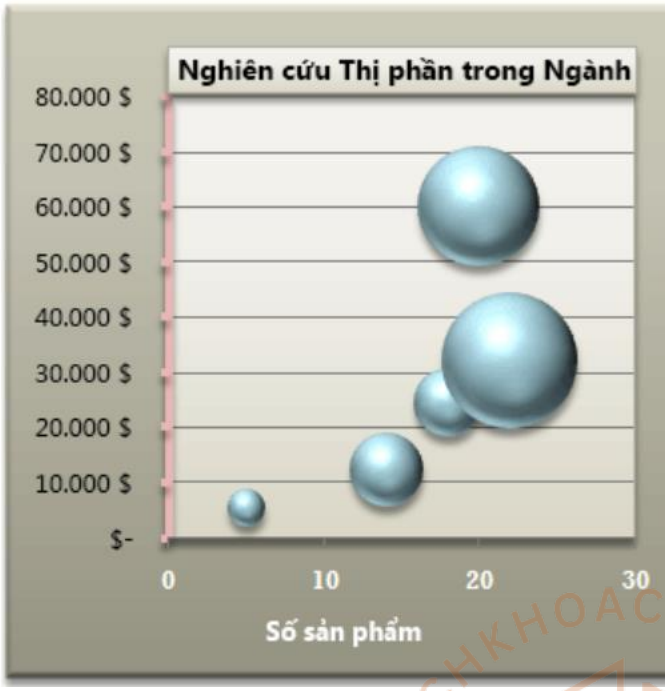

+ Bản đồ nhiệt, là biểu diễn đồ họa của dữ liệu trong đó các giá trị được mô tả bằng màu sắc.

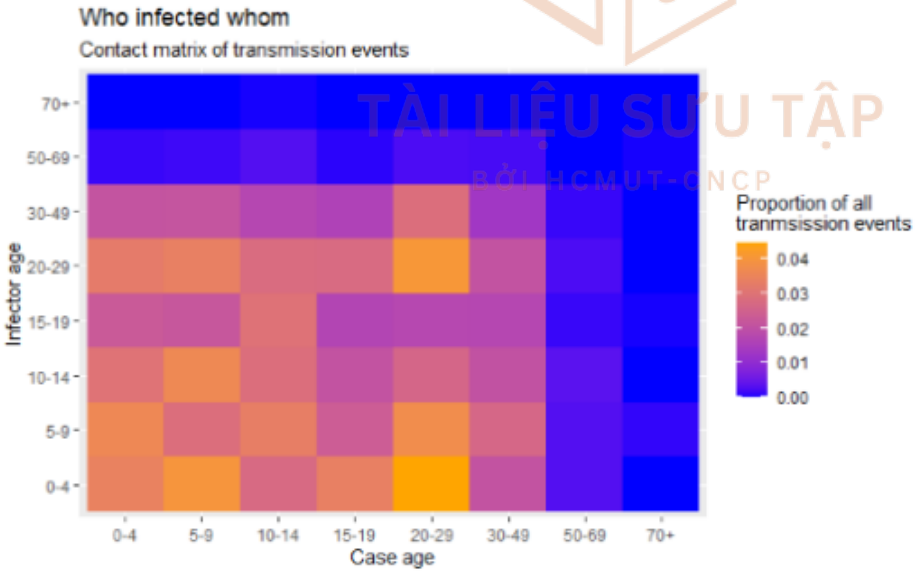

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

PHẦN NỘI DUNG

Chương I: Kiểm định 1 mẫu

❖ **Khái niệm**

1. Giả thuyết thống kê

Xét biến ngẫu nhiên có hàm phân phối F(x,θ) trong đó θ là tham số chưa biết. Ta có thể phát biểu nhiều giả thuyết cho θ, các giả thuyết này gọi là giả thuyết thống kê.

Trong quá trình nghiên cứu vấn đề của tổng thể qua 1 dấu hiệu X, để kiểm tra xem X có hay không. Do không có thông tin đầy đủ trên tổng thể nên không thể đánh giá chính xác vấn đề đó được. Thông tin trên mẫu sẽ được sử dụng để kiểm tra, đánh giá tính chất đó theo 1 phương pháp toán học. Bài toán đó gọi là kiểm định giả thuyết thống kê. Bao gồm ba loại:

- Kiểm định về dạng phân phối
- Kiểm định về tham số đặc trưng
- Kiểm định về tính độc lập của các biến ngẫu nhiên

2. Giả thuyết không và giả thuyết ngược lại (đối thuyết).

Các mệnh đề cần kiểm định sẽ được đặt dưới dạng cặp giả thuyết:

- Giả thuyết không H_0: là giả thuyết về yếu tố cần kiểm định của tổng thể ở trạng thái bình thường, không chịu tác động của các hiện tượng liên quan. Yếu tố trong H_0 phải được xác định cụ thể.
- Giả thuyết đối H_1: là một mệnh đề mâu thuẫn với H_0, H_1 thể hiện xu hướng cần kiểm định.

3. Các loại sai lầm trong kiểm định giả thuyết thống kê.

Việc kiểm định giả thuyết thống kê có thể phạm 2 sai lầm

3.1. Sai lầm loại I

Là loại sai lầm mà chúng ta phạm phải trong việc bác bỏ giả thuyết H_0 khi H_0 đúng. Xác suất của việc bác bỏ H_0 khi H_0 đúng là xác suất của sai lầm loại I và được kí hiệu là α

α = P (bác bỏ H_0 / H_0 đúng)

α còn gọi là mức ý nghĩa.

3.2. Sai lầm loại II

Là loại sai lầm mà chúng ta phạm phải khi không bác bỏ giả thuyết H_0 khi H_0 sai.

BACHKHOACNCP.COM

Xác suất của việc không bác bỏ H_0 khi H_0 sai là xác suất của sai lầm loại II và được kí hiệu là β

β= = P (không bác bỏ H_0 / H_0 sai)

Quyết định về giả thuyết không Ho	Bản chất của Ho	
	Ho đúng	Ho sai
Không bác bỏ (chấp nhận)	**Quyết định đúng** Prob = 1- α P (không bác bỏ Ho / Ho) = 1-α	**Sai lầm loại II** Prob = β
Bác bỏ	**Sai lầm loại I** Prob = α (α = mức ý nghĩa kiểm định)	**Quyết định đúng** Prob = 1 - β (1 - β: năng lực kiểm định)

❖ **Quy tắc kiểm định**

1. Nguyên lý xác suất

1.1. Nguyên lý xác suất nhỏ

- "Một biến cố có xác suất xuất hiện khá nhỏ thì có thể xem như biến cố đó không xảy ra khi thực hiện một phép thử có liên quan đến biến cố đó."
- Mức xác suất được coi là nhỏ tùy thuộc vào từng bài toán và gọi là mức ý nghĩa.
- Nguyên lí xác suất nhỏ là cơ sở của phương pháp kiểm định.

1.2. Nguyên lý xác suất lớn

- "Nếu một biến cố có xác suất rất lớn thực tế có thể chorằng trong một phép thử biến cố đó sẽ xảy ra."
- Mức xác suất đủ lớn gọi là độ tin cậy.
- Nguyên lý xác suất lớn là cơ sở của phương pháp ước lượng bằng khoảng tin cậy.

2. Tiêu chuẩn kiểm định một mẫu

Tiêu chuẩn kiểm định là hàm một thống kê $G = G(X_1, X_2, X_3, ...,X_n, \theta_0)$ xây dựng trên mẫu ngẫu nhiên $W = f(X_1, X_2, X_3, ...,X_n)$ và tham số θ_0 liên quan đến H_0. Điều kiện đặt ra với thống kê G là nếu H_0 đúng thì quy luật phân phối xác suất của G phải hoàn toàn xác định.

BACHKHOACNCP.COM

2.1. Kiểm định tỷ lệ tổng thể trong điều kiện cỡ mẫu lớn

Gọi P là tỷ lệ tổng thể, f là tỷ lệ mẫu.

Khi cỡ mẫu n lớn, thì biến ngẫu nhiên chuẩn hóa $\sum = \frac{f-p}{\sqrt{p(1-p)}}\sqrt{n}$ sẽ gần đúng có phân phối chuẩn hóa.

Ta sẽ có 3 trường hợp p với mức ý nghĩa α

+ *Trường hợp 1:*

H_0 : P=P_0 hay H_0 : P≥P_0

H_1: P<P_0

R: Bác bỏ H_0 nếu Z < Z_α

Với $Z = \frac{f-p}{\sqrt{p(1-p)}}\sqrt{n}$

+ *Trường hợp 2:*

H_0 : P=P_0 hay H_0 : P≤P_0

H_1: P>P_0

R: Bác bỏ H_0 nếu Z > Z_α

Với $Z = \frac{f-p}{\sqrt{p(1-p)}}\sqrt{n}$

+*Trường hợp 3:*

H_0 : P=P_0

H_1: P≠P_0

R: Bác bỏ H_0 nếu | Z| > $Z_{\alpha/2}$

Với $Z = \frac{f-p}{\sqrt{p(1-p)}}\sqrt{n}$

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

	GT không H_0	Giả thiết đối H_1	Tiêu chuẩn kiểm định	Miền bác bỏ H_0 với mức ý nghĩa α
BT 1 mẫu	$p = p_0$	$p \neq p_0$	$Z_{qs} = \frac{F - p_0}{\sqrt{p_0(1-p_0)}}\sqrt{n}$	$RR = (-\infty, -z_{\alpha/2}) \cup (z_{\alpha/2}, +\infty)$
		$p < p_0$		$RR = (-\infty, -z_{\alpha})$
n≥30		$p > p_0$		$RR = (z_{\alpha}, +\infty)$
			$Z_{qs} \overset{xx}{\sim} N(0; 1)$	
BT		$p_1 \neq p_2$		

Hình 1: Bảng tóm tắt một số công thức của bài toán kiểm định tỷ lệ 1 mẫu

2.2. Kiểm định trung bình tổng thể:

+ Kiểm định giá trị trung bình μ của phân phối chuẩn khi đã biết σ^2

+ Trường hợp 1:

H_0: $\mu = \mu_0$

H_1: $\mu \neq \mu_0$

Miền bác bỏ R: Bác bỏ H_0 nếu $Z > Z_{\alpha/2}$ *hay* $Z < -Z_{\alpha/2}$

Với $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$

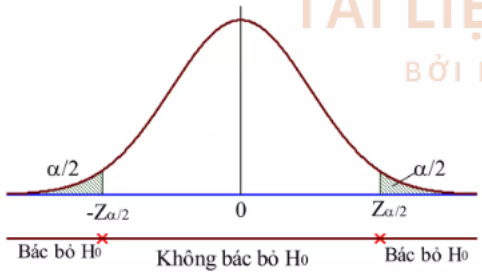

+ Trường hợp 2

H_0: $\mu = \mu_0$

H_1: $\mu < \mu_0$

Miền bác bỏ R: Bác bỏ H_0 nếu $Z < -Z_{\alpha}$

Với $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

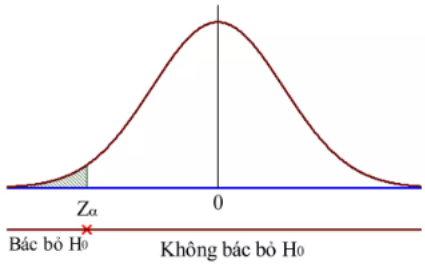

+ *Trường hợp 3:*

H_0: $\mu = \mu_0$

H_1: $\mu > \mu_0$

Miền bác bỏ R: Bác bỏ H_0 nếu $Z > Z_\alpha$

Với $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$

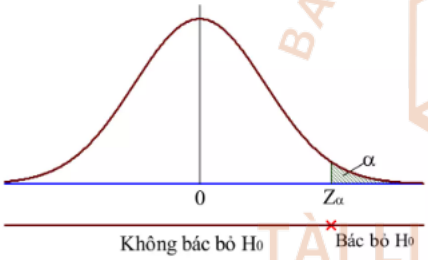

+ Kiểm định giá trị trung bình μ của phân phối chuẩn khi chưa biết σ^2

Giả sử ta có mẫu ngẫu nhiên cỡ mẫu là n được lấy từ tập hợp chính tuân theo phân phối chuẩn có số trung bình là μ. Gọi $\bar{X}$ và S_x là số trung bình và độ lệch của mẫu, ta sẽ có 3 trường hợp kiểm định μ với mức ý nghĩa α.

+ *Trường hợp 1:*

H_0: $\mu = \mu_0$

H_1: $\mu \neq \mu_0$

Miền bác bỏ R: Bác bỏ H_0 nếu $t > t_{\alpha/2}(n-1)$ *hay* $t < -t_{\alpha/2}(n-1)$

Với $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$

BACHKHOACNCP.COM

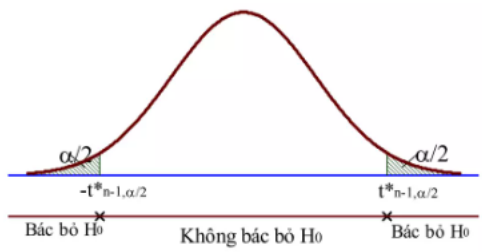

+ *Trường hợp 2:*

H_0: $\mu = \mu_0$

H_1: $\mu < \mu_0$

Miền bác bỏ R: Bác bỏ H_0 nếu $t < -t_\alpha(n-1)$

Với $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$

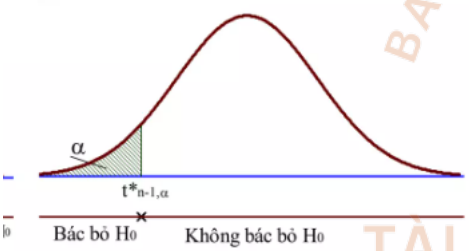

+ *Trường hợp 3:*

H_0: $\mu = \mu_0$

H_1: $\mu > \mu_0$

Miền bác bỏ R: Bác bỏ H_0 nếu $t > t_\alpha(n-1)$

Với $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

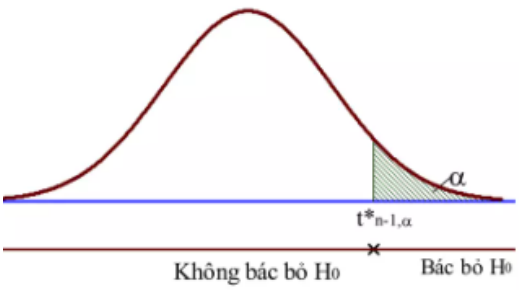

+ Kiểm định tổng thể có mẫu n ≥ 30, có phân phối tùy ý.

Các trường hợp này được kiểm định như kiểm định mẫu có phân phối chuẩn đã biết phương sai σ^2. Với trường hợp chưa biết σ thì dùng S thay thế.

Phân bố của tổng thể	Gt H_0	Gt H_1	Miền bác bỏ RR	Tiêu chuẩn kiểm định
* X có pp chuẩn. * Đã biết σ^2 (2a)	$\mu = \mu_0$	$\mu \neq \mu_0$	$(-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$	$Z_{qs} = \dfrac{\overline{X} - \mu_0}{\dfrac{\sigma}{\sqrt{n}}}$
		$\mu < \mu_0$	$(-\infty; -z_\alpha)$	
		$\mu > \mu_0$	$(z_\alpha; +\infty)$	
* X có pp chuẩn. * Chưa biết σ^2 (2b)	$\mu = \mu_0$	$\mu \neq \mu_0$	$(-\infty; -t_{\alpha/2}(n-1)) \cup (t_{\alpha/2}(n-1); +\infty)$	$T_{qs} = \dfrac{\overline{X} - \mu_0}{\dfrac{s}{\sqrt{n}}}$
		$\mu < \mu_0$	$(-\infty; -t_\alpha(n-1))$	
		$\mu > \mu_0$	$(t_\alpha(n-1); +\infty)$	
* X có pp tùy ý * Mẫu lớn: n≥30 * Đã biết hoặc chưa biết σ^2 (2c)	$\mu = \mu_0$	$\mu \neq \mu_0$	$(-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$	$Z_{qs} = \dfrac{\overline{X} - \mu_0}{\dfrac{\sigma}{\sqrt{n}}}$ *Nếu chưa biết σ thì dùng s thay thế*
		$\mu < \mu_0$	$(-\infty; -z_\alpha)$	
		$\mu > \mu_0$	$(z_\alpha; +\infty)$	

Hình 2: Bảng tóm tắt công thức của bài toán kiểm định trung bình 1 mẫu

2.3. Kiểm định phương sai của phân phối chuẩn

Giả sử ta có mẫu ngẫu nhiên cỡ mẫu là n được lấy từ tập hợp chính tuân theo phân phối chuẩn có phương sai là σ^2 . Gọi S^2_x là phương sai của mẫu, ta sẽ có 3 trường hợp kiểm định σ^2 với mức ý nghĩa α.

+ Trường hợp 1:

H_0: $\sigma^2 = \sigma_0^2$

BACHKHOACNCP.COM

$H_{1:}\ \sigma^2 \neq \sigma_0^2$

Miền bác bỏ R: Bác bỏ H_0 nếu $\chi^2 > \chi^2{}_{\alpha/2}(n-1)$ *hay* $\chi^2 < -\chi^2{}_{\alpha/2}(n-1)$

Với $\chi^2 = \frac{(n-1)\,s^2}{\sigma_0^2}$

+ *Trường hợp 2*:

H_0: $\sigma^2 = \sigma_0^2$

$H_{1:}\ \sigma^2 > \sigma_0^2$

Miền bác bỏ R: Bác bỏ H_0 nếu $\chi^2 > \chi^2{}_{\alpha/2}(n-1)$

Với $\chi^2 = \frac{(n-1)\,s^2}{\sigma_0^2}$

+ *Trường hợp 3:*

H_0: $\sigma^2 = \sigma_0^2$

$H_{1:}\ \sigma^2 < \sigma_0^2$

Miền bác bỏ R: Bác bỏ H_0 nếu $\chi^2 < -\chi^2{}_{\alpha/2}(n-1)$

Với $\chi^2 = \frac{(n-1)\,s^2}{\sigma_0^2}$

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Chương 2: Kiểm định 2 mẫu

Có 3 dạng thường gặp:
- Kiểm định tỉ lệ 2 mẫu
- Kiểm định trung bình 2 mẫu
- Kiểm định phương sai 2 mẫu (làm BTL)

❖ Kiểm định tỉ lệ 2 mẫu:

Cho tổng thể X có tỉ lệ các phần tử có đặc điểm A là p_1 và tổng thể Y có tỉ lệ các phần tử có đặc điểm A là p_2, so sánh tỉ lệ 2 tông thể này với mức ý nghĩa a

$$\bar{f} = \frac{m_1 + m_2}{n_1 + n_2} = \frac{n_1 \times f_1 + n_2 \times f_2}{n_1 + n_2}$$ là tỷ lệ mẫu gộp.

Giả thuyết H_0	Giả thuyết đối H_1	Tiêu chuẩn kiểm định	Miền bác bỏ
$p_1 = p_2$	$p_1 \neq p_2$	$Z_{qs} = \frac{f_1 - f_2}{\sqrt{\frac{\bar{f}(1-\bar{f})}{\bar{n}}}}$	$RR = (-\infty; -Z_{\frac{\alpha}{2}}) \cup (Z_{\frac{\alpha}{2}}; +\infty)$
$p_1 = p_2$	$p_1 > p_2$		$RR = (Z_a; +\infty)$
$p_1 = p_2$	$p_1 < p_2$		$RR = (-\infty; -Z_a)$

Phương pháp:

Step 1: Xác định giả thuyết H_0 và H_1

Step 2: Tùy trường hợp mà sử dụng các công thức sau'
Step 3: Kết luận

- Nếu $Z_{qs} \in RR$ thì ta có thể bác bỏ giả thuyết H_0, chấp nhận giả thuyết H_1
- Nếu $Z_{qs} \notin RR$ thì ta không bác bỏ ý kiến H_o (chưa có đủ bằng chứng để bác bỏ H_0)

❖ Kiểm định trung bình 2 mẫu

Cho tổng thể X có trung bình là μ_1 và tổng thể Y có trung bình là μ_2, so sánh tỉ lệ 2 tổng thể này với mức ý nghĩa α

BACHKHOACNCP.COM

1) Hai mẫu độc lập

Phương pháp:

Step 1: Xác định giả thuyết H_0 và H_1

Step 2: Tùy trường hợp mà sử dụng các công thức

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Dạng	Giả thuyết H_o	Giả thuyết đối H_1	Tiêu chuẩn kiểm định	Miền bác bỏ H_o
X, Y Có phân phối chuẩn và đã biết σ_1^2, σ_2^2 (z-test)	$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$Z_{qs} = \dfrac{\overline{x_1} - \overline{x_2}}{\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}}$	$RR = (-\infty; -z_{\frac{\alpha}{2}}) \cup (z_{\frac{\alpha}{2}}; +\infty)$
		$\mu_1 > \mu_2$		RR=$(z_\alpha; +\infty)$
		$\mu_1 < \mu_2$		RR=$(-\infty; -z_\alpha)$
Có phân phối chuẩn và chưa biết σ_1^2, σ_2^2, và cho biết rằng $\sigma_1^2 = \sigma_2^2$, $n_1, n_2 \leq 30$ (t-test)	$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$T_{qs} = \dfrac{\overline{x_1} - \overline{x_2}}{\sqrt{\dfrac{s_p^2}{n_1} + \dfrac{s_p^2}{n_2}}}$	$RR = (-\infty; -t_{\frac{\alpha}{2}; n_1+n_2-2}) \cup (t_{\frac{\alpha}{2}; n_1+n_2-2}; +\infty)$
		$\mu_1 > \mu_2$	với $s_p^2 = \dfrac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$	RR=$(t_{\alpha; n_1+n_2-2}; +\infty)$
		$\mu_1 < \mu_2$		RR=$(-\infty; -t_{\alpha; n_1+n_2-2})$
Có phân phối chuẩn và chưa biết σ_1^2, σ_2^2, và cho biết rằng $\sigma_1^2 \neq \sigma_2^2$, $n_1, n_2 \leq 30$ (t-test)	$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$T_{qs} = \dfrac{\overline{x_1} - \overline{x_2}}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}}$	$RR = (-\infty; -t_{\frac{\alpha}{2}; v}) \cup (t_{\frac{\alpha}{2}; v}; +\infty)$
		$\mu_1 > \mu_2$		RR=$(t_{\alpha; v}; +\infty)$
		$\mu_1 < \mu_2$	$v = \dfrac{\left(\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}\right)^2}{\dfrac{\left(\dfrac{s_1^2}{n_1}\right)^2}{n_1-1} + \dfrac{\left(\dfrac{s_2^2}{n_2}\right)^2}{n_2-1}}$ *(làm tròn, dùng để tìm RR)*	RR=$(-\infty; -t_{\alpha; v})$
Lưu ý, để kiểm tra $\sigma_1^2 = \sigma_2^2$ hay $\sigma_1^2 \neq \sigma_2^2$ khi biết s_1 và s_2, ta tính nếu $\frac{s_1}{s_2} \in [0,5; 2]$ thì $\sigma_1^2 = \sigma_2^2$ và ngược lại				
Có phân phối tùy ý và chưa biết σ_1^2, σ_2^2 và $n_1, n_2 \geq 30$ (z-test)	$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$Z_{qs} = \dfrac{\overline{x_1} - \overline{x_2}}{\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}}$	$RR = (-\infty; -z_{\frac{\alpha}{2}}) \cup (z_{\frac{\alpha}{2}}; +\infty)$
		$\mu_1 > \mu_2$		RR=$(z_\alpha; +\infty)$
		$\mu_1 < \mu_2$		RR=$(-\infty; -z_\alpha)$

Step 3: Kết luận

- Nếu $Z_{qs} \in$ RR thì ta có thể bác bỏ giả thuyết H_0, chấp nhận giả thuyết H1
- Nếu $Z_{qs} \notin$ RR thì ta không bác bỏ ý kiến H_o (chưa có đủ bằng chứng để bác bỏ H_0

BACHKHOACNCP.COM

2) Hai mẫu không độc lập tương ứng từng cặp một

Phương pháp:

Step 1: Xác định giả thuyết H_0 và H_1

Step 2: Tùy trường hợp mà sử dụng các công thức

Có phân phối chuẩn, chưa biết σ_1^2, σ_2^2 và kích thước mẫu cùng là n (t-test)	$\mu = \mu_o$	$\mu \neq \mu_o$	Đặt $D = X - Y$ $T_{qs} = \frac{\overline{D}}{s_d}\sqrt{n}$ với • $\overline{x_1}$ là giá trị trung bình của D • s_d là độ lệch chuẩn của mẫu D	$RR = (-\infty; -t_{\frac{\alpha}{2};n-1}) \cup (t_{\frac{\alpha}{2};n-1}; +\infty)$
		$\mu > \mu_o$		RR=$(t_{\alpha;n-1}; +\infty)$
		$\mu < \mu_o$		RR=$(-\infty; -t_{\alpha;n-1})$
Phân phối tùy ý, chưa biết σ_1^2, σ_2^2 và kích thước mẫu cùng là $n \geq 30$ (z-test)	$\mu = \mu_o$	$\mu \neq \mu_o$	Đặt $D = X - Y$ $T_{qs} = \frac{\overline{D}}{s_d}\sqrt{n}$ với • $\overline{x_1}$ là giá trị trung bình của D • s_d là độ lệch chuẩn của mẫu D	$RR = (-\infty; -z_{\frac{\alpha}{2}}) \cup (z_{\frac{\alpha}{2}}; +\infty)$
		$\mu > \mu_o$		RR=$(z_\alpha; +\infty)$
		$\mu < \mu_o$		RR=$(-\infty; -z_\alpha)$

Step 3: Kết luận

- Nếu $Z_{qs} \in$ RR thì ta có thể bác bỏ giả thuyết H_0, chấp nhận giả thuyết H1
- Nếu $Z_{qs} \notin$ RR thì ta không bác bỏ ý kiến H_o (chưa có đủ bằng chứng để bác bỏ H_0)

BACHKHOACNCP.COM

Chương 3: Anova

❖ **Định nghĩa phân tích phương sai:**

Phân tích phương sai là một mô hình dùng để xem xét sự biến động của một biến ngẫu nhiên định lượng X chịu tác động trực tiếp của một hay nhiều yếu tố nguyên nhân (định tính).

❖ **Bài toán phân tích phương sai (phân tích Anova)**

Bài toán: Cho k tổng thể có phân phối chuẩn có phương sai bằng nhau $N(\mu_i, \sigma^2)$

$i = 1,2,3, \dots k$ ($thường\ k \geq 3$)

Khảo sát k mẫu ta được:

	Mẫu 1	Mẫu 2	Mẫu 3	…	Mẫu k
Mẫu quan sát được	$x_{11}, x_{21}, \dots, x_{n1;1}$	$x_{12}, x_{22}, \dots, x_{n2;2}$	$x_{13}, x_{23}, \dots, x_{n3;3}$		$x_{1k}, x_{2k}, \dots, x_{nk;k}$
Kích thước	n_1	n_2	n_3	$\dots$	n_k
Trung bình từng mẫu	$\overline{x_1}$	$\overline{x_2}$	$\overline{x_3}$	$\dots$	$\overline{x_k}$
Kích thước mẫu gộp	$N = n_1 + n_2 + n_3 + \dots + n_k$				

❖ Giả thuyết kiểm định

- H_0: $\mu_1 = \mu_2 = \dots = \mu_k$

Trung bình tất cả các phương thức xử lý bằng nhau, hay nói cách khác, không có sự khác biệt về trung bình giữa các nhóm

- H_1: $\exists \mu_i \neq \mu_j$ (tồn tại ít nhất 1 cặp trung bình tổng thể khác nhau)

Nghĩa là có tồn tại sự khác biệt giữa các nhóm, nhưng không có nghĩa là tất cả trung bình đều khác nhau (có thể có một vài cặp).

❖ Miền bác bỏ H_0

$$RR = ((f_\alpha k - 1; N - k); +\infty)$$

Xác định $f_\alpha k - 1; N - k$ bằng các tra bảng fisher với mức ý nghĩa α, cột $k - 1$ và hàng $N - k$

BACHKHOACNCP.COM

❖ Tính giá trị kiểm định thống kê:

-Trung bình chung của k mẫu:

$$\bar{x} = \frac{\sum_{i,j=1}^{i=k,j=n_k} ij}{N}$$

-Tính chêch lệch bình phương giữa các nhóm SSB

$$SSB = \sum_{i=1}^{k} n_i(\overline{x_i} - \bar{x})^2 = n_1(\overline{x_1} - \bar{x})^2 + n_2(\overline{x_2} - \bar{x})^2 + \cdots + n_k(\overline{x_k} - \bar{x})^2$$

-Tính tổng chêch lệch bình phương trong nội bộ mẫu SSW

$SS_1 = (n_1 - 1)S_1^2$, $SS_2 = (n_2 - 1)S_2^2$,…, $SS_k = (n_k - 1)S_k^2$

=> SSW = $SS_1 + SS_2 + \cdots + SS_k$

-Tính tổng chêch lệch bình phương toàn bộ SST

SST = SSW + SSB

-Tính phương sai giữa các nhóm

$MSB = \frac{SSB}{k-1}$

-Tính phương sai trong nội bộ nhóm

$MSW = \frac{SSW}{N-k}$

-Tính phương sai toàn bộ

$MST = \frac{SST}{N-1}$

-Tính tiêu chuẩn kiểm định F

$F = \frac{MSB}{MSW}$

-Hệ số xác định

$R^2 = \frac{SSB}{SST} x100\%$

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Source of groups	Tổng bình phương chêch lệch	Bậc tự do	Phương sai	Tiêu chuẩn kiểm định F
Between groups	SSB (sstr)	k-1	$MSB = \frac{SSB}{k-1}$	$F = \frac{MSB}{MSW}$
Within groups	SSW (sse)	N-k	$MSW = \frac{SSW}{N-k}$	
Total	SST	N-1	N là kích thước mẫu gộp, k là số mẫu khảo xác	

❖ Kết luận:

- Nếu F $\in RR$ thì ta có thể bác bỏ giả thuyết Ho, chấp nhận giả thuyết $H1$

- Nếu $F \notin RR$ thì ta không bác bỏ ý kiến Ho (chưa có đủ bằng chứng để bác bỏ Ho)

❖ **Giả định ANOVA:**

Phân tích ANOVA (Analysis of Variance) là một phương pháp thống kê được sử dụng để kiểm tra sự khác biệt giữa các giá trị trung bình của ba hoặc nhiều nhóm khác nhau. Khi thực hiện phân tích ANOVA, có một số giả định cần được xem xét:

1. Giả định về phân phối chuẩn: Các nhóm phải tuân theo phân phối chuẩn. Tuy nhiên, với kích thước mẫu lớn, ANOVA có thể là ổn định đối với việc vi phạm giả định này.

- Giả định: Các nhóm cần phải tuân theo phân phối chuẩn.

- Kiểm tra: Kiểm tra phần đồ thị (như histogram) hoặc kiểm tra thống kê như Kolmogorov-Smirnov test, Shapiro-Wilk test để kiểm tra tính chuẩn.

2. Homogeneity of Variances (Phương sai đồng nhất): Phương sai của các nhóm cần phải giống nhau. Điều này có nghĩa là sự biến động (phương sai) trong mỗi nhóm cần phải tương đương. ANOVA có khả năng chịu đựng một số độ không đồng đều nếu kích thước mẫu làm tăng tính ổn định của kết quả.

- Giả định: Phương sai của các nhóm cần phải giống nhau.

BACHKHOACNCP.COM

- Kiểm tra: Sử dụng kiểm tra Levene hoặc kiểm tra Bartlett để kiểm tra tính đồng nhất của phương sai giữa các nhóm.

3. Dữ liệu độc lập: Các quan sát trong mỗi nhóm cần phải độc lập với nhau. Điều này có nghĩa là kết quả của một quan sát không ảnh hưởng đến kết quả của các quan sát khác.

- Giả định: Các quan sát trong mỗi nhóm cần phải độc lập với nhau.

- Kiểm tra: Điều này thường được kiểm tra bằng cách đảm bảo rằng không có tương tác giữa các quan sát, và mỗi quan sát chỉ ảnh hưởng đến nhóm của nó.

4. Kiểm tra sự tương quan giữa các phần tử dư: Trong phân tích ANOVA, giả định về sự độc lập giữa các phần tử dư (residuals) là quan trọng để đảm bảo tính chính xác của kết quả. Sự độc lập này ngụ ý rằng không có mối tương quan nào giữa các sai số của các quan sát trong mô hình. Nếu có sự tương quan giữa các phần tử dư, có thể dẫn đến việc xác định sai về mặt thống kê và làm suy giảm độ tin cậy của kết quả.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Chương 4: Hồi quy

❖ **Phân tích hồi quy:**

1. Định nghĩa:

Hồi quy tuyến tính là một phương pháp thống kê được sử dụng để mô hình hóa mối quan hệ tuyến tính giữa một biến phụ thuộc (biến mục tiêu) và một hoặc nhiều biến độc lập (biến giải thích). Mục tiêu của hồi quy tuyến tính là tìm ra một mô hình tuyến tính tốt nhất để dự đoán giá trị của biến phụ thuộc dựa trên giá trị của các biến độc lập.

Ví dụ: Chi tiêu của hộ gia đình về thực phẩm phụ thuộc vào quy mô hộ gia đình, thu nhập, vị trí địa lý, …; Tỷ lệ tử vong trẻ em của một quốc gia phụ thuộc vào thu nhập bình quân đầu người, trình độ giáo dục, …; Lương của một người phụ thuộc vào chức vụ, kinh nghiệm, độ tuổi, …

Phương trình hồi quy tuyến tính có dạng:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \ldots + \beta_n X_n + \varepsilon$$

Trong đó:

- Y là biến phụ thuộc (biến mục tiêu) mà chúng ta muốn dự đoán.
- $X_1, X_2, \ldots, X_n$ là các biến độc lập (biến giải thích) có thể ảnh hưởng đến biến phụ thuộc.
- $\beta_0, \beta_1, \beta_2, \ldots, \beta_n$ là các tham số chưa biết (hệ số hồi quy), thể hiện mức độ ảnh hưởng của các biến độc lập lên biến phụ thuộc.
- ε là sai số ngẫu nhiên.

2. Ý nghĩa:

Đường hồi quy tuyến tính mẫu là đường thẳng xấp xỉ nội suy từ bảng số liệu của X và Y theo phương pháp bình phương tối tiểu.Nếu X và Y có tương quan xấp xỉ tuyến tính thì đường hồi quy tuyến tính mẫu cho ta một dự báo đơn giản:

$$X = x_0 \Rightarrow Y \approx y_0 = a + bx_0$$

BACHKHOACNCP.COM

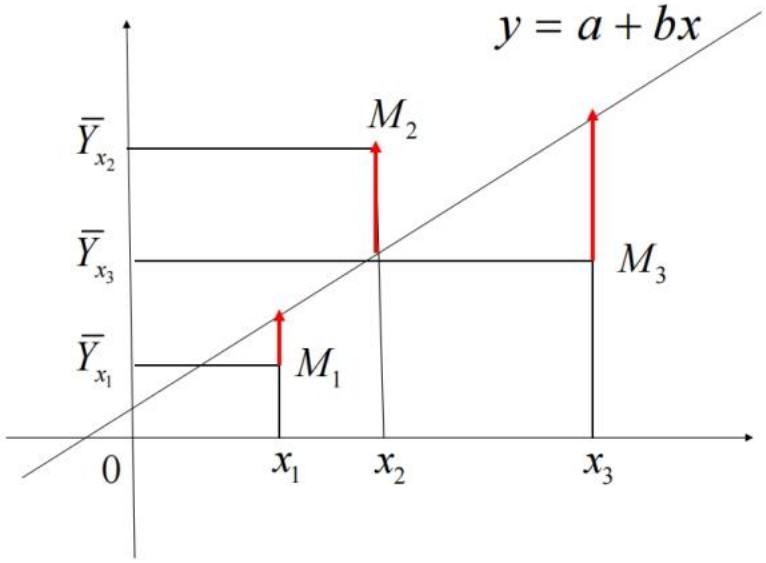

3. Ứng dụng:

Thống kê hiện nay đã được ứng dụng vào mọi lĩnh vực:

- Lĩnh vực kinh tế - xã hội tự nhiên, kỹ thuật, thống kê thường quan tâm nghiên cứu các hiện tượng
- Về dân số, nguồn lao động.
- Về tâm lý, giáo dục, thể thao, y tế.
- Về sinh hoạt chính trị, xã hội
- Về kỹ thuật.
- Thời tiết, dự báo bão. . .

Các loại hồi quy tuyến tính và ví dụ:

Hồi quy tuyến tính là động lực quan trọng đằng sau nhiều ứng dụng khoa học dữ liệu và AI. Kỹ thuật thống kê này hữu ích cho các doanh nghiệp vì nó đơn giản, dễ hiểu và đánh giá xu hướng, cũng như đưa ra các dự báo hiệu quả. Các loại mô hình hồi quy tuyến tính gồm:

_Hồi quy tuyến tính đơn:

+ Hồi quy tuyến tính đơn (Simple linear regression) cho thấy mối quan hệ giữa một biến phụ thuộc và một biến độc lập. Mô hình hồi quy này chủ yếu dành cho hai trường hợp:

+ Độ mạnh của mối quan hệ giữa các biến đã cho. Ví dụ: Mối quan hệ giữa mức độ ô nhiễm và nhiệt độ tăng.

+ Giá trị của biến phụ thuộc dựa trên giá trị của biến độc lập. Ví dụ: Giá trị của mức độ ô nhiễm ở một nhiệt độ cụ thể.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

_ Hồi quy tuyến tính bội:
+ Hồi quy tuyến tính bội (Multiple linear regression) cho thấy mối quan hệ giữa các biến độc lập (từ hai biến trở lên) và một biến phụ thuộc tương ứng. Trong đó, các biến độc lập có thể là biến liên tục hoặc biến phân loại. Mô hình hồi quy này được sử dụng để dự đoán các xu hướng, xác định các giá trị trong tương lai và dự đoán tác động của các thay đổi.
Ví dụ: Nếu biến phụ thuộc là huyết áp, thì chiều cao, cân nặng và lượng vận động sẽ là các biến độc lập. Ở đây, chúng ta có thể sử dụng hồi quy tuyến tính bội để phân tích mối quan hệ giữa ba biến độc lập và một biến phụ thuộc này

❖ Giả định hồi quy.

Khi thực hiện mô hình hồi quy, có một số giả định quan trọng mà bạn cần kiểm tra để đảm bảo độ tin cậy của các kết quả hồi quy. Dưới đây là các giả định chính trong mô hình hồi quy:

- Linearity (Độ tuyến tính): Mối quan hệ giữa biến độc lập và phụ thuộc nên là một mối quan hệ tuyến tính.
- Independence (Độc lập): Các điểm dữ liệu nên độc lập với nhau. Điều này có nghĩa là giá trị phụ thuộc của một quan sát không được ảnh hưởng bởi giá trị phụ thuộc của các quan sát khác.
- Homoscedasticity (Đồng nhất phương sai): Phương sai của các giá trị phụ thuộc cần phải là không đổi qua các mức giá trị của biến độc lập. Điều này có nghĩa là phương sai của các điểm dữ liệu nên giống nhau.
- Normality of Residuals (Phân phối chuẩn của phần dư): Phần dư (hiệu số giữa giá trị dự đoán và giá trị thực tế) nên tuân theo phân phối chuẩn. Điều này quan trọng đối với việc đưa ra kết luận chính xác từ các kiểm định thống kê và xây dựng khoảng tin cậy.
- No Perfect Multicollinearity (Không tuyến tính đa cộng tuyến): Các biến độc lập nên độc lập với nhau, và không có tuyến tính đa cộng tuyến giữa chúng.
- No Endogeneity (Không có yếu tố nội tại): Không có yếu tố nội tại nào tác động đồng thời lên biến độc lập và phụ thuộc.
- No Autocorrelation (Không có tương quan tự do): Các phần dư nên không có tương quan với nhau. Tương quan tự do xuất hiện khi có mối tương quan giữa phần dư của các quan sát liên tiếp.

BACHKHOACNCP.COM

Chương 5: Xử Lý và tính toán số liệu

❖ Xử lý dữ liệu

+ Đọc dữ liệu từ file excel dirty_data lưu vào biến thongke

+ Đọc dữ liệu từ file excel warehouses lưu vào biến diachi

```
thongke = read.csv("dirty_data.csv",header=TRUE) #đọc dữ liệu
diachi= read.csv("warehouses.csv",header=TRUE)
```

Bảng số liệu dirty_data khi nhập vào (xem 10 số liệu)

	order_id	customer_id	date	nearest_warehouse	shopping_cart	order_price	delivery_charges	customer_lat	customer_long
1	ORD182494	ID6197211592	06/22/2019	Thompson	[('Lucent 330S', 1), ('Thunder line', 2), ('iStream', 2),...	12200	79.89	-37.81511	144.9328
2	ORD395518	ID0282825849	12/29/2019	Thompson	[('Thunder line', 1), ('Universe Note', 2)]	9080	62.71	-37.80274	144.9511
3	ORD494479	ID0579391891	03/02/2019	Nickolson	[('Thunder line', 1), ('pearTV', 2)]	10670	65.87	-37.82130	144.9576
4	ORD019224	ID4544561904	01/12/2019	Nickolson	[('Universe Note', 1), ('Alcon 10', 2), ('Olivia x460', 1...	24800	57.61	-37.81142	144.9731
5	ORD104032	ID6231506320	11/28/2019	Nickolson	[('Universe Note', 1), ('Olivia x460', 1), ('iStream', 1),...	9145	75.54	37.82386	144.9699
6	ORD146760	ID0311654900	09/16/2019	Bakers	[('Thunder line', 2), ('Universe Note', 1)]	7810	71.22	37.82025	145.0149
7	ORD337984	ID3394768956	09/14/2019	Thompson	[('Candle Inferno', 1), ('Alcon 10', 1), ('Toshika 750', ...	13700	74.84	-37.80774	144.9516
8	ORD072312	ID0774517121	05/23/2019	Thompson	[('Universe Note', 1), ('Thunder line', 2), ('iStream', 1)]	7960	52.28	-37.80634	144.9595
9	ORD377837	ID4769265355	10/09/2019	Bakers	[('Alcon 10', 2), ('Thunder line', 1), ('Candle Inferno',...	25390	107.58	-37.81081	145.0141
10	ORD462194	ID5301568579	03/21/2019	Thompson	[('Universe Note', 1), ('Lucent 330S', 1), ('Toshika 75...	13320	62.26	-37.80868	144.9423

coupon_discount	order_total	season	is_expedited_delivery	distance_to_nearest_warehouse	latest_customer_review	is_happy_customer
10	11059.89	Winter	TRUE	1.2800	perfect phone and trusted seller. phone itself is ama...	TRUE
0	9142.71	Summer	FALSE	1.1621	it keeps dropping calls the wifi don't work this is a w...	FALSE
10	9668.87	Autumn	FALSE	1.0949	five stars this is a great cheap phone.	TRUE
15	21137.61	Summer	FALSE	0.8571	charger did not fit the charger didn't fit.	FALSE
25	6934.29	Spring	FALSE	0.5867	four stars good	TRUE
10	7100.22	Spring	FALSE	2.0752	stolen phone sold us a stolen phone so we couldn't ...	FALSE
5	13089.84	Spring	FALSE	0.6767	love our inferno stick,easy to set up and have loads ...	TRUE
5	10789.79	Autumn	FALSE	1.3043	it sucks mine came with dead pixels	FALSE
10	22958.58	Spring	TRUE	1.6595	this is how top phone should look like! super fast ph...	TRUE
15	11384.26	winter	TRUE	0.6093	does not live up to its reputation. customer service ...	FALSE

Bảng số liệu warehouses khi nhập vào

	names	lat	lon
1	Nickolson	-37.81860	144.9696
2	Thompson	-37.81267	144.9471
3	Bakers	-37.81000	144.9952

Xử lý cột date và cột sesson

BACHKHOACNCP.COM

Ta có cột date có 1 vài số liệu không định dạng giống với phần lớn số liệu trong cột chẳng hạn như thiếu dấu "/" giữa ngày tháng năm

ORD493666	ID0844489306	01 27 2019	Thompson

ORD129378	ID6167417934	02 03 2019	Nickolson

Cách khắc phục:

```
#xử lý lỗi cột date và cột season
thongke <- thongke %>%
  mutate(date = gsub("(\\d{2}) (\\d{2}) (\\d{4})", "\\1/\\2/\\3", date))
thongke=arrange(thongke,date)
```

-Câu lệnh "thongke=arrange(thongke,date)" dùng để sắp xếp lại thứ tự ngày từ thấp đến cao

ORD163916	ID0030945778	01/24/2019	Bakers
ORD345202	ID0702451456	01/26/2019	Thompson
ORD404813	ID1132014865	01/26/2019	Thompson
ORD493666	ID0844489306	01/27/2019	Thompson
ORD439821	ID6167489399	01/28/2019	Thompson

ORD127141	ID0777789266	02/03/2019	Thompson
ORD129378	ID6167417934	02/03/2019	Nickolson
ORD190264	ID0581715652	02/03/2019	Thompson
ORD057375	ID0710001161	02/03/2019	Thompson

Sắp xếp lại cột cột sesson bởi vì nó so với dữ liệu với cột date thì bất hợp lí

03/16/2019	Thompson	[('Universe Note', 2), ('Olivia x460', 1), ('Thunder line', 2), ('pearTV', 2)]	25105	81.70	-37.80420	144.9280	0	25186.70	Autumn
07/09/2019	Thompson	[('Lucent 330S', 1), ('Thunder line', 1), ('Toshika 750', 1), ('iAssist Line', 2)]	12180	67.47	-37.80065	144.9358	0	12247.47	Winter
04/26/2019	Bakers	[('iStream', 1), ('Thunder line', 2), ('Candle Inferno', 2), ('Lucent 330S', 2)]	7830	70.74	-37.79114	144.9369	0	7900.74	Autumn
12/25/2019	Thompson	[('Toshika 750', 1), ('Lucent 330S', 2)]	6780	75.54	-37.81572	144.9371	0	6855.54	Summer
10/10/2019	Thompson	[('Toshika 750', 1), ('Lucent 330S', 2), ('Thunder line', 2), ('Candle Inferno', 1)]	11570	91.79	-37.78912	144.9381	0	11661.79	Spring
02/11/2019	Thompson	[('Alcon 10', 1), ('Universe Note', 1), ('pearTV', 1), ('iStream', 2)]	19010	94.75	-37.80543	144.9413	0	926057.25	Summer
10/18/2019	Thompson	[('Thunder line', 1), ('Lucent 330S', 1), ('Alcon 10', 2)]	21310	98.58	-37.81354	144.9427	0	21408.58	Spring
03/20/2019	Thompson	[('Olivia x460', 2), ('Alcon 10', 2), ('iStream', 1)]	20500	66.24	-37.82435	144.9438	0	20566.24	Autumn
09/18/2019	Thompson	[('Lucent 330S', 2), ('Candle Inferno', 2), ('Universe Note', 1), ('Toshika 750', 1)]	11090	98.73	-37.81644	144.9458	0	11188.73	Spring
01/27/2019	Thompson	[('Lucent 330S', 1), ('pearTV', 2), ('iAssist Line', 2)]	18300	74.75	-37.82076	144.9481	0	18374.75	Summer
06/15/2019	Thompson	[('Lucent 330S', 2), ('iStream', 1), ('Olivia x460', 2)]	5060	63.08	-37.80368	144.9500	0	5123.08	Winter

Khắc phục lỗi sai:

BACHKHOACNCP.COM

```
thongke <- thongke %>%
  mutate(date = as.Date(date, format="%m/%d/%Y"))
thongke <- thongke %>%
  mutate(season = case_when(
    between(month(date), 3, 5) ~ "Spring",
    between(month(date), 6, 8) ~ "Summer",
    between(month(date), 9, 11) ~ "Autumn",
    TRUE ~ "Winter"
  ))
library(stringr)
```

Câu lệnh

```
mutate(date = as.Date(date, format="%m/%d/%Y"))
```

=>> Đưa về định dạng chuẩn ngày tháng năm

Kết quả sao khi khắc phục lỗi:

2019-02-26	Bakers	[('Alcon 10', 2), ('Candle Inferno', 1), ('Toshika 750', ...	29195	73.43	-37.80491	144.9468	25	21969.68	Winter
2019-02-27	Thompson	[('Universe Note', 2), ('Lucent 330S', 2), ('iAssist Lin...	20535	83.99	37.82309	144.9379	15	17538.74	Winter
2019-02-27	Thompson	[('Universe Note', 1), ('Olivia x460', 2), ('Thunder lin...	16570	102.72	-37.80086	144.9608	10	15015.72	Winter
2019-02-27	Nickolson	[('Lucent 330S', 1), ('iStream', 2), ('Toshika 750', 2), ...	12350	93.09	-37.81215	144.9738	25	9355.59	Winter
2019-02-28	Nickolson	[('pearTV', 2), ('Thunder line', 1), ('Candle Inferno', 2)]	15660	87.96	-37.81545	144.9705	0	15747.96	Winter
2019-03-01	Thompson	[('Thunder line', 2), ('Toshika 750', 1), ('pearTV', 2), (...	21730	69.68	-37.82534	144.9513	10	19626.68	Spring
2019-03-01	Thompson	[('Universe Note', 2), ('iAssist Line', 2), ('Toshika 750...	15820	64.81	-37.81152	144.9592	15	402307.25	Spring
2019-03-01	Thompson	[('iStream', 2), ('Candle Inferno', 2), ('iAssist Line', 2...	12510	70.02	-37.79979	144.9580	10	11329.02	Spring
2019-03-02	Nickolson	[('Thunder line', 1), ('pearTV', 2)]	10670	65.87	-37.82130	144.9576	10	9668.87	Spring
2019-03-02	Bakers	[('iAssist Line', 1), ('Thunder line', 1)]	4405	65.72	-37.80419	145.0023	0	4470.72	Spring
2019-03-02	Nickolson	[('iAssist Line', 1), ('Universe Note', 2), ('Alcon 10', 2...	28255	80.72	-37.82539	145.0153	25	21271.97	Spring

Khắc phục lỗi sai cột customer_lat:

customer_lat	customer_long	coupon_discount	order_total	season	is_expedited_delivery	distance_to_nearest_warehouse
-37.81318	144.9515	10	11551.05	Spring	TRUE	0.3966
-37.81881	144.9641	10	7017.78	Spring	FALSE	0.4785
37.80452	144.9694	10	3056.12	Spring	FALSE	1.5671
-37.80729	144.9445	5	7026.61	Spring	FALSE	0.6412

Giá trị 37.80452 thì tính toán lại cột distance_to _nearest_warehouses sẽ đưa ra kết quả vô cùng lớn (lớn hơn 8000) =>> giá trị bất hợp lý nên ta chuyển sang giá trị âm (phù hợp với vị trí trên bản đồ thế giới)

Kết quả sau khi sửa:

```
library(stringr)
thongke$nearest_warehouse = str_to_title(thongke$nearest_warehouse)
thongke$customer_lat <- ifelse(thongke$customer_lat > 0, -thongke$customer_lat, thongke$customer_lat)
```


BACHKHOACNCP.COM

-37.81881	144.9641	10	7017.78	Spring	FALSE	0.4785
-37.80452	144.9694	10	3056.12	Spring	FALSE	1.5671
-37.80729	144.9445	5	7026.61	Spring	FALSE	0.6412

Do thay đổi 1 số giá trị ở cột customer_lat nên ta phải tính lại giá trị cột distance_to_nearest_warehouses

```
#tính lại khoảng cách
haversine_distance <- function(lat1, lon1, lat2, lon2, R = 6378) {
  # Chuyển đổi vĩ độ và kinh độ từ độ sang radian
  lat1 <- lat1 * pi / 180
  lon1 <- lon1 * pi / 180
  lat2 <- lat2 * pi / 180
  lon2 <- lon2 * pi / 180

  # Tính các độ chênh lệch giữa các vĩ độ và kinh độ
  dlat <- lat2 - lat1
  dlon <- lon2 - lon1

  # Công thức Haversine
  a <- sin(dlat/2)^2 + cos(lat1) * cos(lat2) * sin(dlon/2)^2
  c <- 2 * atan2(sqrt(a), sqrt(1-a))

  # Khoảng cách giữa hai điểm trên bề mặt cầu
  distance <- R * c

  return(distance)
}
for (i in 1:nrow(thongke)) {
  kho_hang <- thongke$nearest_warehouse[i]
  # Tìm thông tin từ bảng 2 dựa trên tên kho hàng
  kho_hang_info <- diachi[diachi$names == kho_hang, ]
  # Kiểm tra nếu có thông tin về kho hàng
  if (nrow(kho_hang_info) > 0) {
    # Tính khoảng cách và ghi vào cột khoang_cach
    thongke$distance_to_nearest_warehouse[i] <- haversine_distance(
      thongke$customer_lat[i],
      thongke$customer_long[i],
      kho_hang_info$lat,
      kho_hang_info$lon
    )
```

Số liệu trước khi tính

BACHKHOACNCP.COM

customer_lat	customer_long	coupon_discount	order_total	season	is_expedited_delivery	distance_to_nearest_warehouse
-37.80686	144.9589	10	5379.13	Winter	FALSE	1.2283
-37.81492	144.9680	5	6294.86	Winter	TRUE	61.2935
-37.82142	144.9639	5	2302.95	Winter	TRUE	0.5863
-37.80403	144.9695	25	9582.29	Winter	FALSE	1.6211
-37.80287	145.0166	10	20346.04	Winter	TRUE	2.0425
-37.82281	145.0093	5	2069.47	Winter	FALSE	1.8899
-37.09163	144.9952	25	15448.61	Winter	FALSE	0.8283
-37.81507	144.9889	15	7543.51	Winter	FALSE	0.7925
-37.80326	144.9501	5	15860.18	Winter	FALSE	1.0799
-37.81813	144.9486	10	11999.17	Winter	FALSE	0.6217

Số liệu sau khi tính

-37.80686	144.9589	10	5379.13	Winter	FALSE	1.2282863
-37.81492	144.9680	5	6294.86	Winter	TRUE	0.4309678
-37.82142	144.9639	5	2302.95	Winter	TRUE	0.5862973
-37.80403	144.9695	25	9582.29	Winter	FALSE	1.6211449
-37.80287	145.0166	10	20346.04	Winter	TRUE	2.0425307
-37.82281	145.0093	5	2069.47	Winter	FALSE	1.8899358
-37.09163	144.9952	25	15448.61	Winter	FALSE	79.9668204
-37.81507	144.9889	15	7543.51	Winter	FALSE	0.7924540
-37.80326	144.9501	5	15860.18	Winter	FALSE	1.0799194

Kiểm tra sai lệch cột order_total:

```
#kiem tra sai lech tong tien
tong_tien = thongke$order_price*((100-thongke$coupon_discount)/100) + thongke$delivery_charges
print(tong_tien)
sai_lech = abs(tong_tien - thongke$order_total)
print(sai_lech)
thongke$order_total = tong_tien
```

Kết quả sau khi tính tổng lại: (xem 105 số liệu đầu)

```
 [1]   5379.13   6294.86   2302.95   9582.29  20346.04   2069.47  15448.61   7543.51  15860.18  11999.17  13751.19   6655.24   6479.02  13757.19   3785.32
[16]  14827.60   5931.25  21137.61   8143.19  72366.26  14744.86  20388.62  13925.47  14327.27   9999.06   4770.31  10884.03  22206.48  18154.49   3241.11
[31]  17046.75  11374.78   6633.83  31053.70   5887.94   2291.84  83319.62  26021.13   2409.27   2397.82  13796.43  25062.35   6419.50  18374.75   2346.86
[46]   5098.00   7858.54   3913.42  12032.83  69777.70   7393.24   6060.90  13938.52   8162.80   2703.69  10621.14   8584.11  21008.16  15537.01  19104.75
[61]   3293.95   5197.21   2214.76  10598.30  23495.54   6207.96   1932.41   5417.05   2226.86 621327.23  24352.30  11716.90   1102.79  14646.58  52455.54
[76]  12210.93   5091.55   6268.89  16474.13   3813.87  17918.91  17141.80  13593.65  21969.68  17538.74  15015.72   9355.59  15747.96  19626.68  13511.81
[91]  11329.02   9668.87   4470.72  21271.97  13428.25  24293.23   4058.02   6541.61   4980.34   3138.47   5717.79  16234.77 504686.82  10018.24   8131.57
```

Kết quả tính sai số (xem 112 số liệu đầu)

BACHKHOACNCP.COM

```
 [1]      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00
[15]      0.00      0.00      0.00      0.00      0.00  63907.50      0.00      0.00      0.00      0.00      0.00      0.00 5677385.57      0.00
[29]  69070.20      0.00      0.00      0.00      0.00      0.00      0.00      0.00  72510.65      0.00 907054.67      0.00      0.00      0.00
[43]      0.00      0.00      0.00      0.00      0.00      0.00 608469.47  38565.00      0.00      0.00 651147.14      0.00   1779.35      0.00
[57]      0.00      0.00      0.00 906952.50      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00 599886.05
[71]      0.00      0.00      0.00      0.00  34139.40      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00
[85]      0.00      0.00      0.00      0.00      0.00 388795.44      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00
[99]      0.00      0.00      0.00      0.00 486714.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00      0.00
```

Số giá trị sai lệch:

```
so_luong_sai_lech_khac_khong <- sum(sai_lech != 0)
print(so_luong_sai_lech_khac_khong)
```

Kết quả:

```
> print(so_luong_sai_lech_khac_khong)
[1] 40
```

❖ Thống kê mô tả

```
count <- table(thongke$nearest_warehouse)

# Tạo nhãn cho biểu đồ tròn với cả tỉ lệ phần trăm và số lượng

labels <- paste(names(count), "\nSố lượng: ", count, "\nTỉ lệ: ", round(count/sum(count)*100, 3), "%")

# Vẽ biểu đồ tròn

pie(count, main = "Biểu đồ tròn thể hiện số lượng và tỉ lệ của các kho", labels = labels, col = c("red", "blue","green"))
```

Vẽ biểu đồ thể thể hiện số lượng và tỉ lệ các kho

BACHKHOACNCP.COM

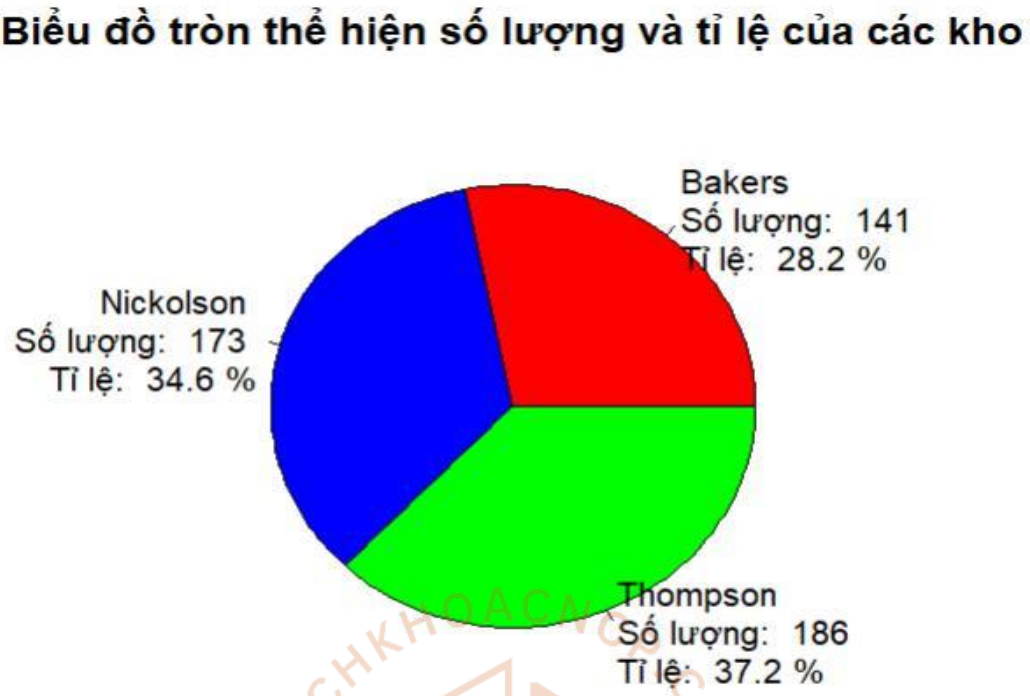

Biểu đồ cho thấy tỉ lệ hàng hóa được giữ ở từng kho. Kho Thompson giữ phần lớn hàng hóa (37.2%), tiếp theo là kho Nicholson (34.6%) và cuối cùng là kho Bakers (28.2%).

Điều này có thể cho thấy nhu cầu của khách hàng tại các khu vực gần các kho này hoặc khả năng cung cấp của từng kho.

Tìm tần suất mua hàng hàng tháng

```
library(lubridate)
purchase_freq_by_month <- table(month(thongke$date))
# In kết quả
print(purchase_freq_by_month)
```

```
 1  2  3  4  5  6  7  8  9 10 11 12
47 40 41 43 45 40 33 39 51 47 39 35
```


BACHKHOACNCP.COM

Biểu diễn tần suất mua hàng theo tháng của khách

```
barplot(purchase_freq_by_month, main = "Tần số mua hàng
theo tháng", xlab = "Tháng", ylab = "Tần số")
```

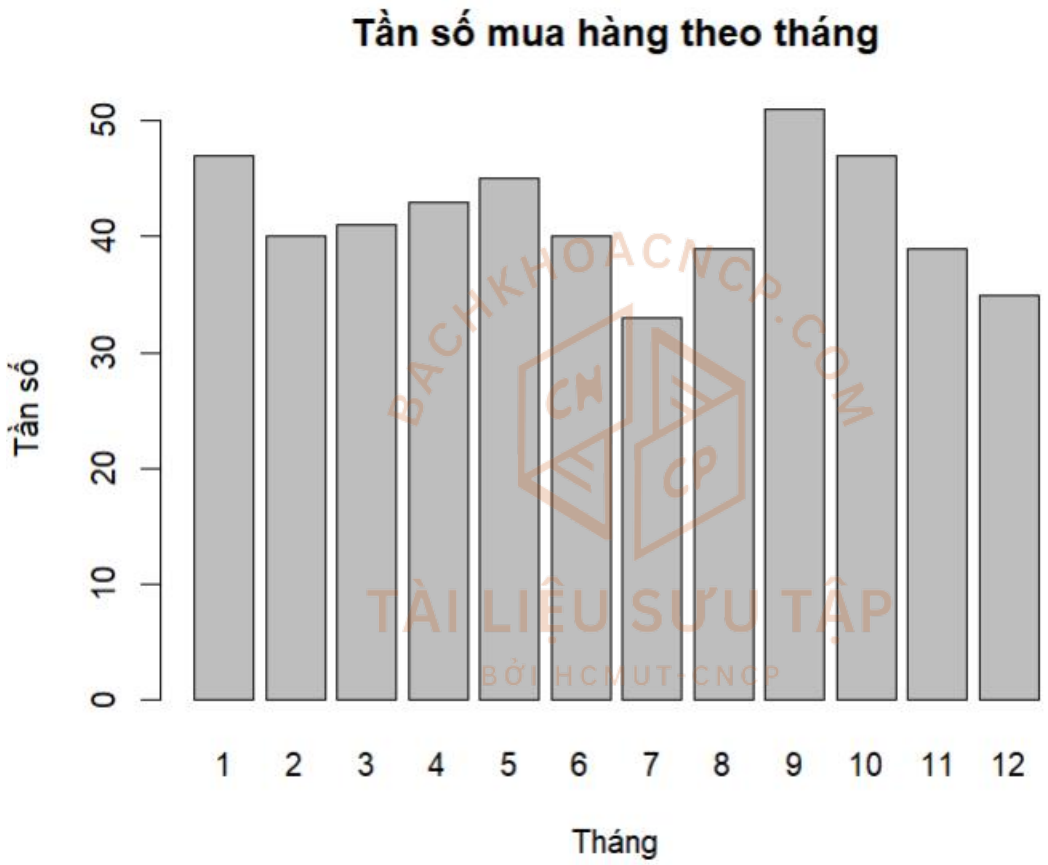

Có vẻ như có hai tháng trong năm có tần số mua hàng cao nhất, đó là tháng 1 và tháng 9. Điều này có thể cho thấy mùa mua sắm hoặc các sự kiện quan trọng diễn ra trong những tháng này.Tần số mua hàng có sự biến động rõ rệt theo từng tháng. Điều này có thể do nhiều yếu tố như xu hướng mua sắm, các chương trình khuyến mãi hoặc mùa của năm.

BACHKHOACNCP.COM

- Dữ liệu vào:

dulieu_cut=thongke[c(4,6,7,8,9,10,11,13,14,16)]

head(dulieu_cut)

=>> Lọc những biến cần thiết cho tính toán

- Xuất ra :

nearest_warehouse	order_price	delivery_charges	customer_lat	customer_long	coupon_discount	order_total	is_expedited_delivery	distance_to_nearest_warehouse	is_happy_customer
Thompson	5890	78.13	-37.80686	144.9589	10	5379.13	FALSE	1.2282863	TRUE
Nickolson	6545	77.11	-37.81492	144.9680	5	6294.86	TRUE	0.4309678	FALSE
Nickolson	2330	89.45	-37.82142	144.9639	5	2302.95	TRUE	0.5862973	TRUE
Nickolson	12690	64.79	-37.80403	144.9695	25	9582.29	FALSE	1.6211449	FALSE
Bakers	22490	105.04	-37.80287	145.0166	10	20346.04	TRUE	2.0425307	TRUE
Bakers	2090	83.97	-37.82281	145.0093	5	2069.47	FALSE	1.8899358	TRUE
Bakers	20520	58.61	-37.09163	144.9952	25	15448.61	FALSE	79.9668204	FALSE
Bakers	8790	72.01	-37.81507	144.9889	15	7543.51	FALSE	0.7924540	TRUE
Thompson	16615	75.93	-37.80326	144.9501	5	15860.18	FALSE	1.0799194	TRUE
Thompson	13270	56.17	-37.81813	144.9486	10	11999.17	FALSE	0.6216569	FALSE
Thompson	14390	80.69	-37.81496	144.9275	5	13751.19	FALSE	1.7369005	TRUE
Thompson	8770	77.74	-37.81054	144.9593	25	6655.24	FALSE	1.1017225	TRUE
Nickolson	6750	66.52	-37.81731	144.9689	5	6479.02	FALSE	0.1542271	TRUE
Nickolson	14420	58.19	-37.82160	144.9613	5	13757.19	FALSE	0.7991613	FALSE
Bakers	4910	102.82	-37.80062	145.0102	25	3785.32	TRUE	1.6817546	TRUE
Thompson	19665	78.85	-37.80625	144.9417	25	14827.60	TRUE	0.8564924	FALSE
Thompson	6865	96.00	-37.82351	144.9399	15	5931.25	TRUE	1.3612152	TRUE
Nickolson	24800	57.61	-37.81142	144.9731	15	21137.61	FALSE	0.8570942	FALSE
Bakers	8070	73.19	-37.04500	145.0059	0	8143.19	FALSE	85.1627649	TRUE
Nickolson	96385	77.51	-37.81926	144.9575	25	72366.26	FALSE	1.0589747	TRUE
Nickolson	14685	59.86	-37.80964	144.9710	0	14744.86	FALSE	1.0051748	FALSE
Nickolson	23880	90.62	-37.81658	144.9666	15	20388.62	TRUE	0.3408632	TRUE
Nickolson	13820	105.47	-37.80120	144.9699	0	13925.47	TRUE	1.9364353	TRUE

- Dữ liệu nhập

```
tinhtoan = function(x){
  av = mean(x)
  med = median(x)
  sd = sd(x)
  min = min(x)
  max = max(x)
  c(MEAN = av, SD = sd, MED = med, MIN = min, MAX = max)}
a = tinhtoan(dulieu_cut$order_price)
b = tinhtoan(dulieu_cut$delivery_charges)
c = tinhtoan(dulieu_cut$coupon_discount)
d = tinhtoan(dulieu_cut$distance_to_nearest_warehouse)
e = tinhtoan(dulieu_cut$order_total)
dinhluong = data.frame(a,b,c,d,e)
colnames(dinhluong) = c("order_price","delivery_charges","coupon_discount",
                        "distance_to_nearest_warehouse",
                        "order_total")
View(dinhluong)
```

=>> Tính toán các giá trị thống kê mô tả cho các biến order_price, delivery_charges,
, coupon_discount, order_total, distance_to_nearest.

TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

- Xuất kết quả:

	order_price	delivery_charges	coupon_discount	distance_to_nearest_warehouse	order_total
MEAN	25522.22	76.65820	10.890000	2.4886747	22564.57
SD	86333.73	14.48146	8.649134	9.9582460	75499.21
MED	12807.50	76.31000	10.000000	1.0781044	11293.96
MIN	585.00	46.35000	0.000000	0.1077811	530.54
MAX	947691.00	114.04000	25.000000	88.8772347	853012.72

- Dữ liệu nhập:

```
hist(dulieu_cut$order_price,col = "yellow")
hist(dulieu_cut$delivery_charges,col = "red")
hist(dulieu_cut$coupon_discount,col = "green")
hist(dulieu_cut$distance_to_nearest_warehouse, col = "red")
```

=>> Vẽ đồ thị tần số cho các biến: order_price, delivery_charges, order_total , coupon_discount, distance_to_nearest_warehouse.

- Kết quả:

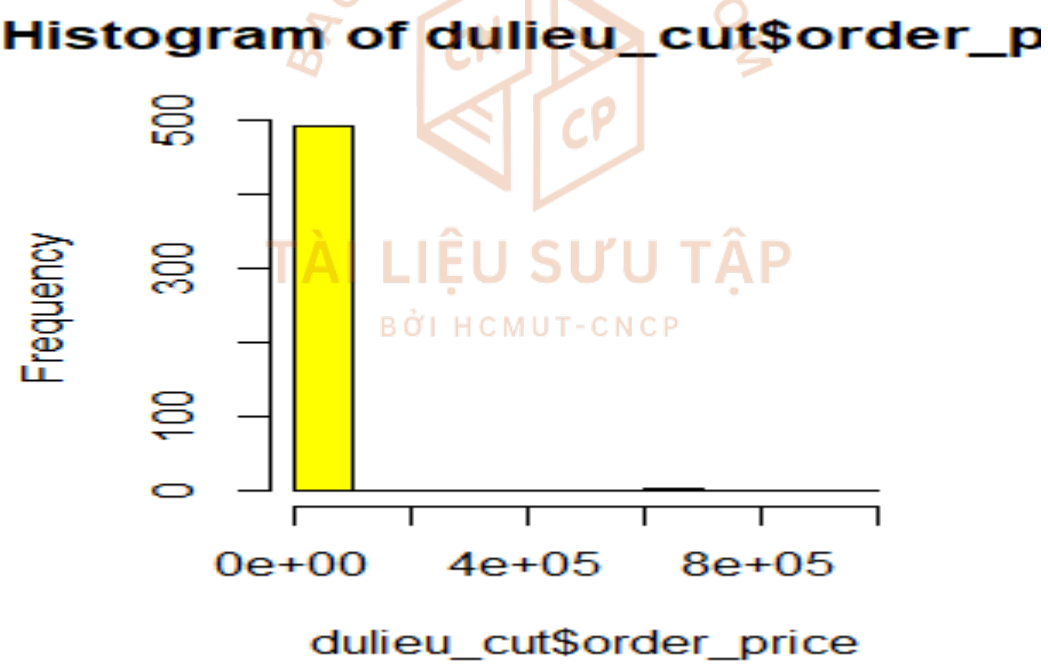

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

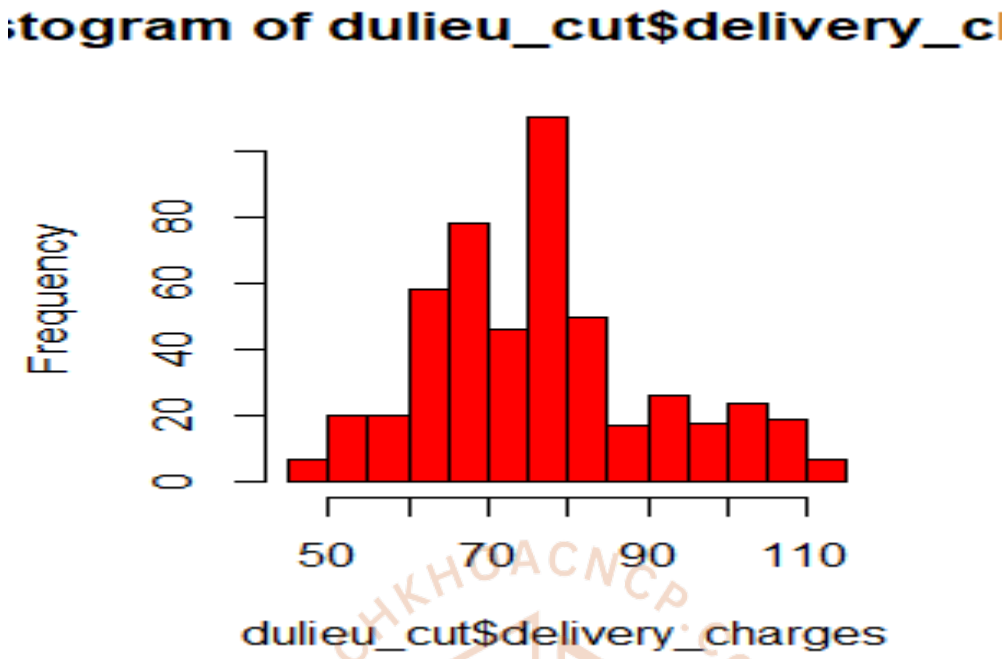

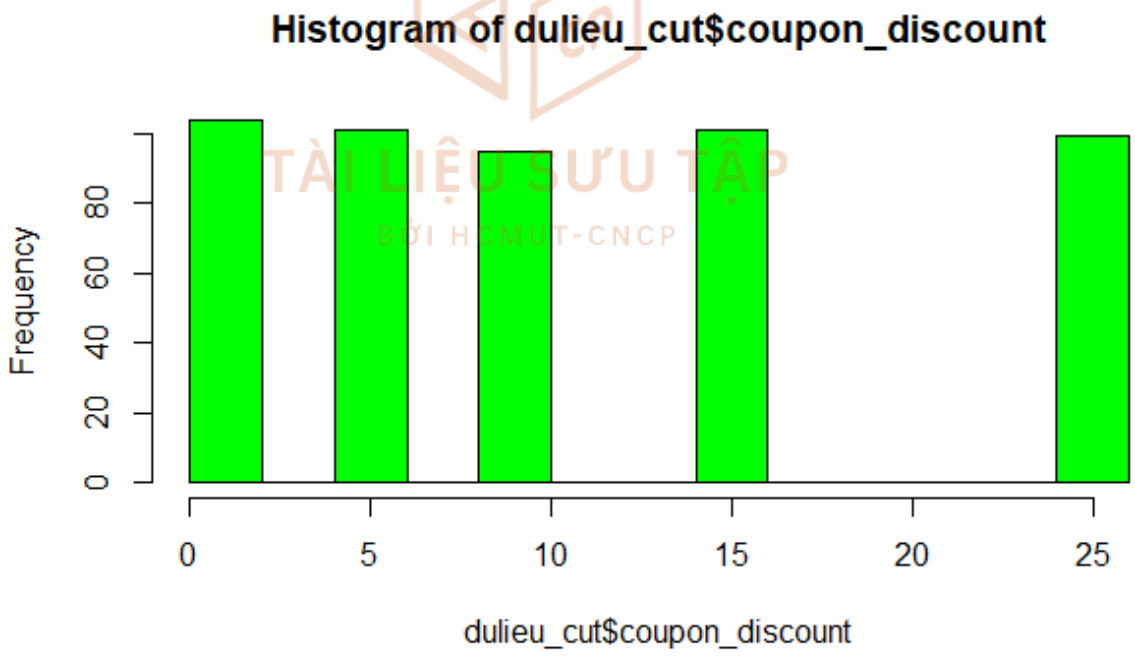

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

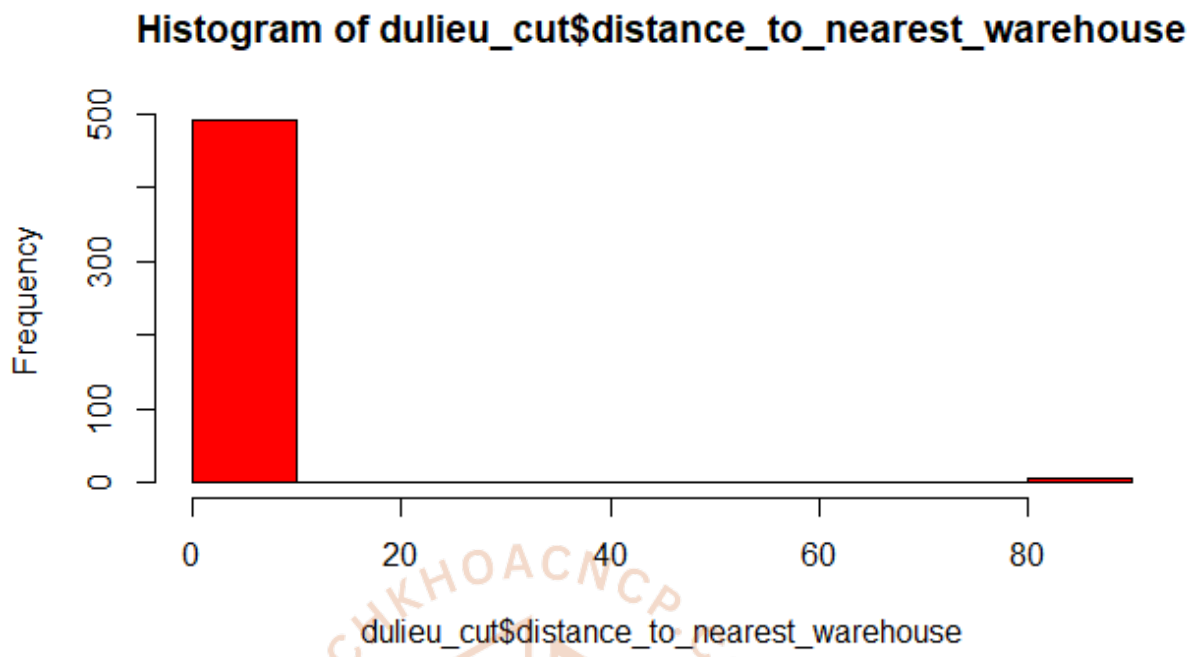

- Dữ liệu vào:

```
boxplot(dulieu_cut$order_total~ order_price,data = dulieu_cut,col = "yellow")
boxplot(dulieu_cut$order_total~ coupon_discount,data = dulieu_cut, col ="green")
```

=>> Vẽ biểu đồ phân phối thể hiện các điểm tứ phân vị cho các biến độc lập: order_price, coupon_discount theo biến phụ thuộc order_total

- Xuất kết quả:

BACHKHOACNCP.COM

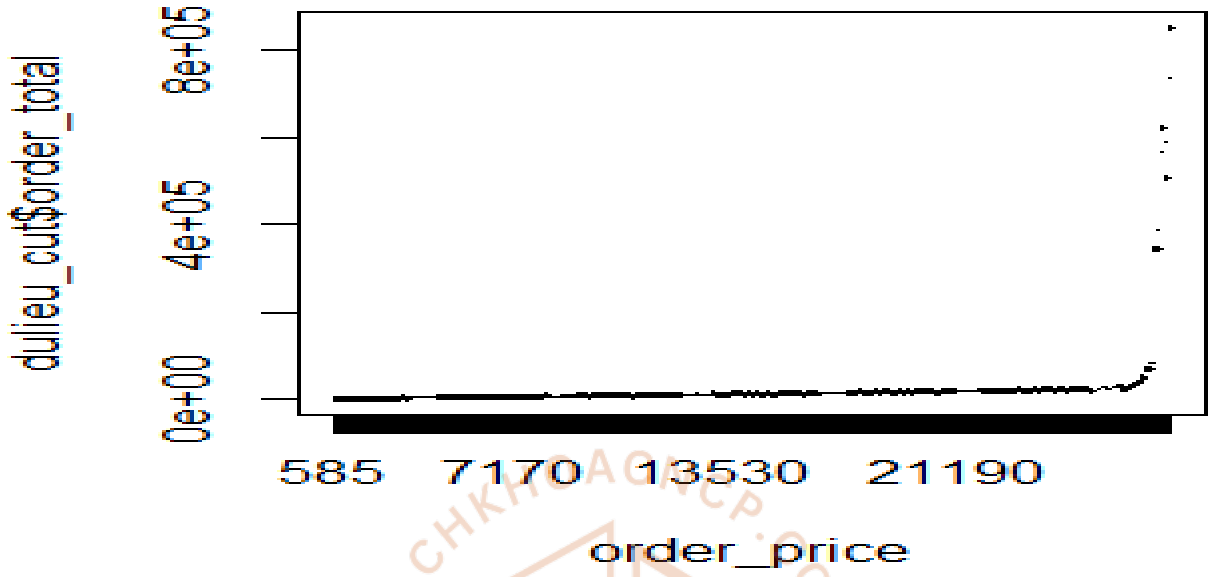

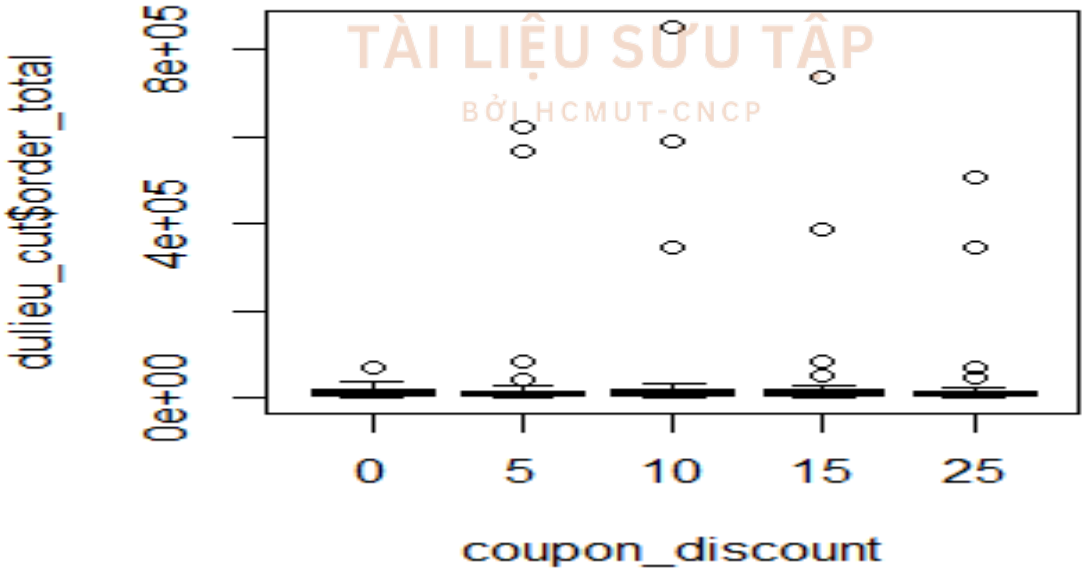

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

- Dữ liệu vào:

```
dulieu_cut1=thongke[c(6,7,10,11,14)]
dulieu_cut1= cor(dulieu_cut1)
corrplot(dulieu_cut1, type = "upper", method= "number",col = "blue")
```

=>> Tính toán các hệ số tương quan cho các biến độc lập: order_price, delivery_charges, coupon_discount, order_total, distance_to_nearest_warehouse

- Xuất ra kết quả:

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Nhận xét:
Hệ số tương quan r là hệ số thể hiện mức độ liên quan giữa các biến.
Nếu R>0 thì là tương quan thuận, nghĩa là biến này tăng thì tương ứng biến kia cũng sẽ
tăng.
- Nếu R<0 thì là tương quan nghịch, nghĩa là biến này tăng thì tương ứng biến kia sẽ giảm.
- Bên cạnh đó, về mặt giá trị, hệ số r có giá trị từ -1 đến +1 cụ thể:
+ r = 0: không tương quan;
+ $|r| \leq 0.3$: tương quan yếu;
+ $0.3 < r \leq 0.7$: tương quan trung bình;
+ $|r| \geq 0.7$: tương quan mạnh

❖ **Các ví dụ bài toán**

✓ **<u>Kiểm định 1 tổng thể</u>**

_ Mục tiêu: kiểm định giả thuyết, ước lượng tham số, tìm khoảng tin cậy, dự đoán về tổng thể, kiểm tra độ tin cậy.
Bài toán: Cửa hàng tuyên bố rằng 2/3 số khách hàng hài lòng với chất lượng sản phẩm được giao bởi cửa hàng. Trong mẫu 500 khách hàng được khảo sát thì có 359 khách hàng hài lòng về chất lượng sản phẩm.Với mức ý nghĩa 5%, số liệu trên có chứng tỏ là tuyên bố của cửa hàng là đúng hay không?
→ Giải:
Gọi p là tỉ lệ khách hàng hài lòng với chất lượng sản phẩm
Giả thuyết kiểm định H_0: p = 2/3
Giả thuyết đối H_1: $p \neq 2/3$
Ta có n = 500; $\hat{p} = \frac{359}{500} = 0{,}718$

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0.(1-p_0)}}.\sqrt{n} = \frac{0{,}718 - 2/3}{\sqrt{2/3.(1-2/3)}}.\sqrt{500} = 2{,}435$$

$$\alpha = 0{,}05 \Rightarrow Z_{\frac{\alpha}{2}} = Z_{0{,}025} = 1{,}96$$

_ Kết quả: $|Z| > Z_{\frac{\alpha}{2}} \Leftrightarrow 2{,}435 > 1{,}96$

Hay Z $\in$ miền bác bỏ $W = \left(-\infty; -Z_{\frac{\alpha}{2}}\right) \cup \left(Z_{\frac{\alpha}{2}}; +\infty\right) \Leftrightarrow 2{,}435 \in W$
$= (-\infty; -1{,}96) \cup (1{,}96; +\infty)$

_ Nhận xét: có cơ sở bác bỏ giả thuyết H_0.

BACHKHOACNCP.COM

_ Kết luận: Với mức ý nghĩa 5%, có thể bác bỏ tuyên bố của cửa hàng về rằng 2/3 số khách hàng hài lòng với chất lượng sản phẩm được giao bởi cửa hàng

Phần code

```
# Số lượng khách hàng
n <- 500

# Tỉ lệ dự kiến theo giả thuyết H0
p0 <- 2/3

# Tỉ lệ quan sát được trong mẫu
p_qsm <- 359/500

# Độ lệch chuẩn
se <- sqrt((p0 * (1 - p0)) / n)

# Giá trị kiểm định thống kê
z <- (p_qsm - p0) / se

# Mức ý nghĩa
alpha <- 0.05

# Giá trị tương ứng với mức ý nghĩa
z_1 <- qnorm(1 - alpha/2)

# In kết quả
cat("Giá trị kiểm định:", z, "\n")
cat("giá trị tương ứng mức ý nghĩa:", z_1, "\n")

# Kiểm tra điều kiện và đưa ra kết luận
if (abs(z) < z_1) {
  cat("Z không nằm trong miền bác bỏ H0\n")
  cat("Chưa có đủ bằng chứng để bác bỏ giả thuyết H0\n")
} else {
  cat("Z nằm trong miền bác bỏ H0\n")
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
}
```

Kết quả chạy code:

BACHKHOACNCP.COM

```
> # Số lượng khách hàng
> n <- 500

> # Tỉ lệ dự kiến theo giả thuyết H0
> p0 <- 2/3

> # Tỉ lệ quan sát được trong mẫu
> p_qsm <- 359/500

> # Độ lệch chuẩn
> se <- sqrt((p0 * (1 - p0)) / n)

> # Giá trị kiểm định thống kê
> z <- (p_qsm - p0) / se

> # Mức ý nghĩa
> alpha <- 0.05

> # Giá trị tương ứng với mức ý nghĩa
> z_1 <- qnorm(1 - alpha/2)

> # In kết quả
> cat("Giá trị kiểm định:", z, "\n")
Giá trị kiểm định: 2.434954

> cat("giá trị tương ứng mức ý nghĩa:", z_1, "\n")
giá trị tương ứng mức ý nghĩa: 1.959964

> # Kiểm tra điều kiện và đưa ra kết luận
> if (abs(z) < z_1) {
+   cat("Z không nằm trong miền bác bỏ H0\n")
+   cat("Chưa có đủ bằng chứng để bác bỏ ..." ... [TRUNCATED]
Z nằm trong miền bác bỏ H0
Có đủ bằng chứng để bác bỏ giả thuyết H0
```

Giải thích code :

```
# Độ lệch chuẩn
se <- sqrt((p0 * (1 - p0)) / n)

# Giá trị kiểm định thống kê
z <- (p_qsm - p0) / se
```

Tương đương với phương trình $Z = \frac{\hat{p}-p_0}{\sqrt{p_0.(1-p_0)}} . \sqrt{n}$

BACHKHOACNCP.COM

Ta có $|Z| > Z_{alpha/2}$ (2.434954 >1,959964) nên xuất ra màn hình là Z nằm trong miề n bác bỏ H_0
=>> Có đủ bằng chứng để bác bỏ giả thuyết H_0

- ✓ **Kiểm định 2 tổng thể**

Bài toán: Một cuộc khảo sát về độ hài lòng của khách hàng giữa hai kho Bakers và Thompson ta thu được số liệu : Kho Bakers : Khảo sát 119 khách hàng có 80 khách hàng hài lòng với đơn hàng. Kho Thompson : Khảo sát 197 khách hàng thì có 142 khách hàng hài lòng với đơn hàng : Với mức ý nghĩa 5% có thể khẳng định đơn hàng ở kho Thompson tốt hơn ở kho Bakers hay không.

Gọi p_1,p_2 là tỷ lệ khách hàng hài lòng ở 2 kho Bakers và Thompson

Ta có giả thuyết

$H_0 : p_1 = p_2$

$H_1 : p_1 < p_2$

Theo đề bài ta có :

$$n = 316,\ f_1 = \frac{m_1}{n_1} = \frac{80}{119},\ f_2 = \frac{m_2}{n_2} = \frac{142}{197}$$

$$\bar{f} = \frac{m_1+m_2}{n_1+n_2} = \frac{80+142}{119+197} = \frac{111}{158};\ \bar{n} = \frac{n_1n_2}{n_1+n_2} = \frac{119.197}{119+197} = \frac{23443}{316}$$

Mức ý nghĩa: 5% => $\Phi(z_\alpha) = 1- \alpha = 0.95$

Tra bảng phân phối chuẩn ta được: $z_{\square} = 1.645$

Vậy miền bác bỏ H_0 là :

$RR = (-\infty ; -z_\alpha) = (-\infty ; -1.645)$

Giá trị kiểm định thống kê (tiêu chuẩn kiểm định) :

$$Z_{qs} = \frac{f_1-f_2}{\sqrt{\frac{\bar{f}(1-\bar{f})}{\bar{n}}}} = \frac{\frac{80}{119} - \frac{142}{197}}{\sqrt{\frac{\frac{111}{158}.(1-\frac{111}{158})}{\frac{23443}{316}}}} = -0.9146 \notin RR$$ nên chưa đủ dữ kiện bác bỏ H_0

BACHKHOACNCP.COM

+Phần code :

```
# Dữ liệu
n1 <- 119
m1 <- 80
f1 <- m1 / n1

n2 <- 197
m2 <- 142
f2 <- m2 / n2

f <- (n1 * f1 + n2 * f2) / (n1 + n2)

# tiêu chuẩn kiểm định
z <- (f1 - f2) / sqrt(f * (1 - f) * (1/n1 + 1/n2))

# Mức ý nghĩa
alpha <- 0.05

# giá trị tương ứng với mức ý nghĩa
z_alpha <- qnorm(1 - alpha)

# In kết quả
cat("giá trị tiêu chuẩn kiểm định:", z, "\n")
cat("giá trị tương ứng mức ý nghĩa:", z_alpha, "\n")

# Kiểm tra điều kiện và đưa ra kết luận
if (z < -z_alpha) {
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Tỷ lệ khách hàng hài lòng ở kho Thompson có thể cao hơn ở kho Bakers\n")
} else {
  cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Không có sự khác biệt đáng kể giữa tỷ lệ khách hàng hài lòng ở hai kho\n")
}
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

+Kết quả xuất ra màn hình:

BACHKHOACNCP.COM

```
> m1 <- 80

> f1 <- m1 / n1

> n2 <- 197

> m2 <- 142

> f2 <- m2 / n2

> f <- (n1 * f1 + n2 * f2) / (n1 + n2)

> # tiêu chuẩn kiểm định
> z <- (f1 - f2) / sqrt(f * (1 - f) * (1/n1 + 1/n2))

> # Mức ý nghĩa
> alpha <- 0.05

> # giá trị tương ứng với mức ý nghĩa
> z_alpha <- qnorm(1 - alpha)

> # In kết quả
> cat("giá trị tiêu chuẩn kiểm định:", z, "\n")
giá trị tiêu chuẩn kiểm định: -0.914616

> cat("giá trị tương ứng mức ý nghĩa:", z_alpha, "\n")
giá trị tương ứng mức ý nghĩa: 1.644854

> # Kiểm tra điều kiện và đưa ra kết luận
> if (z < -z_alpha) {
+   cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
+   cat("Tỷ lệ khách hàng hài lò ..." ... [TRUNCATED]
Không có đủ bằng chứng để bác bỏ giả thuyết H0
Không có sự khác biệt đáng kể giữa tỷ lệ khách hàng hài lòng ở hai kho
>
```

Giải thích :

Ta có giá trị kiểm định khi tính ra là Z= -0,914616 và nhỏ hơn Z_{alpha} (1,644854)

=>> Nên xuất ra màn hình không có bằng chứng bác bỏ H0

=>> Không có sự khác biệt đáng kể giữa tỷ lệ khách hàng hài lòng ở 2 kho

- ✓ **<u>Anova</u>**

Giả định của mô hình Anova

BACHKHOACNCP.COM

```r
#install.packages("car")
library(car)
# Dữ liệu
thompson <- c(6, 9, 8, 7, 7, 13, 6, 6, 6, 10, 8, 6)
nickolson <- c(9, 8, 5, 9, 12, 6, 7, 11, 10, 8, 9, 3)
bakers <- c(5, 0, 6, 6, 5, 6, 3, 7, 6, 8, 6, 2)

# Kiểm tra phân phối chuẩn
shapiro_test_thompson <- shapiro.test(thompson)
shapiro_test_nickolson <- shapiro.test(nickolson)
shapiro_test_bakers <- shapiro.test(bakers)

# Chuyển đổi dữ liệu thành một dạng phù hợp
data_for_levene <- stack(list(Thompson=thompson, Nickolson=nickolson, Bakers=bakers))

# Kiểm tra đồng nhất của phương sai
levene_test <- leveneTest(values ~ ind, data=data_for_levene)

# Kiểm tra ANOVA
anova_test <- aov(c(thompson, nickolson, bakers) ~ rep(c("Thompson", "Nickolson", "Bakers"), each = 12))

# In kết quả
cat("Kiểm tra phân phối chuẩn - Thompson:", shapiro_test_thompson$p.value, "\n")
cat("Kiểm tra phân phối chuẩn - Nickolson:", shapiro_test_nickolson$p.value, "\n")
cat("Kiểm tra phân phối chuẩn - Bakers:", shapiro_test_bakers$p.value, "\n")
print("Kiểm tra đồng nhất phương sai:")
print(levene_test)
# In thông tin cụ thể từ kết quả ANOVA
print("Kiểm tra ANOVA:")
print(anova_test)
```

```r
# Tạo dataframe
data <- data.frame(
  Group = rep(c("Thompson", "Nickolson", "Bakers"), each = 12),
  Value = c(thompson, nickolson, bakers)
)

# Kiểm tra độc lập giữa các nhóm
t_test_A_B <- t.test(Value ~ Group, data = data[data$Group %in% c("Thompson", "Nickolson"),], var.equal = TRUE)
t_test_A_C <- t.test(Value ~ Group, data = data[data$Group %in% c("Thompson", "Bakers"),], var.equal = TRUE)
t_test_B_C <- t.test(Value ~ Group, data = data[data$Group %in% c("Nickolson", "Bakers"),], var.equal = TRUE)

print("Kiểm tra độc lập giữa nhóm A và B:")
print(t_test_A_B)
print("Kiểm tra độc lập giữa nhóm A và C:")
print(t_test_A_C)
print("Kiểm tra độc lập giữa nhóm B và C:")
print(t_test_B_C)

# Kiểm tra sự không tương quan của các phần tử phần dư
aov_test <- aov(Value ~ Group, data = data)
durbin_watson_test <- durbinWatsonTest(aov_test)

print("Kiểm tra sự không tương quan của các phần tử phần dư:")
print(durbin_watson_test)
```

Kết quả xuất ra

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
> #install.packages("car")
> library(car)

> # Dữ liệu
> thompson <- c(6, 9, 8, 7, 7, 13, 6, 6, 6, 10, 8, 6)

> nickolson <- c(9, 8, 5, 9, 12, 6, 7, 11, 10, 8, 9, 3)

> bakers <- c(5, 0, 6, 6, 5, 6, 3, 7, 6, 8, 6, 2)

> # Kiểm tra phân phối chuẩn
> shapiro_test_thompson <- shapiro.test(thompson)

> shapiro_test_nickolson <- shapiro.test(nickolson)

> shapiro_test_bakers <- shapiro.test(bakers)

> # Chuyển đổi dữ liệu thành một dạng phù hợp
> data_for_levene <- stack(list(Thompson=thompson, Nickolson=nickolson, Bakers=bakers))

> # Kiểm tra đồng nhất của phương sai
> levene_test <- leveneTest(values ~ ind, data=data_for_levene)

> # Kiểm tra ANOVA
> anova_test <- aov(c(thompson, nickolson, bakers) ~ rep(c("Thompson", "Nickolson", "Bakers"), each = 12))

> # In kết quả
> cat("Kiểm tra phân phối chuẩn - Thompson:", shapiro_test_thompson$p.value, "\n")
Kiểm tra phân phối chuẩn - Thompson: 0.00948922

> cat("Kiểm tra phân phối chuẩn - Nickolson:", shapiro_test_nickolson$p.value, "\n")
Kiểm tra phân phối chuẩn - Nickolson: 0.9274334
```


```
> cat("Kiểm tra phân phối chuẩn - Nickolson:", shapiro_test_nickolson$p.value, "\n")
Kiểm tra phân phối chuẩn - Nickolson: 0.9274334
```


```
> cat("Kiểm tra phân phối chuẩn - Bakers:", shapiro_test_bakers$p.value, "\n")
Kiểm tra phân phối chuẩn - Bakers: 0.07414758

> print("Kiểm tra đồng nhất phương sai:")
[1] "Kiểm tra đồng nhất phương sai:"

> print(levene_test)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  2  0.2317 0.7945
      33

> # In thông tin cụ thể từ kết quả ANOVA
> print("Kiểm tra ANOVA:")
[1] "Kiểm tra ANOVA:"

> print(anova_test)
Call:
   aov(formula = c(thompson, nickolson, bakers) ~ rep(c("Thompson",
    "Nickolson", "Bakers"), each = 12))

Terms:
                rep(c("Thompson", "Nickolson", "Bakers"), each = 12) Residuals
Sum of Squares                                           67.16667 177.58333
Deg. of Freedom                                                 2        33

Residual standard error: 2.319766
Estimated effects may be unbalanced
```


BACHKHOACNCP.COM

1) Kiểm tra phân phối chuẩn

- Thompson: p-value = 0.00948922

-Mức ý nghĩa (p-value) nhỏ hơn mức ý nghĩa thông thường 0.05.

Kết luận: Có đủ bằng chứng để bác bỏ giả định về phân phối chuẩn. Dữ liệu của nhóm "Thompson" không tuân theo phân phối chuẩn.

-Kiểm tra phân phối chuẩn - Nickolson: p-value = 0.9274334

Mức ý nghĩa (p-value) lớn hơn mức ý nghĩa thông thường 0.05.

Kết luận: Không có đủ bằng chứng để bác bỏ giả định về phân phối chuẩn. Dữ liệu của nhóm "Nickolson" có thể được giả định tuân theo phân phối chuẩn.

-Kiểm tra phân phối chuẩn - Bakers: p-value = 0.07414758

Mức ý nghĩa (p-value) gần đến mức ý nghĩa thông thường 0.05.

Kết luận: Không có đủ bằng chứng để bác bỏ giả định về phân phối chuẩn. Dữ liệu của nhóm "Bakers" có thể được giả định tuân theo phân phối chuẩn.

2) Kiểm tra đồng nhất phương sai:

-Giải thích:

Df: Số độ tự do cho kiểm tra.

F value: Giá trị thống kê F.

Pr(>F): Giá trị p-value.

-Kết luận:

Mức ý nghĩa (p-value) của kiểm tra Levene là 0.7945, lớn hơn mức ý nghĩa thông thường 0.05.

Kết luận: Không có đủ bằng chứng để bác bỏ giả định về đồng nhất phương sai. Các nhóm có thể được giả định có độ biến động giống nhau.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

```
> # Tạo dataframe
> data <- data.frame(
+   Group = rep(c("Thompson", "Nickolson", "Bakers"), each = 12),
+   Value = c(thompson, nickolson, bakers)
+ .... [TRUNCATED]

> # Kiểm tra độc lập giữa các nhóm
> t_test_A_B <- t.test(Value ~ Group, data = data[data$Group %in% c("Thompson", "Nickolson"),], var.equal = TRUE)

> t_test_A_C <- t.test(Value ~ Group, data = data[data$Group %in% c("Thompson", "Bakers"),], var.equal = TRUE)

> t_test_B_C <- t.test(Value ~ Group, data = data[data$Group %in% c("Nickolson", "Bakers"),], var.equal = TRUE)

> print("Kiểm tra độc lập giữa nhóm A và B:")
[1] "Kiểm tra độc lập giữa nhóm A và B:"

> print(t_test_A_B)

        Two Sample t-test

data:  Value by Group
t = 0.43415, df = 22, p-value = 0.6684
alternative hypothesis: true difference in means between group Nickolson and group Thompson is not equal to 0
95 percent confidence interval:
 -1.573696  2.407029
sample estimates:
mean in group Nickolson  mean in group Thompson
               8.083333                7.666667


> print("Kiểm tra độc lập giữa nhóm A và C:")
[1] "Kiểm tra độc lập giữa nhóm A và C:"

> print(t_test_A_C)


        Two Sample t-test

data:  Value by Group
t = -2.9665, df = 22, p-value = 0.007126
alternative hypothesis: true difference in means between group Bakers and group Thompson is not equal to 0
95 percent confidence interval:
 -4.5309399 -0.8023934
sample estimates:
  mean in group Bakers mean in group Thompson
              5.000000               7.666667


> print("Kiểm tra độc lập giữa nhóm B và C:")
[1] "Kiểm tra độc lập giữa nhóm B và C:"

> print(t_test_B_C)

        Two Sample t-test

data:  Value by Group
t = -3.1445, df = 22, p-value = 0.004708
alternative hypothesis: true difference in means between group Bakers and group Nickolson is not equal to 0
95 percent confidence interval:
 -5.116882 -1.049785
sample estimates:
   mean in group Bakers mean in group Nickolson
               5.000000                8.083333


> # Kiểm tra sự không tương quan của các phần tử phần dư
> aov_test <- aov(Value ~ Group, data = data)

> durbin_watson_test <- durbinWatsonTest(aov_test)
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
HCMUT-CNCP

BACHKHOACNCP.COM

3) Kiểm tra độc lập giữa các nhóm :

- Xét A và B:

+Mô tả Kết quả:
-t-value: 0.43415
-Độ tự do (df): 22
-p-value: 0.6684
-Khoảng tin cậy 95% cho sự chênh lệch giữa trung bình hai nhóm: (-1.573696, 2.407029)
-Estimates (ước lượng):
+ Mean của nhóm "Nickolson": 8.083333
+ Mean của nhóm "Thompson": 7.666667
*Giải thích Kết quả:
-t-value: Là giá trị thống kê t, đo lường sự chênh lệch giữa trung bình của hai nhóm dựa trên mẫu dữ liệu. Trong trường hợp này, t-value là 0.43415.
-p-value: Là giá trị xác suất, đo lường xác suất của việc nhận được giá trị t hiện tại hoặc lớn hơn nếu giả định rằng không có sự chênh lệch giữa các nhóm (null hypothesis). Ở đây, p-value là 0.6684.
-95% confidence interval: Là khoảng tin cậy 95% cho sự chênh lệch giữa trung bình của hai nhóm. Trong trường hợp này, khoảng tin cậy là từ -1.573696 đến 2.407029.
-Estimates (ước lượng): Là giá trị trung bình của mỗi nhóm trong mẫu dữ liệu. Trong trường hợp này, mean của nhóm "Nickolson" là 8.083333 và mean của nhóm "Thompson" là 7.666667.
-Alternative Hypothesis (Giả thuyết thay thế):
"True difference in means between group Nickolson and group Thompson is not equal to 0."
Tức là, giả định rằng sự chênh lệch thực sự giữa trung bình của hai nhóm "Nickolson" và "Thompson" không bằng 0.
*Kết luận:
-Mức ý nghĩa (p-value) là 0.6684, lớn hơn mức ý nghĩa thông thường 0.05.
-Không có đủ bằng chứng để bác bỏ giả định rằng sự chênh lệch giữa trung bình của hai nhóm là bằng 0.

- Xét A và C:

+ t-value: -2.9665

+ Độ tự do (df): 22

BACHKHOACNCP.COM

+ p-value: 0.007126

+ Khoảng tin cậy 95% cho sự chênh lệch giữa trung bình hai nhóm: (-4.5309399, -0.8023934)

+ Estimates (ước lượng):

Mean của nhóm "Bakers": 5.000000

Mean của nhóm "Thompson": 7.666667

- Giải thích Kết quả:

-t-value: Là giá trị thống kê t, đo lường sự chênh lệch giữa trung bình của hai nhóm dựa trên mẫu dữ liệu. Trong trường hợp này, t-value là -2.9665.

-p-value: Là giá trị xác suất, đo lường xác suất của việc nhận được giá trị t hiện tại hoặc nhỏ hơn nếu giả định rằng không có sự chênh lệch giữa các nhóm (null hypothesis). Ở đây, p-value là 0.007126.

-95% confidence interval: Là khoảng tin cậy 95% cho sự chênh lệch giữa trung bình của hai nhóm. Trong trường hợp này, khoảng tin cậy là từ -4.5309399 đến -0.8023934.

-Estimates (ước lượng): Là giá trị trung bình của mỗi nhóm trong mẫu dữ liệu. Trong trường hợp này, mean của nhóm "Bakers" là 5.000000 và mean của nhóm "Thompson" là 7.666667.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

-Alternative Hypothesis (Giả thuyết thay thế):

"True difference in means between group Bakers and group Thompson is not equal to 0."

Tức là, giả định rằng sự chênh lệch thực sự giữa trung bình của hai nhóm "Bakers" và "Thompson" không bằng 0.

- Kết luận:

- Mức ý nghĩa (p-value) là 0.007126, nhỏ hơn mức ý nghĩa thông thường 0.05.

-Có đủ bằng chứng để bác bỏ giả định rằng sự chênh lệch giữa trung bình của hai nhóm là bằng 0.

- Xét B và C:

BACHKHOACNCP.COM

* Mô tả Kết quả:

- t-value: -3.1445

- Độ tự do (df): 22

- p-value: 0.004708

- Khoảng tin cậy 95% cho sự chênh lệch giữa trung bình hai nhóm: (-5.116882, -1.049785)

- Estimates (ước lượng):

+ Mean của nhóm "Bakers": 5.000000

+ Mean của nhóm "Nickolson": 8.083333

- Giải thích Kết quả:
  - t-value: Là giá trị thống kê t, đo lường sự chênh lệch giữa trung bình của hai nhóm dựa trên mẫu dữ liệu. Trong trường hợp này, t-value là -3.1445.
  - p-value: Là giá trị xác suất, đo lường xác suất của việc nhận được giá trị t hiện tại hoặc nhỏ hơn nếu giả định rằng không có sự chênh lệch giữa các nhóm (null hypothesis). Ở đây, p-value là 0.004708.
  - 95% confidence interval: Là khoảng tin cậy 95% cho sự chênh lệch giữa trung bình của hai nhóm. Trong trường hợp này, khoảng tin cậy là từ -5.116882 đến -1.049785.
  - Estimates (ước lượng): Là giá trị trung bình của mỗi nhóm trong mẫu dữ liệu. Trong trường hợp này, mean của nhóm "Bakers" là 5.000000 và mean của nhóm "Nickolson" là 8.083333.
  - Alternative Hypothesis (Giả thuyết thay thế):

"True difference in means between group Bakers and group Nickolson is not equal to 0."

Tức là, giả định rằng sự chênh lệch thực sự giữa trung bình của hai nhóm "Bakers" và "Nickolson" không bằng 0.

- Kết luận:
  - Mức ý nghĩa (p-value) là 0.004708, nhỏ hơn mức ý nghĩa thông thường 0.05.
  - Có đủ bằng chứng để bác bỏ giả định rằng sự chênh lệch giữa trung bình của hai nhóm là bằng 0.

BACHKHOACNCP.COM

```
> print("Kiểm tra sự không tương quan của các phần tử phần dư:")
[1] "Kiểm tra sự không tương quan của các phần tử phần dư:"

> print(durbin_watson_test)
 lag Autocorrelation D-W Statistic p-value
   1      -0.1467621      2.227202   0.682
 Alternative hypothesis: rho != 0
>
```

4) Kiểm tra sự không tương quan của các phần tử dư:

- lag: Đây là số lags (độ trễ) được sử dụng trong kiểm tra. Trong trường hợp này, lag được đặt là 1.

- Autocorrelation: Đây là hệ số tương quan tự do giữa các phần tử phần dư. Trong trường hợp này, autocorrelation là -0.1467621.

- D-W Statistic (Durbin-Watson Statistic): Đây là giá trị thống kê Durbin-Watson, được tính dựa trên tỷ lệ thay đổi của phần dư. Trong trường hợp này, D-W Statistic là 2.227202.

- p-value: Đây là giá trị xác suất được sử dụng để đánh giá xem có đủ bằng chứng để bác bỏ giả định không tương quan hay không. Trong trường hợp này, p-value là 0.732.

- Alternative hypothesis: Đây là giả định thay thế. Trong trường hợp này, giả định thay thế là "rho != 0," ngụ ý rằng tồn tại tương quan không tuyến tính giữa các phần tử phần dư.

BACHKHOACNCP.COM TÀI LIỆU SƯU TẬP BỞI HCMUT-CNCP

- Giải thích:
  - Nếu giả định không tương quan là đúng , giá trị autocorrelation sẽ xấp xỉ 0. Trong trường hợp này, giá trị autocorrelation là -0.1467621, nhỏ hơn 0, nhưng p-value (0.732) lớn hơn mức ý nghĩa thường được sử dụng (0.05).
  - Do đó, chúng ta không có đủ bằng chứng để bác bỏ giả định không tương quan, và có thể chấp nhận giả định rằng các phần tử phần dư không có tương quan tuyến tính với nhau.

=>> Các số liệu này chỉ mang tính tham khảo.

Bài toán: Một khảo sát được thực hiện nhằm xem xét sự yêu cầu giao hàng nhanh của 3 kho hàng.

Kết quả thu thập của 12 tháng năm 2019:

BACHKHOACNCP.COM

Tháng	1	2	3	4	5	6	7	8	9	10	11	12
Thompson	6	9	8	7	7	13	6	6	6	10	8	6
Nickolson	9	8	5	9	12	6	7	11	10	8	9	3
Bakers	5	0	6	6	5	6	3	7	6	8	6	2

Hãy sử dụng phương pháp Anova để so sánh sự yêu cầu giao hàng nhanh của 3 kho hàng có khác nhau hay không ? Với mức ý nghĩa 5%

Giải:

Dùng **EXCEL**:

D	E	F	G
Tháng	Thompson	Nickolson	Bakers
1	6	9	5
2	9	8	0
3	8	5	6
4	7	9	6
5	7	12	5
6	13	6	6
7	6	7	3
8	6	11	7
9	6	10	6
10	10	8	8
11	8	9	6
12	6	3	2

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Anova: Single Factor

SUMMARY

Groups	*Count*	*Sum*	*Average*	*Variance*
Thompson	12	92	7.666666667	4.606060606
Nickolson	12	97	8.083333333	6.446969697
Bakers	12	60	5	5.090909091

ANOVA

Source of Variation	*SS*	*df*	*MS*	*F*	*P-value*	*F crit*
Between Groups	67.16666667	2	33.58333333	6.240732051	0.005025876	3.284918
Within Groups	177.5833333	33	5.381313131			
Total	244.75	35				

BACHKHOACNCP.COM

Giải tay: ***(sai số do làm tròn)***

Đặt giả thuyết

H_0 sự yêu cầu giao hàng nhanh của 3 kho hàng không có sự khác biệt

H_1 sự yêu cầu giao hàng nhanh của 3 kho hàng là có sự khác biệt

-Tính giá trị trung bình:

+Trung bình từng cột:

- $\sum x_1 = 92$; $\sum x_2 = 97$; $\sum x_3 = 60$
- $n_1 = n_2 = n_3 = 12$
- $\overline{x_1} = \frac{23}{3}$; $\overline{x_2} = \frac{97}{12}$; $\overline{x_3} = 5$
- $s_1 = 2.14617348$; $s_2 = 2.539088359$; $s_3 = 2.256304299$

+Trung bình chung:

$$\bar{x} = \frac{\sum x_1 + \sum x_2 + \sum x_3}{n_1 + n_2 + n_3} = \frac{83}{12}$$

-Tính tổng các chênh lệch bình phương:

+Tổng độ lệch bình phương nội bộ 3 kho hàng

- $SS_1 = (n_1 - 1)S_1^2 = 50.66666759$
- $SS_2 = (n_2 - 1)S_2^2 = \frac{851}{12}$
- $SS_3 = (n_3 - 1)S_3^2 = 56$

=> SSW = $SS_1 + SS_2 + SS_3 = 177.58(3) = \frac{2131}{12}$

$$SSB = \sum_{j=1}^{k} n_j(\bar{x}_j - \bar{x})^2 = 12(\frac{23}{3} - \frac{83}{12})^2 + 12(\frac{97}{12} - \frac{83}{12})^2 + 12(5 - \frac{83}{12})^2$$

$$= 67.16666667 = \frac{403}{6}$$

+Tổng độ lệch bình phương chung:

SST = SSW + SSB = 244.75

-Tính các phương sai:

$$MSW = \frac{SSW}{N-k} = 5.38(13) = \frac{2131}{396}$$

$$MSB = \frac{SSB}{k-1} = 33.58(3) = \frac{403}{12}$$

BACHKHOACNCP.COM

-Giá trị kiểm định $F = \frac{MSB}{MSW} = 6.24073205 \ldots = \frac{13299}{2131}$

-Với mức ý nghĩa 5%:

$$F_{k-1;N-k;\alpha} = F_{2;33;0.05} = 3.28491765103829 \approx 3.284918$$

F > $F_{2;33;0.05}$

Khi đó bác bỏ giả thuyết H_0

Vậy sự yêu cầu giao hàng nhanh của 3 kho hàng là khác nhau.

Phần code:

```
# Dữ liệu
thompson <- c(6, 9, 8, 7, 7, 13, 6, 6, 6, 10, 8, 6)
nickolson <- c(9, 8, 5, 9, 12, 6, 7, 11, 10, 8, 9, 3)
bakers <- c(5, 0, 6, 6, 5, 6, 3, 7, 6, 8, 6, 2)

# Tạo dataframe từ dữ liệu
data <- data.frame(
  Customer = rep(c("Thompson", "Nickolson", "Bakers"), each = 12),
  Month = rep(1:12, times = 3),
  Requests = c(thompson, nickolson, bakers)
)
# Tạo dataframe với biến 'Customer' là factor
data$Customer <- factor(data$Customer)
# Kiểm định Anova
model <- aov(Requests ~ Customer, data = data)
summary(model)

# Kiểm tra mức ý nghĩa
alpha <- 0.05
p_value <- summary(model)[[1]]$"Pr(>F)"[1]

# In kết quả
cat("P-value:", p_value, "\n")

# Kiểm tra điều kiện và đưa ra kết luận
if (p_value < alpha) {
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Có sự khác biệt đáng kể về sự yêu cầu giao hàng nhanh giữa ít nhất một cặp khách hàng\n")
} else {
  cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Không có sự khác biệt đáng kể về sự yêu cầu giao hàng nhanh giữa các khách hàng\n")
}
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

```r
#install.packages("multcomp")
library(multcomp)

# Kiểm tra sự khác nhau
if (p_value < alpha) {
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Có sự khác nhau giữa sự yêu cầu giao hàng nhanh của ba khách hàng\n")

# Tính khoảng tin cậy 95% cho sự khác nhau
conf_int <- TukeyHSD(model, "Customer", conf.level = 0.95)

# In khoảng tin cậy
print(conf_int)

# Tìm nhóm khác nhau
diff_groups <- glht(model, linfct = mcp(Customer = "Tukey"))
summary(diff_groups)
} else {
  cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Không có sự khác nhau đáng kể giữa sự yêu cầu giao hàng nhanh của ba khách hàng\n")
}
```

Kết quả xuất ra màn hình:

```
> # Dữ liệu
> thompson <- c(6, 9, 8, 7, 7, 13, 6, 6, 6, 10, 8, 6)
> nickolson <- c(9, 8, 5, 9, 12, 6, 7, 11, 10, 8, 9, 3)
> bakers <- c(5, 0, 6, 6, 5, 6, 3, 7, 6, 8, 6, 2)
>
> # Tạo dataframe từ dữ liệu
> data <- data.frame(
+   Customer = rep(c("Thompson", "Nickolson", "Bakers"), each = 12),
+   Month = rep(1:12, times = 3),
+   Requests = c(thompson, nickolson, bakers)
+ )
> # Tạo dataframe với biến 'Customer' là factor
> data$Customer <- factor(data$Customer)
> # Kiểm định Anova
> model <- aov(Requests ~ Customer, data = data)
> summary(model)
            Df Sum Sq Mean Sq F value  Pr(>F)
Customer     2  67.17   33.58   6.241 0.00503 **
Residuals   33 177.58    5.38
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
>
> # Kiểm tra mức ý nghĩa
> alpha <- 0.05
> p_value <- summary(model)[[1]]$"Pr(>F)"[1]
>
> # In kết quả
> cat("P-value:", p_value, "\n")
P-value: 0.005025876
>
```

Giải thích:

BACHKHOACNCP.COM

```
            Df Sum Sq Mean Sq F value  Pr(>F)
Customer     2  67.17   33.58   6.241 0.00503 **
Residuals   33 177.58    5.38
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

+Df (Degrees of Freedom):

Df(Customer): Số bậc tự do của nhóm khách hàng (số nhóm - 1).

Df(Residuals): Số bậc tự do của sai số (tổng số quan sát - số nhóm).

+Sum Sq (Sum of Squares):

Sum Sq(Customer): Tổng bình phương giữa các giá trị trung bình của các nhóm.

Sum Sq(Residuals): Tổng bình phương của sai số (khác biệt giữa mỗi quan sát và giá trị trung bình của nhóm).

+Mean Sq (Mean Square):

Mean Sq(Customer): Tính bằng cách chia Sum Sq(Customer) cho Df(Customer).

Mean Sq(Residuals): Tính bằng cách chia Sum Sq(Residuals) cho Df(Residuals).

+F value (F-statistic):

F value: Một thống kê kiểm định để kiểm tra sự khác biệt giữa các nhóm. Giá trị càng cao, khả năng sự khác biệt càng lớn.

+Pr(>F) (p-value): Pr(>F): Giá trị p, đo lường xác suất của giả thuyết không có sự khác biệt giữa các nhóm. Nếu giá trị này nhỏ hơn mức ý nghĩa (thường là 0.05), chúng ta có đủ bằng chứng để bác bỏ giả thuyết không có sự khác biệt.

Trong trường hợp này:

Giá trị F là 6.241.

Giá trị p (Pr(>F)) là 0.00503.

Với mức ý nghĩa 0.05, vì giá trị p < 0.05, nên chúng ta có đủ bằng chứng để bác bỏ giả thuyết không có sự khác biệt giữa ít nhất một cặp nhóm khách hàng. Điều này thường được biểu thị bằng dấu '**' để chỉ ra mức ý nghĩa đạt được (significant) ở mức 0.01.

BACHKHOACNCP.COM

```
> # Kiểm tra điều kiện và đưa ra kết luận
> if (p_value < alpha) {
+   cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
+   cat("Có sự khác biệt đáng kể về sự yêu cầu giao hàng nhanh giữa ít nhất một cặp khách hàng\n")
+ } else {
+   cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")
+   cat("Không có sự khác biệt đáng kể về sự yêu cầu giao hàng nhanh giữa các khách hàng\n")
+ }
Có đủ bằng chứng để bác bỏ giả thuyết H0
Có sự khác biệt đáng kể về sự yêu cầu giao hàng nhanh giữa ít nhất một cặp khách hàng
> #install.packages("multcomp")
> library(multcomp)
>
> # Kiểm tra sự khác nhau
> if (p_value < alpha) {
+   cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
+   cat("Có sự khác nhau giữa sự yêu cầu giao hàng nhanh của ba khách hàng\n")
+
+ # Tính khoảng tin cậy 95% cho sự khác nhau
+ conf_int <- TukeyHSD(model, "Customer", conf.level = 0.95)
+
+ # In khoảng tin cậy
+ print(conf_int)
```

Do p_value < alpha (0,00503<0,05) nên xuất ra màn hình " Có đủ bằng chứng để bác bỏ H_0"

=>> Có sự khác biệt về sự yêu cầu giao hang nhanh ít nhát giữa 1 cặp kho hàng

```
+ # Tìm nhóm khác nhau
+ diff_groups <- glht(model, linfct = mcp(Customer = "Tukey"))
+ summary(diff_groups)
+ } else {
+   cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")
+   cat("Không có sự khác nhau đáng kể giữa sự yêu cầu giao hàng nhanh của ba khách hàng\n")
+ }
Có đủ bằng chứng để bác bỏ giả thuyết H0
Có sự khác nhau giữa sự yêu cầu giao hàng nhanh của ba khách hàng
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = Requests ~ Customer, data = data)

$Customer
                        diff        lwr      upr     p adj
Nickolson-Bakers    3.0833333  0.7594908 5.407176 0.0071893
Thompson-Bakers     2.6666667  0.3428241 4.990509 0.0216367
Thompson-Nickolson -0.4166667 -2.7405092 1.907176 0.8991260


         Simultaneous Tests for General Linear Hypotheses

Multiple Comparisons of Means: Tukey Contrasts


$Customer
                        diff        lwr      upr     p adj
Nickolson-Bakers    3.0833333  0.7594908 5.407176 0.0071893
Thompson-Bakers     2.6666667  0.3428241 4.990509 0.0216367
Thompson-Nickolson -0.4166667 -2.7405092 1.907176 0.8991260
```

+ diff (Difference):

BACHKHOACNCP.COM

Nickolson-Bakers: Sự chênh lệch trung bình giữa nhóm Nickolson và nhóm Bakers là 3.0833333.

Thompson-Bakers: Sự chênh lệch trung bình giữa nhóm Thompson và nhóm Bakers là 2.6666667.

Thompson-Nickolson: Sự chênh lệch trung bình giữa nhóm Thompson và nhóm Nickolson là -0.4166667.

+ lwr (Lower Confidence Interval) và upr (Upper Confidence Interval):

Nickolson-Bakers: Khoảng tin cậy 95% cho sự chênh lệch giữa Nickolson và Bakers là từ 0.7594908 đến 5.407176.

Thompson-Bakers: Khoảng tin cậy 95% cho sự chênh lệch giữa Thompson và Bakers là từ 0.3428241 đến 4.990509.

Thompson-Nickolson: Khoảng tin cậy 95% cho sự chênh lệch giữa Thompson và Nickolson là từ -2.7405092 đến 1.907176.

+ p adj (p-value điều chỉnh):

Nickolson-Bakers: Giá trị p điều chỉnh cho so sánh giữa Nickolson và Bakers là 0.0071893.

Thompson-Bakers: Giá trị p điều chỉnh cho so sánh giữa Thompson và Bakers là 0.0216367.

Thompson-Nickolson: Giá trị p điều chỉnh cho so sánh giữa Thompson và Nickolson là 0.8991260.

Giải thích p adj:

Giá trị p điều chỉnh là giá trị p đã được sửa đổi để điều chỉnh cho nhiều lần kiểm định thực hiện đồng thời (điều chỉnh đa cấp).

Khi giá trị p điều chỉnh nhỏ hơn mức ý nghĩa (thường là 0.05), chúng ta có đủ bằng chứng để bác bỏ giả thuyết không có sự khác biệt giữa các nhóm.

Dựa vào giá trị p điều chỉnh, có thể kết luận rằng có sự khác biệt đáng kể giữa ít nhất một cặp nhóm khách hàng (Nickolson-Bakers và Thompson-Bakers), nhưng không có sự khác biệt đáng kể giữa Thompson và Nickolson.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

```
Fit: aov(formula = Requests ~ Customer, data = data)

Linear Hypotheses:
                           Estimate Std. Error t value Pr(>|t|)
Nickolson - Bakers == 0      3.0833     0.9470   3.256   0.0072 **
Thompson - Bakers == 0       2.6667     0.9470   2.816   0.0216 *
Thompson - Nickolson == 0   -0.4167     0.9470  -0.440   0.8991
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
(Adjusted p values reported -- single-step method)
```

+Linear Hypotheses:

Nickolson - Bakers == 0: Giả thuyết rằng sự chênh lệch giữa nhóm Nickolson và nhóm Bakers là bằng 0.

Thompson - Bakers == 0: Giả thuyết rằng sự chênh lệch giữa nhóm Thompson và nhóm Bakers là bằng 0.

Thompson - Nickolson == 0: Giả thuyết rằng sự chênh lệch giữa nhóm Thompson và nhóm Nickolson là bằng 0.

+Estimate:

Estimate: Ước lượng của sự chênh lệch trung bình giữa các nhóm.

+Std. Error (Standard Error):

Std. Error: Sai số chuẩn của ước lượng.

+t value:

t value: Giá trị t, một thống kê kiểm định, được tính bằng cách chia ước lượng cho sai số chuẩn. Nếu giá trị này càng lớn, khả năng sự khác biệt càng cao.

+Pr(>|t|) (p-value):

Pr(>|t|): Giá trị p, đo lường xác suất của giả thuyết không có sự khác biệt. Nếu giá trị này nhỏ hơn mức ý nghĩa (thường là 0.05), chúng ta có đủ bằng chứng để bác bỏ giả thuyết không có sự khác biệt.

+Signif. codes:

***: 0.001, **: 0.01, *: 0.05. Các ký hiệu này thường được sử dụng để biểu thị mức ý nghĩa của kết quả, nơi *** là mức ý nghĩa cao nhất và . là không có ý nghĩa.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

+Adjusted p values:

Kết quả này bao gồm giá trị p đã được điều chỉnh để kiểm soát sai số loại 1 khi thực hiện nhiều kiểm định đồng thời. Phương pháp điều chỉnh ở đây là single-step method.

Tóm lại, dựa trên giá trị p, có đủ bằng chứng để bác bỏ giả thuyết không có sự khác biệt giữa ít nhất một cặp nhóm khách hàng (Nickolson-Bakers và Thompson-Bakers). Đối với Thompson-Nickolson, không có đủ bằng chứng để bác bỏ giả thuyết không có sự khác biệt.

✓ **<u>Hồi Quy</u>**

Phương trình hồi quy Logistic có dạng như sau:

$$log - odds = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n$$

Trong đó:

$log - odds$: là logarit tự nhiên của tỷ lệ xác suất $\left(\frac{p}{1-p}\right)$

β_0 là hệ số chặn intercept

$\beta_1, \beta_2, \ldots, \beta_n$ là các hệ số tương ứng với các biến độc lập $x_1, x_2, \ldots, x_n$

β_0 là hệ số chặn intercept

$\beta_1, \beta_2, \ldots, \beta_n$ là các hệ số tương ứng với các biến độc lập $x_1, x_2, \ldots, x_n$

Đưa biến phụ thuộc về hệ nhị phân:

```
dirty_data$is_happy_customer_numeric <- ifelse(dirty_data$is_happy_customer ==
TRUE, 1, 0)
```

Xây dựng mô hình hồi quy Logistic:

```
logistic_model <- glm(is_happy_customer_numeric ~ delivery_charges + coupon_dis
count + season + is_expedited_delivery, data=dirty_data, family=binomial)
summary(logistic_model)
```

Kết quả:

BACHKHOACNCP.COM

```
##
## Call:
## glm(formula = is_happy_customer_numeric ~ delivery_charges +
##     coupon_discount + season + is_expedited_delivery, family = binomial,
##     data = dirty_data)
##
## Coefficients:
##                            Estimate Std. Error z value Pr(>|z|)
## (Intercept)               -20.04255    1.97116 -10.168  < 2e-16 ***
## delivery_charges            0.37028    0.03445  10.748  < 2e-16 ***
## coupon_discount            -0.02904    0.01853  -1.567   0.1171
## seasonSpring               -6.48116    0.75682  -8.564  < 2e-16 ***
## seasonSummer               -4.17375    0.59992  -6.957 3.47e-12 ***
## seasonWinter                1.09297    0.49669   2.201   0.0278 *
## is_expedited_deliveryTRUE  -7.23990    0.78762  -9.192  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 594.83  on 499  degrees of freedom
## Residual deviance: 250.73  on 493  degrees of freedom
## AIC: 264.73
##
## Number of Fisher Scoring iterations: 6
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Nhận xét:

Đặt giả thuyết:

$H_0 : \beta_i = 0$ (biến ứng với β_i không làm ảnh hưởng lên sự hài lòng khách hàng)

$H_1 : \beta_i \neq 0$ (biến ứng với β_i làm ảnh hưởng lên sự hài lòng khách hàng)

Ta thấy có biến **coupon_discount** (p-value > 5%). Vậy ta chưa đủ cơ sở để bác bỏ

H_0 , đồng nghĩa với việc các biến này chưa ảnh hưởng lên sự hài lòng của khách hàng.Ta thấy rằng các biến **deliver_charges, season, is_expedited_delivery** (p-value <

5%). Vậy ta đủ bằng chứng để bác bỏ $H0$, đồng nghĩa với việc các biến này ảnh hưởng

lên sự hài lòng của khách hàng.

Phương trình hồi quy có thể được viết dưới dạng:

BACHKHOACNCP.COM

$$log - odds = -20.04255 + 0.37028 \times deliver_charges$$
$$-0.02904 \times coupon_discount - 6.48116 \times seasonSpring$$
$$-4.17375 \times seasonSummer + 1.09297 \times seasonWinter$$
$$-7.23990 \times is_expedited_deliveryTRUE$$

Ở đây các biến như **deliver_charges, coupon_discount, seasonSpring, seasonSummer, seasonWinter, is_expedited_deliveryTRUE** đại diện cho các giá trị của từng biến trong dữ liệu. Phương trình này sẽ cho bạn *log-odds* của biến phụ thuộc **is_happy_customer_numeric** dựa trên các giá trị của các biến độc lập. Để chuyển từ *log-odds* sang xác suất, ta có thể sử dụng hàm sigmoid:

$$P(is_happy_customer_numeric) = \frac{1}{1 + e^{-(log-odds)}}$$

Trong đó *e* là số Euler.

• **Intercept:** Giá trị của hệ số chặn là – 20.04255. Đây là giá trị của log-odds khi tất cả các biến độc lập đều bằng 0.

• **Các hệ số (Coefficients):**

o **deliver_charges:** Hệ số là 0.37028 với p-value gần 0, có ý nghĩa thống kê. Điều này cho biết sự ảnh hưởng tích cực của *deliver_charges* lên xác suất của *is_happy_customer_numeric.*

o **coupon_discount:** Hệ số là -0.02904 nhưng p-value là 0.1171, không đạt mức ý nghĩa thống kê ở mức 0.05. Có vẻ như *coupon_discount* không ảnh hưởng đến xác suất của *is_happy_customer_numeric.*

o **seasonSpring, seasonSummer, seasonWinter:** Tất cả đều có ảnh

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

hưởng đáng kể đến xác suất của biến phụ thuộc.o **is_expedited_deliveryTRUE:** Có ảnh hưởng tích cực với hệ số -

7.23990, p-value gần bằng 0.

o **Significance Codes:** Khả năng bác bỏ của giả thuyết không.

• **Deviance và AIC:** Deviance là một độ đo của sự khác biệt giữa mô hình và dữ liệu. AIC là một độ đo của sự phù hợp của mô hình. Trong trường hợp này, giảm deviance và AIC so với mô hình null (intercept-only) cho thấy mô hình có khả năng dự đoán tốt hơn.

• **Null deviance và Residual deviance:** Cả hai giá trị này giúp đánh giá sự phù hợp của mô hình. Nếu Residual deviance giảm đáng kể so với Null deviance, điều này chỉ ra rằng mô hình có thể giải thích dữ liệu tốt hơn mô hình null.

• **Số lần lặp Fisher Scoring:** Số lần lặp của thuật toán hội tụ đến giải pháp tối ưu sau 6 lần.

Tóm lại, mô hình này có vẻ phù hợp với dữ liệu và một số biến như 'delivery_charges', 'season', 'is_expedited_delivery' có vẻ quan trọng đối với việc dự đoán xác suất 'is_happy_customer_numeric'. Tuy nhiên, việc đánh giá ý nghĩa thống kê của từng biến là quan trọng để đảm bảo tính chắc chắn của các kết luận

Thảo luận và mở rộng

<u>a. Kiểm định một tổng thể:</u>

<u>Ưu điểm:</u>

_ Dễ thực hiện và hiểu: Kiểm định một tổng thể là phương pháp đơn giản, thích hợp cho mẫu lớn và dễ hiểu.

_ Không yêu cầu nhiều giả định: Không đòi hỏi nhiều giả định phức tạp về phân phối của dữ liệu.

<u>Hạn chế:</u>

_ Giới hạn trong việc đưa ra kết luận: Chỉ cho biết sự khác biệt giữa mẫu và tổng thể nếu có sự khác biệt ở mức ý nghĩa thống kê.

_ Không phản ánh mối quan hệ giữa biến: Không cung cấp thông tin về mối quan hệ giữa biến độc lập và biến phụ thuộc.

<u>Đề nghị mở rộng:</u>

BACHKHOACNCP.COM

_Kết hợp với phương pháp khác: Khi có sẵn dữ liệu thêm, xem xét sử dụng phương pháp khác như hồi quy để hiểu rõ hơn về mối quan hệ giữa các biến.
_ Thực hiện kiểm định nhóm nhiều hơn: Nếu có nhiều nhóm, cân nhắc sử dụng phương pháp phân tích ANOVA để kiểm tra sự khác biệt giữa các nhóm.

b. Kiểm định hai tổng thể:

Ưu điểm:
_ So sánh trực tiếp giữa hai nhóm: Cho phép so sánh trực tiếp giữa hai nhóm, đặc biệt hữu ích khi quan tâm đến sự khác biệt giữa chúng.
_ Thích hợp cho dữ liệu liên tục: Phù hợp khi muốn biết sự khác biệt giữa hai nhóm trên biến độc lập liên tục.

Hạn chế:
_ Giả định về phân phối: Đòi hỏi giả định về phân phối của dữ liệu, có thể không phù hợp nếu dữ liệu không tuân theo phân phối chuẩn.
_ Chỉ cho biết sự khác biệt, không phải mối quan hệ nguyên nhân - kết quả: Không cung cấp thông tin về mối quan hệ nguyên nhân - kết quả giữa biến độc lập và biến phụ thuộc.

Đề nghị mở rộng:
_ Kiểm định phi tham số: Sử dụng kiểm định Mann-Whitney hoặc Kiểm định Wilcoxon nếu dữ liệu không tuân theo phân phối chuẩn.
_ Sử dụng phân tích ANOVA cho nhiều nhóm: Nếu có nhiều hơn hai nhóm, cân nhắc sử dụng phân tích ANOVA để đánh giá sự khác biệt giữa các nhóm.

c. Phân Tích ANOVA:

Ưu điểm:
_ So sánh nhiều nhóm: Cho phép so sánh sự khác biệt giữa nhiều nhóm, làm cho phương pháp này phù hợp trong nhiều tình huống.
_ Kiểm tra tác động của nhiều yếu tố: Cung cấp khả năng kiểm tra tác động của nhiều yếu tố đồng thời lên biến phụ thuộc.

Hạn chế:
_ Giả định về phân phối và phương sai đồng nhất: Đòi hỏi giả định về phân phối chuẩn và phương sai đồng nhất, và nếu giả định này không được đáp ứng, kết quả có thể bị sai lệch.
_ Không xác định mối quan hệ chính xác: Chỉ cho biết sự khác biệt giữa các nhóm mà không xác định được mối quan hệ chính xác giữa biến độc lập và biến phụ thuộc.

Đề nghị mở rộng:
_ Kiểm tra giả định: Sử dụng kiểm tra giả định như Levene's Test để kiểm tra giả định về phương sai đồng nhất.
_ Sử dụng phân tích ANCOVA: Khi cần kiểm soát một biến liên tục khác, sử dụng phân tích ANCOVA để cải thiện độ chính xác.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

d. Hồi quy Logistic:

Ưu điểm:

- Hiệu suất tốt trong không gian chiều cao: Hoạt động tốt trong không gian chiều cao, khi số chiều của dữ liệu lớn.- Phân loại linh hoạt: SVM có thể sử dụng các hàm kernel để phân loại dữ liệu phi tuyến.

Hạn chế:

- Đòi hỏi tài nguyên tính toán lớn: SVM có thể tốn nhiều thời gian tính toán với tập dữ liệu lớn.
- Dễ bị ảnh hưởng bởi siêu tham số: Việc chọn siêu tham số (như kernel function, regularization parameter) có thể ảnh hưởng đến hiệu suất của mô hình.

Đề nghị mở rộng:

-Trong một số trường hợp, SVM có thể cung cấp độ chính xác tốt hơn hoặc tương đương với Logistic Regression, nhưng hiệu suất cụ thể có thể phụ thuộc vào dữ liệu và cấu hình của mô hình.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Phần kết luận

Về xử lý số liệu

1. Bảng dirty_data

Về cách nhóm xử lý dữ liệu của bảng dirty_data: Nhóm không có đủ kiến thức về cách xử lý dữ liệu nhiễu ở những cột khác nhau. Với cách làm của nhóm sẽ chỉnh sửa lại cột date và dựa vào cột date để chỉnh sửa cột season. Tiếp đến sẽ chỉnh sửa cột customer_lat, customer_long dựa vào đó chỉnh sửa cột distance_to_nearest_warehouse và cột nearest_warehouse. Điều chỉnh cột order_total dựa vào cột order_price , delivery_charges, coupon_discount. Xem xét sự duy nhất của các giá trị trong cột order_id, customer_id, is_expedited_delivery, is_happy_customer. Điều này có ưu điểm là nhanh và phù hợp với kiến thức hiện tại của nhóm, nhược điểm là chưa khắc phục được các dữ liệu nhiễu trong chính cột này dẫn đến tính sai các cột khác. Cách xử lý distance_to_nearest_warehouse và nearesr_warehouse bằng công thức Vincenty của nhóm là khá tối ưu vì qua kiểm tra dữ liệu tọa độ khách hàng không bị nhiễu quá nhiều, dẫn đến kết quả từ công thức Vincenty là có ý nghĩa thống kê. Tuy nhiên nhóm còn chưa tận dụng, xử lí được cột shopping_cart và latest_customer_review, từ đó không thể triệt để xứ lí hết lỗi trong file dirty_data.

2. Bảng missing_data

Cách xử lý dữ liệu khuyết của nhóm là sử dụng các cột sẵn có như cột date để tìm các dữ liệu khuyết ở cột season, sai số của phương pháp này rất thấp. Sử dụng cột customer_lat, customer_long của file missing_data và warehouses để tìm cột distance_to _nearest_warehouse và nearest_warehouse, phương pháp Vincenty sẽ là lựa chọn tối ưu hơn trong trường hợp này. Ngược lại, dựa vào cột customer_lat, customer_long của file warehouses và distance_to_nearest_warehouse để tìm

BACHKHOACNCP.COM

customer_lat hoặc customer_long bị thiếu, nhưng lần này dùng phương pháp Haversine để suy ngược sẽ tốt hơn Vincenty. Dựa vào order_price để tìm order_total và ngược lại, do áp dụng công thức tính toán nên khả năng sai rất thấp. Tuy nhiên cách xử lí dữ liệu khuyết ở cột is_happy_customer chưa được tốt, nhóm dựa vào cột latest_customer_review, khi đánh giá của khách hàng mang nghĩa tích cực thì sẽ cho rằng khách hài lòng với đơn hàng. Cách này để giải quyết dữ liệu khuyết là rất không hiệu quả nhưng cực kỳ nhanh chóng và không đòi hỏi quá nhiều kiến thức từ nhóm.

Với mức kiến thức đại cương, nhóm không thể thực hiện quá nhiều các. Để có thể

thực hiện những phương pháp thống kê mức cao hơn, cần có thêm thời gian và kiến thức để nhóm thực hiện. Bên cạnh đó về dữ liệu được cung cấp cũng nên là dữ liệu gốc, các bước thu thập dữ liệu nên làm cẩn thận, trách thu thập bị nhiễu, bị khuyết từ đó sẽ có những thông số thống kê có ý nghĩa hơn.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Code R

❖ **Xử lý số liệu**

```
#install.packages("lubridate")
library(lubridate)
library(dplyr)
thongke = read.csv("dirty_data.csv",header=TRUE) #đọc dữ liệu
diachi= read.csv("warehouses.csv",header=TRUE)
#xử lý lỗi cột date và cột season
thongke <- thongke %>%
  mutate(date = gsub("(\\d{2}) (\\d{2}) (\\d{4})", "\\1/\\2/\\3", date))
thongke=arrange(thongke,date)
thongke <- thongke %>%
  mutate(date = as.Date(date, format="%m/%d/%Y"))
thongke <- thongke %>%
  mutate(season = case_when(
    between(month(date), 3, 5) ~ "Spring",
    between(month(date), 6, 8) ~ "Summer",
    between(month(date), 9, 11) ~ "Autumn",
```


BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
  TRUE ~ "Winter"
 ))
library(stringr)
thongke$season = str_to_title(thongke$season)
library(stringr)
thongke$nearest_warehouse = str_to_title(thongke$nearest_warehouse)
thongke$customer_lat <- ifelse(thongke$customer_lat > 0, -thongke$customer_lat,
thongke$customer_lat)

#kiem tra sai lech tong tien
tong_tien = thongke$order_price*((100-thongke$coupon_discount)/100) +
thongke$delivery_charges
print(tong_tien)
sai_lech = abs(tong_tien - thongke$order_total)
so_luong_sai_lech_khac_khong <- sum(sai_lech != 0)
print(so_luong_sai_lech_khac_khong)
print(sai_lech)
thongke$order_total = tong_tien

#tính lại khoảng cách
haversine_distance <- function(lat1, lon1, lat2, lon2, R = 6378) {
 # Chuyển đổi vĩ độ và kinh độ từ độ sang radian
 lat1 <- lat1 * pi / 180
 lon1 <- lon1 * pi / 180
 lat2 <- lat2 * pi / 180
 lon2 <- lon2 * pi / 180
```


BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
  # Tính các độ chênh lệch giữa các vĩ độ và kinh độ
  dlat <- lat2 - lat1
  dlon <- lon2 - lon1

  # Công thức Haversine
  a <- sin(dlat/2)^2 + cos(lat1) * cos(lat2) * sin(dlon/2)^2
  c <- 2 * atan2(sqrt(a), sqrt(1-a))

  # Khoảng cách giữa hai điểm trên bề mặt cầu
  distance <- R * c

  return(distance)
}
for (i in 1:nrow(thongke)) {
  kho_hang <- thongke$nearest_warehouse[i]
  # Tìm thông tin từ bảng 2 dựa trên tên kho hàng
  kho_hang_info <- diachi[diachi$names == kho_hang, ]
  # Kiểm tra nếu có thông tin về kho hàng
  if (nrow(kho_hang_info) > 0) {
    # Tính khoảng cách và ghi vào cột khoang_cach
    thongke$distance_to_nearest_warehouse[i] <- haversine_distance(
      thongke$customer_lat[i],
      thongke$customer_long[i],
      kho_hang_info$lat,
```


BACHKHOACNCP.COM

```
    kho_hang_info$lon
   )
  }
}
library(openxlsx)
write.xlsx(thongke, "du_lieu_hoan_chinh.xlsx")
```

❖ **Thống kê mô tả**

```
#install.packages("corrplot")
library(corrplot)
#install.packages("lubridate")
library(lubridate)
library(dplyr)
#thongke = read.csv("dirty_data.csv",header=TRUE) #đọc dữ liệu
#diachi= read.csv("warehouses.csv",header=TRUE)
dulieu_cut=thongke[c(4,6,7,8,9,10,11,13,14,16)]
tinhtoan = function(x){
  av = mean(x)
  med = median(x)
  sd = sd(x)
  min = min(x)
  max = max(x)
  c(MEAN = av, SD = sd, MED = med, MIN = min, MAX = max)}
a = tinhtoan(dulieu_cut$order_price)
b = tinhtoan(dulieu_cut$delivery_charges)
c = tinhtoan(dulieu_cut$coupon_discount)
```


BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
d = tinhtoan(dulieu_cut$distance_to_nearest_warehouse)
e = tinhtoan(dulieu_cut$order_total)
dinhluong = data.frame(a,b,c,d,e)
colnames(dinhluong) = c("order_price","delivery_charges","coupon_discount",
                        "distance_to_nearest_warehouse",
                        "order_total")
View(dinhluong)
hist(dulieu_cut$order_price,col = "yellow")
hist(dulieu_cut$delivery_charges,col = "red")
hist(dulieu_cut$coupon_discount,col = "green")
hist(dulieu_cut$distance_to_nearest_warehouse, col = "red")
boxplot(dulieu_cut$order_total~ order_price,data = dulieu_cut,col = "yellow")
boxplot(dulieu_cut$order_total~ coupon_discount,data = dulieu_cut, col ="green")
dulieu_cut1=thongke[c(6,7,10,11,14)]
dulieu_cut1= cor(dulieu_cut1)
corrplot(dulieu_cut1, type = "upper", method= "number",col = "blue")
#Vẽ biểu đồ thể thể hiện số lượng và tỉ lệ các kho
count <- table(thongke$nearest_warehouse)
# Tạo nhãn cho biểu đồ tròn với cả tỉ lệ phần trăm và số lượng
labels <- paste(names(count), "\nSố lượng: ", count, "\nTỉ lệ: ",
round(count/sum(count)*100, 3), "%")
# Vẽ biểu đồ tròn
pie(count, main = "Biểu đồ tròn thể hiện số lượng và tỉ lệ của các kho", labels =
labels, col = c("red", "blue","green"))
#Tìm tần suất mua hàng hàng tháng
purchase_freq_by_month <- table(month(thongke$date))
```


BACHKHOACNCP.COM

```
# In kết quả
print(purchase_freq_by_month)
#Biểu diễn tần suất mua hàng theo tháng của khách
barplot(purchase_freq_by_month, main = "Tần số mua hàng theo tháng", xlab =
"Tháng", ylab = "Tần số")
```

+ Bài toán kiểm định 1 mẫu

```
# Số lượng khách hàng
n <- 500
# Tỉ lệ dự kiến theo giả thuyết H0
p0 <- 2/3
# Tỉ lệ quan sát được trong mẫu
p_qsm <- 359/500
# Độ lệch chuẩn
se <- sqrt((p0 * (1 - p0)) / n)
# Giá trị kiểm định thống kê
z <- (p_qsm - p0) / se
# Mức ý nghĩa
alpha <- 0.05
# Giá trị tương ứng với mức ý nghĩa
z_1 <- qnorm(1 - alpha/2)
# In kết quả
cat("Giá trị kiểm định:", z, "\n")
cat("giá trị tương ứng mức ý nghĩa:", z_1, "\n")
# Kiểm tra điều kiện và đưa ra kết luận
if (abs(z) < z_1) {
```


BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
  cat("Z không nằm trong miền bác bỏ H0\n")
  cat("Chưa có đủ bằng chứng để bác bỏ giả thuyết H0\n")
} else {
  cat("Z nằm trong miền bác bỏ H0\n")
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
}
```

+ Bài kiểm định 2 mẫu:

```
# Dữ liệu
n1 <- 119
m1 <- 80
f1 <- m1 / n1
n2 <- 197
m2 <- 142
f2 <- m2 / n2
f <- (n1 * f1 + n2 * f2) / (n1 + n2)
# tiêu chuẩn kiểm định
z <- (f1 - f2) / sqrt(f * (1 - f) * (1/n1 + 1/n2))
# Mức ý nghĩa
alpha <- 0.05
# giá trị tương ứng với mức ý nghĩa
z_alpha <- qnorm(1 - alpha)
# In kết quả
cat("giá trị tiêu chuẩn kiểm định:", z, "\n")
cat("giá trị tương ứng mức ý nghĩa:", z_alpha, "\n")
# Kiểm tra điều kiện và đưa ra kết luận
```


BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
if (z < -z_alpha) {
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Tỷ lệ khách hàng hài lòng ở kho Thompson có thể cao hơn ở kho Bakers\n")
} else {
  cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Không có sự khác biệt đáng kể giữa tỷ lệ khách hàng hài lòng ở hai kho\n")
}
```

+ Giả định mô hình Anova:

```
#install.packages("car")
library(car)
# Dữ liệu
thompson <- c(6, 9, 8, 7, 7, 13, 6, 6, 6, 10, 8, 6)
nickolson <- c(9, 8, 5, 9, 12, 6, 7, 11, 10, 8, 9, 3)
bakers <- c(5, 0, 6, 6, 5, 6, 3, 7, 6, 8, 6, 2)
# Kiểm tra phân phối chuẩn
shapiro_test_thompson <- shapiro.test(thompson)
shapiro_test_nickolson <- shapiro.test(nickolson)
shapiro_test_bakers <- shapiro.test(bakers)
# Chuyển đổi dữ liệu thành một dạng phù hợp
data_for_levene <- stack(list(Thompson=thompson, Nickolson=nickolson,
Bakers=bakers))
# Kiểm tra đồng nhất của phương sai
levene_test <- leveneTest(values ~ ind, data=data_for_levene)
# Kiểm tra ANOVA
anova_test <- aov(c(thompson, nickolson, bakers) ~ rep(c("Thompson",
"Nickolson", "Bakers"), each = 12))
```


BACHKHOACNCP.COM

```
# In kết quả
cat("Kiểm tra phân phối chuẩn - Thompson:",
shapiro_test_thompson$p.value,"\n")
cat("Kiểm tra phân phối chuẩn - Nickolson:", shapiro_test_nickolson$p.value,"\n")
cat("Kiểm tra phân phối chuẩn - Bakers:", shapiro_test_bakers$p.value, "\n")
print("Kiểm tra đồng nhất phương sai:")
print(levene_test)
# In thông tin cụ thể từ kết quả ANOVA
print("Kiểm tra ANOVA:")
print(anova_test)
# Tạo dataframe
data <- data.frame(
  Group = rep(c("Thompson", "Nickolson", "Bakers"), each = 12),
  Value = c(thompson, nickolson, bakers)
)
# Kiểm tra độc lập giữa các nhóm
t_test_A_B <- t.test(Value ~ Group, data = data[data$Group %in% c("Thompson",
"Nickolson"),], var.equal = TRUE)
t_test_A_C <- t.test(Value ~ Group, data = data[data$Group %in% c("Thompson",
"Bakers"),], var.equal = TRUE)
t_test_B_C <- t.test(Value ~ Group, data = data[data$Group %in% c("Nickolson",
"Bakers"),], var.equal = TRUE)
print("Kiểm tra độc lập giữa nhóm A và B:")
print(t_test_A_B)
print("Kiểm tra độc lập giữa nhóm A và C:")
print(t_test_A_C)
```


BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
print("Kiểm tra độc lập giữa nhóm B và C:")
print(t_test_B_C)
# Kiểm tra sự không tương quan của các phần tử phần dư
aov_test <- aov(Value ~ Group, data = data)
durbin_watson_test <- durbinWatsonTest(aov_test)
print("Kiểm tra sự không tương quan của các phần tử phần dư:")
print(durbin_watson_test)
```

+Bài toán Anova:

```
# Dữ liệu
thompson <- c(6, 9, 8, 7, 7, 13, 6, 6, 6, 10, 8, 6)
nickolson <- c(9, 8, 5, 9, 12, 6, 7, 11, 10, 8, 9, 3)
bakers <- c(5, 0, 6, 6, 5, 6, 3, 7, 6, 8, 6, 2)
# Tạo dataframe từ dữ liệu
data <- data.frame(
  Customer = rep(c("Thompson", "Nickolson", "Bakers"), each = 12),
  Month = rep(1:12, times = 3),
  Requests = c(thompson, nickolson, bakers)
)
# Tạo dataframe với biến 'Customer' là factor
data$Customer <- factor(data$Customer)
# Kiểm định Anova
model <- aov(Requests ~ Customer, data = data)
summary(model)
# Kiểm tra mức ý nghĩa
alpha <- 0.05
```


BACHKHOACNCP.COM

```
p_value <- summary(model)[[1]]$"Pr(>F)"[1]
# In kết quả
cat("P-value:", p_value, "\n")
# Kiểm tra điều kiện và đưa ra kết luận
if (p_value < alpha) {
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Có sự khác biệt đáng kể về sự yêu cầu giao hàng nhanh giữa ít nhất một cặp kho hàng\n")
} else {
  cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Không có sự khác biệt đáng kể về sự yêu cầu giao hàng nhanh giữa các kho hàng\n")
}
#install.packages("multcomp")
library(multcomp)
# Kiểm tra sự khác nhau
if (p_value < alpha) {
  cat("Có đủ bằng chứng để bác bỏ giả thuyết H0\n")
  cat("Có sự khác nhau giữa sự yêu cầu giao hàng nhanh của ba kho hàng\n")
# Tính khoảng tin cậy 95% cho sự khác nhau
conf_int <- TukeyHSD(model, "Customer", conf.level = 0.95)
# In khoảng tin cậy
print(conf_int)
# Tìm nhóm khác nhau
diff_groups <- glht(model, linfct = mcp(Customer = "Tukey"))
summary(diff_groups)
```


BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

} else {

cat("Không có đủ bằng chứng để bác bỏ giả thuyết H0\n")

cat("Không có sự khác nhau đáng kể giữa sự yêu cầu giao hàng nhanh của ba kho hàng\n")

}

+Bài toán hồi quy:

Đưa biến phụ thuộc về hệ nhị phân:

```
dirty_data$is_happy_customer_numeric <- ifelse(dirty_data$is_happy_customer ==
TRUE, 1, 0)
```

Xây dựng mô hình hồi quy Logistic:

```
logistic_model <- glm(is_happy_customer_numeric ~ delivery_charges + coupon_dis
count + season + is_expedited_delivery, data=dirty_data, family=binomial)
summary(logistic_model)
```

Kết quả:

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

```
##
## Call:
## glm(formula = is_happy_customer_numeric ~ delivery_charges +
##     coupon_discount + season + is_expedited_delivery, family = binomial,
##     data = dirty_data)
##
## Coefficients:
##                            Estimate Std. Error z value Pr(>|z|)
## (Intercept)               -20.04255    1.97116 -10.168  < 2e-16 ***
## delivery_charges            0.37028    0.03445  10.748  < 2e-16 ***
## coupon_discount            -0.02904    0.01853  -1.567   0.1171
## seasonSpring               -6.48116    0.75682  -8.564  < 2e-16 ***
## seasonSummer               -4.17375    0.59992  -6.957 3.47e-12 ***
## seasonWinter                1.09297    0.49669   2.201   0.0278 *
## is_expedited_deliveryTRUE  -7.23990    0.78762  -9.192  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 594.83  on 499  degrees of freedom
## Residual deviance: 250.73  on 493  degrees of freedom
## AIC: 264.73
##
## Number of Fisher Scoring iterations: 6
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

TÀI LIỆU THAM KHẢO

[1]. Douglas C. Montgomery, George C. Runger. Hoboken. Applied Statistics and Probability for Engineers. NJ: Wiley, (2007).

[2]. Peter Dalgaard Introductory Statistics with R. Springer, (2008).

BACHKHOACNCP.COM

[3]. Phân tích số liệu và biểu đồ bằng, Truy cập từ:
https://cran.rproject.org/doc/contrib/Intro_to_R_Vietnamese.pdf

[4]. Giới thiệu phân tích phương sai (ANOVA), Truy cập từ

https://www.youtube.com/watch?v=I19vEdaM1eY&list=LL&index=6&t=2s

[5]. Giáo trình xác suất thống kê – Nguyễn Đình Huy

[6]. Multiple regression, Truy cập từ:

https://rstudio-pubsstatic.s3.amazonaws.com/233905_8c9601100a364df0a9972f955ab1dc14.html

[7]. Hồi quy tuyến tính, Truy cập từ:

https://www.youtube.com/watch?v=L15RellDWvk&t=6s

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM