ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

Khoa Điện – Điện tử

MÔN HỌC

XÁC SUẤT THỐNG KÊ (MT2013)

BÀI TẬP LỚN

"Cửa hàng điện máy "

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT.CNCP

Giảng viên : LÊ XUÂN ĐẠI

Họ và tên sinh viên	MSSV
Bùi Tiến Đạt	2210650
Nguyễn Thái Hiệp	2211049
Vũ Văn Huy	2211306
Trần Nguyễn Quốc Anh	2210138
Phan Thị Bích Ngọc	2212271

Hồ Chí Minh, tháng 12 năm 2023

BACHKHOACNCP.COM

MỤC LỤC

1 Mô tả dữ liệu .....

2 Kiến thức nền tảng.....

2.1 Kiểm định Anova .....

2.2 Hồi quy Logistic .....

3 Tiền xử lý số liệu .....

3.1 Đọc dữ liệu thô .....

3.2 Làm sạch dữ liệu .....

3.3 Xử lý định dạng dữ liệu .....

3.3.1 Dữ liệu neareast_warehouse .....

3.3.2 Dữ liệu season.....

3.3.3 Số hóa dữ liệu .....

3.4 Xử lý dữ liệu khuyết trong file missing_data.....

3.4.1 Nhập dữ liệu .....

3.4.2 Kiểm tra dữ liệu khuyết .....

3.4.3 Xử lý dữ liệu khuyết trong cột customer_long: .....

3.4.4 Xử lý dữ liệu khuyết trong cột customer_lat .....

3.4.5 Xử lý dữ liệu khuyết trong cột order_total .....

3.4.6 Xử lý dữ liệu khuyết trong cột season:.....

3.4.7 Xử lý dữ liệu khuyết trong cột nearest_warehouse .....

3.4.8 Xử lý dữ liệu khuyết trong cột distance_to_nearest_warehouse .....

3.4.9 Xử lý dữ liệu khuyết trong cột is_happy_customer.....

3.4.10 Số hóa và lọc dữ liệu .....

3.4.11 Làm rõ dữ liệu.....

4 Thống kê tả.....

4.1 Thống kê dạng bảng .....

4.2 Thống kê dạng biểu đồ .....

5 Thống kê suy diễn .....

5.1 Kiểm định ANOVA.....

5.1.1 So sánh trung bình về chi phí đặt hàng của khách hàng ở 3 kho hàng:.....

5.1.2 So sánh trung bình về chi phí đặt hàng của khách hàng 4 mùa.....

5.2 Kiểm định hồi quy Logistic:.....

6. Thảo luận và mở rộng .....

7. Tổng kết.....

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

1 Mô tả dữ liệu

Bộ dữ liệu được sử dụng trong báo cáo này chứa thông tin về giao dịch bán lẻ của một cửa hàng điện tử trực tuyến. Cửa hàng này có ba kho để giao hàng cho khách hàng. Sau đây là một vài thông tin sơ lược về các biến có trong bộ dữ liệu:

Biến	Định dạng	Đơn vị	Mô tả
order_id	ORDxxxxxx	N/A	Mỗi đơn hàng có duy nhất một id
customer_id	IDzzzzzzzzzz	N/A	Mỗi khách hàng có duy nhất một id
date	YYYY-MM-DD	N/A	Ngày đơn hàng được xác nhận
nearest_warehouse	Chuỗi 1 trong các giá trị sau: Thomson, Nickolson, Bakers	N/A	Tên kho gần nhất
shopping_cart	[('Tên mặt hàng', số lượng), ('Tên mặt hàng', số lượng), …]	N/A	Danh sách mặt hàng và số lượng đặt (phần tử đầu là mặt hàng được đặt và phần tử thứ hai là số lượng đặt hàng cho sản phẩm đó)
order_price	Số thực dương	USD	Tổng giá của tất cả sản phẩm chưa được giảm giá và chưa tính tiền vận chuyển
delivery_charges	Số thực dương	USD	Phí vận chuyển
customer_lat	Số thực làm tròn đến phần chục triệu	0	Vĩ độ của vị trí khách hàng

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

customer_long	Số thực làm tròn đến phần chục triệu	0	Kinh độ của vị trí khách hàng
coupon_discount	Số nguyên	%	Chiết khấu sản phẩm
order_total	Số thực dương, làm tròn đến phần trăm	USD	Tổng giá trị đơn hàng sau khi tính tiền vận chuuyển và chiết khẩu giảm giá
season	Chuỗi thuộc 1 tròn các giá trị sau: Spring, Summer, Autumn, Winter	N/A	Thời gian đơn hàng được đặt trong mùa nào
is_expedited_delivery	x=0 hoặc x=1	N/A	Khách hàng có yêu cầu giao hỏa tốc hay không (1 = Có, 0 = Không)
distance_to_nearest_warehouse	Number	km	Khoảng cách từ vị trí khách hàng đến kho gần nhất
latest_customer_review	Number	N/A	Đánh giá mới nhất của khách hàng
is_happy_customer	x=0 hoặc x=1	N/A	Mức độ hài lòng của khách hàng đối với dịch vụ (1 = Có, 0 = Không)

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

2 Kiến thức nền tảng

2.1 Kiểm định Anova

Kiểm định ANOVA là một phương pháp thống kê được sử dụng để so sánh trung bình của ba nhóm trở lên. Kiểm định ANOVA giúp kiểm tra xem có sự khác biệt có ý nghĩa thống kê giữa các nhóm hay không, hay nói cách khác, xem các nhóm có cùng phân phối hay không.

Kiểm định ANOVA có hai loại chính là kiểm định ANOVA một chiều và kiểm định ANOVA hai chiều. Kiểm định ANOVA một chiều được áp dụng khi chỉ có một yếu tố ảnh hưởng đến biến phụ thuộc, còn kiểm định ANOVA hai chiều được áp dụng khi có hai yếu tố ảnh hưởng đến biến phụ thuộc. Để thực hiện kiểm định ANOVA, ta cần thỏa mãn các điều kiện sau: các nhóm là độc lập với nhau, các nhóm có cùng phương sai, và biến phụ thuộc tuân theo phân phối chuẩn. Các bước kiểm định ANOVA:

Xây dựng giả thiết:

- Giả thiết H0: Các trung bình của tất cả các nhóm bằng nhau (không có sự khác biệt).
- Đối giả thiết (H1): Có ít nhất một cặp trung bình khác nhau.

Chọn mức ý nghĩa (α): Chọn mức ý nghĩa để đánh giá giả thiết H0. Thông thường, giá trị phổ biến là 0.05.

Thu thập dữ liệu: thu thập dữ liệu từ các nhóm cần so sánh.

Phân tích dữ liệu

- Tính trung bình của mỗi nhóm và trung bình tổng cộng của tất cả các dữ liệu. Tính tổng bình phương sai giữa các nhóm (SSB) và tổng bình phương sai trong nhóm (SSW).
- Tính bình phương sai giữa nhóm (MSB = SSB / (k - 1)) và bình phương sai trong nhóm (MSW = SSW / (N - k)), với k là số nhóm và N là tổng số quan sát.
- Tính giá trị thống kê $F = \frac{MSB}{MSW}$

Kết luận

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

- So sánh giá trị thống kê F với giới hạn quyết định tại mức ý nghĩa α.
- Nếu giá trị thống kê F vượt ngưỡng, ta bác bỏ giả thiết H0 và kết luận rằng có ít nhất một cặp trung bình khác nhau

Ngược lại, nếu giá trị thống kê F không vượt ngưỡng, ta không có đủ bằng chứngđể bác bỏ giả thiết H0 và kết luận rằng không có sự khác biệt ý nghĩa giữa các nhóm.

Kiểm tra điều kiện: Kiểm tra các điều kiện cho phép sử dụng kiểm định Anova, chẳng hạn như sự đồng nhất về phương sai (homogeneity of variances) và phân phối chuẩn (normality).

Kiểm định hậu ANOVA (Post Hoc Tests):

- Nếu kiểm định Anova chỉ ra sự khác biệt, có thể thực hiện các kiểm tra hậu quả như Tukey HSD hoặc Bonferroni để xác định cặp nhóm nào có sự khác biệt đặc biệt.

Kiểm định Anova là một công cụ mạnh mẽ để phân tích sự khác biệt giữa nhiều nhóm và xác định liệu sự khác biệt đó có ý nghĩa thống kê hay không.

2.2 Hồi quy Logistic

Hồi quy logistic là một công cụ phổ biến trong thống kê được áp dụng để nghiên cứu và dự đoán sự xuất hiện hay vắng mặt của một biến phụ thuộc nhị phân. Thay vì dự đoán giá trị cụ thể, như trong hồi quy tuyến tính, hồi quy logistic tập trung vào việc ước lượng xác suất một biến nhị phân nhận giá trị 1 (thường được hiểu là "thành công").

Mô hình logistic sử dụng hàm logistic, giúp chuyển đổi tổng trọng số của các biến độc lập thành một xác suất ở giữa 0 và 1. Mô hình này thường được ước lượng bằng phương pháp tối đa hóa hàm hợp lý (maximum likelihood) từ dữ liệu.

Các biến độc lập có thể là liên tục hoặc phân loại, và mô hình có thể bao gồm nhiều biến độc lập. Các tham số của mô hình logistic được ước lượng để tối ưu hóa khả năng dự đoán xác suất đúng.

Khi mô hình đã được xây dựng, nó có thể được sử dụng để đưa ra dự đoán về xác suất của sự kiện ở các giá trị khác nhau của biến độc lập. Đánh giá hiệu suất của mô hình thường dựa vào các thước đo như đường cong ROC, diện tích dưới đường cong (AUC), và Brier Score.

Hồi quy logistic chủ yếu được sử dụng trong các lĩnh vực như y tế, tài chính, và hành vi người tiêu dùng, nơi nhu cầu dự đoán xác suất của một sự kiện nhị phân là quan trọng.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Phương trình hồi quy Logistic

$$P(X) = \frac{1}{1 + e^{-X\beta}}$$

Trong đó:

P: "Xác suất thành công" - xác suất của biến phụ thuộc với một trường hợp thành công/tổng trường hợp chứ không phải là một trường hợp thất bại/không trường hợp (xác suất là 1)

$X = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$: Biến phụ thuộc

k: Số lượng tham số

X_i: Biến độc lập

β_0: Hằng số hồi quy

β_i: Hệ số hồi quy

.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

3. Tiền xử lý số liệu

3.1 Đọc dữ liệu thô

```
data <-read.csv("E:/btkts/dirty_data.csv", header = TRUE)
data
```

```
data                                500 obs. of 17 variables
    $ order_id                      : chr  "ORD182494" "ORD395518" "ORD494479" "ORD019224" ...
    $ customer_id                   : chr  "ID6197211592" "ID0282825849" "ID0579391891" "ID4544561904" ...
    $ date                          : chr  "6/22/2019" "12/29/2019" "3/2/2019" "1/12/2019" ...
    $ nearest_warehouse             : chr  "Thompson" "Thompson" "Nickolson" "Nickolson" ...
    $ shopping_cart                 : chr  "[('Lucent 330S', 1), ('Thunder line', 2), ('iStream', 2), ('pearTV', 1)]" "[(
    $ order_price                   : int  12200 9080 10670 24800 9145 7810 13700 7960 25390 13320 ...
    $ delivery_charges              : num  79.9 62.7 65.9 57.6 75.5 ...
    $ customer_lat                  : num  -37.8 -37.8 -37.8 -37.8 37.8 ...
    $ customer_long                 : num  145 145 145 145 145 ...
    $ coupon_discount               : int  10 0 10 15 25 10 5 5 10 15 ...
    $ order_total                   : num  11060 9143 9669 21138 6934 ...
    $ season                        : chr  "Winter" "Summer" "Autumn" "Summer" ...
    $ is_expedited_delivery         : num  1 0 0 0 0 0 0 0 1 1 ...
    $ distance_to_nearest_warehouse: num  1.28 1.162 1.095 0.857 0.587 ...
    $ latest_customer_review        : chr  "perfect phone and trusted seller. phone itself is amazing. i got this phone a
    $ is_happy_customer             : num  1 0 1 0 1 0 1 0 1 0 ...
    $ is__expedited_delivery        : num  NA NA NA NA NA NA NA NA NA NA ...
```

3.2 Làm sạch dữ liệu

```
new_data<-data [,c(3,12)]
head(new_data)
apply(is.na(new_data),2,which)
```

```
new_data                    500 obs. of 2 variables
    $ date  : chr  "6/22/2019" "12/29/2019" "3/2/2019" "1/12/2019" ...
    $ season: chr  "Winter" "Summer" "Autumn" "Summer" ...
```

Nhận xét: Bộ dữ liệu không chứa dữ liệu khuyết

3.3 Xử lý định dạng dữ liệu

3.3.1 Dữ liệu *neareast_warehouse*

- *Kiểm tra dữ liệu :*

```
unique(is.na(new_data$nearest_warehouse))
```

- *Xử lý dữ liệu*

```
new_data$nearest_warehouse[new_data$nearest_warehouse == 'thompson'] <- 'Thompson'
new_data$nearest_warehouse[new_data$nearest_warehouse == 'nickolson'] <- 'Nickolson'
unique(new_data$nearest_warehouse)
```

TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Nhận xét: Dữ liệu *neareast_warehouse* đã được làm sạch

3.3.2 Dữ liệu season

- ***Kiểm tra dữ liệu :***

```
unique(new_data$season)
```

```
new_data$season[new_data$season == 'spring'] <- 'Spring'
new_data$season[new_data$season == 'summer'] <- 'Summer'
new_data$season[new_data$season == 'autumn'] <- 'Autumn'
new_data$season[new_data$season == 'winter'] <- 'Winter'
unique(new_data$season)
```

Nhận xét: dữ liệu season đã được làm sạch

3.3.3 Số hóa dữ liệu

- Nhận xét: Dữ liệu ở 2 cột *is_expedited_delivery* và *is_happy_customer* có định dạng dữ liệu kiểu Boolean, có thể số hóa được.
- Tiến hành số hóa dữ liệu:

```
new_data$is__expedited_delivery[new_data$is_expedited_delivery == 'True'] <- 1
new_data$is_expedited_delivery[new_data$is_expedited_delivery == 'False'] <- 0
new_data$is_happy_customer[new_data$is_happy_customer == 'True'] <- 1
new_data$is_happy_customer[new_data$is_happy_customer == 'False'] <- 0
```

- Thay đổi kiểu dữ liệu của biến:

```
new_data$is_expedited_delivery<-as.numeric(new_data$is_expedited_delivery)
new_data$is_happy_customer<-as.numeric(new_data$is_happy_customer)
```

Nhận xét: Dữ liệu đã được số hóa.

3.4 Xử lý dữ liệu khuyết trong file missing_data

3.4.1 Nhập dữ liệu

-Tiến hành nhập dữ liệu vào R

3.4.2 Kiểm tra dữ liệu khuyết

- **Đếm số lượng missing data values trong các biến**

```
}
apply(is.na(missing_data1),2,sum)
```

BACHKHOACNCP.COM

```
>
> apply(is.na(missing_data1),2,sum)
                    order_id                  customer_id                         date             nearest_warehouse
                           0                            0                            0                            10
                shopping_cart                  order_price             delivery_charges                  customer_lat
                           0                           10                            0                            10
                 customer_long               coupon_discount                 order_total                       season
                          10                            0                           10                            10
        is_expedited_delivery distance_to_nearest_warehouse        latest_customer_review             is_happy_customer
                           0                           10                            0                            10
> |
```

- **Kiểm tra vị trí các missing valua**

```
apply(is.na(missing_data1),2,which)
```

```
$order_id
integer(0)

$customer_id
integer(0)

$date
integer(0)

$nearest_warehouse
 [1]   8  17 106 220 237 248 252 293 296 417

$shopping_cart
integer(0)

$order_price
 [1]  20  41  85 146 171 258 274 344 426 432

$delivery_charges
integer(0)

$customer_lat
 [1]  26  76 134 190 193 204 225 325 399 461

$customer_long
 [1]  97 144 156 166 232 253 364 371 377 453

$coupon_discount
integer(0)

$order_total
 [1]  27  74 132 203 211 249 260 346 431 481

$season
 [1]   3  77 111 133 136 174 210 311 336 443

$is_expedited_delivery
integer(0)

$distance_to_nearest_warehouse
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

- **Kiểm tra tỷ lệ missing values từng biến**

```
apply(is.na(missing_data1),2,mean)
```

```
> apply(is.na(missing_data1),2,mean)
                    order_id                  customer_id                         date             nearest_warehouse
                        0.00                         0.00                         0.00                         0.02
                shopping_cart                  order_price             delivery_charges                  customer_lat
                        0.00                         0.02                         0.00                         0.02
                 customer_long               coupon_discount                 order_total                       season
                        0.02                         0.00                         0.02                         0.02
        is_expedited_delivery distance_to_nearest_warehouse        latest_customer_review             is_happy_customer
                        0.00                         0.02                         0.00                         0.02
> |
```

Nhận xét:

• Có 8 biến chứa missing values với số lượng 10 missing values gồm các biến: **nearest_warehouse, order_price, customer_lat, customer_long, order_total, season, distance_to_nearest_warehouse, is_happy_customer.**

• Tỉ lệ missing values trong mỗi biến bằng 2% và chiếm 16% trong bộ dữ liệu.

• Vị trí các missing values xuất hiện một cách ngẫu nhiên không theo quy luật.

BACHKHOACNCP.COM

Hướng xử lý missing values:
Dựa vào tính chất của missing values, ta không thể áp dụng biện pháp loại bỏ các missing values vì: số lượng lớn (16%), xuất hiện ngẫu nhiên bất kì.
⟹ Ta phải thay thế missing values bằng một giá trị hợp lý khác tùy thuộc vào bản chất của dữ liệu:
• Đối với biến chứa missing values có kiểu dữ liệu số (Numeric): Có thể thay bằng thế missing values bằng 0, median, mean,…
• Đối với biến chứa missing values có kiểu dữ liệu kí tự (Character) hay kiểu dữ liệu Logic (Logical): Thay thế missing values bằng những giá trị hợp lý hoặc nhóm những trường hợp missing values thành một nhóm tên Missing values (trường hợp không còn cách nào để loại bỏ missing values)

3.4.3 Xử lý dữ liệu khuyết trong cột *customer_long:*

- **Kiểm tra tính chất của biến:**

```
summary(missing_data1$customer_long)
```

```
> summary(missing_data1$customer_long)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's 
  144.9   145.0   145.0   145.0   145.0   145.0      10 
>
```

Nhận xét: • Missing values của biến customer_long xuất hiện ở các dòng: 97, 144, 156, 166, 232, 253, 364, 371, 377, 453. • Dữ liệu của biến customer_long không có sự chênh lệch đáng kể với nhau và không xuất hiện các giá trị ngoại lai quá cao hoặc quá thấp so với tổng quan dữ liệu, do đó ta có thể thay thế các giá trị missing values trong customer_long bằng giá trị trung bình (mean)

- **Tiến hành xử lý dữ liệu khuyết:**

```
A <- missing_data1[c(9)]
library(dplyr)
A %>% mutate(customer_long = case_when(is.na(customer_long) ~ ceiling(mean(customer_long, na.rm =  TRUE )),TRUE~ customer_lor
missing_data1[c(9)]<-A
  missing_data1[c(97,144,156,166,232,253,364,371,377,453),c(9)]
```

-Kiểm tra lại

```
# A tibble: 10 × 1
   customer_long
           <dbl>
 1           145
 2           145
 3           145
 4           145
 5           145
 6           145
 7           145
 8           145
 9           145
10           145
>
```

3.4.4 Xử lý dữ liệu khuyết trong cột *customer_lat:*

- **Kiểm tra tính chất của biến**

BACHKHOACNCP.COM

```
summary(missing_data1$customer_lat)

   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's 
 -37.83  -37.82  -37.81  -37.81  -37.81  -37.79      10 
>
```

Nhận xét: • Missing values của biến customer_lat xuất hiện ở các dòng: 26, 76, 134, 190, 193, 204, 225, 325, 399, 461. • Tính chất tương tự như customer_long, ta sẽ thay thế mean vào các missing values trong customer_lat

- Tạo một ma trận B chứa biến *customer_lat* để dễ dàng thực hiện các thay đổi:

```
B<- missing_data1[c(8)]
```

- Tiến hành thay thế các dữ liệu khuyết bằng *mean*:

```
B %>% mutate(customer_lat = case_when(is.na(customer_lat) ~  ceiling(mean(customer_lat, na.rm = TRUE)), TRUE ~ customer_lat)) ->B
missing_data1[c(8)] <- B
```

- Kiểm tra lại dữ liệu khuyết trong cột *customer_lat* đã được thay thế bằng mean hay chưa

```
missing_data1[c(26, 76, 134, 190, 193, 204, 225, 325, 399, 461), c(8)]

   customer_lat
          <dbl>
 1          -37
 2          -37
 3          -37
 4          -37
 5          -37
 6          -37
 7          -37
 8          -37
 9          -37
10          -37
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

3.4.5 Xử lý dữ liệu khuyết trong cột *order_total:*

- Kiểm tra tính chất biến:

```
summary(missing_data1$order_total)

  Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
 568.6  6569.9 10756.6 11916.2 16231.7 37362.5 
```

Nhận xét:
- Missing values trong biến order_total xuất hiện ở các dòng: 27, 74, 132, 203, 211, 249, 260, 346, 431, 481.
- Dữ kiệu trong order total có sự chênh lệch khá lớn với nhau, xuất hiện các giá trị ngoại lai quá lớn hoặc quá bé so với tổng quan dữ liệu khiến cho giá trị tổng quan sẽ bị ảnh hưởng khá nhiều. Do đó ta không thể thay thế các missing values bằng giá trị trung bình (mean). Để phản ánh gần đúng tính chất của dữ liệu ta cần thay thế missing values bằng giá trị trung vị (median).

- Xử lý dữ liệu khuyết

BACHKHOACNCP.COM

Tạo một ma trận C chứa biến *order_total* để dễ dàng thực hiện các thay đổi

```
C<- missing_data1[c(11)]
```

Tiến hành thay thế các missing values bằng *median*:

```
C %>% mutate(order_total = case_when(is.na(order_total) ~ median(order_total, na.rm = TRUE), TRUE ~ order_total)) -> C
missing_data1[c(11)]<-C
```

Kiểm tra lại missing values trong order_total đã được thay thế bằng *median* chưa:

```
missing_data1[c(27,74,132,203,211,249,260,346,431,481),c(11)]
   order_total
         <dbl>
 1      10757.
 2      10757.
 3      10757.
 4      10757.
 5      10757.
 6      10757.
 7      10757.
 8      10757.
 9      10757.
10      10757.
```

Nhận xét: Đã hoàn tất thay thế missing values trong biến ***customer_lat***, các giá trị tổng quan không bị ảnh hưởng quá nhiều.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP

3.4.6 Xử lý dữ liệu khuyết trong cột season

Nhận xét: • Missing values của biến season: 3, 77, 111, 133, 136, 174, 210, 311, 336, 443. • Nhận thấy các missing values trong season có thể được thay thế một cách tương đối chính xác với dữ liệu ngày tháng (date)

Thực hiện xử lý dữ liệu khuyết

```
E <- missing_data1[c(3,77,111, 133, 136, 174, 210,311,336,443), c(3,12)]
E
```

```
   date                season
   <dttm>              <chr>
 1 2019-03-24 00:00:00 Autumn
 2 2019-09-14 00:00:00 Spring
 3 2019-10-13 00:00:00 Spring
 4 2019-01-12 00:00:00 Summer
 5 2019-10-20 00:00:00 Spring
 6 2019-10-27 00:00:00 Spring
 7 2019-06-03 00:00:00 Winter
 8 2019-06-28 00:00:00 Winter
 9 2019-06-19 00:00:00 Winter
10 2019-10-31 00:00:00 Spring
```

Nhận xét: Đã hoàn tất thay thế missing values trong biến ***season***, các giá trị được thay

BACHKHOACNCP.COM

thế tương đối đúng và các giá trị tổng quan không bị ảnh hưởng quá nhiều.

3.4.7 Xử lý dữ liệu khuyết trong cột *nearest_warehouse:*

Nhận xét:

- Missing values trong biến *nearesr_warehouse* xuất hiện ở các dòng: 8, 17, 106, 220, 237, 248, 252, 293, 296, 417.
- Như biến season, nhận thấy rằng các missing values trong nearest_warehouse có thể được thay thế tương đối chính xác dựa vào đối chiếu với dữ liệu tọa độ gồm customer_long và customer_lat (đã loại bỏ những giá trị mean ở 2 đầu).

  Xử lí dữ liệu khuyết

  -Tạo ma trận như sao:

```
F <- missing_data1[c(8, 17, 106, 220, 237, 248, 252, 293, 296, 417), c(4,8,9)]
F
```

	nearest_warehouse	customer_lat	customer_long
	<chr>	<dbl>	<dbl>
1	NA	-37.8	145.
2	NA	-37.8	145.
3	NA	-37.8	145.
4	NA	-37.8	145.
5	NA	-37.8	145.
6	NA	-37.8	145.
7	NA	-37.8	145.
8	NA	-37.8	145.
9	NA	-37.8	145.
10	NA	-37.8	145.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Từ dữ liệu ta có bảng sau:

```
for (i in 1:nrow(F)) {
  if ((144.9212 <= F$customer_long[i] && F$customer_long[i] < 144.9554)
      ||( -37.79872 <= F$customer_lat[i] && F$customer_lat[i] < -37.79504)) {
    F$nearest_warehouse <- "Thompson"
  }
}
for (i in 1:nrow(F)) {
  if ((144.9554 <= F$customer_long[i] && F$customer_long[i] < 144.9737
       || 144.9636 <= F$customer_long[i] && F$customer_long[i]< 144.9850)
      || (-37.82822 <= F$customer_lat[i] && F$customer_lat[i] < -37.82634)) {
    F$nearest_warehouse[i] <- "Nickolson"
  }
}
for (i in 1:nrow(F)) {
  if ((144.9850 <= F$customer_long[i] && F$customer_long[i] < 145.0170)
      || (-37.82634 <= F$customer_lat[i] && F$customer_lat[i] < -37.82574
          || -37.79504<= F$customer_lat[i] && F$customer_lat[i] < -37.79361)) {
    F$nearest_warehouse[i] <- "Bakers"
  }
}
F
```

BACHKHOACNCP.COM

```
# A tibble: 10 × 3
   nearest_warehouse customer_lat customer_long
   <chr>                    <dbl>         <dbl>
 1 Nickolson               -37.8          145.
 2 Bakers                  -37.8          145.
 3 Bakers                  -37.8          145.
 4 Nickolson               -37.8          145.
 5 Nickolson               -37.8          145.
 6 Nickolson               -37.8          145.
 7 Nickolson               -37.8          145.
 8 Thompson                -37.8          145.
 9 Nickolson               -37.8          145.
10 Bakers                  -37.8          145.
```

Ta thay thế dữ liệu từ F vào biến ***nearest_warehouse*** của *missing_data* để loại bỏ các missing values:

```
missing_data1[c(8, 17, 106, 220, 237, 248, 252, 293, 296, 417), c(4)]
```

Kiểm tra lại

```
    nearest_warehouse customer_lat customer_long
8           Nickolson     -37.81741      144.9676
17             Bakers     -37.80114      144.9886
106            Bakers     -37.81936      144.9896
220         Nickolson     -37.81097      144.9631
237         Nickolson     -37.81260      144.9572
248         Nickolson     -37.80457      144.9675
252         Nickolson     -37.80295      144.9817
293          Thompson     -37.78827      144.9292
296         Nickolson     -37.81412      144.9681
417            Bakers     -37.81063      144.9905
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Nhận xét: đã thay thế tương đối đúng mà không thay đổi quá nhiều

3.4.8 Xử lý dữ liệu khuyết trong cột *distance_to_nearest_warehouse:*

Ta thấy missing values của biến ***distance_to_nearest_warehouse*** xuất hiện ở các dòng: 40, 185, 192, 264, 271, 282, 327, 348, 386, 393.

Xử lý dữ liệu khuyết:

-TIến hành "Import" dữ liệu từ file "warehouses" để nhận dữ liệu tọa độ các kho hàng

```
warehouses <-read.csv("E:/btkts/warehouses.csv", header = TRUE)
```

-Tạo ma trận

BACHKHOACNCP.COM

```
G <- missing_data1[c(40, 185, 192, 264, 271, 282, 327, 348, 386, 393), c(4,8,9,14)]
G
```

```
# A tibble: 10 × 4
   nearest_warehouse customer_lat customer_long distance_to_nearest_warehouse
   <chr>                    <dbl>         <dbl>                        <dbl>
 1 Nickolson               -37.8          145.                        3443.
 2 Thompson                -37.8          145.                        3482.
 3 Bakers                  -37.8          145.                        3498.
 4 Bakers                  -37.8          145.                        3499.
 5 Bakers                  -37.8          145.                        3499.
 6 Nickolson               -37.8          145.                        3442.
 7 Nickolson               -37.8          145.                        3445.
 8 Thompson                -37.8          145.                        3481.
 9 Thompson                -37.8          145.                        3482.
10 Thompson                -37.8          145.                        3481.
```

-Xử lý dữ liệu

```
for (i in 1: nrow(G)){
  G$customer_lat[i] <- G$customer_lat[i] * (pi/180)
  G$customer_long[i] < G$customer_long[i] * (pi/180)
}
for (i in 1: nrow (warehouses)) {
  warehouses$lat[i] < warehouses$lat[i] * (pi/180)
  warehouses$lon[i] < warehouses$lon[i] * (pi/180)
}
G
```

```
# A tibble: 10 × 4
   nearest_warehouse customer_lat customer_long distance_to_nearest_warehouse
   <chr>                    <dbl>         <dbl>                        <dbl>
 1 Nickolson               -0.660          145.                        3443.
 2 Thompson                -0.660          145.                        3482.
 3 Bakers                  -0.660          145.                        3498.
 4 Bakers                  -0.660          145.                        3499.
 5 Bakers                  -0.660          145.                        3499.
 6 Nickolson               -0.660          145.                        3442.
 7 Nickolson               -0.660          145.                        3445.
 8 Thompson                -0.660          145.                        3481.
 9 Thompson                -0.660          145.                        3482.
10 Thompson                -0.660          145.                        3481.
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

-Thực hiện viết lại chương trình

```
for (i in 1:nrow(G)) {
  for (j in 1: nrow (warehouses)){
    if (G$nearest_warehouse[i] == warehouses$names[j]){
      a <- sin(abs(G$customer_lat[i] - warehouses$lat[j])/2)^2 + cos(G$customer_lat[i])*cos(warehouses$lat[j])*sin(abs(G$customer_long[i] - warehouses$lon[j])/2)^2
      c<- 2*atan2(sqrt(a), sqrt(1-a))
      G$distance_to_nearest_warehouse[i] <- (round (6371*c, digits = 4))
    }
  }
}
G
```

```
# A tibble: 10 × 4
   nearest_warehouse customer_lat customer_long distance_to_nearest_warehouse
   <chr>                    <dbl>         <dbl>                        <dbl>
 1 Nickolson               -0.660          145.                        3443.
 2 Thompson                -0.660          145.                        3482.
 3 Bakers                  -0.660          145.                        3498.
 4 Bakers                  -0.660          145.                        3499.
 5 Bakers                  -0.660          145.                        3499.
 6 Nickolson               -0.660          145.                        3442.
 7 Nickolson               -0.660          145.                        3445.
 8 Thompson                -0.660          145.                        3481.
 9 Thompson                -0.660          145.                        3482.
10 Thompson                -0.660          145.                        3481.
```

-Thay thế dữ liệu G vào

```
missing_data1[c(40, 185, 192, 264, 271, 282, 327, 348, 386, 393), c(14)] <- G[c(4)]
```

BACHKHOACNCP.COM

-Kiểm tra dữ liệu

```
missing_data1[c(40, 185, 192, 264, 271, 282, 327, 348, 386, 393), c(14)]
```

```
# A tibble: 10 × 1
   distance_to_nearest_warehouse
                           <dbl>
 1                         3443.
 2                         3482.
 3                         3498.
 4                         3499.
 5                         3499.
 6                         3442.
 7                         3445.
 8                         3481.
 9                         3482.
10                         3481.
```

Nhận xét: đã hoàn tất thay thế mà không thay đổi quá nhiều

3.4.9 Xử lý dữ liệu khuyết trong cột *is_happy_customer:*

Nhận xét:

Missing values trong biến ***is_happy_customer*** xuất hiện ở các dòng: 21, 23, 93, 130, 142, 180, 251, 304, 306, 489.

- Xử lý dữ liệu khuyết:

-Tạo một ma trận H

```
H <- missing_data1[c(21, 23, 93, 130, 142, 180, 251, 304, 306, 489), c(15,16)]
H
```

```
# A tibble: 10 × 2
   latest_customer_review                                                                   is_happy_customer
   <chr>                                                                                    <lgl>
 1 bought for wife who is not into the techie word. she likes it - suggest buying a protectiv… TRUE
 2 one star i never used this phone since i bought, was not charging                         FALSE
 3 upgraded from my lilttle thunder line. happy with sound                                   TRUE
 4 will not seem to charge all the way and this is my 7th kindlle.                           FALSE
 5 i highly recommend!! i give this a five star rating, hands down! the phone is in excellent… TRUE
 6 note 8 amazing product                                                                    TRUE
 7 i bought this inferno for my 7 year old and she loves it.                                 TRUE
 8 five stars great product at a great price.                                                TRUE
 9 beautiful phones! was pleasantly surprised at how nice of quality these phones were when t… TRUE
10 great deal love the phone. everything i wanted. fast shipping.                            TRUE
```

-Sau khi đọc dữ liệu trong biến *latest_customer_review* ta nhận thấy các đánh giá ở dòng thứ 2, 4 thể hiện sự phàn nàn và phản ánh tiêu cực của khách hàng, do đó dữ liệu trả về trong dòng 2,4 trong biến *is_happy_customer* của ma trận D sẽ là 0 (False), các dữ liệu còn lại sẽ trả về 1 (True).

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
for (i in 1:nrow(H)) {
  if (i == 2 || i == 4) {
    H$is_happy_customer[i] <- FALSE
  }
  else {
    H$is_happy_customer[i] <- TRUE
  }
}
H[c(2)]
```

```
# A tibble: 10 × 1
   is_happy_customer
   <lgl>
 1 TRUE
 2 FALSE
 3 TRUE
 4 FALSE
 5 TRUE
 6 TRUE
 7 TRUE
 8 TRUE
 9 TRUE
10 TRUE
```

-Tiến hành trả dữ liệu

```
missing_data1[c(21, 23, 93, 130, 142, 180, 251, 304, 306, 489), c(16)] <- H[c(2)]
```

-Kiểm tra lại

```
missing_data1[c(21, 23, 93, 130, 142, 180, 251, 304, 306, 489), c(16)]
```

```
# A tibble: 10 × 1
   is_happy_customer
   <lgl>
 1 TRUE
 2 FALSE
 3 TRUE
 4 FALSE
 5 TRUE
 6 TRUE
 7 TRUE
 8 TRUE
 9 TRUE
10 TRUE
```

Nhận xét :

Đã hoàn tất thay đổi mà giá trị tổng quan không thay đổi quá nhiều

3.4.10 Số hóa và đọc dữ liệu

```
missing_data1$is_expedited_delivery[new_data$is_expedited_delivery == 'True'] <- 1
missing_data1$is_expedited_delivery[new_data$is_expedited_delivery == 'False'] <- 0
missing_data1$is_happy_customer[new_data$is_happy_customer == 'True'] <- 1
missing_data1$is_happy_customer[new_data$is_happy_customer == 'False'] <-0

missing_data1$is_expedited_delivery<-as.numeric(data$is_expedited_delivery)
missing_data1$is_happy_customer<-as.numeric(data$is_happy_customer)
new_missing_data1 <- missing_data1[,c("nearest_warehouse","is_expedited_delivery","order_price",
      "delivery_charges", "coupon_discount","order_total", "season","distance_to_nearest_warehouse", "is_happy_customer")]
head(new_missing_data1)
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

```
# A tibble: 6 × 9
  nearest_warehouse is_expedited_delivery order_price delivery_charges coupon_discount order_total season    distance_to_nearest_w…'
  <chr>                             <dbl>       <dbl>            <dbl>           <dbl>       <dbl> <list>                     <dbl>
1 Thompson                              1        7170             61.7              15       6156. <chr [1]>                  0.442
2 Thompson                              0       13590             65.2              10      12296. <chr [1]>                  0.655
3 Bakers                                0        4310             78.8              15       3742. <chr [1]>                  0.885
4 Thompson                              0       10940             92.6              25       8298. <chr [1]>                  0.788
5 Nickolson                             0       21700             95.6               5      20711. <chr [1]>                  0.222
6 Nickolson                             0        6820             84.1               0       6904. <chr [1]>                  1.93
# ℹ abbreviated name: 'distance_to_nearest_warehouse
# ℹ 1 more variable: is_happy_customer <dbl>
```

Nhận xét dữ liệu đã được làm sạch và điền khuyết

3.4.11 Làm rõ dữ liệu

4 Thống kê tả

4.1 Thống kê dạng bảng

- Thống kê các biến liên tục:

```
fileht<-missing_data1
des_function <- function(x) {c(mean(x), median(x), sd(x), var(x), min(x), max(x))}
des_table <-apply(fileht[,c("is_expedited_delivery","is_happy_customer","order_price","delivery_charges",
                            "coupon_discount","order_total","distance_to_nearest_warehouse")],2,des_function)
rownames(des_table)=c("Kỳ vọng", "Trung vị", "Độ lệch chuẩn", "Phương sai", "Giá trị thấp nhất", "Giá trị cao nhất")
des_table
```

```
                  is_expedited_delivery is_happy_customer order_price delivery_charges coupon_discount  order_total
Kỳ vọng                       0.4980000         0.7180000          NA         77.68338       11.190000    11916.176
Trung vị                      0.0000000         1.0000000          NA         77.27500       10.000000    10756.615
Độ lệch chuẩn                 0.5004967         0.4504240          NA         14.56667        8.734213     6963.756
Phương sai                    0.2504970         0.2028818          NA        212.18778       76.286473 48493902.108
Giá trị thấp nhất             0.0000000         0.0000000          NA         46.20000        0.000000      568.640
Giá trị cao nhất              1.0000000         1.0000000          NA        110.99000       25.000000    37362.470
                  distance_to_nearest_warehouse
Kỳ vọng                            70.56149
Trung vị                            1.05745
Độ lệch chuẩn                     486.88644
Phương sai                     237058.40234
Giá trị thấp nhất                   0.05490
Giá trị cao nhất                 3499.47050
```

Nhận xét: Ta xuất ra các giá trị cần thiết cho thống kê như: Kỳ vọng, Trung vị, Độ lệch chuẩn, … của các biến để quan sát, chuẩn bị thống kê.

4.2 Thống kê dạng biểu đồ

- Biểu đồ cột và tròn thể hiện lượng khách gần kho nhất của 3 kho

```
barplot(table(fileht$nearest_warehouse), main="Biểu đồ cột biểu thị lượng khách gần kho nhất của 3 kho",
        ylab="số khách hà ng",ylim=c(0,500), col=c("red","green","lightblue"))
```

-

BACHKHOACNCP
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
pie(table(fileht$nearest_warehouse), main="Biểu đồ tròn biểu thị lượng khách hàng gần kho nhất của 3 kho")
```

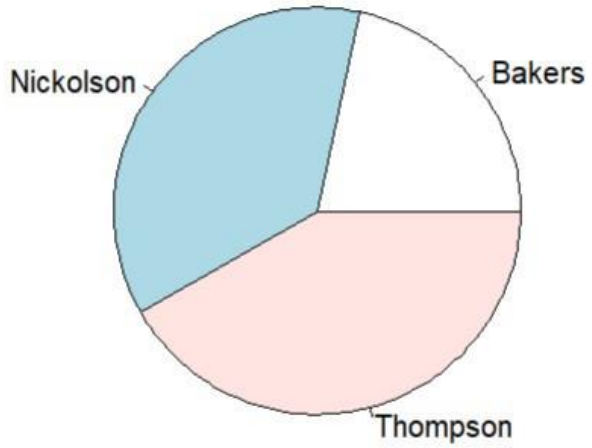

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Nhận xét: Qua 2 biểu đồ, ta thấy được kho Thompson gần với nhiều khách hàng nhất trong 3 kho với 406 khách. Tiếp đến là kho Nickolson với 367 khách hàng gần nhất và cuối cùng là kho Bakers với lượng khách hàng thấp nhất là 227.

- Biểu đồ cột và tròn biểu thị sự hài lòng của khách hàng

```
barplot(table(fileht$is_happy_customer), main="Biểu đồ cột biểu thị sự hài lòng của khách hàng",
        ylab="số khách hàng", ylim =c(0,1000),col="blue")
```

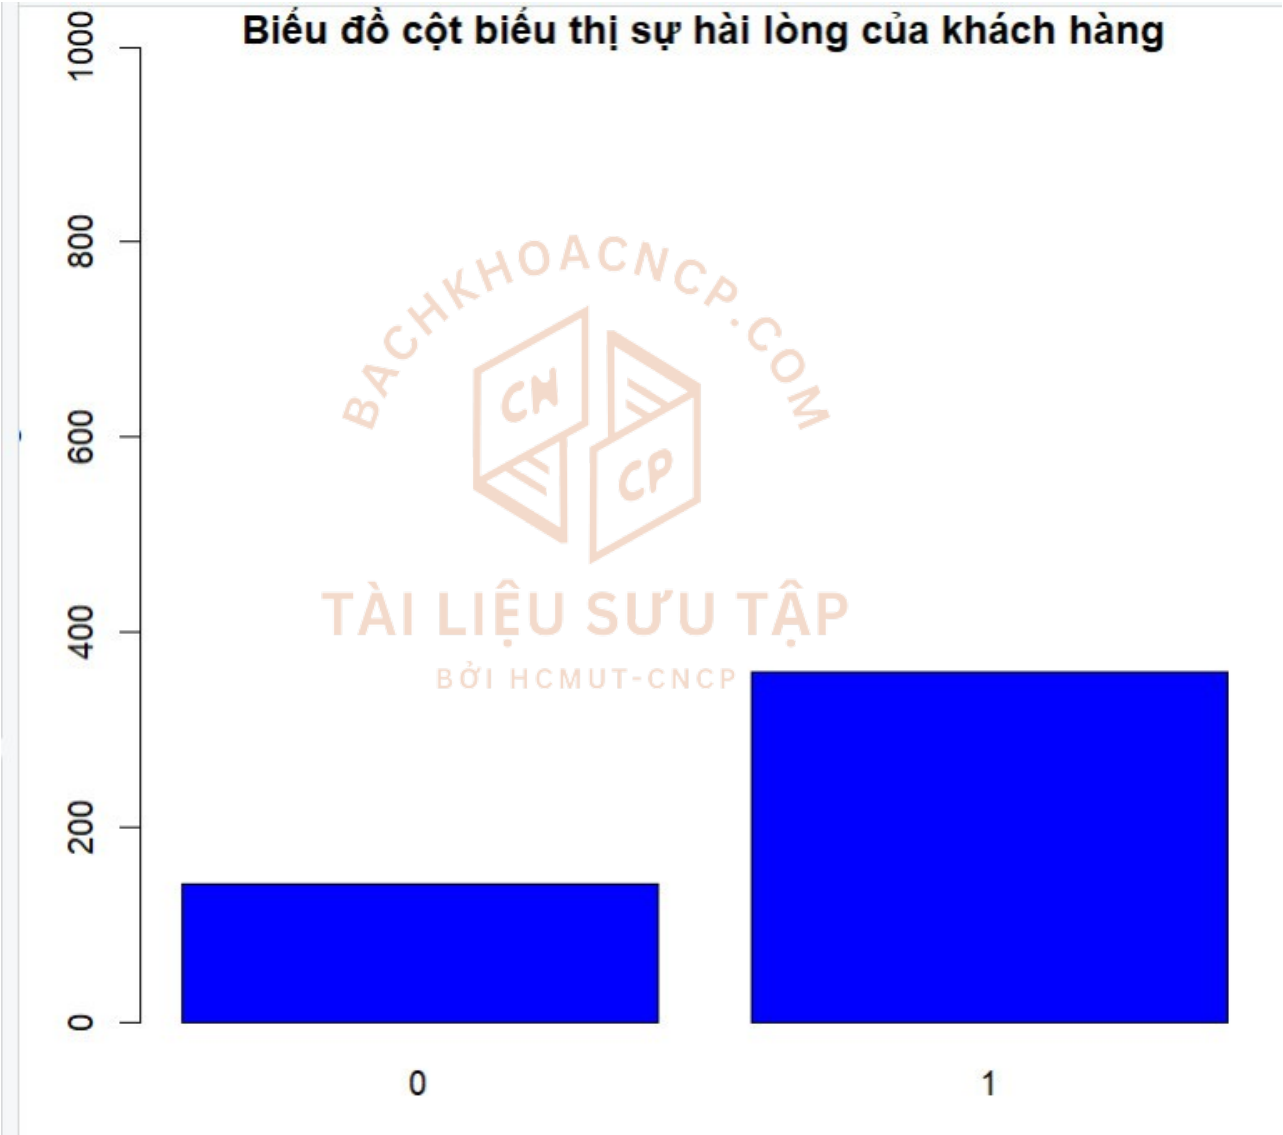

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

```
pie(table(fileht$is_happy_customer), main="Biểu đồ tròn biểu thị sự hài lòng của khách hàng",
    col=c("yellow", "lightgreen"))
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Nhận xét: Qua 2 biểu đồ này, ta thấy phần đông khách hàng cảm thấy hài lòng với dịch vụ với 718 khách hàng hài lòng và cũng có một lượng khách hàng cảm thấy không hài lòng với 282 người.

- Biểu đồ thống kê lượng khách vào mua vào các mùa

BACHKHOACNCP.COM

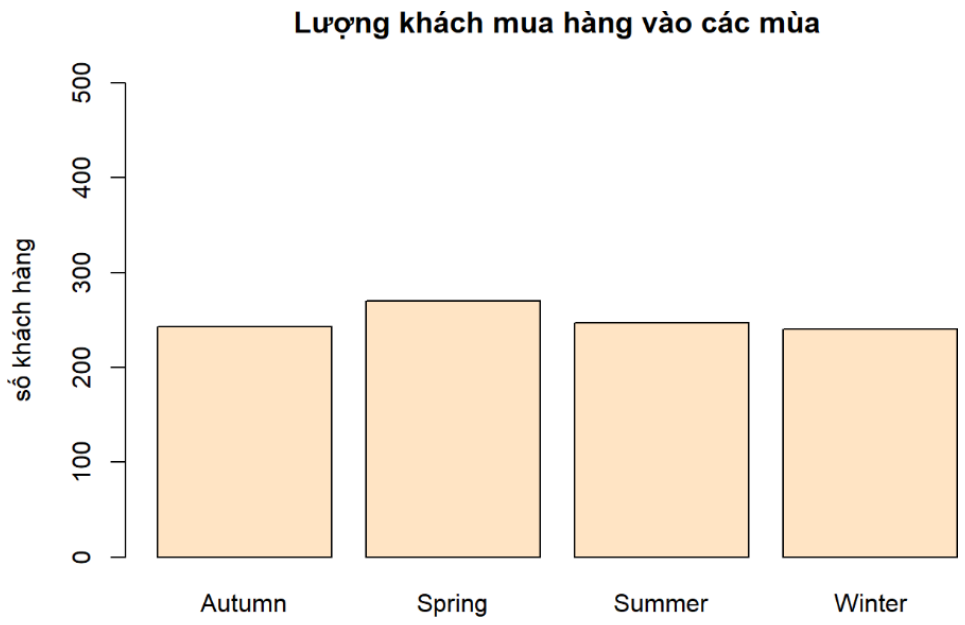

Nhận xét: Lượng khách hàng mua sắm ở 3 cửa hàng là như nhau trong 4 mùa, không có sự chênh lệch rõ ràng. Từ đó ta thấy nhu cầu của khách hàng đối với việc mua hàng ở 3 cửa hàng là không đổi ở 4 mùa.

- Biểu đồ tần suất vị trí của khách hàng đến kho gần nhất

```
hist(fileht$distance_to_nearest_warehouse, main="Biểu đồ tần suất biểu thị vị trí của khách hàng đến kho gần nhất",
     ylab = "số khách hàng", xlab= "log (khoảng cách + 1)")
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

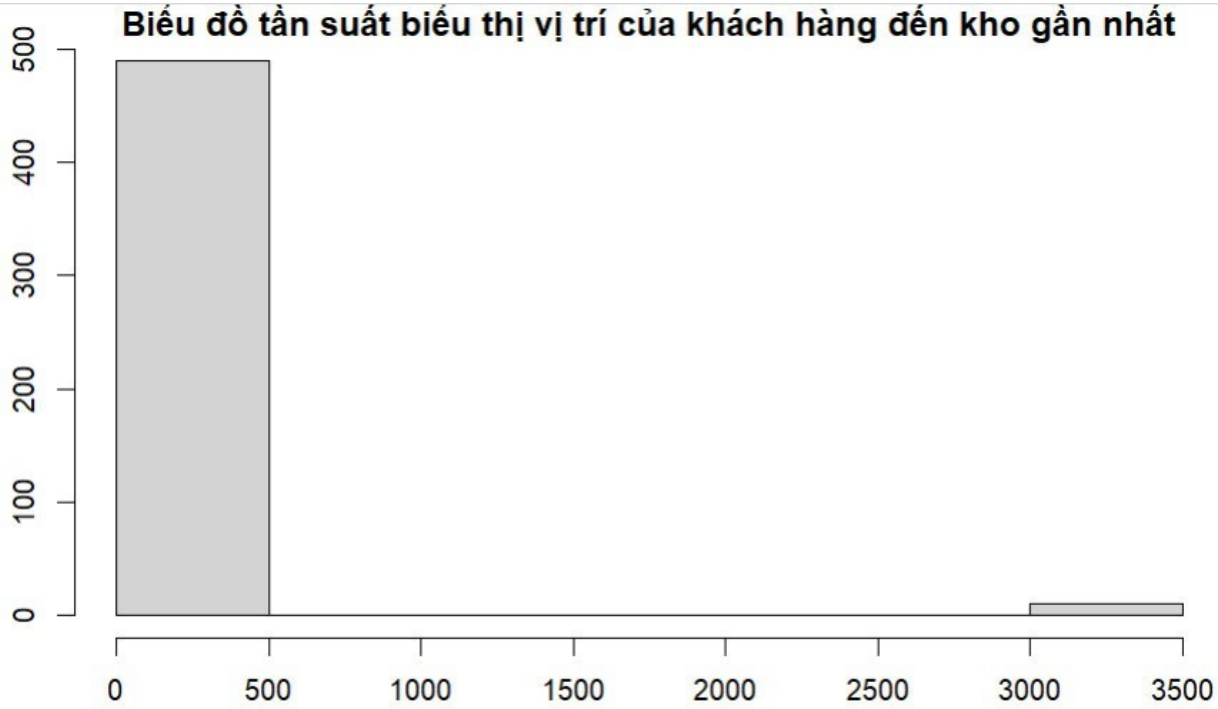

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Nhận xét: Đồ thị có xu hướng lệch trái, từ đó suy ra người dùng có xu hướng mua hàng tại cửa hàng gần với nhà mình.

- Biểu đồ thể hiện tổng chi phí đặt hàng:

```
hist(fileht$order_total, main="Biểu đồ tần suất biểu thị tổng chi phí đặt hàng của khách hàng",
     ylab="số khách hàng", xlab ="log(Tổng chi phí đặt hàng + 1)", ylim=c(0,350), col="Coral")
```

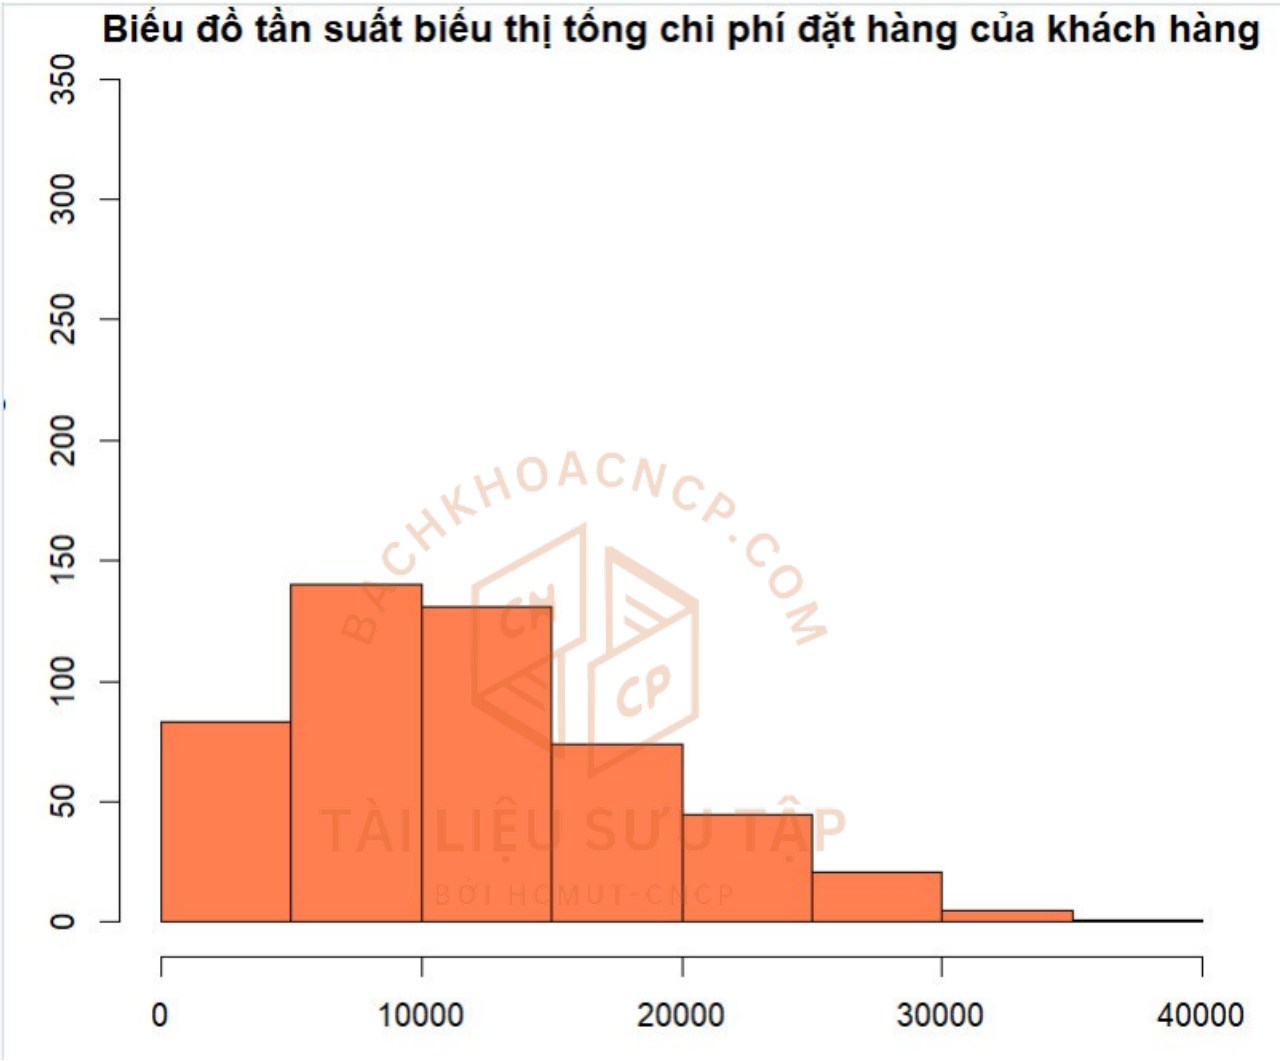

Nhận xét: Khách hàng có xu hướng mua hàng với tổng giá trị đơn hàng ở mức khá cao và khá thường xuyên.

- Biểu đồ hộp thể hiện chi phí đặt hàng của 3 kho:

```
boxplot(order_total~nearest_warehouse, main = "Biểu đồ hộp biểu thị chi phí đặt hàng của 3 kho",
        xlab ="Kho", ylab ="log (Tổn g chi phí đặt hàng + 1)", fileht)
```

BACHKHOACNCP.COM

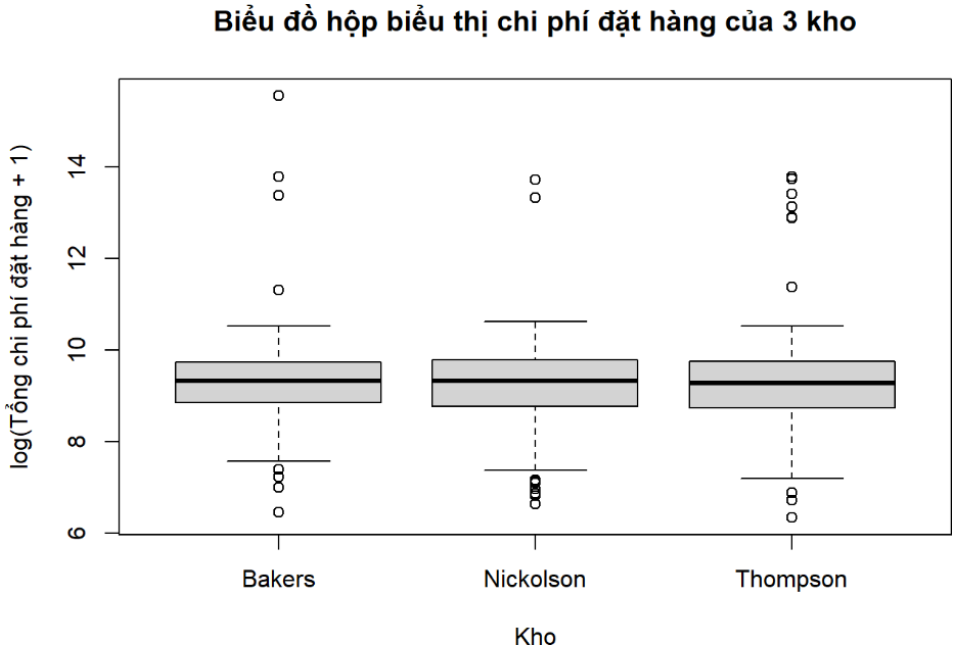

Nhận xét: Qua biểu đồ trên, ta thấy còn nhiều điểm ngoại lai, làm ta không thể xác định được các quy luật phân phối nên cần xử lý lại biểu đồ bằng cách loại bỏ một số điểm ngoại lai làm ảnh hưởng đến thống kê.

Tiến hành tìm các giá trị ngoại lai và chuyển của giái trị ngoại lai thành NA. Kiểm tra số NA:

```
rm.out <- function(x, na.rm = TRUE, ...){
  qnt <- quantile(x, probs=c(.25, .75), na.rm =na.rm, ...)
  H<- 1.5* IQR(x, na.rm = na.rm)
  y <- x
  y[x < (qnt[1]-H)] <- NA
  y[x > (qnt[2]+H)] <- NA
  y
}
Bakers_data = subset(fileht,fileht$snearest_warehouse == "Bakers")
Bakers_data$order_total= rm.out(Bakers_data$order_total)
Nickolson_data = subset (fileht, fileht$nearest_warehouse =="Nickolson")
Nickolson_data$order_total= rm.out(Nickolson_data$order_total)
Thompson_data = subset(fileht, fileht$nearest_warehouse =="Thompson")
Thompson_data$order_total = rm.out(Thompson_data$order_total)
final_data_2 <-rbind(Bakers_data, Nickolson_data, Thompson_data)
apply(is.na(final_data_2),2,sum)
```

```
(Top Level)
Background Jobs
4.3.2 · E:/btkts/New folder/new_DF2/
npson_data$order_total = rm.out(Thompson_data$order_total)
al_data_2 <-rbind(Bakers_data, Nickolson_data, Thompson_data)
ly(is.na(final_data_2),2,sum)
                order_id                 customer_id                        date            nearest_warehouse
                       0                           0                           0                            0
           shopping_cart                 order_price             delivery_charges                  customer_lat
                       0                           8                           0                            0
           customer_long             coupon_discount                 order_total                       season
                       8                           0                           4                            0
  is_expedited_delivery distance_to_nearest_warehouse       latest_customer_review             is_happy_customer
                       0                           0                           0                            0
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Kiểm tra phân trăm của các giái trị ngoại lai:

```
apply(is.na(final_data_2),2,mean)
```

```
apply(is.na(final_data_3),2, mean)
                  order_id                     customer_id                            date
               0.000000000                     0.000000000                     0.000000000
          nearest_warehouse                   shopping_cart                     order_price
               0.000000000                     0.000000000                     0.020040080
           delivery_charges                    customer_lat                   customer_long
               0.002004008                     0.000000000                     0.020040080
            coupon_discount                     order_total                          season
               0.000000000                     0.000000000                     0.000000000
      is_expedited_delivery distance_to_nearest_warehouse         latest_customer_review
               0.000000000                     0.000000000                     0.000000000
          is_happy_customer
               0.000000000
```

Nhận xét: Có 30 dữ liệu ngoại lại, chiếm 3%, tỷ lệ khá nhỏ. Ta có thể loại bỏ ngoại lai và vẽ lại đồ thị mà không làm thay đổi kết quả thống kê.

```
final_data_2<-na.omit(final_data_2)

boxplot(fileht$order_total~fileht$nearest_warehouse, col =c('pink', 'grey', 'green'),
        main = "Biểu đồ hộp biểu thị chi phí đặt hàng ở 3 kho",
        xlab="Kho", ylab = "Tổng chi phí đặt hàng", final_data_2)
```

TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

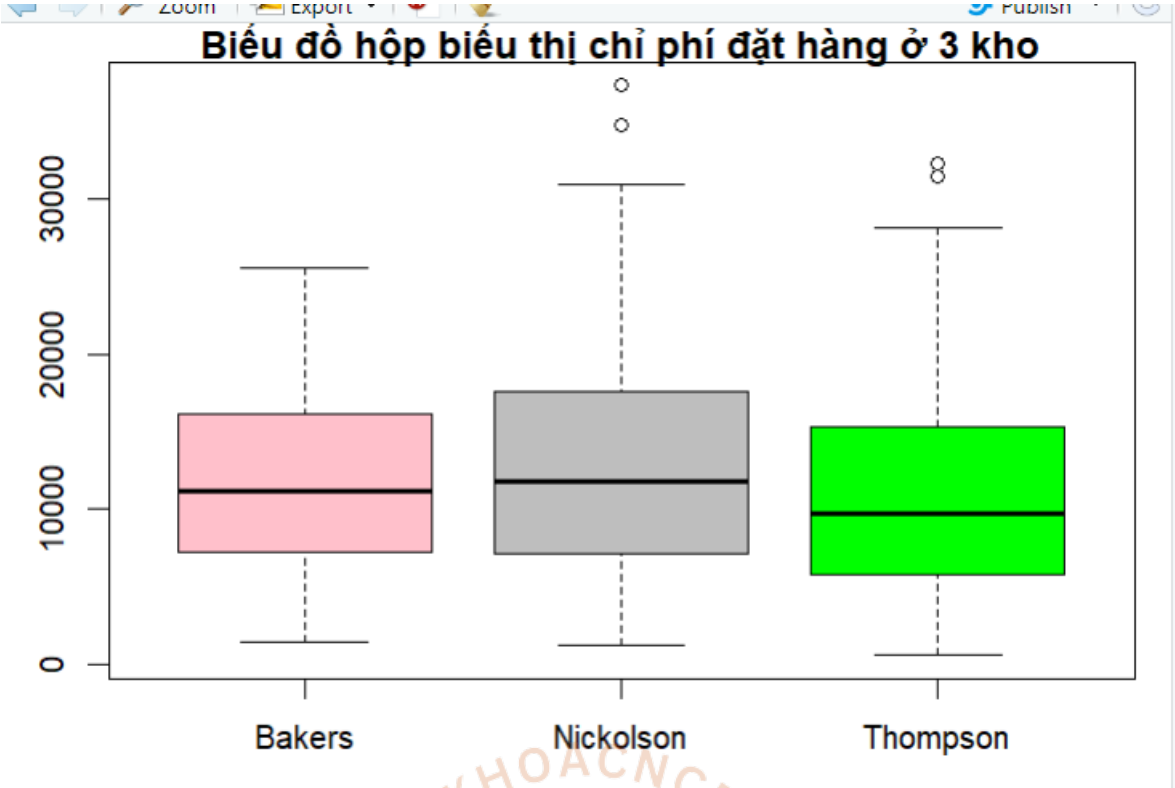

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

- Biểu đồ hộp biểu thị chi phí vận chuyển của 3 kho:

```
boxplot(delivery_charges~nearest_warehouse,
        main = "Biểu đồ hộp biểu thị chi phí vận chuyển của 3 kho", fileht)
```

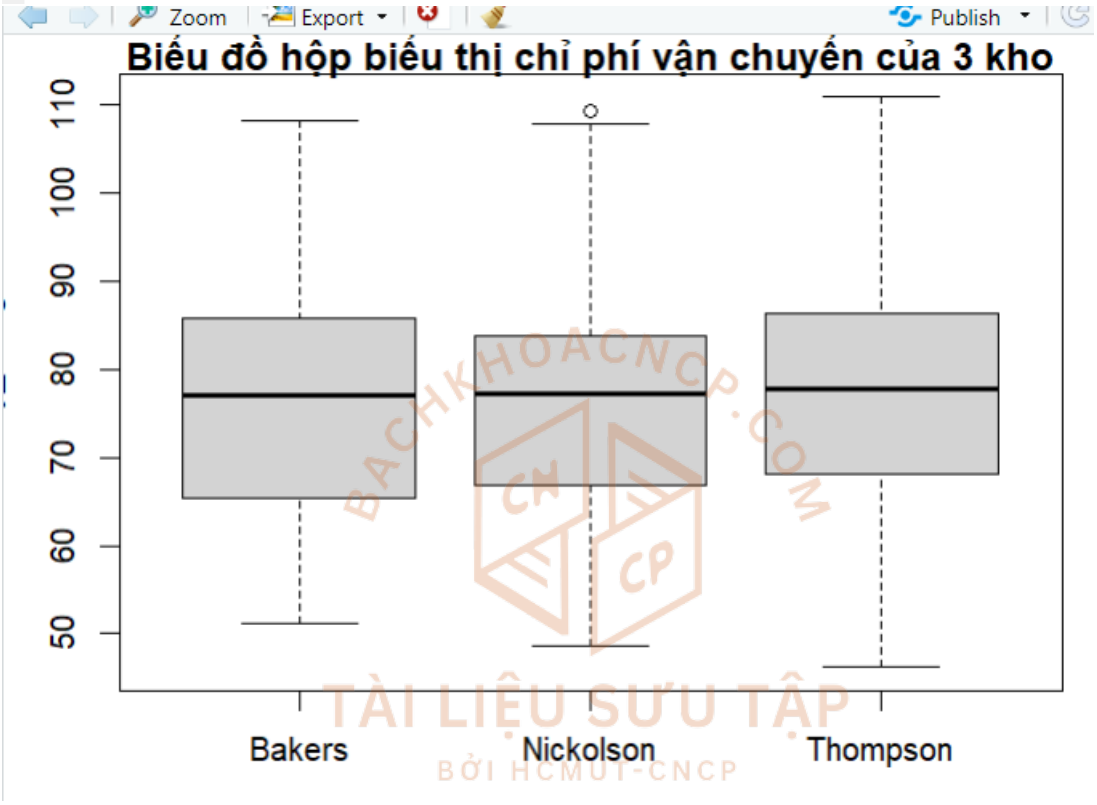

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

Nhận xét: Qua biểu đồ trên, ta thấy còn nhiều điểm ngoại lai, làm ta không thể xác định được các quy luật phân phối nên cần xử lý lại biểu đồ bằng cách loại bỏ một số điểm ngoại lai làm ảnh hưởng đến thống kê.

Tìm các giá trị ngoại lai và kiểm tra tổng các giá trị ngoại lai:

```
rm.out <- function(x, na.rm = TRUE, ...){
  qnt <- quantile(x, probs=c(.25, .75), na.rm =na.rm, ...)
  H<- 1.5* IQR(x, na.rm = na.rm)
  y <- x
  y[x < (qnt[1]-H)] <- NA
  y[x > (qnt[2]+H)] <- NA
  y
}
Bakers_data_1 = subset(fileht,fileht$nearest_warehouse =="Bakers")
Bakers_data_1$delivery_charges= rm.out (Bakers_data_1$delivery_charges)
Nickolson_data_1 = subset(fileht, fileht$nearest_warehouse =="Nickolson")
Nickolson_data_1$delivery_charges= rm.out(Nickolson_data_1$delivery_charges)
Thompson_data_1 = subset(fileht, fileht$nearest_warehouse =="Thompson")
Thompson_data_1$delivery_charges = rm.out(Thompson_data_1$delivery_charges)
final_data_3 <- rbind(Bakers_data_1, Nickolson_data_1, Thompson_data_1)
apply(is.na(final_data_3),2, sum)
```

```
apply(is.na(final_data_3),2, sum)
                  order_id                     customer_id                            date
                         0                               0                               0
          nearest_warehouse                   shopping_cart                     order_price
                         0                               0                              10
           delivery_charges                    customer_lat                   customer_long
                         1                               0                              10
            coupon_discount                     order_total                          season
                         0                               0                               0
      is_expedited_delivery distance_to_nearest_warehouse          latest_customer_review
                         0                               0                               0
          is_happy_customer
                         0
```

Kiểm tra phần trăm giá trị ngoại lai:

```
apply(is.na(final_data_3),2, mean)
```

```
apply(is.na(final_data_3),2, mean)
                  order_id                     customer_id                            date
               0.000000000                    0.000000000                     0.000000000
          nearest_warehouse                   shopping_cart                     order_price
               0.000000000                    0.000000000                     0.020040080
           delivery_charges                    customer_lat                   customer_long
               0.002004008                    0.000000000                     0.020040080
            coupon_discount                     order_total                          season
               0.000000000                    0.000000000                     0.000000000
      is_expedited_delivery distance_to_nearest_warehouse          latest_customer_review
               0.000000000                    0.000000000                     0.000000000
          is_happy_customer
               0.000000000
```

BACHKHOACNCP.COM

Nhận xét: Ta thấy phần trăm giá trị ngoại lai chỉ chiếm 0.2% rất nhỏ. Ta có thể tiến hành xóa bỏ các quan sát chưa NA và vẽ lại đồ thị mà không bị ảnh hưởng đáng kể:

```
final_data_3<-na.omit(final_data_3)
boxplot(delivery_charges~nearest_warehouse,
main ="Biểu đồ hộp biểu thị chi phí vận chuyển của 3 kho",
xlab="Kho", ylab ="Chi phí vận chuyển", col = "LightCoral", final_data_3)
```

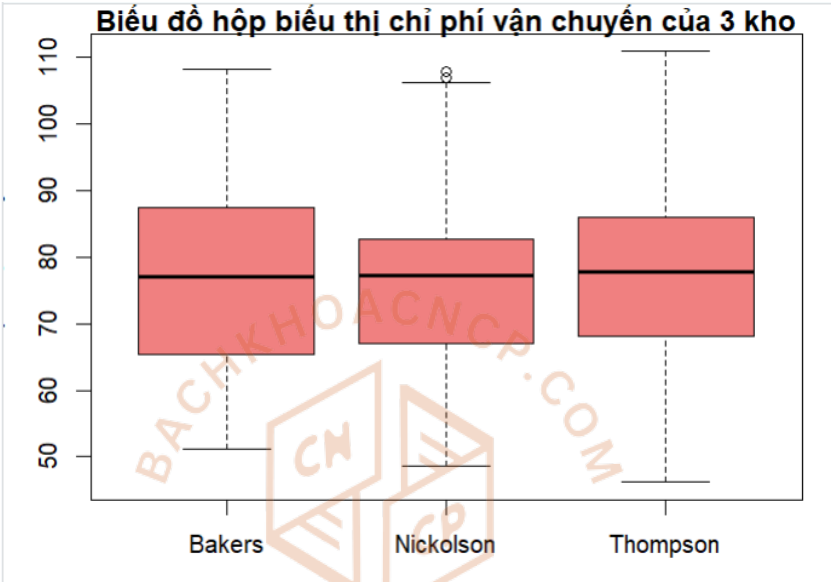

Nhận xét: Sau khi xử lý lại biểu đồ thì ta thấy được tổng chi phí vận chuyển của 3 kho gần như bằng nhau không có sự khác biệt nhiều.

- Biểu đồ hộp biểu thị chi phí đặt hàng trong 4 mùa

```
boxplot(order_total ~ season, final_data_2,
  main="Biểu đồ hộp biểu thị chi phí đặt hàng trong 4 mùa", xlab="Mùa", ylab="Chi phí đặt hàng")
```

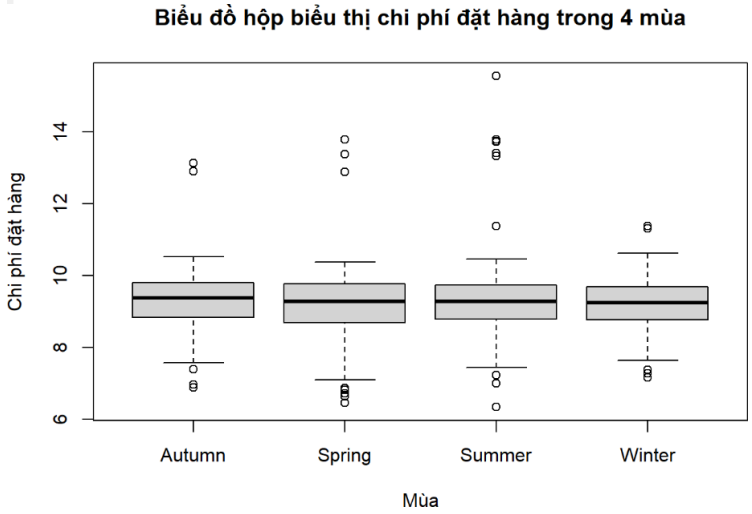

BACHKHOACNCP.COM

Nhận xét: Qua biểu đồ trên, ta thấy còn nhiều điểm ngoại lai, làm ta không thể xác định được các quy luật phân phối nên cần xử lý lại biểu đồ bằng cách loại bỏ một số điểm ngoại lai làm ảnh hưởng đến thống kê.

Tìm các giá trị ngoại lai và tổng các giá trị ngoại lai:

```
Spring_data = subset(fileht, fileht$season =="Spring")
Spring_data$order_total = rm.out(Spring_data$order_total)
Summer_data = subset(fileht, fileht$season =="Summer")
Summer_data$order_total = rm.out(Summer_data$order_total)
Autumn_data = subset(fileht, fileht$season =="Autumn")
Autumn_data$order_total = rm.out(Autumn_data$order_total)
Winter_data=subset(fileht, fileht$season =="Winter")
Winter_data$order_total =rm.out(Winter_data$order_total)
final_data_1 <-rbind(Spring_data, Summer_data,Autumn_data, Winter_data)

apply(is.na(final_data_1),2, sum)
```

```
> apply(is.na(final_data_1),2, sum)
                   order_id                        customer_id                               date
                          0                                  0                                  0
          nearest_warehouse                      shopping_cart                        order_price
                          1                                  0                                 10
           delivery_charges                       customer_lat                       customer_long
                          0                                  0                                 10
            coupon_discount                        order_total                             season
                          0                                  7                                  0
      is_expedited_delivery distance_to_nearest_warehouse                latest_customer_review
                          0                                  0                                  0
          is_happy_customer
                          0
```

Kiểm tra phần trăm giá trị ngoại lai:

```
apply(is.na(final_data_1),2, mean)
```

```
> apply(is.na(final_data_1),2, mean)
                   order_id                        customer_id                               date
                      0.000                              0.000                              0.000
          nearest_warehouse                      shopping_cart                        order_price
                      0.002                              0.000                              0.020
           delivery_charges                       customer_lat                       customer_long
                      0.000                              0.000                              0.020
            coupon_discount                        order_total                             season
                      0.000                              0.014                              0.000
      is_expedited_delivery distance_to_nearest_warehouse                latest_customer_review
                      0.000                              0.000                              0.000
          is_happy_customer
                      0.000
```

Nhận xét: Các giá trị ngoại lai chỉ chiếm 3%, rất nhỏ. Trong trường hợp này, ta có thể tiến hành loại bỏ các giá trị NA và vẽ đồ thị mà không làm ảnh hưởng đến thống kê.

```
final_data_1<-na.omit(final_data_1)
boxplot(order_total ~ season, main="Biểu đồ hộp biểu thị chi phí đặt hàng trong 4 mùa",
    xlab="Mùa", ylab ="Chi phí đặt hàng", col ="LavenderBlush", final_data_1)
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BK HCMUT-CNCP

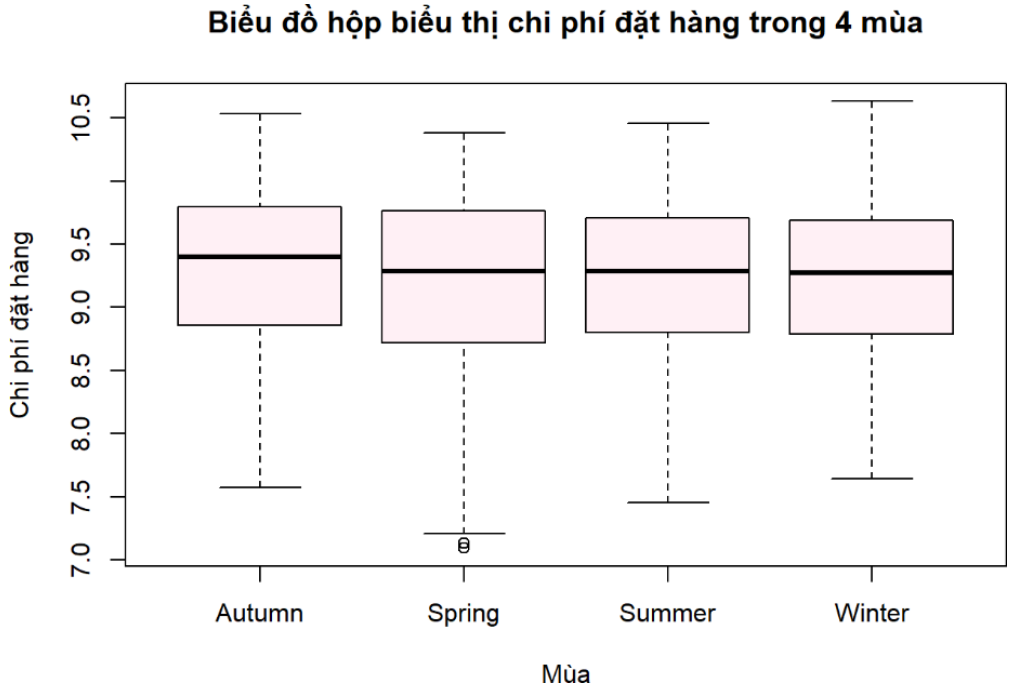

Nhận xét: Sau khi xử lý lại đồ thị, ta thấy không có sự khác biệt nhiều về chi phí đặt hàng ở 4 mùa

5 Thống kê suy diễn

5.1 kiểm định ANOVA

5.1.1 So sánh trung bình về chi phí đặt hang của khách hàng ở 3 kho

- Cửa hang Bakers

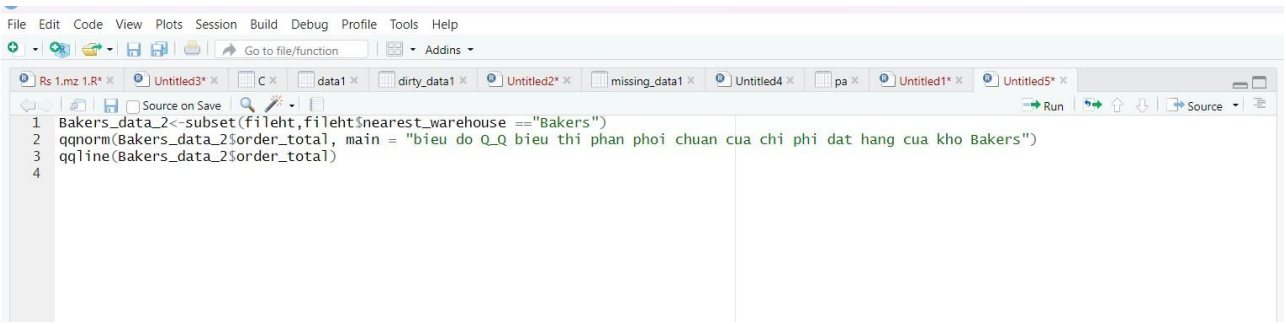

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

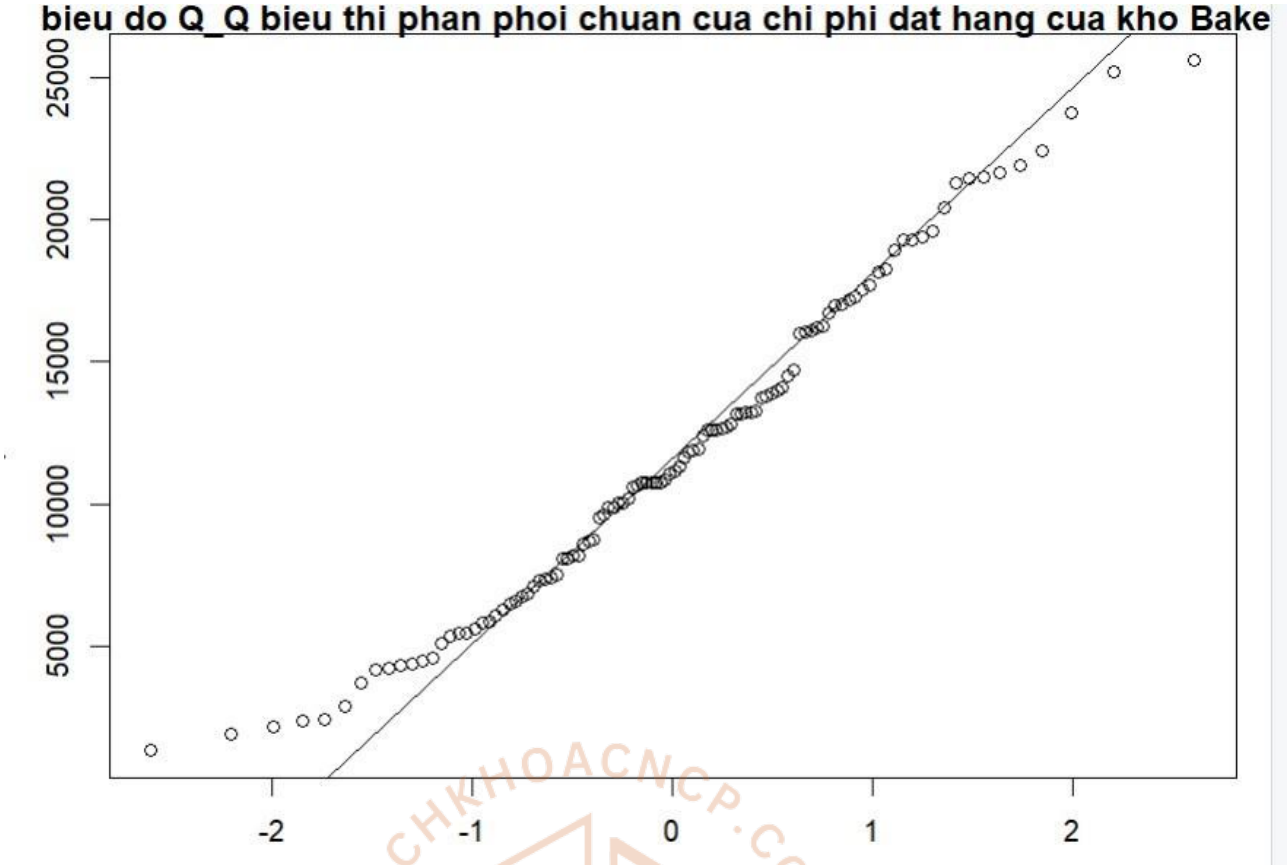

Nhận xét: Dựa vào đồ thị trên, ta thấy có các quan sát không nằm trên đường xu hướng, nên có thể kết luận rằng, chi phí của cửa hàng Bakers không tuân theo phân phối chuẩn. Kiểm tra bằng kiểm định Shapiro-Wilk test:

```
        Shapiro-Wilk normality test

data:  Bakers_data_2$order_total
W = 0.97728, p-value = 0.0612

>
```

- Cửa hang NICKOLSON

```
Nickolson_data_2<-subset(fileht,fileht$nearest_warehouse =="Nickolson")
qqnorm(Nickolson_data_2$order_total, main = "bieu do Q_Q bieu thi phan phoi chuan cua chi phi dat hang cua kho Nickolson")
qqline(Nickolson_data_2$order_total)
```

BACHKHOACNCP.COM

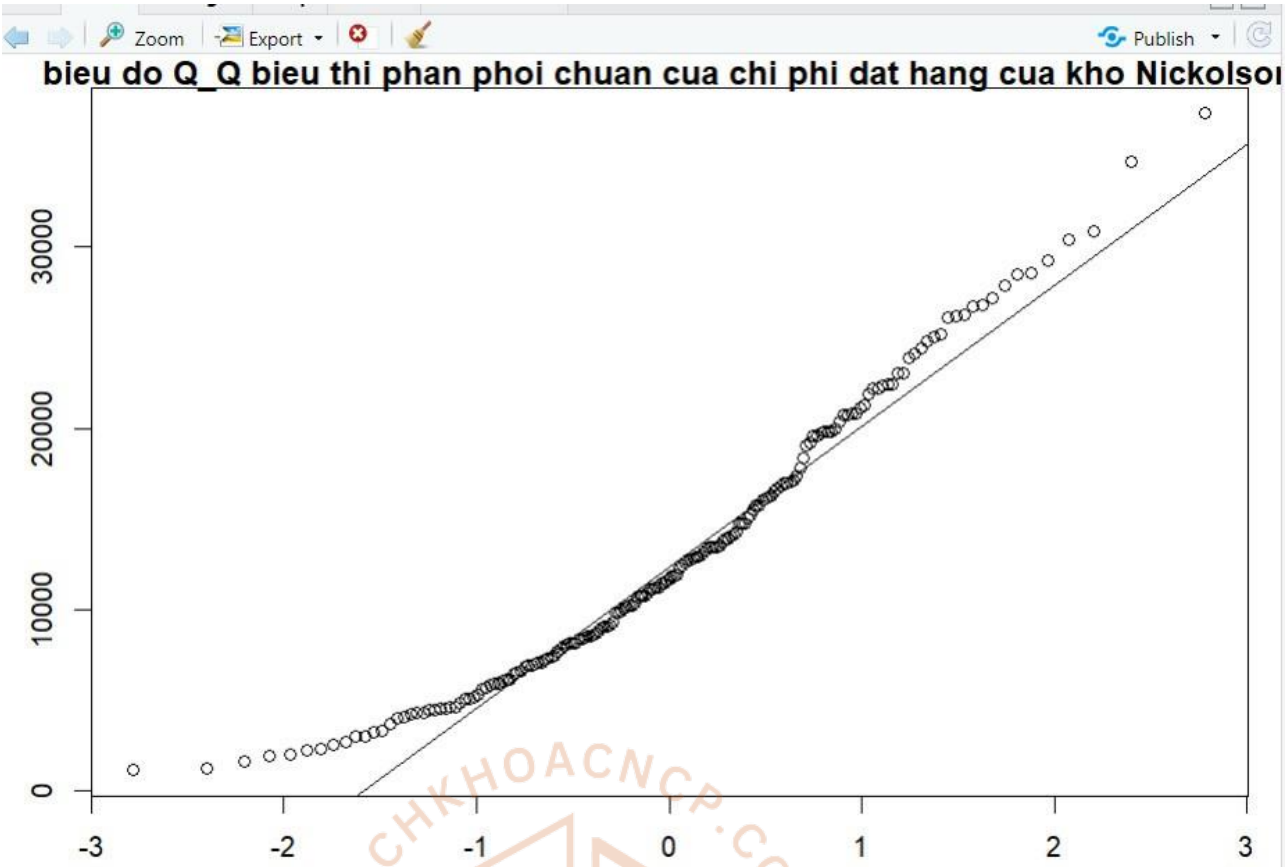

Nhận xét: Dựa vào đồ thị trên, ta thấy có các quan sát không nằm trên đường xu hướng, nên có thể kết luận rằng, chi phí của cửa hàng Nickolson không tuân theo phân phối chuẩn. Kiểm tra bằng kiểm định Shapiro-Wilk test:

```
data:  Nickolson_data_2$order_total
W = 0.95491, p-value = 1.4e-05
```

- Cửa hang Thompson

```
Thompson_data_2<-subset(fileht,fileht$nearest_warehouse =="Thompson")
qqnorm(Thompson_data_2$order_total, main = "bieu do Q_Q bieu thi phan phoi chuan cua chi phi dat hang cua kho Thompson")
qqline(Thompson_data_2$order_total)
```

BACHKHOACNCP.COM

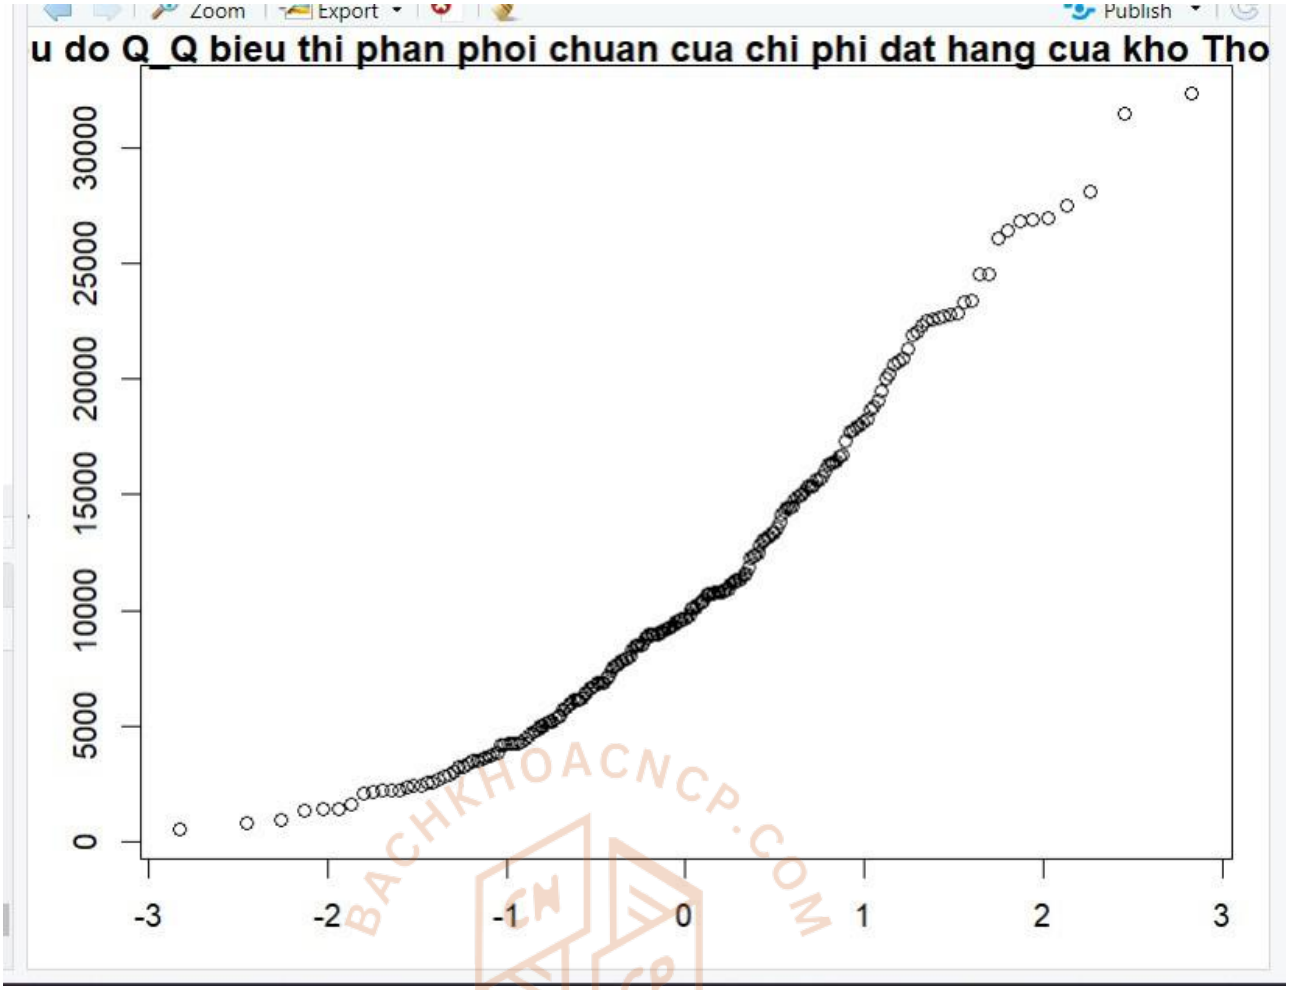

Nhận xét: Dựa vào đồ thị trên, ta thấy có các quan sát không nằm trên đường xu hướng, nên có thể kết luận rằng, chi phí của cửa hàng Thompson không tuân theo phân phối chuẩn. Kiểm tra bằng kiểm định Shapiro-Wilk test:

```
        Shapiro-Wilk normality test

data:  Thompson_data_2$order_total
W = 0.94453, p-value = 3.697e-07

>
```

5.1.2 So sánh trung bình đặt hàng của khách hang 4 mùa

- **Mùa xuân**

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

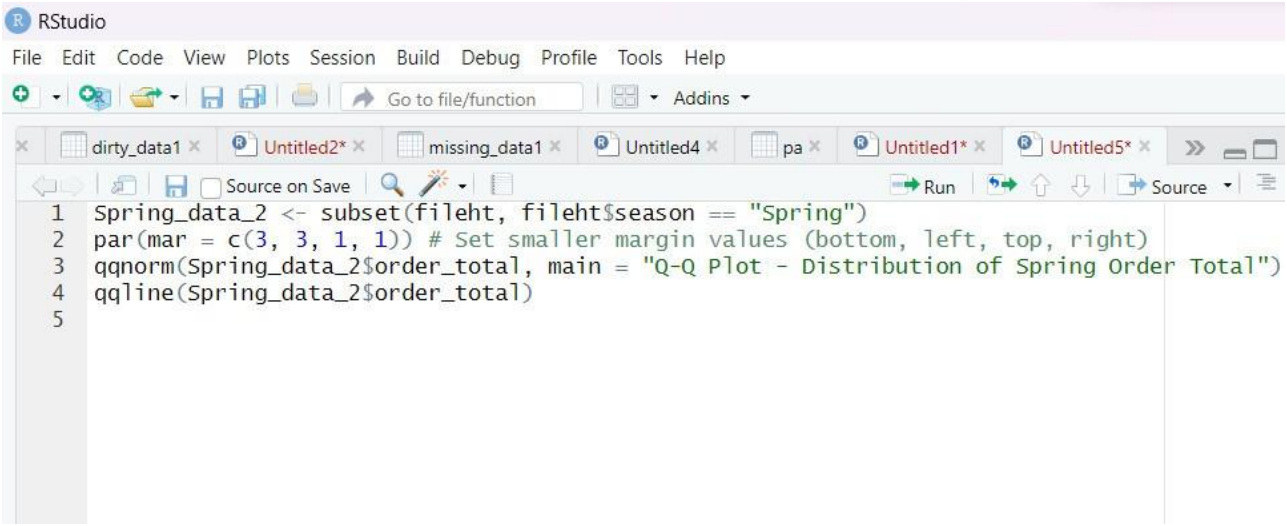

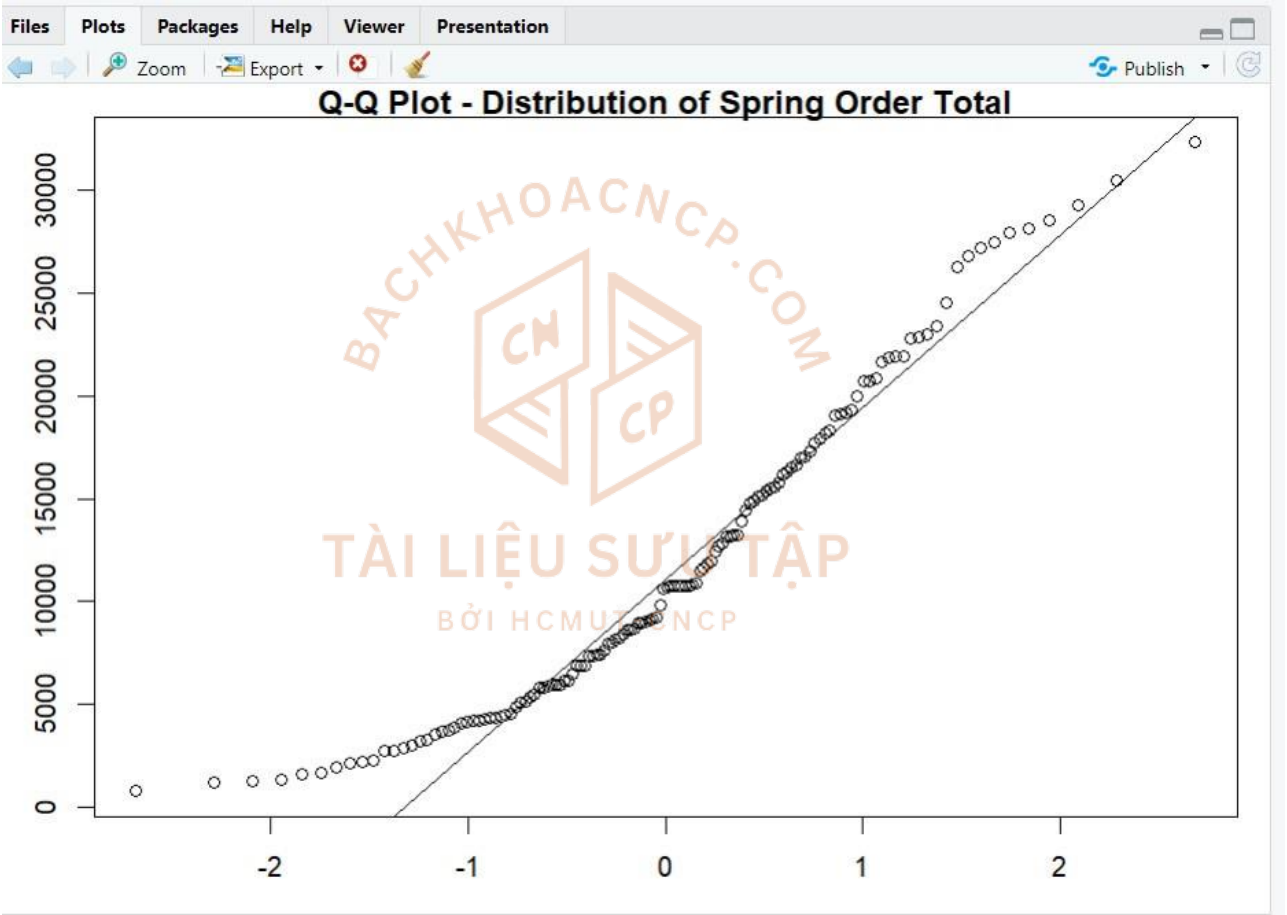

Nhận xét: Biểu đồ cho thấy rằng những giá trị quan sát đa phần nằm lệch khỏi đường thẳng kì vọng của phân phối chuẩn, do đó chi phí đặt hàng mùa xuân không theo phân phối chuẩn.

- **Mùa hạ**

BACHKHOACNCP.COM

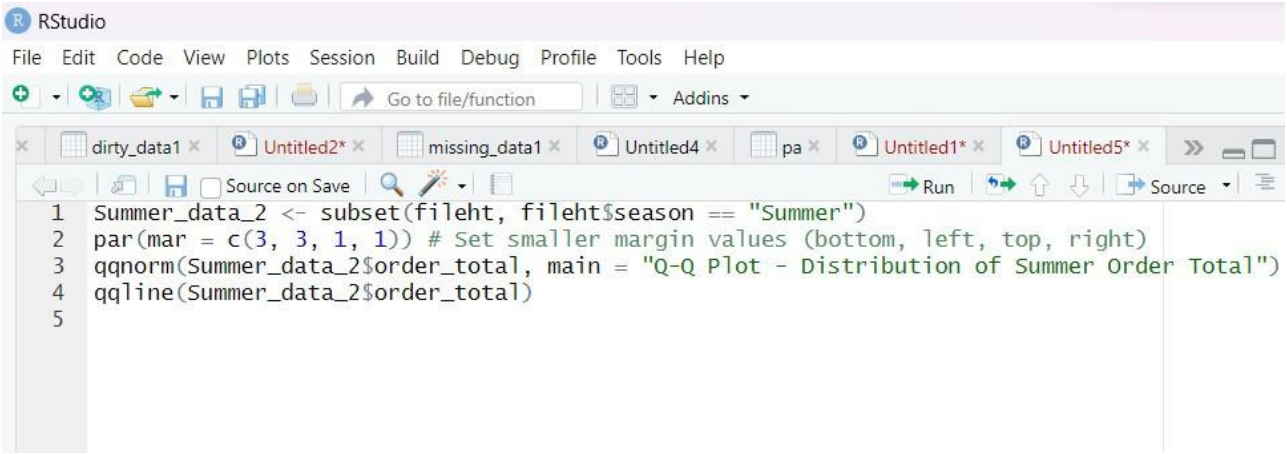

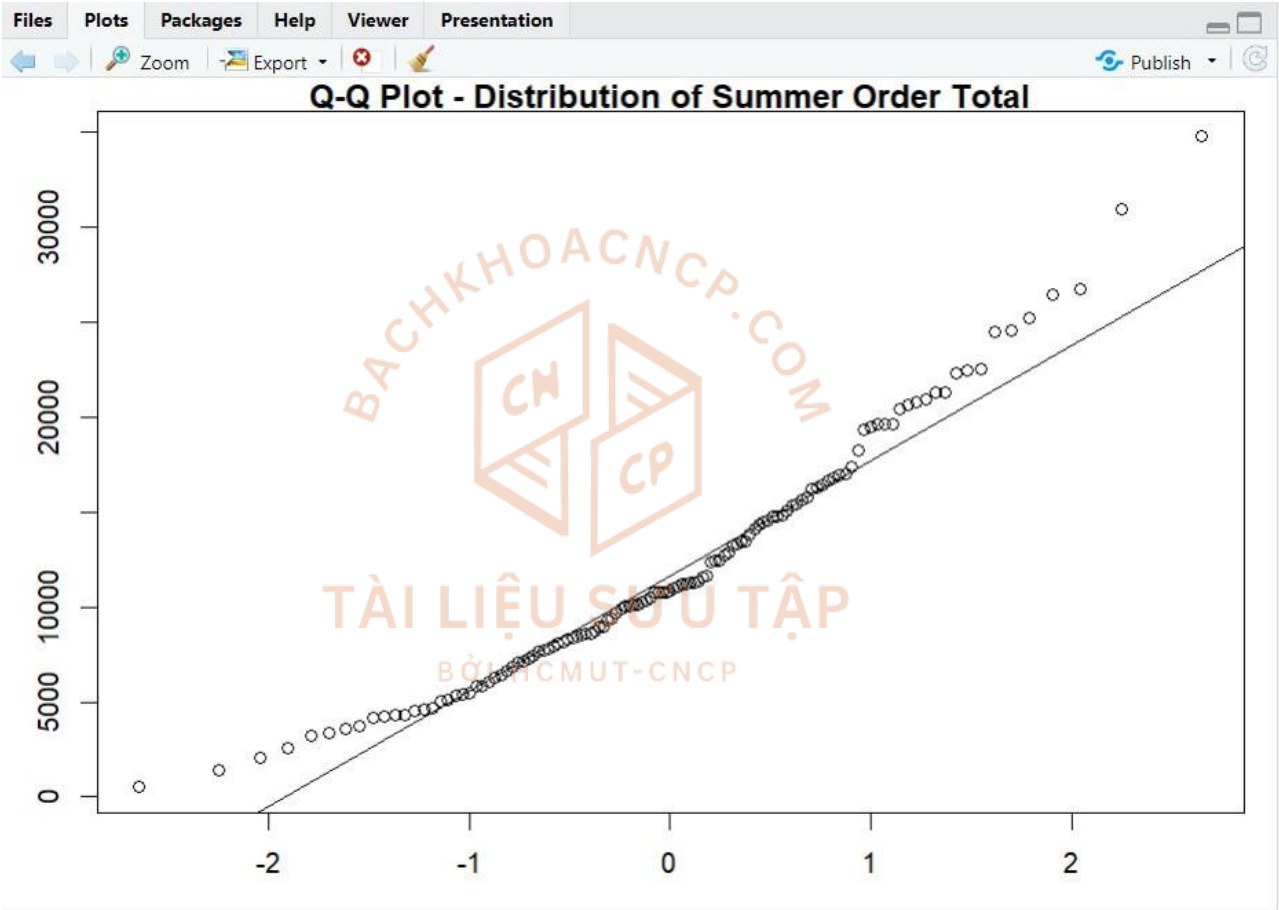

Nhận xét: Biểu đồ cho thấy rằng những giá trị quan sát đa phần nằm lệch khỏi đường thẳng kì vọng của phân phối chuẩn, do đó chi phí đặt hàng mùa hè không theo phân phối chuẩn

- **Mùa thu**

BACHKHOACNCP.COM

```r
Autumn_data_2 <- subset(fileht, fileht$season == "Autumn")
par(mar = c(3, 3, 1, 1)) # Set smaller margin values (bottom, left, top, right)
qqnorm(Autumn_data_2$order_total, main = "Q-Q Plot - Distribution of Autumn Order Total")
qqline(Autumn_data_2$order_total)
```

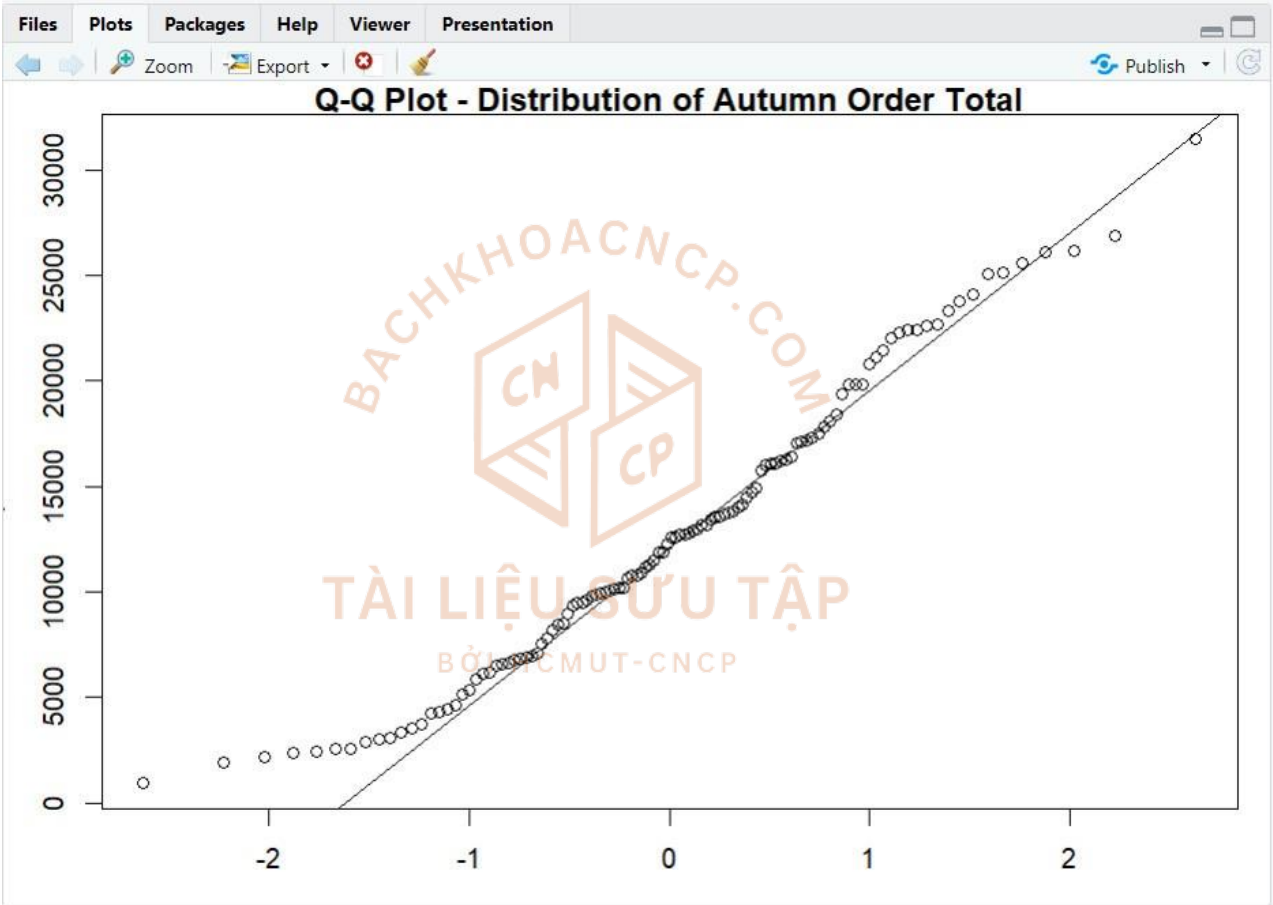

Nhận xét: Biểu đồ cho thấy rằng những giá trị quan sát đa phần nằm lệch khỏi đường thẳng kì vọng của phân phối chuẩn, do đó chi phí đặt hàng mùa thu không theo phân phối chuẩn

- **Mùa đông**

BACHKHOACNCP.COM

```r
Winter_data_2 <- subset(fileht, fileht$season == "Winter")
par(mar = c(3, 3, 1, 1)) # Set smaller margin values (bottom, left, top, right)
qqnorm(Winter_data_2$order_total, main = "Q-Q Plot - Distribution of Winter Order Total")
qqline(Winter_data_2$order_total)
```

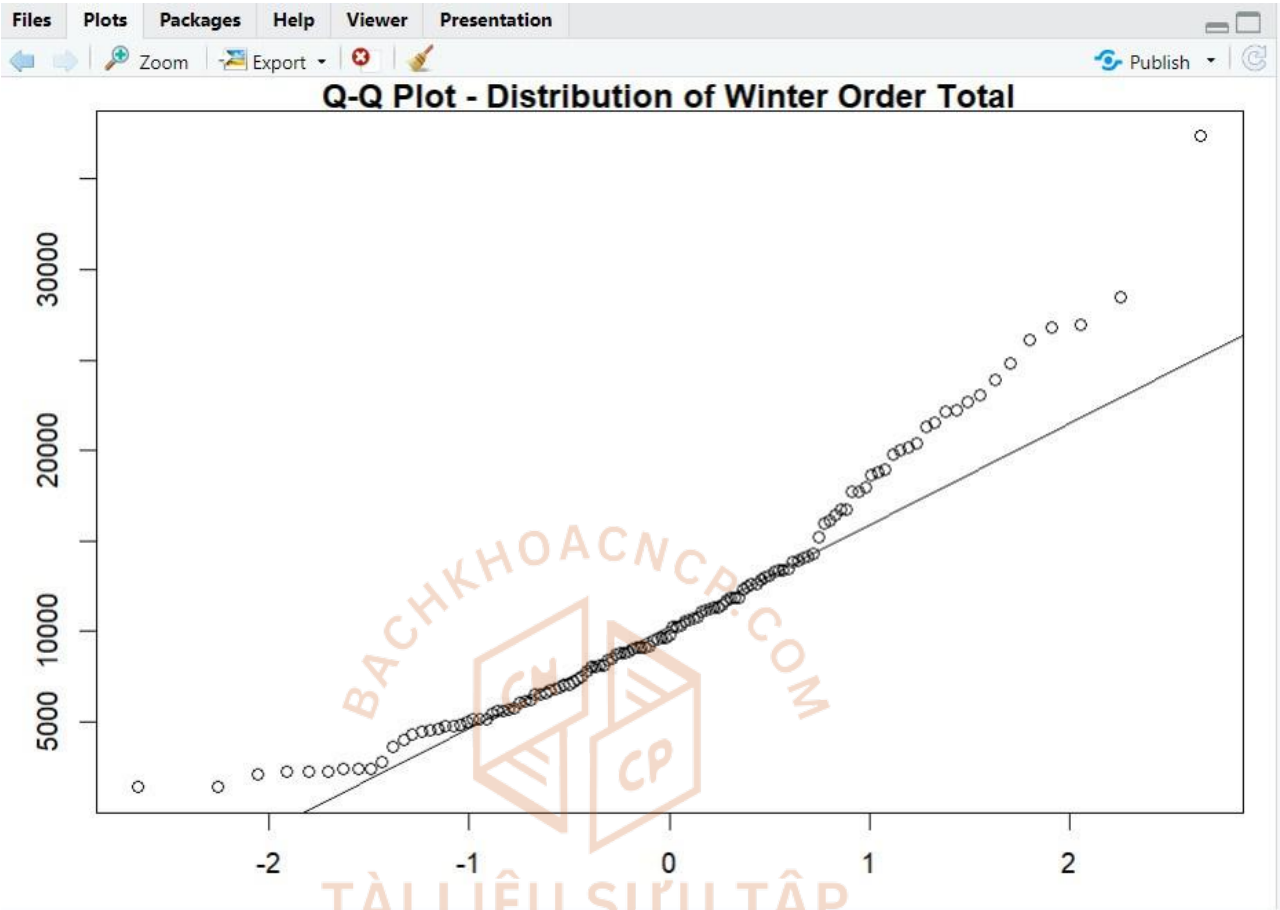

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Nhận xét: Biểu đồ cho thấy rằng những giá trị quan sát đa phần nằm lệch khỏi đường thẳng kì vọng của phân phối chuẩn, do đó chi phí đặt hàng mùa đông không theo phân phối chuẩn

BACHKHOACNCP.COM

6. Thảo luận và mở rộng

Tổng kết lại, hồi quy logistic và kiểm định ANOVA là hai phương pháp thống kê mạnh mẽ được sử dụng trong các tình huống và mục tiêu khác nhau. Hồi quy logistic tập trung vào dự đoán xác suất của biến phụ thuộc nhị phân, trong khi kiểm định ANOVA nhấn mạnh sự khác biệt trung bình giữa các nhóm.

Ngoài 2 phương pháp kiểm định trên, hiện nay có rất nhiều phương án kiểm định khác nhau và phù hợp với từng dạng dữ liệu khác nhau:

Kiểm định t-Test:

- Sử dụng khi bạn chỉ muốn so sánh trung bình giữa hai nhóm.
- Phù hợp cho dữ liệu liên tục và có phân phối chuẩn.

Kiểm định Wilcoxon-Mann-Whitney (U Test):

- Sử dụng khi dữ liệu không đáp ứng các điều kiện của t-Test.
- Phù hợp cho dữ liệu không phân phối chuẩn hoặc có tính chất rang và thứ tự.

Kiểm định Log-Rank (Survival Analysis):

- Sử dụng khi quan tâm đến thời gian đến sự kiện (survival time) và muốn so sánh các nhóm theo thời gian.

Phân tích Đánh giá Hiệu quả (Cost-Effectiveness Analysis):

- Sử dụng trong kinh tế y tế để đánh giá mức hiệu quả của một phương pháp so với phương pháp khác.

7. Tổng kết

Với chủ đề dự đoán mức độ hài lòng của khách hằng thông qua phương pháp hồi quy logistic với ngôn ngữ lập trình R, nhóm chúng em đã có cái nhìn trực quan hơn về cách trích xuất dữ liệu, xử lý và phân tích dữ liệu thô, biến chúng thành nguồn dữ liệu có giá trị lâu dài hoặc tốt hơn nữa là có khả năng khái quát hóa tình hình chung và đưa ra dự đoán về bộ dữ liệu.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Ngoài ra, sau khi học ngôn ngữ lập trình R và sử dụng RMarker để áp dụng tính toán phân tích và vẽ đồ thị, chúng ta đạt được nhiều kỹ năng hơn trong việc quản lý thời gian của đồ án, thực hiện đúng trình tự của kế hoạch đề ra cũng như có được kỹ năng giải quyết vấn đề khi gặp khó khăn trong quá trình xử lý các bộ dữ liệu phức tạp. Việc hợp tác thực hiện dự án đã nâng cao năng lực và trách nhiệm trong công việc của mỗi thành viên trong nhóm. Chắc chắn trong quá trình thực hiện dự án chắc chắn không thể tránh khỏi những sai sót. Vì vậy, chúng em rất mong nhận được những ý kiến đóng góp từ giảng viên để thực hiện các dự án chỉnh chu và chuyên nghiệp hơn trong tương lai

Cuối cùng, chúng em, với tư cách là tác giả của dự án này, hy vọng rằng các giải pháp của chúng em sẽ đáp ứng được những vấn đề được đưa ra.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM