ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

BÀI TẬP LỚN MÔN HỌC

XÁC SUẤT VÀ THỐNG KÊ (MT2013)

ĐỀ TÀI

Transactional Retail Dataset of Electronics Store

Lớp: Nhóm: Học kỳ: 231

GVHD: Phan Thị Hường

Khoa: Điện- Điện tử

NHÓM SINH VIÊN THỰC HIỆN

STT	MSSV	HỌ	TÊN	ĐIỂM BTL	GHI CHÚ
1					
2					
3					

TP. HỒ CHÍ MINH – THÁNG 11 NĂM 2023

BACHKHOACNCP.COM

BÁO CÁO PHÂN CÔNG NHIỆM VỤ VÀ KẾT QUẢ THỰC HIỆN ĐỀ TÀI CỦA TỪNG THÀNH VIÊN

NHÓM: 12 – LỚP: L10 – HỌC KỲ: 231 – MÔN: XÁC SUẤT VÀ THỐNG KÊ (CH2013)

STT	MSSV	Họ	Tên	Nhiệm vụ	Đóng góp	Điểm tổng kết
1						
2						
3						

BACHKHOACNCP.COM

MỤC LỤC

1. Tổng quan dữ liệu **1**

1.1 Ngữ cảnh của dữ liệu ***1***

1.1. Các biến ***1***

1.2. Xử lý số hiệu ***2***

2. Kiến thức nền **2**

3. Tiền xử lý số liệu **6**

3.1 Đọc dữ liệu ***6***

3.2 Phát hiện lỗi và sửa lỗi trong dirty_data.csv ***6***

4. Thống kê mô tả **10**

4.1 Lọc các biến mà ta quan tâm ***10***

4.2 Làm rõ dữ liệu ***11***

5. Thống kê suy diễn **21**

5.1 Kiểm định một mẫu ***21***

5.2 ANOVA ***22***

5.3 Hồi quy tuyến tính ***25***

6. Thảo luận và mở rộng **29**

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

1. **Tổng quan dữ liệu**

1.1 Ngữ cảnh của dữ liệu

Tập dữ liệu chứa thông tin về một cửa hàng điện tử trực tuyến. Cửa hàng có ba kho để giao hàng cho khách hàng. Dựa vào dữ liệu trên tìm được mối quan hệ giữa các biến để từ đó đưa ra được phỏng đoán, xây dựng được mô hình dự báo mức độ hài lòng của khách hàng

- Tiêu đề : Transactional Retail Dataset of Electronics Store
- Thông tin nguồn :

- Tác giả : SHAHRAYAR
- Ngày : 2 năm trước

- Giá trị quan trắc : 500
- Số lượng biến : 16

1.1. Các biến

Dữ liệu bao gồm các biến:

- **order_id:** Một id duy nhất cho mỗi đơn hàng
- **customer_id:** Một id duy nhất cho mỗi khách hàng
- **date:** Ngày đặt hàng, được đưa ra ở định dạng YYYY-MM-DD
- **nearest_warehouse**: Một chuỗi biểu thị tên kho gần khách hàng nhất
- **shopping_cart**: Danh sách các bộ dữ liệu đại diện cho các mục đơn hàng: phần tử đầu tiên của bộ dữ liệu là mục được sắp xếp và phần tử thứ hai là số lượng đặt hàng cho mặt hàng đó
- **order_price:** Một số float biểu thị giá đặt hàng bằng USD. Giá đặt hàng là giá của mặt hàng trước khi có bất kỳ khoản giảm giá và/hoặc phí giao hàng nào được áp dụng.
- **delivery_charges:** Một hình nổi thể hiện phí giao hàng của đơn hàng
- **customer_lat:** Vĩ độ vị trí của khách hàng
- **customer_long:** Kinh độ vị trí của khách hàng
- **coupon_discount:** Một số nguyên biểu thị phần trăm chiết khấu được áp dụng cho order_price.
- **order_total:** một số float biểu thị tổng đơn đặt hàng bằng USD sau khi
- giảm giá và/hoặc phí giao hàng được áp dụng
- **season:** Một chuỗi biểu thị mùa mà đơn hàng được đặt.
- **is_expedited_delivery:** Một boolean biểu thị liệu khách hàng có yêu cầu giao hàng nhanh hay không **distance_to_nearest_warehouse:** Một số float biểu thị khoảng cách vòng

BACHKHOACNCP.COM

cung, tínhbằng km, giữa khách hàng và nhà kho gần nhất với họ.

- **latest_customer_review:** Một chuỗi thể hiện đánh giá mới nhất của khách hàng về đơn hàng gần đây nhất của họ
- **is_happy_customer:** Một boolean biểu thị liệu khách hàng có hài lòng hay không hoặccó vấn đề với đơn hàng gần đây nhất của họ.

1.2. Xử lý số liệu

Tệp **dirty_data.csv** chứa thông tin về một cửa hàng điện tử trực tuyến. Cửa hàng có ba kho để giao hàng cho khách hàng.

ĐỀ :

- Phát hiện và sửa lỗi trong **dirty_data.csv**
- Phát hiện và loại bỏ các bất thường.
- Để kiểm tra xem khách hàng có hài lòng với đơn hàng cuối cùng của họ không?

Dữ liệu gốc được cung cấp tại:

https://www.kaggle.com/datasets/muhammadshahrayar/transactional-retail-dataset-of-electronics-store?select%3Ddirty_data.csv=&sa=D&source=editors&ust=1699428221686725&usg=AOvVaw015l5HqRmPf8cmfuKulXF-

Mục đích của file là đánh giá sự hài lòng của khách hàng khi mua đồ điện tử ở cửa hàng điện tử online. Với giá trị quan trắc là giỏ hàng, 1 giá trị quan trắc là 1 giỏ hàng có tổng mẫu là 500 nên ta có được 500 tổng mẫu hay còn gọi là 500 giá trị quan trắc.

Các biến phân loại: order_id, customer_id, date, nearest_warehouse, shopping_cart, season, is_expedited_delivery, latest_customer_review, is_happy_customer.

Các biến liên tục: order_price, delivery_charges, customer_lat, customer_long, coupon_discount, order_total.

2. Kiến thức nền

a. Mean (giá trị trung bình) được tính bằng $\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$ với n là cỡ mẫu

b. Median (trung vị tổng thể) là một giá trị x_0 thoả cả 2 tính chất $P(X \leq x_0) \geq 0.5$ và $P(X \geq x_0) \geq 0.5$

BACHKHOACNCP.COM

Mức phân vị $100p\%$ tổng thể là giá trị x_0 thoả cả 2 tính chất $P(X \leq x_0) \geq p$ và $P(X \geq x_0) \geq 1 - p$

- Mức phân vị 25% mẫu được gọi là mức phân vị thứ nhất, ký hiệu **Q1**.
- Mức phân vị 75% mẫu được gọi là mức phân vị thứ 3, ký hiệu **Q3**.

c. Kiểm định 1 mẫu

Xét bài toán kiểm định giả thuyết có giả thuyết H0 và đối thuyết H1, với mức ý nghĩa α cho trước. Một quy trình kiểm định bao gồm 4 bước:

BƯỚC 1: Phát biểu giả thuyết H0 và đối thuyết H1.

BƯỚC 2: Tính giá trị kiểm định thống kê dựa trên giả sử rằng H0 đúng.

BƯỚC 3: Xác định miền bác bỏ trị số p-value dựa trên phân phối của tiêu chuẩn kiểm định thống kê.

BƯỚC 4: Đưa ra kết luận bác bỏ H0 nếu giá trị kiểm định thống kê thuộc miền bác bỏ hoặc pvalue < α.

Với p-value cung cấp một thước đo về độ tin cậy của giả thuyết H0.

p-value	Độ tin cậy
<0.01	Chứng cứ rất mạnh để bác bỏ H0
0.01-0.05	Chứng cứ mạnh để bác bỏ H0
0.05-0.1	Chứng cứ rất yếu để bác bỏ H0
>0.1	Không đủ chứng cứ để bác bỏ H0

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

d. ANOVA

Mục tiêu của phân tích phương sai là so sánh trung bình của nhiều nhóm (tổng thể) dựa trên các số trung bình của các mẫu quan sát từ các nhóm này và thông qua kiểm định giả thuyết để kết luận về sự bằng nhau của các số trung bình này. Trong nghiên cứu, phân tích phương sai được dùng như là một công cụ để xem xét ảnh hưởng của một hay một số yếu tố nguyên nhân (định tính) đến một yếu tố kết quả (định lượng).

ANOVA hai nhân tố dùng để: Nghiên cứu tác động của

- Hai nhân tố được quan tâm trên một biến phụ thuộc (biến giải thích).

BACHKHOACNCP.COM

Ví dụ: ảnh hưởng của ánh sáng (cường độ: mạnh, trung bình, yếu) và lượng nước (nhiều, ít) tưới lên chiều cao của cây.

- Tương tác giữa các mức khác nhau của hai nhân tố. Chẳng hạn, có tương tác nào giữa cường độ ánh sáng mạnh chiếu lên cây khi tưới nhiều nước hay không?

e. Hồi quy tuyến tính

Với phương trình

$$Y = \beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p + \epsilon$$

Được sử dụng xác định mối liên hệ giữa:

- Một biến phụ thuộc Y (biến đáp ứng), và
- Một hay nhiều biến độc lập $X_1, X_2, X_3, \ldots X_P$. Các biến này còn được gọi là biến giải thích.

Trong đó

$\beta_0, \beta_1, \beta_p$ là các tham số chưa biết, gọi là các hệ số hồi quy

x giải thích cho y.

ϵ là thành phần sai số, ϵ được giả sử có phân phối chuẩn với $E(\epsilon) = 0, Var(\epsilon) = \sigma^2$

Biến phụ thộc Y phải là biến liên tục

Các biến độc lập $X_1, X_2, X_3, \ldots X_P$ có thể là biến liên tục, hoặc phân loại.

Mối liên hệ giữa $X_1, X_2, X_3, \ldots X_P$ và Y được biểu diễn bởi một hàm tuyến tính.

Sự thay đổi trong Y được giả sử do những thay đổi trong $X_1, X_2, X_3, \ldots X_P$ gây ra.

Trên cơ sở xác định mối liên hệ giữa biến phụ thuộc Y và các biến giải thích $X_1, X_2, X_3, \ldots X_P$, ta có thể: dự đoán, dự báo giá trị của Y , giải thích tác động của sự thay đổi trong các biến giải thích lên biến phụ thuộc.

f. Đánh giá mô hình hồi quy tuyến tính

Đánh giá mô hình: Phân tích tính phù hợp của mô hình, kiểm tra giả định về sai số, đánh giá độ chính xác và tin cậy của dự đoán. Để đánh giá hiệu quả của mô hình hồi quy tuyến tính đa biến, có thể sử dụng các thước đo như hệ số xác định R^2, sai số chuẩn hóa, kiểm định F và kiểm định t.

BACHKHOACNCP.COM

Hệ số xác định R^2 : Hệ số xác định đo lường tỷ lệ phương sai của biến phụ thuộc được giải thích bởi mô hình hồi quy. Giá trị $R2$ dao động từ 0 đến 1, và càng gần 1 thì mô hình càng phù hợp. Tuy nhiên, $R2$ không phản ánh xem xét về sự phù hợp của các biến giải thích cụ thể trong mô hình.

Sai số chuẩn hóa: Sai số chuẩn hóa là các sai số của mô hình được chia cho độ lớn tiêu chuẩn. Điều này cho phép so sánh các sai số giữa các quan sát và đánh giá xem liệu chúng có tuân theo phân phối chuẩn hay không. Nếu sai số chuẩn hóa không tuân theo phân phối chuẩn và có cấu trúc không ngẫu nhiên, điều này có thể cho thấy mô hình không phù hợp.

Kiểm định F: Kiểm định F được sử dụng để kiểm tra tính chính xác và ý nghĩa chung của mô hình hồi quy. Kiểm định này kiểm tra xem ít nhất một trong các hệ số hồi quy khác không (β1, β2, ..., βn) có ý nghĩa thống kê, tức là có ảnh hưởng đáng kể đến biến phụ thuộc hay không. Giá trị p-value của kiểm định F được sử dụng để đánh giá ý nghĩa thống kê của mô hình.

Kiểm định t: Kiểm định t được sử dụng để kiểm tra ý nghĩa thống kê của từng hệ số hồi quy đơn lẻ (β1, β2, ..., βn). Giá trị p-value của kiểm định t được sử dụng để đánh giá xem liệu từng biến độc lập có ảnh hưởng đáng kể đến biến phụ thuộc hay không. *Phân tích sai số*: Phân tích sai số của mô hình là một bước quan trọng để đánh giá sự phù hợp. Nếu có mô hình hồi quy tốt, các sai số sẽ phân phối ngẫu nhiên xung quanh giá trị dự đoán. Phân tích sai số có thể bao gồm việc kiểm tra tính đồng nhất của phương sai sai số, kiểm tra sự không tương quan của sai số và kiểm tra sự không có yếu tố còn lại.

Kiểm tra độc lập và tương quan của biến độc lập: Đối với mô hình hồi quy tuyến tính, độc lập và tương quan giữa các biến độc lập là một yếu tố quan trọng để đánh giá sự phù hợp. Nếu các biến độc lập không độc lập hoặc có mức độ tương quan cao, điều này có thể ảnh hưởng đến độ chính xác và độ tin cậy của mô hình.

Bên cạnh chỉ số R^2, chúng ta còn có thêm chỉ số R^2Adjusted (R^2 hiệu chỉnh). Chỉ số R^2hiệu chỉnh không nhất thiết tăng lên khi nhiều biến độc lập được thêm vào hồi quy, do đó R^2 hiệu chỉnh phản ánh độ phù hợp của mô hình chính xác hơn hệ số R^2.

R^2 hay R^2 hiệu chỉnh đều có mức dao động trong đoạn từ 0 đến 1. Nếu R^2 càng tiến về 1, các biến độc lập giải thích càng nhiều cho biến phụ thuộc và ngược lại, R^2 càng tiến về 0, các biến độc lập giải thích càng ít cho biến phụ thuộc.

BACHKHOACNCP.COM

Bảng Coefficients

- Pr(>|t|) < 0.05: Bác bỏ giả thuyết H0, nghĩa là hệ số hồi quy của biến Xi khác 0 một cách có ý nghĩa thống kê, biến Xi có tác động lên biến phụ thuộc.

- Pr(>|t|) > 0.05: Chấp nhận giả thuyết H0, nghĩa là hệ số hồi quy của biến Xi bằng 0 một cách có ý nghĩa thống kê, biến Xi không tác động lên biến phụ thuộc

3. Tiền xử lý số liệu

3.1 Đọc dữ liệu

-Đọc dữ liệu "dirty_data.csv".

Hình 1: code R và kết quả khi đọc dữ liệu và bảng dữ liệu

```
dirt <- read.csv("D:/ElectricStore/dirty_data.csv") #Đọc dữ liệu
View(dirt) #Xem bảng dữ liệu
```

Dữ liệu nhận được như sau:

CodeFinal.R | dirt

Filter

	order_id	customer_id	date	nearest_warehouse	shopping_cart	order_price	delivery_charges	customer_lat	customer_long	coupon_discount	order_total	season	is_expedited_d
1	ORD182494	ID6197211592	2019-06-22	Thompson	[('Lucent 330S', 1), ('Thunder line', 2), ('iStream', 2), ('pearTV',...	12200	79.89	-37.81511	144.9328	10	11059.89	Winter	True
2	ORD395518	ID0282825849	2019-12-29	Thompson	[('Thunder line', 1), ('Universe Note', 2)]	9080	62.71	-37.80274	144.9511	0	9142.71	Summer	False
3	ORD494479	ID0579391891	2019-03-02	Nickolson	[('Thunder line', 1), ('pearTV', 2)]	10670	65.87	-37.82130	144.9576	10	9668.87	Autumn	False
4	ORD019224	ID4544561904	2019-01-12	Nickolson	[('Universe Note', 1), ('Alcon 10', 2), ('Olivia x460', 1), ('iAssist ...	24800	57.61	-37.81142	144.9731	15	21137.61	Summer	False
5	ORD104032	ID6231506320	2019-11-28	Nickolson	[('Universe Note', 1), ('Olivia x460', 1), ('iStream', 1), ('Toshika ...	9145	75.54	37.82386	144.9699	25	6934.29	Spring	False
6	ORD146760	ID0311654900	2019-09-16	Bakers	[('Thunder line', 2), ('Universe Note', 1)]	7810	71.22	37.82025	145.0149	10	7100.22	Spring	False
7	ORD337984	ID3394768956	2019-09-14	Thompson	[('Candle Inferno', 1), ('Alcon 10', 1), ('Toshika 750', 1)]	13700	74.84	-37.80774	144.9516	5	13089.84	Spring	False
8	ORD072312	ID0774517121	2019-05-23	Thompson	[('Universe Note', 1), ('Thunder line', 2), ('iStream', 1)]	7960	52.28	-37.80634	144.9595	5	10789.79	Autumn	False
9	ORD377837	ID4769265355	2019-10-09	Bakers	[('Alcon 10', 2), ('Thunder line', 1), ('Candle Inferno', 2), ('iAssi...	25390	107.58	-37.81081	145.0141	10	22958.58	Spring	True
10	ORD462194	ID5301568579	2019-03-21	Thompson	[('Universe Note', 1), ('Lucent 330S', 1), ('Toshika 750', 2)]	13320	62.26	-37.80868	144.9423	15	11384.26	winter	True
11	ORD034800	ID4283908179	2019-08-03	Bakers	[('Alcon 10', 2), ('pearTV', 2), ('iStream', 1), ('Olivia x460', 1)]	31895	78.25	-37.81133	145.0087	0	31973.25	Winter	True
12	ORD361636	ID0589500304	2019-12-05	Nickolson	[('Lucent 330S', 1), ('pearTV', 2)]	13850	77.29	-37.82023	144.9574	25	10464.79	Summer	False
13	ORD124395	ID0702352304	2019-02-11	Thompson	[('Alcon 10', 1), ('Universe Note', 1), ('pearTV', 1), ('iStream', 2)]	19010	94.75	-37.80543	144.9413	0	926057.25	Summer	True
14	ORD255642	ID3085953531	2019-12-24	Nickolson	[('iAssist Line', 2), ('Alcon 10', 1), ('pearTV', 1)]	19710	75.64	-37.81617	144.9753	0	19785.64	Summer	True
15	ORD496722	ID0589449820	2019-04-09	Nickolson	[('pearTV', 2), ('iStream', 1), ('Lucent 330S', 1), ('Alcon 10', 2)]	31900	79.78	-37.80946	144.9724	0	31979.78	Autumn	True
16	ORD449130	ID0356449717	2019-05-17	Bakers	[('Toshika 750', 2), ('Alcon 10', 1), ('Thunder line', 1), ('Candle ...	20200	46.35	-37.80813	144.9868	25	15196.35	Autumn	False
17	ORD036056	ID0767733196	2019-08-10	Nickolson	[('Alcon 10', 1), ('Olivia x460', 2), ('Lucent 330S', 1), ('Thunder ...	14810	80.69	-37.80423	144.9717	25	11188.19	Winter	True
18	ORD428910	ID2180614753	2019-07-15	Nickolson	[('Olivia x460', 1), ('Candle Inferno', 1)]	1655	63.27	-37.81411	144.9714	25	1304.52	Winter	False
19	ORD007249	ID0767586831	2019-02-24	Nickolson	[('iAssist Line', 2), ('Candle Inferno', 2), ('Olivia x460', 1)]	6535	60.64	-37.80918	144.9729	5	6268.89	Summer	False
20	ORD232940	ID2020835025	2019-01-04	Nickolson	[('iAssist Line', 1), ('Toshika 750', 1)]	6545	77.11	-37.81492	144.9680	5	6294.86	Summer	True

3.2 Phát hiện lỗi và sửa lỗi trong dirty_data.csv

a. Các lỗi đã phát hiện được trong bảng dữ liệu dirty_data là:

- Sai định dạng ký tự cột nearest_warehouse, cột shopping_cart, cột is_happy_customer
- Sai định dạng ngày và sai các mùa theo tháng
- Các biến phân loại chưa được định dạng
- Sai giá trị cột order_total
- Tìm ra các biến ngoại lai

BACHKHOACNCP.COM

b. Sửa lỗi :

b1. Sửa lỗi định dạng ký tự các cột bị sai :

```
##sua font nearest_warehouse
dirt <- dirt %>% mutate(nearest_warehouse=recode(nearest_warehouse,
                                                 "bakers" = "Bakers",
                                                 "nickolson" = "Nickolson",
                                                 "thompson" = "Thompson"))
```

```
##sua font is_happy_customer
dirt<-dirt %>% mutate(is_happy_customer = recode(is_happy_customer,
                                                 "true"="True",
                                                 "false"="False"))
```

```
##sua font shopping_cart
dirt<-dirt %>% mutate(shopping_cart=recode(shopping_cart,
"[('IASSIST LINE', 2), ('lucent 330s', 2)]"="[('iAssit Line', 2), ('Lucent 330S', 2)]","[('PEARTV', 2), ('CANDLE INFERNO', 1), ('THUNDER LINE', 2), ('ALCON 10', 1)]"="[('pea
"[('ISTREAM', 1), ('ALCON 10', 1), ('PEARTV', 1), ('TOSHIKA 750', 2)]"="[('iStream', 1), ('Alcon 10', 1), ('pearTV', 1), ('Toshika 750', 2)]",
"[('iassist line', 1), ('alcon 10', 2), ('candle inferno', 2), ('istream', 2)]"="[('iAssist Line', 1), ('Alcon 10', 2), ('Candle inferno', 2), ('iStream', 2)]",
"[('iassist line', 2), ('toshika 750', 2), ('olivia x460', 1), ('universe note', 1)]"="[('iAssist Line', 2), ('Toshika 750', 2), ('Olivia x460', 1), ('Universe Note', 1)]",
"[('IASSIST LINE', 1), ('ALCON 10', 2), ('OLIVIA X460', 1), ('ISTREAM', 1)]"="[('iAssist Line', 1), ('Alcon 10', 2), ('Olivia x460', 1), ('iStream', 1)]",
"[('ALCON 10', 1), ('thunder line', 1)]"="[('Alcon 10', 1), ('Thunder line', 1)]",
"[('PEARTV', 2), ('LUCENT 330S', 1), ('OLIVIA X460', 2)]"="[('pearTV', 2), ('Lucent 330S', 1), ('Olivia x460', 2)]",
"[('toshika 750', 2), ('istream', 1), ('peartv', 2), ('universe note', 1)]"="[('Toshika 750', 2), ('iStream', 1), ('pearTV', 2), ('Universe Note', 1)]",
"[('ALCON 10', 2), ('istream', 2)]"="[('Alcon 10', 2), ('iStream', 2)]",
"[('ISTREAM', 1), ('peartv', 1)]"="[('iStream', 1), ('pearTV', 1)]",
"[('universe note', 2), ('iassist line', 2), ('lucent 330s', 2)]"="[('Universe Note', 2), ('iAssist Line', 2), ('Lucent 330S', 2)]",
"[('THUNDER LINE', 1), ('OLIVIA X460', 2), ('LUCENT 330S', 1), ('IASSIST LINE', 1)]"="[('Thunder line', 1), ('Olivia x460', 2), ('Lucent 330S', 1), ('iAssist Line', 1)]",
"[('LUCENT 330S', 1), ('THUNDER LINE', 2), ('ISTREAM', 1)]"="[('Lucent 330S', 1), ('Thunder line', 2), ('iStream', 1)]",
"[('ISTREAM', 1), ('ALCON 10', 1), ('PEARTV', 1), ('TOSHIKA 750', 2)]"="[('iStream', 1), ('Alcon 10', 1), ('pearTV', 1), ('Toshika 750', 2)]",
"[('ALCON 10', 1), ('iassist line', 1)]"="[('Alcon 10', 1), ('iAssist Line', 1)]"))
```

b2. Sửa định dạng ngày, và sửa các mùa theo tháng dạng if else :

```
##sua dinh dang ngay
dirt<-dirt %>% mutate(date = recode(date,
                                    "03-13-2019" = "2019-03-13",
                                    "04-01-2019" = "2019-04-01",
                                    "12-09-2019" = "2019-12-09",
                                    "06/29/2019" = "2019-06-29",
                                    "09/04/2019" = "2019-09-04",
                                    "02 03 2019" = "2019-02-03",
                                    "04/20/2019" = "2019-04-20",
                                    "03 10 2019" = "2019-03-10",
                                    "01 27 2019" = "2019-01-27",
                                    "07-13-2019" = "2019-07-13",
                                    "03 29 2019" = "2019-03-29",
                                    "05/06/2019" = "2019-05-06",
                                    "05/12/2019" = "2019-05-12",
                                    "02-24-2019" = "2019-02-24",
                                    "10 12 2019" = "2019-10-12",
                                    "06-18-2019" = "2019-06-18",
                                    "03/16/2019" = "2019-03-16",
                                    "08-18-2019" = "2019-08-19",
                                    "03-28-2019" = "2019-03-28",
                                    "03/27/2019" = "2019-03-27"))
```

```
#Sua cac mua theo thang
dirt <- dirt %>%
  mutate(a = month(as.POSIXlt(date, format="%Y-%m-%d")))
dirt <- dirt %>%
  mutate(
    c = c <- ifelse(a>=1 & a<=3,'Spring',0))
dirt <- dirt %>%
  mutate(
    c = c <- ifelse(a>=4 & a<=6,'Summer',c))
dirt <- dirt %>%
  mutate(
    c = c <- ifelse(a>=7 & a<=9,'Autumn',c))
dirt <- dirt %>%
  mutate(
    c = c <- ifelse(a>=10 & a<=12,'Winter',c))
dirt <- dirt %>%
  mutate(season = c)
```


BACHKHOACNCP.COM

- Dùng lệnh **summary()** để tóm tắt thống kê cho bảng dữ liệu **dirty_data** :

```
##coi bang thay duoc cac bien phan loai chua duoc dinh dang
summary(dirt)
```

```
> summary(dirt)
   order_id         customer_id           date           nearest_warehouse  shopping_cart       order_price     delivery_charges  customer_lat     customer_long
 Length:500         Length:500         Length:500         Length:500         Length:500         Min.   :   585   Min.   : 46.35   Min.   :-37.83   Min.   :144.9
 Class :character   Class :character   Class :character   Class :character   Class :character   1st Qu.:  7050   1st Qu.: 65.98   1st Qu.:-37.82   1st Qu.:145.0
 Mode  :character   Mode  :character   Mode  :character   Mode  :character   Mode  :character   Median : 12808   Median : 76.31   Median :-37.81   Median :145.0
                                                                                              Mean   : 25522   Mean   : 76.66   Mean   :-35.84   Mean   :145.0
                                                                                              3rd Qu.: 20360   3rd Qu.: 82.56   3rd Qu.:-37.81   3rd Qu.:145.0
                                                                                              Max.   :947691   Max.   :114.04   Max.   : 37.83   Max.   :145.0
 coupon_discount  order_total         season          is_expedited_delivery distance_to_nearest_warehouse latest_customer_review is_happy_customer        a
 Min.   : 0.00   Min.   :    639   Length:500         Length:500            Min.   : 0.1078               Length:500             Length:500         Min.   : 1.000
 1st Qu.: 5.00   1st Qu.:   6455   Class :character   Class :character      1st Qu.: 0.7514               Class :character       Class :character   1st Qu.: 3.000
 Median :10.00   Median :  11294   Mode  :character   Mode  :character      Median : 1.0301               Mode  :character       Mode  :character   Median : 6.000
 Mean   :10.89   Mean   :  39210                                           Mean   : 2.2042                                                         Mean   : 6.402
 3rd Qu.:15.00   3rd Qu.:  18119                                           3rd Qu.: 1.4086                                                         3rd Qu.: 9.000
 Max.   :25.00   Max.   :5688270                                           Max.   :94.9734                                                         Max.   :12.000
      c
 Length:500
 Class :character
 Mode  :character
```

=> Ta thấy rằng các biến phân loại chưa được định dạng.

b3. Sửa các biến phân loại chưa được định dạng:

```
##dinh dang cho cac bien phan loai
dirt$order_id_new <- factor(dirt$order_id)
dirt$customer_id_new <- factor(dirt$customer_id)
dirt$date_new <- factor(dirt$date)
dirt$nearest_warehouse <- factor(dirt$nearest_warehouse)
dirt$shopping_cart <- factor(dirt$shopping_cart)
dirt$season <- factor(dirt$season)
dirt$is_expedited_delivery <- factor(dirt$is_expedited_delivery)
dirt$is_happy_customer <- factor(dirt$is_happy_customer)
summary(dirt)
```

```
> summary(dirt)
   order_id         customer_id           date           nearest_warehouse                                                   shopping_cart  order_price
 Length:500         Length:500         Length:500         Bakers   :119   [('iAssist Line', 1), ('Thunder line', 1)]                :  3   Min.   :   585
 Class :character   Class :character   Class :character   Nickolson:184   [('iStream', 1), ('Candle Inferno', 2)]                   :  3   1st Qu.:  7050
 Mode  :character   Mode  :character   Mode  :character   Thompson :197   [('iStream', 1), ('Thunder line', 2)]                     :  3   Median : 12808
                                                                           [('Alcon 10', 2), ('Lucent 330S', 2)]                     :  2   Mean   : 25522
                                                                           [('Candle Inferno', 1), ('Thunder line', 1), ('iStream', 2)]:  2   3rd Qu.: 20360
                                                                           [('iAssist Line', 1), ('Toshika 750', 1)]                 :  2   Max.   :947691
                                                                           (Other)                                                   :485
 delivery_charges  customer_lat    customer_long   coupon_discount  order_total         season    is_expedited_delivery distance_to_nearest_warehouse latest_customer_review
 Min.   : 46.35   Min.   :-37.83   Min.   :144.9   Min.   : 0.00   Min.   :    639   Autumn:122   False:251             Min.   : 0.1078               Length:500
 1st Qu.: 65.98   1st Qu.:-37.82   1st Qu.:145.0   1st Qu.: 5.00   1st Qu.:   6455   Spring:129   True :249             1st Qu.: 0.7514               Class :character
 Median : 76.31   Median :-37.81   Median :145.0   Median :10.00   Median :  11294   Summer:128                         Median : 1.0301               Mode  :character
 Mean   : 76.66   Mean   :-35.84   Mean   :145.0   Mean   :10.89   Mean   :  39210   Winter:121                         Mean   : 2.2042
 3rd Qu.: 82.56   3rd Qu.:-37.81   3rd Qu.:145.0   3rd Qu.:15.00   3rd Qu.:  18119                                      3rd Qu.: 1.4086
 Max.   :114.04   Max.   : 37.83   Max.   :145.0   Max.   :25.00   Max.   :5688270                                      Max.   :94.9734

 is_happy_customer       a               c               order_id_new     customer_id_new       date_new
 False:141         Min.   : 1.000   Length:500         ORD001041:  1   ID0245493801:  2    2019-09-14:  5
 True :359         1st Qu.: 3.000   Class :character   ORD004361:  1   ID0591274456:  2    2019-10-16:  5
                   Median : 6.000   Mode  :character   ORD004602:  1   ID0710001161:  2    2019-11-03:  5
                   Mean   : 6.402                      ORD004848:  1   ID1463620434:  2    2019-01-07:  4
                   3rd Qu.: 9.000                      ORD005232:  1   ID3924911400:  2    2019-02-03:  4
                   Max.   :12.000                      ORD005286:  1   ID6167489462:  2    2019-02-14:  4
                                                       (Other)  :494   (Other)     :488    (Other)   :473
```

⇨ Các biến phân loại đã được định dạng đúng.

b4. Tính order_total theo công thức order_price*(100-coupon_discount)/100+delivery_charges và so sánh order_total được tính theo công thức với order_total được cho nếu giá trị khác nhau thì sẽ in ra.

BACHKHOACNCP.COM

```
##tinh lai tong gia tri dat hang va so sanh voi gia tri dat hang de cho
dirt <- dirt %>%
  mutate(order_total_new = order_price*(100-coupon_discount)/100+delivery_charges)
for (i in 1:500) {if (dirt$order_total_new[i] != dirt$order_total[i]) {cat(paste
            ("Khong bang nhau thu tu", i, " : so duoc tinh theo cong thuc ", dirt$order_total_new[i], " khong bang gia tri de cho ", dirt$order_total[i], "\n"))}}
### ta thay duoc co cac gia tri sai nen ta se su dung gia tri order total new
```

Kết quả có được 18 giá trị khác như vậy ta sẽ dùng order_total theo công thức để sử dụng:

```
> ##tinh lai tong gia tri dat hang va so sanh voi gia tri dat hang de cho
> dirt <- dirt %>%
+   mutate(order_total_new = order_price*(100-coupon_discount)/100+delivery_charges)
> for (i in 1:500) {if (dirt$order_total_new[i] != dirt$order_total[i]) {cat(paste
+             ("Khong bang nhau thu tu", i, " : so duoc tinh theo cong thuc ", dirt$order_total_new[i], " khong bang gia tri de cho ", dirt$order_total[i], "\n"))}}
Khong bang nhau thu tu 8  : so duoc tinh theo cong thuc  7614.28  khong bang gia tri de cho  10789.79
Khong bang nhau thu tu 13  : so duoc tinh theo cong thuc  19104.75  khong bang gia tri de cho  926057.25
Khong bang nhau thu tu 32  : so duoc tinh theo cong thuc  13511.81  khong bang gia tri de cho  402307.25
Khong bang nhau thu tu 42  : so duoc tinh theo cong thuc  12032.83  khong bang gia tri de cho  620502.3
Khong bang nhau thu tu 58  : so duoc tinh theo cong thuc  16606.2  khong bang gia tri de cho  22306.28
Khong bang nhau thu tu 68  : so duoc tinh theo cong thuc  52455.54  khong bang gia tri de cho  18316.14
Khong bang nhau thu tu 71  : so duoc tinh theo cong thuc  589729.3  khong bang gia tri de cho  16803.7
Khong bang nhau thu tu 82  : so duoc tinh theo cong thuc  14445.09  khong bang gia tri de cho  393761.23
Khong bang nhau thu tu 121  : so duoc tinh theo cong thuc  3269.62  khong bang gia tri de cho  2421.82
Khong bang nhau thu tu 157  : so duoc tinh theo cong thuc  69777.7  khong bang gia tri de cho  31212.7
Khong bang nhau thu tu 205  : so duoc tinh theo cong thuc  8436.03  khong bang gia tri de cho  967408.88
Khong bang nhau thu tu 238  : so duoc tinh theo cong thuc  736121.5  khong bang gia tri de cho  19468.65
Khong bang nhau thu tu 239  : so duoc tinh theo cong thuc  17609.05  khong bang gia tri de cho  648477.6
Khong bang nhau thu tu 250  : so duoc tinh theo cong thuc  2703.69  khong bang gia tri de cho  4483.04
Khong bang nhau thu tu 262  : so duoc tinh theo cong thuc  16706.42  khong bang gia tri de cho  649193.76
Khong bang nhau thu tu 268  : so duoc tinh theo cong thuc  15405.2  khong bang gia tri de cho  969651.79
Khong bang nhau thu tu 277  : so duoc tinh theo cong thuc  18077.99  khong bang gia tri de cho  33706.75
Khong bang nhau thu tu 278  : so duoc tinh theo cong thuc  7448.34  khong bang gia tri de cho  507327.39
Khong bang nhau thu tu 290  : so duoc tinh theo cong thuc  567457.91  khong bang gia tri de cho  18338.91
Khong bang nhau thu tu 293  : so duoc tinh theo cong thuc  11447.08  khong bang gia tri de cho  11203.14
Khong bang nhau thu tu 300  : so duoc tinh theo cong thuc  72366.26  khong bang gia tri de cho  8458.76
Khong bang nhau thu tu 306  : so duoc tinh theo cong thuc  10884.03  khong bang gia tri de cho  5688269.6
Khong bang nhau thu tu 308  : so duoc tinh theo cong thuc  47732.18  khong bang gia tri de cho  4622.18
Khong bang nhau thu tu 309  : so duoc tinh theo cong thuc  530.54  khong bang gia tri de cho  639.29
Khong bang nhau thu tu 311  : so duoc tinh theo cong thuc  7538.91  khong bang gia tri de cho  88124.81
Khong bang nhau thu tu 314  : so duoc tinh theo cong thuc  346389.31  khong bang gia tri de cho  9709.81
Khong bang nhau thu tu 336  : so duoc tinh theo cong thuc  853012.72  khong bang gia tri de cho  9266.32
Khong bang nhau thu tu 352  : so duoc tinh theo cong thuc  18154.49  khong bang gia tri de cho  87224.69
Khong bang nhau thu tu 363  : so duoc tinh theo cong thuc  2294.7  khong bang gia tri de cho  3434.7
Khong bang nhau thu tu 364  : so duoc tinh theo cong thuc  83920.38  khong bang gia tri de cho  5449.23
Khong bang nhau thu tu 379  : so duoc tinh theo cong thuc  2403.89  khong bang gia tri de cho  82214.42
Khong bang nhau thu tu 386  : so duoc tinh theo cong thuc  2409.27  khong bang gia tri de cho  909463.94
Khong bang nhau thu tu 398  : so duoc tinh theo cong thuc  621327.23  khong bang gia tri de cho  21441.18
Khong bang nhau thu tu 405  : so duoc tinh theo cong thuc  83319.62  khong bang gia tri de cho  10808.97
Khong bang nhau thu tu 427  : so duoc tinh theo cong thuc  13938.52  khong bang gia tri de cho  665085.66
```

```
Khong bang nhau thu tu 446  : so duoc tinh theo cong thuc  5426.35  khong bang gia tri de cho  13143.99
Khong bang nhau thu tu 456  : so duoc tinh theo cong thuc  386825.88  khong bang gia tri de cho  13628.28
Khong bang nhau thu tu 473  : so duoc tinh theo cong thuc  504686.82  khong bang gia tri de cho  17972.82
Khong bang nhau thu tu 475  : so duoc tinh theo cong thuc  1482.41  khong bang gia tri de cho  2443.76
Khong bang nhau thu tu 496  : so duoc tinh theo cong thuc  348158.1  khong bang gia tri de cho  20174.7
```

b5. Các biến ngoại lai khi so sánh giữa latest_customer_review và is_happy_customer khi latest_customer_review tích cực nhưng is_happy_customer lại không và ngược lại.

```
##cac bien ngoai lai dua theo latest_customer_review va is_happy_customer
"ORD157353"
"ORD439821"
"ORD370065"
"ORD226452"
"ORD452012"
"ORD452642"
"ORD057521"
"ORD073993"
"ORD413882"
"ORD355763"
"ORD371242"
"ORD051673"
"ORD319178"
"ORD051670"
"ORD121712"
"ORD267220"
"ORD374251"
"ORD083728"
"ORD243905"
```

b6. Dùng boxplot để coi các giá trị ngoại lai của order_total theo công thức và xem có bao nhiêu giá trị ngoại lai.

TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

```
##tim cac gia tri ngoai lai bang cong thuc boxplot.stats
boxplot(dirt$order_total_new)
out <- boxplot.stats(dirt$order_total_new)$out
length(out)
out
```

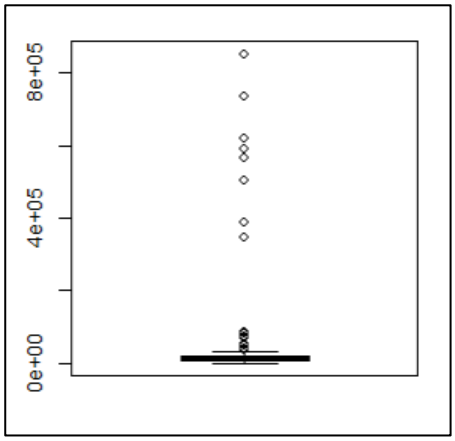

- Số lượng giá trị ngoại lai là :

```
> length(out)
[1] 18
```

- Giá trị các điểm ngoại lai :

```
> out
 [1]  41406.93  37215.32  52455.54 589729.30  69777.70 736121.50 567457.91  72366.26  47732.18 346389.31 853012.72  83920.38
[13]  37649.94 621327.23  83319.62 386825.88 504686.82 348158.10
```

- Tính tỉ lệ ngoại lai so với tổng lượng giá trị trong biến order_total:

```
length(out)/length(dirt$order_total_new)
```

Kết quả :

```
> length(out)/length(dirt$order_total_new)
[1] 0.036
```

=> Ta thấy rằng giá trị ngoại lai chiếm tỉ lệ rất nhỏ khoảng 0,036 so với tổng lượng giá trị trong biến order_total nên nó không ảnh hưởng đến việc phân tích dữ liệu.

4. Thống kê mô tả

Đầu tiên ta sẽ đưa các biến phân loại về dạng 0 và 1 tương ứng True trả về 1, False trả về 0.

```
##dua cac bien is_happy_customer va is_expedited_delivery neu la true tra ve 1 con fale ve 0
dirt$is_happy_customer_bang_so <- ifelse(dirt$is_happy_customer == "True", 1, 0)
dirt$is_expedited_delivery_bang_so <- ifelse(dirt$is_expedited_delivery == "True", 1, 0)
```

4.1 Lọc các biến mà ta quan tâm

a) Hãy trích ra:

- Tạo một dữ liệu mới chỉ bao gồm các biến chính mà ta quan tâm, lưu với tên là dirt_new.

BACHKHOACNCP.COM

```
dirt_new <- dirt[,c("order_price","order_total_new","delivery_charges","coupon_discount","distance_to_nearest_warehouse",
                    "is_happy_customer_bang_so","is_expedited_delivery_bang_so")]
View(dirt_new)
```

- Kết quả:

CodeFinal.R* × | dirt_new × | dirt ×

Filter

	order_price	order_total_new	delivery_charges	coupon_discount	distance_to_nearest_warehouse	is_happy_customer_bang_so	is_expedited_delivery_bang_so
1	12200	11059.89	79.89	10	1.2800	1	1
2	9080	9142.71	62.71	0	1.1621	0	0
3	10670	9668.87	65.87	10	1.0949	1	0
4	24800	21137.61	57.61	15	0.8571	0	0
5	9145	6934.29	75.54	25	0.5867	1	0
6	7810	7100.22	71.22	10	2.0752	0	0
7	13700	13089.84	74.84	5	0.6767	1	0
8	7960	7614.28	52.28	5	1.3043	0	0
9	25390	22958.58	107.58	10	1.6595	1	1
10	13320	11384.26	62.26	15	0.6093	0	1
11	31895	31973.25	78.25	0	1.1919	1	1
12	13850	10464.79	77.29	25	1.0829	1	0
13	19010	19104.75	94.75	0	0.9509	1	1
14	19710	19785.64	75.64	0	0.5716	0	1
15	31900	31979.78	79.78	0	66.6483	1	1
16	20200	15196.35	46.35	25	0.7706	0	0
17	14810	11188.19	80.69	25	1.6104	1	1
18	1655	1304.52	63.27	25	0.5250	1	0
19	6535	6268.89	60.64	5	1.0880	0	0
20	6545	6294.86	77.11	5	61.2935	0	1

4.2 Làm rõ dữ liệu

- Chuyển đổi các biến order_price, order_total_new, delivery_charges, distance_to_nearest_warehouse thành log(order_price), log(order_total_new), log(delivery_charges), log(distance_to_nearest_warehouse).

```
dirt_new1 <- dirt_new
dirt_new1[,c("order_price","order_total_new","delivery_charges","distance_to_nearest_warehouse")] <-
  log(dirt_new1[,c("order_price","order_total_new","delivery_charges","distance_to_nearest_warehouse")])
View(dirt_new1)
```

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

- Kết quả :

CodeFinal.R* | dirt_new1 | dirt_new | dirt

Filter

	order_price	order_total_new	delivery_charges	coupon_discount	distance_to_nearest_warehouse	is_happy_customer_bang_so	is_expedited_delivery_bang_so
1	9.409191	9.311080	4.380651	10	0.2468600779	1	1
2	9.113829	9.120712	4.138521	0	0.1502287132	0	0
3	9.275191	9.176667	4.187683	10	0.0906630349	1	0
4	10.118599	9.958809	4.053696	15	-0.1542006811	0	0
5	9.120963	8.844234	4.324662	25	-0.5332416631	1	0
6	8.963160	8.867881	4.265774	10	0.7300575346	0	0
7	9.525151	9.479592	4.315353	5	-0.3905272357	1	0
8	8.982184	8.937781	3.956614	5	0.2656664984	0	0
9	10.142111	10.041447	4.678235	10	0.5065163522	1	1
10	9.497022	9.339987	4.131319	15	-0.4954445217	0	1
11	10.370205	10.372655	4.359909	0	0.1755486725	1	1
12	9.536041	9.255772	4.347565	25	0.0796426277	1	0
13	9.852720	9.857692	4.551242	0	-0.0503463744	1	1
14	9.888881	9.892712	4.325985	0	-0.5593158329	0	1
15	10.370361	10.372859	4.379273	0	4.1994295399	1	1
16	9.913438	9.628811	3.836221	25	-0.2605858468	0	0
17	9.603058	9.322614	4.390615	25	0.4764825953	1	1
18	7.411556	7.173590	4.147411	25	-0.6443570164	1	0
19	8.784928	8.743355	4.104955	5	0.0843411484	0	0
20	8.786457	8.747489	4.345233	5	4.1156738014	0	1

- Giải thích lý do chuyển sang dạng log(x):

Cải thiện sự phù hợp của mô hình: giả định khi ta xây dựng mô hình hồi quy thì các sai số hồi quy (phần dư) phải có phân phối chuẩn, do đó trong trường hợp sai số hồi quy (phần dư) không có phân phối chuẩn thì việc lấy log của của một biến giúp thay đổi tỉ lệ và làm cho biến đó có phân phối chuẩn. Ngoài ra, trong trường hợp phần dư (phương sai thay đổi) do các biến độc lập gây ra, ta cũng có thể chuyển đổi các biến đó sang dạng log.

Diễn giải: đây là lý do giúp ta có thể diễn giải mối quan hệ giữa 2 biến thuận tiện hơn. Nếu ta lấy log của biến phụ thuộc Y và biến độc lập X, khi đó hệ số hồi quy β sẽ là hệ số co giãn và diễn giải sẽ như sau: X tăng 1% sẽ dẫn đến tăng việc ta sẽ kỳ vọng Y tăng lên β% (về mặt trung bình của Y), ...

Ước lượng mô hình phi tuyến: việc lấy log cho phép ta ước lượng các mô hình này bằng hồi quy tuyến tính.

- Tính các giá trị thống kê mô tả (trung bình, độ lệch chuẩn, min, max, trung vị) cho các biến order_price, order_total_new, delivery_charges, distance_to_nearest_warehouse. Xuất kết quả dưới dạng bảng.

```
#Tính các giá trị trong thống kê tả
mean<-apply(dirt_new,2,mean) #Tính độ lệch chuẩn
sd<-apply(dirt_new,2,sd) #Tính độ lệch chuẩn
min<-apply(dirt_new,2,min) #Tính giá trị nhỏ nhất
max<-apply(dirt_new,2,max) #Tính giá trị lớn nhất
median<-apply(dirt_new,2,median) #Tính trung vị
Q1<-apply(dirt_new,2,quantile,probs=0.25) #Tính phân vị Q1
Q3<-apply(dirt_new,2,quantile,probs=0.75) #Tính phân vị Q3
bang_thong_ke_1<-data.frame(mean,sd,min,max,median,Q1,Q3) #Lập bảng thống kê
View(bang_thong_ke_1)
```

-

BACHKHOACNCP.COM

- **Kết quả :**

	mean	sd	min	max	median	Q1	Q3
order_price	25522.216000	8.633373e+04	585.0000	947691.0000	12807.5000	7050.000000	20360.000000
order_total_new	22564.565100	7.549921e+04	530.5400	853012.7200	11293.9600	6388.340000	17926.880000
delivery_charges	76.658200	1.448146e+01	46.3500	114.0400	76.3100	65.982500	82.555000
coupon_discount	10.890000	8.649134e+00	0.0000	25.0000	10.0000	5.000000	15.000000
distance_to_nearest_warehouse	2.204224	8.812416e+00	0.1078	94.9734	1.0301	0.751425	1.408625
is_happy_customer_bang_so	0.718000	4.504240e-01	0.0000	1.0000	1.0000	0.000000	1.000000
is_expedited_delivery_bang_so	0.498000	5.004967e-01	0.0000	1.0000	0.0000	0.000000	1.000000

- Tính các giá trị thống kê mô tả (trung bình, độ lệch chuẩn, min, max, trung vị) cho các biến order_price, order_total_new, delivery_charges, distance_to_nearest_warehouse đã chuyển sang dạng log. Xuất kết quả dưới dạng bảng.

```
#Lấy log
mean<-apply(dirt_new1,2,sd) #Tính độ lệch chuẩn
sd<-apply(dirt_new1,2,sd) #Tính độ lệch chuẩn
min<-apply(dirt_new1,2,min) #Tính giá trị nhỏ nhất
max<-apply(dirt_new1,2,max) #Tính giá trị lớn nhất
median<-apply(dirt_new1,2,median) #Tính trung vị
Q1<-apply(dirt_new1,2,quantile,probs=0.25) #Tính phân vị Q1
Q3<-apply(dirt_new1,2,quantile,probs=0.75) #Tính phân vị Q3
bang_thong_ke_2<-data.frame(mean,sd,min,max,median,Q1,Q3) #Lập bảng thống kê
View(bang_thong_ke_2)
```

- Kết quả :

	mean	sd	min	max	median	Q1	Q3
order_price	0.9294426	0.9294426	6.371612	13.761784	9.45778620	8.8607829	9.9213275
order_total_new	0.9236060	0.9236060	6.273895	13.656530	9.33202327	8.7621938	9.7940562
delivery_charges	0.1872279	0.1872279	3.836221	4.736549	4.33480396	4.1893893	4.4134635
coupon_discount	8.6491338	8.6491338	0.000000	25.000000	10.00000000	5.0000000	15.0000000
distance_to_nearest_warehouse	0.7752893	0.7752893	-2.227478	4.553597	0.02965587	-0.2857839	0.3426141
is_happy_customer_bang_so	0.4504240	0.4504240	0.000000	1.000000	1.00000000	0.0000000	1.0000000
is_expedited_delivery_bang_so	0.5004967	0.5004967	0.000000	1.000000	0.00000000	0.0000000	1.0000000

- Trong các biến chính thì biến is_happy_customer và is_expedited_delivery là các biến rời rạc phân loại. Vì vậy ta sẽ lập bảng tần số cho từng biến:

```
#Lập bảng tần số
table_is_happy_customer <- as.data.frame(table(dirt_new$is_happy_customer_bang_so))
View(table_is_happy_customer)
table_is_expedited_delivery <- as.data.frame(table(dirt_new$is_expedited_delivery))
View(table_is_expedited_delivery)
```


BACHKHOACNCP.COM

- Kết quả ta thu được bảng tần số như sau:

	Var1	Freq
1	0	251
2	1	249

Bảng tần số is_happy_customer

	Var1	Freq
1	0	141
2	1	359

Bảng tần số is_expedited_delivery

- Tiếp theo chúng ta sẽ tính mode và lập bảng giá mode cho 2 biến rời rạc is_happy_customer và is_expedited_delivery :

```
#Tính Mode
is_happy_customer_mode = names(table(dirt_new$is_happy_customer_bang_so))[which.max(table(dirt_new$is_happy_customer_bang_so))]
is_expedited_delivery_mode = names(table(dirt_new$is_expedited_delivery_bang_so))[which.max(table(dirt_new$is_expedited_delivery_bang_so))]
mode_table <- data.frame(is_happy_customer_mode, is_expedited_delivery_mode)
rownames(mode_table) <- c("Mode")
View(mode_table)
```

- Kết quả :

	is_happy_customer_mode	is_expedited_delivery_mode
Mode	1	0

- Sau khi tính toán các giá trị thống kê mô tả trên và lập bảng, ta sẽ thực hiện thống kê mô tả bằng đồ thị để trực quan hóa các đặc tính của 2 biến rời rạc is_happy_customer và is_expedited_delivery:

```
#Vẽ histogram
hist(dirt_new$is_happy_customer_bang_so, main="Đồ thị phân phối của is_happy_customer_bang_so",
     col = "blue", border ="white", xlab = "is_happy_customer_bang_so", breaks = 15,labels=T,ylim=c(0,400))
hist(dirt_new$is_expedited_delivery_bang_so, main="Đồ thị phân phối của is_expedited_delivery_bang_so",
     col = "red", border ="white", xlab = "is_expedited_delivery_bang_so", breaks = 15,labels=T,ylim=c(0,400))
```

- Kết quả :

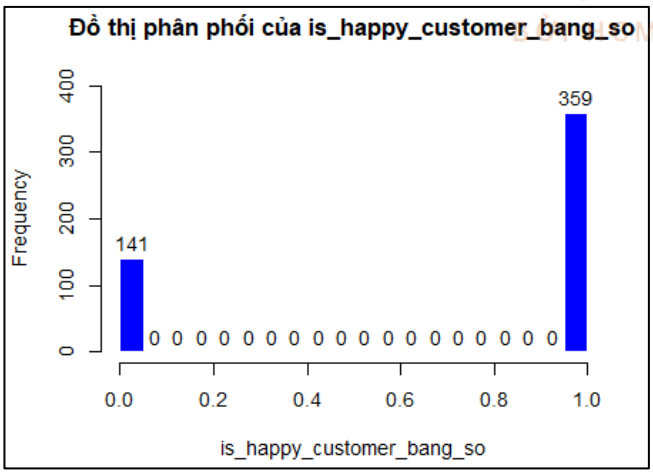

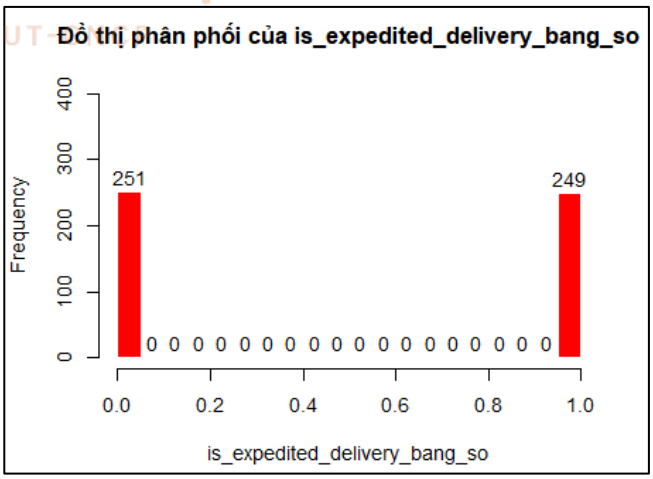

- Đồ thị thể hiện rõ mode của biến is_happy_customer là 1, mode của biến is_expedited_delivery là 0.

BACHKHOACNCP.COM

- Đối với các biên liên tục:

Vẽ biểu đồ histogram thể hiện phân phối của biến order_total_new trước và sau khi chuyển sang dạng log.

a) Trước khi chuyển sang dạng log:

```
hist(dirt_new$order_total_new, main="Đồ thị phân phối của order_total_new",
     col = "blue", border ="white", xlab = "order_total_new", breaks = 15,labels=T,ylim=c(0,500))
```

- Kết quả :

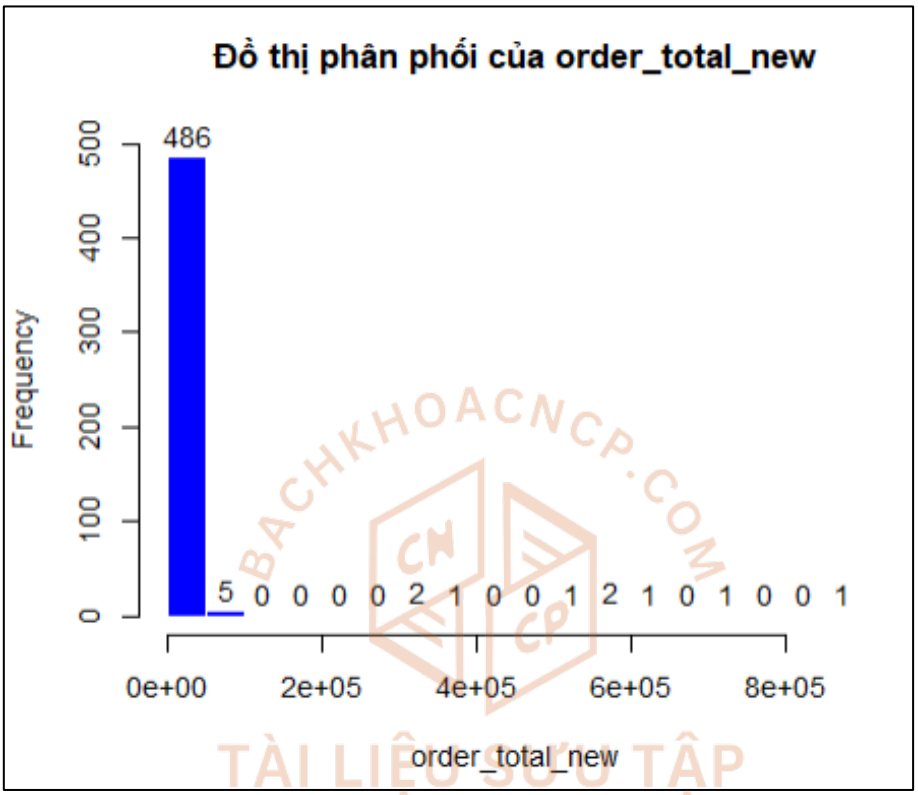

b) Sau khi chuyển sang dạng log :

```
hist(dirt_new1$order_total_new, main="Đồ thị phân phối của order_price_new sau khi lấy log",
     col = "red", border ="white", xlab = "order_total", breaks = 15,labels=T,ylim=c(0,200))
```

- Kết quả :

BACHKHOACNCP.COM

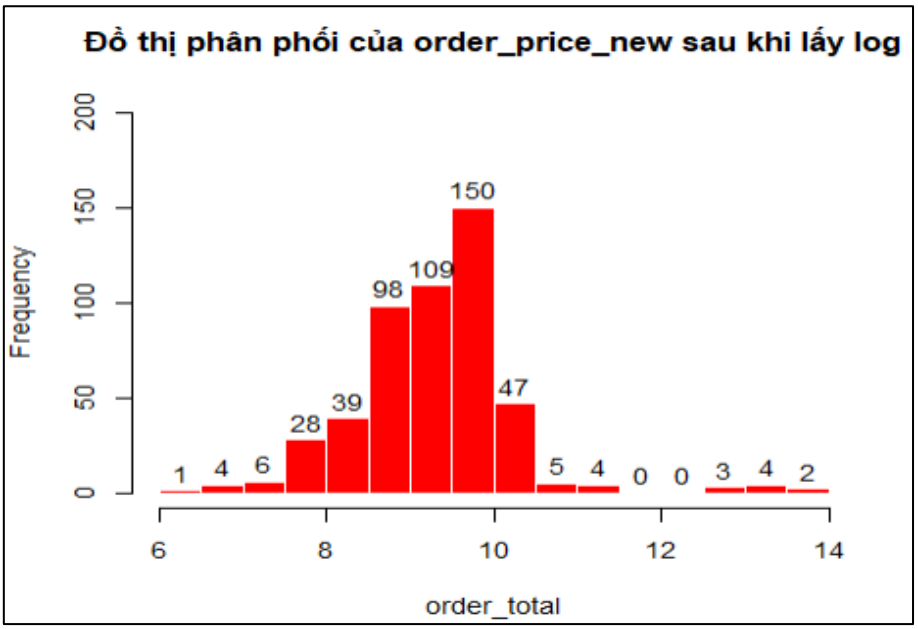

⇨ Nhận xét: Dựa trên biểu đồ histogram của biến order_total_new, ta nhận thấy phân phối của biến order_total_new có xu hướng lệch phải, cho thấy phần lớn các đơn hàng có giá tiền gần như nhau, và chỉ có số ít đơn hàng có giá trị cao hơn. Trong khi với biểu đồ của biến log(order_total_new) có hình dạng phân phối chuẩn.

- Vẽ biểu đồ boxplot thể hiện phân phối của biến order_total_new và log(order_total_new) theo từng phân loại của biến is_happy_customer.

```
boxplot(order_total_new ~ is_happy_customer_bang_so, data = dirt_new,
        main = "Phân phối của order_total_new cho từng giá trị của biến is_happy_customer", col = "blue")
```

- Kết quả :

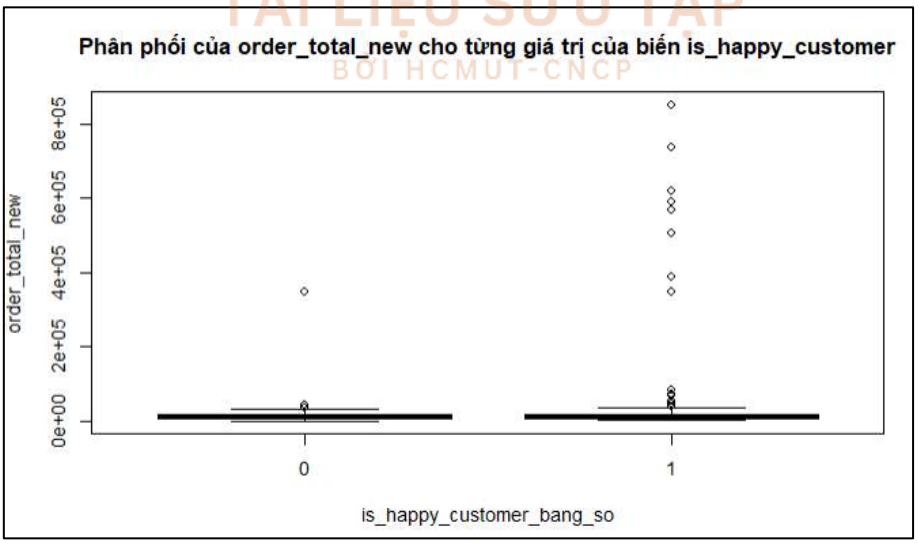


```
boxplot(order_total_new ~ is_happy_customer_bang_so, data = dirt_new1,
        main = "Phân phối của order_total_new cho từng giá trị của biến is_happy_customer sau khi lấy log", col = "red")
```


BACHKHOACNCP.COM

- Kết quả :

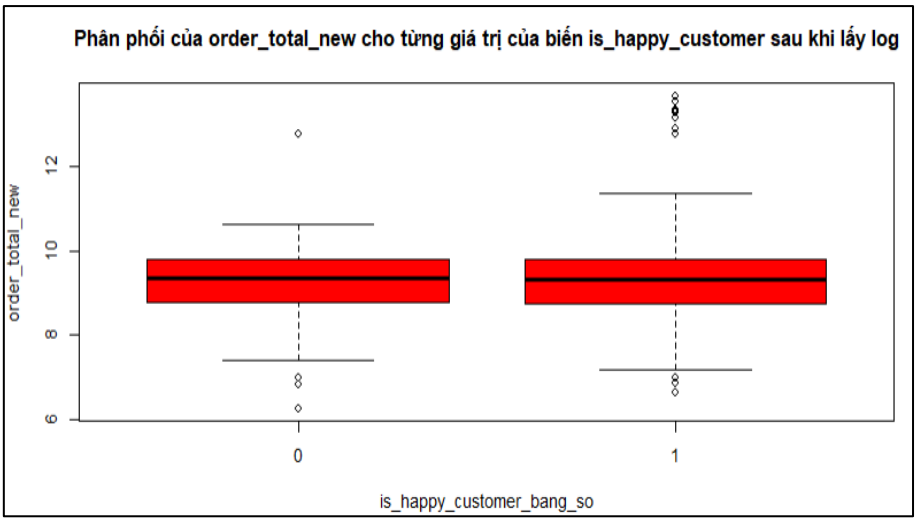

- Vẽ biểu đồ boxplot thể hiện phân phối của biến order_total_new và log(order_total_new) theo từng phân loại của biến is_expedited_delivery.

```
boxplot(order_total_new ~ is_expedited_delivery_bang_so, data = dirt_new,
        main = "Phân phối của order_total_new cho từng giá trị của biến is_expedited_delivery", col = "blue")
```

- Kết quả :

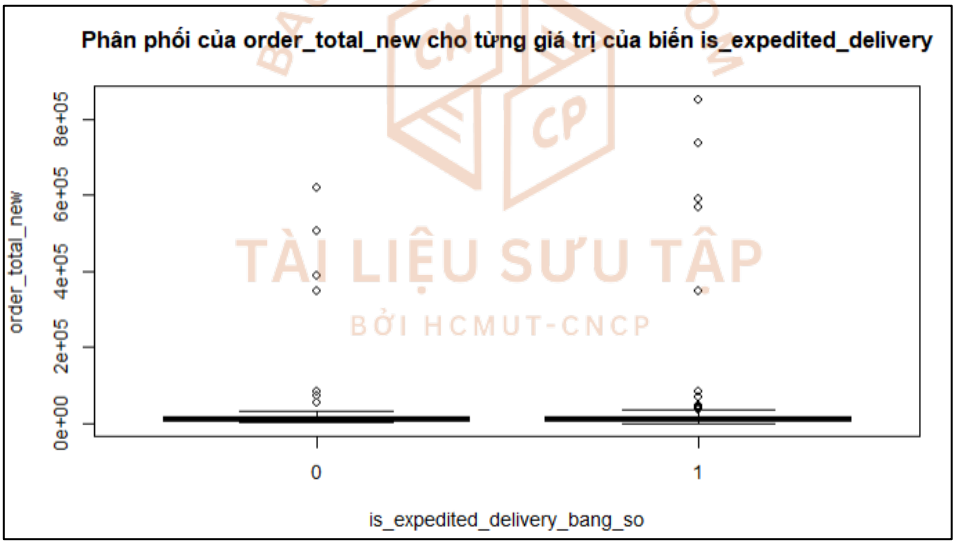


```
boxplot(order_total_new ~ is_expedited_delivery_bang_so, data = dirt_new1,
        main = "Phân phối của order_total_new cho từng giá trị của biến is_expedited_delivery sau khi lấy log", col = "red")
```


BACHKHOACNCP.COM

- Kết quả:

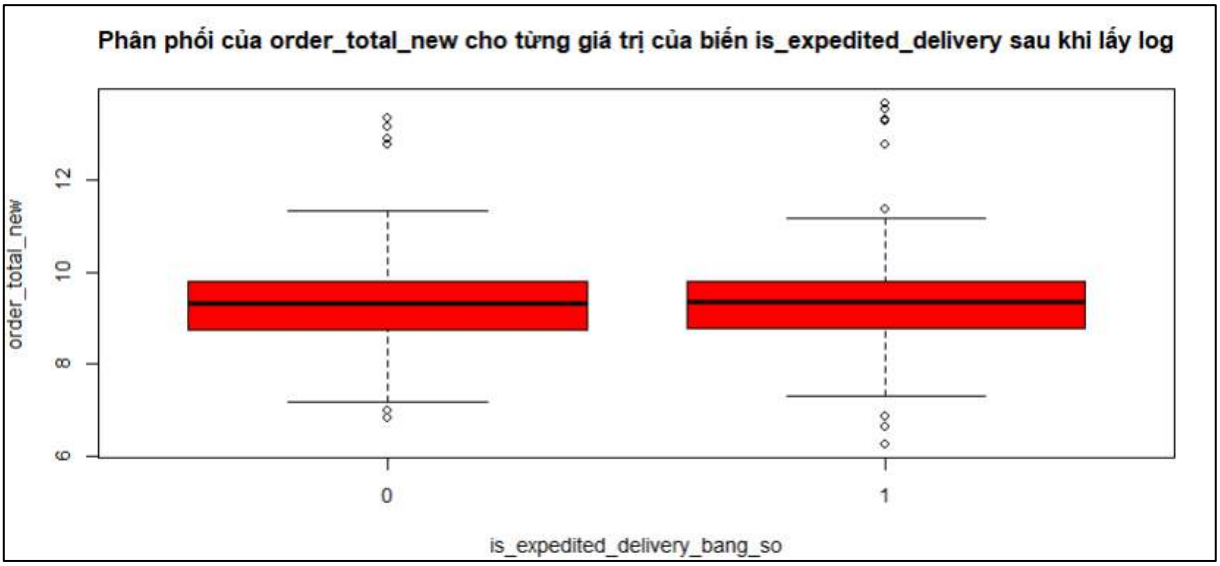

Vẽ biểu đồ boxplot thể hiện phân phối của biến delivery_charges và log(delivery_charges) theo từng phân loại của biến is_happy_customer và biến is_expedited_delivery.

```
boxplot(delivery_charges ~ is_happy_customer_bang_so, data = dirt_new,
        main = "Phân phối của delivery_charges cho từng giá trị của biến is_happy_customer", col = "blue")
boxplot(delivery_charges ~ is_expedited_delivery_bang_so, data = dirt_new,
        main = "Phân phối của delivery_charges cho từng giá trị của biến is_expedited_delivery", col = "blue")
```

- Kết quả :

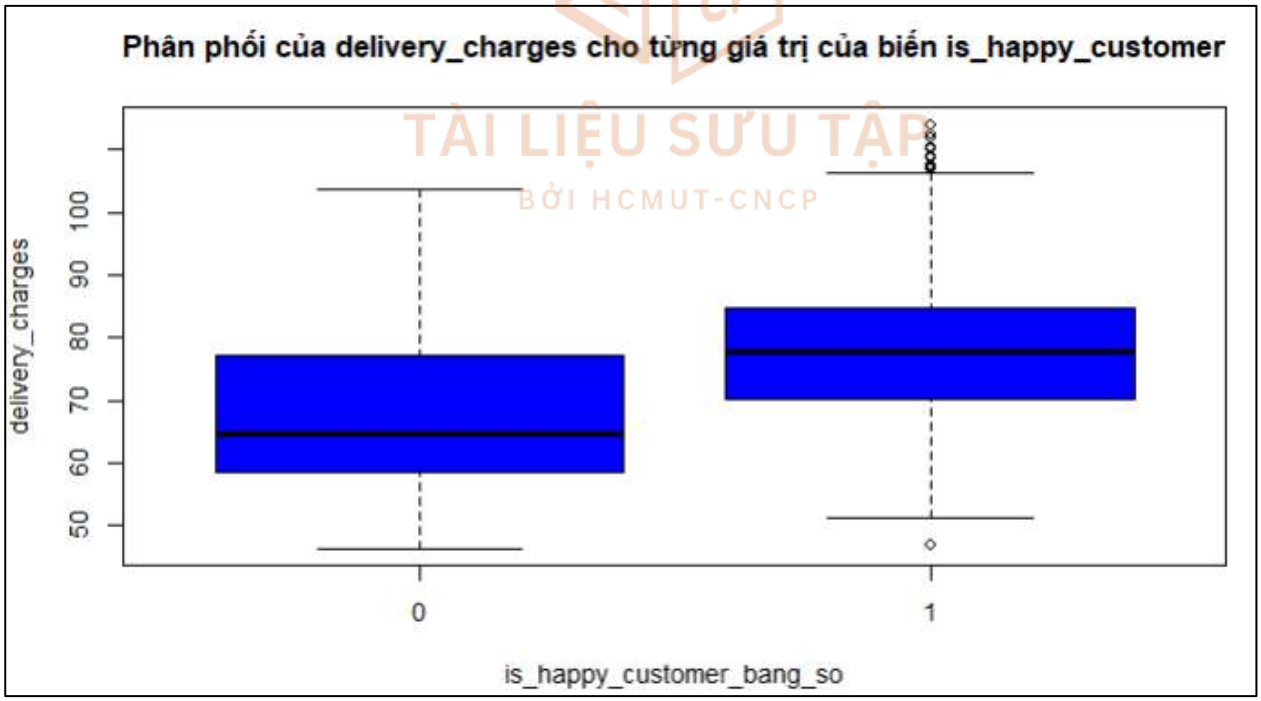


```
boxplot(delivery_charges ~ is_happy_customer_bang_so, data = dirt_new1,
        main = "Phân phối của delivery_charges cho từng giá trị của biến is_happy_customer sau khi lấy log", col = "red")
boxplot(delivery_charges ~ is_expedited_delivery_bang_so, data = dirt_new1,
        main = "Phân phối của delivery_charges cho từng giá trị của biến is_expedited_delivery sau khi lấy log", col = "red")
```


BACHKHOACNCP.COM

- Kết quả :

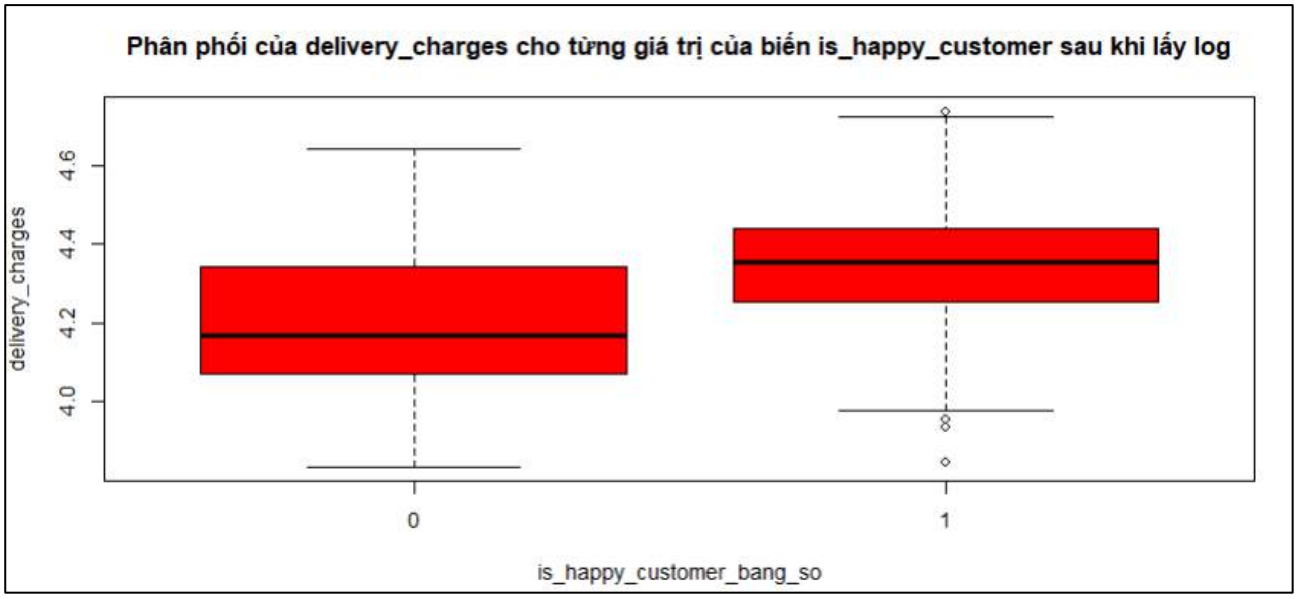

⇨ **Nhận xét:** Tóm lại, dựa trên các đồ thị trên, ta nhận thấy việc chuyển đổi các biến sang dạng log(x) sẽ hiệu quả hơn trong việc phân tích mối quan hệ tuyến tính giữa các biến độc lập với biến phụ thuộc.

Câu hỏi đặt ra lúc này là mối quan hệ giữa các biến với order_total_new là ngẫu nhiên hay thực sự có mối quan hệ tuyến tính giữa các biến với order_total_new. Mô hình hồi quy tuyến tính sẽ giúp ta kiểm tra điều này thông qua các khoảng tin cậy và các phép kiểm định. Hơn nữa, nó còn cho phép ta ước lượng giá trị của biến phụ thuộc (order_total_new) theo các biến độc lập (order_price, delivery_charges, distance_to_nearest_warehouse, is_happy_customer, is_expedited_delivery)

Các phân phối của biến order_total_new lần lượt theo các biến order_price, delivery_charges, distance_to_nearest_warehouse.

```
#Các phân phối của biến order_total_new lần lượt theo các biến delivery_charges, order_price, distance_to_nearest_warehouse
pairs(dirt_new$order_total_new~dirt_new$delivery_charges + dirt_new$order_price + dirt_new$distance_to_nearest_warehouse,
      labels= c("order_total_new","delivery_charges","order_price","distance_to_nearest_warehouse"),col= "blue")
pairs(dirt_new1$order_total_new~dirt_new1$delivery_charges + dirt_new1$order_price + dirt_new1$distance_to_nearest_warehouse,
      labels= c("order_total_new","delivery_charges","order_price","distance_to_nearest_warehouse"),col= "red")
```


BACHKHOACNCP.COM

- Kết quả :

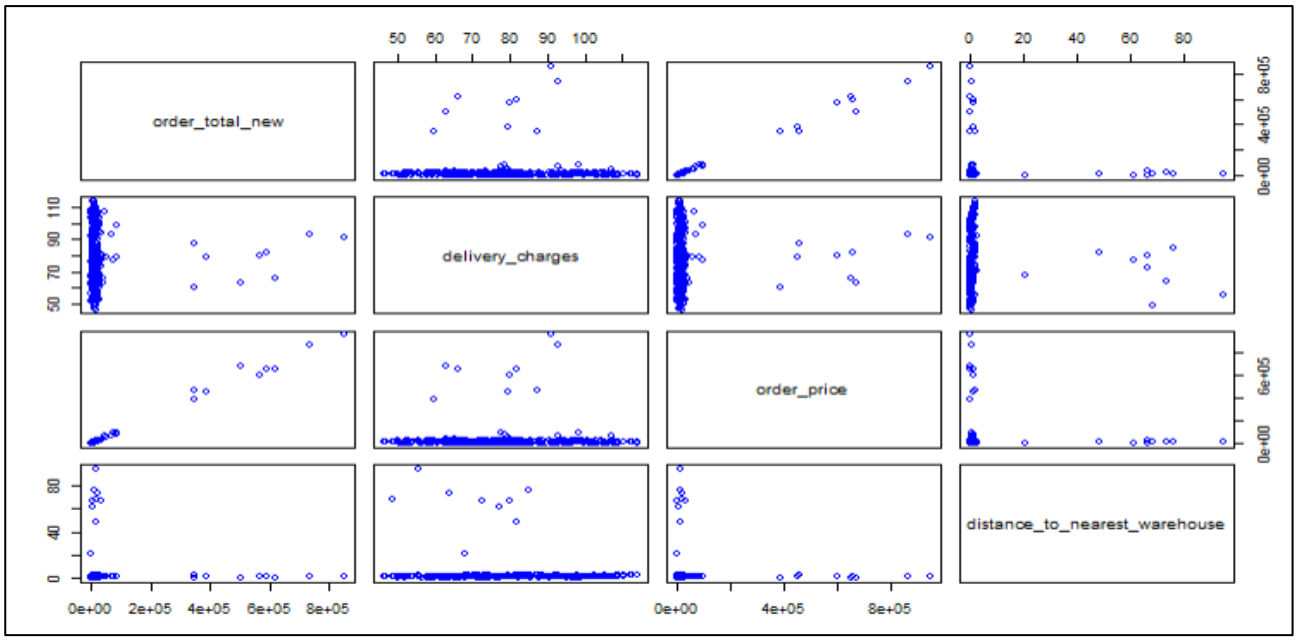

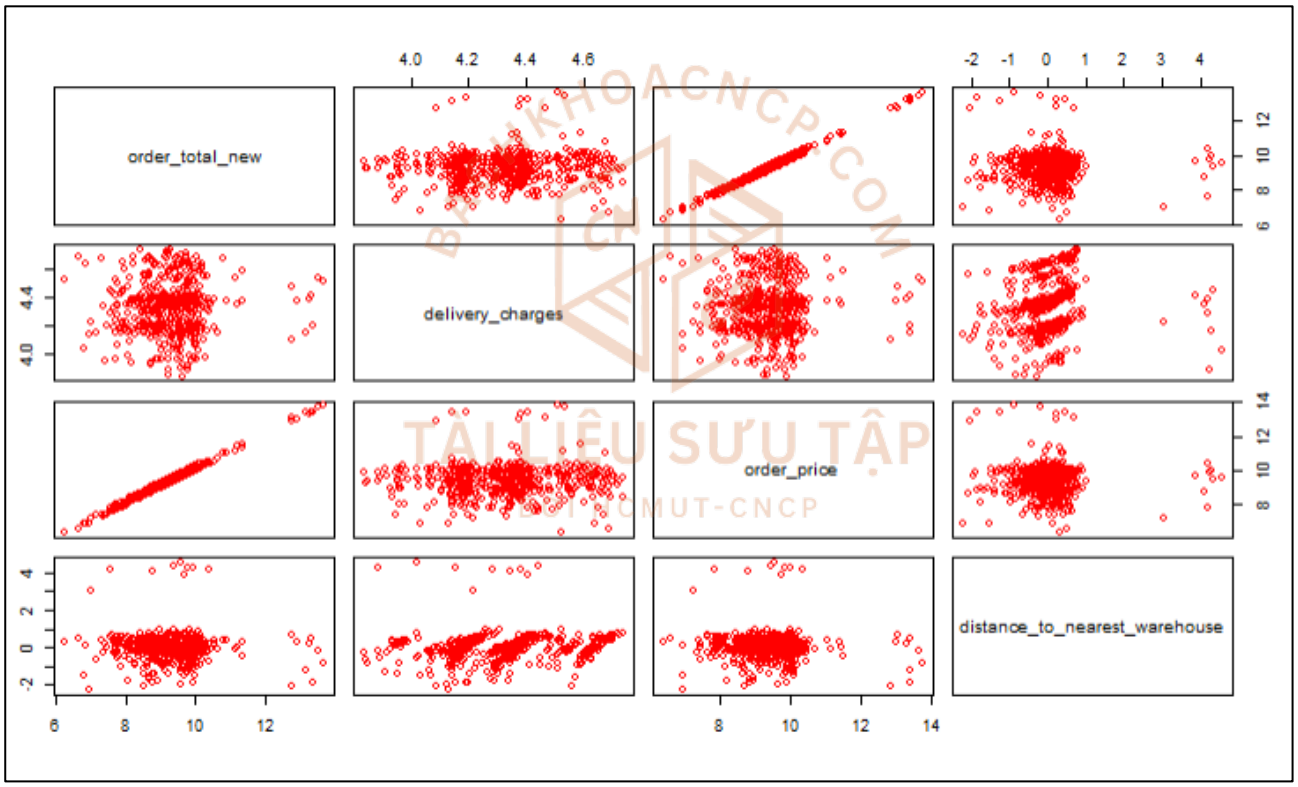

BACHKHOACNCP.COM

5. Thống kê suy diễn

5.1 Kiểm định một mẫu

Kiểm định order_price với mức ý nghĩa 5%

Khi chưa bỏ giá trị ngoại lai

```
> t_result <- t.test(dirt$order_price)
> print(t_result)

        One Sample t-test

data:  dirt$order_price
t = 6.6103, df = 499, p-value = 9.873e-11
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 17936.47 33107.96
sample estimates:
mean of x
 25522.22
```

Khi bỏ ngoại lai order_total_new

```
> dirt$order_total_new[dirt$order_total_new %in% c(out)] <- NA
> dirt <- na.omit(dirt)
> t_result <- t.test(dirt$order_price)
> print(t_result)

        One Sample t-test

data:  dirt$order_price
t = 37.274, df = 481, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 12713.92 14128.96
sample estimates:
mean of x
 13421.44
```

Khi bỏ tất cả ngoại lai total_new và is_happy_customer

```
> dirt <- dirt[-c(38, 53, 57, 84, 94, 100, 120, 201, 222, 223, 251, 265, 296, 383, 415, 419, 424, 434),]
> t_result <- t.test(dirt$order_price)
> print(t_result)

        One Sample t-test

data:  dirt$order_price
t = 36.768, df = 463, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 12774.66 14217.27
sample estimates:
mean of x
 13495.97
```


BACHKHOACNCP.COM

Dựa vào kết quả trên ta có:

Thống kê t khi chưa bỏ ngoại lai là 6.6103. Bỏ giá trị ngoại lai order_total_new tăng lên 37.274 và khi bỏ hết các giá trị ngoại lai thì t xuống thành 36.768.

Bậc tự do giảm do khi bỏ các giá trị ngoại lai từ 499 xuống 481 tiếp 463

p-value khi có ngoại lai giá trị 9.873e-11 bỏ ngoại lai order_total_new rồi bỏ hết ngoại lai sẽ càng về rất gần 0

Khoảng tin cậy 95% có giá trị trung bình giảm đi khi bỏ hết ngoại lai còn 1274.66 đến 14217.27

Ước lượng mẫu rất lớn khi bỏ ngoại lai thì giảm chỉ còn 13495.97

Như vậy thì có các biến ngoại lai sẽ ảnh hưởng thống kê t, bậc tự do, p-value, khoảng tin cậy 95% cho giá trị trung bình và ước lượng mẫu. Đặc biệt giá trị đều thay đổi rất lớn.

5.2 ANOVA

So sánh giá trị đơn đặt hàng theo từng kho. Mức ý nghĩa 5%

Cặp giả thuyết:

H0: giá trị trung bình các đơn đặt hàng là như nhau giữa các kho

H1: giá trị trung bình các đơn đặt hàng là không như nhau giữa các kho

Khi chưa bỏ ngoại lai

```
> anova1 <- aov(dirt$order_total ~ dirt$nearest_warehouse)
> summary(anova1)
                        Df    Sum Sq   Mean Sq F value Pr(>F)
dirt$nearest_warehouse   2 2.681e+11 1.341e+11   1.789  0.168
Residuals              497 3.725e+13 7.495e+10
```

Khi bỏ ngoại lai order_total_new

```
> anova1 <- aov(dirt$order_total ~ dirt$nearest_warehouse)
> summary(anova1)
                        Df    Sum Sq   Mean Sq F value Pr(>F)
dirt$nearest_warehouse   2 2.731e+11 1.366e+11   1.757  0.174
Residuals              479 3.723e+13 7.773e+10
```


BACHKHOACNCP.COM

Khi bỏ tất cả giá trị ngoại lai order_total_new và is_happy_customer

```
> dirt <- dirt[-c(38, 53, 57, 84, 94, 100, 120, 201, 222, 223, 251, 265, 296, 383, 415, 419, 424, 434),]
> anova1 <- aov(dirt$order_total ~ dirt$nearest_warehouse)
> summary(anova1)
                      Df    Sum Sq   Mean Sq F value Pr(>F)
dirt$nearest_warehouse   2 2.757e+11 1.378e+11   1.708  0.182
Residuals              461 3.721e+13 8.072e+10
```

Dựa vào các Pr(>F) (P-value) có các giá trị lần lượt là $0.168, 0.174, 0.182 > 5\%$ đều không thể bác bỏ H0. Và ta cũng thấy rằng khi có giá trị ngoại lai và bỏ giá trị ngoại lai đều không ảnh hưởng đến miền bác bỏ theo phân tích phương sai.

So sánh giá trị đơn đặt hàng theo từng mùa. Mức ý nghĩa 5%

Cặp giả thuyết:

H0: giá trị trung bình các đơn đặt hàng là như nhau theo mùa

H1: giá trị trung bình các đơn đặt hàng là không như nhau theo mùa

Khi bỏ giá trị ngoại lai

```
> anova2 <- aov(dirt$order_total_new ~ dirt$season)
>  summary(anova2)
             Df    Sum Sq   Mean Sq F value Pr(>F)
dirt$season   3 8.592e+09 2.864e+09   0.501  0.682
Residuals   496 2.836e+12 5.717e+09
```

Khi bỏ ngoại lai order_total_new

```
> dirt$order_total_new[dirt$order_total_new %in% c(out)] <- NA
> dirt <- na.omit(dirt)
> anova2 <- aov(dirt$order_total_new ~ dirt$season)
>  summary(anova2)
             Df    Sum Sq  Mean Sq F value Pr(>F)
dirt$season   3 1.468e+08 48936277   0.958  0.412
Residuals   478 2.442e+10 51081960
```

Khi bỏ tất cả ngoại lai

```
> dirt <- dirt[-c(38, 53, 57, 84, 94, 100, 120, 201, 222, 223, 251, 265, 296, 383, 415, 419, 424, 434),]
> anova2 <- aov(dirt$order_total_new ~ dirt$season)
>  summary(anova2)
             Df    Sum Sq  Mean Sq F value Pr(>F)
dirt$season   3 9.849e+07 32828493   0.642  0.588
Residuals   460 2.352e+10 51140249
```


BACHKHOACNCP.COM

So sánh giá trị đơn đặt hàng giữa người hài lòng và người không hài lòng với đơn hàng gần nhất. Mức ý nghĩa 5%

Cặp giả thuyết:

H0: giá trị trung bình các đơn đặt hàng là như nhau giữa người không hài lòng với đơn hàng gần nhất

H1: giá trị trung bình các đơn đặt hàng là không như nhau giữa người không hài lòng với đơn hàng gần nhất

Khi không bỏ giá trị ngoại lai

```
> anova4 <- aov(dirt$order_total_new ~ dirt$is_happy_customer)
> summary(anova4)
                        Df    Sum Sq   Mean Sq F value Pr(>F)
dirt$is_happy_customer   1 1.102e+10 1.102e+10   1.936  0.165
Residuals              498 2.833e+12 5.689e+09
```

Khi bỏ giá trị ngoại lai order_total_new

```
> dirt$order_total_new[dirt$order_total_new %in% c(out)] <- NA
> dirt <- na.omit(dirt)
> anova4 <- aov(dirt$order_total_new ~ dirt$is_happy_customer)
> summary(anova4)
                        Df    Sum Sq  Mean Sq F value Pr(>F)
dirt$is_happy_customer   1 1.419e+07 14186247   0.277  0.599
Residuals              480 2.455e+10 51145416
```

Khi bỏ hết tất cả giá trị ngoại lai

```
> dirt <- dirt[-c(38, 53, 57, 84, 94, 100, 120, 201, 222, 223, 251, 265, 296, 383, 415, 419, 424, 434),]
> anova4 <- aov(dirt$order_total_new ~ dirt$is_happy_customer)
> summary(anova4)
                        Df    Sum Sq  Mean Sq F value Pr(>F)
dirt$is_happy_customer   1 3.480e+07 34797902   0.682  0.409
Residuals              462 2.359e+10 51056715
```

Như vậy 2 bài toán so sánh giá trị đơn đặt hàng theo mùa và so sánh giá trị đơn đặt hàng hài lòng với giá trị đơn đặt hàng không hài lòng dù có ngoại lai hay không có ngoại lai thì cho ra p-value đều lớn hơn mức ý nghĩa 5% không thể bác bỏ giả thuyết H0. Tất cả đều bác bỏ giả thuyết H1. Như vậy ta có thể thấy rằng các giá trị ngoại lai không ảnh hưởng đến bài phân tích phương sai 1 yếu tố.

BACHKHOACNCP.COM

5.3 Hồi quy tuyến tính

Ta dùng biến phụ thuộc là biến liên tục order_total_new

Các biến độc lập là order_price, delivery_charges, coupon_discount, distance_to_nearest_warehouse.

Ta xét khi có các biến ngoại lai

Hồi quy ta có được

```
> model = lm(order_total_new ~  order_price + delivery_charges + coupon_discount +  distance_to_nearest_warehouse, data = dirt)
> summary(model)

Call:
lm(formula = order_total_new ~ order_price + delivery_charges +
    coupon_discount + distance_to_nearest_warehouse, data = dirt)

Residuals:
   Min     1Q Median     3Q    Max
-79598   -620     40    501  49203

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
(Intercept)                  2.427e+03  1.408e+03   1.724   0.0854 .
order_price                  8.725e-01  2.937e-03 297.106  < 2e-16 ***
delivery_charges             2.608e+00  1.752e+01   0.149   0.8817
coupon_discount             -2.149e+02  2.932e+01  -7.330 9.46e-13 ***
distance_to_nearest_warehouse 4.361e+00  2.881e+01   0.151   0.8797
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 5657 on 495 degrees of freedom
Multiple R-squared:  0.9944,    Adjusted R-squared:  0.9944
F-statistic: 2.21e+04 on 4 and 495 DF,  p-value: < 2.2e-16
```

Với hình trên ta có intercept là biến β_0 và các biến còn lại lần lượt là $\beta_1, \beta_2, \beta_3, \beta_4$ là của cột Estimate. Std. Error là sai số chuẩn và có R hiệu chỉnh gần về 1 cho thấy mô hình này phù hợp.

Từ đó ta có phương trình: $Y = 2427 + 0.8725X_1 + 2.608X_2 - 214.9X_3 + 4.361X_4$

Dựa vào P-value thì thấy delivery_charges và distance_to_nearest_warehouse dựa vào mức ý nghĩa 10% thì thấy không ảnh hưởng tới giá trị đặt hàng.

Kiểm định các biến delivery_charges và distance_to_nearest_warehouse đồng thời không ảnh hưởng tới giá trị đơn đặt hàng

```
> linearHypothesis(model,c("delivery_charges=0", "distance_to_nearest_warehouse=0"))
Linear hypothesis test

Hypothesis:
delivery_charges = 0
distance_to_nearest_warehouse = 0

Model 1: restricted model
Model 2: order_total_new ~ order_price + delivery_charges + coupon_discount +
    distance_to_nearest_warehouse

  Res.Df        RSS Df Sum of Sq      F Pr(>F)
1    497 1.5841e+10
2    495 1.5840e+10  2   1370899 0.0214 0.9788
```


BACHKHOACNCP.COM

Cặp giả thuyết:

H0: biến delivery_charges và distance_to_nearest_warehouse đồng thời không ảnh hưởng đến giá trị đơn đặt hàng.

H1: biến delivery_charges và distance_to_nearest_warehouse một cách đồng thời thì có ảnh hưởng đến giá trị đơn đặt hang.

Với P-value =0.9788>5% nên chấp nhận H0. Vì vậy delivery_charges và distance_to_nearest_warehouse đồng thời không ảnh hưởng đến giá trị đơn đặt hàng. Loại bỏ biến delivery_charges và distance_to_nearest_warehouse.

Chạy lại khi bỏ biến delivery_charges và distance_to_nearest_warehouse.

```
> model = lm(order_total_new ~  order_price  + coupon_discount , data = dirt)
> summary(model)

Call:
lm(formula = order_total_new ~ order_price + coupon_discount,
    data = dirt)

Residuals:
   Min     1Q Median     3Q    Max
-79644   -627     48    508  49161

Coefficients:
                  Estimate Std. Error t value Pr(>|t|)
(Intercept)      2.638e+03  4.112e+02   6.416 3.27e-10 ***
order_price      8.725e-01  2.929e-03 297.880  < 2e-16 ***
coupon_discount -2.151e+02  2.924e+01  -7.357 7.81e-13 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 5646 on 497 degrees of freedom
Multiple R-squared:  0.9944,	Adjusted R-squared:  0.9944
F-statistic: 4.437e+04 on 2 and 497 DF,  p-value: < 2.2e-16
```

Như vậy mô hình có phương trình: $Y = 2638 + 0.8725X_1 - 215.1X_3$

Tiếp theo ta xét tiếp khi bỏ các giá trị ngoại lai

Hồi quy ta có được :

BACHKHOACNCP.COM

```
> dirt$order_total_new[dirt$order_total_new %in% c(out)] <- NA
> dirt <- na.omit(dirt)
> dirt <- dirt[-c(38, 53, 57, 84, 94, 100, 120, 201, 222, 223, 251, 265, 296, 383, 415, 419, 424, 434),]
> model = lm(order_total_new ~  order_price + delivery_charges + coupon_discount +  distance_to_nearest_warehouse, data = dirt)
> summary(model)

Call:
lm(formula = order_total_new ~ order_price + delivery_charges +
    coupon_discount + distance_to_nearest_warehouse, data = dirt)

Residuals:
     Min       1Q   Median       3Q      Max
-2726.10  -327.56     1.71   299.28  2329.79

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
(Intercept)                  1.305e+03  1.851e+02   7.047 6.75e-12 ***
order_price                  8.874e-01  4.053e-03 218.965  < 2e-16 ***
delivery_charges             3.246e+00  2.189e+00   1.483   0.1388
coupon_discount             -1.328e+02  3.714e+00 -35.761  < 2e-16 ***
distance_to_nearest_warehouse 8.122e+00  3.514e+00   2.311   0.0213 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 689.2 on 459 degrees of freedom
Multiple R-squared:  0.9908,    Adjusted R-squared:  0.9907
F-statistic: 1.232e+04 on 4 and 459 DF,  p-value: < 2.2e-16
```

Ta có phương trình

$$Y = 1305 + 0.8874X_1 + 3.246X_2 - 132.8X_3 + 8.1222X_4$$

Dựa vào hình trên ta thấy được p-value của delivery_charges >10% ta thấy không ảnh hưởng đến giá trị đặt hàng.

Kiểm định các biến delivery_charges đồng thời không ảnh hưởng tới giá trị đơn đặt hàng

```
> linearHypothesis(model,c("delivery_charges=0"))
Linear hypothesis test

Hypothesis:
delivery_charges = 0

Model 1: restricted model
Model 2: order_total_new ~ order_price + delivery_charges + coupon_discount +
    distance_to_nearest_warehouse

  Res.Df       RSS Df Sum of Sq     F Pr(>F)
1    460 219046612
2    459 218002179  1   1044433 2.199 0.1388
```

Cặp giả thuyết:

H0: biến delivery_charges không ảnh hưởng đến giá trị đơn đặt hàng.

H1: biến delivery_charges có ảnh hưởng đến giá trị đơn đặt hàng.

Với p-value=0.1388>10% nên chấp nhận H0. Vì vậy loại bỏ delivery_charges.

Chạy lại mô hình khi bỏ biến delivery_charges

BACHKHOACNCP.COM

```
> model = lm(order_total_new ~  order_price  + coupon_discount +  distance_to_nearest_warehouse, data = dirt)
> summary(model)

Call:
lm(formula = order_total_new ~ order_price + coupon_discount +
    distance_to_nearest_warehouse, data = dirt)

Residuals:
     Min       1Q   Median       3Q      Max
-2770.54  -338.04    -1.89   296.83  2331.25

Coefficients:
                                 Estimate Std. Error t value Pr(>|t|)
(Intercept)                    1.555e+03  7.565e+01   20.56   <2e-16 ***
order_price                    8.873e-01  4.058e-03  218.68   <2e-16 ***
coupon_discount               -1.328e+02  3.719e+00  -35.72   <2e-16 ***
distance_to_nearest_warehouse  7.835e+00  3.513e+00    2.23   0.0262 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 690.1 on 460 degrees of freedom
Multiple R-squared:  0.9907,    Adjusted R-squared:  0.9907
F-statistic: 1.638e+04 on 3 and 460 DF,  p-value: < 2.2e-16
```

$$Y = 1555 + 0.8873X_1 - 132.8X_3 + 7.835X_4$$

Từ 2 bài toán trên ta có thể thấy được rằng giá trị ngoại lai ảnh hưởng đến mô hình hồi quy tuyến tính như nào. Việc loại bỏ giá trị ngoại lai giúp ta giữ lại biến distance_to_nearest_warehouse và thấy ràng có ảnh hưởng đến order_total_new còn giữ ngoại lai ta phải bỏ distance_to_nearest_warehouse ra khỏi mô hình.

Đánh giá mô hình

Đánh giá sự phù hợp của mô hình:

H0: Tất cả các yếu tố đều không tác động đến Y. F = 16380 và p-value <2.2e-16 gần bằng 0 nên bác bỏ H0. Vậy có ít nhất 1 nhân tố độc lập có tác động đến mức độ Y. Mô hình là phù hợp.

** Mức độ giải thích của mô hình:*

R^2 *hiệu chỉnh* $= 0.9907$. Mô hình giải thích được 99.07% sự thay đổi của giá trị đơn đặt hàng. Còn lại 0.93% sự thay đổi của Y là do tác động của các yếu tố khác nằm ngoài mô hình.

** Kiểm định ý nghĩa thống kê của các hệ số hồi quy:*

H0: Hệ số hồi quy của biến coupon_discount =0. P-value < 5% nên bác bỏ H0. Vậy X3

có tác động đến Y với mức ý nghĩa 5%. H1: Hệ số hồi quy của biến distance_to_nearest_warehouse = 0. P-value = 0,0262 < 5% nên bác bỏ H0.

Vậy distance_to_nearest_warehouse có tác động đến Y với mức ý nghĩa 5%

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

BACHKHOACNCP.COM

$$order_total_new = 1555 + 0.8873 * order_price - 132.8 * coupon_discount + 7.835 * distance_to_nearest_warehouse$$

Trong đó

0.8873: nếu giá hàng tăng 1 đơn vị và các yếu tố khác không thay đổi thì giá trị đơn đặt hàng trung bình tăng 0.8873.

-132.8: nếu phiếu giảm giá tăng 1 đơn vị và các yếu tố khác không thay đổi thì giá trị đơn đặt hàng trung bình giảm -132.8.

7.835: nếu khoảng cách gần kho tăng 1 đơn vị và các yếu tố khác không thay đổi thì giá trị đơn đặt trung bình tăng 7.835.

6. Thảo luận và mở rộng

Mục đích xây dựng mô hình hồi quy tuyến tính đa biến:

Mục đích chính của việc xây dựng mô hình hồi quy hồi quy tuyến tính đa biến là phân loại cảm xúc của khách hàng khi mua hàng thành các nhóm hay lớp. Điều này giúp ta hiểu được xác suất của việc khách hàng có cảm xúc tích cực hay tiêu cực dựa trên các biến độc lập như customer_id, nearest_warehouse, order_price, và coupon_discount. Mô hình hồi quy tuyến tính đa biến thích hợp cho các bài toán phân loại.

BACHKHOACNCP.COM
ỀU SƯU TẬP
BỞI H

BACHKHOACNCP.COM