ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

Môn học: Xác suất thống kê

Lớp: L06 - Nhóm: DD11

Giảng viên: Nguyễn Kiều Dung

STT	Họ tên SV	MSSV	Tên lớp	Tên khoa/ngành	Điểm chia
1.			L06	Điện – Điện tử	
2.			L06	Điện – Điện tử	
3.			L06	Điện – Điện tử	
4.			L06	Điện – Điện tử	
5.			L06	Điện – Điện tử	

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

BÁO CÁO PHÂN CÔNG NHIỆM VỤ VÀ KẾT QUẢ

STT	Họ tên SV	MSSV	Nhiệm vụ	Đánh giá
1.				
2.				
3.				
4.				
5.				

Nhóm trưởng

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Danh mục bảng

Bảng 1 Giá trị quan trắc 7
Bảng 2 Mẫu điều tra phân tích phương sai 2 nhân tố không lặp 11
Bảng 3 Tính toán phương sai 2 nhân tố không lặp 12
Bảng 4 ANOVA phương sai 2 nhân tố không lặp 12
Bảng 5 Mẫu điều tra phương sai 2 nhân tố có lặp 13
Bảng 6 Xử lý mẫu phương sai 2 nhân tố có lặp 13
Bảng 7 ANOVA phương sai 2 nhân tố có lặp 14

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Danh mục hình ảnh

Hình 1 Code R đọc dữ liệu dirty_data.csv 16
Hình 2 Kết quả khi đọc dữ liệu dirty_data.csv 16
Hình 3 Code R tạo dữ liệu mới data 16
Hình 4 Kết quả khi tạo dữ liệu mới chỉ gồm những biến chính 17
Hình 5 Code R kiểm tra xem các dữ liệu trong biến có bị sai cần định dạng, xử lý 18
Hình 6 Kết quả khi dữ liệu đã được kiểm tra có bị sai cần định dạng, xử lý 18
Hình 7 Code R xử lý các dữ liệu bị sai 18
Hình 8 Code R chuyển đổi các biến từ ký tự sang số 19
Hình 9 Kết quả khi dữ liệu đã được định dạng, xử lý 19
Hình 10 Ví dụ về sai dữ liệu biến 19
Hình 11 Code R tính lại và thay thế toàn bộ biến total_price 19
Hình 12 Kết quả khi dữ liệu đã được tính lại và thay thế biến total_price 20
Hình 13 Tóm tắt dữ liệu delivery_charges 21
Hình 14 Vẽ bảng delivery_charges (1) 21
Hình 15 Vẽ bảng delivery_charges (2) 22
Hình 16 Biểu đồ phân bố biến delivery_charges 22
Hình 17 Vẽ bảng biến neareast_warehouse 23
Hình 18 Vẽ biểu đồ biến neareast_warehouse 23
Hình 19 Vẽ bảng hai biến is_happy_customer và nearest_warehouse 23
Hình 20 Vẽ biểu đồ hai biến is_happy_customer và nearest_warehouse 24
Hình 21 Vẽ biểu đồ tán xạ ba biến delivery_charges, order_total và is_happy_customer trước khi lọc điểm ngoại lai 24
Hình 22 Vẽ biểu đồ tán xạ ba biến delivery_charges, order_total và is_happy_customer sau khi lọc điểm ngoại lai 25
Hình 23 Biểu đồ Box plot giữa 2 biến order_total và nearest_warehouse 26
Hình 24: Các thông số đặc trưng của biến order_total ở cửa hàng Thompson trước khi lọc ngoại lai 26
Hình 25 Các thông số đặc trưng của biến order_total ở cửa hàng Nickolson trước khi lọc ngoại lai 26
Hình 26 Các thông số đặc trưng của biến order_total ở cửa hàng Bakers trước khi lọc ngoại lai 26
Hình 27 Độ lệch chuẩn của biến order_total ở cửa hàng Thompson trước khi lọc ngoại lai 27
Hình 28 Độ lệch chuẩn của biến order_total ở cửa hàng Nickolson trước khi lọc ngoại lai 27
Hình 29 Độ lệch chuẩn của biến order_total ở cửa hàng Bakers trước khi lọc ngoại lai 27
Hình 30 Biểu đồ Box plot giữa 2 biến order_total và nearest_warehouse sau khi xử lí điểm ngoại lai 27

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Hình 31 Các thông số đặc trưng của biến order_total ở cửa hàng Thompson sau khi lọc ngoại lai 28
Hình 32 Các thông số đặc trưng của biến order_total ở cửa hàng Nickolson sau khi lọc ngoại lai 28
Hình 33 Các thông số đặc trưng của biến order_total ở cửa hàng Bakers sau khi lọc ngoại lai 28
Hình 34 Độ lệch chuẩn của biến order_total cửa hàng Thompson sau khi lọc ngoại lai .. 28
Hình 35 Độ lệch chuẩn của biến order_total ở cửa hàng Nickolson sau khi lọc ngoại lai 28
Hình 36 Độ lệch chuẩn của biến order_total ở cửa hàng Bakers sau khi lọc ngoại lai 28
Hình 37 Code R bài toán tìm khoảng tin cậy 29
Hình 38 Kết quả sau khi thực hiện trên R của bài toán tìm khoảng tin cậy 29
Hình 39 Thực hiện trên R của bài toán kiểm định 2 mẫu 30
Hình 40 Kết quả sau khi thực hiện trên R của bài toán kiểm định 2 mẫu 30
Hình 41 Giải thích kết quả bài toán kiểm định hai mẫu sau khi thực hiện trên R (1) 30
Hình 42 Giải thích kết quả bài toán kiểm định hai mẫu sau khi thực hiện trên R (2) 30
Hình 43 Chi phí đặt hàng ở các kho hàng trong các mùa tuân theo phân phối chuẩn 31
Hình 44 Kiểm tra theo phương pháp Shapiro- Wilk test (1) 31
Hình 45 Kiểm tra theo phương pháp Shapiro- Wilk test (2) 31
Hình 46 Phương sai chi phí đặt hàng ở các kho hàng trong các mùa (1) 31
Hình 47 Phương sai chi phí đặt hàng ở các kho hàng trong các mùa (2) 31
Hình 48 Phân tích phương sai 2 yếu tố (1) 32
Hình 49 Phân tích phương sai 2 yếu tố (2) 32
Hình 50 Code R tạo tập tin mới phân tích sau khi làm sạch dữ liệu của bài toán hồi quy đa biến 32
Hình 51 Code R thực hiện hồi quy logistic (1) 33
Hình 52 Code R thực hiện hồi quy logistic (2) 33
Hình 53 Code R thực hiện hồi quy logistic (3) 33
Hình 54 Code R của hàm shapiro.test cho biến coupon_discount 34
Hình 55 Code R cho kiểm định Wilcoxon cho hai mẫu 35
Hình 56 Kết quả sau khi chạy thực hiện trên R của kiểm định Wilcoxon cho 2 mẫu 35
Hình 57 Code R của phương pháp Kruskal- Wallis 36
Hình 58: Kết quả sau khi thực hiện trên R của phương pháp Kruskal- Wallis 36
Hình 59 Code R xây dựng mô hình phương pháp mở rộng Decision Tree 37
Hình 60 Kết quả sau khi thực hiện trên R phương pháp mở rộng Decision Tree 37
Hình 61 Code R thực hiện dự báo về mô hình 37
Hình 62 Kết quả sau khi thực hiện trên R dự báo về mô hình 38
Hình 63 Code R so sánh giữa kết quả dự báo và thực tế trong mẫu 38
Hình 64 So sánh giữa kết quả dự báo và thực tế trong mẫu 38
Hình 65 Code R kiểm tra tỉ lệ phân loại sai 38
Hình 66 Kiểm tra tỉ lệ phân loại sai 38

BACHKHOACNCP.COM

MỤC LỤC

1. Tổng quan dữ liệu 7
1.1 Ngữ cảnh dữ liệu 7
1.2 Giá trị quan trắc 7
2. Kiến thức nền 8
2.1 Kiểm định giả thuyết 8
2.2 Ước lượng 10
2.3 Lý thuyết về mô hình ANOVA 11
2.4 Mô hình hồi quy nhị phân logistic 15
3. Tiền xử lý số liệu 16
3.1 Đọc dữ liệu 16
3.2 Làm sạch dữ liệu (Data cleaning): 16
3.3 Kiểm tra dữ liệu khuyết 17
3.4 Xử lý định dạng dữ liệu 18
3.5 Chuyển đổi biến 19
4. Thống kê tả 21
4.1 Biểu đồ phân bố Histogram 21
4.2 Biểu đồ bánh pie chart 22
4.3 Biểu đồ cho hai biến rời rạc 23
4.4 Biểu đồ tán xạ scatter plot 24
4.5 Biểu đồ hộp box plot 25
5. Thống kê suy diễn 29
5.1 Tìm khoảng tin cậy. 29
5.2 Kiểm định hai mẫu. 29
5.3 Mô hình ANOVA (Phân tích phương sai 2 nhân tố) 30
5.4 Mô hình hồi quy logistic 32
6. Thảo luận và mở rộng 34
6.1 Tìm khoảng tin cậy 34
6.2 Kiểm định 2 mẫu 34
7. Tài liệu tham khảo **39**

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

1. Tổng quan dữ liệu

1.1 Ngữ cảnh dữ liệu

Tập dữ liệu chứa thông tin về một cửa hàng điện tử trực tuyến. Cửa hàng có ba kho để giao hàng cho khách hàng. Dựa vào dữ liệu trên tìm được mối quan hệ giữa các biến để từ đó đưa ra được phỏng đoán, xây dựng được mô hình dự báo mức độ hài lòng của khách hàng.

1.2 Giá trị quan trắc

Biến	Kiểu dữ liệu	Đơn vị	Miêu tả
order_id	Biến rời rạc		ID duy nhất cho mỗi đơn hàng
customer_id	Biến rời rạc		ID duy nhất cho mỗi khách hàng
date	Biến liên tục		Ngày đặt hàng
nearest_warehouse	Phân loại định tính		Chuỗi tên kho gần khách hàng nhất
order_price	Biến liên tục	AUD	Giá đơn hàng trước khi áp dụng giảm giá và phí vận chuyển
delivery_charges	Biến liên tục	AUD	Phí giao hàng của đơn hàng
coupon_discount	Biến rời rạc	%	Phần trăm giảm giá cho giá trị order_price
order_total	Biến liên tục	AUD	Tổng giá trị đơn hàng (bao gồm phí vận chuyển và chiết khấu giảm giá)
season	Phân loại định tính		Mùa mà đơn hàng được đặt
is_expedited_delivery	Biến phân loại		Biểu thị khách hàng có yêu cầu
distance_to_nearest_warehouse	Biến liên tục	mét	Khoảng cách giữa khách hàng và nhà kho gần họ nhất
is_happy_customer	Biến phân loại		biểu thị liệu khách hàng có hài lòng hay gặp vấn đề với đơn hàng gần đây nhất của họ hay không

Bảng 1 Giá trị quan trắc

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

2. Kiến thức nền

2.1 Kiểm định giả thuyết

2.1.1. Giả thuyết thống kê

Chúng ta nghiên cứu vấn đề của một tổng thể thông qua một dấu hiệu nào đó. Trong quá trình nghiên cứu cần kiểm tra xem dấu hiệu đó có hay không có một hoặc một số tính chất nào đó.

Do không có đầy đủ thông tin trên tổng thể nên không thể đánh giá chính xác vấn đề đó được. Thông tin trên mẫu sẽ được sử dụng để kiểm tra đánh giá tính chất đó theo một phương pháp toán học. Những bài toán đó gọi là bài toán kiểm định giả thuyết thống kê.

Dấu hiệu nghiên cứu được đặc trưng bởi (các) biến ngẫu nhiên – gọi là biến ngẫu nhiên gốc. Việc kiểm tra một mệnh đề liên quan đến biến ngẫu nhiên gốc là kiểm định một giả thuyết thống kê, bao gồm 3 loại:

- Kiểm định về dạng phân phối xác suất (chẳng hạn, liệu một biến ngẫu nhiên nào đó có phân phối chuẩn hay không?).
- Kiểm định về tham số đặc trưng (trung bình, phương sai, tỷ lệ).
- Kiểm định về tính độc lập của các biến ngẫu nhiên (chẳng hạn, việc sắp xếp các quầy hàng theo thứ tự khác nhau và sự hài lòng của khách hàng có liên quan với nhau hay không?).

Trong giới hạn chương trình, ở bài này ta chỉ xét các giả thuyết thống kê về các tham số đặc trưng của tổng thể (chính là các tham số đặc trưng của biến ngẫu nhiên gốc). Để thuận tiện và chuẩn xác về mặt toán học, các mệnh đề cần được kiểm định sẽ được đặt dưới dạng các cặp giả thuyết. Tùy mục đích nghiên cứu của từng trường hợp, cặp giả thuyết sẽ tương ứng với các mệnh đề. Cặp giả thuyết gồm một giả thuyết gọi là giả thuyết gốc, kí hiệu H_0, và một giả thuyết đối, kí hiệu là H_1. Khi bác bỏ giả thuyết H_0 thì sẽ chấp nhận giả thuyết H_1 đi kèm theo nó. Các cặp giả thuyết thống kê về tham số đặc trưng θ nào đó của biến ngẫu nhiên gốc có thể quy về ba dạng sau:

$$\begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta \neq \theta_0 \end{cases}$$

$$\begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta > \theta_0 \end{cases}$$

$$\begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta < \theta_0 \end{cases}$$

2.1.2. Phương pháp kiểm định

Xét mẫu ngẫu nhiên (X_1, X_2,…, X_n) được lập từ tổng thể, tùy thuộc cặp giả thuyết, ta chọn lập một thống kê tương ứng với giả thuyết gốc, kí hiệu là $G = f(X_1, X_2,\ldots, X_n)$

BACHKHOACNCP.COM

Thống kê G được chọn sao cho nếu H_0 đúng thì quy luật phân phối xác suất của G hoàn toàn xác định.

Cùng với thống kê G, xác định một miền W_α sao với 1 giá trị là $\alpha \in (0; 1)$ đủ nhỏ thường lấy α bằng 0,05 hoặc 0,1) thì xác suất để thống kê G thuộc miền W_α bằng giá trị đủ nhỏ đó. Tức là: $P(G \in W_\alpha | H_0) = \alpha$

Khi đó, theo nguyên lý xác suất lớn và nhỏ, khi H_0 đúng, xác suất để biến cố $(G \in W_\alpha)$ xảy ra là nhỏ, nên nếu với một mẫu, tính được giá trị cụ thể của G là $G_{qs} = f(x_1,x_2,...,x_n)$

và nếu biến cố $(G \in W_\alpha)$ xảy ra thì có thể cho rằng H_0 là không đúng theo cách kiểm

định này.

- Thống kê G được gọi là tiêu chuẩn kiểm định.
- Giá trị α được gọi là mức ý nghĩa của kiểm định.
- Miền W_α được gọi là miền bác bỏ giả thuyết H_0 với mức ý nghĩa α.

Với một mẫu cụ thể, tính được giá trị quan sát G_{qs} của tiêu chuẩn kiểm định:

- Nếu giá trị quan sát thuộc miền bác bỏ → bác bỏ H_0.
- Nếu giá trị quan sát không thuộc miền bác bỏ → chưa bác bỏ H_0

2.1.3. Các loại sai lầm

Khi sử dụng phương pháp kiểm định thống kê trên, có thể mắc phải các sai lầm. Các sai lầm gồm hai loại:

- Sai lầm loại một: bác bỏ một điều đúng. Xác suất mắc sai lầm loại một bằng mức ý nghĩa α
- Sai lầm loại hai: thừa nhận một điều sai. Xác suất mắc sai lầm loại hai bằng β, $1 - \beta$ gọi là lực kiểm định.

2.1.4. Các bước thực hiện

Bài toán kiểm định ở đây được thực hiện với giá trị cho trước của mức ý nghĩa α. Các

bước tiến hành tổng quát như sau:

- Xây dựng giả thuyết gốc H_0 cần kiểm định, từ đó viết cặp giả thuyết.
- Lập mẫu ngẫu nhiên kích thước n.
- Chọn tiêu chuẩn kiểm định G và xác định được quy luật phân phối xác suất của G khi giả thuyết H_0 là đúng.
- Xác định miền bác bỏ tốt nhất tùy thuộc vào giả thuyết đối H_1.
- Lập mẫu cụ thể và tìm được giá trị quan sát của tiêu chuẩn kiểm định.
- So sánh giá trị quan sát với miền bác bỏ và kết luận.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Trên thực tế, ta thường xét một số bài toán kiểm định các tham số cơ bản là trung bình (μ), phương sai (σ^2) của tổng thể phân phối chuẩn, và tỷ lệ tổng thể (ρ) trên các mẫu đã được cho thông tin. Do đó các tiêu chuẩn kiểm định, miền bác bỏ đã được xác định trước. Công việc phải thực hiện là:

- Xác định chính xác cặp giả thuyết.
- Tìm đúng tiêu chuẩn kiểm định và miền bác bỏ.
- Tính đúng các thống kê dựa trên mẫu, tính giá trị quan sát.
- Tra bảng số để kết luận bác bỏ hoặc chưa bác bỏ H_0.
- Kết luận đúng về câu hỏi.

2.2 Ước lượng

Ước lượng trong xác suất thống kê là quá trình suy luận về các đặc tính của một quần thể dựa trên thông tin thu thập từ một mẫu ngẫu nhiên từ quần thể đó. Mục tiêu của ước lượng là cung cấp các ước lượng thống kê chính xác về các tham số của quần thể, như trung bình, phương sai, tỷ lệ, hay các tham số khác tùy thuộc vào bối cảnh cụ thể.

2.2.1. Mẫu ngẫu nhiên

Một mẫu ngẫu nhiên là một tập hợp các quan sát được chọn từ một quần thể sao cho mỗi phần tử trong quần thể có cơ hội bằng nhau để được chọn vào mẫu.

2.2.2. Tham số và ước lượng

Tham số là một đặc điểm của quần thể, ví dụ như trung bình, phương sai, tỷ lệ thành công, và nhiều tham số khác.

Ước lượng là một con số được tính toán từ mẫu để ước lượng tham số tương ứng trong quần thể.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

2.2.3. Loại ước lượng

Ước lượng điểm: Một con số cụ thể được cho là ước lượng của một tham số.

Ước lượng khoảng: Một dải giá trị được xác định để chứa giá trị ước lượng với một mức độ tin cậy xác định.

2.2.4. Độ tin cậy

Độ tin cậy là khả năng mà một khoảng ước lượng chứa giá trị tham số thực. Thông thường, nó được biểu diễn bằng một tỷ lệ tin cậy, ví dụ như 95%.

2.2.5. Phương pháp ước lượng

Ước lượng cực đại hợp lý: Phương pháp tìm giá trị của tham số làm tăng xác suất của mẫu được quan sát.

Ước lượng phương sai tối thiểu: Phương pháp so sánh các giá trị của các đặc tính mẫu với giá trị kỳ vọng của chúng trong quần thể để ước lượng tham số.

BACHKHOACNCP.COM

2.2.6. Kiểm tra ước lượng

Các phương pháp thống kê được sử dụng để kiểm tra xem một ước lượng có độ tin cậy hay không, ví dụ như kiểm định giả thuyết và kiểm tra t.

2.2.7. Số lượng mẫu và độ chệch

Độ chệch của một ước lượng là sự chênh lệch giữa giá trị ước lượng và giá trị tham số thực tế.

Số lượng mẫu thường được tăng để giảm độ chệch của ước lượng và tăng độ tin cậy của nó.

Những khái niệm này tạo nên cơ sở cho quá trình xây dựng ước lượng thống kê và làm cho chúng hữu ích trong việc tạo ra những kết luận rộng rãi về quần thể từ mẫu có kích thước nhỏ.

2.3 Lý thuyết về mô hình ANOVA

2.3.1. Phân tích phương sai 2 nhân tố không lặp

Phân tích nhằm đánh giá sự ảnh hưởng của 2 nhân tố (yếu tố) A và B trên các giá trị quan sát x_{ij}.

Giả sử: nhân tố A có n mức $a_1, a_2, \ldots, a_n$ (nhân tố hàng); nhân tố B có m mức $b_1, b_2, \ldots, b_m$ (nhân tố cột).

Mẫu điều tra:

A \ B	b_1	b_2	…	b_m
a_1	x_{11}	x_{12}	…	x_{1m}
a_2	X_{21}	x_{22}	…	x_{2m}
⋮	⋮	⋮		⋮
a_n	x_{n1}	x_{n2}	…	x_{nm}

Bảng 2 Mẫu điều tra phân tích phương sai 2 nhân tố không lặp

Giả thiết H_0:

- Trung bình nhân tố cột bằng nhau
- Trung bình nhân tố hàng bằng nhau
- Không có sự tương tác giữa nhân tố cột và hàng

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Tiến hành tính toán theo bảng dưới đây:

A \ B	b_1	b_2	$\cdots$	b_m	$T_{i*} = \sum_j x_{ij}$	$\sum_j x_{ij}^2$
a_1	x_{11}	x_{12}	$\cdots$	x_{1m}	T_{1*}	$\sum_j x_{1j}^2$
a_2	X_{21}	x_{22}	$\cdots$	x_{2m}	T_{2*}	$\sum_j x_{2j}^2$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
a_n	x_{n1}	x_{n2}	$\cdots$	x_{nm}	T_{n*}	$\sum_j x_{nj}^2$
$T_{*j} = \sum_j x_{ij}$	T_{*1}	T_{*2}	$\cdots$	T_{*m}	$T = \sum_{i,j} x_{ij}$	
$\sum_i x_{ij}^2$	$\sum_i x_{i1}^2$	$\sum_i x_{i2}^2$	$\cdots$	$\sum_i x_{im}^2$		$\sum_{i,j} x_{ij}^2$

Bảng 3 Tính toán phương sai 2 nhân tố không lặp

Bảng ANOVA:

Nguồn	SS	df	MS	F
Yếu tố A	$SSA = \frac{\sum_i T_{i*}^2}{m} - \frac{T^2}{m.n}$	$n-1$	$MSA = \frac{SSA}{n-1}$	$F_A = \frac{SSA}{SSE}$
Yếu tố B	$SSB = \frac{\sum_j T_{*j}^2}{n} - \frac{T^2}{m.n}$	$m-1$	$MSB = \frac{SSB}{m-1}$	$F_B = \frac{SSB}{SSE}$
Sai số	$SSE = SST - SSA - SSB$	$(n-1)(m-1)$	$MSE = \frac{SSE}{(n-1)(m-1)}$	
Tổng	$SST = \sum_{i,j} x_{ij}^2 - \frac{T^2}{m.n}$	$nm-1$		

Bảng 4 ANOVA phương sai 2 nhân tố không lặp

Kết luận:

Nếu $F_A > F_{n-1;(n-1).(m-1);1-\alpha}$ thì bác bỏ yếu tố A (hàng)

Nếu $F_B > F_{m-1;(n-1).(m-1);1-\alpha}$ thì bác bỏ yếu tố B (cột)

2.3.2. Phân tích phương sai 2 nhân tố có lặp

Tương tự như bài toán phân tích phương sai 2 nhân tố không lặp, chỉ khác mỗi mức (a_i, b_j) đều có sự lặp lại r lần thí nghiệm và ta cần khảo sát thêm sự tương tác F_{AB} giữa 2 nhân tố A và B.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Mẫu điều tra:

A \ B	b_1	b_2	$\cdots$	b_m
a_1	x_{111} x_{112} $\vdots$ x_{11r}	x_{121} x_{122} $\vdots$ x_{12r}	$\cdots$ $\cdots$ $\cdots$	x_{1m1} x_{1m2} $\vdots$ x_{1mr}
a_2	x_{211} x_{212} $\vdots$ x_{21r}	x_{221} x_{222} $\vdots$ x_{22r}	$\cdots$ $\cdots$ $\cdots$	x_{2m1} x_{2m2} $\vdots$ x_{2mr}
$\vdots$	$\vdots$	$\vdots$		$\vdots$
a_n	x_{n11} x_{n12} $\vdots$ x_{n1r}	x_{n21} x_{n22} $\vdots$ x_{n2r}	$\cdots$ $\cdots$ $\cdots$	x_{nm1} x_{nm2} $\vdots$ x_{nmr}

Bảng 5 Mẫu điều tra phương sai 2 nhân tố có lặp

Xử lý mẫu:

Tính tổng hàng $T_{i**} = \sum_{j,k} x_{ijk}$

Tính tổng hàng $T_{*j*} = \sum_{i,k} x_{ijk}$

A \ B	b_1	b_2	$\cdots$	b_m	T_{i**}
a_1	x_{111} x_{112} $\vdots$ x_{11r}	x_{121} x_{122} $\vdots$ x_{12r}	$\cdots$ $\cdots$ $\cdots$	x_{1m1} x_{1m2} $\vdots$ x_{1mr}	$T_{1**} = \sum_{j,k} x_{1jk}$
a_2	x_{211} x_{212} $\vdots$ x_{21r}	x_{221} x_{222} $\vdots$ x_{22r}	$\cdots$ $\cdots$ $\cdots$	x_{2m1} x_{2m2} $\vdots$ x_{2mr}	$T_{2**} = \sum_{j,k} x_{2jk}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_n	x_{n11} x_{n12} $\vdots$ x_{n1r}	x_{n21} x_{n22} $\vdots$ x_{n2r}	$\cdots$ $\cdots$ $\cdots$	x_{nm1} x_{nm2} $\vdots$ x_{nmr}	$T_{n**} = \sum_{j,k} x_{njk}$
T_{*j*}	$T_{*1*} = \sum_{i,k} x_{i1k}$	$T_{*2*} = \sum_{i,k} x_{i2k}$	$\cdots$	$T_{*m*} = \sum_{i,k} x_{imk}$	$T = \sum_{i,j,k} x_{ijk}$

Bảng 6 Xử lý mẫu phương sai 2 nhân tố có lặp

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Cần tính:

$$\sum_{i,j,k} x_{ijk}^2 \,;\, \sum_{i} T_{i**}^2 \,;\, \sum_{j} T_{*j*}^2 \,;\, \sum_{i,j} T_{ij*}^2$$

Suy ra:

$$SST = \sum_{i,j,k} (x_{ijk} - \bar{x})^2 = \sum_{i,j,k} x_{ijk}^2 - \frac{T^2}{nmr}$$

$$SSA = mr \sum_{i} (\bar{x}_{i**} - \bar{x})^2 = \frac{\sum_i T_{i**}^2}{mr} - \frac{T^2}{nmr}$$

$$SSB = nr \sum_{j} (\bar{x}_{*j*} - \bar{x})^2 = \frac{\sum_j T_{*j*}^2}{nr} - \frac{T^2}{nmr}$$

$$SSAB = r \sum_{j,i} (\bar{x}_{ij*} - \bar{x}_{i**} - \bar{x}_{*j*} + \bar{x})^2 = \frac{\sum_{i,j} T_{ij*}^2}{r} - \frac{\sum_j T_{*j*}^2}{nr} - \frac{\sum_i T_{i**}^2}{mr} + \frac{T^2}{nmr}$$

$$SSE = SST - SSA - SSB - SSAB = \sum_{i,j,k} x_{ijk}^2 - \frac{\sum_{i,j} x_{ij*}^2}{r}$$

* Bảng ANOVA:

Nguồn	SS	df	MS	F
Yếu tố A	SSA	$n-1$	$MSA = \frac{SSA}{n-1}$	$F_A = \frac{MSA}{MSE}$
Yếu tố B	SSB	$m-1$	$MSB = \frac{SSB}{m-1}$	$F_B = \frac{MSB}{MSE}$
Tương tác AB	SSAB	$(n-1)(m-1)$	$MSAB = \frac{SSAB}{(n-1)(m-1)}$	$F_{AB} = \frac{MSAB}{MSE}$
Sai số	SSE	$nm(r-1)$	$MSE = \frac{SSE}{nm(r-1)}$	
Tổng	SST	$rnm-1$		

Bảng 7 ANOVA phương sai 2 nhân tố có lặp

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

Kết luận:

Nếu $F_A > F_{n-1;n.m.(r-1);1-\alpha}$ thì bác bỏ yếu tố A (hàng)

Nếu $F_B > F_{m-1;n.m.(r-1);1-\alpha}$ thì bác bỏ yếu tố B (cột)

Nếu $F_{AB} > F_{(n-1).(m-1);n.m.(r-1);1-\alpha}$ thì có sự tương tác giữa A và B

2.4 Mô hình hồi quy nhị phân logistic

2.4.1. Lý thuyết về mô hình hồi quy nhị phân Logistic

Hồi quy Logistic là mô hình phổ biến trong nghiên cứu dùng để ước lượng xác suất một sự kiện sẽ xảy ra. Đặc trưng của hồi quy nhị phân là biến phụ thuộc chỉ có hai giá trị: 0 và 1. Trên thực tế, có rất nhiều hiện tượng tự nhiên, hiện tượng kinh tế, xã hội,… mà chúng ta cần dự đoán khả năng xảy ra của nó như chiến dịch quảng cáo có được chấp nhận hay không, người vay có trả được nợ hay không, công ty có phá sản hay không, khách hàng có mua hay không,… Những biến nghiên cứu có hai biểu hiện như vậy được mã hóa thành hai giá trị 0 và 1, được gọi là biến nhị phân.

2.4.2. Phương trình hồi quy nhị phân logistic

Thay vì chúng ta ước lượng giá trị của biến phụ thuộc Y theo biến độc lập X như ở hồi quy đa biến, thì trong hồi quy nhị phân Logistic, chúng ta sẽ ước lượng xác suất xảy ra sự kiện Y khi biết giá trị X. Biến phụ thuộc Y có hai giá trị 0 và 1, với 0 là không xảy ra sự kiện và 1 là xảy ra sự kiện. Từ đặc điểm này, chúng ta có thể đánh giá được khả năng xảy ra sự kiện (Y = 1) nếu xác suất dự đoán lớn hơn 0.5, ngược lại, khả năng không xảy ra sự kiện (Y = 0) nếu xác suất dự đoán nhỏ hơn 0.5. Ta có hàm xác suất như sau:

$$P_i = P(Y = 1) = E(Y = 1/X) = \frac{e^{(B_0+B_1X_1+B_2X_2+\cdots+B_nX_n)}}{1 + e^{(B_0+B_1X_1+B_2X_2+\cdots+B_nX_n)}}$$

Trong đó $P_i = P(Y = 1) = E(Y = 1/X)$ là xác suất xảy ra sự kiện. Thực hiện các phép chuyển đổi toán học, chúng ta thu được phương trình hồi quy nhị phân Logistic như sau:

$$\mathbf{log}_e\left[\frac{\boldsymbol{P_i}}{\mathbf{1} - \boldsymbol{P_i}}\right] = B_0 + B_1X_1 + B_2X_2 + \cdots + B_nX_n$$

Trong đó:

$\boldsymbol{P_i}$: xác suất xảy ra sự kiện (Y = 1)

$1 - \boldsymbol{P_i}$: xác suất không xảy ra sự kiện (Y = 0)

B_0: hằng số hồi quy

$B_1, B_2, \ldots, B_n$: hệ số hồi quy

BACHKHOACNCP.COM

3. Tiền xử lý số liệu

3.1 Đọc dữ liệu

Đọc dữ liệu (Import data): dirty_data.csv

Đọc dữ liệu dirty_data.csv

Code R:

```
#Đọc dữ liệu
dirty_data <- read.csv("D:/BTL_XSTK/dirty_data.csv")
View (dirty_data)

```

Hình 1 Code R đọc dữ liệu dirty_data.csv

Kết quả khi đọc dữ liệu:

	order_id	customer_id	date	nearest_warehouse	shopping_cart	order_price	delivery_charges	customer_lat	customer_long	coupon_discount	order_total	season	is_expedited_delivery
1	ORD182494	ID6197211592	2019-06-22	Thompson	[('Lucent 330S', 1), ('Thunder line', 2), ('iStream', 2), ('pearTV',...	12200	79.89	-37.81511	144.9328	10	11059.89	Winter	True
2	ORD395518	ID0282825849	2019-12-29	Thompson	[('Thunder line', 1), ('Universe Note', 2)]	9080	62.71	-37.80274	144.9511	0	9142.71	Summer	False
3	ORD494479	ID0579391891	2019-03-02	Nickolson	[('Thunder line', 1), ('pearTV', 2)]	10670	65.87	-37.82130	144.9576	10	9668.87	Autumn	False
4	ORD019224	ID4544561904	2019-01-12	Nickolson	[('Universe Note', 1), ('Alcon 10', 2), ('Olivia x460', 1), ('iAssist ...	24800	57.61	-37.81142	144.9731	15	21137.61	Summer	False
5	ORD104032	ID6231506320	2019-11-28	Nickolson	[('Universe Note', 1), ('Olivia x460', 1), ('iStream', 1), ('Toshika ...	9145	75.54	37.82386	144.9699	25	6934.29	Spring	False
6	ORD146760	ID0311654900	2019-09-16	Bakers	[('Thunder line', 2), ('Universe Note', 1)]	7810	71.22	37.82025	145.0149	10	7100.22	Spring	False
7	ORD337984	ID3394768956	2019-09-14	Thompson	[('Candle Inferno', 1), ('Alcon 10', 1), ('Toshika 750', 1)]	13700	74.84	-37.80774	144.9516	5	13089.84	Spring	False
8	ORD072312	ID0774517121	2019-05-23	Thompson	[('Universe Note', 1), ('Thunder line', 2), ('iStream', 1)]	7960	52.28	-37.80634	144.9595	5	10789.79	Autumn	False
9	ORD377837	ID4769265355	2019-10-09	Bakers	[('Alcon 10', 2), ('Thunder line', 1), ('Candle Inferno', 2), ('iAssi...	25390	107.58	-37.81081	145.0141	10	22958.58	Spring	True
10	ORD462194	ID5301568579	2019-03-21	Thompson	[('Universe Note', 1), ('Lucent 330S', 1), ('Toshika 750', 2)]	13320	62.26	-37.80868	144.9423	15	11384.26	winter	True
11	ORD034800	ID4283908179	2019-08-03	Bakers	[('Alcon 10', 2), ('pearTV', 2), ('iStream', 1), ('Olivia x460', 1)]	31895	78.25	-37.81133	145.0087	0	31973.25	Winter	True
12	ORD361636	ID0589500304	2019-12-05	Nickolson	[('Lucent 330S', 1), ('pearTV', 2)]	13850	77.29	-37.82023	144.9574	25	10464.79	Summer	False
13	ORD124395	ID0702352304	2019-02-11	Thompson	[('Alcon 10', 1), ('Universe Note', 1), ('pearTV', 1), ('iStream', 2)]	19010	94.75	-37.80543	144.9413	0	926057.25	Summer	True
14	ORD255642	ID3085953531	2019-12-24	Nickolson	[('iAssist Line', 2), ('Alcon 10', 1), ('pearTV', 1)]	19710	75.64	-37.81617	144.9753	0	19785.64	Summer	True
15	ORD496722	ID0589449820	2019-04-09	Nickolson	[('pearTV', 2), ('iStream', 1), ('Lucent 330S', 1), ('Alcon 10', 2)]	31900	79.78	-37.80946	144.9724	0	31979.78	Autumn	True
16	ORD449130	ID0356449717	2019-05-17	Bakers	[('Toshika 750', 2), ('Alcon 10', 1), ('Thunder line', 1), ('Candle ...	20200	46.35	-37.80813	144.9868	25	15196.35	Autumn	False
17	ORD036056	ID0767733196	2019-08-10	Nickolson	[('Alcon 10', 1), ('Olivia x460', 2), ('Lucent 330S', 1), ('Thunder...	14810	80.69	-37.80423	144.9717	25	11188.19	Winter	True
18	ORD428910	ID2180614753	2019-07-15	Nickolson	[('Olivia x460', 1), ('Candle Inferno', 1)]	1655	63.27	-37.81411	144.9714	25	1304.52	Winter	False
19	ORD007249	ID0767586831	2019-02-24	Nickolson	[('iAssist Line', 2), ('Candle Inferno', 2), ('Olivia x460', 1)]	6535	60.64	-37.80918	144.9729	5	6268.89	Summer	False
20	ORD232940	ID2020835025	2019-01-04	Nickolson	[('iAssist Line', 1), ('Toshika 750', 1)]	6545	77.11	-37.81492	144.9680	5	6294.86	Summer	True
21	ORD178590	ID6167441029	2019-11-20	Thompson	[('Candle Inferno', 1), ('Toshika 750', 2), ('Thunder line', 1), ('L...	13710	77.61	-37.80931	145.0186	0	13787.61	Spring	False
22	ORD157688	ID1404219802	2019-12-15	Bakers	[('Candle Inferno', 1), ('Toshika 750', 1)]	4750	73.05	-37.80282	144.9924	0	4823.05	winter	False
23	ORD314979	ID2187972536	2019-09-17	Nickolson	[('Lucent 330S', 1), ('Alcon 10', 2), ('iStream', 1), ('Universe No...	22730	63.51	-37.80960	144.9638	25	17111.01	Spring	False
24	ORD339672	ID0129952519	2019-10-07	Bakers	[('Olivia x460', 1), ('iAssist Line', 2)]	5675	73.03	-37.80698	144.9942	5	5464.28	Spring	False
25	ORD239838	ID1888086809	2019-04-07	Thompson	[('Universe Note', 2), ('Toshika 750', 1), ('pearTV', 1), ('Candle ...	18390	68.69	-37.79960	144.9605	5	17539.19	Autumn	False

Hình 2 Kết quả khi đọc dữ liệu dirty_data.csv

3.2 Làm sạch dữ liệu (Data cleaning):

Bớt biến: Tạo một dữ liệu mới chỉ gồm những biến chính mà ta quan tâm: nearest_warehouse, order_price, delivery_charges, coupon_discount, order_total, season, is_expecdited_delivery, is_happy_customer, lưu với tên là data

Code R tạo dữ liệu mới data:

```

#Tạo dữ liệu mới gồm những biến chính
data <- dirty_data[,c("nearest_warehouse","order_price","delivery_charges","coupon_discount",
                      "order_total","season","is_expedited_delivery","is_happy_customer")]

```

Hình 3 Code R tạo dữ liệu mới data

BACHKHOACNCP.COM

Kết quả khi tạo dữ liệu mới chỉ gồm những biến chính:

	nearest_warehouse	order_price	delivery_charges	coupon_discount	order_total	season	is_expedited_delivery	is_happy_customer
1	Thompson	12200	79.89	10	11059.89	Winter	True	True
2	Thompson	9080	62.71	0	9142.71	Summer	False	False
3	Nickolson	10670	65.87	10	9668.87	Autumn	False	True
4	Nickolson	24800	57.61	15	21137.61	Summer	False	False
5	Nickolson	9145	75.54	25	6934.29	Spring	False	True
6	Bakers	7810	71.22	10	7100.22	Spring	False	False
7	Thompson	13700	74.84	5	13089.84	Spring	False	True
8	Thompson	7960	52.28	5	10789.79	Autumn	False	False
9	Bakers	25390	107.58	10	22958.58	Spring	True	True
10	Thompson	13320	62.26	15	11384.26	winter	True	False
11	Bakers	31895	78.25	0	31973.25	Winter	True	True
12	Nickolson	13850	77.29	25	10464.79	Summer	False	True
13	Thompson	19010	94.75	0	926057.25	Summer	True	True
14	Nickolson	19710	75.64	0	19785.64	Summer	True	False
15	Nickolson	31900	79.78	0	31979.78	Autumn	True	True

Showing 1 to 15 of 500 entries, 8 total columns

Hình 4 Kết quả khi tạo dữ liệu mới chỉ gồm những biến chính

3.3 Kiểm tra dữ liệu khuyết

Kiểm tra dữ liệu khuyết trong new_data

Code R kiểm tra dữ liệu khuyết theo cột:

```
#Kiểm tra dữ liệu khuyết
colSums(is.na(data))
```

Kết quả khi kiểm tra dữ liệu khuyết như sau:

```
> #Kiểm tra dữ liệu khuyết
> colSums(is.na(new_data))
    nearest_warehouse           order_price      delivery_charges       coupon_discount           order_total
                    0                     0                     0                     0                     0
               season  is_expedited_delivery     is_happy_customer
                    0                     0                     0
```

Nhận xét: Dựa vào kết quả trên, ta thấy tất cả các cột đều không chứa dữ liệu khuyết (NA) nên ta kết luận tập dữ liệu không chứa dữ liệu khuyết.

Code R kiểm tra xem các dữ liệu trong biến có bị sai cần định dạng, xử lý:

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
#Kiểm tra xem các dữ liệu trong biến có bị sai cần định dạng, chuyển đổi
unique(data$nearest_warehouse)
unique(data$season)
unique(data$is_expedited_delivery)
unique(data$is_happy_customer)
```

Hình 5 Code R kiểm tra xem các dữ liệu trong biến có bị sai cần định dạng, xử lý

Kết quả khi dữ liệu đã được kiểm tra:

```
> #Kiểm tra xem các dữ liệu trong biến có bị sai cần xử lý
> unique(data$nearest_warehouse)
[1] "Thompson"  "Nickolson" "Bakers"    "nickolson" "thompson"
> unique(data$season)
[1] "Winter" "Summer" "Autumn" "Spring" "winter" "spring" "autumn" "summer"
> unique(data$is_expedited_delivery)
[1] "True"  "False"
> unique(data$is_happy_customer)
[1] "True"  "False"
>
```

Hình 6 Kết quả khi dữ liệu đã được kiểm tra có bị sai cần định dạng, xử lý

Nhận xét:

Ở biến nearest_warehouse có 2 loại dữ liệu cần xử lý đó chính là “nickolson” và “thompson” vì bị thiếu chữ viết hoa đầu dòng nên khi thống kê sẽ bị thiếu 1 vài trường hợp.

Ở biến season có 4 loại dữ liệu cần xử lý đó là “spring”, “summer”, “autumn”, “winter”.

3.4 Xử lý định dạng dữ liệu

Kiểm tra xem các dữ liệu trong biến có bị sai cú pháp, cần xử lý hay không.

Code R xử lý các dữ liệu bị sai:

```
#Tạo dữ liệu mới new_data
new_data <- data
#Xử lý thay thompson thành Thompson, và thay nickolson thành Nickolson
new_data$nearest_warehouse[data$nearest_warehouse == 'thompson'] = 'Thompson'
new_data$nearest_warehouse[data$nearest_warehouse == 'nickolson'] = 'Nickolson'
#Xử lý thay spring thành Spring,...
new_data$season[new_data$season == 'spring'] = 'Spring'
new_data$season[new_data$season == 'summer'] = 'Summer'
new_data$season[new_data$season == 'autumn'] = 'Autumn'
new_data$season[new_data$season == 'winter'] = 'Winter'
```

Hình 7 Code R xử lý các dữ liệu bị sai

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

3.5 Chuyển đổi biến

Chuyển các số liệu từ biến is_expedited_delivery và is_happy_customer từ dạng character (ký tự) sang dạng numeric (số) để dễ khảo sát, thống kê hơn.

Code R chuyển đổi các biến từ ký tự sang số:

```
#Chuyển đổi số liệu từ ký tự sang số
new_data$is_expedited_delivery[new_data$is_expedited_delivery == "False"] = "0"
new_data$is_expedited_delivery[new_data$is_expedited_delivery == "True"] = "1"
new_data$is_happy_customer[new_data$is_happy_customer == "False"] = "0"
new_data$is_happy_customer[new_data$is_happy_customer == "True"] = "1"
#Chuyển đổi các giá trị ở 2 biến is_expedited_delivery, is_happy_customer về dạng numeric
new_data$is_expedited_delivery<-as.numeric(new_data$is_expedited_delivery)
new_data$is_happy_customer<-as.numeric(new_data$is_happy_customer)
View (new_data$count) #Kiểm tra bảng dữ liệu new_data đã được chuyển đổi
```

Hình 8 Code R chuyển đổi các biến từ ký tự sang số

Kết quả khi dữ liệu đã được định dạng, xử lý:

```
> #Kiểm tra lại xem các dữ liệu trong biến đã được định dạng, chuyển đổi hay chưa
> unique(new_data$nearest_warehouse)
[1] "Thompson"  "Nickolson" "Bakers"
> unique(new_data$season)
[1] "Winter" "Summer" "Autumn" "Spring"
> unique(new_data$is_expedited_delivery)
[1] 1 0
> unique(new_data$is_happy_customer)
[1] 1 0
>
```

Hình 9 Kết quả khi dữ liệu đã được định dạng, xử lý

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Tính lại dữ liệu biến và thay thế, tránh những sai sót có thể xảy ra:

Như hình dưới, ở hàng 13, cột order_total đã bị sai giá trị, kết quả phải là 19104.75

Công thức: Order_total = order_price * (1 - coupon_discount / 100) + delivery_charges.

	nearest_warehouse	order_price	delivery_charges	coupon_discount	order_total
13	Thompson	19010	94.75	0	926057.25

Hình 10 Ví dụ về sai dữ liệu biến

Code R tính lại và thay thế toàn bộ biến total_price:

```
# Thay thế cột total_price bị sai
# Chọn cột cần chuyển đổi
cols_to_convert <- c("order_price", "coupon_discount", "delivery_charges")
# Chuyển đổi các cột được chọn sang kiểu số
new_data[, cols_to_convert] <- lapply(new_data[, cols_to_convert], as.numeric)
# Tính toán giá trị mới cho cột order_total
new_data$order_total <- new_data$order_price * (1 - new_data$coupon_discount / 100) + new_data$delivery_charges
# Hiển thị dữ liệu
View(new_data)
```

Hình 11 Code R tính lại và thay thế toàn bộ biến total_price

BACHKHOACNCP.COM

Kết quả khi dữ liệu đã được tính lại và thay thế:

	nearest_warehouse	order_price	delivery_charges	coupon_discount	order_total	season	is_expedited_delivery	is_happy_customer
13	Thompson	19010	94.75	0	19104.75	Summer	1	1
14	Nickolson	19710	75.64	0	19785.64	Summer	1	0
15	Nickolson	31900	79.78	0	31979.78	Autumn	1	1
16	Bakers	20200	46.35	25	15196.35	Autumn	0	0
17	Nickolson	14810	80.69	25	11188.19	Winter	1	1
18	Nickolson	1655	63.27	25	1304.52	Winter	0	1
19	Nickolson	6535	60.64	5	6268.89	Summer	0	0
20	Nickolson	6545	77.11	5	6294.86	Summer	1	0
21	Thompson	13710	77.61	0	13787.61	Spring	0	1
22	Bakers	4750	73.05	0	4823.05	Winter	0	1
23	Nickolson	22730	63.51	25	17111.01	Spring	0	0
24	Bakers	5675	73.03	5	5464.28	Spring	0	1
25	Thompson	18390	68.69	5	17539.19	Autumn	0	1
26	Bakers	2910	91.48	25	2273.98	Spring	1	0
27	Bakers	22490	105.04	10	20346.04	Summer	1	1

Showing 12 to 27 of 500 entries, 8 total columns

Hình 12 Kết quả khi dữ liệu đã được tính lại và thay thế biến total_price

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

4. Thống kê tả

Là các phương pháp sử dụng để tóm tắt hoặc mô tả một tập hợp dữ liệu, một mẫu nghiên cứu dưới dạng số hay biểu đồ trực quan.

4.1 Biểu đồ phân bố Histogram

Xét delivery_charges.

Tóm tắt dữ liệu:

```
> summary(delivery_charges)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
  46.35   65.98   76.31   76.66   82.56  114.04 
> #Độ lệch chuẩn
> sd(delivery_charges)
[1] 14.48146
```

Hình 13 Tóm tắt dữ liệu delivery_charges

Vẽ bảng:

```
delivery_charges
 46.35  46.73  46.89  48.55  48.71  48.99  49.88  50.05  50.65  51.04   51.2  51.82  51.84  52.04  52.12  52.14   52.2  52.28
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      2      1
  52.6  52.69  52.84  52.87  52.92  53.47   53.8  53.95  55.54  55.62  55.71  55.98  56.17   56.5  57.61  57.82  57.93  58.15
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
 58.19  58.32  58.37  58.59  58.61  58.96   59.2  59.68   59.7  59.86  60.61  60.64  60.84  61.09  61.44  61.59  61.64  61.75
     1      1      1      1      1      1      1      1      1      1      1      2      1      1      1      1      1      1
 62.26  62.29   62.3  62.41  62.55  62.56  62.58  62.63  62.65   62.7  62.71  62.73   62.8  62.82  62.93  62.95  63.01  63.08
     1      1      1      1      1      1      1      1      1      1      1      1      1      2      1      1      1      1
 63.11  63.27   63.3  63.51  63.58  63.64  63.68  63.75   63.9  63.92  63.97  64.03  64.09  64.19  64.23  64.27   64.3  64.53
     2      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
 64.61  64.62  64.75  64.76  64.78  64.79  64.81  64.96  64.98  65.06  65.07  65.27  65.28  65.32  65.36  65.39  65.44  65.47
     1      1      1      1      2      1      2      1      1      1      2      1      1      1      1      1      1      1
  65.5   65.7  65.72  65.82  65.84  65.85  65.87   65.9  66.01  66.04  66.07  66.09  66.11  66.13  66.15  66.16  66.18  66.21
     2      2      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
 66.23  66.24  66.28  66.33   66.4  66.41  66.49  66.52  66.54  66.68   66.7  66.73  66.79  66.84  66.86   66.9  66.95  66.96
     1      1      1      1      2      1      1      1      1      1      2      1      1      1      1      1      1      1
    67  67.01  67.12  67.15  67.26  67.47  67.54  67.67  67.75  67.79   67.8  67.96  68.01  68.05  68.12  68.24   68.3  68.49
     1      1      1      1      1      2      1      1      1      1      1      1      1      1      1      1      1      1
 68.51  68.55  68.69  68.83  68.86  69.11  69.62  69.64  69.68  70.01  70.02  70.09  70.38  70.74  71.22  71.27  71.34  71.61
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
 71.64  71.66  71.89  72.01  72.28  72.31  72.41  72.47  72.67  72.75  72.82  72.88  73.03  73.05  73.11  73.14  73.19   73.2
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
 73.33  73.36   73.4  73.43  73.58  73.65  73.73  73.85  74.08  74.12  74.21   74.5  74.52  74.75  74.79  74.84  75.04  75.06
     1      1      1      1      1      1      1      2      1      1      2      2      1      1      1      1      1      1
 75.12  75.22  75.28  75.37  75.39  75.41  75.42  75.54  75.64   75.7  75.78  75.91  75.92  75.93  75.96  76.14  76.29  76.33
     1      1      1      1      1      1      1      2      1      1      1      1      1      1      1      2      1      1
 76.34  76.36  76.41  76.48  76.53  76.56  76.68  76.73  76.77  76.79  76.82  76.85  76.86  76.93  76.98  77.02  77.06  77.07
     1      1      1      1      1      1      1      1      1      2      1      1      1      1      2      1      1      1
 77.09  77.11  77.13  77.17  77.18  77.22  77.24  77.29   77.3  77.33   77.5  77.51  77.52   77.6  77.61  77.64  77.74   77.8
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      2
 77.82  77.85  77.98  78.02  78.08  78.11  78.13  78.24  78.25  78.28   78.3  78.33  78.46  78.54  78.59  78.69  78.72  78.81
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
 78.85  78.91  78.96  79.05  79.06  79.09  79.13  79.18  79.19  79.25  79.28  79.35  79.39  79.46  79.49   79.5  79.71  79.74
     1      1      1      1      1      1      2      1      1      1      1      1      1      1      2      1      1      1
 79.78  79.79  79.87  79.89  79.91  79.92  79.94  79.95  79.98  80.02  80.04  80.23  80.31  80.44  80.46  80.48  80.49  80.53
     1      1      1      2      1      2      1      1      1      1      1      1      1      1      1      1      1      1
 80.56  80.66  80.69   80.7  80.72  80.74  80.75   80.9  80.93  81.31  81.36  81.45  81.55   81.6  81.66   81.7  81.84  81.95
     1      1      2      1      1      1      1      1      1      1      1      1      1      1      1      2      1      1
```

Hình 14 Vẽ bảng delivery_charges (1)

BACHKHOACNCP.COM

```
 82.27  82.33  82.37  82.39  82.44  82.48  82.78  82.93     83  83.03  83.23  83.26  83.28  83.45  83.97  83.99  84.08  84.54
     1      1      2      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
 84.86  84.92  85.06  85.48  85.53  85.63   85.9  87.01  87.31  87.54  87.61  87.96  88.17  88.33  88.45  88.87  89.45  90.62
     1      1      1      2      1      1      1      1      1      1      1      2      1      1      1      1      1      1
 90.66  90.82  91.08  91.19  91.34  91.46  91.48  91.54  91.79  92.62   92.7    92.9  92.94  93.09  93.52   93.7  93.93  94.11
     1      1      1      1      1      1      1      1      2      1      1      1      1      1      1      1      1      1
 94.13  94.19    94.3  94.56  94.73  94.75  95.22  95.71     96  96.49  96.56  96.69   97.3  97.32  97.76   98.3  98.37  98.48
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
  98.5  98.58  98.73  99.42  99.58  99.76 100.36 100.55 100.72 100.74 100.79 101.06  101.2 101.29 101.65 101.84 102.31 102.58
     1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1      1
102.69 102.72 102.82 102.89 103.11 103.41  103.7 103.77 104.42 104.49 104.71 105.04  105.1 105.47 105.86  106.1 106.26 106.46
     1      1      1      1      1      1      2      1      1      1      1      1      1      1      1      1      1      1
106.98 107.18 107.35 107.36 107.48 107.58 108.54 108.57 108.58 108.87 108.92 110.17  110.2 110.36 112.04 112.42 113.83 114.04
     1      1      1      1      1      1      1      1      2      1      1      1      1      1      1      1      1      1
```

Hình 15 Vẽ bảng delivery_charges (2)

Vẽ biểu đồ phân bố:

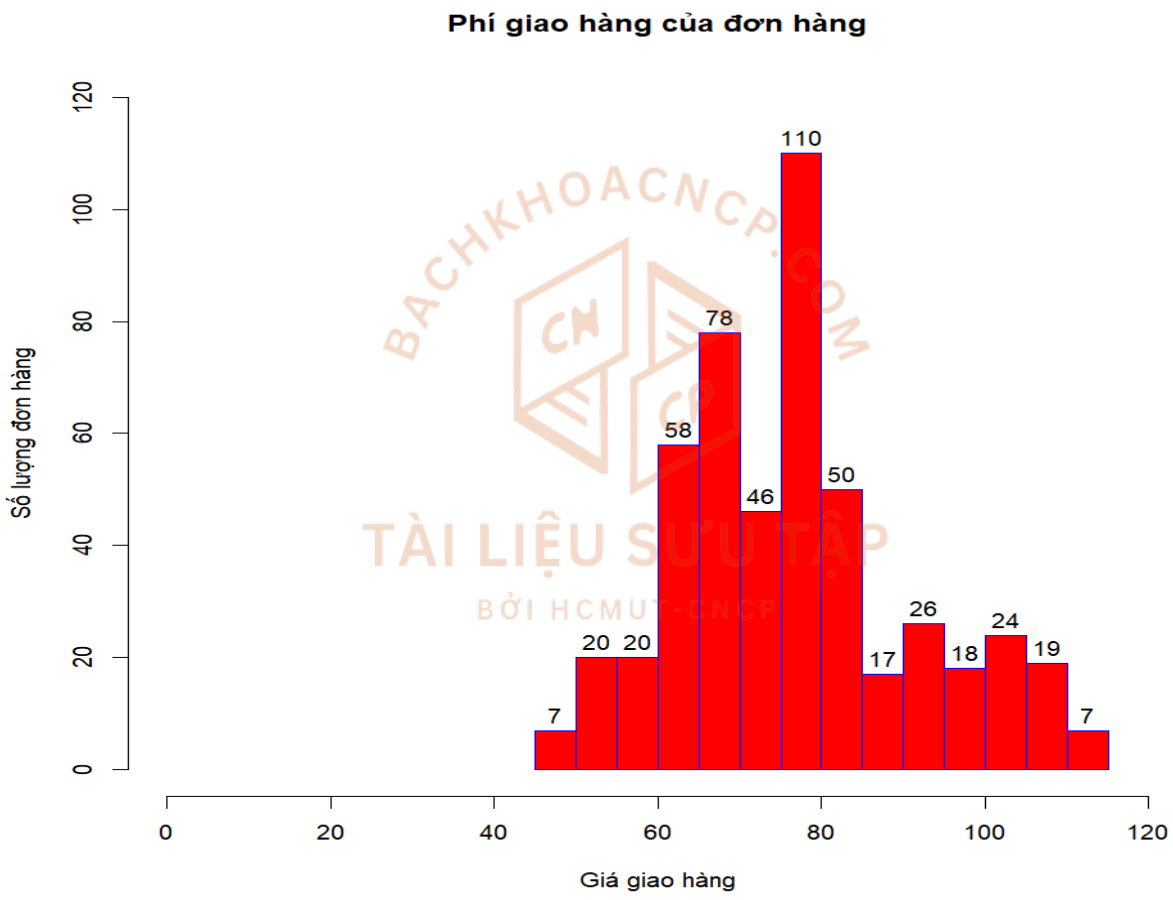

Hình 16 Biểu đồ phân bố biến delivery_charges

Nhận xét:

Phí giao hàng từ 75 đến 80 có số đơn hàng nhiều nhất, kế đến là từ 65 đến 70 có đơn hàng nhiều thứ 2. Đây là biểu đồ phân bố hai đỉnh.

4.2 Biểu đồ bánh pie chart

Xét biến neareast_warehouse

BACHKHOACNCP.COM

Vẽ bảng:

```
nearest_warehouse
   Bakers Nickolson  Thompson
      119       184       197
```

Hình 17 Vẽ bảng biến neareast_warehouse

Vẽ biểu đồ:

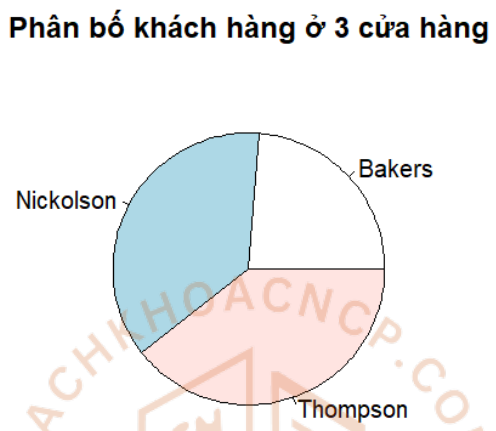

Hình 18 Vẽ biểu đồ biến neareast_warehouse

Nhận xét: Số lượng khách hàng của cửa hàng Thompson là nhiều nhất, ít nhất là của hàng Bakers.

4.3 Biểu đồ cho hai biến rời rạc

Xét hai biến is_happy_customer và nearest_warehouse, xem xét tỉ lệ hài lòng của khách hàng ở 3 cửa hàng

Vẽ bảng:

```
                   nearest_warehouse
is_happy_customer Bakers Nickolson Thompson
                0     39        47       55
                1     80       137      142
```

Hình 19 Vẽ bảng hai biến is_happy_customer và nearest_warehouse

Vẽ biểu đồ:

BACHKHOACNCP.COM

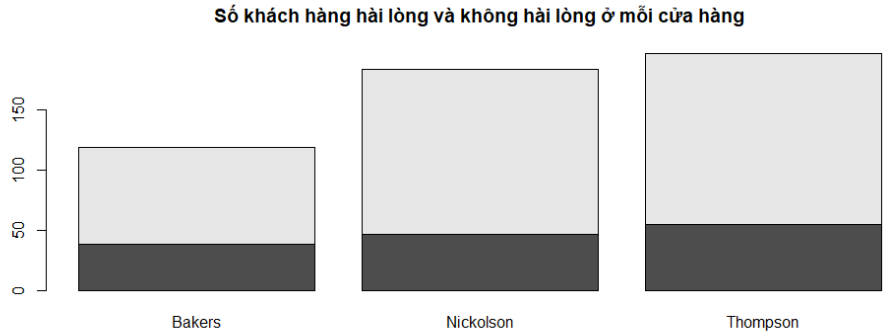

Hình 20 Vẽ biểu đồ hai biến is_happy_customer và nearest_warehouse

Nhận xét: Đa phần khách hàng đều hài lòng khi mua sản phẩm ở ba cửa hàng.

4.4 Biểu đồ tán xạ scatter plot

Xét mối liên hệ giữa hai biến delivery_charges và order_total.

Trục hoành là delivery_charges và trục tung là order_total.

Ta sử dụng thêm biến phân loại để phân tích sự hài lòng của khách hàng (is_ is_happy_customer), hình vuông thể hiện khách hàng không hài lòng, hình tròn thể hiện khách hàng hài lòng.

Vẽ biểu đồ:

TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

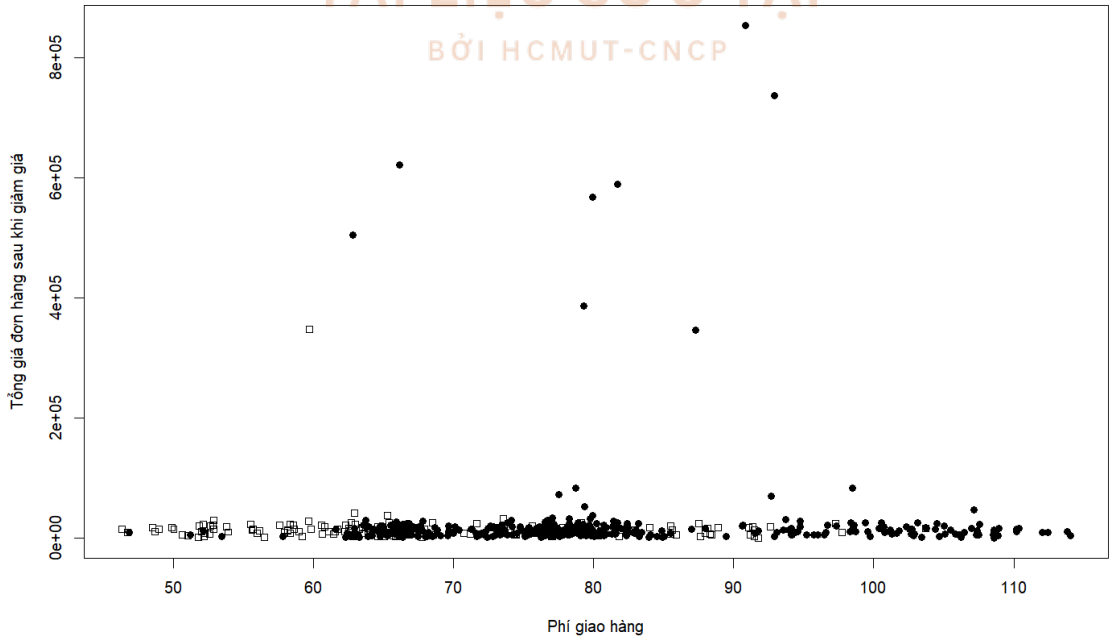

Hình 21 Vẽ biểu đồ tán xạ ba biến delivery_charges, order_total và is_happy_customer trước khi lọc điểm ngoại lai

BACHKHOACNCP.COM

Nhận xét: Có nhiều điểm ngoại lai của biến order_total khiến biểu đồ khó thấy, tuy nhiên ta vẫn thấy được với mức phí giao hàng từ khoảng 62 AUD đến khoảng 71 AUD và từ khoảng 71 AUD đến khoảng 82 AUD có phân bố đơn hàng nhiều nhất.

Lọc điểm ngoại lai (theo order_total):

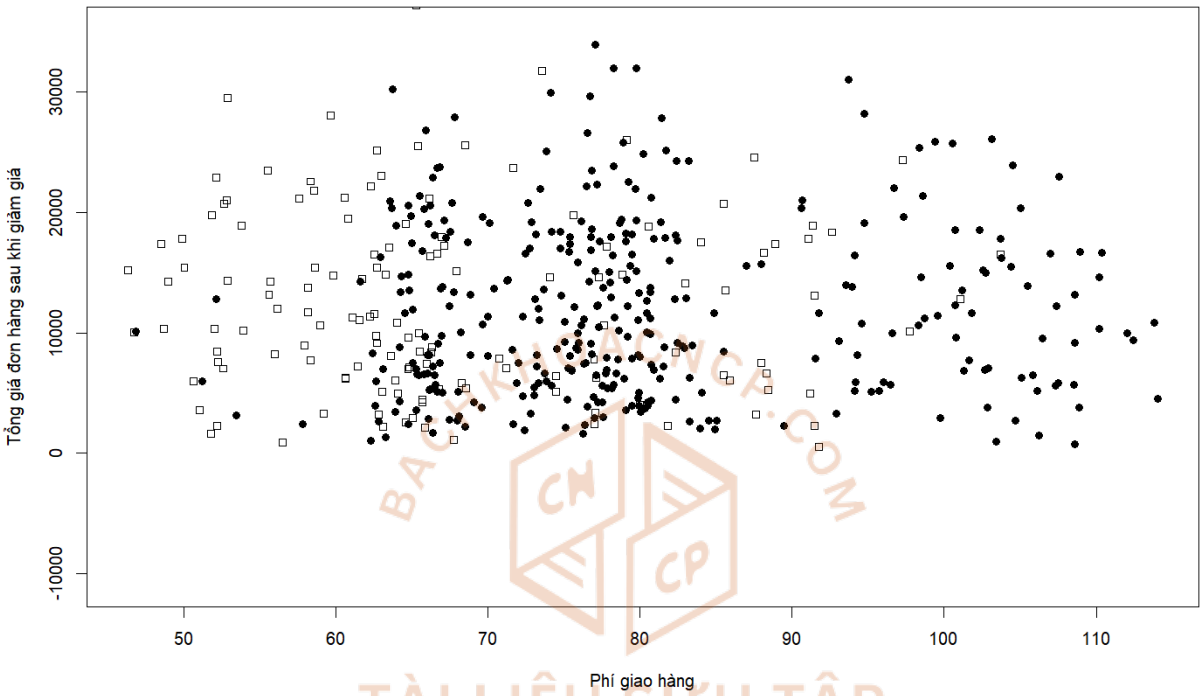

Hình 22 Vẽ biểu đồ tán xạ ba biến delivery_charges, order_total và is_happy_customer sau khi lọc điểm ngoại lai

TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Nhận xét: Với tổng giá trị đơn hàng giống nhau, các khách hàng có xu hướng hài lòng. Khách hàng không hài lòng phân bố nhiều ở khoảng 50 AUD đến 60 AUD (theo phí giao hàng). Theo biểu đồ, ta có thể kết luận, chi phí giao hàng hơn 60 AUD đến khoảng 80 AUD, sẽ cho khách hàng trải nghiệm tốt và hài lòng nhiều nhất.

4.5 Biểu đồ hộp box plot

Vẽ biểu đồ box plot giữa 2 biến order_total và nearest_warehouse

BACHKHOACNCP.COM

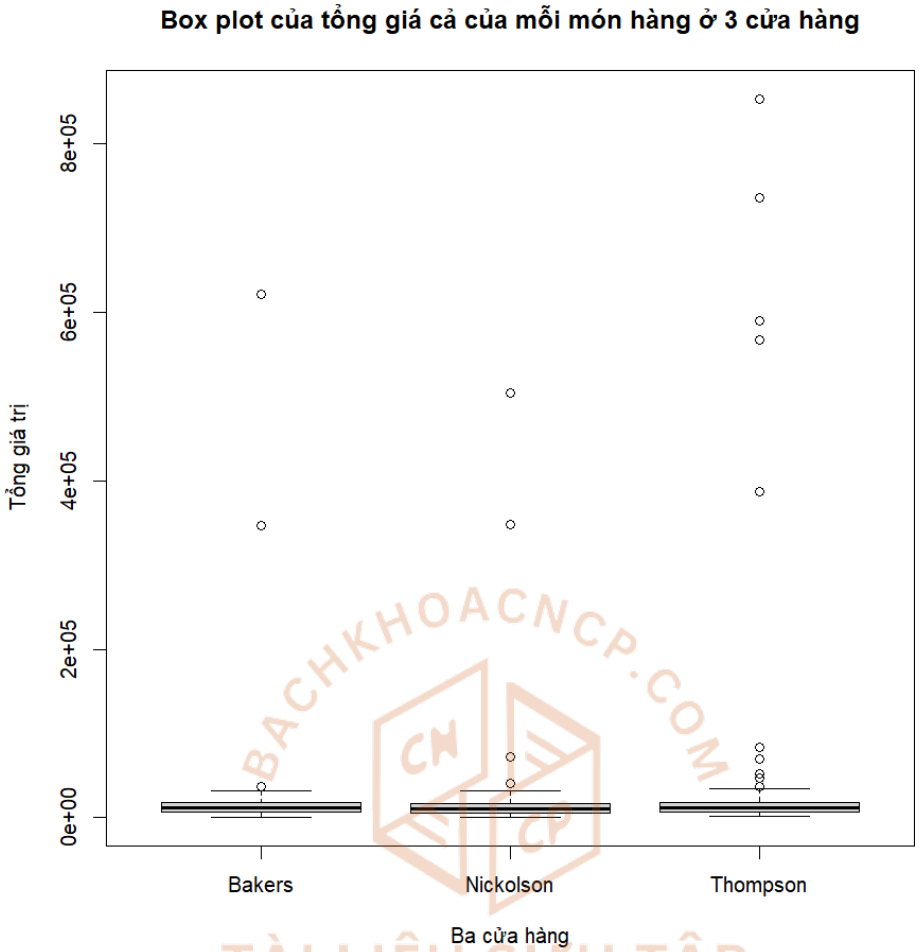

Hình 23 Biểu đồ Box plot giữa 2 biến order_total và nearest_warehouse

Nhận xét: có nhiều điểm ngoại lai khiến ta không thể thấy rõ được phân phối, cần xử lý lại số liệu

Các thông số đặc trưng của biến order_total ở ba cửa hàng trước khi lọc ngoại lai

```
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
1482    6643   11662   29277   18078  853013
```

Hình 24: Các thông số đặc trưng của biến order_total ở cửa hàng Thompson trước khi lọc ngoại lai

```
  Min.   1st Qu.   Median     Mean  3rd Qu.     Max.
 765.6    5652.3  10627.2  16774.8  17373.1 504686.8
```

Hình 25 Các thông số đặc trưng của biến order_total ở cửa hàng Nickolson trước khi lọc ngoại lai

```
  Min.   1st Qu.   Median     Mean  3rd Qu.     Max.
 530.5    6526.1  11613.9  20404.1  17623.7 621327.2
```

Hình 26 Các thông số đặc trưng của biến order_total ở cửa hàng Bakers trước khi lọc ngoại lai

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BOI HCMUT-CNCP
BACHKHOACNCP.COM

Độ lệch chuẩn của biến order_total ở ba cửa hàng trước khi lọc ngoại lai

```
> sd(TH_Thompson_ordertotal)
[1] 100539.5
```

Hình 27 Độ lệch chuẩn của biến order_total ở cửa hàng Thompson trước khi lọc ngoại lai

```
> sd(TH_Nickolson_ordertotal)
[1] 44711.67
```

Hình 28 Độ lệch chuẩn của biến order_total ở cửa hàng Nickolson trước khi lọc ngoại lai

```
> sd(TH_Bakers_ordertotal)
[1] 63893.17
```

Hình 29 Độ lệch chuẩn của biến order_total ở cửa hàng Bakers trước khi lọc ngoại lai

Sau khi xử lý điểm ngoại lai, ta có biểu đồ như sau:

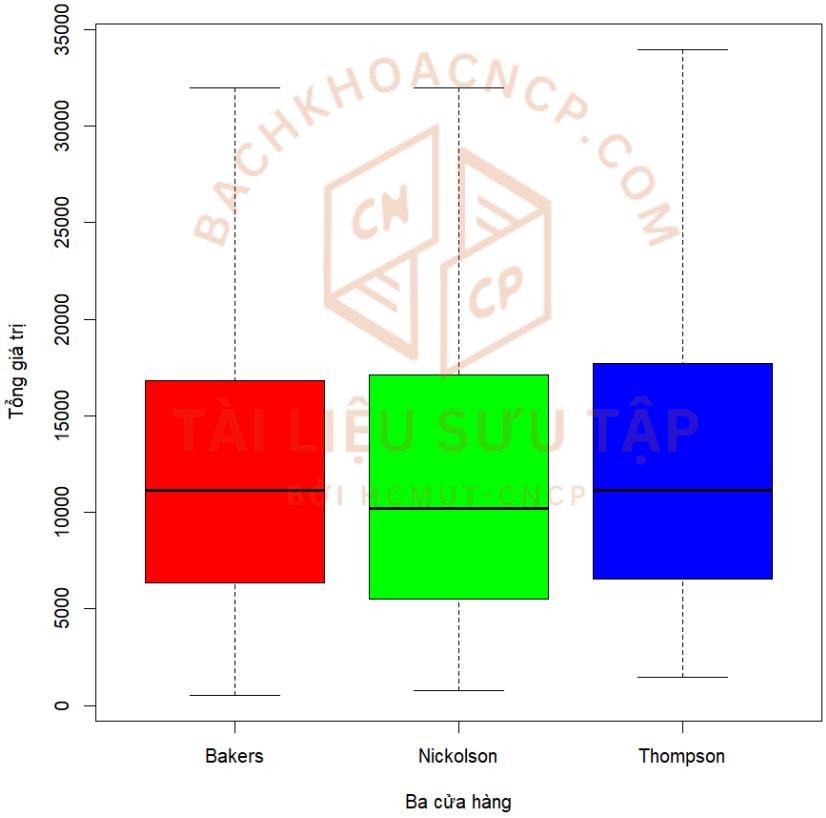

Hình 30 Biểu đồ Box plot giữa 2 biến order_total và nearest_warehouse sau khi xử lí điểm ngoại lai

Nhận xét: Nhìn vào biểu đồ box plot của 3 cửa hàng, ta có nhận xét sau:

Trong ba biểu đồ này, chúng ta thấy trung vị của order_total ở cửa hàng Nickolson thấp nhất, nhưng độ dao động giữa ba cửa hàng không khác nhau bao nhiêu, và đều lớn hơn 10.000AUD và nhỏ hơn 12.000 AUD.

BACHKHOACNCP.COM

Giá trị đơn hàng nhỏ nhất của 3 cửa hàng không quá khác nhau, tổng giá trị đơn hàng nhỏ nhất cửa hàng Thompson lớn nhất trong ba cửa hàng.

25% tổng số đơn hàng của cửa hàng Bankers, 25% tổng số đơn hàng của cửa hàng Nickolson, 25% tổng số đơn hàng của cửa hàng Thompson đều dưới 7500 AUD và hơn 5000 AUD.

75% tổng số đơn hàng của cửa hàng Bankers, 75% tổng số đơn hàng của cửa hàng Nickolson, 75% tổng số đơn hàng của cửa hàng Thompson đều dưới 20.000 AUD và hơn 15.000 AUD.

Tổng giá trị cao nhất của 1 đơn hàng từ cửa hàng Bakers là khoảng 32.000 AUD, thấp nhất của 1 đơn hàng là khoảng 500 AUD.

Tổng giá trị cao nhất của 1 đơn hàng từ cửa hàng Nickolson là khoảng 32.000 AUD, thấp nhất của 1 đơn hàng là khoảng 0 AUD.

Tổng giá trị cao nhất của 1 đơn hàng từ cửa hàng Thompson là khoảng 34.000 AUD, thấp nhất của 1 đơn hàng là khoảng 1500 AUD.

Kiểm tra các thông số đặc trưng của biến order_total ở 3 cửa hàng sau khi lọc ngoại lai

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1482    6568   11133   12148   17650   33947
```

Hình 31 Các thông số đặc trưng của biến order_total ở cửa hàng Thompson sau khi lọc ngoại lai

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  765.6  5571.0 10199.5 11777.5 17118.7 31979.8
```

Hình 32 Các thông số đặc trưng của biến order_total ở cửa hàng Nickolson sau khi lọc ngoại lai

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  530.5  6443.5 11165.6 12268.6 16824.1 31973.2
```

Hình 33 Các thông số đặc trưng của biến order_total ở cửa hàng Bakers sau khi lọc ngoại lai

Độ lệch chuẩn của biến order_total ở ba cửa hàng sau khi lọc ngoại lai

```
> sd(TH_Thompson_ordertotal_xuly)
[1] 6732.951
```

Hình 34 Độ lệch chuẩn của biến order_total ở cửa hàng Thompson sau khi lọc ngoại lai

```
> sd(TH_Nickolson_ordertotal_xuly)
[1] 7390.206
```

Hình 35 Độ lệch chuẩn của biến order_total ở cửa hàng Nickolson sau khi lọc ngoại lai

```
> sd(TH_Bakers_ordertotal_xuly)
[1] 7448.77
```

Hình 36 Độ lệch chuẩn của biến order_total ở cửa hàng Bakers sau khi lọc ngoại lai

BACHKHOACNCP.COM

5. Thống kê suy diễn

5.1 Tìm khoảng tin cậy.

Đặt vấn đề: Tìm khoảng tin cậy về giá đơn hàng (biến order_price) của các nhà kho.

Giải quyết:

Chúng ta chọn 1 mẫu gồm 150 đơn hàng bất kì. Dựa trên thông tin về giá các đơn hàng của 150 mẫu này từ đó tìm ra khoảng tin cậy về giá.

Thực hiện trên R:

```
> set.seed(123)
> mau_order_price=sample(1:500,150,replace = TRUE)
> t.test(mau_order_price,conf.level=0.95)
```

Hình 37 Code R bài toán tìm khoảng tin cậy

Kết quả sau khi thực hiện:

```
        One Sample t-test

data:  mau_order_price
t = 21.002, df = 149, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 224.5216 271.1584
sample estimates:
mean of x
   247.84
```

Hình 38 Kết quả sau khi thực hiện trên R của bài toán tìm khoảng tin cậy

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Dựa vào kết quả ở "One Sample t-test", khoảng tin cậy về giá của các đơn hàng là [224.5216; 271.1584] với độ tin cậy là 95%.

5.2 Kiểm định hai mẫu.

Đặt vấn đề: So sánh mã giảm giá trung bình (coupon_discount) của 1 đơn hàng giữa hài lòng (True) và không hài lòng (False). Kết luận với myn 5%. Giả thuyết các mức mã giảm giá đều theo phân phối chuẩn.

Nhận xét:

Giả thuyết H_0: Mã giảm giá trung bình của 1 đơn hàng hài lòng bằng với đơn hàng không hài lòng.

Giả thuyết đối H_1: Mã giảm giá trung bình của 1 đơn hàng hài lòng khác với đơn hàng không hài lòng.

Thực hiện trên R:

BACHKHOACNCP.COM

```
#Chuyển dổi giá trị ở biến is_happy_customer về dạng characters
new_data$is_happy_customer[new_data$is_happy_customer == "0"] = "False"
new_data$is_happy_customer[new_data$is_happy_customer == "1"] = "True"
#Kiểm định 2 mẫu
t.test(new_data$coupon_discount ~ new_data$is_happy_customer, mu=0,
       alt="two.sided",conf=0.95, var.eq=F, paired=F)
```

Hình 39 Thực hiện trên R của bài toán kiểm định 2 mẫu

Kết quả sau khi thực hiện:

```
        Welch Two Sample t-test

data:  new_data$coupon_discount by new_data$is_happy_customer
t = 1.1292, df = 249.49, p-value = 0.2599
alternative hypothesis: true difference in means between group False and group True is not equal to 0
95 percent confidence interval:
 -0.7314987  2.6973613
sample estimates:
mean in group False  mean in group True
           11.59574            10.61281

>
```

Hình 40 Kết quả sau khi thực hiện trên R của bài toán kiểm định 2 mẫu

Giải thích:

```
t = 1.1292, df = 249.49, p-value = 0.2599
```

Hình 41 Giải thích kết quả bài toán kiểm định hai mẫu sau khi thực hiện trên R (1)

Trị số p = 0.2599 cho thấy mức độ khác biệt giữa hai nhóm hài lòng (True) và không hài lòng (False) không có ý nghĩa thống kê (vì cao hơn 0.05 hay 5%).

```
95 percent confidence interval:
 -0.7314987  2.6973613
```

Hình 42 Giải thích kết quả bài toán kiểm định hai mẫu sau khi thực hiện trên R (2)

Là khoảng tin cậy 95% về độ khác biệt giữa hai nhóm. Kết quả tính toán trên cho biết mã giảm giá ở nhóm không hài lòng có thể thấp hơn nhóm hài lòng 0,7314987 hoặc cao hơn nhóm hài lòng khoảng 2,6973613.

Kết luận: Vì p-value = 0.2599 > mức ý nghĩa 5% nên ta chưa bác bỏ được giả thuyết H_0. Vì vậy mã giảm giá trung bình của 1 đơn hàng hài lòng bằng với đơn hàng không hài lòng.

5.3 Mô hình ANOVA (Phân tích phương sai 2 nhân tố)

Đặt vấn đề: So sánh trung bình về chi phí đặt hàng của khách hàng ở 3 kho hàng trong 4 mùa.

Kiểm tra giả định:

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP

Chi phí đặt hàng ở các kho hàng trong các mùa tuân theo phân phối chuẩn:

```
season<-as.factor(dirty_data$season)
warehouse<-as.factor(dirty_data$nearest_warehouse)
total<-dirty_data$order_total
```

Hình 43 Chi phí đặt hàng ở các kho hàng trong các mùa tuân theo phân phối chuẩn

Kiểm tra theo phương pháp Shapiro- Wilk test:

```
library(nortest)
av_residual<-rstandard(aov(total~season*warehouse))
shapiro.test(av_residual)
```

Hình 44 Kiểm tra theo phương pháp Shapiro- Wilk test (1)

```
        Shapiro-Wilk normality test

data:  av_residual
W = 0.15813, p-value < 2.2e-16
```

Hình 45 Kiểm tra theo phương pháp Shapiro- Wilk test (2)

Giá trị p-value bé hơn rất nhiều so với mức ý nghĩa 5%, nên ta có thể đưa ra kết luận là chi phí đặt hàng ở các kho hàng trong các mùa không theo phân phối chuẩn.

Chi phí đặt hàng ở các kho hàng trong các mùa có phương sai đồng nhất:

```
library(car)
leveneTest(total~season*warehouse, data=dirty_data)
```

Hình 46 Phương sai chi phí đặt hàng ở các kho hàng trong các mùa (1)

```
Levene's Test for Homogeneity of Variance (center = median)
       Df F value Pr(>F)
group  21   1.127 0.3151
      478
```

Hình 47 Phương sai chi phí đặt hàng ở các kho hàng trong các mùa (2)

Nhận xét:

Giả thuyết 1: Phương sai chi phí đặt hàng ở 3 kho hàng trong 4 mùa bằng nhau.

Giả thuyết 2: Có ít nhất 1 kho hàng trong 1 mùa bất kì có phương sai khác so với các đối tượng còn lại.

Vì p-value = 0.3151 > mức ý nghĩa 5% nên ta chưa bác bỏ được giả thuyết 1. Vì vậy phương sai chi phí đặt hàng ở 3 kho hàng trong 4 mùa bằng nhau.

Phân tích phương sai 2 yếu tố:

BACHKHOACNCP.COM

```
av2<-aov(total~season*warehouse, data=dirty_data)
summary(av2)
```

Hình 48 Phân tích phương sai 2 yếu tố (1)

```
                  Df    Sum Sq   Mean Sq F value Pr(>F)
season             7 4.758e+11 6.796e+10   0.908  0.500
warehouse          4 3.396e+11 8.490e+10   1.135  0.339
season:warehouse  10 9.327e+11 9.327e+10   1.246  0.259
Residuals        478 3.577e+13 7.483e+10
```

Hình 49 Phân tích phương sai 2 yếu tố (2)

Nhận xét:

Giả thuyết 1: Chi phí đặt hàng trung bình ở 3 kho hàng trong 4 mùa bằng nhau.

Giả thuyết 2: Có ít nhất 1 kho hàng trong 1 mùa bất kì có chi phí đặt hàng trung bình khác so với các đối tượng còn lại.

Vì tất cả p-value đều lớn hơn mức ý nghĩa 5% nên ta chưa bác bỏ được giả thuyết 1. Vì vậy chi phí đặt hàng ở 3 kho hàng trong 4 mùa bằng nhau.

5.4 Mô hình hồi quy logistic

Đặt vấn đề: Kiểm tra sự phụ thuộc của độ hài lòng qua các phiếu giảm giá lẫn tổng số tiền

Tạo tập tin mới phân tích sau khi làm sạch dữ liệu:

```
new_data_3<-new_data[,c("nearest_warehouse","coupon_discount","order_total","season","is_expedited_delivery","is_happy_customer")]
head(new_data_3,100)
```

Hình 50 Code R tạo tập tin mới phân tích sau khi làm sạch dữ liệu của bài toán hồi quy đa biến

Chia bộ dữ liệu thành 2 phần: training (80%) và testing (20%) và thực hiện hồi quy logistic:

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

```
Start:  AIC=489.09
is_happy_customer ~ nearest_warehouse + coupon_discount + order_total +
    season + is_expedited_delivery

                       Df Deviance    AIC
- nearest_warehouse     2   473.03 487.03
- season                3   475.99 487.99
- is_expedited_delivery 1   472.12 488.12
- order_total           1   472.56 488.56
<none>                     471.09 489.09
- coupon_discount       1   474.48 490.48

Step:  AIC=487.03
is_happy_customer ~ coupon_discount + order_total + season +
    is_expedited_delivery

                       Df Deviance    AIC
- season                3   477.51 485.51
- is_expedited_delivery 1   474.05 486.05
- order_total           1   474.89 486.89
<none>                     473.03 487.03
- coupon_discount       1   476.26 488.26

Step:  AIC=485.51
is_happy_customer ~ coupon_discount + order_total + is_expedited_delivery

                       Df Deviance    AIC
- is_expedited_delivery 1   478.08 484.08
<none>                     477.51 485.51
- order_total           1   479.98 485.98
- coupon_discount       1   480.99 486.99

Step:  AIC=484.08
is_happy_customer ~ coupon_discount + order_total

                 Df Deviance    AIC
<none>               478.08 484.08
- order_total     1   480.44 484.44
- coupon_discount 1   481.56 485.56
```

Hình 51 Code R thực hiện hồi quy logistic (1)

```
summary(research)
```

Hình 52 Code R thực hiện hồi quy logistic (2)

```
Call:
glm(formula = is_happy_customer ~ coupon_discount + order_total,
    family = "binomial", data = train_data)

Coefficients:
                  Estimate Std. Error z value Pr(>|z|)
(Intercept)      1.174e+00  1.855e-01   6.326 2.51e-10 ***
coupon_discount -2.392e-02  1.283e-02  -1.865   0.0622 .
order_total     -5.986e-07  5.071e-07  -1.180   0.2378
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 483.50  on 399  degrees of freedom
Residual deviance: 478.08  on 397  degrees of freedom
AIC: 484.08

Number of Fisher Scoring iterations: 4
```

Hình 53 Code R thực hiện hồi quy logistic (3)

Nhận xét: Có 2 giá trị p-value lớn hơn mức ý nghĩa 5% nên nhìn chung mô hình hồi quy logistic này không phù hợp để dự báo.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

6. Thảo luận và mở rộng

6.1 Tìm khoảng tin cậy

Ưu điểm: đối với những trường hợp khảo sát có tổng thể lớn, dùng phương pháp ước lượng sẽ tiết kiệm được thời gian, công sức khi khảo sát. Từ mẫu, ta có suy ra những đặc trưng cho tổng thể.

Hạn chế: ở bài toán này, dùng ước lượng khoảng sẽ có 1 sai số nhất định. Đối với những bài toán cần độ chính xác cao thì không thể dùng phương pháp ước lượng. Và sai số của phương pháp ước lượng còn phải phụ thuộc vào độ tin cậy. Có nguy cơ việc lựa chọn mẫu không ngẫu nhiên.

Mở rộng: dùng một số phương pháp có độ chính xác cao hơn như: phương pháp Bootstrap, phương pháp ước lượng bậc cao, phương pháp lọc,…

6.2 Kiểm định 2 mẫu

Ưu điểm: Dễ hiểu và áp dụng: Phương pháp này khá đơn giản và dễ hiểu, điều này làm cho nó trở thành một công cụ hữu ích cho người làm nghiên cứu và phân tích dữ liệu.

Nhược điểm: Yêu cầu kích thước mẫu lớn: Đôi khi, kiểm định 2 mẫu có thể không đủ để phát hiện sự khác biệt nếu kích thước mẫu quá nhỏ.

Kiểm định t dựa vào giả thiết là phân phối của một biến phải tuân theo luật phân phối chuẩn. Nếu giả định này không đúng, kết quả của kiểm định t có thể không hợp lí (valid).

Kết luận: Vì phải tuân theo phân phối chuẩn nên đây chính là hạn chế lớn nhất của kiểm định trung bình. Ta có thể sử dụng phương pháp khác để khắc phục điều này.

Kiểm định Wilcoxon cho hai mẫu (wilcox.test)

Để kiểm định phân phối của coupon_discount, chúng ta có thể dùng hàm shapiro.test như sau:

```
> shapiro.test(new_data$coupon_discount)

        Shapiro-Wilk normality test

data:  new_data$coupon_discount
W = 0.87667, p-value < 2.2e-16

>
```

Hình 54 Code R của hàm shapiro.test cho biến coupon_discount

Trị số p nhỏ hơn 0.05 rất nhiều, cho nên chúng ta có thể nói rằng phân phối của coupon_discount không tuân theo luật phân phối chuẩn. Trong trường hợp này, việc so sánh giữa hai nhóm có thể dựa vào phương pháp phi tham số (non-parametric) có tên là kiểm định Wilcoxon, vì kiểm định này (không như kiểm định t) không tùy thuộc vào giả định phân phối chuẩn.

BACHKHOACNCP.COM

Thực hiện trên R:

```
#Kiểm định phân bố chuẩn
shapiro.test(new_data$coupon_discount)
#Kiểm định Wilcoxon cho 2 mẫu
wilcox.test(new_data$coupon_discount ~ new_data$is_happy_customer, alt="two.sided")
```

Hình 55 Code R cho kiểm định Wilcoxon cho hai mẫu

Kết quả sau khi thực hiện:

```
> #Kiểm định Wilcoxon cho 2 mẫu
> wilcox.test(new_data$coupon_discount ~ new_data$is_happy_customer, alt="two.sided")

        Wilcoxon rank sum test with continuity correction

data:  new_data$coupon_discount by new_data$is_happy_customer
W = 26883, p-value = 0.2694
alternative hypothesis: true location shift is not equal to 0
```

Hình 56 Kết quả sau khi chạy thực hiện trên R của kiểm định Wilcoxon cho 2 mẫu

Trị số p = 0.2694 cho thấy kết quả thật độ khác biệt về coupon_discount giữa hai nhóm hài lòng và không hài lòng không có ý nghĩa thống kê. Kết luận này cũng không khác với kết quả phân tích bằng kiểm định t.

6.3 Mô hình ANOVA (phân tích phương sai 2 nhân tố)

Ưu điểm:

- ANOVA 2 yếu tố có khả năng phát hiện tương tác giữa hai yếu tố..
- So với các phương pháp phức tạp hơn như MANOVA hay các mô hình hồi quy tuyến tính đa biến, ANOVA 2 yếu tố thường đơn giản và dễ tính toán.
- Cho phép kiểm tra sự ảnh hưởng của hai yếu tố đồng thời và xác định xem sự khác biệt giữa các nhóm có ý nghĩa thống kê hay không.

Hạn chế:

- ANOVA giả định rằng dữ liệu tuân theo phân phối chuẩn.
- Phân tích ANOVA 2 yếu tố thích hợp cho nghiên cứu với hai yếu tố độc lập. Nếu có nhiều hơn hai yếu tố, cần sử dụng các phương pháp phức tạp hơn

Kết luận:

Vì phải tuân theo phân phối chuẩn nên đây chính là hạn chế lớn nhất của anova 2 yếu tố. Ta có thể sử dụng phương pháp khác để khắc phục điều này.

Phương pháp mở rộng: Kruskal- Wallis

Phương pháp so sánh nhiều nhóm phi tham số tương đương với phương pháp phân tích phương sai là Kruskal-Wallis. Cũng như phương pháp Wilcoxon so sánh hai nhóm theo

BACHKHOACNCP.COM

phương pháp phi tham số, phương pháp Kruskal-Wallis cũng biến đổi số liệu thành thứ bậc và phân tích độ khác biệt thứ bậc này giữa các nhóm. Hàm kruskal.test trong R có thể giúp chúng ta trong kiểm định này:

```
# Thực hiện Kruskal-Wallis Test
result <- kruskal.test(total ~ interaction(season, warehouse), data = dirty_data)

# Hiển thị kết quả
print(result)
```

Hình 57 Code R của phương pháp Kruskal- Wallis

Chạy hàm cho ra được kết quả sau:

```
        Kruskal-Wallis rank sum test

data:  total by interaction(season, warehouse)
Kruskal-Wallis chi-squared = 10.196, df = 21, p-value = 0.9763
```

Hình 58: Kết quả sau khi thực hiện trên R của phương pháp Kruskal- Wallis

Trị số p = 0.9763 rất cao so với mức ý nghĩa 0.05 cho thấy phương sai chi phí đặt hàng ở 3 kho hàng trong 4 mùa gần không chênh lệch nhiều, giống với kết quả khi ta phân tích bằng Anova.

6.4 Mô hình hồi quy logistic

Ưu điểm:

- Hồi quy logistic nhị phân là phương pháp phù hợp khi biến phụ thuộc là một biến nhị phân, tức là chỉ có hai giá trị.
- Hồi quy logistic không chỉ dự đoán lớp của quan sát, mà còn cung cấp xác suất của quan sát thuộc vào mỗi lớp. Điều này làm cho nó hữu ích trong việc đưa ra quyết định và đánh giá mô hình
- Hồi quy logistic nhị phân cho phép bạn đánh giá ảnh hưởng của mỗi biến độc lập lên xác suất của biến phụ thuộc.

Nhược điểm:

- Mô hình logistic nhị phân giả định một mối quan hệ tuyến tính giữa biến độc lập và log-odds của biến phụ thuộc. Nếu mối quan hệ thực sự không tuyến tính, mô hình có thể không phản ánh đúng mối quan hệ.
- Hồi quy logistic nhị phân chỉ thích hợp cho dữ liệu có biến phụ thuộc là biến nhị phân hoặc được chuyển đổi thành biến nhị phân.

Kết luận: Như cách dùng hồi quy logistic ở trên cho thấy, không phải mô hình nào cũng có thể dùng phương pháp này để phản ánh đúng quan hệ và đưa ra dự báo. Sau đây là một trong những phương pháp mở rộng có thể giải quyết vấn đề trên.

BACHKHOACNCP.COM

Phương pháp mở rộng Decision Tree

Xây dựng mô hình:

```
library(rpart)
library(rpart.plot)
dcst <- rpart(is_happy_customer~., data = train_data, method = 'class')
rpart.plot(dcst, extra = 106)
```

Hình 59 Code R xây dựng mô hình phương pháp mở rộng Decision Tree

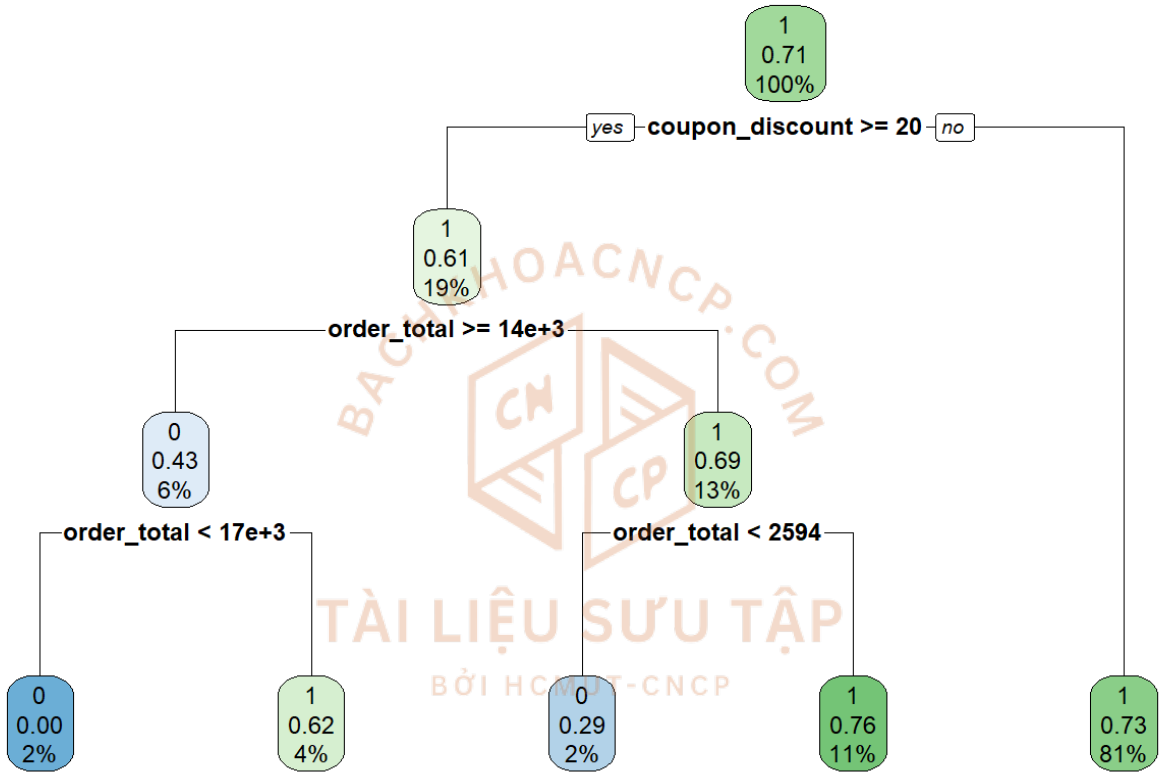

Hình 60 Kết quả sau khi thực hiện trên R phương pháp mở rộng Decision Tree

Nhìn vào mô hình trên ta thấy được không có quá nhiều sự chênh lệch khi phân loại độ hài lòng (0 và 1) dựa vào coupon và order.

Thực hiện dự báo về mô hình trên:

```
test_data$predicted <-predict(dsct, test_data, type = 'class')
head(test_data,10)
```

Hình 61 Code R thực hiện dự báo về mô hình

BACHKHOACNCP.COM

```
   nearest_warehouse coupon_discount order_total season is_expedited_delivery is_happy_customer predicted
1           Thompson              10    11059.89 Winter                     1                 1         1
15         Nickolson               0    31979.78 Autumn                     1                 1         1
17         Nickolson              25    11188.19 Winter                     1                 1         1
19         Nickolson               5     6268.89 Summer                     0                 0         1
28         Nickolson               0     5663.28 Winter                     1                 1         1
37            Bakers              25    10186.45 Winter                     0                 0         1
38         Nickolson               0    12822.12 Winter                     0                 1         1
44         Nickolson               5     8131.57 Autumn                     0                 1         1
46          Thompson              10     7446.01 Summer                     0                 0         1
47          Thompson              25    10598.30 Summer                     1                 1         1
```

Hình 62 Kết quả sau khi thực hiện trên R dự báo về mô hình

So sánh giữa kết quả dự báo và thực tế trong mẫu này:

```
Observation<-table(test_data$is_happy_customer)
Predicted_value<-table(test_data$predicted)
rbind(Observation,Predicted_value)
```

Hình 63 Code R so sánh giữa kết quả dự báo và thực tế trong mẫu

```
                0  1
Observation    24 76
Predicted_value 3 97
```

Hình 64 So sánh giữa kết quả dự báo và thực tế trong mẫu

Kiểm tra tỉ lệ phân loại sai:

```
true_labels <- test_data$is_happy_customer
predicted_labels <- test_data$predicted
misclassification_rate <- sum(true_labels != predicted_labels) / length(true_labels)
print(misclassification_rate)
```

Hình 65 Code R kiểm tra tỉ lệ phân loại sai

```
[1] 0.25
```

Hình 66 Kiểm tra tỉ lệ phân loại sai

Tỉ lệ phân loại sai chiếm khoảng 25%.

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP
BACHKHOACNCP.COM

7. Tài liệu tham khảo

Hoàng Trọng & Chu Nguyễn Mộng Ngọc (2008), *Thống kê ứng dụng trong Kinh tế - Xã hội*, Nxb. Thống Kê, Hà Nội

Nguyễn Đình Huy, (2016), *Giáo trình xác suất và thống kê*, Nxb. Đại học Quốc Gia, Thành phố Hồ Chí Minh.

Nguyễn Văn Tuấn, (2014), *Phân tích dữ liệu với R*, Nxb. Tổng hợp, Thành phố Hồ Chí Minh.

Trường Đại học Kinh tế Quốc dân, *Bài 7: Kiểm định giả thuyết thống kê*, truy cập từ http://eldata2.neu.topica.vn/TXTOKT02/Giao%20trinh/08_NEU_TXTOKT02_Bai7_v1.0014109205.pdf

BACHKHOACNCP.COM
TÀI LIỆU SƯU TẬP
BỞI HCMUT-CNCP