ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHOA ĐIỆN ĐIỆN TỬ

BÀI TẬP LỚN

XÁC SUẤT THỐNG KÊ (MT2013)

NHÓM: L09 - 05

Transactional Retail Dataset of Electronics Store

GV hướng dẫn: PHAN THỊ HƯỜNG

Nhóm sinh viên thực hiện:

Họ và tên	*MSSV*
Hồ Hữu Đức	2310771
Nguyễn Hữu Đức	2310784
Nguyễn Lê Thanh Toàn	2313487
Lê Trí Toàn	2313480

TP. Hồ Chí Minh, 2024

Nhóm trưởng:

Họ và tên	MSSV	Đóng góp	Nhiệm vụ
Hồ Hữu Đức	2310771		
Nguyễn Hữu Đức	2310784		
Nguyễn Lê Thanh Toàn	2313487		
Lê Trí Toàn	2313480		

Giáo viên đánh giá

Họ và tên	Điểm	Nhận xét
Hồ Hữu Đức		
Nguyễn Hữu Đức		
Nguyễn Lê Thanh Toàn		
Lê Trí Toàn		

Mục lục

1 Tổng quan dữ liệu **3**

2 Cơ sở lý thuyết **5**
2.1 Thống kê mô tả và thống kê suy diễn 5
2.1.1 Thống kê mô tả (Descriptive statistics) 5
2.1.2 Thống kê suy diễn (Inferential statistics) 5
2.2 Biểu đồ thống kê 5
2.3 Hồi quy tuyến tính bội 6
2.3.1 Hàm hồi quy tổng thể (PRF - Population Regression Function) . . 6
2.3.2 Hàm hồi quy mẫu (SRF - Sample Regression Function) 7
2.3.3 Phương pháp bình phương nhỏ nhất cho mô hình hồi quy tuyến tính bội 7
2.3.4 Độ phù hợp của mô hình 7
2.4 Khoảng tin cậy và kiểm định các hệ số hồi quy 8
2.5 Kiểm định mức độ ý nghĩa của mô hình (Trường hợp đặc biệt của kiểm định WALD) 9
2.5.1 Khái quát kiểm định WALD 9
2.5.2 Kiểm định ý nghĩa của mô hình 10
2.6 Phân tích phương sai một yếu tố 11
2.6.1 Khái quát ANOVA (Phân tích phương sai) 11
2.6.2 Phân tích ANOVA 11

3 Tiền xử lý số liệu **13**
3.1 Đọc dữ liệu vào R 13
3.2 Làm sạch dữ liệu 13
3.2.1 Tạo tệp tin con bao gồm các biến sẽ được sử dụng và phân tích . . 13
3.2.2 Kiểm tra các dữ liệu bị khuyết 14
3.2.3 Kiểm tra và xử lý các dữ liệu bị lỗi 14

4 Thống kê mô tả **15**
4.1 Tính thống kê mô tả cho các biến định lượng 15
4.2 Thống kê số lượng cho các biến phân loại 15
4.3 Kiểm tra các giá trị ngoại lai 16
4.4 Mô tả dữ liệu bằng đồ thị 19
4.4.1 Đồ thị Histogram 19
4.4.2 Đồ thị Boxplot 20
4.4.3 Đồ thị Plot 21
4.4.4 Đồ thị ma trận tương quan 22

5 Thống kê suy diễn **23**
5.1 Kiểm tra dữ liệu có phải tuân theo phân phối chuẩn không 23
5.2 Mô hình hồi quy tuyến tính 23
5.3 Kiểm định các hệ số β_i 25
5.4 Mô hình hồi quy tuyến tính về sự ảnh hưởng các nhân tố lên order_total . 27

6 Nguồn dữ liệu và nguồn code **28**

1 Tổng quan dữ liệu

Tệp dữ liệu chứa thông tin về một cửa hàng điện tử trực tuyến. Cửa hàng có ba kho để giao hàng cho khách hàng. Trong bài tập lớn này nhóm chúng em sẽ sử dụng tệp dữ liệu này để thực hiện các phương pháp graphical and non-graphical EDA. Dựa vào dữ liệu trên tìm được mối quan hệ giữa các biến để từ đó đưa ra được phỏng đoán, xây dựng được mô hình dự báo mức độ hài lòng của khách hàng.

Các biến trong tệp dữ liệu này bao gồm:

1. Order_id: Mã ID cho mỗi đơn hàng.
2. Customer_id: Mã ID của mỗi khách hàng.
3. Date: Thời gian đặt hàng, được đưa ra ở định dạng YYYY - MM - DD.
4. Nearest_warehouse: Một chuỗi biểu thị tên của kho hàng gần khách hàng nhất.
5. Shopping_cart: Danh sách các bộ dữ liệu đại diện cho các mục đặt hàng: phần tử đầu tiên của bộ dữ liệu là mục được sắp xếp và phần tử thứ hai là số lượng đặt hàng cho mặt hàng đó.
6. Order_price: Một số thực biểu thị giá đặt hàng bằng USD. Giá đặt hàng là giá của mặt hàng trước khi có bất kỳ khoản giảm giá và/hoặc phí giao hàng nào được áp dụng.
7. Delivery_charge: Một số thực thể hiện chi phí vận chuyển của đơn hàng.
8. Customer_lat: Vĩ độ của khách hàng.
9. Customer_long: Kinh độ của khách hàng.
10. Coupon_discount: một số nguyên biểu thì phần trăm giảm giá cho order_price.
11. Order_total: một số thực biểu thị tổng đơn đặt hàng bằng USD sau khi - giảm giá và/hoặc phí giao hàng được áp dụng.
12. Season: Một chuỗi biểu thị mùa mà đơn đặt hàng được đặt.
13. Is_expedited_delivery: Một hàm boolean biểu thị việc khách hàng có yêu cầu giao hàng nhanh hay không.
14. Distance_to_nearest_warehouse: Một số thực biểu thị khoảng cách vòng cung, tính bằng km, giữa khách hàng và kho hàng gần nhất với họ. (bán kính trái đất: 6378 KM)
15. Latest_customer_review: Một chuỗi thể hiện đánh giá mới nhất của khách hàng về đơn hàng gần đây nhất của họ.
16. Is_happy_customer: Một boolean biểu thị liệu khách hàng có hài lòng hay không hoặc có vấn đề với đơn hàng gần đây nhất của họ.

Dữ liệu có tổng cộng 16 biến (9 biến phân loại, 7 biến liên tục).

Các biến phân loại: order_id, customer_id, date, nearest_warehouse, shopping_cart, season, is_expedited_delivery, latest_customer_review, is_happy_customer. **Các biến liên tục:** order_price, delivery_charges, customer_lat, customer_long, coupon_discount, order_total.

Trong bài tập lớn này nhóm sẽ sử dụng công cụ R và Rstudio để phân tích các dữ liệu trong tệp tin.

	order_total	season	nearest_warehouse	delivery_charges	coupon_discount	order_price	is_expedited_delivery	is_happy_customer
1	11059.89	Winter	Thompson	79.89	10	12200	True	True
2	9142.71	Summer	Thompson	62.71	0	9080	False	False
3	9668.87	Autumn	Nickolson	65.87	10	10670	False	True
4	21137.61	Summer	Nickolson	57.61	15	24800	False	False
5	6934.29	Spring	Nickolson	75.54	25	9145	False	True

Một phần của dữ liệu sau khi đưa vào Rstudio.

Mục tiêu phân tích: Thực hiện dự đoán tổng chi phí của các đơn đặt hàng.

2 Cơ sở lý thuyết

2.1 Thống kê mô tả và thống kê suy diễn

2.1.1 Thống kê mô tả (Descriptive statistics)

Thống kê mô tả là một phương pháp sử dụng để tóm tắt, mô tả, thu nhập, biểu diễn, tổng hợp và xử lý một tập hợp dữ liệu để biến đổi thành thông tin.

- Thu thập thông tin: khảo sát, xem xét mục tiêu cần nghiên cứu, từ đó thu thập các thông tin tương ứng nhằm mục đích phân tích.
- Mô tả dữ liệu: Sắp xếp dữ liệu thành các bảng, biểu, hoặc danh sách, đảm bảo cấu trúc rõ ràng để dễ dàng phân tích và trình bày.
- Tính toán thống kê dữ liệu: Tóm tắt dữ liệu thô bằng các giá trị thống kê như trung bình, trung vị, độ lệch chuẩn, hoặc phương sai, nhằm mô tả đặc điểm chính của tập dữ liệu.
- Minh họa dữ liệu trực quan: Biểu diễn dữ liệu bằng đồ thị, biểu đồ (ví dụ: biểu đồ cột, biểu đồ tròn, hoặc histogram) để làm nổi bật các đặc trưng của dữ liệu một cách trực quan.
- Đánh giá hình dáng phân phối: Kiểm tra các đặc điểm của phân phối dữ liệu, bao gồm độ tập trung, độ phân tán, tính đối xứng, và sự hiện diện của các giá trị ngoại lai.
- Kết luận: Đưa ra các kết luận dựa trên dữ liệu đã được tổng hợp, nhấn mạnh các xu hướng, đặc điểm nổi bật hoặc tóm lược thông tin hỗ trợ cho việc ra quyết định.

2.1.2 Thống kê suy diễn (Inferential statistics)

Thống kê suy diễn là phương pháp phân tích xử lý dữ liệu được lấy từ thông tin ở thống kê mô tả để dự đoán, dự báo và ước lượng.

- Ước lượng: Các tham số thống kê gồm trung bình, tỷ lệ, phương sai.
- Kiểm định giả thuyết: Tham số thống kê (trung bình, tỷ lệ, phương sai), quy luật phân phối xác suất (chuẩn, poisson, ...), độc lập, ...

2.2 Biểu đồ thống kê

Biểu đồ thống kê là một công cụ trực quan hữu ích để minh họa dữ liệu. Những biểu đồ này thường được dùng để mô tả các đặc trưng cơ bản của tập dữ liệu, chẳng hạn như giá trị trung bình, độ lệch chuẩn, giá trị lớn nhất và giá trị nhỏ nhất.

- **Biểu đồ Histogram (Histogram chart)**: Đây là một công cụ quan trọng trong việc hiểu và phân tích chuỗi dữ liệu, cung cấp những thông tin cần thiết về mối quan hệ giữa các giá trị trong dữ liệu. Cụ thể, biểu đồ Histogram giúp phân tích

sự phân bố tần số, đánh giá tính đối xứng của dữ liệu và nghiên cứu sự thay đổi qua thời gian.

- **Biểu đồ boxplot (box-and-whisker plot)**: Biểu đồ này biểu diễn 5 vị trí phân bố chính của dữ liệu, bao gồm giá trị nhỏ nhất (min), tứ phân vị thứ nhất (Q1), trung vị (median), tứ phân vị thứ ba (Q3) và giá trị lớn nhất (max).
- **Biểu đồ cặp (pair plot)**: Được sử dụng để hiểu rõ các đặc trưng tốt nhất mô tả mối liên kết giữa hai biến số hoặc tạo ra các cụm khác biệt nhất.
- **Ma trận tương quan**: Hiển thị hệ số tương quan giữa các biến trong một bảng. Mỗi ô trong bảng biểu thị mối liên hệ giữa hai biến.

2.3 Hồi quy tuyến tính bội

Mô hình hồi quy tuyến tính bội có dạng tổng quát như sau:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + e$$

Trong đó:

– Y: Biến phụ thuộc.

– X_i: Biến độc lập.

– β_0: Hệ số tự do (Hệ số chặn)

– β_i: Hệ số hồi quy riêng.

Phương pháp hồi quy tuyến tính là phương pháp dự đoán giá trị của biến phụ thuộc (Y) trên các biến độc lập (X).

2.3.1 Hàm hồi quy tổng thể (PRF - Population Regression Function)

Ta có:

Y là biến phụ thuộc ngẫu nhiên, có phân phối xác suất.

X_1, X_2, ..., X_n là biến độc lập

Suy ra Tồn tại $E\,(Y \mid X_1,\, X_2,\, ...,\, X_n)$ = giá trị xác định.

Vì vậy $F\,(Y \mid X_1,\, X_2,\, ...,\, X_n) = E\,(Y \mid X_1,\, X_2,\, ...,\, X_n)$ là hàm hồi quy tổng thể của Y theo X_1, X_2, ..., X_n.

Ta có: $Y_i \neq F\,(X_1,\, X_2,\, ...,\, X_n) \Rightarrow u_i = Y_i$ – F

Vì vậy: $Y_i = E\,(Y \mid X_1,\, X_2,\, ...,\, X_n) + u_i$

Hồi quy tổng thể PRF:

– Y = E (Y | X) + U

– E (Y | X) = F(X)

2.3.2 Hàm hồi quy mẫu (SRF - Sample Regression Function)

Trong thực tế, việc có được toàn bộ dữ liệu từ tổng thể là điều rất hiếm. Vì thế, không thể chắc chắn về mức độ chính xác của giá trị trung bình tổng thể của biến phụ thuộc. Do đó, chúng ta cần sử dụng dữ liệu mẫu để đưa ra ước lượng. Trên một mẫu gồm n cá thể, ta định nghĩa $\hat{Y} = \hat{F}(X_1, X_2, \ldots, X_n)$ là hàm hồi quy ước lượng từ mẫu. Đối với một cá thể trong mẫu,$Y_i \neq \hat{F}(X_1, X_2, \ldots, X_n)$, dẫn đến sai số $e_i = \hat{Y} - \hat{F}(X_1, X_2, \ldots, X_n)$. Ở đây, e_i được gọi là phần dư của mô hình hồi quy đơn giản (SRF). Dạng tổng quát của hàm hồiquy mẫu có thể được biểu diễn như sau.

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1,i} + \hat{\beta}_2 x_{2,i} + ... + \hat{\beta}_n x_{n,i}$$

2.3.3 Phương pháp bình phương nhỏ nhất cho mô hình hồi quy tuyến tính bội

Để xây dựng mô hình hồi quy tuyến tính đa biến ta cần xem xét các giả định như sau:

i. Hàm hồi quy là tuyến tính theo các tham số.

Quá trình hồi quy trên thực tế được mô tả bởi mối quan hệ dưới dạng:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + e$$

Mối quan hệ có thể được viết dưới dạng loga cả hai vế.

ii. Kỳ vọng của các yếu tố ngẫu nhiên u_i bằng 0.

Trung bình của tổng thể sai số bằng 0. Ta được một số giá trị sai số mang dấu dương và một số giá trị sai số mang dấu âm. Hàm được xem là đường trung bình nên có thể giả định rằng các sai số ngẫu nhiên trên sẽ bị loại trừ nhau, ở mức trung bình, trong tổng thể.

iii. Các sai số độc lập với nhau.

iv. Các sai số có phương sai bằng nhau.

Các giá trị u phân phối giống nhau với cùng phương sai σ^2, sau cho:

$$\mathrm{Var}(u_i) = E(u_i^2) = \sigma^2$$

v. Các sai số có phân phối chuẩn.

Điều này rất quan trọng khi phát sinh khoảng tin cậy và thực hiện kiểm định giả thuyết trong những phạm vi mẫu là nhỏ. Nhưng phạm vi mẫu lớn hơn, điều này trở nên không mấy quan trọng.

2.3.4 Độ phù hợp của mô hình

Người ta sử dụng R^2 để mô hình giải thích được như thế nào hay bao nhiêu % biến động của biến phụ thuộc.

Ta có: TSS = ESS + RSS

Với ý nghĩa cũng từng thành phần:

- TSS (Total Sum of Squares): $\sum(y_i - \bar{y})^2$ là tổng bình phương các sai lệch giữa giá trị quan sát Y_i với giá trị trung bình.
- ESS (Explained Sum of Squares): $\sum(\hat{y}_i - \bar{y})^2$ là tổng bình phương tất cả các sai lệch của biến phụ thuộc Y nhận được từ hàm hồi quy mẫu và giá trị trung bình chúng. Phần này đo đạt độ chính xác của hàm hồi quy.
- RSS (Residual Sum of Squares): $\sum e_i^2$ là tổng bình phương của tất cả các sai lệch giữa các giá trị quan sát Y và các giá trị nhận được từ hàm hồi quy.

Từ đó R^2 xác định bằng công thức:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}; \quad (0 \leq R^2 \leq 1)$$

Từ định nghĩa R^2 chúng ta thấy R^2 đo tỷ lệ hay số % của toàn bộ sai lệch Y với giá trị trung bình được giải thích bằng mô hình. Khi đó người ta sử dụng R^2 để đo sự phù hợp của hàm hồi quy:

- R^2 cao nghĩa là mô hình ước lượng được giải thích được một mức độ cao biến động của biến phụ thuộc.
- Nếu R^2 bằng 0 thì điều này có nghĩa là mô hình không đưa ra thông tin nào về sự thay đổi của biến phụ thuộc y.
- Nếu R^2 bằng 1 thì điều này có nghĩa là sự thây đổi của biến phụ thuộc là 100% và được chứng minh bằng đường hồi quy.

2.4 Khoảng tin cậy và kiểm định các hệ số hồi quy

Ước lượng khoảng tin cậy các hệ số hồi quy.

Mục tiêu của phân tích hồi quy không chỉ dừng lại ở việc dự đoán các hệ số hồi quy riêng lẻ như β_0, β_1, β_2, ..., β_n, mà còn nhằm kiểm tra bản chất và mối quan hệ phụ thuộc. Vì vậy, cần xác định phân phối xác suất của các hệ số β_0, β_1, β_2, ..., β_n. Các phân phối này phụ thuộc vào phân phối của các sai số u_i.

Theo các giả định của OLS, các sai số u_i tuân theo phân phối chuẩn $\mathcal{N}(0, \sigma^2)$. Do đó, các hệ số ước lượng cũng tuân theo phân phối chuẩn.

$$\hat{\beta}_j \sim N\left(\beta_j,\, Se\left(\hat{\beta}_j\right)\right)$$
$$\frac{\hat{\beta}_j - \beta_j}{Se\left(\hat{\beta}_j\right)} \sim T(n-k)$$

Từ phần dư bình phương tối thiểu ta ước lượng phương sai sai số, với k là số hệ số trong phương trình hồi quy đa biến:

$$\hat{\sigma}^2 = \frac{\sum e_i^2}{n-k}$$

– Ước lượng 2 phía, ta tìm được $\frac{\alpha}{2}$ thỏa mãn:

$$P\left(-t_{\frac{\alpha}{2}}(n-k) \leq \frac{\hat{\beta}_j - \beta_j}{Se(\hat{\beta}_j)} \leq t_{\frac{\alpha}{2}}(n-k)\right) = 1 - \alpha$$

– Khoảng tin cậy 1 - α của β_j là:

$$\left[\hat{\beta}_j - t_{\frac{\alpha}{2}}(n-k)Se(\hat{\beta}_j);\ \hat{\beta}_j + t_{\frac{\alpha}{2}}(n-k)Se(\hat{\beta}_j)\right]$$

Kiểm định giả thiết đối với β_j.

Việc kiểm định ý nghĩa thống kê của các hệ số hồi quy nhằm xác định xem các biến giải thích có thực sự tác động đến biến phụ thuộc hay không. Nói cách khác, mục tiêu là đánh giá liệu hệ số hồi quy có ý nghĩa thống kê hay không.

Giả sử $\beta_j = \beta_j*$. Nếu giả thiết đúng thì:

$$T = \frac{\hat{\beta}_j - \beta_j^*}{Se(\hat{\beta}_j)} \sim T(n-k)$$

Ta có bảng sau:

Loại giả thuyết	**Giả thuyết H_0**	**Giả thuyết đối H_1**	**Miền bác bỏ**
Hai phía	$\beta_i = \beta_i^*$	$\beta_i \neq \beta_i^*$	$\lvert t\rvert > t_{\alpha/2;n-k}$
Phía phải	$\beta_i \leq \beta_i^*$	$\beta_i > \beta_i^*$	$t > t_{\alpha;n-k}$
Phía trái	$\beta_i \geq \beta_i^*$	$\beta_i < \beta_i^*$	$t < -t_{\alpha;n-k}$

Bảng tóm tắt giả thuyết và miền bác bỏ tương ứng

P-value < mức ý nghĩa thì sẽ bác bỏ giả thuyết H_0.

– Giả thuyết: H_0: $\beta_j = 0 \Leftrightarrow x_j$ không tác động.

– Giả thuyết: H_0: $\beta_j \neq 0 \Leftrightarrow x_j$ có tác động.

– $\beta_j < 0 \Leftrightarrow x_j$ có tác động ngược.

– $\beta_j > 0 \Leftrightarrow x_j$ có tác động thuận.

2.5 Kiểm định mức độ ý nghĩa của mô hình (Trường hợp đặc biệt của kiểm định WALD)

2.5.1 Khái quát kiểm định WALD

Giả sử ta có 2 mô hình:

$$(U): Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + u$$
$$(R): Y = \beta_0 + \beta_1 X_1 + v$$

Mô hình U được gọi là mô hình không bị ràng buộc (Unrestricted), trong khi mô hình R được xem là mô hình có ràng buộc (Restricted). Sự khác biệt này xuất phát từ việc các

hệ số β_2 và β_3 bị cố định bằng 0 trong mô hình R. Chúng ta có thể thực hiện kiểm định giả thuyết rằng $\beta_2 = \beta_3 = 0$, với điều kiện rằng ít nhất một trong hai hệ số này không bằng 0. Loại kiểm định giả thuyết này được gọi là kiểm định WALD, và quy trình thực hiện được trình bày như sau.

Các mô hình giới hạn và không giới hạn lần lượt là:

$$(U) : Y = \beta_0 + \beta_1 X_1 + ... + \beta_m X_m + \beta_{m+1} X_{m+1} + ... + \beta_k X_k + u$$

$$(N) : Y = \beta_0 + \beta_1 X_1 + ... + \beta_m X_m + v$$

Mô hình (N) có được bằng cách bỏ bớt một số biến ở mô hình (M), đó là: $X_{m+1}, X_{m+2}, ..., X_k$.

Giả thuyết: H_0: $\beta_{m+1} = ... = \beta_k = 0 | H_1$: "Không phải đồng thời các tham số bằng 0"

Lưu ý rằng mô hình U bao gồm k hệ số hồi quy chưa biết, trong khi mô hình R chỉ chứa m hệ số hồi quy chưa biết. Do đó, mô hình N có ít hơn (k m) tham số so với mô hình M. Vấn đề cần xem xét là liệu việc loại bỏ (k m) biến này có gây ảnh hưởng đáng kể đến mối liên hệ với biến Y hay không.

Ta có trị thống kê kiểm định là:

$$F_c = \frac{[RSS_R - RSS_U]/(k-m)}{RSS_U/(n-k)} \sim F(\alpha, k-m, n-k) \Leftrightarrow F_c = \frac{R_U^2 - R_R^2}{k-m} \Big/ \frac{1-R_U^2}{n-k}$$

Với R^2 là độ đo thích hợp không hiệu chỉnh. Với giả thuyết không, F_c có phân phối F với (k - m) bậc tự do đối với tử số và (n - k) bậc tự do đối với mẫu số.

Bác bỏ giả thuyết H_0 khi:

$$F_c > F(\alpha, k-m, n-k)$$

Hay giá trị p-value của thống kê F_c nhỏ hơn mức ý nghĩa trước.

2.5.2 Kiểm định ý nghĩa của mô hình

Đặt giả thuyết

- Giả thuyết không (H_0): $\beta_2 = \beta_3 = \cdots = \beta_k = 0$, tức là các hệ số hồi quy riêng của mô hình không có ý nghĩa.
- Giả thuyết đối (H_1): Ít nhất một trong các hệ số β khác 0, nghĩa là mô hình có ý nghĩa.

Tiến hành kiểm định

Thực hiện hồi quy biến phụ thuộc Y theo một tập hợp các biến độc lập $X_2, X_3, \ldots, X_k$.

Tính tổng bình phương sai số:

- RSS_U: Tổng bình phương sai số từ mô hình đầy đủ (Unrestricted Model).
- RSS_R: Tổng bình phương sai số từ mô hình ràng buộc (Restricted Model).

Thống kê kiểm định:

$$F_c = \frac{[RSS_R - RSS_U]/(k-m)}{RSS_U/(n-k)} \sim F(\alpha, k-m, n-k)$$

Trong trường hợp $H_0 : \beta_2 = \beta_3 = \cdots = \beta_k = 0$, công thức F_c có thể được viết lại như sau:

$$F_c = \frac{ESS/(k-1)}{RSS/(n-k)} \sim F(\alpha, k-1, n-k)$$

Trong đó:

- ESS: Tổng bình phương do hồi quy giải thích (Explained Sum of Squares).
- RSS: Tổng bình phương phần dư (Residual Sum of Squares).

Tra bảng phân phối F

Sử dụng bảng giá trị phân phối F để xác định giá trị tới hạn tương ứng với mức ý nghĩa α, với:

- Bậc tự do tử số: $k-1$,
- Bậc tự do mẫu số: $n-k$.

Quy tắc bác bỏ giả thuyết

Bác bỏ H_0 nếu:

$$F_c > F(\alpha, k-1, n-k).$$

Hoặc, sử dụng giá trị p-value: bác bỏ H_0 nếu $P(F > F_c \mid H_0) < \alpha$. Điều này có nghĩa là xác suất sai số khi bác bỏ H_0 nhỏ hơn mức ý nghĩa cho trước.

2.6 Phân tích phương sai một yếu tố

2.6.1 Khái quát ANOVA (Phân tích phương sai)

Phân tích phương sai (ANOVA) là phương pháp thống kê được sử dụng để so sánh giá trị trung bình của nhiều nhóm nhằm đánh giá xem có sự khác biệt đáng kể giữa chúng hay không. Phương pháp này dựa trên các quan sát mẫu đại diện cho các nhóm tổng thể và thực hiện kiểm định giả thuyết để xác định tính đồng nhất của các giá trị trung bình. ANOVA được chia thành hai loại chính: phân tích phương sai một yếu tố và hai yếu tố, trong đó "yếu tố" đề cập đến các biến độc lập hoặc nguyên nhân có khả năng ảnh hưởng đến biến phụ thuộc được nghiên cứu.

2.6.2 Phân tích ANOVA

Phương pháp phân tích phương sai là một phương thức dùng để so sánh trung bình của nhiều nhóm khác nhau để có thể két luận trung bình các nhóm đó có khác nhau hay không.

Ta có các mô hình phân tích phương sai như sau: phân tích phương sai một nhân tố,

hai hoặc ba nhân tố. Những nhân tố này ta có thể coi là những yếu tố có thể làm ảnh hưởng đến với kết quả mà ta quan tâm.

Để có thể áp dụng ANOVA vô một bài toán ta cần giả sử những điều kiện sau đây:

– Tổng thể có phân phối chuẩn.

– Tổng thể có phương sai bằng nhau.

– Mẫu phải được chọn ngẫu nhiên và độc lập với nhau.

Nếu trung bình các tổng thể được ký hiệu là $\mu_1, \mu_2, \ldots, \mu_k$ thì ta có các giả thiết trong mô hình phân tích phương sai như sau:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$$

Ta giả sử H_0 cho rằng trung bình của k tổng thể bằng nhau, tức nhân tố nguyên nhân không có tác động gì đến nhân tố kết quả ta đang nghiên cứu.

$$H_1 : \exists \mu_i \neq \mu_j \quad (i \neq j)$$

Ta giả sử H_1 cho rằng có ít nhất 2 giá trị trung bình ở các tổng thể khác nhau, tức nhân tố nguyên nhân có tác động đến nhân tố kết quả ta đang nghiên cứu.

Phân tích phương sai như sau:

Bước 1: Tính trung bình mẫu của các nhóm $\overline{x}_i$ theo công thức:

$$\overline{x}_i = \frac{\sum_{j=1}^{n_i} x_{ij}}{n_i}, \quad (i = 1, 2, \ldots, k)$$

Trung bình chung của k mẫu được tính theo công thức:

$$\overline{x} = \frac{\sum_{j=1}^{n_i} n_i \overline{x}_i}{\sum_{j=1}^{n_i} n_i}, \quad (i = 1, 2, \ldots, k)$$

Bước 2: Tính tổng các chênh lệch bình phương (tổng bình phương):

Tổng các độ lệch bình phương trong nội bộ nhóm (SSW):

$$SSW = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (x_{ij} - \overline{x}_i)^2$$

Tổng các độ lệch bình phương giữa các nhóm (SSB):

$$SSB = \sum_{i=1}^{k} n_i (\overline{x}_i - \overline{x}_i)^2$$

Tổng các độ lệch bình phương của toàn bộ tổng thể(SST):

$$SST = SSB + SSW = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (x_{ij} - \overline{x})^2$$

Bước 3: Tính phương sai:

$$MSM = \frac{SSW}{n-k}, \qquad MSB = \frac{SSB}{k-1}$$

Bước 4: Tính thống kê kiểm định (tiêu chuẩn kiểm định, giá trị quan sát):

$$F = \frac{MSB}{MSW}$$

Bước 5: Xác định miền bác bỏ:

$$RR = (F_{\alpha;k-1;n-k}; +\infty)$$

Ta tìm giá trị $F_{\alpha;k-1;n-k}$ bằng cách tra bảng Fisher mức ý nghĩa α và cột $k-1$ và dòng $n-k$.

Bước 6: Đưa ra kết luận:

Nếu $F > F_{\alpha;k-1;N-k} \Leftrightarrow F \in RR \Rightarrow$ Bác bỏ H_0.

Nếu $F < F_{\alpha;k-1;N-k} \Leftrightarrow F \notin RR \Rightarrow$ Không bác bỏ H_0.

3 Tiền xử lý số liệu

3.1 Đọc dữ liệu vào R

Đọc dữ liệu "dirty_data.csv" và lưu vào biến có tên là dirty_data. Sau đây là kết quả hiển thị một số biến.

Result (Code: 1 → 3)

```
$ order_id                      : chr "ORD182494" "ORD395518" "ORD494479"
"ORD019224" ...
$ customer_id                   : chr "ID6197211592" "ID0282825849"
"ID0579391891" "ID4544561904" ...
$ date                          : chr "2019-06-22" "2019-12-29" "2019-03-02"
"2019-01-12" ...
```

Tệp bao gồm 16 biến và 500 giá trị.

3.2 Làm sạch dữ liệu

3.2.1 Tạo tệp tin con bao gồm các biến sẽ được sử dụng và phân tích

Ta chọn ra 9 biến bao gồm biến phân loại và biến liên tục và tổng hợp vào Data1. Những biến đó bao gồm order_total, order_price, delivery_charges, is_expedited_delivery, season, nearest_warehouse, date, distance_to_nearest_warehouse, is_happy_customer, coupon_discount, customer_long, customer_lat. Dưới đây là kết quả hiển thị một số biến.

Result (Code: 5 → 7)

```
     order_total  season  nearest_warehouse  delivery_charges  coupon_discount
115      3965.53  Spring          Nickolson             80.53               25
116      2214.76  Summer             Bakers             68.51               15
117     19223.36  Spring           Thompson             81.36               15
     order_price  is_expedited_delivery  is_happy_customer
115         5180                  False               True
116         2525                  False               True
117        22520                  False               True
     distance_to_nearest_warehouse        date
115                         1.1423  12-09-2019
116                         0.7443  2019-02-13
117                         1.4937  2019-09-10
```

3.2.2 Kiểm tra các dữ liệu bị khuyết

Ta kiểm tra xem các dữ liệu của các biến ta chọn để phân tích có bị thiếu hay khuyết không. Kết quả được hiển thị như sau.

Result (Code: 8)

```
           order_total              season               nearest_warehouse
                     0                   0                               0
     delivery_charges     coupon_discount                     order_price
                     0                   0                               0
is_expedited_delivery   is_happy_customer  distance_to_nearest_warehouse
                     0                   0                               0
                  date
                     0
```

Dựa vào kết quả trên, ta có thể thấy được không có dữ liệu nào bị khuyết.

3.2.3 Kiểm tra và xử lý các dữ liệu bị lỗi

Dựa vào dữ liệu được tổng hợp vào Data1 và xuất ra màn hình ở trên ta thấy được lỗi thứ nhất, cột ngày tháng năm bị lỗi định dạng và thời gian không đúng theo mùa. Kết quả sau khi được chỉnh sửa như sau.

Result (Code: 12 → 24)

```
     season        date
115  Winter  2019-12-09
116  Spring  2019-02-13
117  Autumn  2019-09-10
```

Ta tiếp tục kiểm tra các biến phân loại còn lại như nearest_warehouse, is_happy_customer và is_expedited_delivery, kết quả như sau.

Result (Code: 25 → 27)

```
> unique (fix_Data1$nearest_warehouse)
[1] "Thompson" "Nickolson" "Bakers" "nickolson" "thompson"
> unique (fix_Data1$is_happy_customer)
[1] "True" "False"
> unique (fix_Data1$is_expedited_delivery)
[1] "True" "False"
```

Từ đó ta thấy được biến nearest_warehouse có các giá trị bị lỗi làm sai lệch trong quá trình phân tích. Kết quả sau khi được chỉnh sửa ở bên dưới.

Result (Code: 28 → 29)

```
> unique(fix_Data1$nearest_warehouse)
[1] "Thompson" "Nickolson" "Bakers"
```

4 Thống kê mô tả

4.1 Tính thống kê mô tả cho các biến định lượng

Ta tính thống kê mô tả cho các biến định lượng và kết quả xuất ra như sau.

Result (Code: 31 → 37)

	order_total	order_price	delivery_charges	distance_to_nearest_warehouse
mean	39209.67	25522.22	76.65820	2.204224
median	11293.96	12807.50	76.31000	1.030100
sd	274194.02	86333.73	14.48146	8.812416
min	639.29	585.00	46.35000	0.107800
max	5688269.60	947691.00	114.04000	94.973400

4.2 Thống kê số lượng cho các biến phân loại

Lập bảng thống kê cho mỗi phân loại của các biến season, s_expedited_delivery, is_happy_customer và nearest_warehouse. Kết quả xuất ra như sau.

Result (Code: 39 → 42)

```
> table(fix_Data1$season)
 Autumn   Spring   Summer   Winter
    122      129      128      121
> table(fix_Data1$nearest_warehouse)
 Bakers   Nickolson   Thompson
    119         184        197
> table(fix_Data1$is_expedited_delivery)
 False   True
   251    249
> table(fix_Data1$is_happy_customer)
 False   True
   141    359
```

4.3 Kiểm tra các giá trị ngoại lai

Ta kiểm tra xem biến order_total có tồn tại các giá trị ngoại lai bằng sơ đồ Boxplot, cho ra đồ thị như sau.

Result (Code: 46)

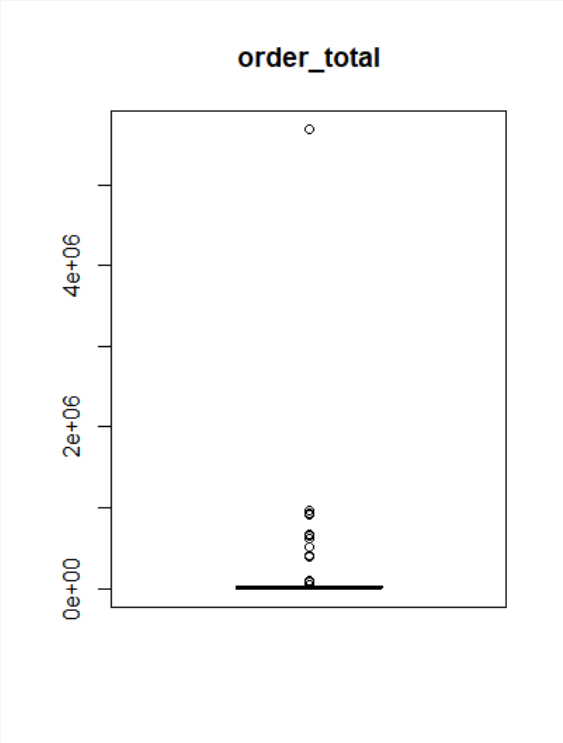

Dựa vào đồ thị trên, ta thấy được có các biến ngoại lai khiến ta khó có thể phân tích sự ảnh hưởng bằng sơ đồ Boxplot.

Để khắc phục tình trạng này, ta áp dụng cơ sở lý thuyết bằng đoạn code **(Code: 48 → 54)**. Đoạn code này có tác dụng ta sẽ gán các giá trị ngoại lai bằng NA. Sau đó chúng ta sẽ xem xét có nên xóa các dữ liệu ngoại lai này không (bởi khi các giá trị ngoại lai quá nhiều thì ta không nên xóa đi vì rất có thể sẽ ảnh hưởng đến quá trình phân tích).

Số giá trị ngoại lai của biến order_total được hiển thị như sau.

Result (Code: 56)

```
order_total
         18
```

Ta thấy được có 18 giá trị ngoại lai (tức 3.6%) khá ít nên ta có thể xóa các giá trị ngoại lai này. Xóa các giá trị ngoại lai, kết quả cho ra đồ thị đã xử lý ngoại lai như sau.

Result (Code: 57)

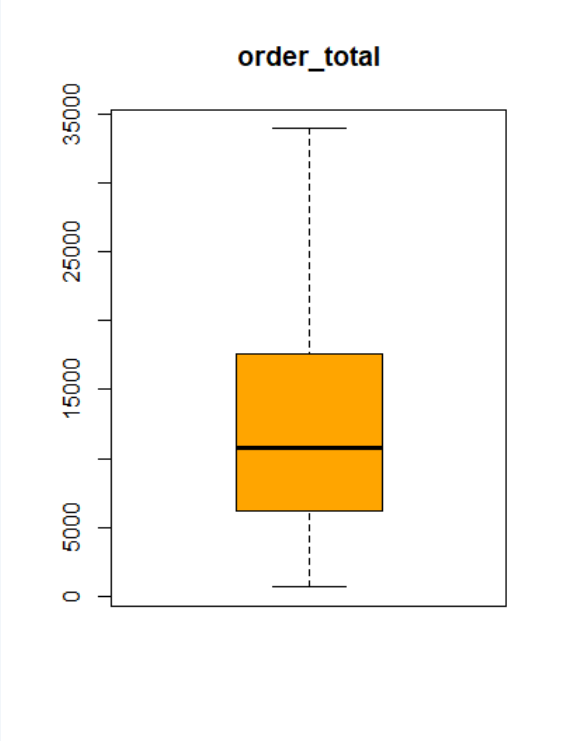

Từ hình ta nhận xét rằng sau khi xóa đi các giá trị ngoại lai, ta đã có thể quan sát được biến order_total trên sơ đồ Boxplot.

Tương tự như vậy, ta kiểm tra lần lượt các biến order_price, delivery_charges, distance_to_nearest_warehouse, coupon_discount, customer_long và customer_lat.

Result (Code: 62 → 68

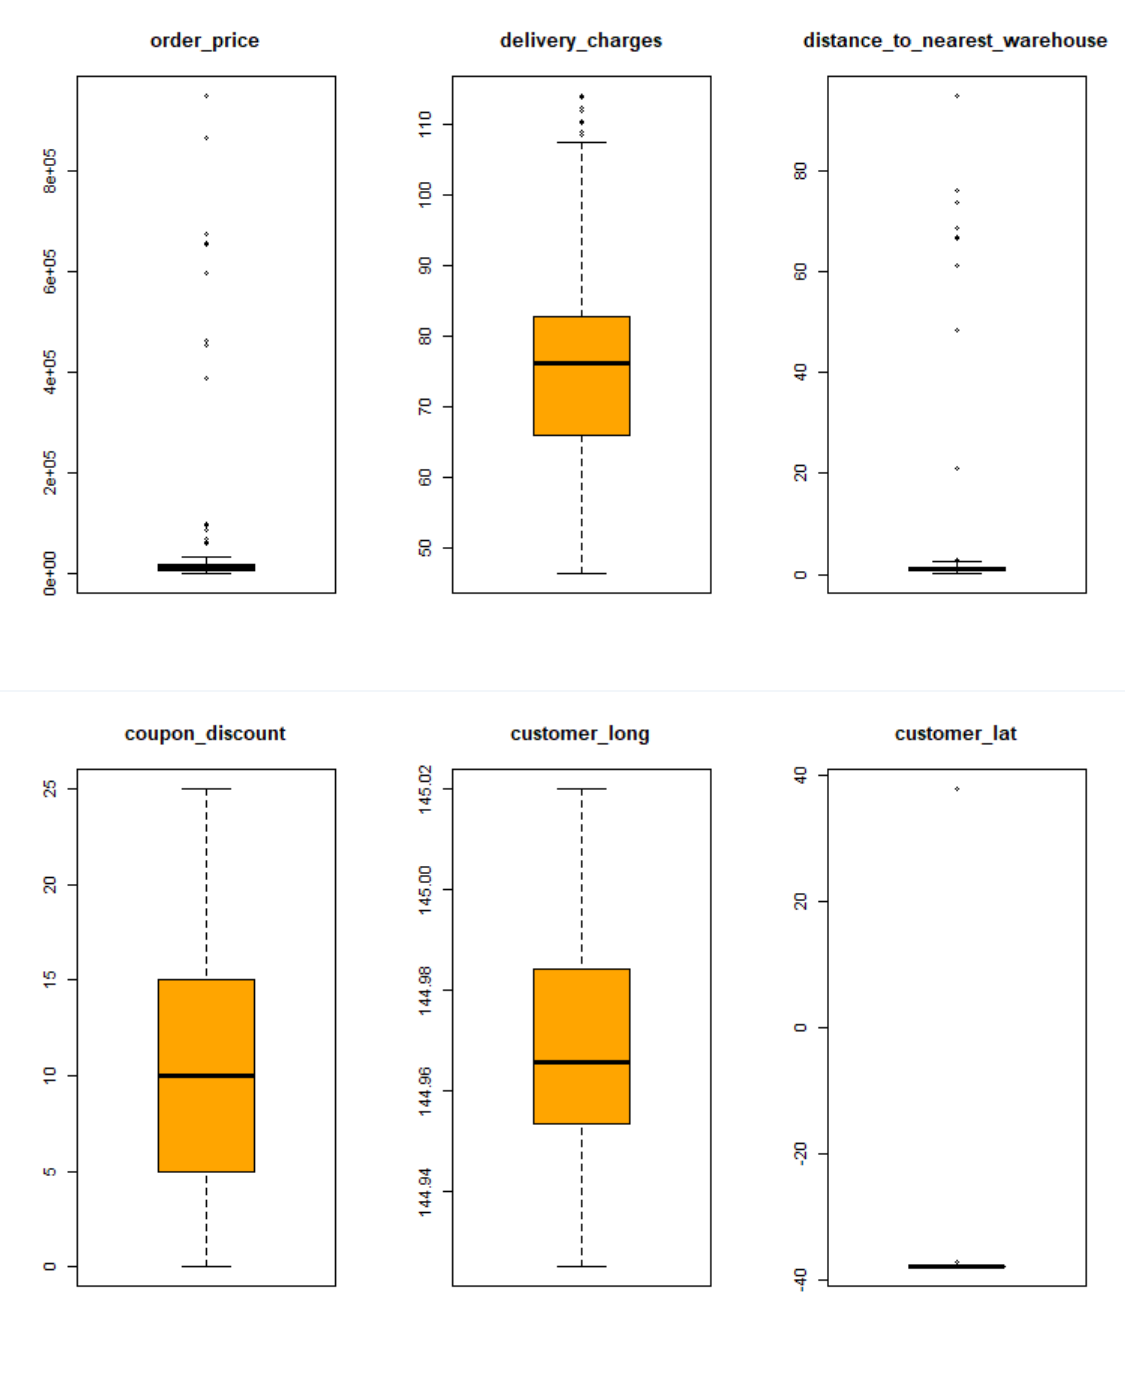

Dựa vào các đồ thị Boxplot được vẽ trên của các biến liên tục, ta thấy những biến cần được hiệu chỉnh để thuận tiện cho việc phân tích gồm các biến order_price, distance_to_nearest_warehouse và customer_lat. 3 đồ thị Boxplot mới sau khi được hiệu chỉnh.

Result (Code: 73 → 104)

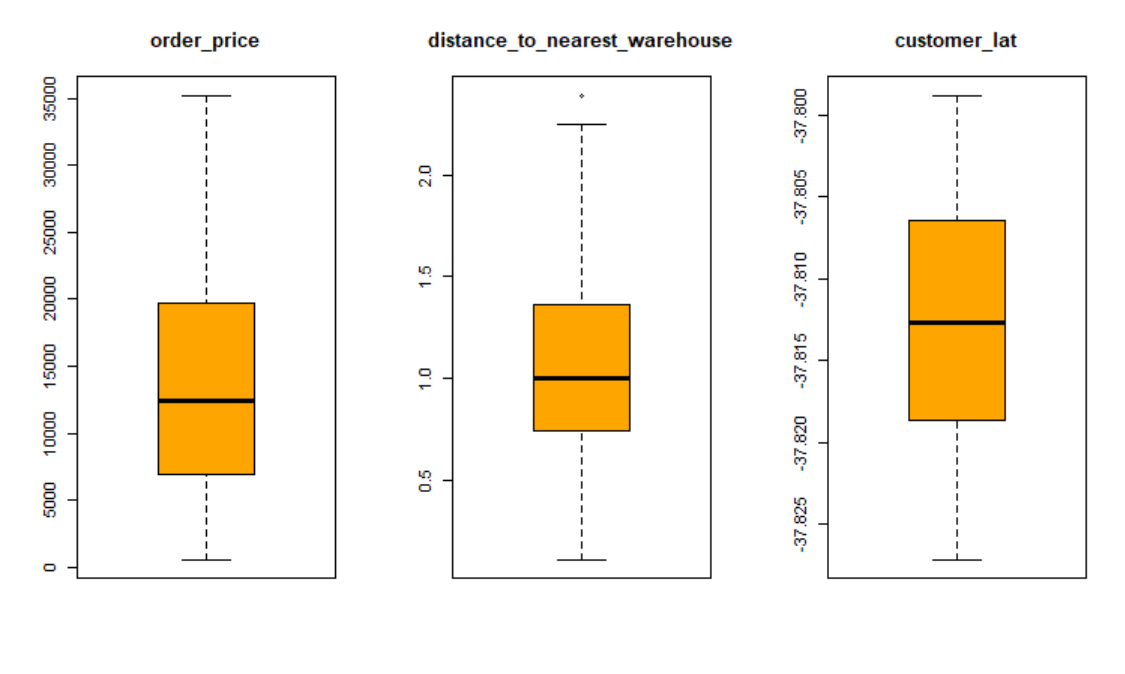

4.4 Mô tả dữ liệu bằng đồ thị

4.4.1 Đồ thị Histogram

Vẽ đồ thị Histogram thể hiện sự phân phối của các biến liên tục coupon_discount, order_price, distance_to_nearest_warehouse, order_total, delivery_charges, customer_lat và customer_long. Dưới đây là một số đồ thị của một số biến.

Result (Code: 107 → 114)

Các biểu đồ trên thể hiện phân bố tần suất của bốn biến trong tập dữ liệu: order_total, delivery_charges. Mỗi biểu đồ cho thấy các đặc điểm phân bố khác nhau, giúp ta hiểu rõ hơn về cấu trúc dữ liệu.

Biểu đồ **order_total** cho thấy tổng giá trị các đơn hàng có xu hướng phân bố lệch phải. Phần lớn các đơn hàng tập trung trong khoảng từ 10.000 đến 20.000, trong khi một số ít đơn hàng có giá trị cao hơn, vượt quá 30.000. Điều này cho thấy phần lớn các giao dịch thuộc mức trung bình, nhưng có một số đơn hàng lớn có thể cần được xem xét kỹ lưỡng.

Biểu đồ **delivery_charges** (chi phí giao hàng) lại có phân bố gần với dạng chuẩn, với đỉnh tần suất cao nhất nằm trong khoảng từ 70 đến 80. Chi phí giao hàng phân bố đều xung quanh giá trị trung tâm này, tuy nhiên có một vài giá trị ở hai đầu (50 và 110) có thể được xem xét là ngoại lệ. Điều này cho thấy phần lớn chi phí giao hàng rơi vào một khoảng giá cố định.

4.4.2 Đồ thị Boxplot

Vẽ biểu đồ Boxplot thể hiện sự phân phối của order_total theo các biến phân loại season, nearest_warehouse, is_happy_customer và is_expedited_delivery để ta xem những yếu tố xung quanh tác động đến order_total như thế nào. Và dưới đây là các đồ thị Boxplot ta có được.

Result (Code line: 117 -> 121)

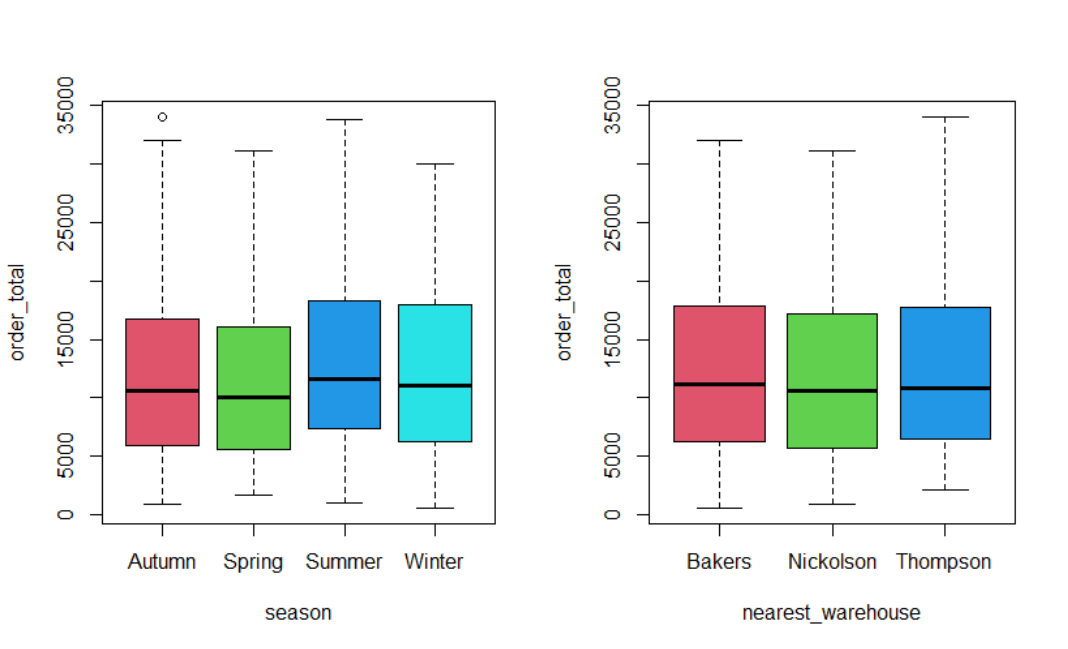

Theo biểu đồ phân phối theo season, tổng giá trị đơn hàng quá các mùa không có sự chênh lệch nhiều, trung bình dao động khoảng 10000 USD. Giá trị đơn hàng cao nhất

rơi vào mùa hạ với giá trị khoảng 18000 USD, giá trị đơn hàng thấp nhất thì là vào mùa xuân với khoảng 5500 USD.

Dựa vào biểu đồ bên phải, biểu đồ biểu thị sự phân phối theo nearest_warehouse, ta thấy được tổng giá trị đơn hàng cũng được phân bố đều giữa các kho hàng, với trung bình tổng đơn hàng cũng rơi vào khoảng 10000 USD. Điều này cho thấy được các kho hàng đều hoạt động ổn định với tổng số đơn hàng tương đương nhau, không có kho nào vượt trội hoặc yếu thế rõ rệt.

Qua các biểu đồ Boxplot ta xem xét về sự phân phối của order_total theo các biến phân loại khác, ta thấy có vẫn có sự chênh lệch với nhau quá các yếu tố nhưng chưa rõ ràng.

4.4.3 Đồ thị Plot

Vẽ biểu đồ phân tán thể hiện mối quan hệ tuyến tính giữa order_total theo các biến order_price, delivery_charges, coupon_discount, distance_to_nearest_warehouse, customer_long và customer_lat.

Dưới đây là các đồ thị thể hiện được mối quan hệ tuyến tính.

Result (Cide: 123 -> 135)

Ở biểu đồ bên trái, biểu đồ thể hiện mối quan hệ order_total và order_price, ta nhận thấy giữ chúng có mối quanh hệ tuyến tính rất mạnh, các điểm dữ liệu tập trung hầu hết trên một đường chéo. Điều này cho thấy tổng số đơn hàng gần như tỉ lệ thuận với giá trị đơn hàng với hệ số tương quan rất cao. Qua đó thể hiện sự phụ thuộc chặt chẽ giữa hai biến.

Ở biểu đồ bên phải, biểu đồ thể hiện mối quan hệ order_total và coupon_discount, ta thấy không có xu hướng rõ ràng hay tuyến tính giữa hai biến. Các số cụm điểm xuất hiện ở các giá trị cụ thể mức chiết khấu cố định của coupon_discount. Điều này cho thấy mức chiết khấu không có ảnh hưởng tuyến tính trực tiếp đến tổng số đơn hàng. Chứng minh rằng, mối quan hệ giữ order_total và coupon_discount rất yếu hoặc không tồn tại.ơ

4.4.4 Đồ thị ma trận tương quan

Ta vẽ ma trận tương quan giữa các biến định lượng với nhau xem mức độ tương quan giữa chúng như thế nào.

Result (Code: 136 → 138)

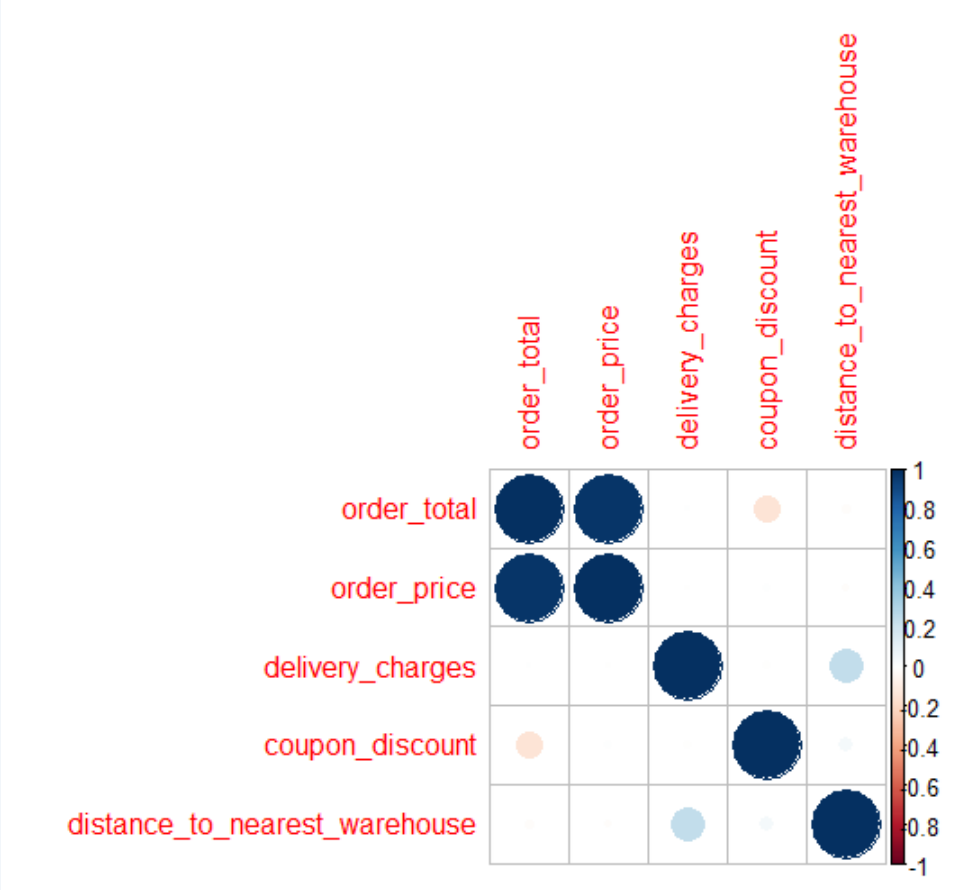

Dựa vào biểu đồ trên, ta nhận thấy sự tương quan giữa các biến với nhau khác rõ rệt. Giữa order_total và order_price có sự tương quan rất cao khoảng 0.98, cho thấy rằng tổng giá trị đơn hàng hầu như bị chi phối bởi giá trị của hàng hóa. Bên cạnh sự tương quan mạnh mẽ đó, giữ oder_total với coupon_discount có tương quan âm nhẹ với nhau khoảng -0.15, nghĩa là việc sử dụng mã giảm giá có xu hướng làm giảm tổng giá trị đơn hàng. Sự tương quan giữa các biến còn lại thì không đáng kể.

5 Thống kê suy diễn

5.1 Kiểm tra dữ liệu có phải tuân theo phân phối chuẩn không

Đầu tiên, ta cần kiểm tra xem các dữ liệu của ta có tuân theo quy luật phân phối chuẩn hay không bằng cách cho mức ý nghĩa là 5%, ta dùng lệnh shapiro.test để kiểm tra P_values. Nếu P_values > 0.05, thì cột dữ liệu đó tuân theo quy luật phân phối chuẩn và ngược lại.

Result (Cide: 144 -> 150)

```
data: fix_Data1$order_total
W = 0.95431, p-value = 2.283e-10
data: fix_Data1$order_price
W = 0.95541, p-value = 3.303e-10
data: fix_Data1$delivery_charges
W = 0.96343, p-value = 5.947e-09
data: fix_Data1$coupon_discount
W = 0.87822, p-value  2.2e-16
data: fix_Data1$distance_to_nearest_warehouse
W = 0.98648, p-value = 0.0004425
```

7 cột dữ liệu đề có P_values < 0.05, điều đó cho ta thấy cả 7 cột không tuân theo quy luật phân phối chuẩn nên nhóm sẽ không kiểm định t.test, z.test, ...

5.2 Mô hình hồi quy tuyến tính

Mô hình hồi quy bao gồm:

Biến phụ thuộc: order_total.

Biến độc lập: order_price, delivery_charges , coupon_discount, is_expedited_delivery, distance_to_nearest_warehouse, customer_long, customer_lat, season, is_happy_customer.

Vì trường hợp này ta có nhiều hơn hai biến, nên ta sẽ dùng đến phương trình hồi quy đa bội như sau:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + e; \qquad i = 1, 2, \ldots, n.$$

Để đánh giá mối quan hệ giữa order_total với các biến khác, ta tìm mô hình hồi quy giữ chúng như sau:

Result (Code: 154 → 156)

```
Residuals:
    Min      1Q  Median      3Q       Max
-2715.3  -420.9   -72.3   278.9   14986.1
Coefficients:
                                  Estimate  Std. Error  t value     Pr(>|t|)
(Intercept)                       1177e+03   4.421e+02    2.662   0.00805 **
order_price                      8.885e-01   6.778e-03  131.073  < 2e-16 ***
delivery_charges                 3.771e+00   7.322e+00    0.515      0.60680
distance_to_nearest_warehouse    7.299e+01   1.320e+02    0.553      0.58060
coupon_discount                 -1.337e+02   6.304e+00  -21.208  < 2e-16 ***
seasonSpring                    -1.077e+02   1.542e+02   -0.698      0.48549
seasonSummer                     2.299e+02   1.602e+02    1.435      0.15195
seasonWinter                    -2.028e+01   1.695e+02   -0.120      0.90481
nearest_warehouseNickolson       6.686e+01   1.459e+02    0.458      0.64702
nearest_warehouseThompson        1.354e+02   1.421e+02    0.953      0.34099
is_expedited_deliveryTrue       -5.747e+01   1.709e+02   -0.336      0.73686
is_happy_customerTrue            3.093e+01   1.511e+02    0.205      0.83797
---
Signif. codes:   0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error:  1126 on 424 degrees of freedom
Multiple R-squared:  0.9767, Adjusted R-squared: 0.9761
F-statistic:  1614 on 11 and 424 DF, p-value: < 2.2e-16
```

Từ phân tích mô hình hồi quy trên ta thấy những biến có liên hệ với order_total lần lượt là:

- order_price: X_1
- delivery_charges: X_2
- distance_to_nearest_warehouse: X_3
- coupon_discount: X_4
- seasonSpring: X_5
- seasonSummer: X_6
- seasonWinter: X_7
- near_warehouseNickolson: X_8
- near_warehouseThompson: X_9
- is_expedited_deliveryTrue: X_{10}
- is_happy_customerTrue: X_{11}

Và các hệ số hồi quy lận lượt là:

- $\beta_0 : 1.177e + 03$;
- $\beta_1 : 8.885e - 01$;
- $\beta_2 : 3.771e + 00$
- $\beta_3 : 7.299e + 01$
- $\beta_4 : -1.337e + 02$
- $\beta_5 : -1.077e + 02$
- $\beta_6 : 2.299e + 02$
- $\beta_7 : -2.028e + 01$
- $\beta_8 : 6.686e + 01$
- $\beta_9 : 1.354e + 02$
- $\beta_{10} : -5.747e{+}01$
- $\beta_{11} : 3.093e + 01$

Từ những số liệu về hệ số hồi quy ta thây vào công thức phương trình hồi quy tổng

quát, ta kết luận được rằng khi **order_price** tăng lên một đơn vị thì **order_total** sẽ tăng lên 8.885e-01 đơn vị, tương tự với các biến khác. Như vậy, ta thấy được mối liên hệ giữa các biến.

5.3 Kiểm định các hệ số β_i

Giả thuyết H_0: $\beta_i = 0$: Hệ số β_i không có ý nghĩa thống kê.

Đối thuyết H_1: $\beta_i \neq 0$: Hệ số β_i có ý nghĩa thống kê.

Ta nhận thấy rằng p-giá trị ứng với các biến **distance_to_nearest_warehouse, delivery_charges**, ... lớn hơn mức ý nghĩa 5% nên ta chưa bác bỏ được H_0. Vậy hệ số β_i ứng với các biến này bằng 0 (không có ý nghĩa thống kê). Tức là các biến này không ảnh hưởng **order_total**. Ta sẽ xem xét loại bỏ các biến này ra khỏi mô hình.
Ta xây dựng model_2 bỏ đi các biến nghi ngờ không phụ thuộc từ model_1.

Result (Code: 159 → 160)

```
Residuals:
    Min      1Q  Median      3Q     Max
-2880.9  -426.9   -66.4   236.6  15238.3
Coefficients:
                    Estimate  Std. Error  t value     Pr(>|t|)
(Intercept)        1.633e+03   1.251e+02    13.05   <2e-16 ***
order_price        8.890e-01   6.733e-03   132.04   <2e-16 ***
coupon_discount   -1.336e+02   6.243e+00   -21.39  < 2e-16 ***
---
Signif. codes:   0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error:  1123 on 433 degrees of freedom
Multiple R-squared:  0.9763, Adjusted R-squared: 0.9762
F-statistic:  8922 on 2 and 433 DF, p-value: < 2.2e-16
```

Ta so sánh model_1 và model_2 ta đưa ra được nhận xét:

Giả thuyết H_0: Mô hình model_2 hiệu quả hơn.

Đối thuyết H_1: Mô hình model_1 hiệu quả hơn.

Để có thể lựa chọn ra model nào tối ưu nhất, ta xét cả 2 model này bằng anova.

Result (Code: 161)

```
Model 1:
order_total ~ order_price + delivery_charges + distance_to_nearest_warehouse +
coupon_discount + season + nearest_warehouse + is_expedited_delivery +
is_happy_customer
Model 2:
order_total ~ order_price + coupon_discount
    Res.Df     RSS     Df  Sum of Sq     F    Pr(>F)
 1    424   537111679   -      -        -      -
 2    433   545627678  -9   -8515999   0.747  0.6658
```

Nhận xét: Ta nhận thấy p = 0.6658 lớn hơn mức ý nghĩa 5%, nên ta chưa bác bỏ được H_0, vậy nên mô hình model_2 hiệu quả hơn.

Từ mô hình hồi quy bội ta có những giả định cần được xác thực như sau:

- Mối quan hệ giữ biến dự báo X và biến phụ thuộc Y được giả sử là tuyến tính.
- Sai số có kỳ vọng bằng 0.
- Phương sai của các sai số là hằng số.
- Sai số phân phối chuẩn $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.
- Các sai số $\varepsilon_1,\ \varepsilon_2,\ \ldots,\ \varepsilon_n$ thì độc lập.

Result (Code: 163 → 165)

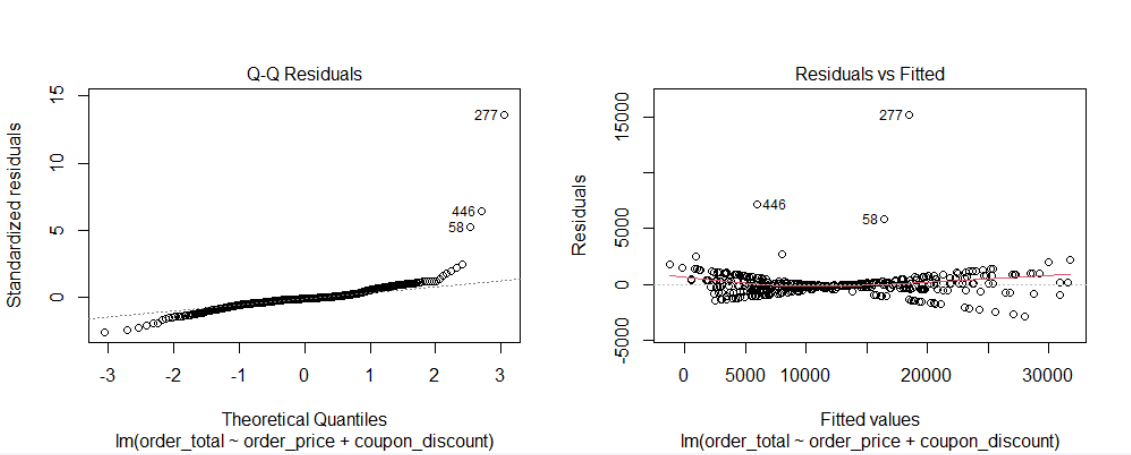

Biểu đồ Q-Q Residuals

Nhận xét: Vẽ các sai số hồi quy được chuẩn hoá, dùng để kiểm tra giả định sai số có phân phối chuẩn. Theo như biểu đồ trên, các quan trắc tương đối nằm trên đường thẳng kỳ vọng phân phối chuẩn, nên giả định Sai số có phân phối chuẩn thoả mãn.

Biểu đồ Residuals vs Fitted

Nhận xét: Vẽ các sai số hồi quy tương ứng với giá trị dự báo, dùng để kiểm tra giả định. Dựa vào biểu đồ ta thấy đường màu đỏ tương đối là đường thẳng nằm ngang nên giả định Y và các biến độc lập X có quan hệ tuyến tính thoả mãn. Đường màu đỏ tương đối nằm sát đường y = 0 nên ta giả định Sai số có kỳ vọng bằng 0 thoả mãn. Các giá trị sai số phân tán ngẫu nhiên dọc theo đường màu đỏ, nên giả định Phương sai các sai số là hằng số thoả mãn.

Result (Code: 163 → 165)

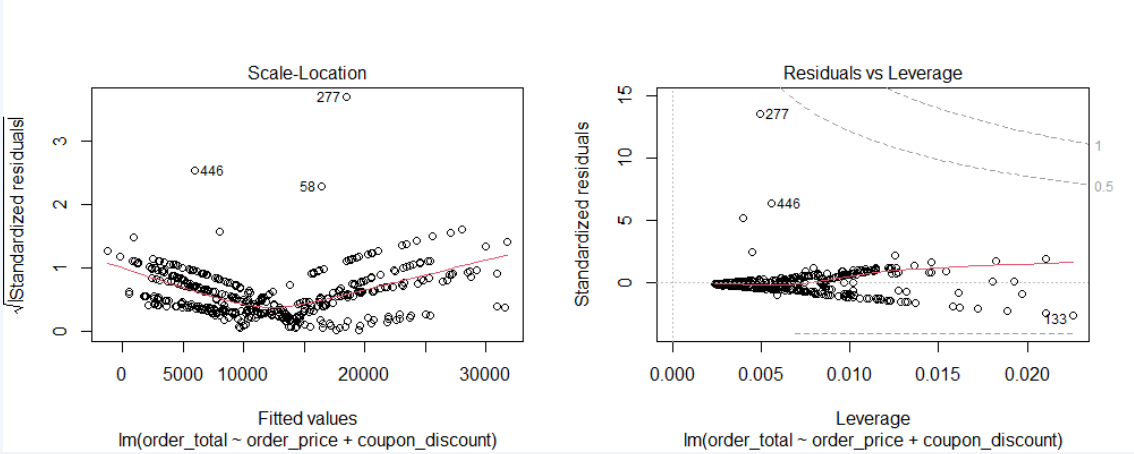

Biểu đồ Scale-Location

Nhận xét: Vẽ căc bậc 2 các sai số được chuẩn hoá, dùng để kiểm tra giả định phương sai các sai số là hằng số. Dựa vào kết quả của biểu đồ, Các giá trị sai số phân tán ngẫu nhiên dọc theo đường màu đỏ, nên giả định Phương sai các sai số là hằng số thoả mãn.

Biểu đồ Residuals vs Leverage

Nhận xét: Vẽ ra những điểm có gây ảnh hưởng cao trong bộ dữ liệu, cụ thể là các điểm 277, 446, 133. Tuy nhiên không có điểm nào vượt ra khỏi đường Cook's distance. Vì vậy, ta không cần phải loại bỏ các điểm ra khỏi bộ dữ liệu.

5.4 Mô hình hồi quy tuyến tính về sự ảnh hưởng các nhân tố lên order_total

Result (Code: 168 → 198)

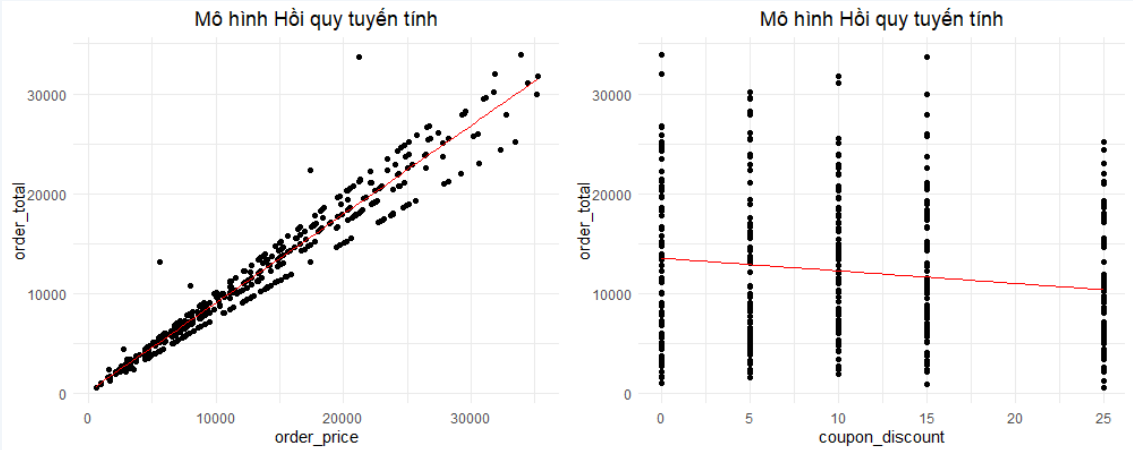

order_total = 1.633e+03 + 8.890e-01 × order_price - 1.336e+02 × coupon_discount

Hệ số xác định hiệu chỉnh (Adjusted R-squared): R^2 hiệu chỉnh = 0.9763 nghĩa là 97.63% sự biến thiên trong tổng chi phí order_total được giải thích bởi các biến độc lập.

6 Nguồn dữ liệu và nguồn code

Link dữ liệu:

https://www.kaggle.com/datasets/muhammadshahrayar/transactional-retaildataset-of-electronics-store?select=dirty_data.csv

Link code: GITHUB

Tài liệu tham khảo

1. Hoàng Văn Hà, Bài giảng Xác suất Thống Kê.
2. Nguyễn Thị Mộng Ngọc, Bài giảng Xác suất Thống Kê.
3. Nguyễn Tiến Dũng (chủ biên), Nguyễn Đình Huy, Xác suất - Thống kê & Phân tích số liệu, 2019.
4. Introductory Statistic with R, J. Jambers - D. Hand - W. Hardle.
5. Applied Statistics with R, 2020.
6. Phan Thị Hường, Bài giảng Xác suất Thống Kê
7. Nguyễn Đình Huy, GIÁO TRÌNH XÁC SUẤT VÀ THỐNG KÊ, NHÀ XUẤT BẢN ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH, 2023